Chapter 1

Basic Conception

AI发展历程 & 基本要素

人工智能主要任务类别

线性回归 & 逻辑回归

深度学习 & 全连接网络

准确判断房屋价格应该怎么做呢?

收集信息，信息越丰富越好!

学区房	景观房	商业中心
医疗条件	居民经济条件	交通情况
房型结构	房屋面积	……

用机器学习的方法解决回归问题

案例研究

1978波士顿区域房价预测

3.1 波士顿房价预测问题——If…else…方法

步骤1：数据准备

1978年波士顿区域房屋价格表

x_1：犯罪率（%）	0.00632	0.02731	0.02729	0.03237	0.06905
x_2：大住宅用地占比（%）	18.00	0.00	0.00	0.00	0.00
x_3：非零售商业用地占比（%）	2.31	7.07	7.07	2.18	2.18
x_4：景观房（0/1）	0	0	0	0	0
x_5：氮氧化物浓度（ppm）	0.538	0.469	0.469	0.458	0.458
x_6：平均房间数（个）	6.575	6.421	7.185	6.998	7.147
x_7：老旧房屋占比（%）	65.2	78.9	61.1	45.8	54.2
x_8：离就业中心的加权距离	4.09	4.9671	4.9671	6.0622	6.0622
……	……	……	……	……	……
y：房价中位数（千美元）	**24.00**	**21.6**	**34.7**	**33.4**	**36.2**

Harrison, D. and Rubinfeld, D.L. "Hedonic prices and the demand for clean air", J. Environ. Economics & Management, vol.5, 81-102, 1978.

3.1 波士顿房价预测问题——If…else…方法

步骤2：分析数据，发现规律，构建规则（人工）

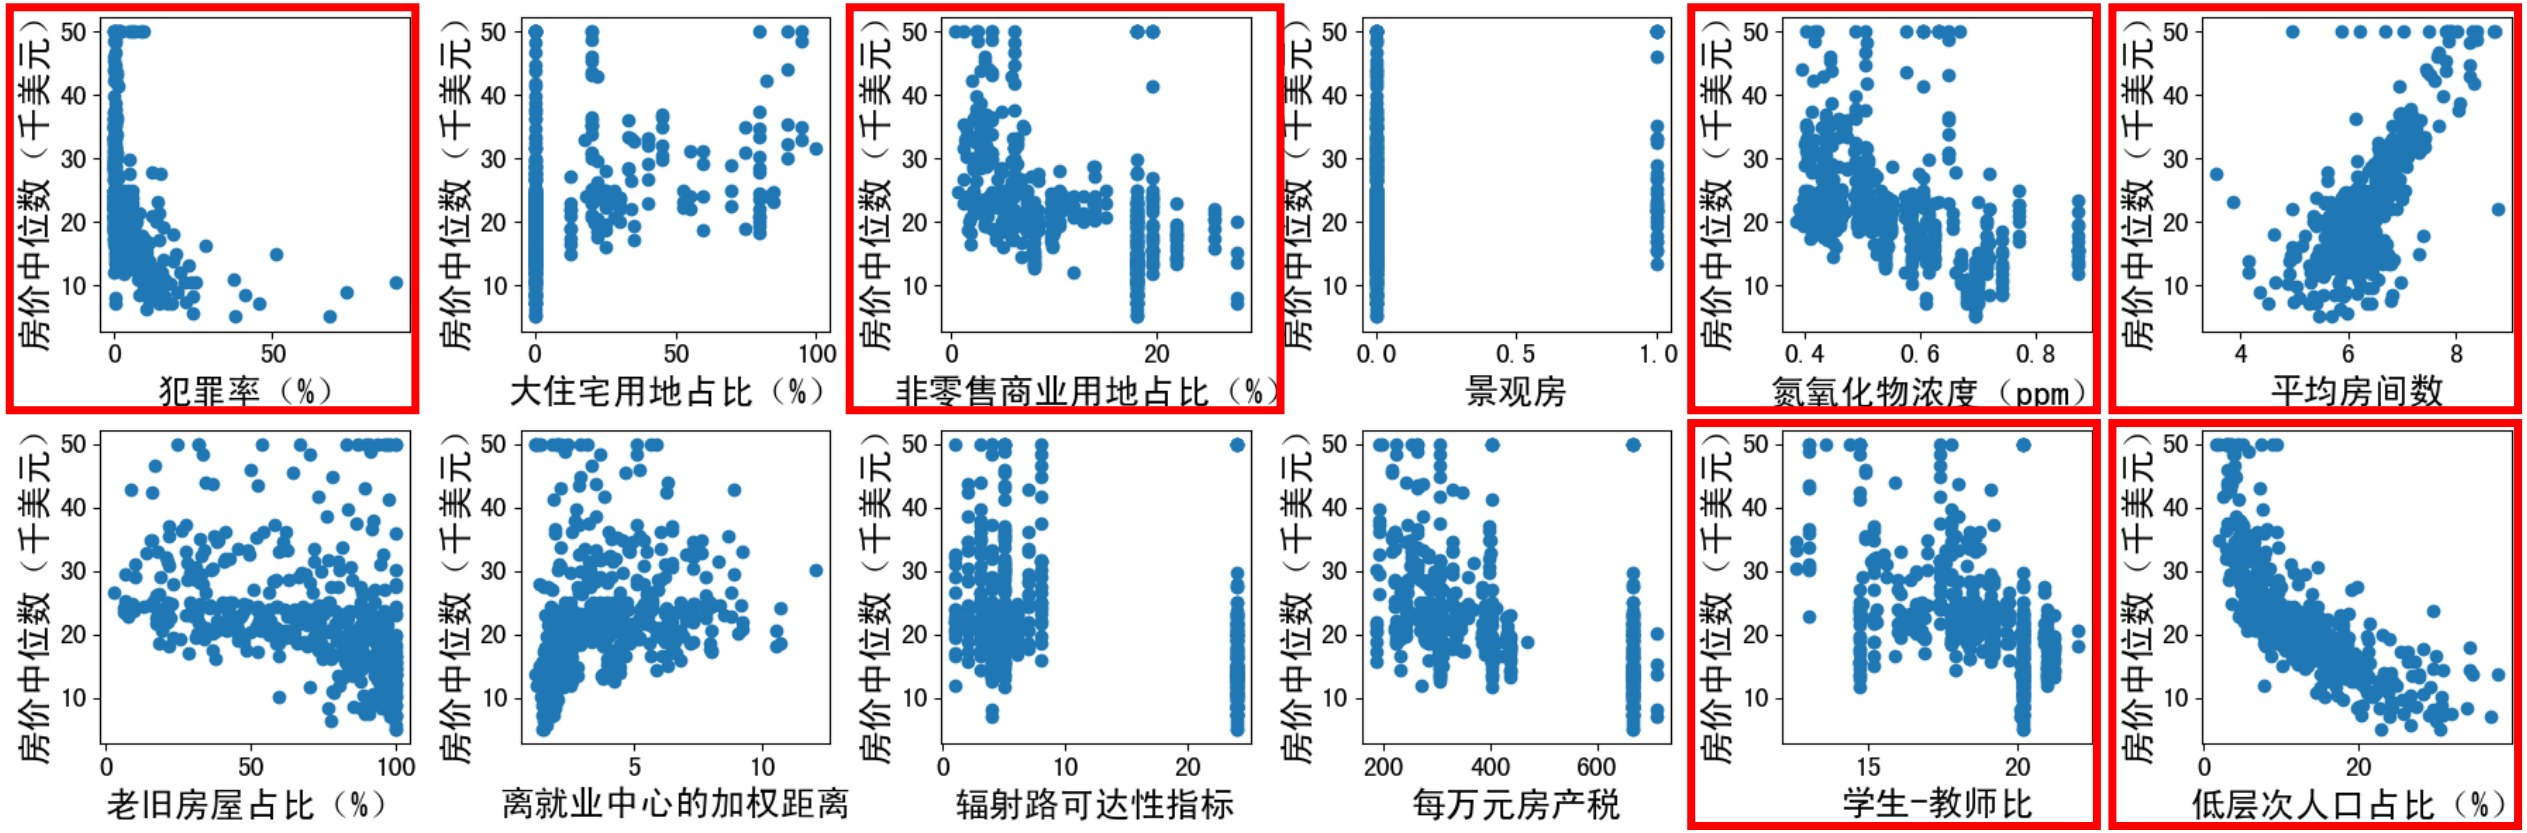

部分特征与房价明显相关，部分特征有一定影响

3.1 波士顿房价预测问题——If…else…方法

步骤2：分析数据，发现规律，构建规则（人工）

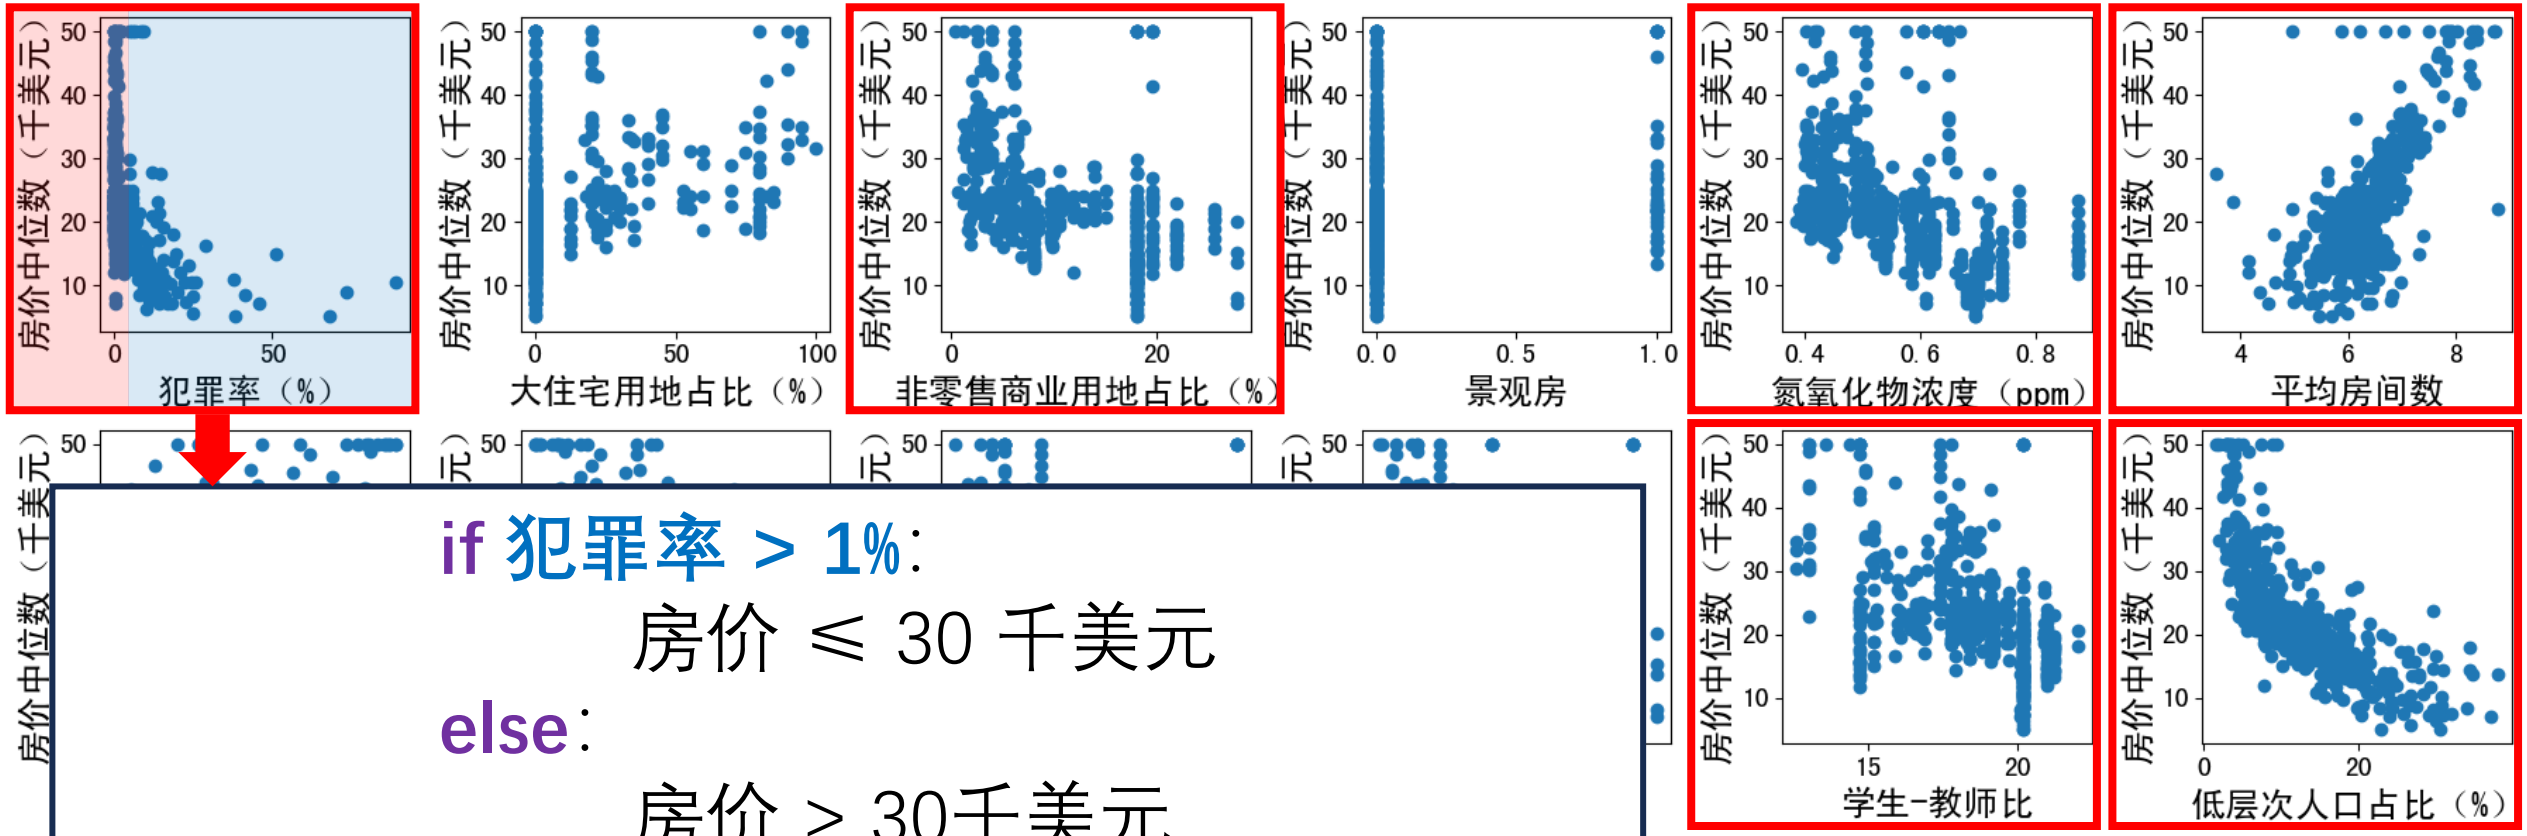

if 犯罪率 > 1%:

房价 ≤ 30 千美元

else:

房价 > 30千美元

3.1 波士顿房价预测问题——If…else…方法

步骤2：分析数据，发现规律，构建规则（人工）

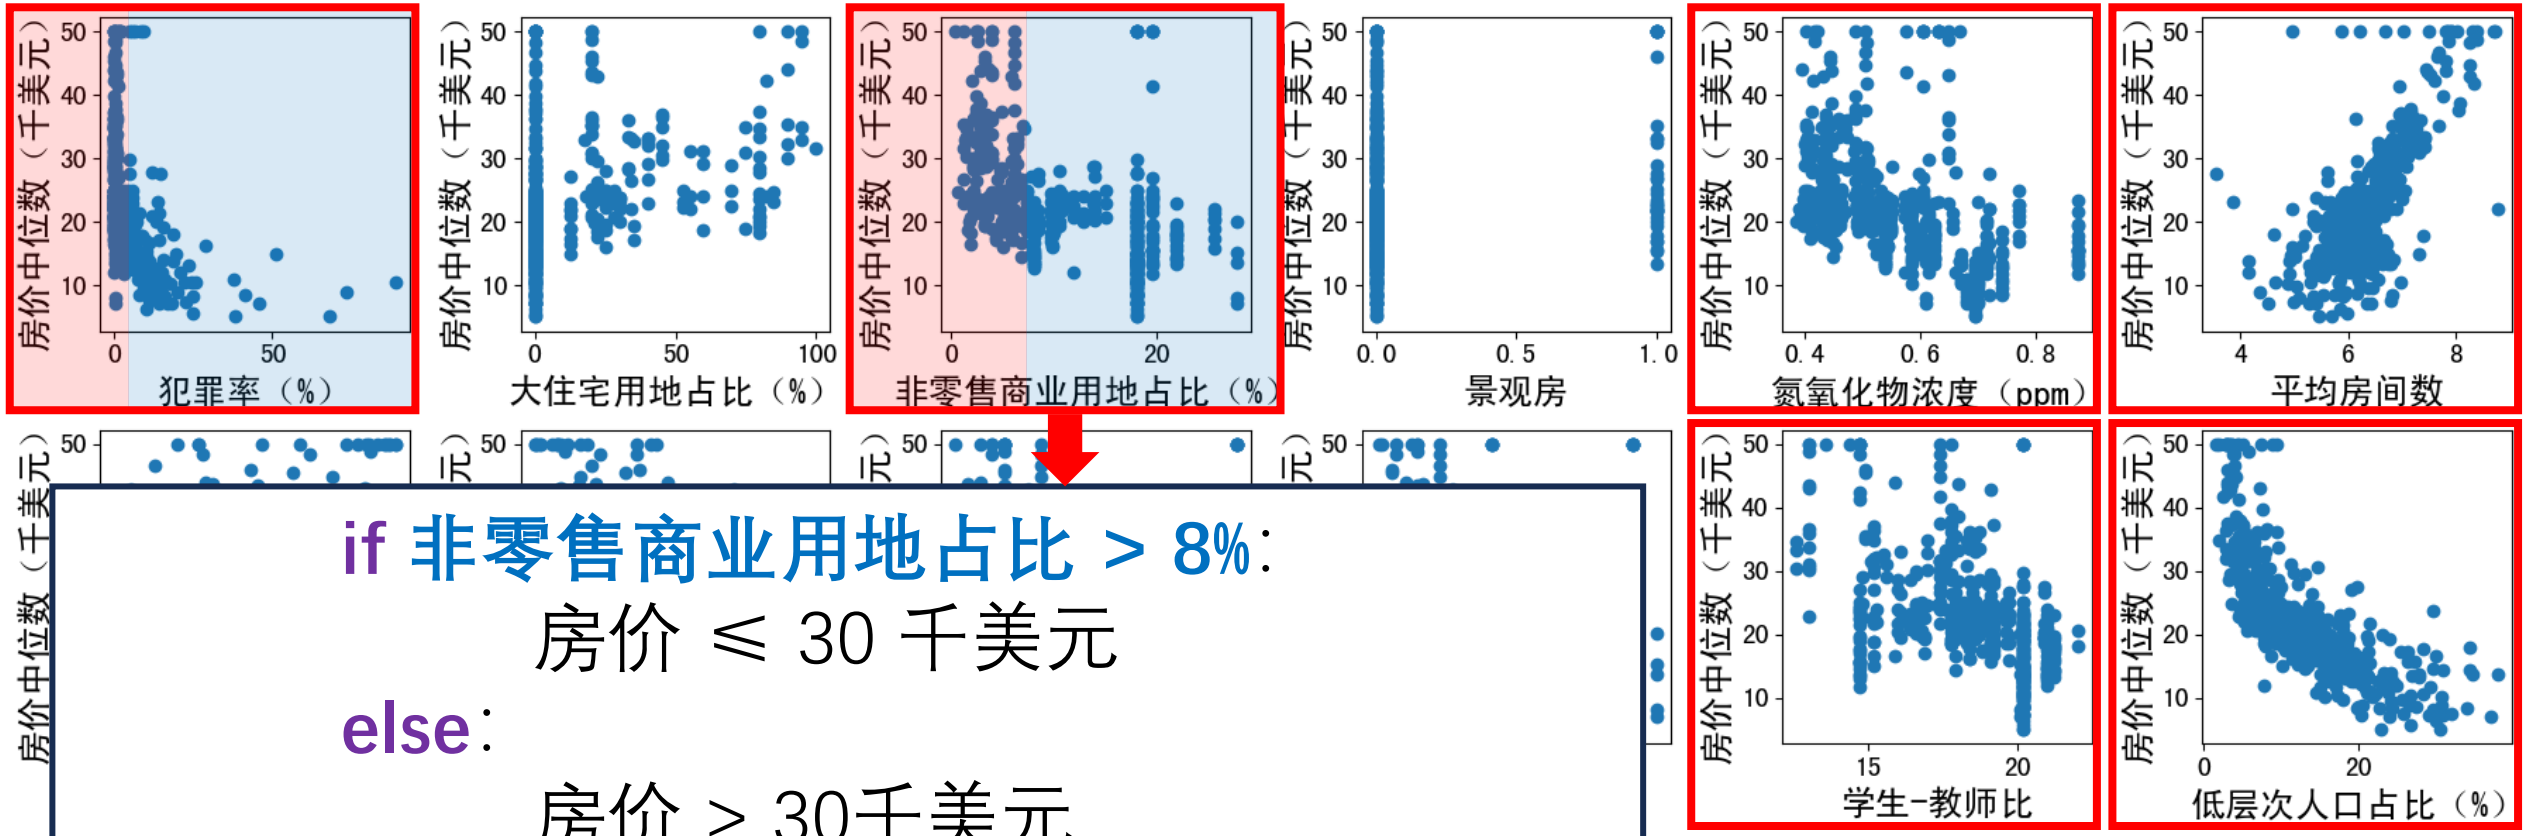

if 非零售商业用地占比 > 8%：

房价 ≤ 30 千美元

else：

房价 > 30千美元

3.1 波士顿房价预测问题——If…else…方法

步骤2：分析数据，发现规律，构建规则（人工）

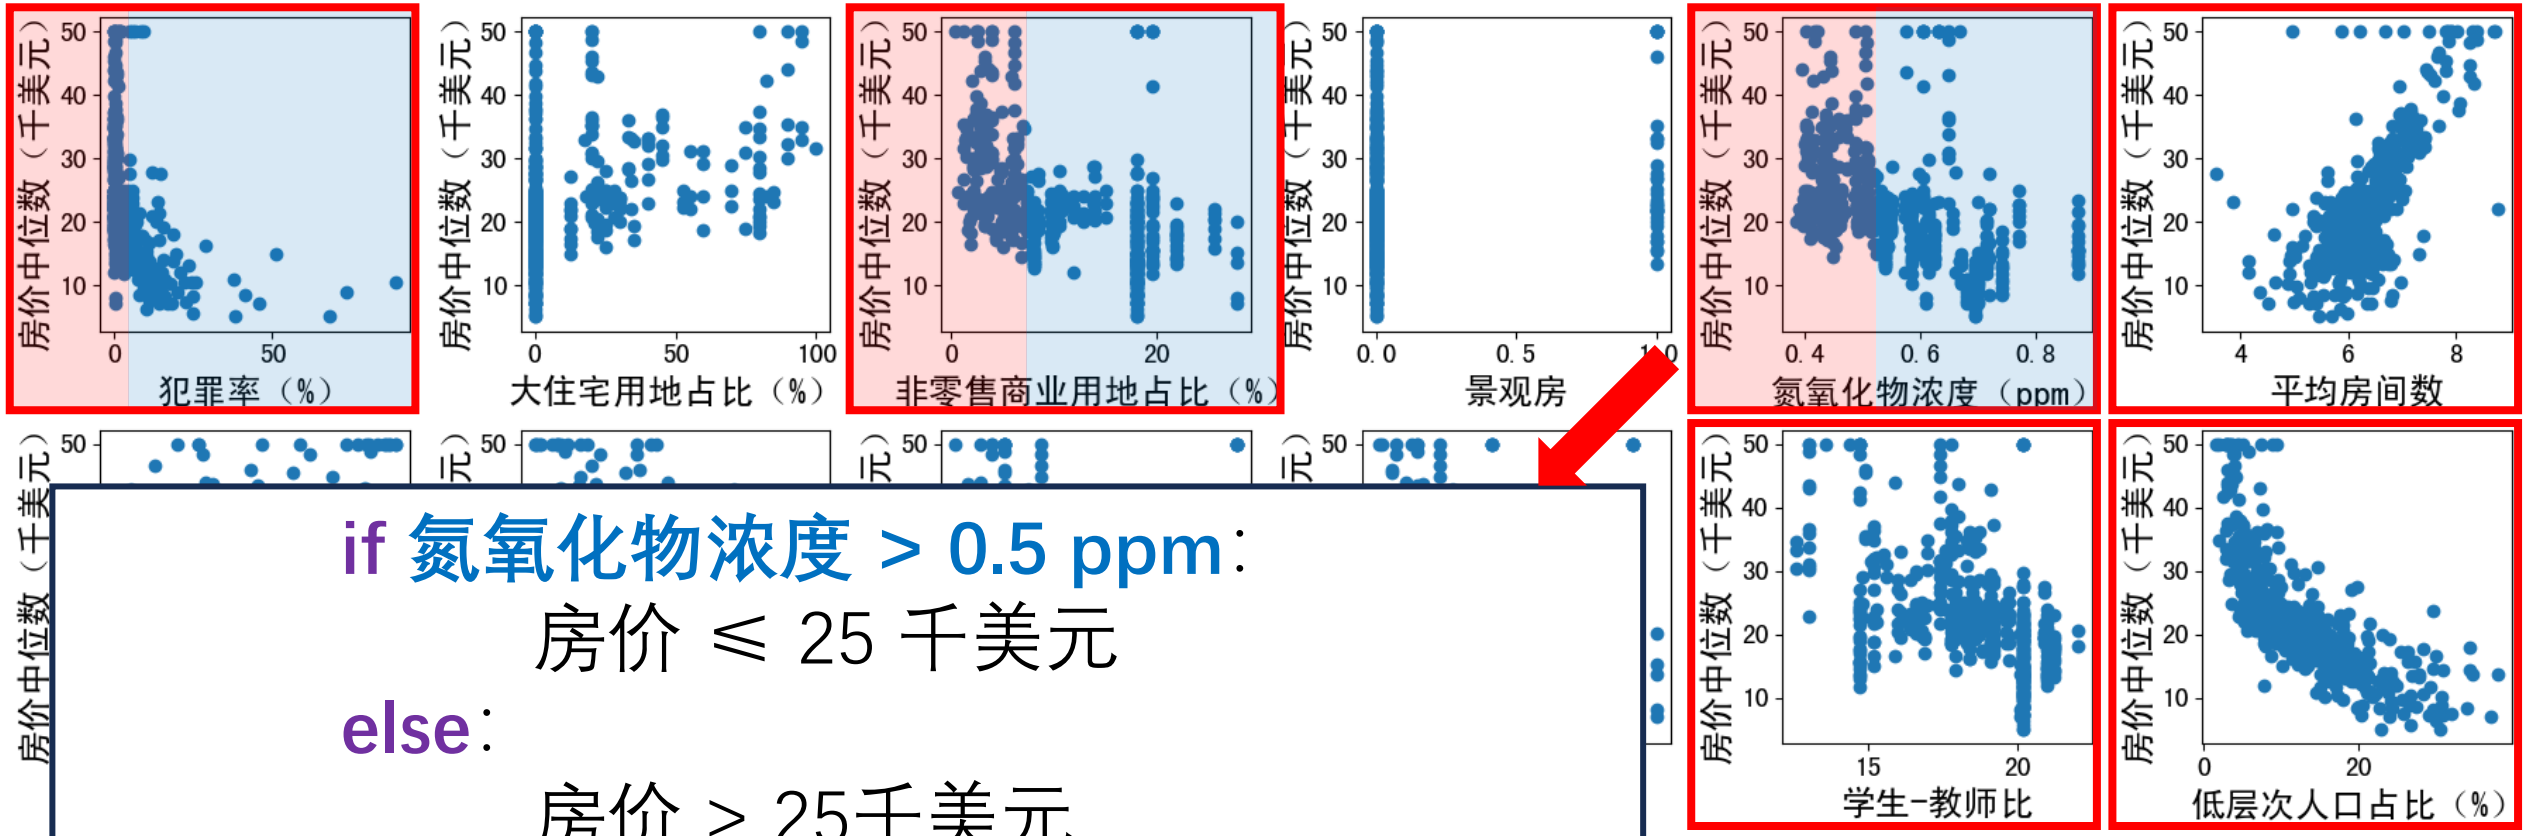

if 氮氧化物浓度 > 0.5 ppm：

房价 ≤ 25 千美元

else：

房价 > 25千美元

3.1 波士顿房价预测问题——If…else…方法

步骤2：分析数据，发现规律，构建规则（人工）

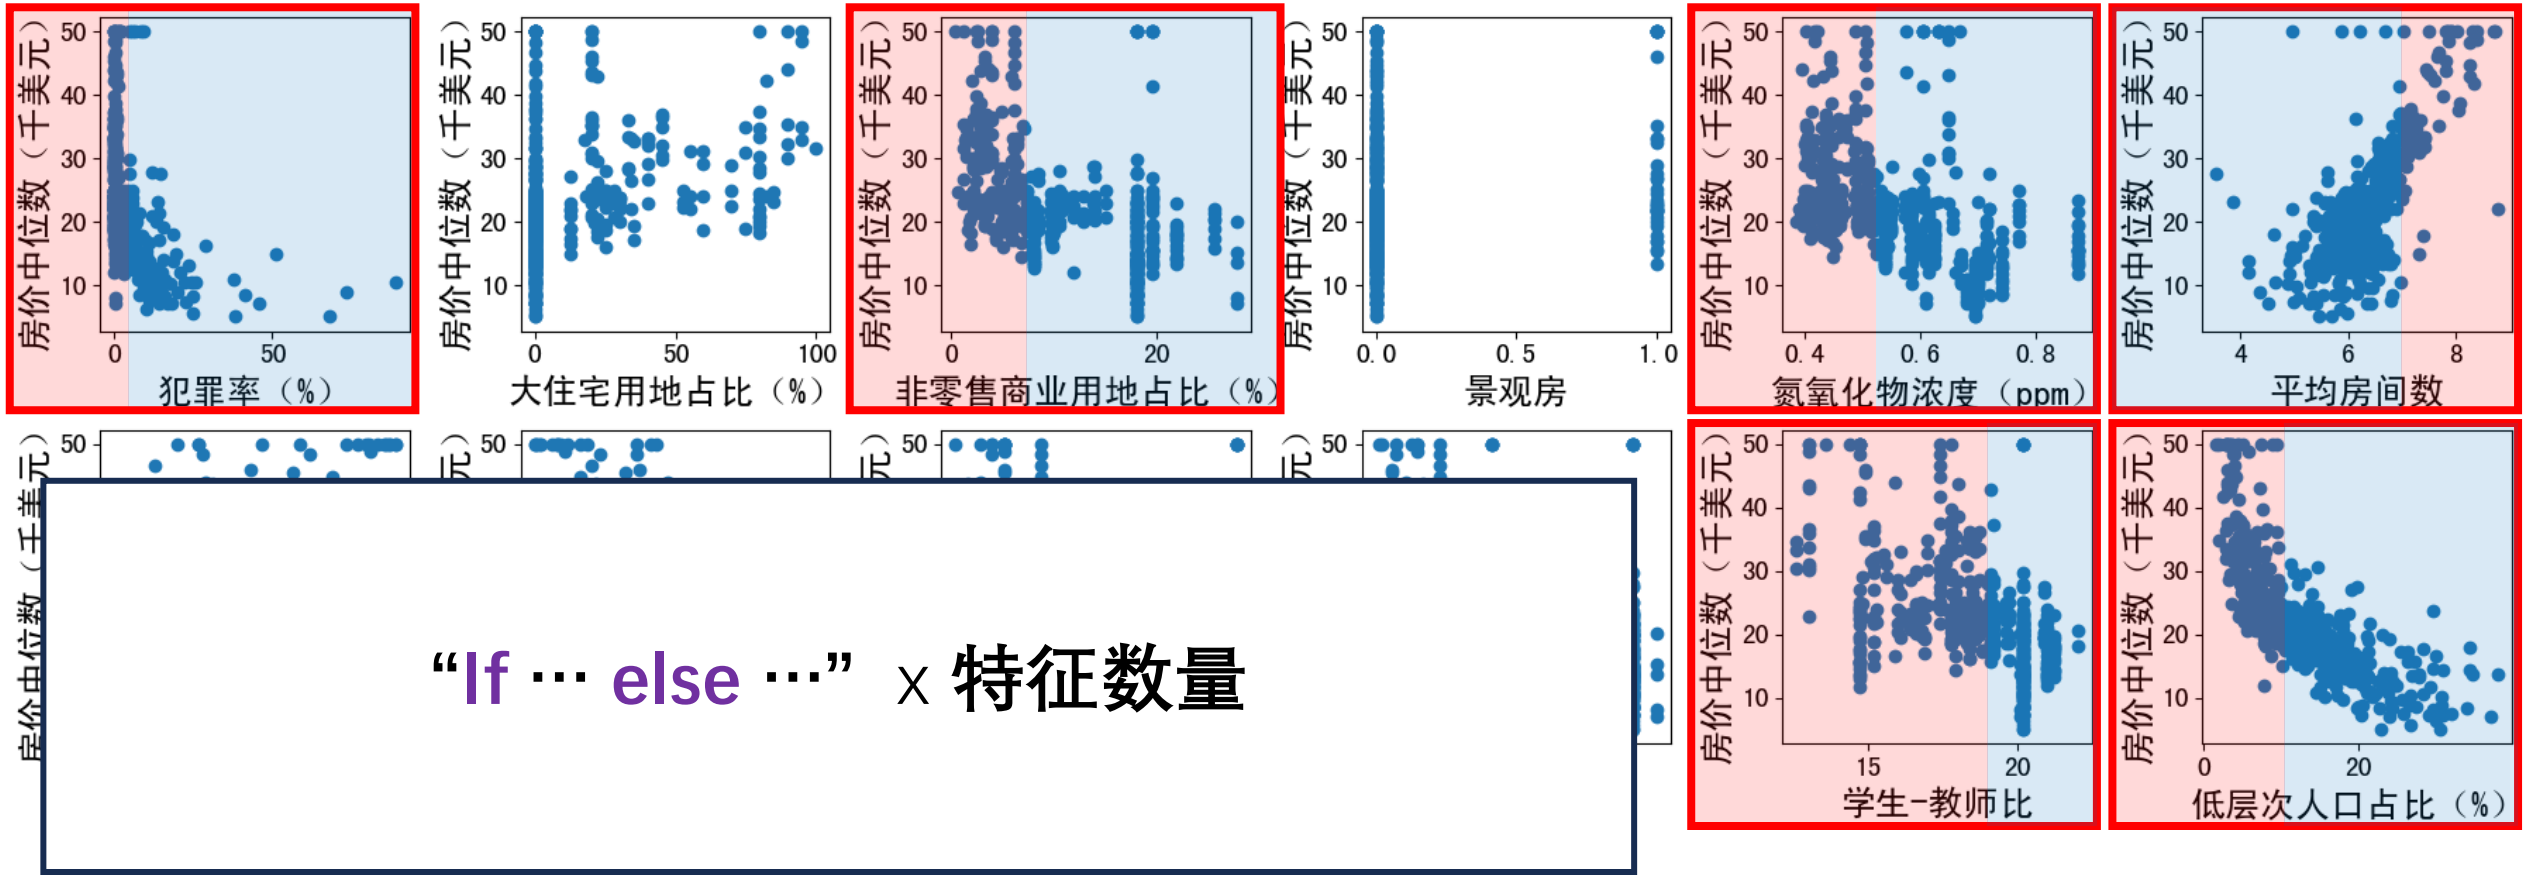

“If … else …” x 特征数量

3.1 波士顿房价预测问题——If…else…方法

步骤3：根据专家知识，编写推理引擎

if 犯罪率 < 0.05% & 非零售商业用地 < 2% & 氮氧化物浓度 < 0.4 ppm & …:
　　房价 > 50 千美元
else if 0.05% < 犯罪率 < 0.1% & 非零售商业用地 < 2% & 氮氧化物浓度 < 0.4 ppm & … :
　　50 千美元 ≥ 房价 > 45 千美元
else if 0.05% < 犯罪率 < 0.1% & 2% < 非零售商业用地 < 4% & 0.4 ppm < 氮氧化物浓度 < 0.5 ppm & … :
　　45 千美元 ≥ 房价 > 40 千美元
else if 0.1% < 犯罪率 < 0.2% & 4% < 非零售商业用地 < 8% & 0.4 ppm < 氮氧化物浓度 < 0.5 ppm & … :
　　40 千美元 ≥ 房价 > 35 千美元
else if 0.1% < 犯罪率 < 0.2% & 4% < 非零售商业用地 < 8% & 0.5 ppm < 氮氧化物浓度 < 0.6 ppm & … :
　　35 千美元 ≥ 房价 > 30 千美元
……

容易理解，但是极其复杂，难以用于其它的情况（难泛化）

3.1 波士顿房价预测问题——If…else…方法

步骤2：分析数据，发现规律，构建规则（人工）

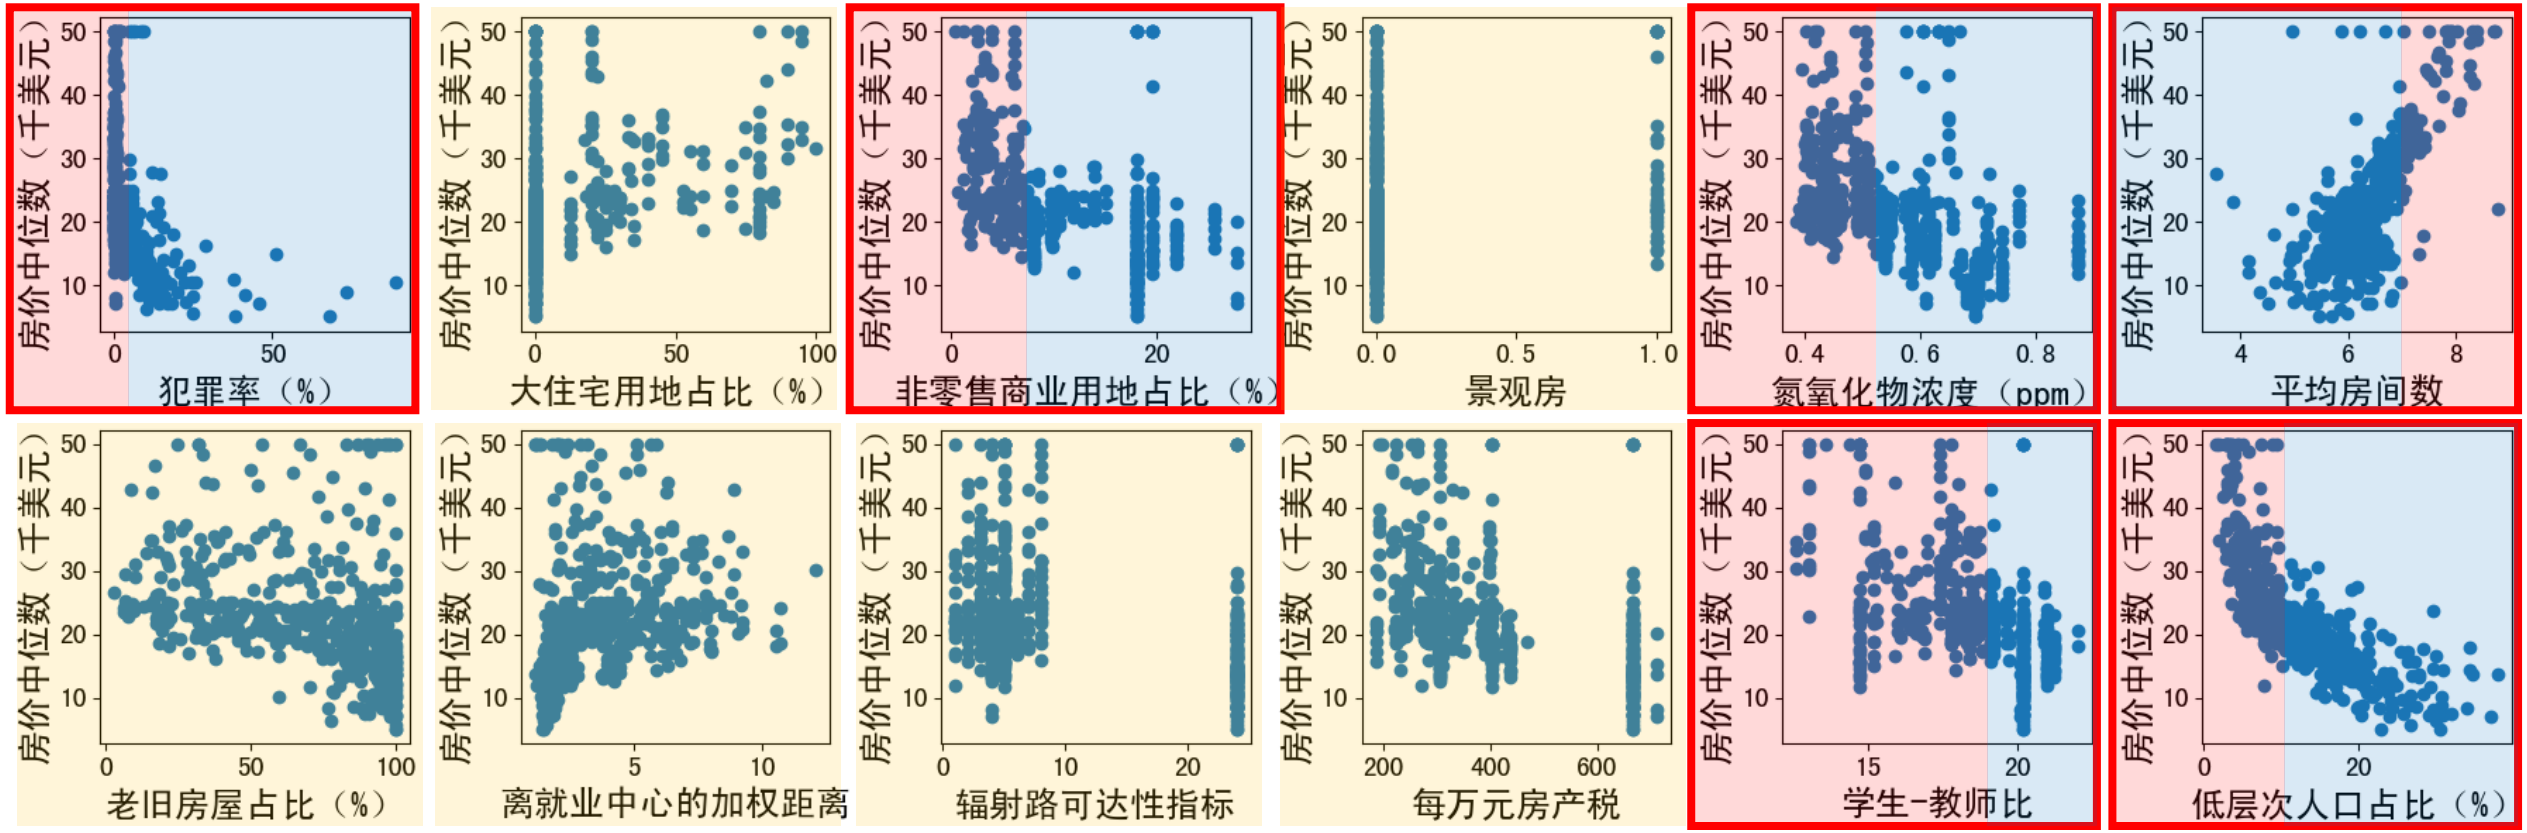

容易忽视其它特征的影响

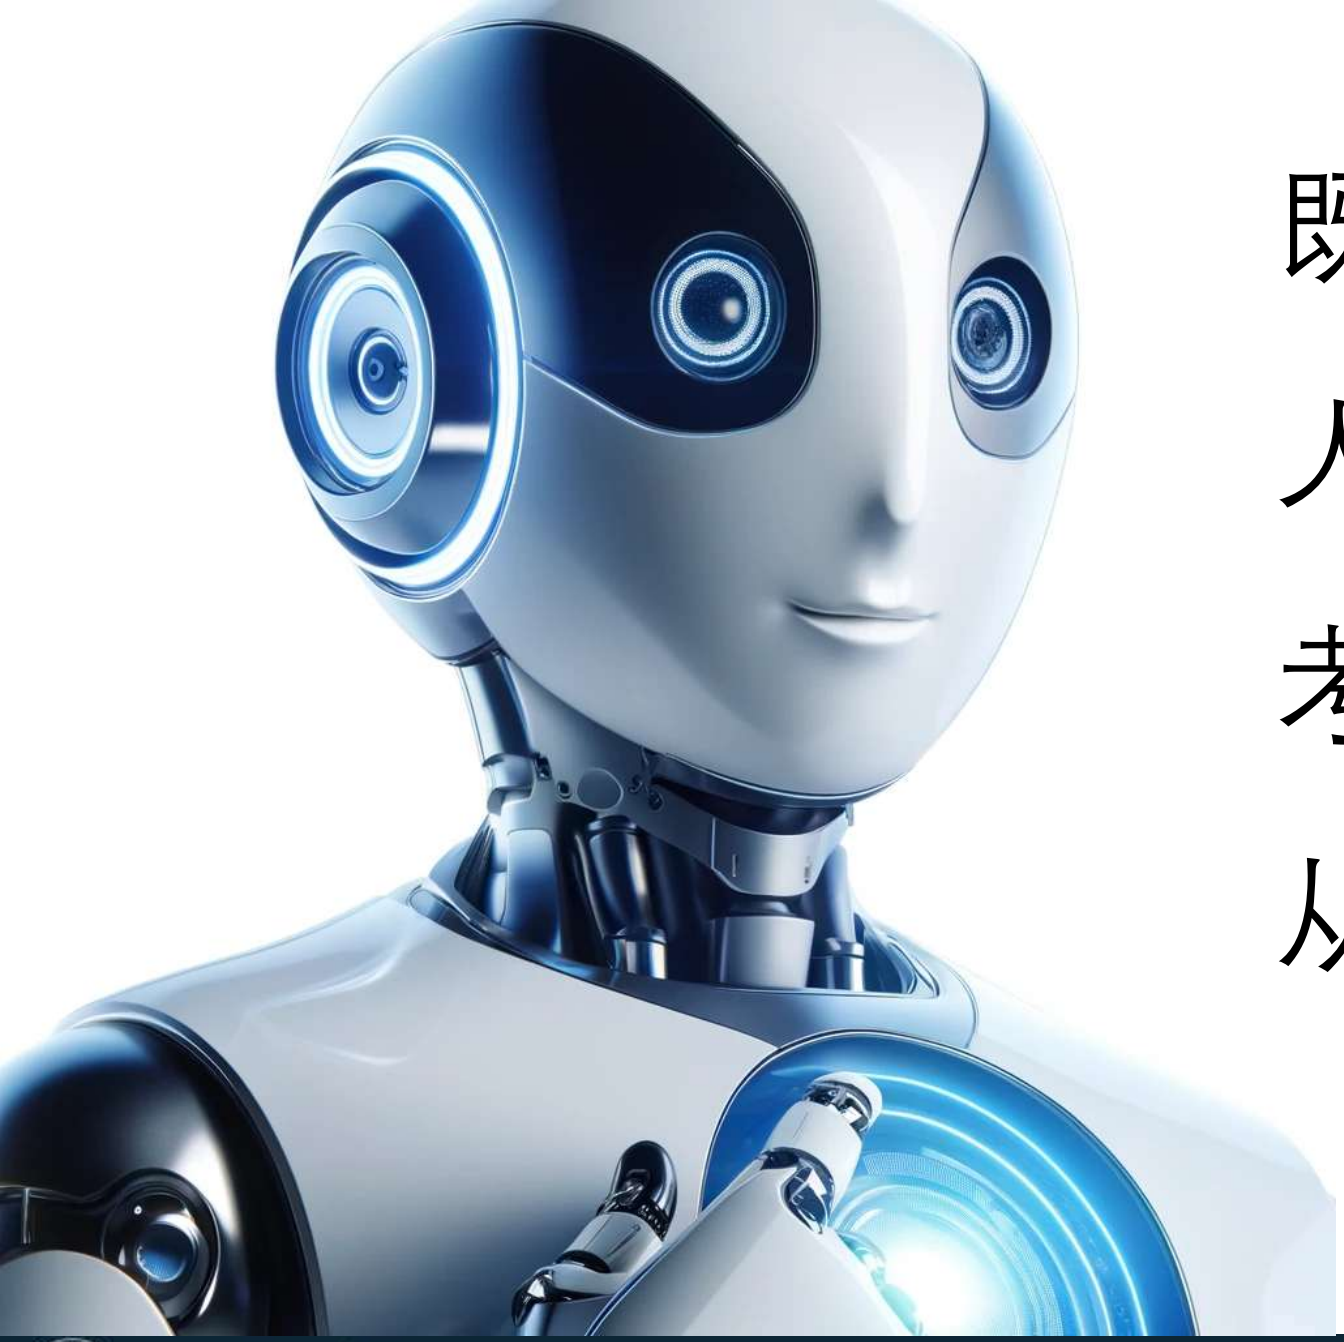

既然这么繁琐复杂，

人类，要不……

考虑一下让机器

从数据中学习规律

3.2 波士顿房价预测问题——机器学习方法

一大堆数据

- 输入：房价特征
- 输出：房价（标签）
- 定义问题形式
- 阐述正确的结果

x：平均房间数（个）	y：房价中位数（千美元）
6.575	24.00
6.421	21.60
7.185	34.70
…	…

3.2 波士顿房价预测问题——机器学习方法

一大堆数据

- 输入：房价特征
- 输出：房价（标签）
- 定义问题形式
- 阐述正确的结果

一堆模型
$f_1, f_2, \dots, f_n$

- $y = \Sigma\alpha x + \beta$，$x$是特征值
- f由参数α和β定义

$$f_1 \rightarrow y = 3.5x + 2$$

$$f_2 \rightarrow y = 1.5x + 3$$

- f有无数的可能

3.2 波士顿房价预测问题——机器学习方法

一大堆数据 → 选择最优模型 ← 一堆模型 $f_1, f_2, \dots, f_n$

- 输入：房价特征
- 输出：房价（标签）
- 定义问题形式
- 阐述正确的结果

平均房间数	6.575	6.421	7.185
房价（千美元）	**24**	**21.6**	**34.7**

✓

25.0	24.5	27.1

✗

12.9	13.6	13.8

- $y = \Sigma\alpha x + \beta$，$x$是特征值
- f由参数α和β定义

$f_1 \rightarrow y = 3.5x + 2$

$f_2 \rightarrow y = 1.5x + 3$

- f有无数的可能

3.2 波士顿房价预测问题——机器学习方法

一大堆数据 → 选择最优模型 ← 一堆模型 $f_1, f_2, \dots, f_n$

- 输入：房价特征
- 输出：房价（标签）

- $y = \Sigma\alpha x + \beta$，$x$是特征值
- f由参数α和β定义

平均房间数
6.998
7.147

⇨ 最优模型f_{best} ⇨

房价（千美元）
33.4
36.2

3.2 波士顿房价预测问题——机器学习方法

训练阶段（Training）

步骤1

一大堆数据

步骤3

选择最优模型

步骤2

一堆模型

$f_1, f_2, \dots, f_n$

- 输入：房价特征
- 输出：房价（标签）

- $y = \Sigma\alpha x + \beta$，$x$是特征值
- f由参数α和β定义

测试阶段（Testing）

平均房间数
6.998
7.147

步骤4

最优模型f_{best}

房价（千美元）
33.4
36.2

这也是所有机器学习方法的通用框架！

问题来了

如何构建最优的预测模型?

如何从有标签的数据中学到 f_{best}?

步骤1

一大堆数据

继续使用波士顿的房价数据

1978年波士顿区域房屋价格表

x_1：犯罪率（%）	0.00632	0.02731	0.02729	0.03237	0.06905
x_2：大住宅用地占比（%）	18.00	0.00	0.00	0.00	0.00
x_3：非零售商业用地占比（%）	2.31	7.07	7.07	2.18	2.18
x_4：景观房（0/1）	0	0	0	0	0
x_5：氮氧化物浓度（ppm）	0.538	0.469	0.469	0.458	0.458
x_6：平均房间数（个）	6.575	6.421	7.185	6.998	7.147
x_7：老旧房屋占比（%）	65.2	78.9	61.1	45.8	54.2
x_8：离就业中心的加权距离	4.09	4.9671	4.9671	6.0622	6.0622
……	……	……	……	……	……
y：房价中位数（千美元）	**24.00**	**21.6**	**34.7**	**33.4**	**36.2**

步骤1

一大堆数据

继续使用波士顿的房价数据

1978年波士顿区域房屋价格表

x_1：犯罪率（%）	[illegible]	[illegible]	[illegible]	[illegible]	0.06905
x_2：大住宅用	[illegible]	[illegible]	[illegible]	[illegible]	0.00
x_3：非零售商	[illegible]	[illegible]	[illegible]	[illegible]	2.18
x_4：景观房	[illegible]	[illegible]	[illegible]	[illegible]	0
x_5：氮氧化物浓度（ppm）	0.538	0.469	0.469	0.458	0.458
x_6：平均房间数（个）	6.575	6.421	7.185	6.998	7.147
x_7：老旧房屋占比（%）	65.2	78.9	61.1	45.8	54.2
x_8：离就业中心的加权距离	4.09	4.9671	4.9671	6.0622	6.0622
……	……	……	……	……	……
y：房价中位数（千美元）	**24.00**	**21.6**	**34.7**	**33.4**	**36.2**

便于理解：仅考虑单个特征

步骤1

一大堆数据

输入数据 x（特征，Feature）	输出结果 y（目标，Target | 标签，Label）
6.575	24.0
6.421	21.6
7.185	34.7
6.998	33.4
7.147	36.2
……	……

更直观的表示

房价与平均房间数正相关

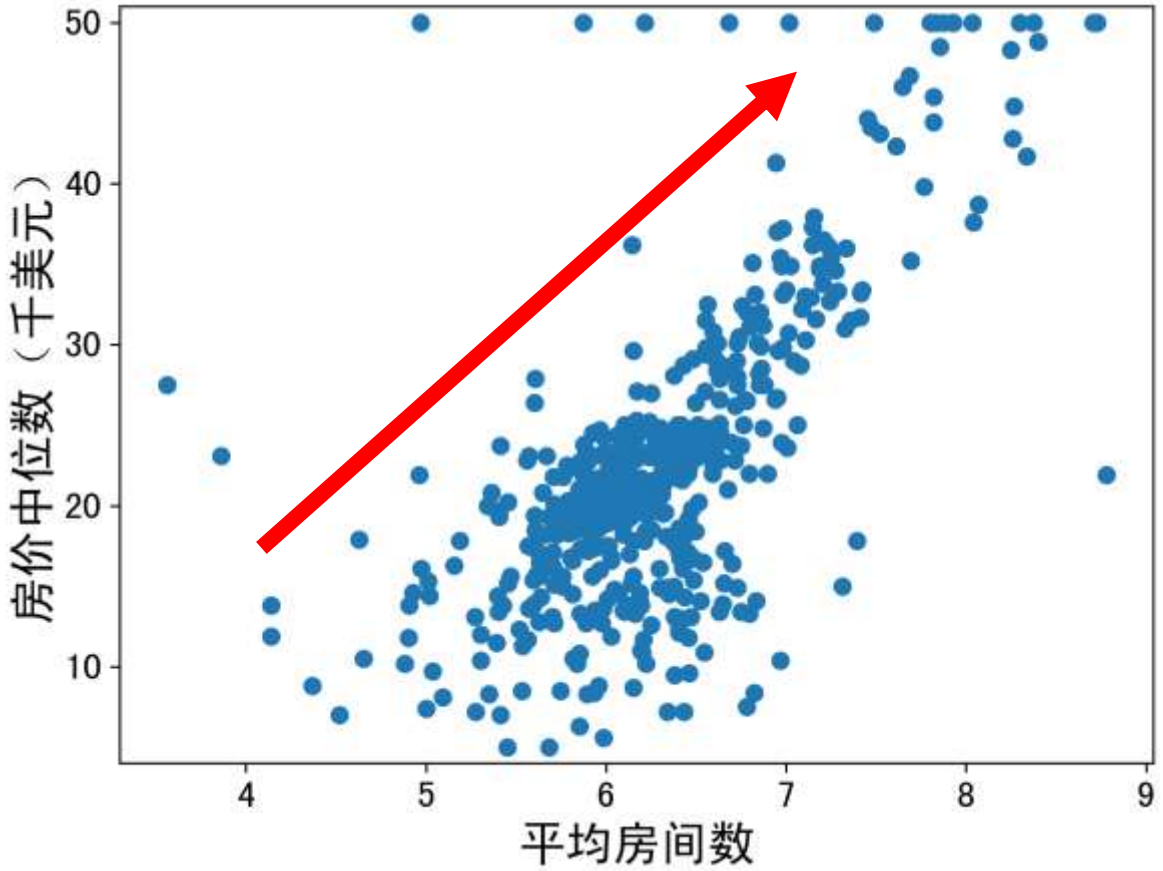

步骤2

一堆模型
$f_1, f_2, \dots, f_n$

随意地构建正/组关函数$y = f(x)$

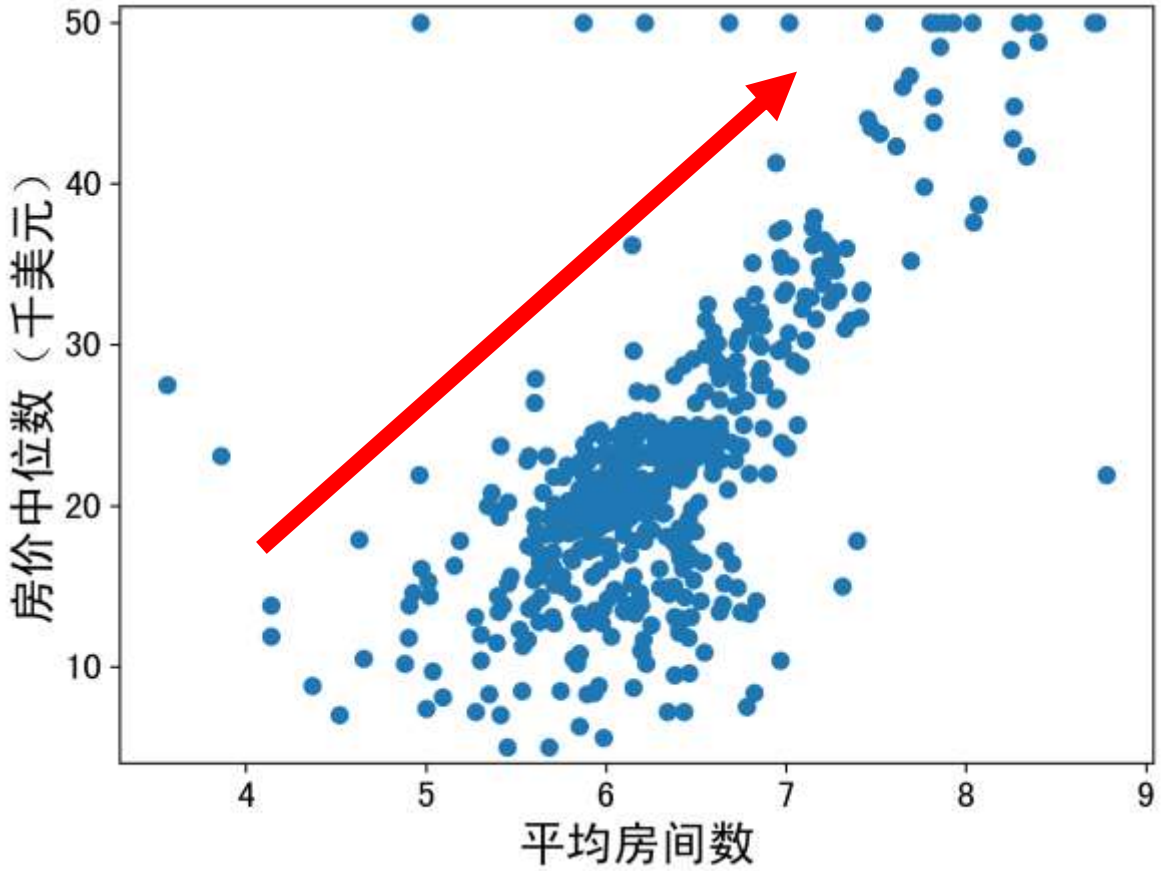

步骤2

一堆模型
$f_1, f_2, \dots, f_n$

随意地构建函数$y = f(x)$

可以选择**线性函数** $y = wx + b$

w（weight）：权重 | 参数 | 系数

b（bias）：偏见 | 偏好

```
def pred_linear(x, w, b):
    return w * x + b
```

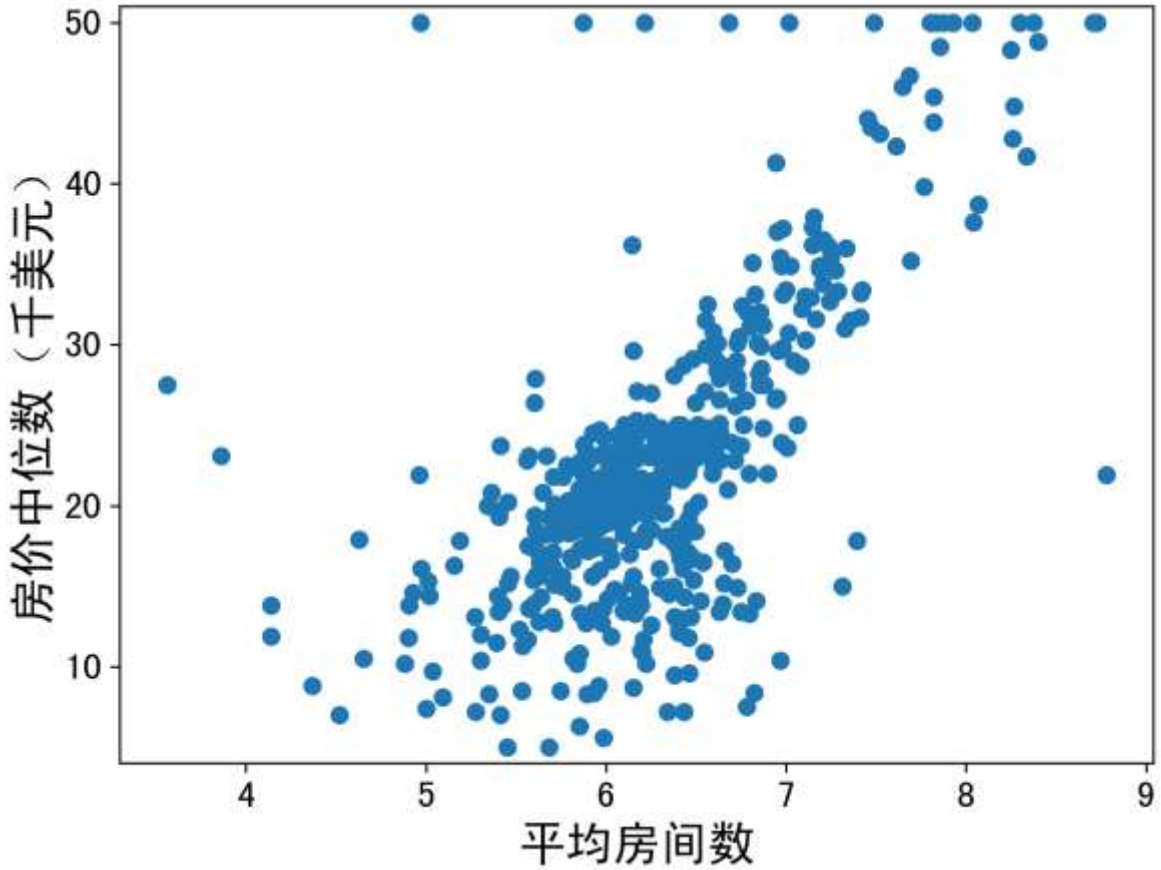

步骤2

一堆模型
$f_1, f_2, \dots, f_n$

随意地构建函数$y = f(x)$

可以选择**线性函数** $y = wx + b$

w（weight）：权重 | 参数 | 系数

b（bias）：偏见 | 偏好

```
def pred_linear(x, w, b):
    return w * x + b
```

当 $(w, b) \leftarrow (1,4)$ 时……

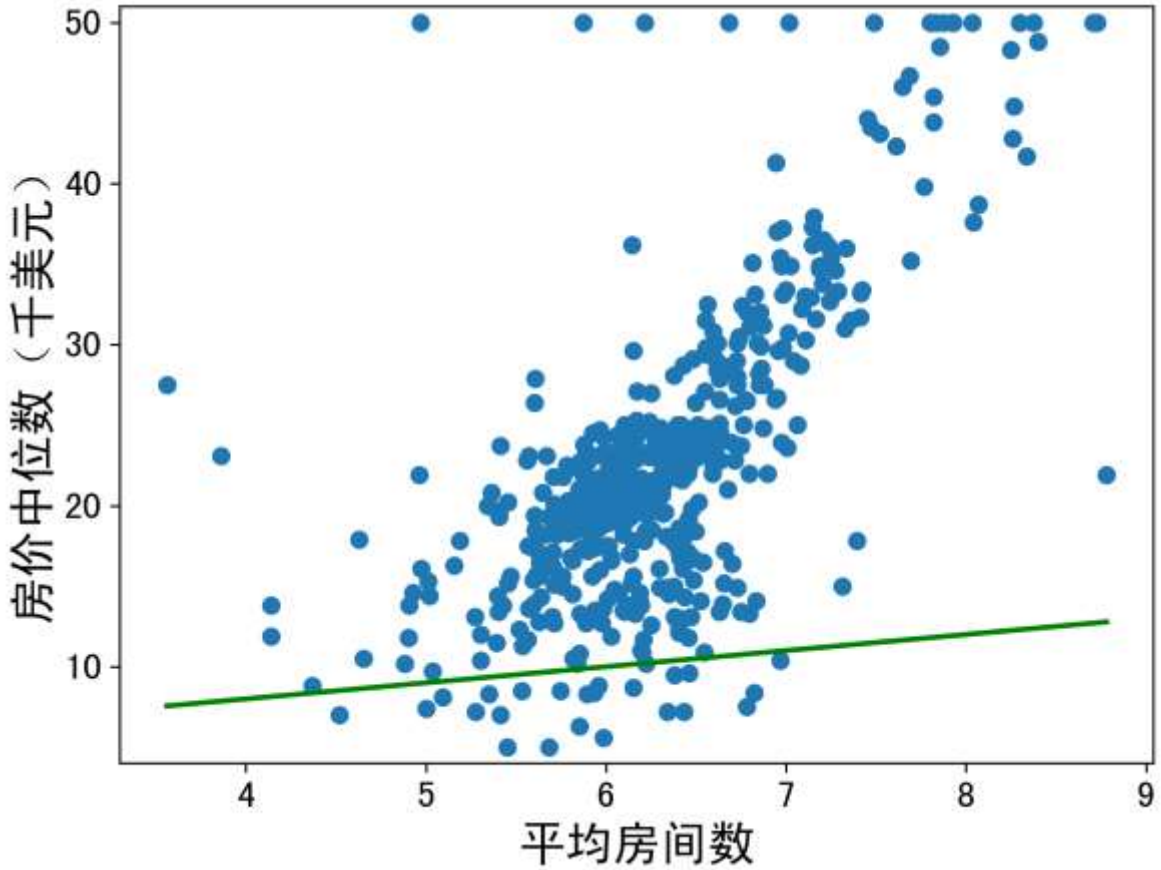

步骤2

一堆模型
$f_1, f_2, \dots, f_n$

随意地构建函数$y = f(x)$

可以选择**线性函数** $y = wx + b$

w（weight）：权重 | 参数 | 系数

b（bias）：偏见 | 偏好

```
def pred_linear(x, w, b):
    return w * x + b
```

当 $(w, b) \leftarrow (1,4)$ 时……

当 $(w, b) \leftarrow (6, -4)$ 时……

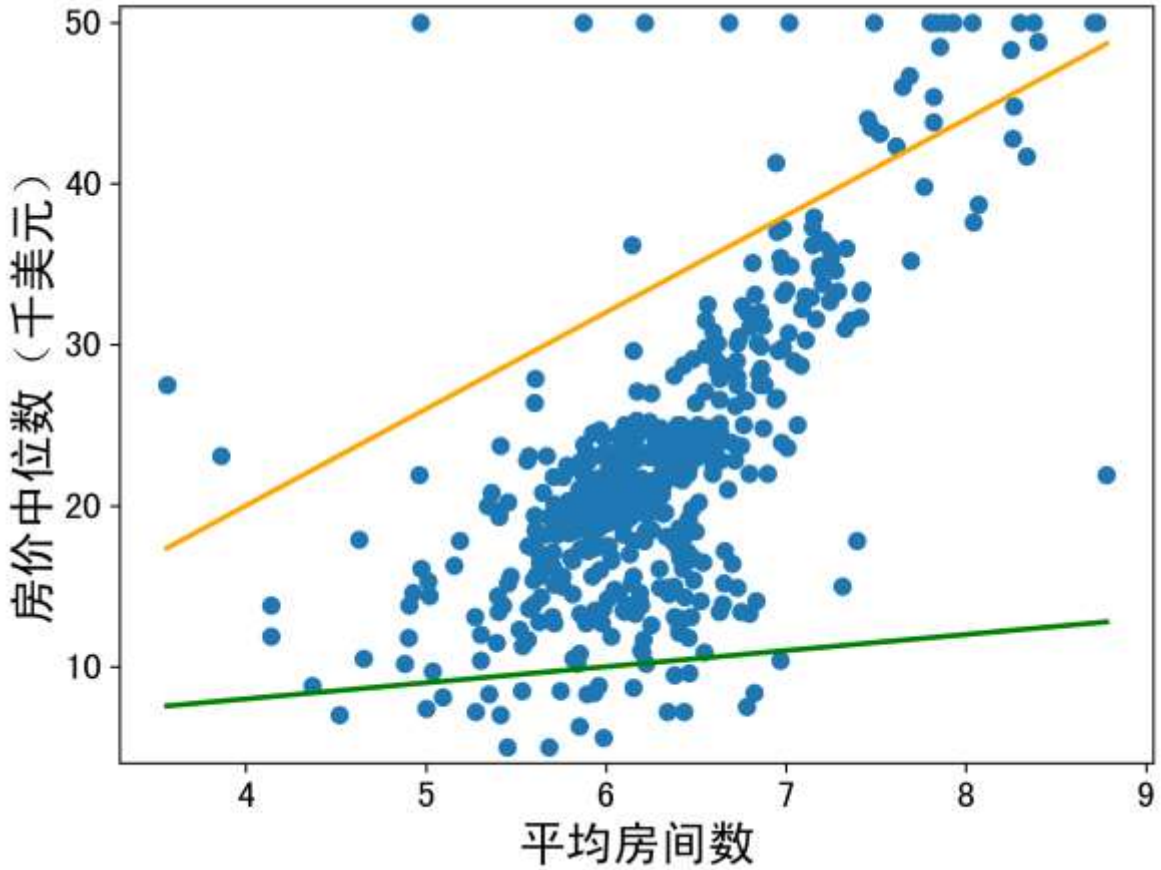

步骤2

一堆模型
$f_1, f_2, \dots, f_n$

随意地构建函数$y = f(x)$

可以选择**线性函数** $y = wx + b$

w（weight）：权重 | 参数 | 系数

b（bias）：偏见 | 偏好

```
def pred_linear(x, w, b):
    return w * x + b
```

当 $(w, b) \leftarrow (1,4)$ 时……

当 $(w, b) \leftarrow (6, -4)$ 时……

当 $(w, b) \leftarrow (11, -47)$ 时……

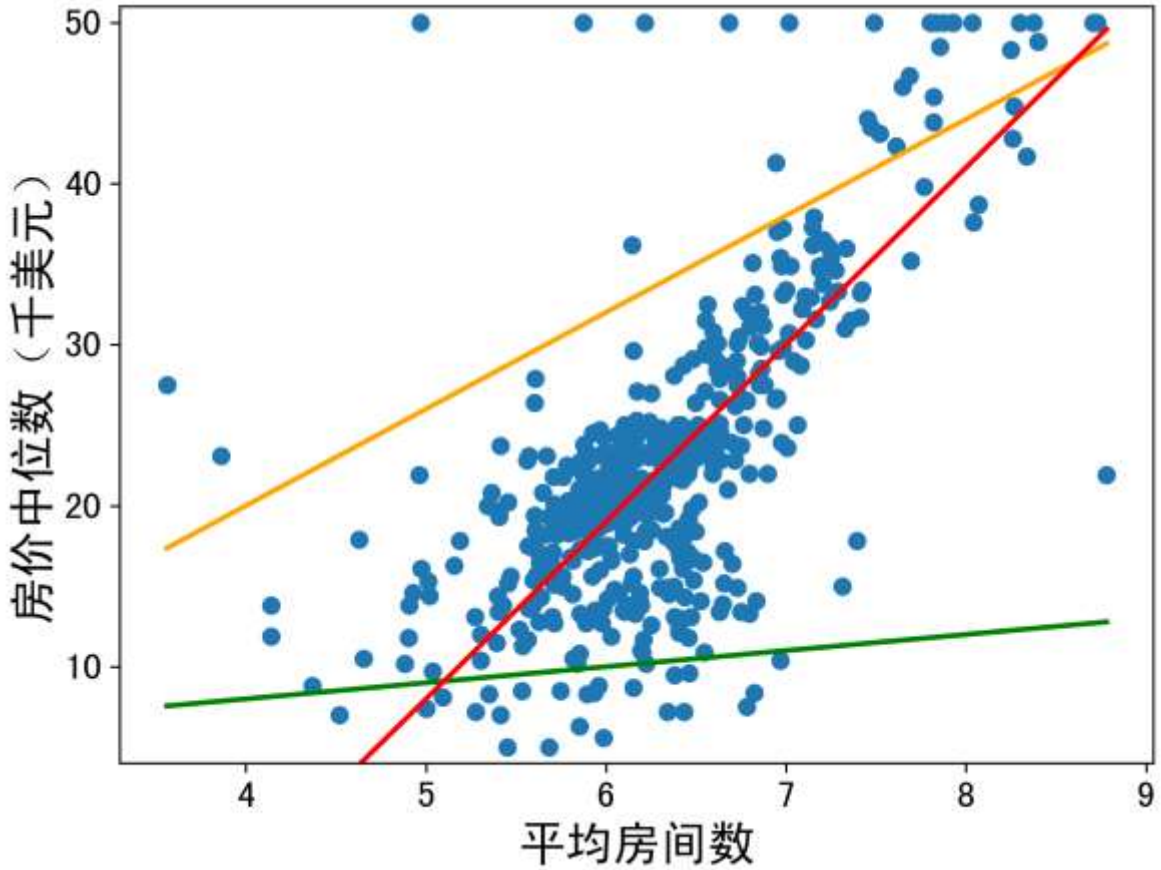

步骤2

一堆模型
$f_1, f_2, \dots, f_n$

随意地构建函数$y = f(x)$

可以选择**线性函数** $y = wx + b$

也可以尝试**非线性函数**

$$y = w\frac{1}{x} + b$$

$$y = we^x + b$$

$$y = wx^n + b$$

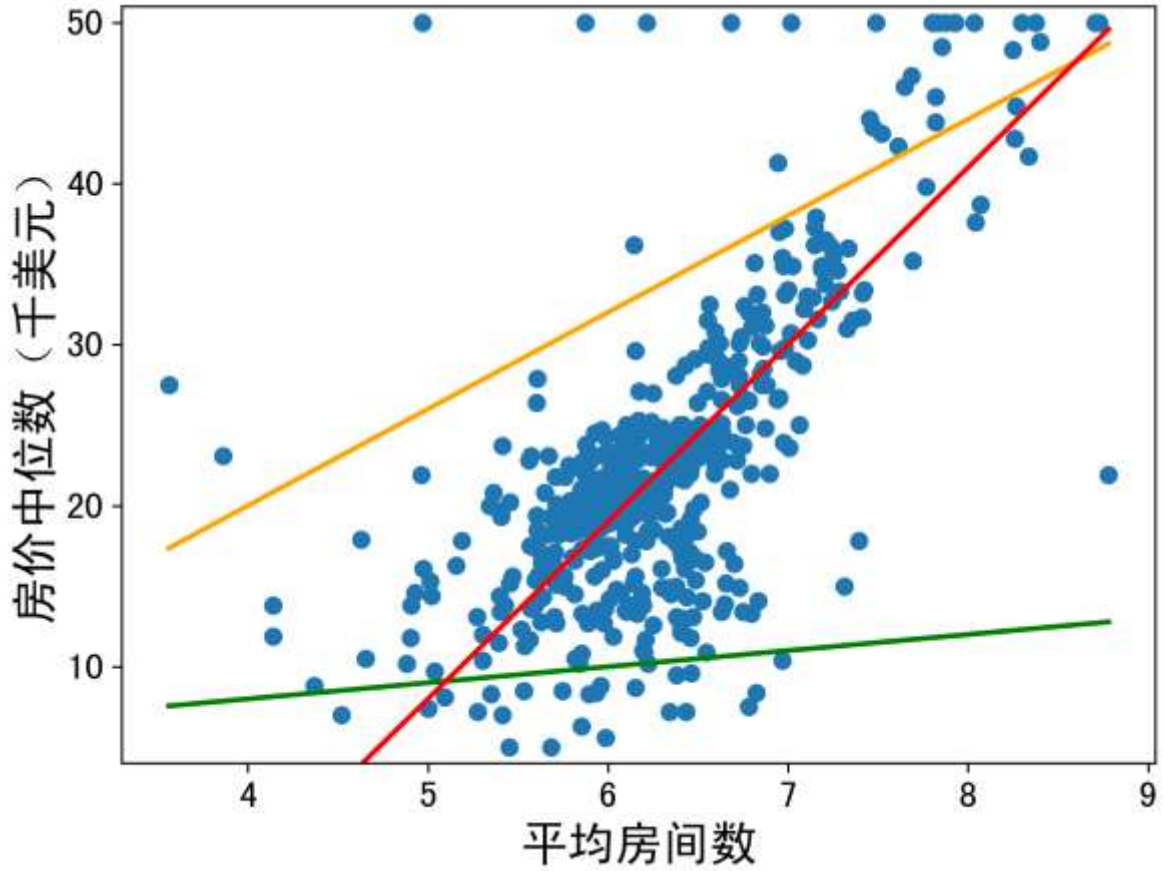

已经设计了一大堆不知道有没有用的函数

怎样选出**最优的** $(\boldsymbol{w}, \boldsymbol{b})$ 呢?

步骤3

选择最优模型

思考一下：如何判断预测模型的好坏？

和真实值越接近越准

设 y 为真实值，$\hat{y}$ 为预测值

$x = x_0$时的预测误差可记为：

单个结果缺乏说服力

$$|\widehat{y_0} - y_0|^2$$

“不管预测值高了或者低了都算作误差，所以应该消除正负号”

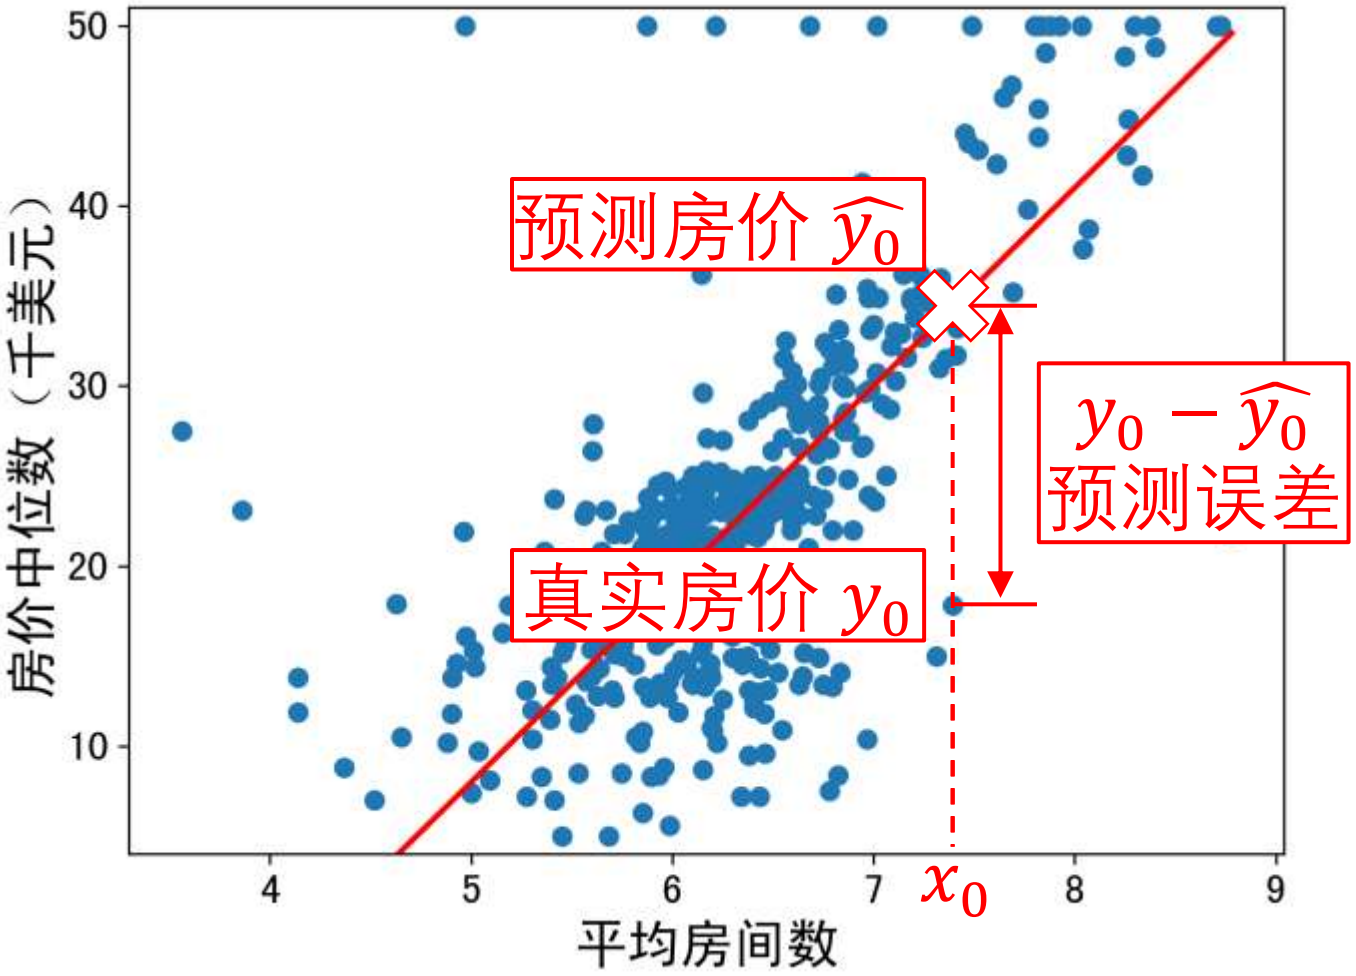

步骤3

选择最优模型

继续思考：如何对整体进行评价？

- **计算所有结果的和**

  误差会随样本数量增加而变大

- **取平均值**

  保证误差不随样本数量变化

$$\frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2$$

$N \rightarrow$ 样本数量

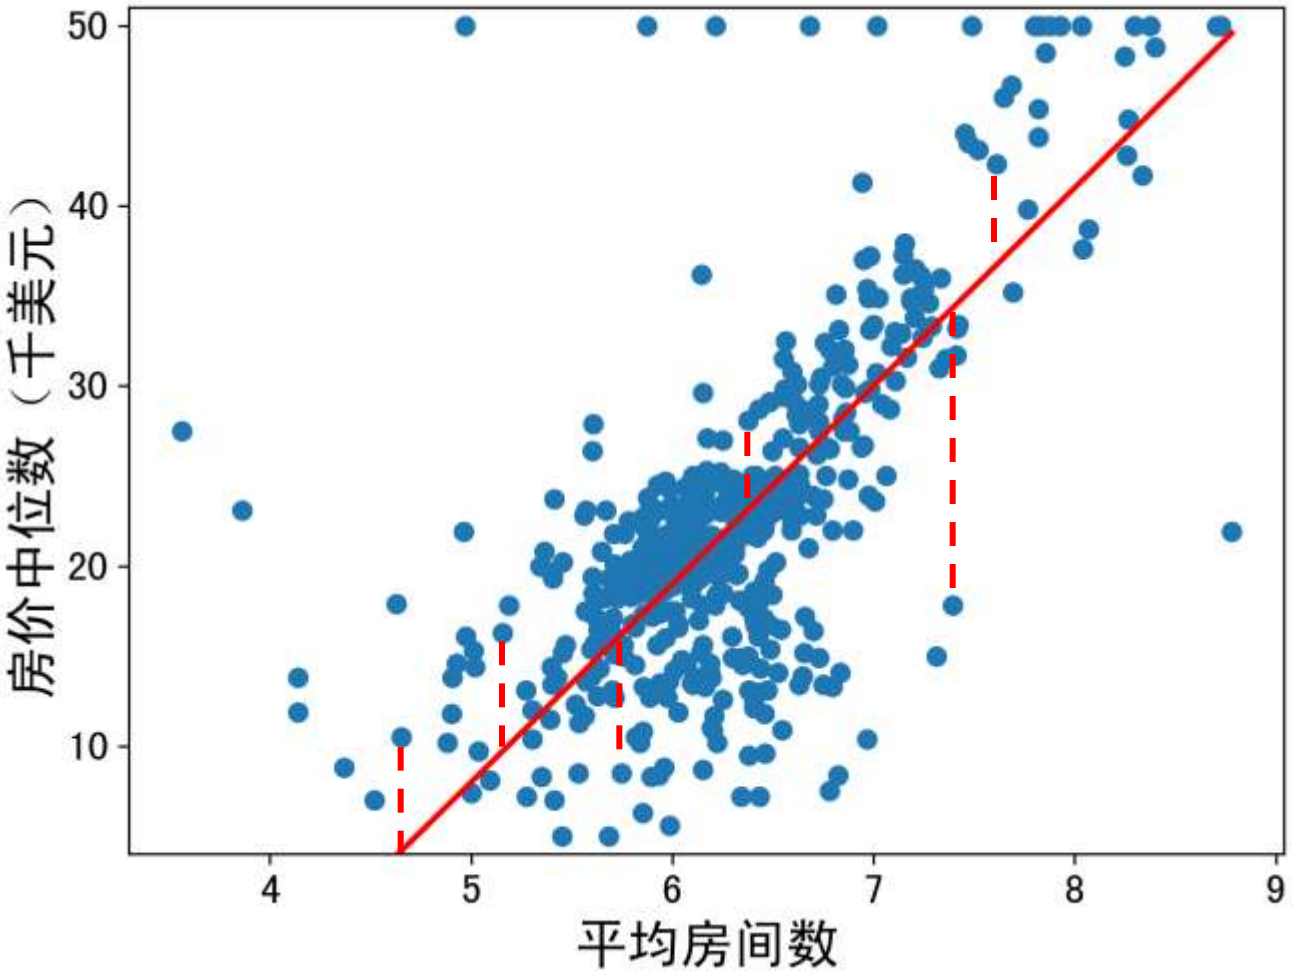

步骤3

选择最优模型

继续思考：如何对整体进行评价？

- **计算所有结果的和**

  误差会随样本数量增加而变大

- **取平均值**

  保证误差不随样本数量变化

$N \rightarrow$ 样本数量

$$\frac{1}{2N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2$$

“通常我们会写成这样，因为方便计算。可以思考一下原因。”

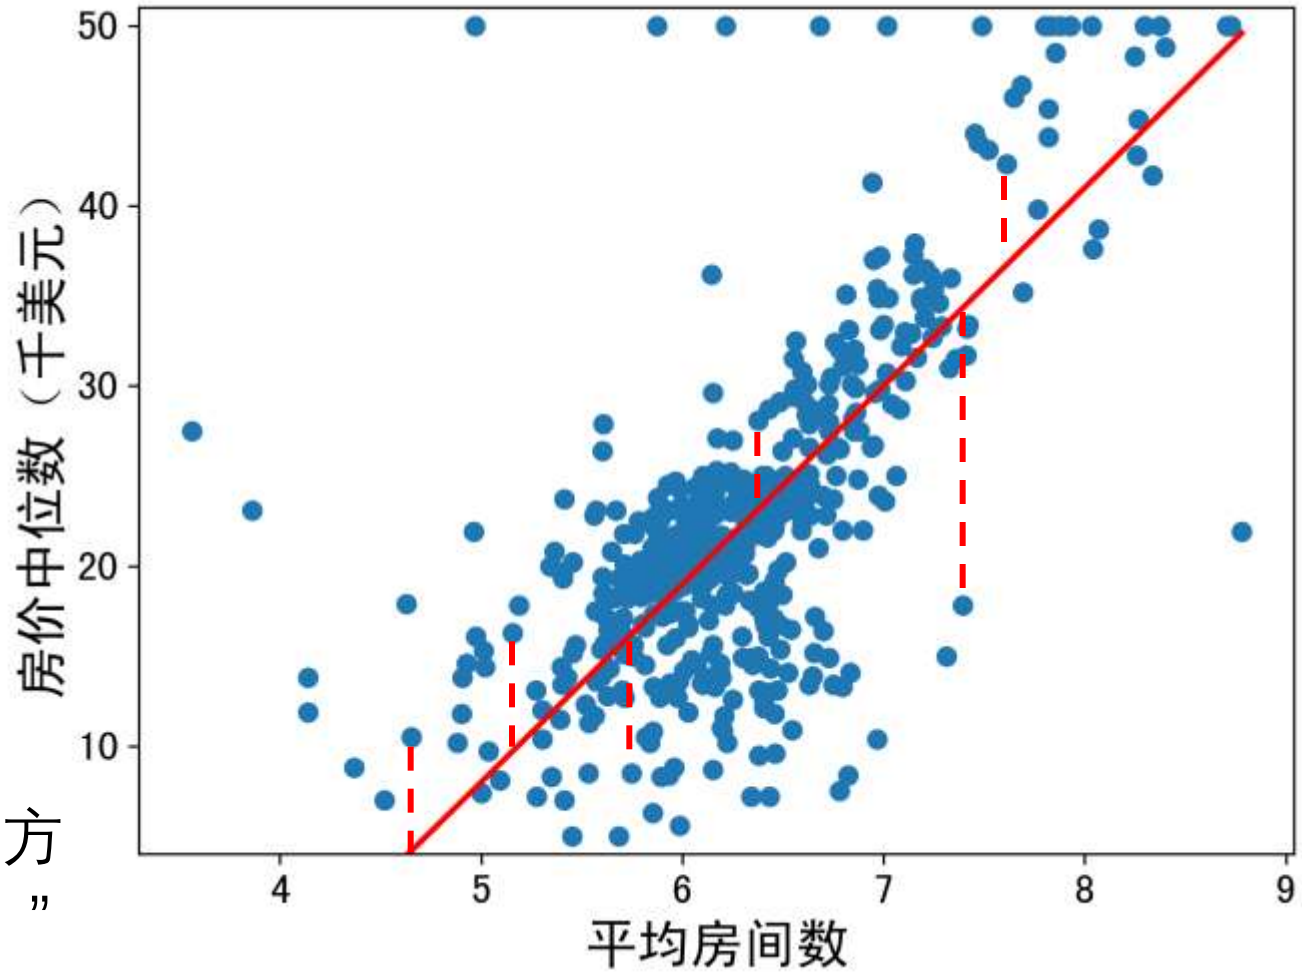

步骤3

选择最优模型

继续思考：如何对整体进行评价？

- **计算所有结果的和**

  误差会随样本数量增加而变大

- **取平均值**

  保证误差不随样本数量变化

$$Loss = \frac{1}{2N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2$$

损失函数

衡量模型好坏

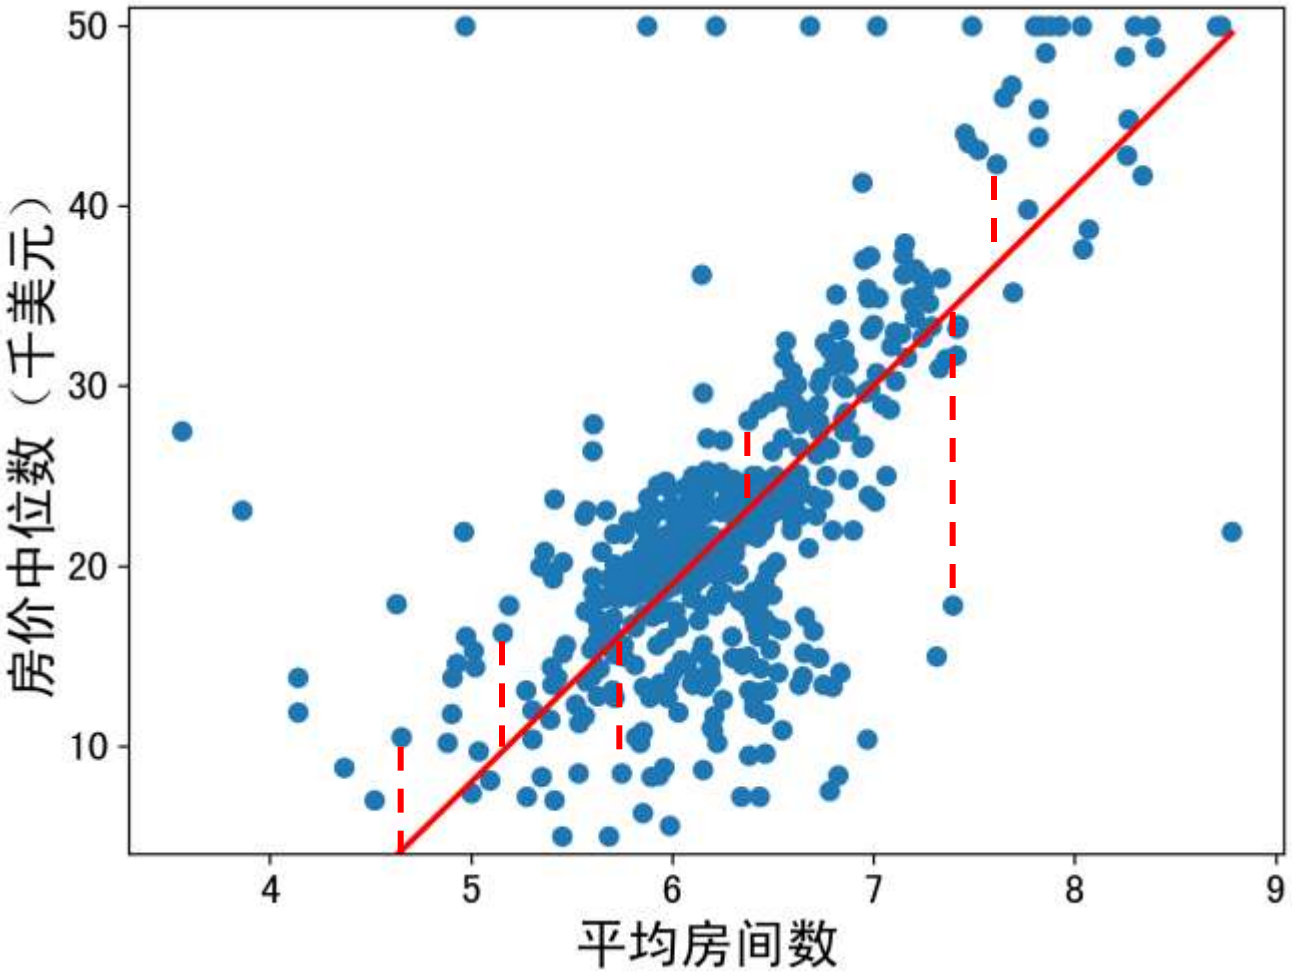

步骤3

选择最优模型

损失函数是描述预测函数好坏的函数

变换一下形式：

$$Loss = \frac{1}{2N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2 \xleftarrow{\text{代入 } \hat{y}_i} \hat{y}_i = wx_i + b$$

$$Loss(w, b) = \frac{1}{2N}\sum_{i=1}^{N}\left((wx_i + b) - y_i\right)^2$$

$Loss$的结果仅与预测函数的参数 w 和 b 相关

步骤3

选择最优模型

怎样找出最好的预测模型呢?

屠呦呦，中国首位诺贝尔医学奖获得者

- 查阅大量中医古籍找出2000+中草药制剂
- 筛选出640可能的治疟药方
- 从200种草药种得到380种提取物
- 经历190失败
- 对虐原虫的抑制率达到100%

向着确定的目标不断努力，是成功的必要条件

人民网, 屠呦呦自述:190次失败之后的成功. 2015. http://politics.people.com.cn/n/2015/1005/c70731-27664603.html

步骤3

选择最优模型

怎样找出最好的预测模型呢？

- 给出w和b“所有”的值

$w \in [w_{min}, w_{max}]$

$b \in [b_{min}, b_{max}]$

- 尝试所有的情况

```
for w in w_list:
    for b in b_list:
        loss(x, y, w, b)
```

- 选择最优的结果

$$w^*, b^* = arg\min_{w,b} L(w, b)$$

- 查阅大量中医古籍找出2000+中草药制剂
- 筛选出640可能的治疟药方
- 从200种草药种得到380种提取物
- 经历190失败
- 对虐原虫的抑制率达到100%

目标函数（Objective Function)

指导算法选出最优的预测模型。

步骤3

选择最优模型

- 给出w和b“所有”的值

$w \in [-100,100]$

$b \in [-100,100]$

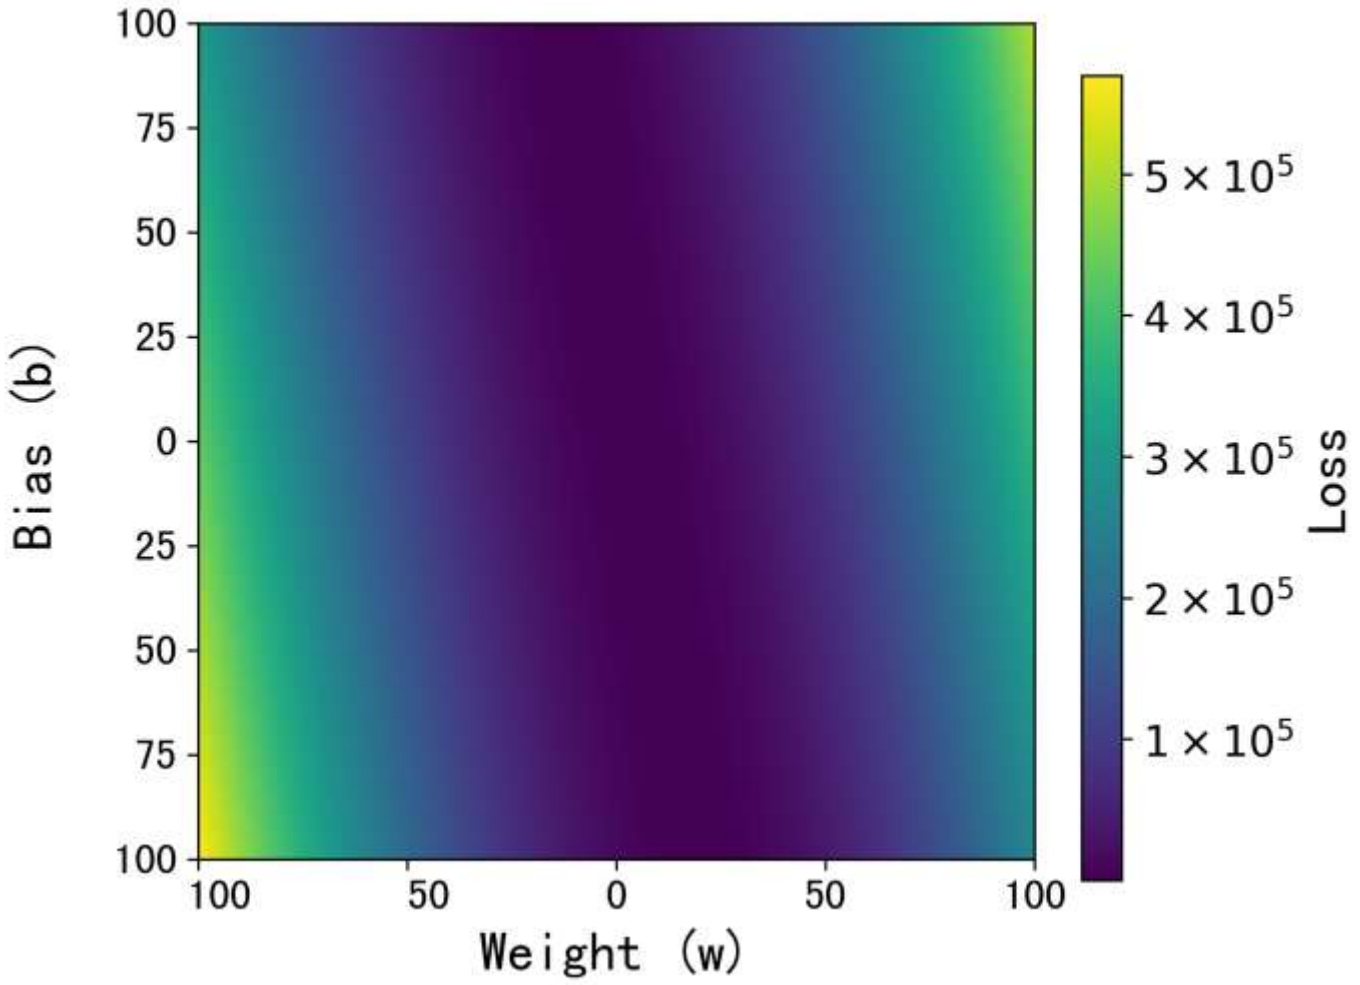

颜色越深，损失越小，模型预测得越准确

步骤3

选择最优模型

- 给出w和b“所有”的值

  $w \in [-100,100]$

  $b \in [-100,100]$

- 根据目标函数得到最优解

  $w = 9.55$

  $b = -37.69$

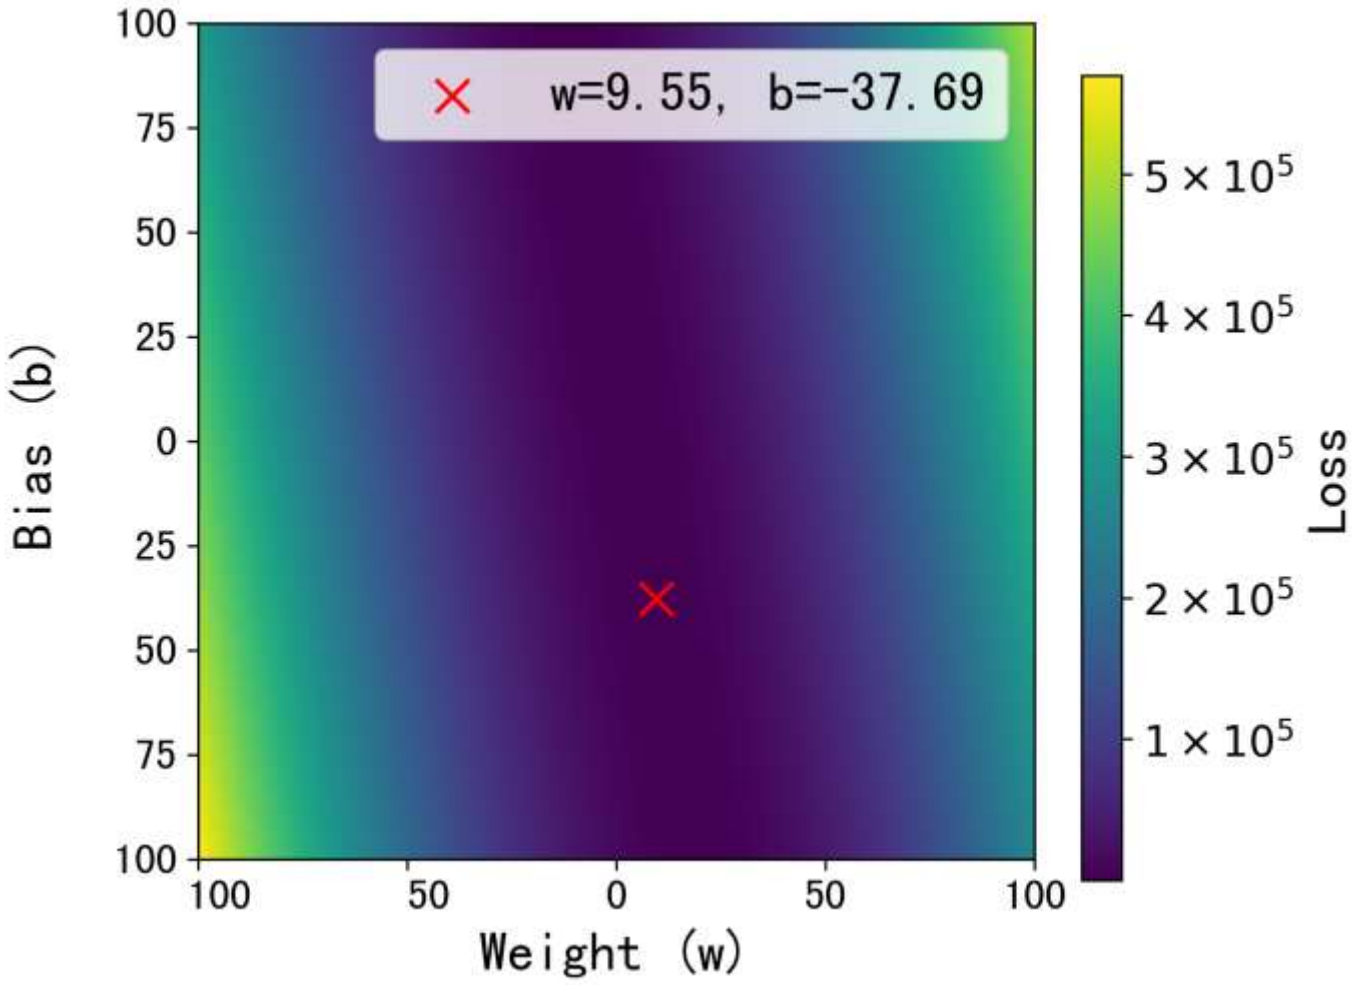

颜色越深，损失越小，模型预测得越准确

步骤3

选择最优模型

- 给出w和b“所有”的值

  $w \in [-100,100]$

  $b \in [-100,100]$

- 根据目标函数得到最优解

  $w = 9.55$

  $b = -37.69$

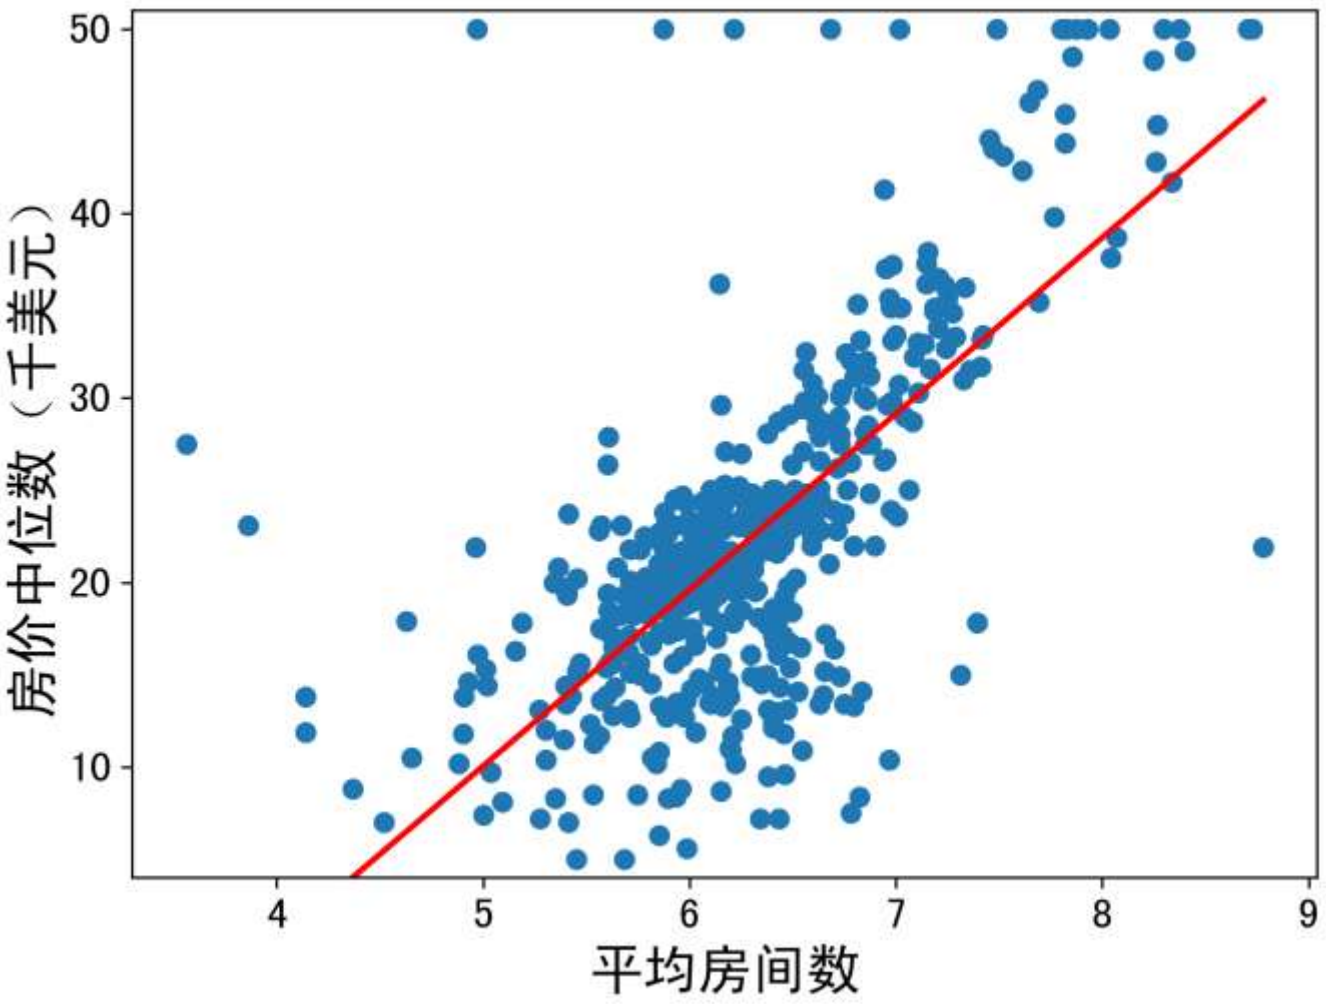

仅参考“平均房间数”时的最优预测函数

更加复杂的情况下是否还能如此呢?

- 当房价相关特征的数量为10时
- 线性模型至少由10个参数决定
- 损失函数的计算次数N_{Loss}:

$$N_{Loss} = 100^{10} = 10^{20}\ （次）$$

- 计算一次Loss平均耗时 0.382（毫秒）
- 计算10^{20}次Loss耗时约 12亿年

“资源有限的情况下，还是不要蛮干。”

“T博士建议考虑一下Gradient Descend，也就是梯度下降。”

3.3 模型训练

训练阶段（Training）

步骤1

一大堆数据

步骤3

选择最优模型

步骤2

一堆模型

$f_1, f_2, \dots, f_n$

- 输入：房价特征
- 输出：房价（标签）

如何让这个过程更优雅?

- $y = \Sigma\alpha x + \beta$，$x$是特征值
- f由参数α和β定义

平均房间数
6.998
7.147

步骤4

最优模型f_{best}

房价（千美元）
33.4
36.2

测试阶段（Testing）

3.3 模型训练——梯度下降

设想一下…

不论在何处，都能判断

最优点的大致方向

$$w^*, b^* = arg\min_{w,b} L(w,b)$$

最小的 $L(w,b)$

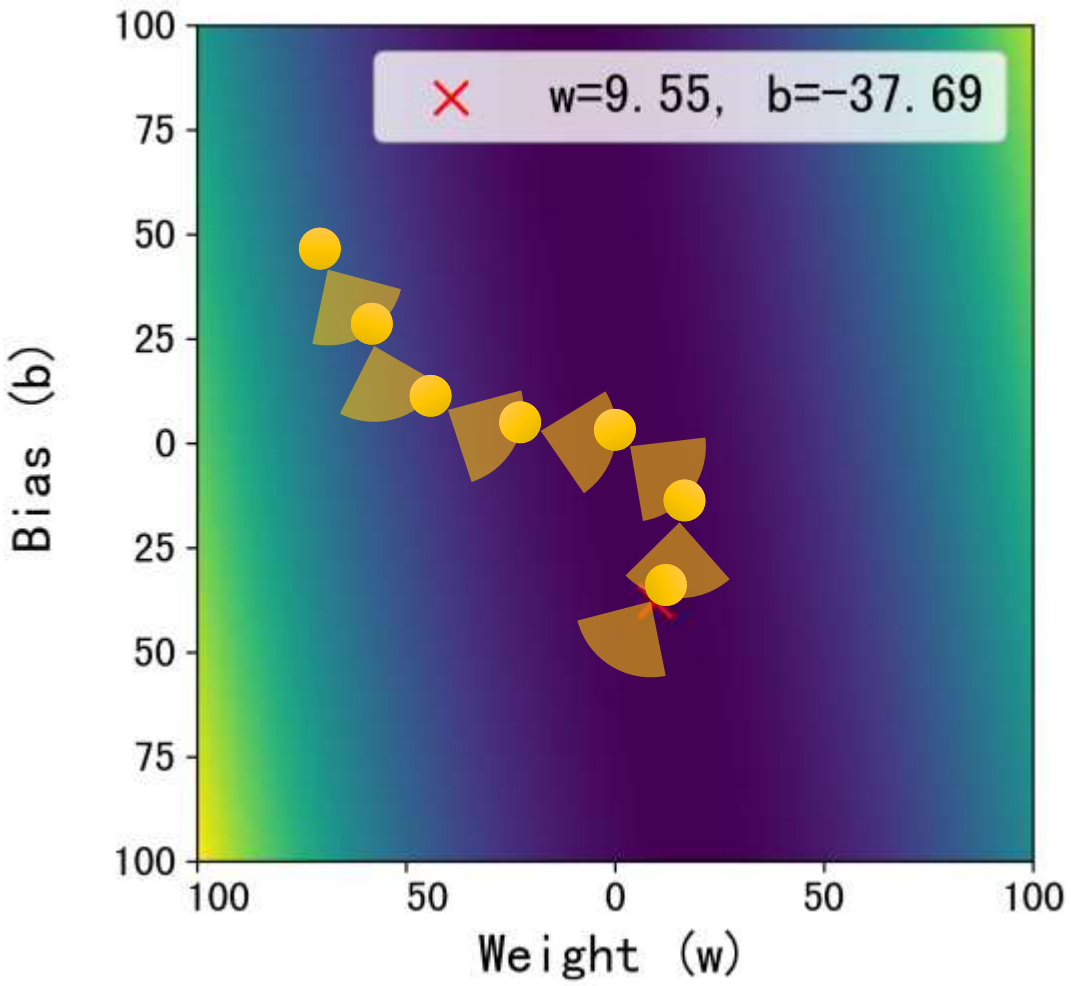

3.3 模型训练——梯度下降

沿 $b = -37.69$， 画一条关于 w 的损失函数曲线 $L(w)$

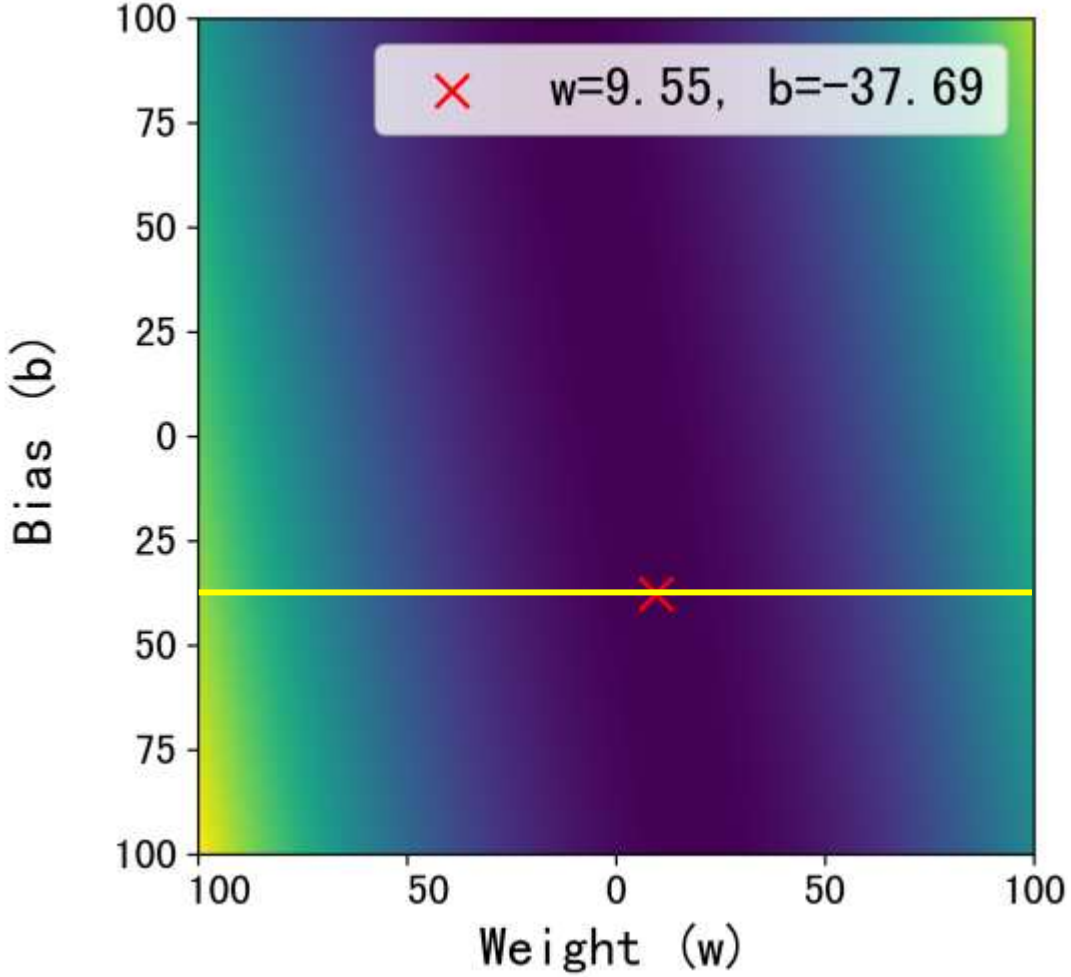

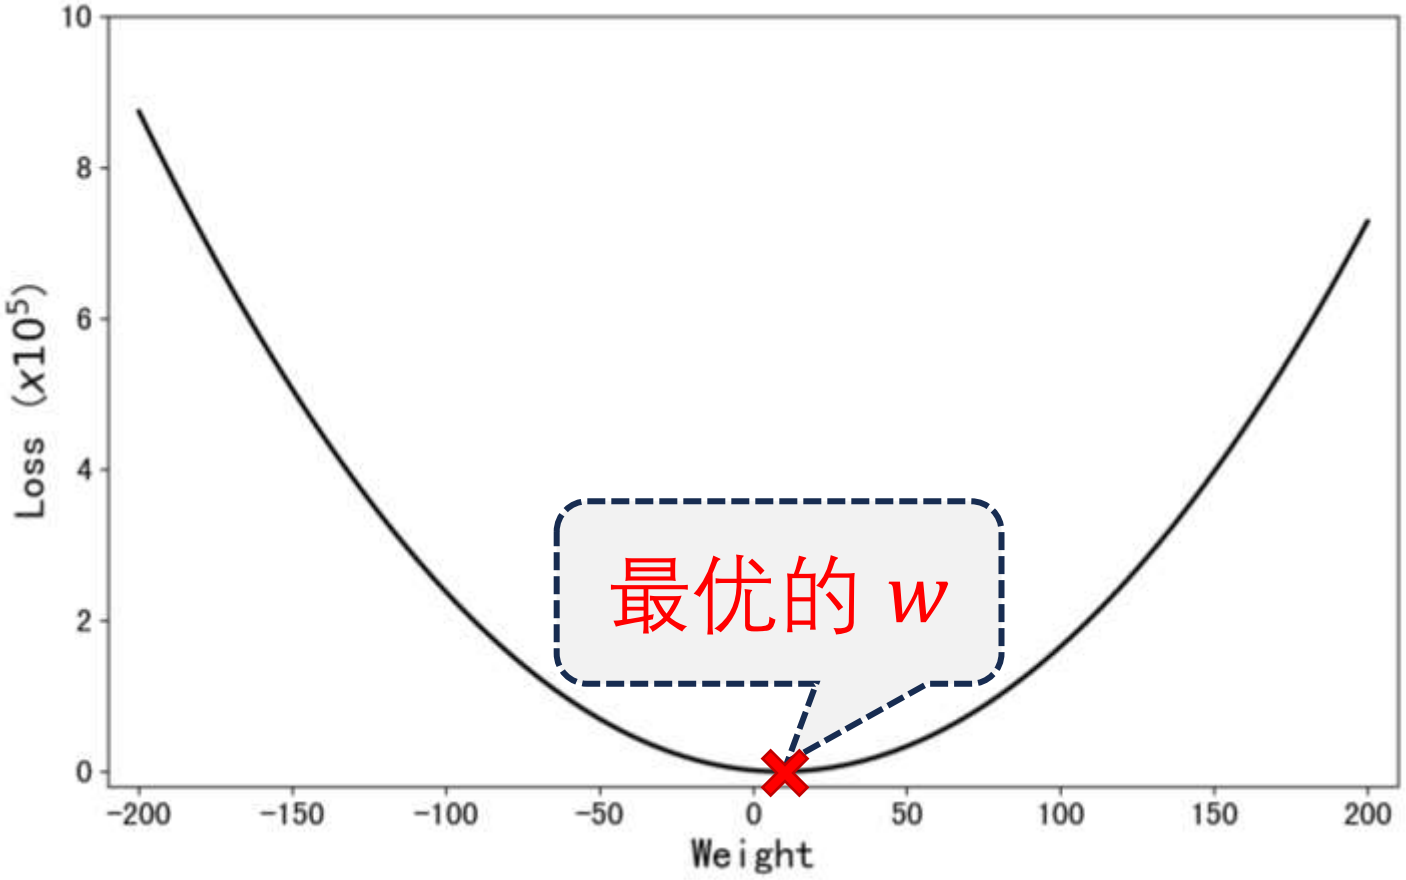

3.3 模型训练——梯度下降

① 任意初始化一个点 P_0

② 通过启发式的梯度下降法

③ 让Loss收敛到最优的 w

模型训练就是在
找最优的参数

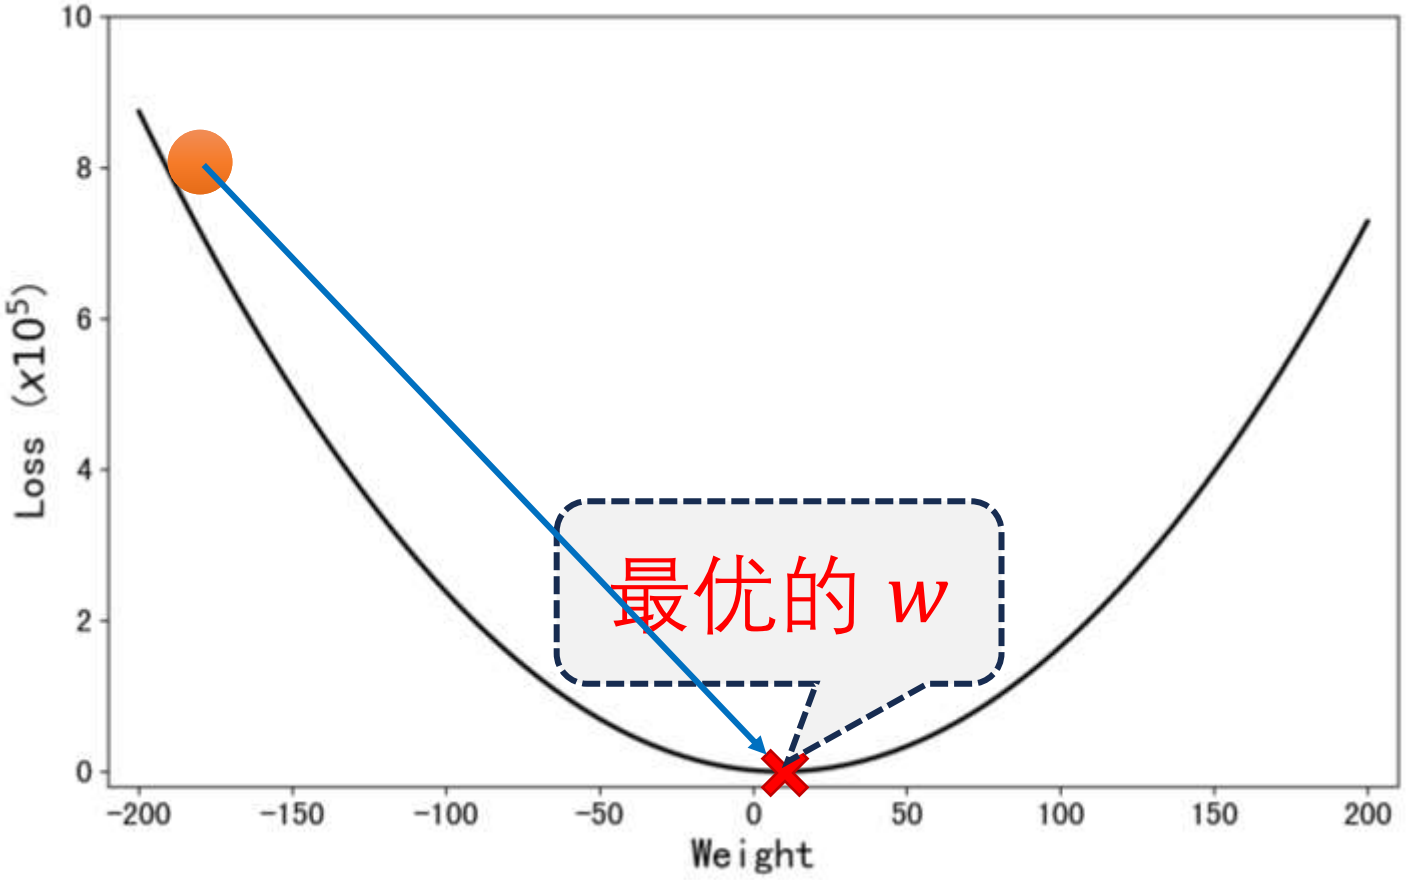

3.3 模型训练——梯度下降：基本思想

想象一下在P_0点放上个小球

小球在重力作用下，沿曲线

$$y = f(x)$$

朝着最优点下滑

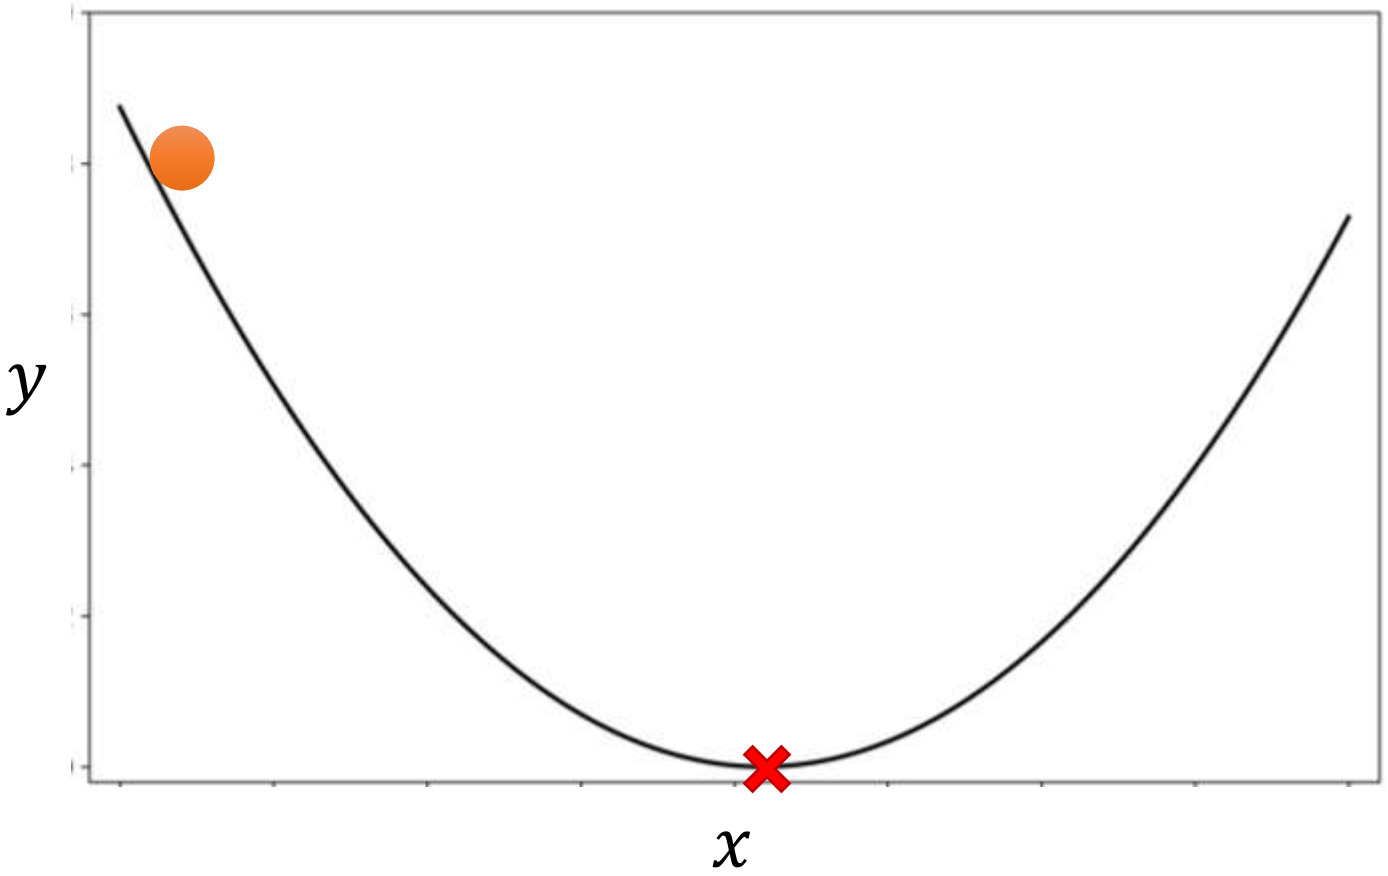

3.3 模型训练——梯度下降：基本思想

想象一下在P_0点放上个小球

小球在重力作用下，沿曲线

$$y = f(x)$$

朝着最优点下滑

t_0时刻，小球沿合力方向运动，

即曲线在P_0处切线方向

沿切线方向运动即为最快到达目标的方向

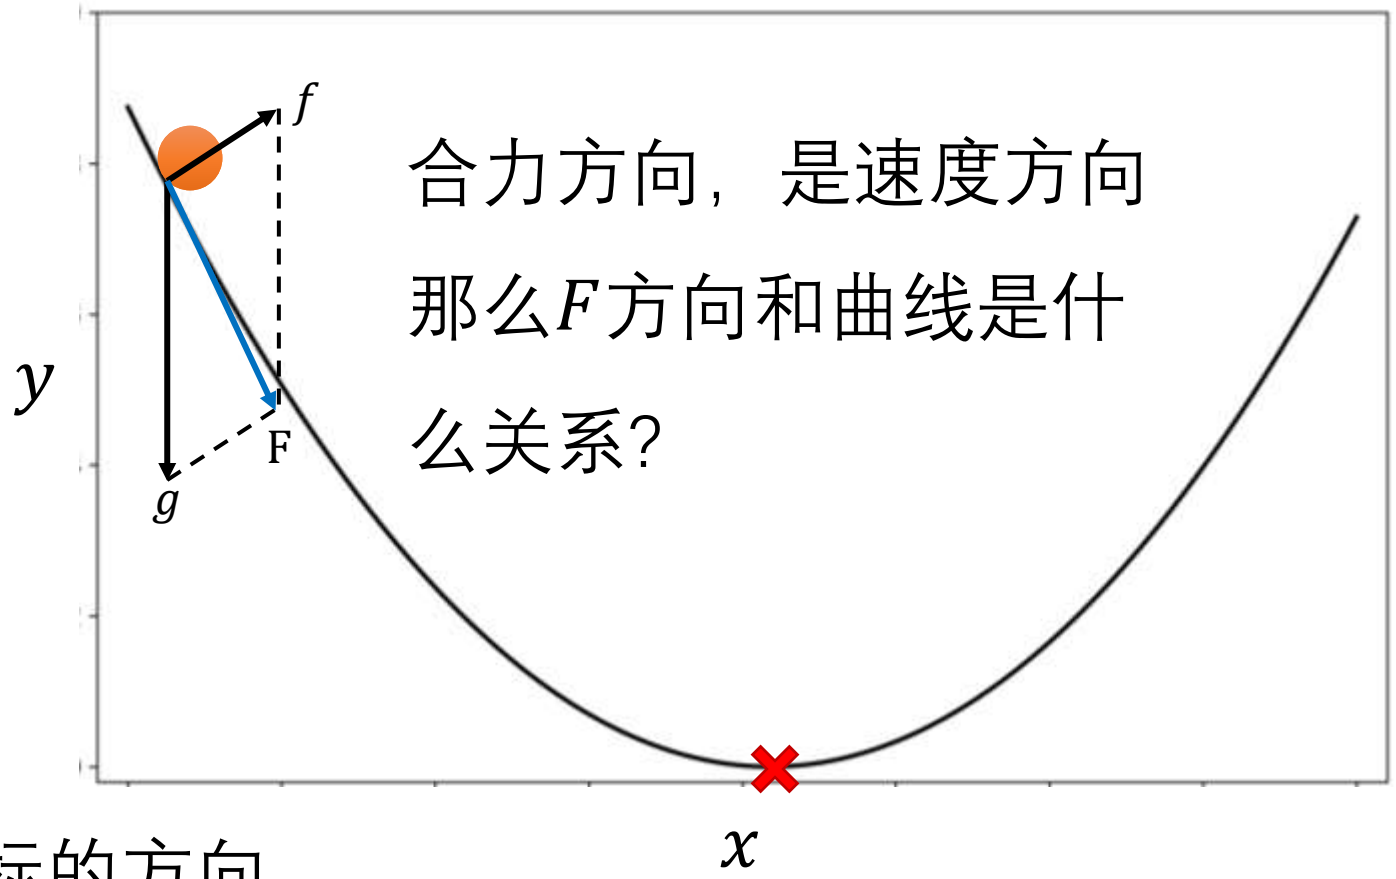

合力方向，是速度方向

那么F方向和曲线是什么关系?

3.3 模型训练——梯度下降：基本思想

用数学符号归纳运动

P_0 处切线为$y = a_{p_0}x + b_{p_0}$

$$a_{p_0} < 0$$

在下一时刻，小球移动到 P_1

$$x_1 - x_0 > 0$$

“当斜率为负时，球朝正向移动”

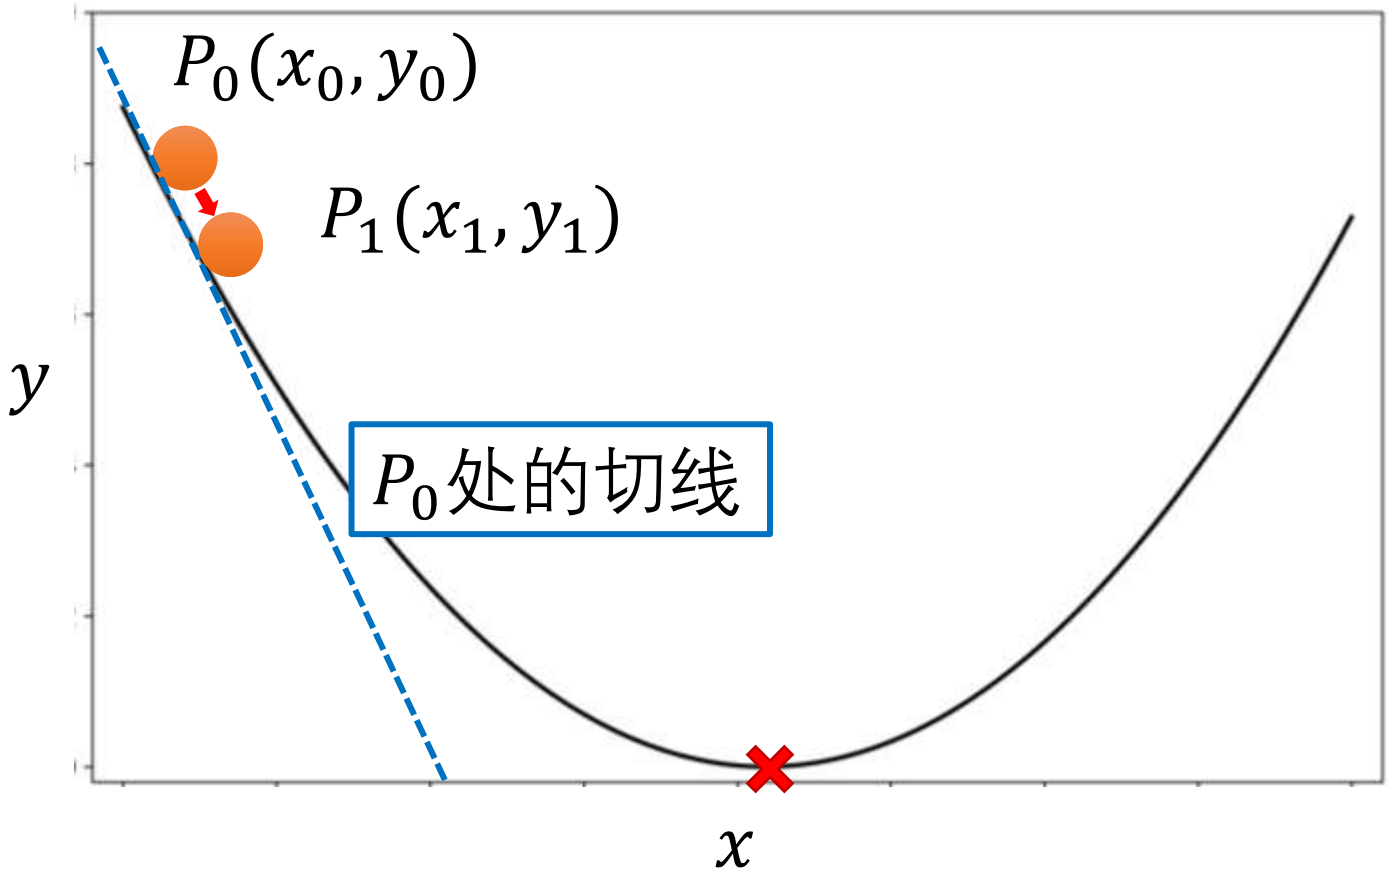

3.3 模型训练——梯度下降：基本思想

用数学符号归纳运动

假设 P_0 处切线为$y = a'_{p_0}x + b'_{p_0}$

$$a'_{p_0} > 0$$

在下一时刻，小球移动到 P_1

$$x_1 - x_0 < 0$$

“当斜率为正时，球朝负向移动”

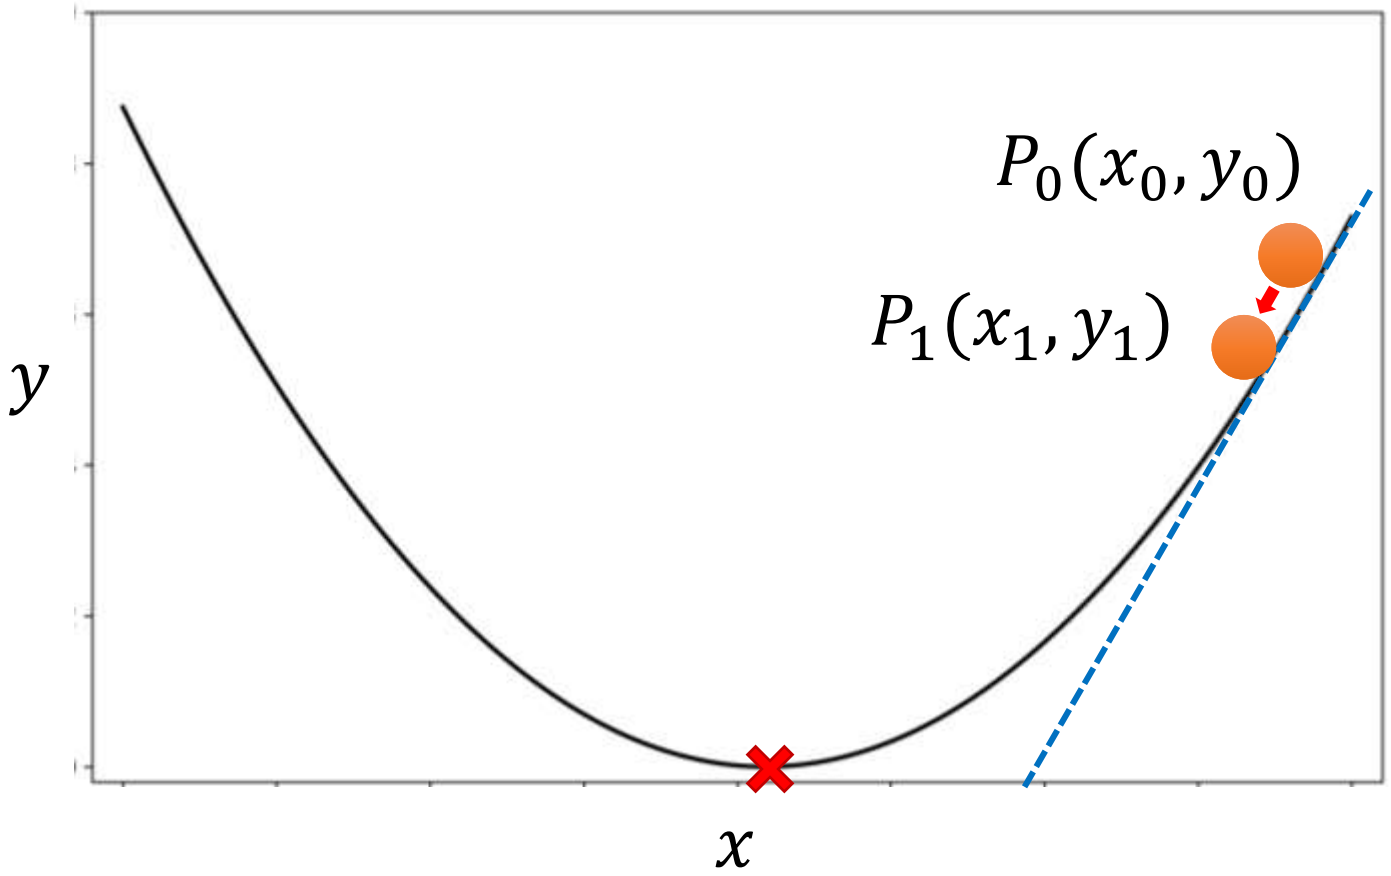

3.3 模型训练——梯度下降：基本思想

用数学符号归纳运动

$P_0 \to P_1$： η 表示“走”的距离

$$-\eta \cdot a_{p_0} = -\eta \cdot \frac{dy}{dx}\Big|_{x=x_0}$$

$P_1 \to P_2$：

$$-\eta \cdot a_{p_1} = -\eta \cdot \frac{dy}{dx}\Big|_{x=x_1}$$

$\ldots \to P_n$：

$$-\eta \cdot a_{p_{n-1}} = -\eta \cdot \frac{dy}{dx}\Big|_{x=x_{n-1}}$$

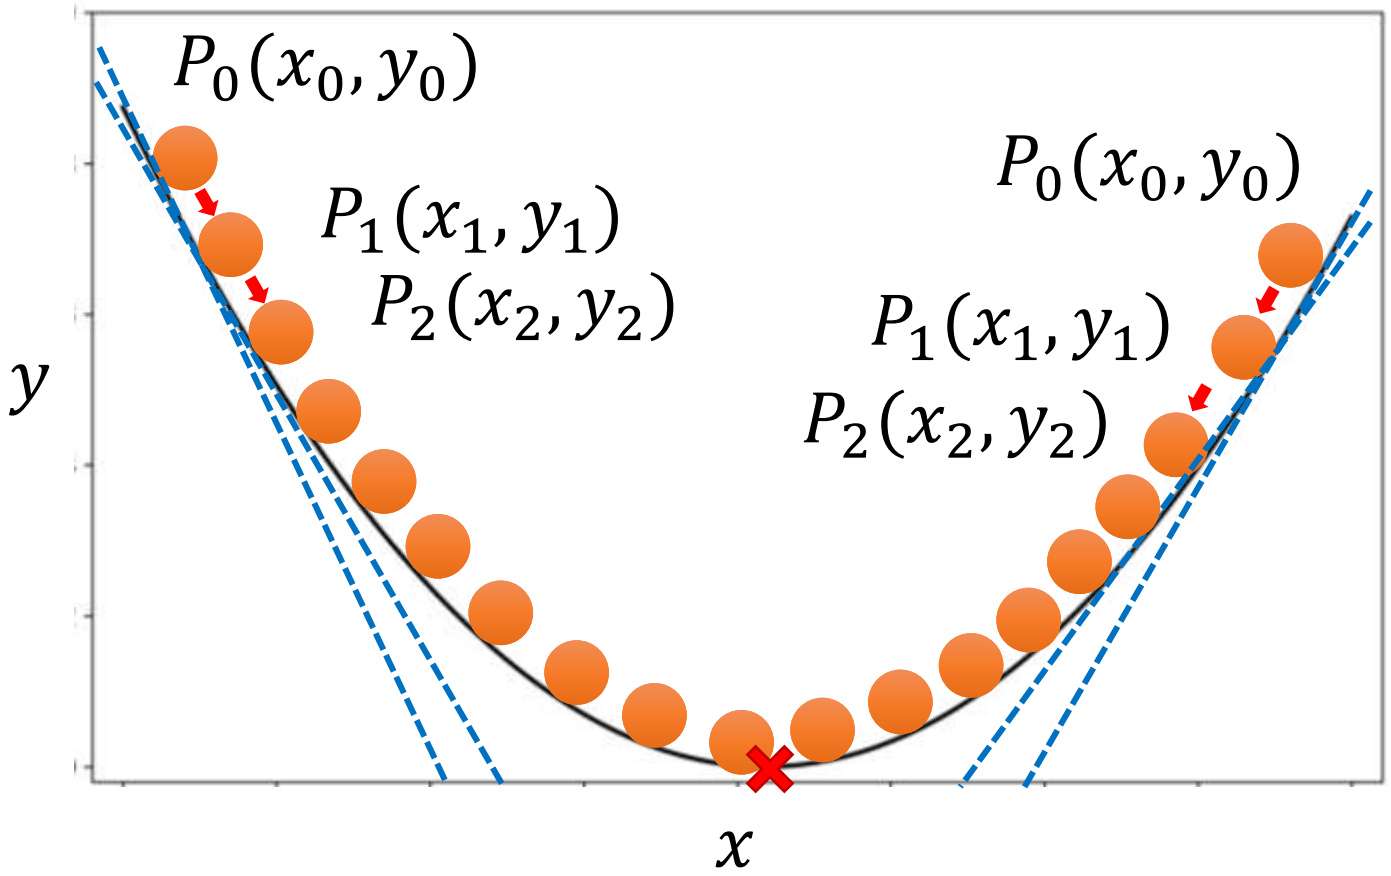

3.3 模型训练——梯度下降：基本思想

回到找最优预测函数的问题 $w^* = arg\min_{w} L(w)$

Step 1: 计算一下 P_0 处的梯度 $\frac{d_L}{d_w}$

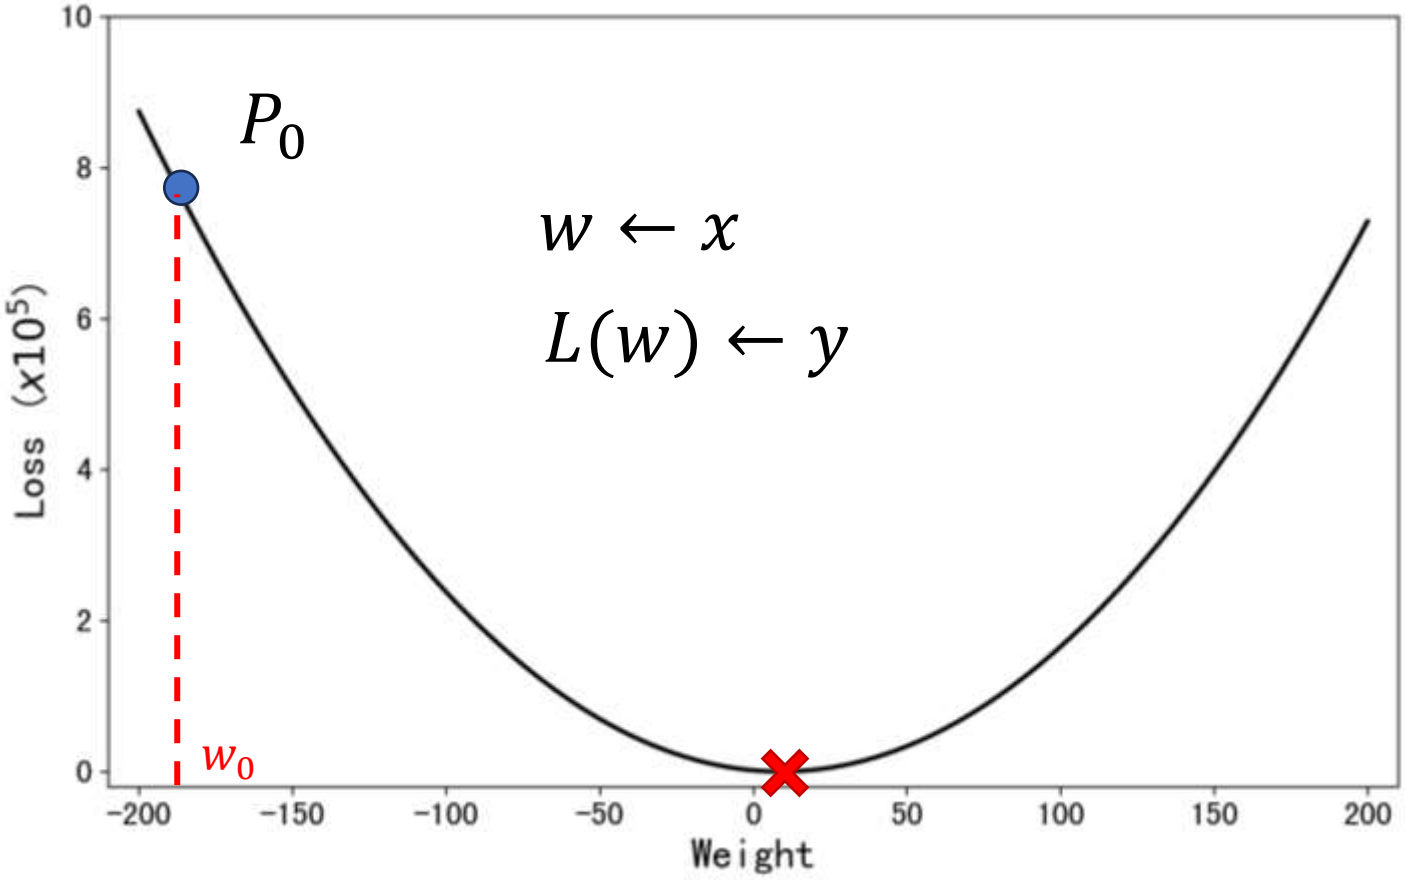

3.3 模型训练——梯度下降：基本思想

回到找最优预测函数的问题 $w^* = arg\min_{w} L(w)$

Step 1: 计算一下 P_0 处的梯度 $\frac{d_L}{d_w}$

$$Loss = \frac{1}{2N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2$$

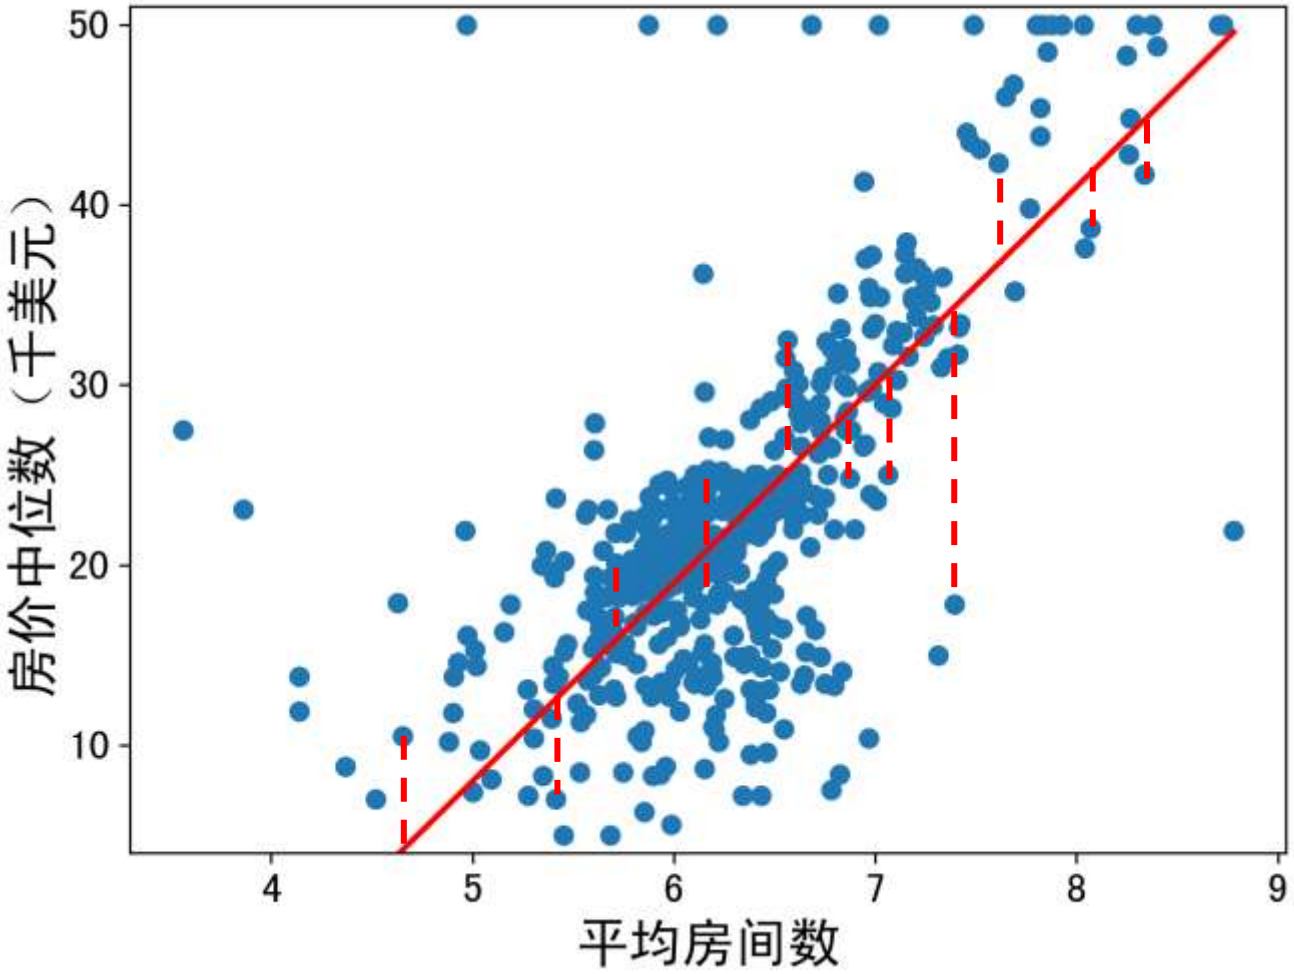

3.3 模型训练——梯度下降：基本思想

回到找最优预测函数的问题 $w^* = arg\min_{w} L(w)$

Step 1: 计算一下 P_0 处的梯度 $\frac{d_L}{d_w}$

$$\frac{d_L}{dw} = \frac{d\left(\frac{1}{2N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2\right)}{dw}, \qquad \hat{y}_i = wx_i + b$$

$$= \frac{d\left(\frac{1}{2N}\sum_{i=1}^{N}\left((wx_i + b) - y_i\right)^2\right)}{d_w}$$

$$= \frac{1}{N}\sum_{i=1}^{N}(wx_i + b - y_i)x_i = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)x_i$$

3.3 模型训练——梯度下降：基本思想

回到找最优预测函数的问题 $w^* = arg\min_{w} L(w)$

Step 2: 沿梯度反方向 $-\frac{d_L}{d_w}$ 移动 η

参数更新 $w' = w - \frac{d_L}{d_w} \cdot \eta$

学习率

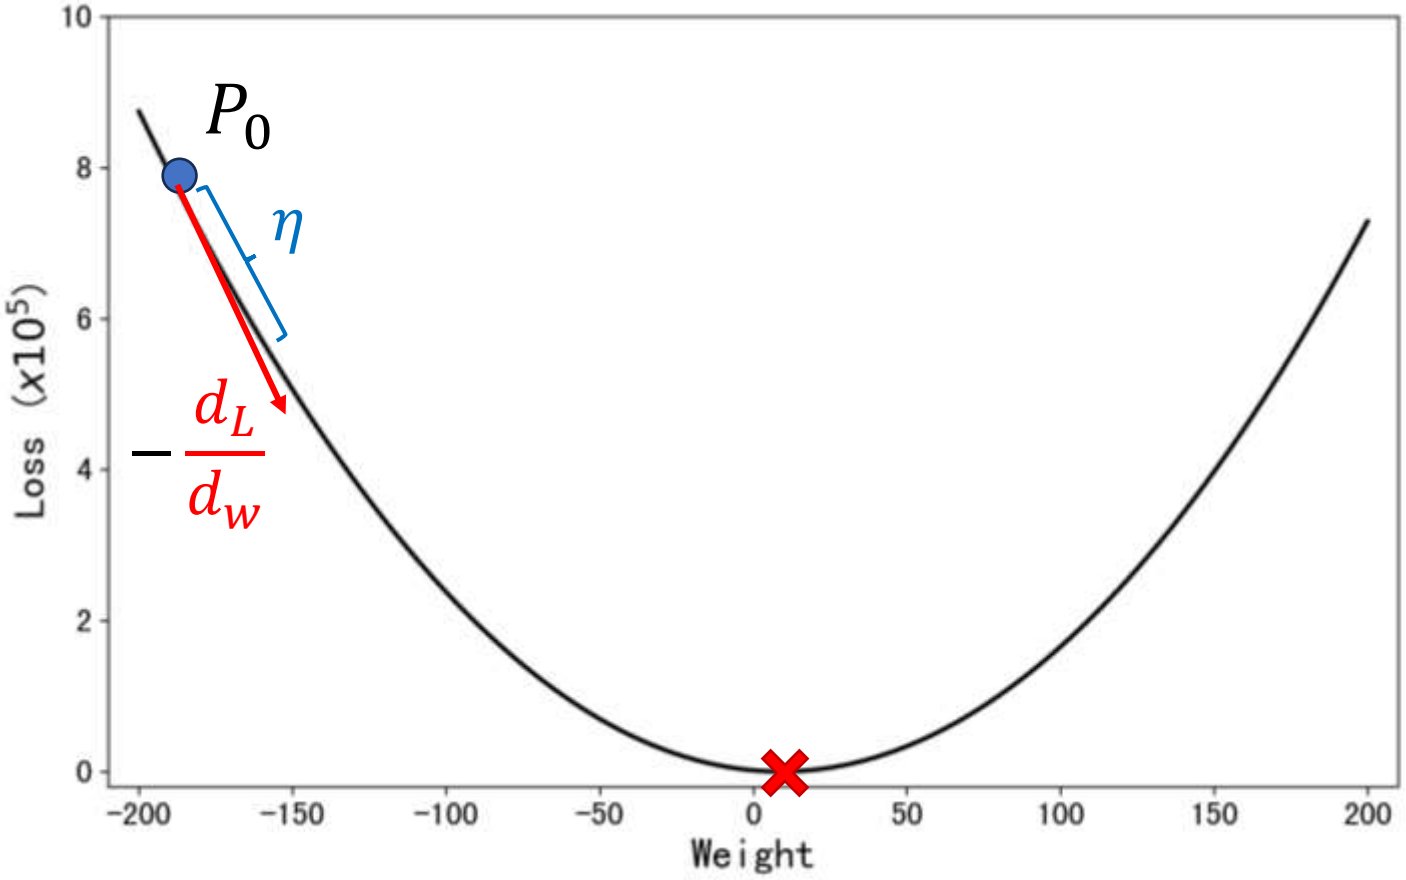

3.3 模型训练——梯度下降：基本思想

回到找最优预测函数的问题 $w^* = arg\min_{w} L(w)$

Step 3: 不断重复**Step 1**和**Step 2**

计算当前w的梯度 $\frac{d_L}{d_w}$

梯度下降

参数更新 $w' = w - \frac{d_L}{d_w} \cdot \eta$

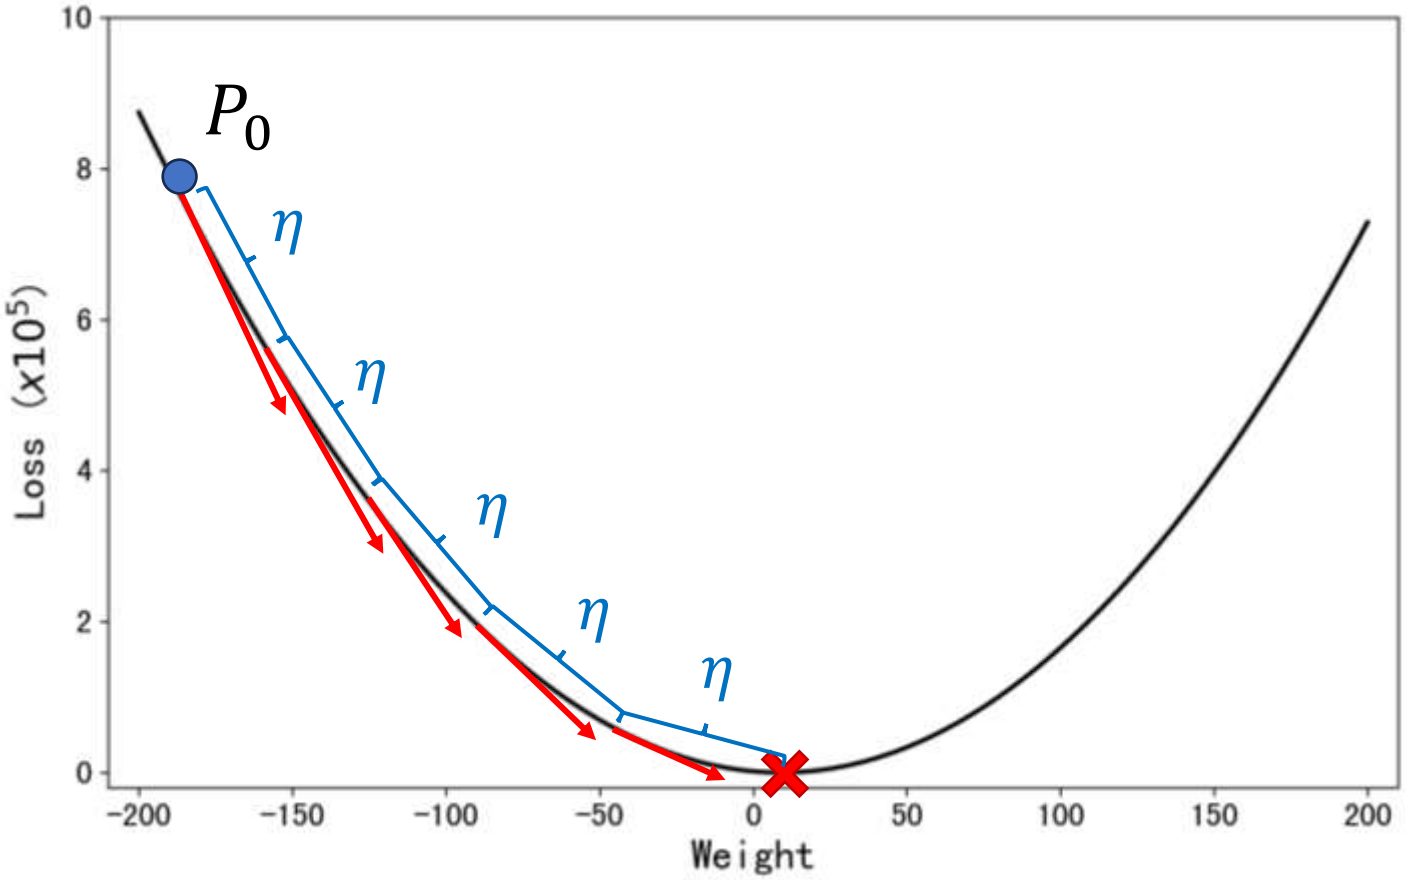

3.3 模型训练——梯度下降：基本思想

对于更加复杂的函数怎么办？$L(\boldsymbol{w}, b) = \sum_{i=1}^{N} w_i \cdot x_i + b$

Step 1: 计算各参数的偏导数 $\frac{\partial L}{\partial b}$， $\frac{\partial L}{\partial w_i}$

Step 2: 分别更新各参数 $b_{i+1} = b_i - \eta \frac{\partial L}{\partial b}$， $w_{i+1} = w_i - \eta \frac{\partial L}{\partial w_i}$

Step 3: 不断重复 **Step 1** 和 **Step 2**

3.3 模型训练——梯度下降：基本思想

$$-\frac{d_L}{d_w}\cdot\eta$$

理解 1：梯度描述变化速度

$$\frac{d_L}{d_w}$$

梯度数值越大，w变化越快

数值越小，表示变化越平缓

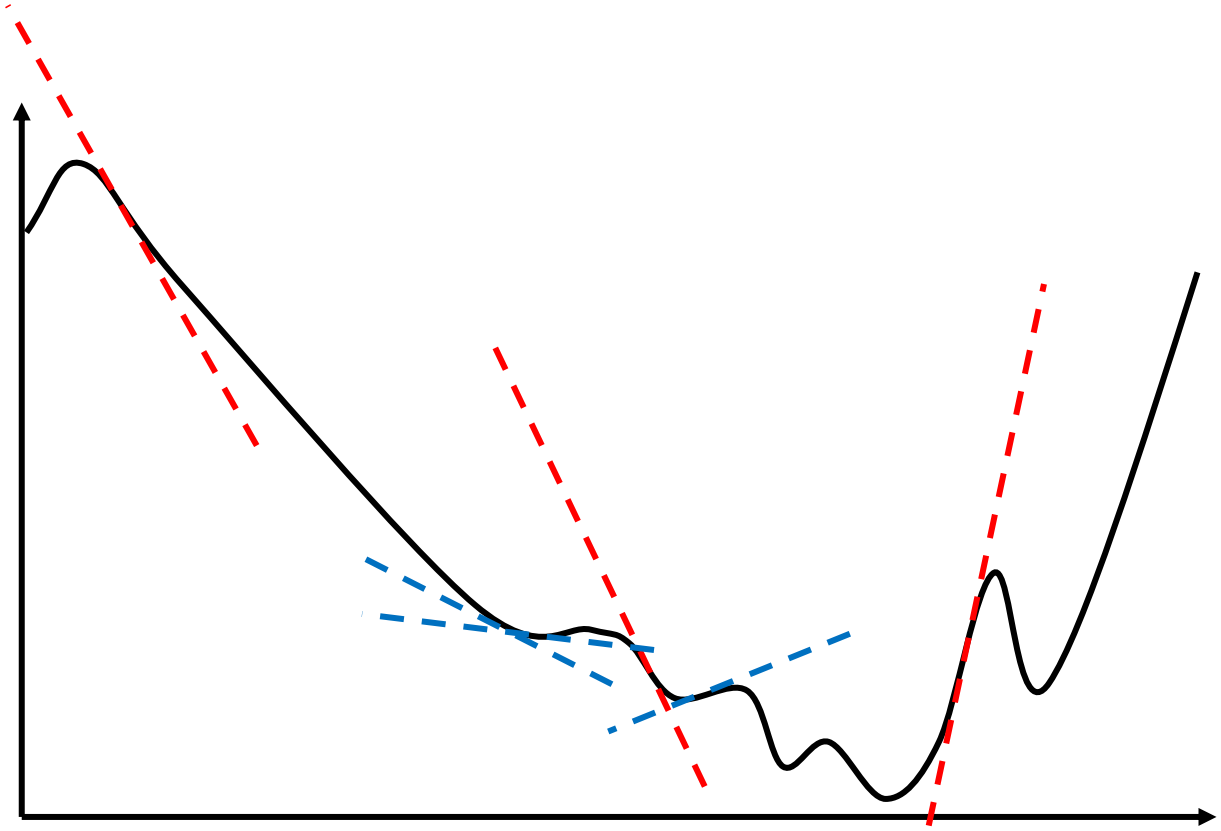

3.3 模型训练——梯度下降：基本思想

$$-\frac{d_L}{d_w}\cdot\eta$$

理解 1：梯度描述变化速度

理解 2：学习率为“步幅”，需谨慎设定

η

- 较大的学习率能提升模型训练效率
- 过于“激进”的学习率会“爆炸”
- 过于“谨慎”的学习率，会使模型训练效率极为低下

3.4 模型训练——学习率

在训练模型时……

理想情况

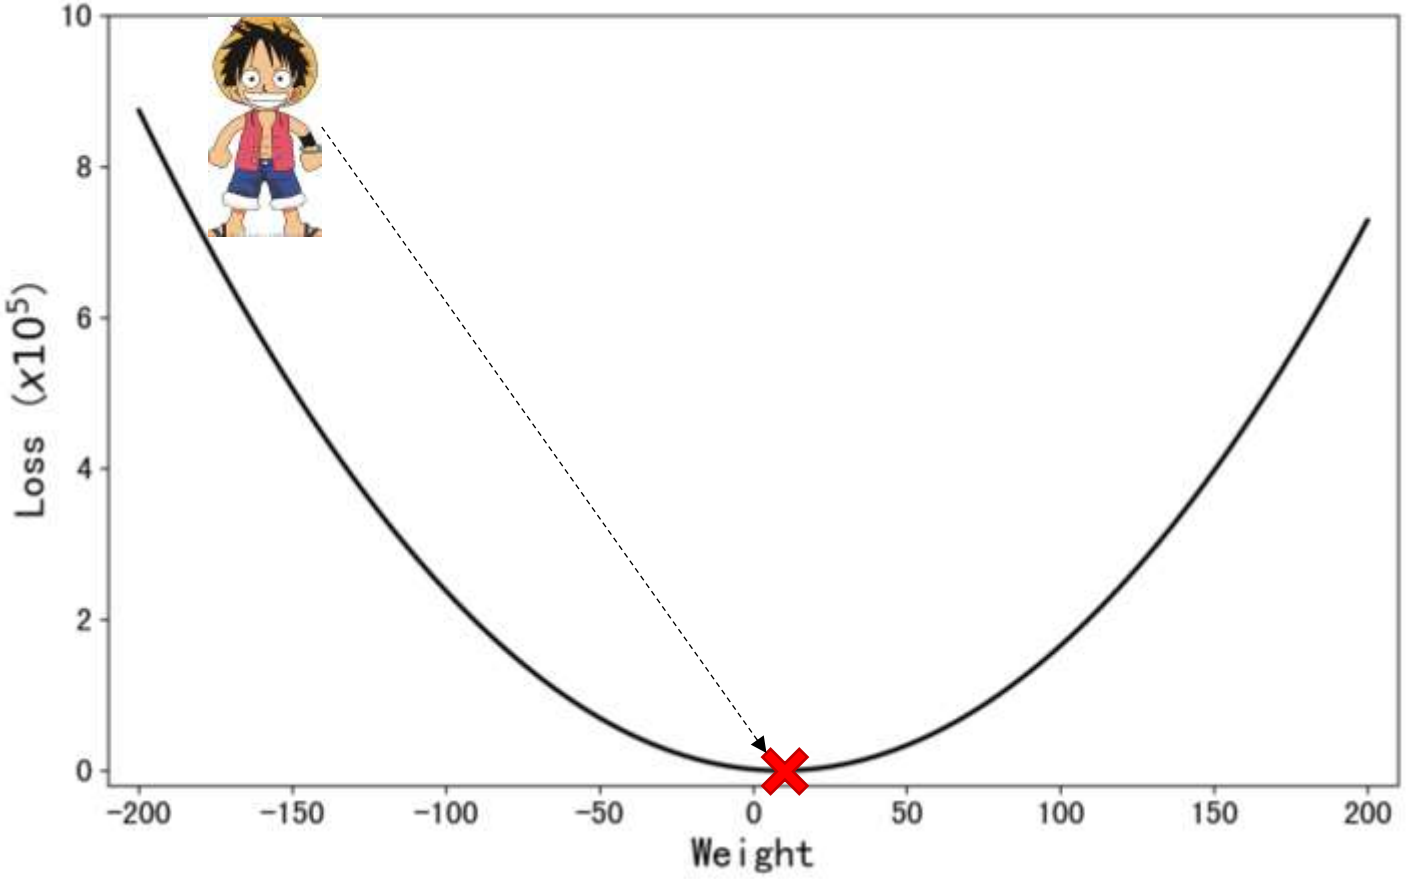

3.4 模型训练——学习率

在训练模型时……

实际情况

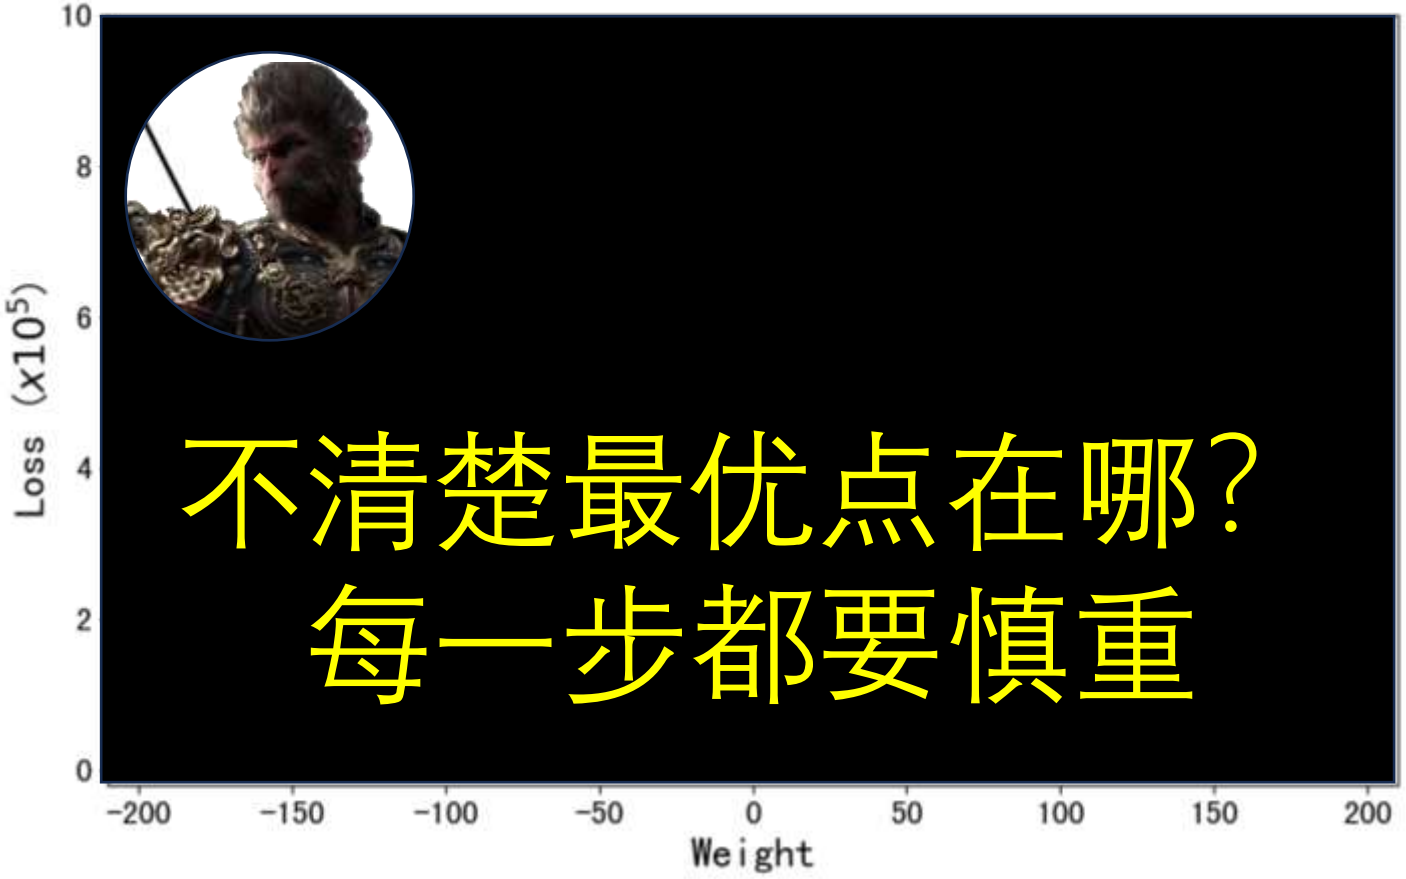

3.4 模型训练——学习率

当碰巧选择了合适的学习率，能在时间范围内收敛至最优点

$$\eta = 0.001$$

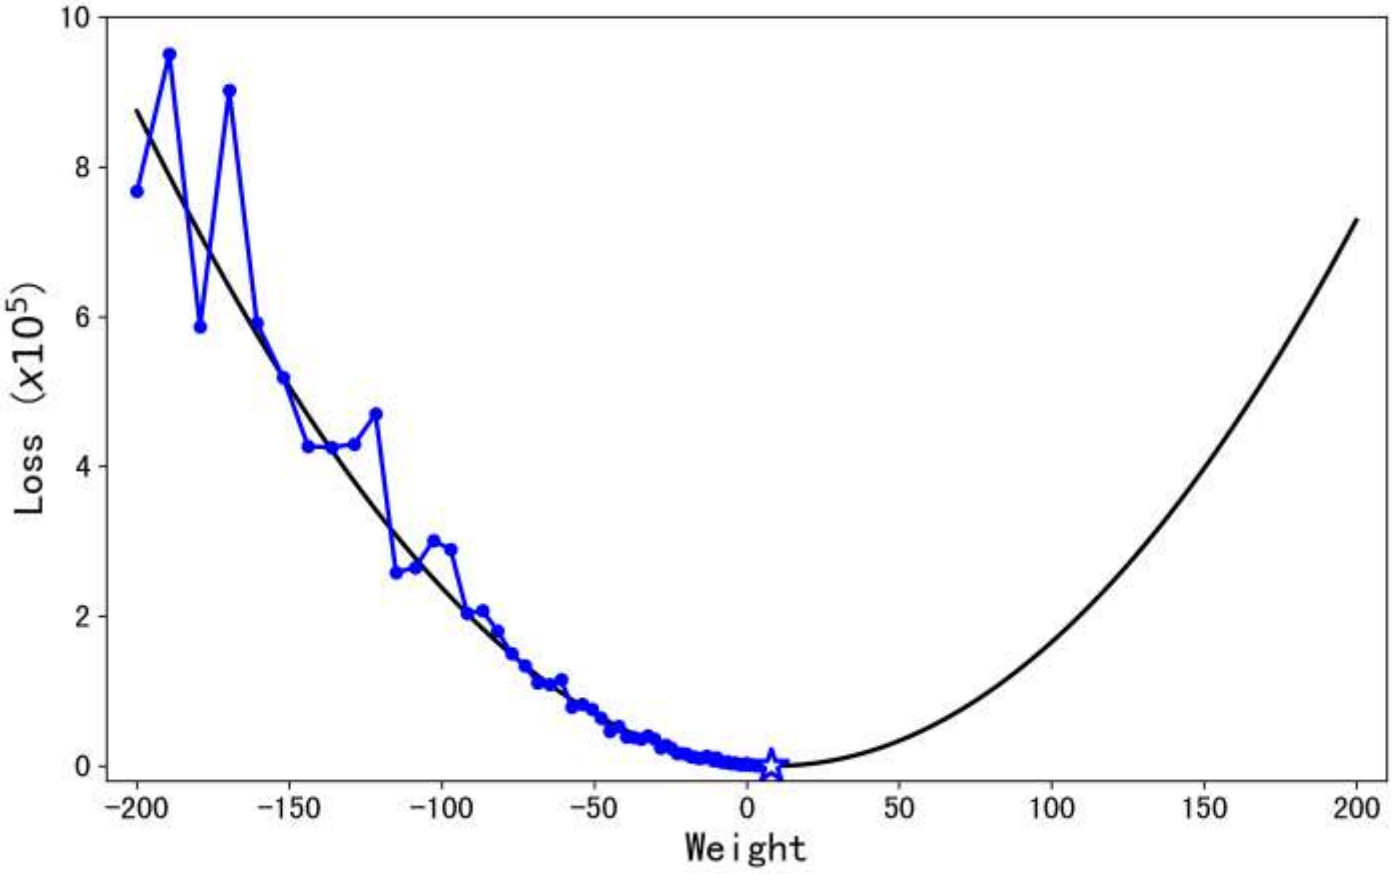

3.4 模型训练——学习率

更小一点的学习率，无法在规定的时间内收敛至最优点

$$\eta = 0.00001$$

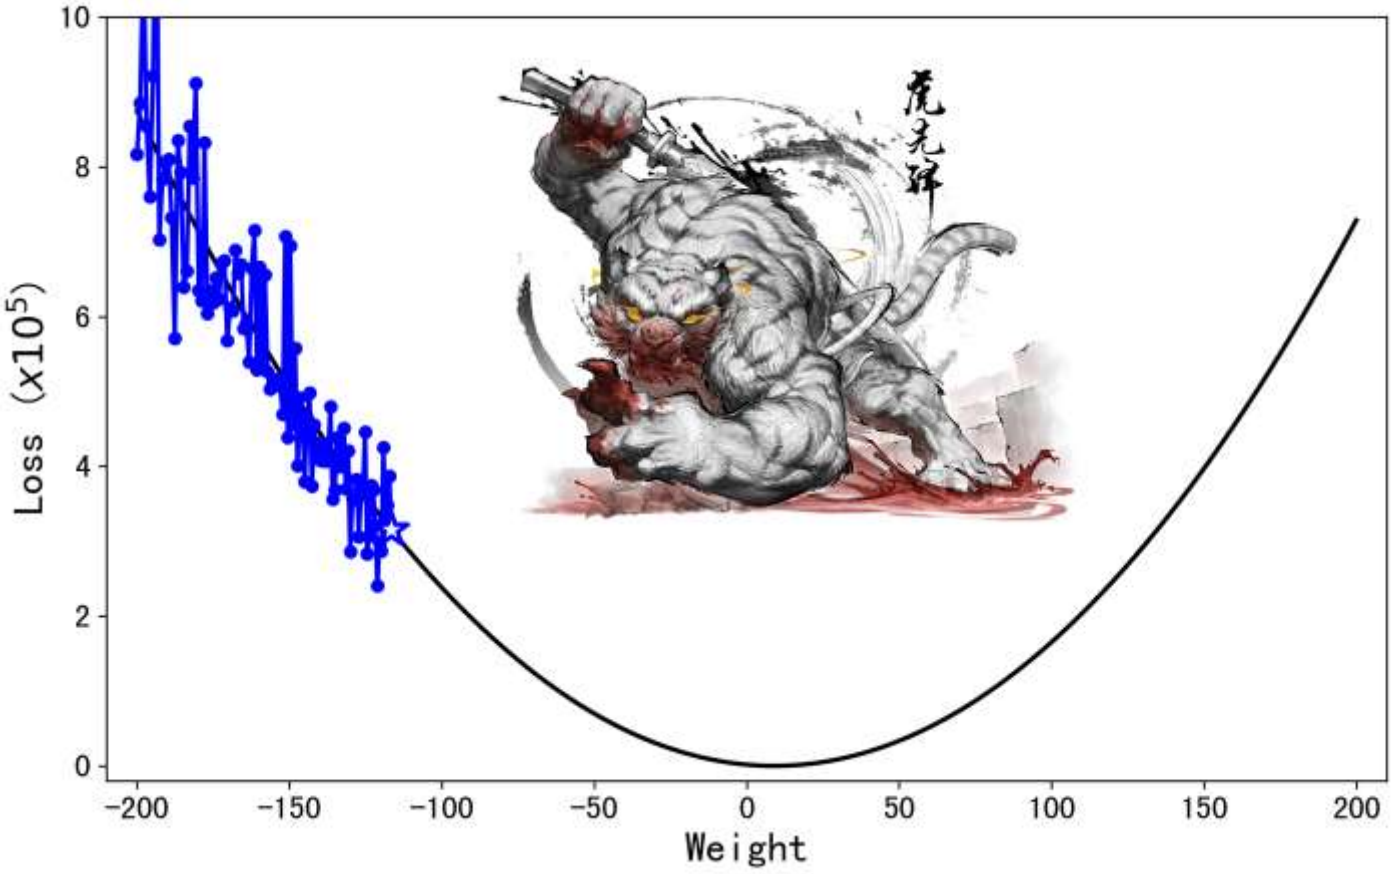

3.4 模型训练——学习率

再小一点的学习率，无法学到一点

$$\eta = 0.0000001$$

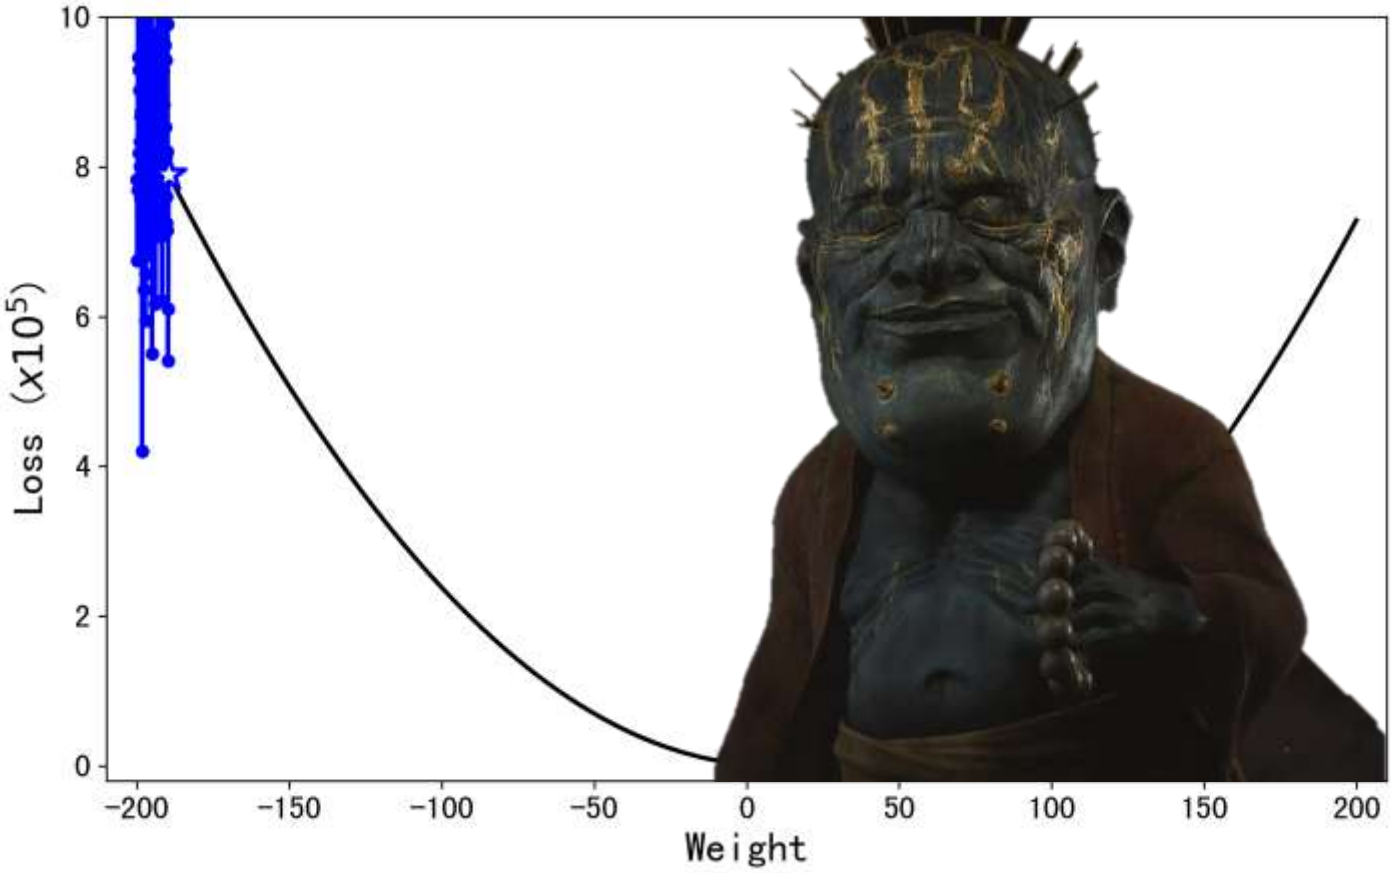

3.4 模型训练——学习率

调大一点学习率，能够更快速地逼近最优点

$$\eta = 0.0001$$

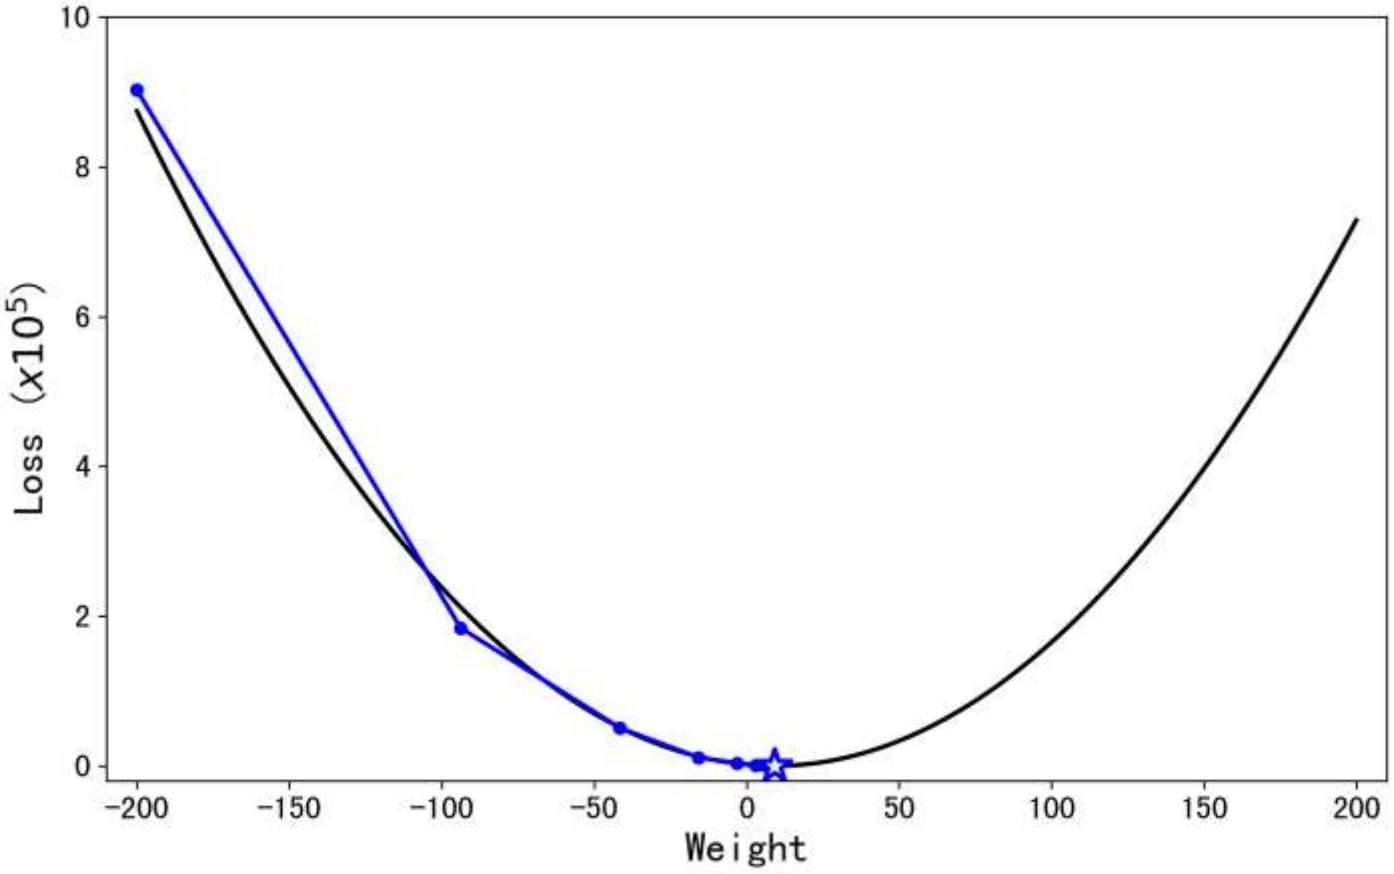

3.4 模型训练——学习率

如果学习率设更大一点，在最优点周围反复横跳

$$\eta = 0.003$$

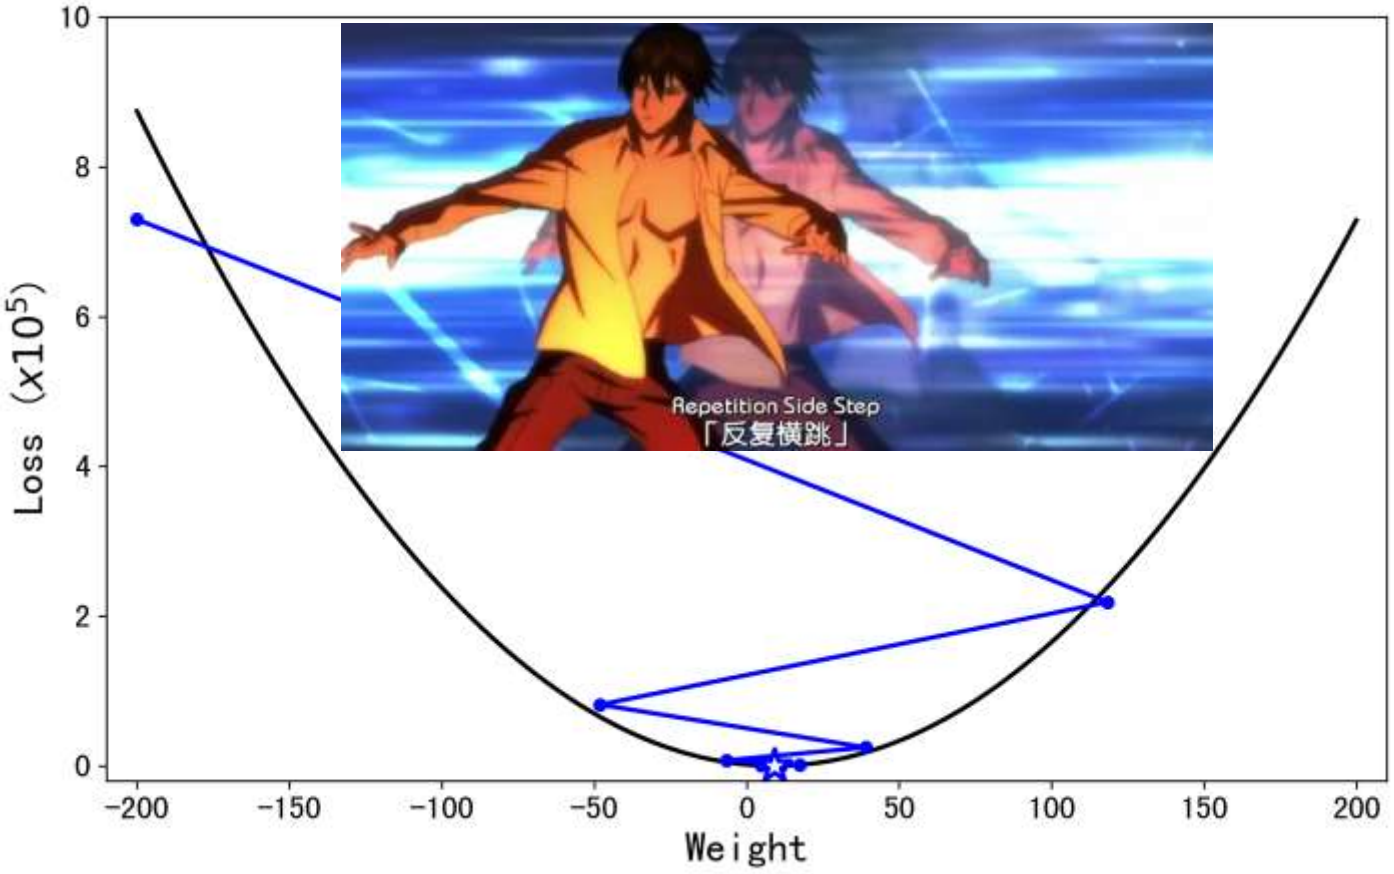

《在下版本有何贵干》

3.4 模型训练——学习率

如果学习率设再大一点，结果便不收敛了

$$\eta = 0.005$$

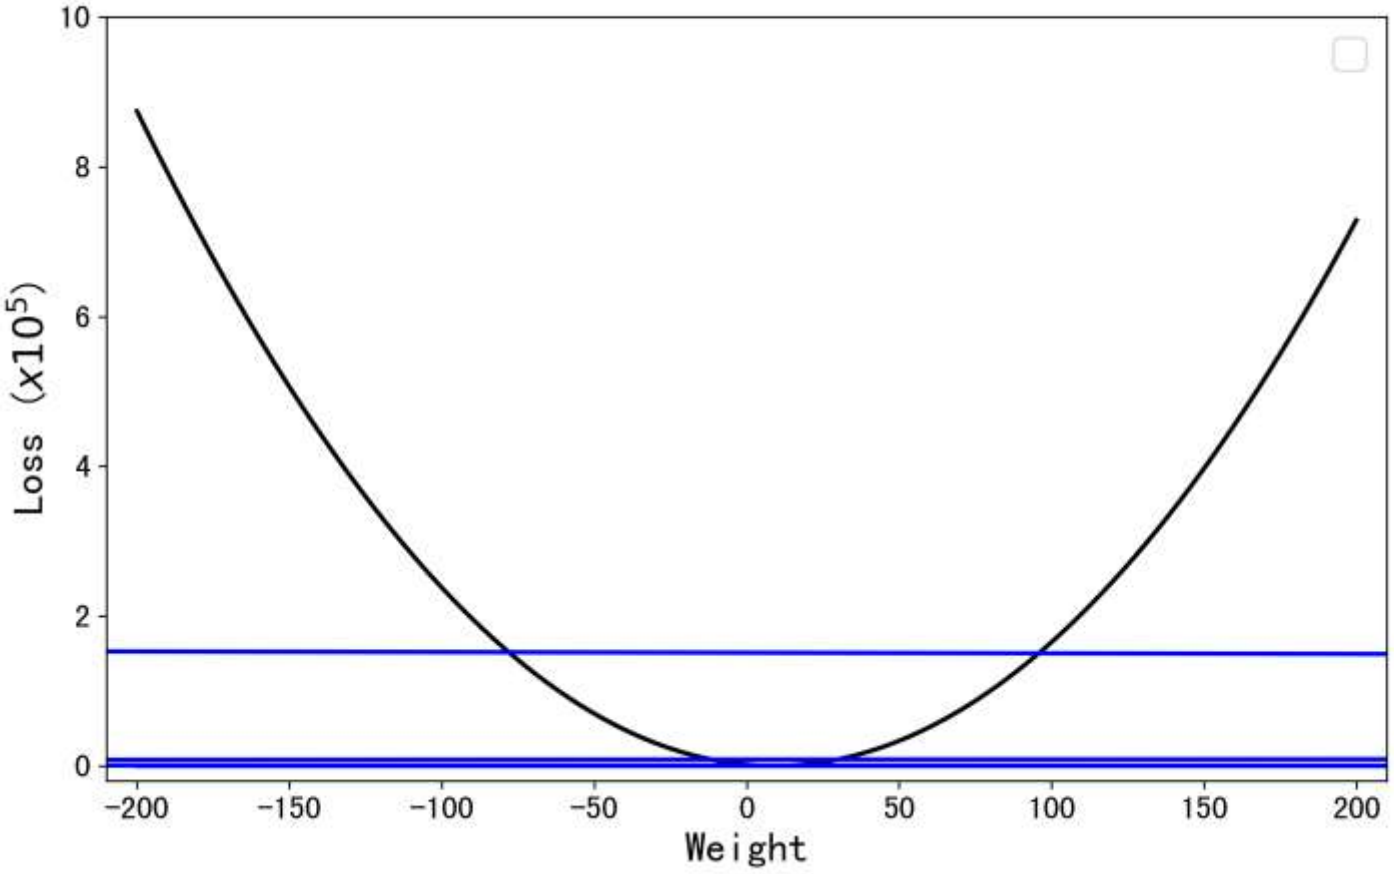

学习率最好是开始大，后来小

3.5 模型训练——自适应学习率（Adagrad）

让学习率随时间动态变小:

$$\eta = \frac{1}{T}\eta$$

学习率开始大，能够迅速靠近最优点

学习率随时间增加逐渐减小

在靠近最优点时，较小地学习率能够避免反复横跳，从而收敛

所有参数统一减小是好事吗？

3.5 模型训练——自适应学习率

观察右图，学习w和b 时有何不同:

学习w较快，学习b较慢

如果w和b的学习率同步减小，则b可能难以收敛至最优

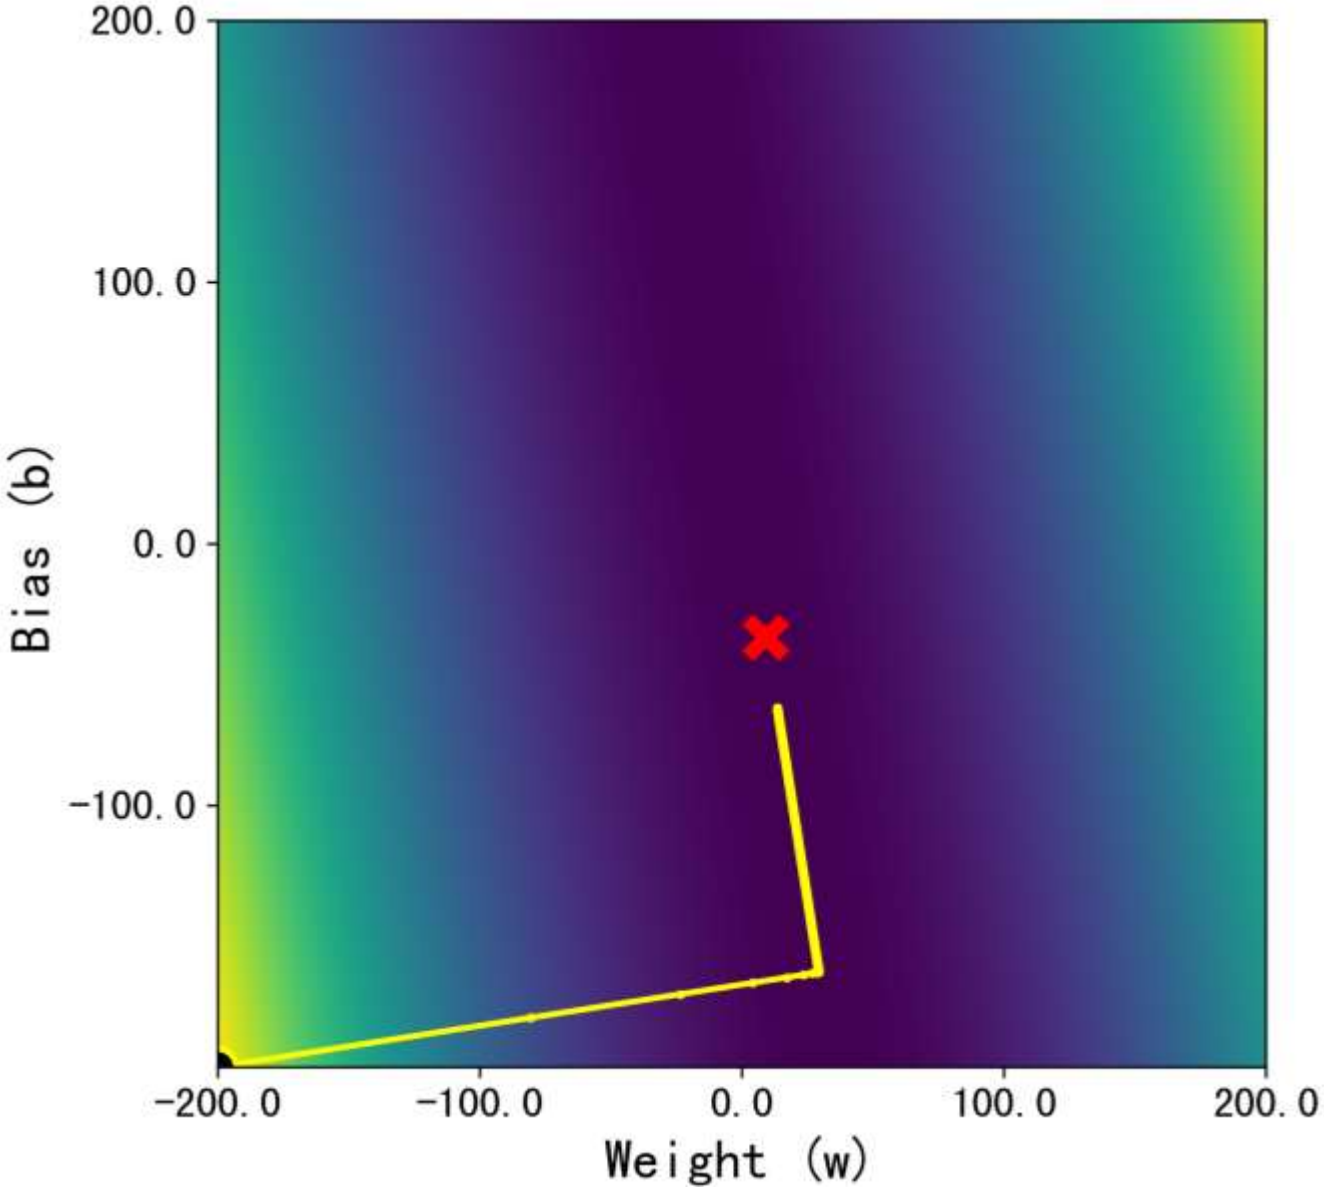

最好根据参数定制

学习率衰减方式

3.5 模型训练——自适应学习率 Adagrad

Adagrad 数学公式:

$$\eta_w = \frac{1}{\boxed{\sqrt{\sum_{i=1}^{T}\left(dw_i - \overline{dw}\right)^2}}}\eta_w$$

前T次计算所得之dw的**标准差**

前路平坦就冲
道阻且长就怂

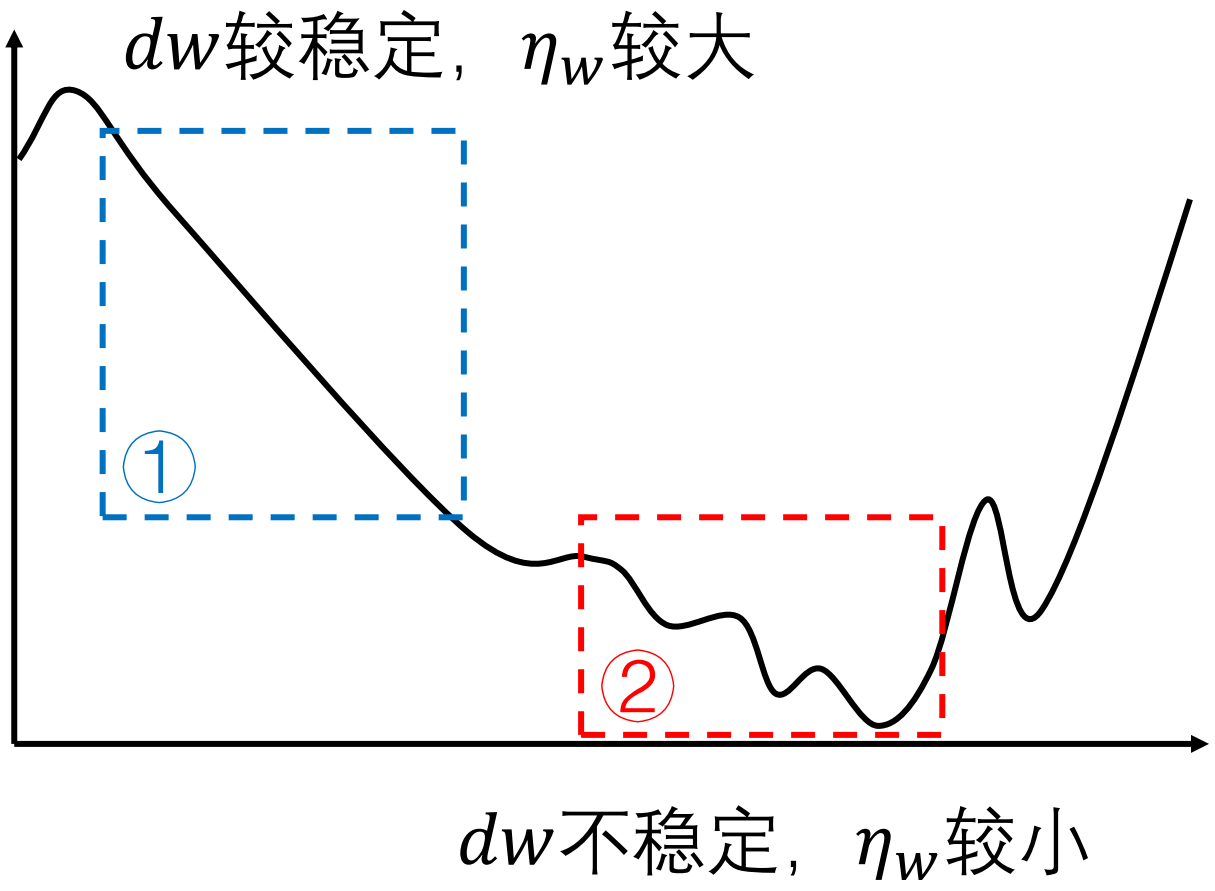

3.5 模型训练——自适应学习率 Adagrad

在训练时应用Adagrad，各参数都能较为快速的收敛

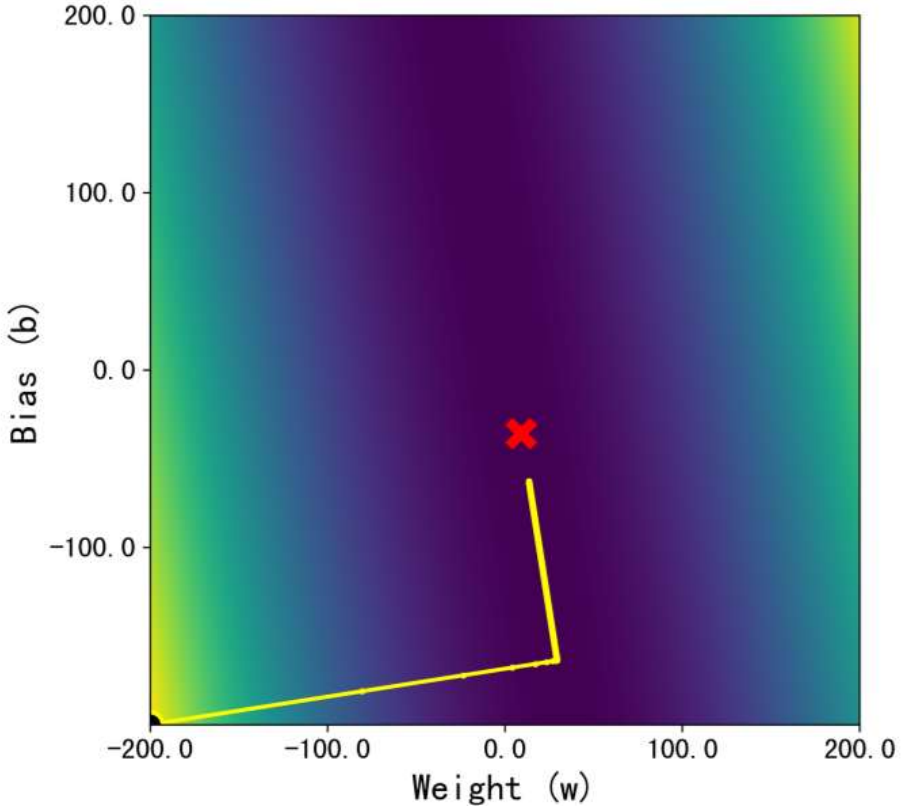

With Adagrad

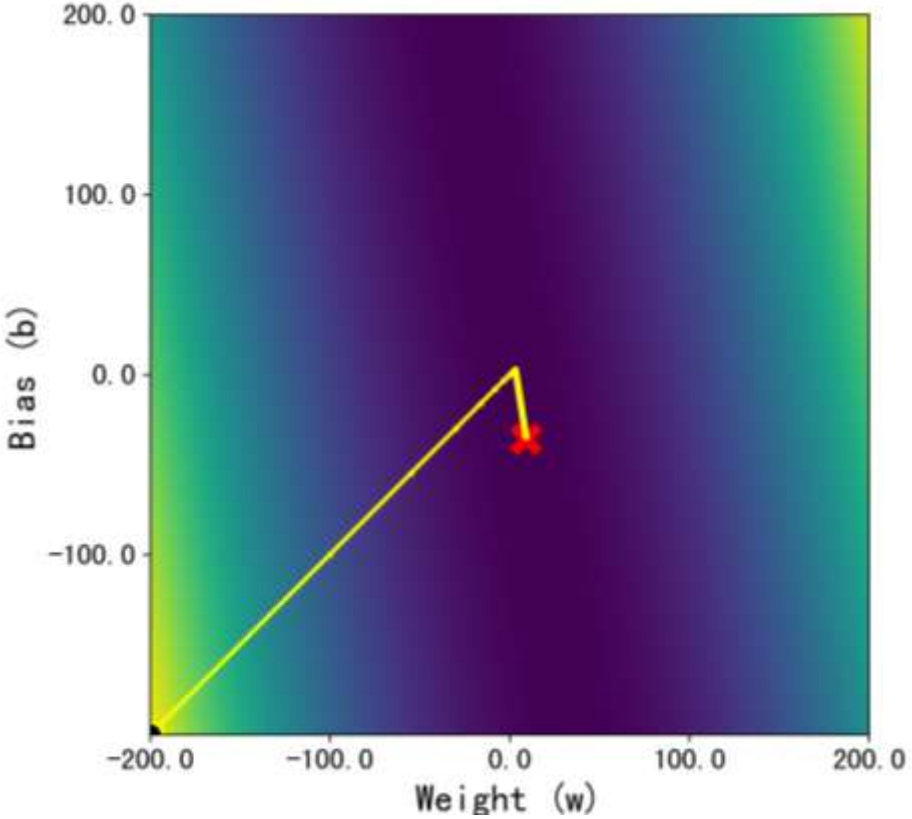

Without Adagrad

接下来尝试一下分类问题

案例研究

基于MNIST数据集的手写字母识别

3.6 分类问题——手写识别MNIST数据集简介

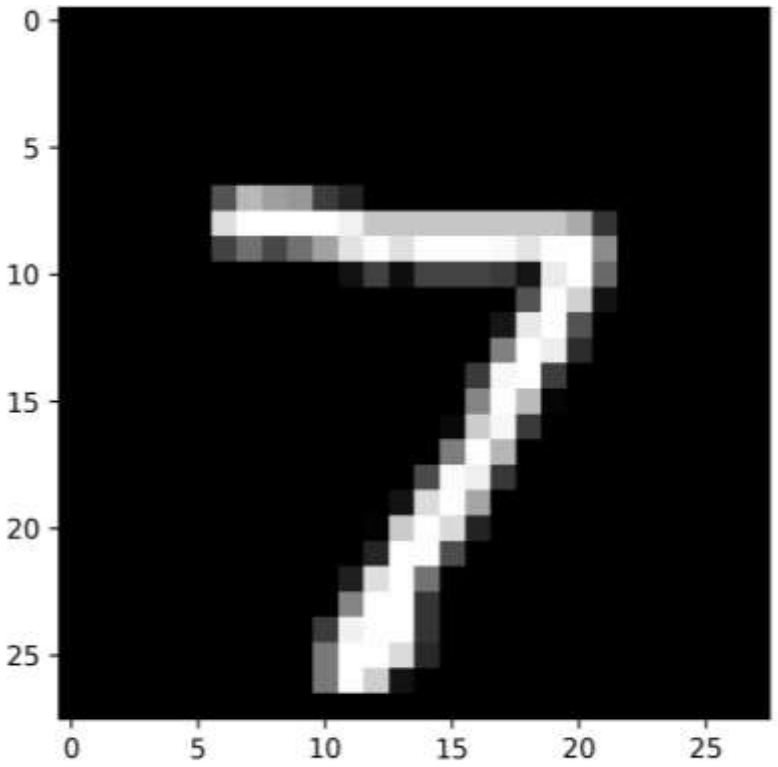

Size: 28 X 28 X 1

MNIST： Mini-NIST

60000 个训练样本

10000 个测试样本

Yann LeCun

Pioneer of CNN

Yann LeCun, Corinna Cortes, and Christopher J.C. Burges. The MNIST database of handwritten digits. https://yann.lecun.com/exdb/mnist/

3.6 分类问题是一种什么样的任务呢？

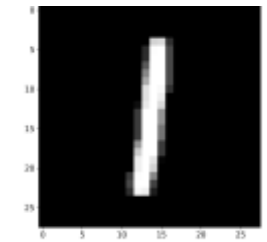

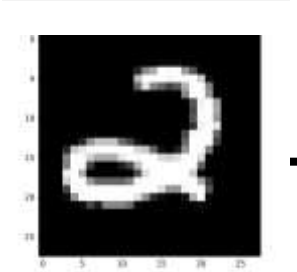

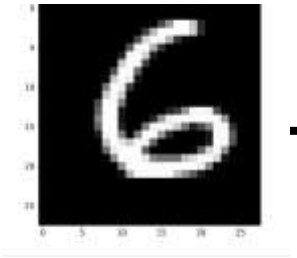

分类器

0	1	2	3	4	5	6	7	8	9
0.01	0.83	0.01	0.01	0.07	0.01	0.03	0.01	0.01	0.01
0.00	0.00	0.58	0.08	0.00	0.34	0.00	0.00	0.00	0.00
0.00	0.00	0.04	0.00	0.00	0.00	0.95	0.00	0.01	0.00

3.6 分类问题是一种什么样的任务呢？

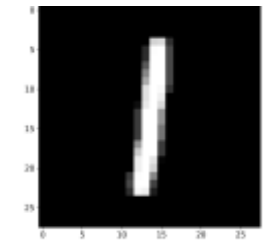

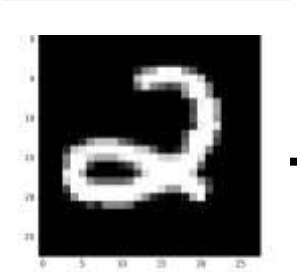

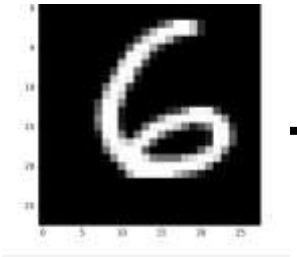

分类器

0	1	2	3	4	5	6	7	8	9
0.01	0.83	0.01	0.01	0.07	0.01	0.03	0.01	0.01	0.01
0.00	0.00	0.58	0.08	0.00	0.34	0.00	0.00	0.00	0.00
0.00	0.00	0.04	0.00	0.00	0.00	0.95	0.00	0.01	0.00

3.6 分类问题是一种什么样的任务呢？

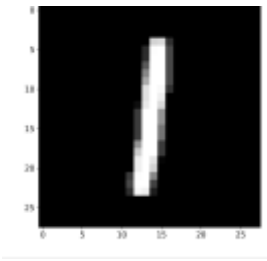

→ 分类器

0	1	2	3	4	5	6	7	8	9
0.01	0.83	0.01	0.01	0.07	0.01	0.03	0.01	0.01	0.01

$\in$ [0, 1.0]

这难道不是连续的数值吗？

怎么可以叫分类呢？

可以根据标签判断	0	1	0	0	0	0	0	0	0	0

	回归问题	分类问题
任务目标	预测或推测	归类
输出结果	连续的数值	离散的数值

3.6 分类问题是一种什么样的任务呢？

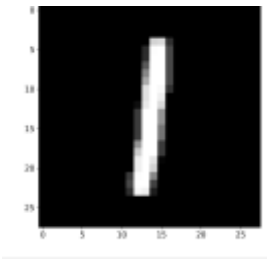

→ 分类器

0	1	2	3	4	5	6	7	8	9
0.01	0.83	0.01	0.01	0.07	0.01	0.03	0.01	0.01	0.01

$\in$

[0, 1.0]

假设：仅需要知道图片是“1”的概率，不需明确手写的字母类型是什么，那是什么任务呢？

如果是这样的话，称作回归也不是不可以

	回归问题	分类问题
任务目标	预测或推测	归类
输出结果	连续的数值	离散的数值

3.7 为什么线性回归不适合分类任务？

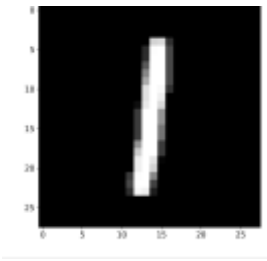

→ 回归模型

0	1	2	3	4	5	6	7	8	9
$-\infty$	$\geqslant 0.5$	$\geqslant 1.5$	$\geqslant 2.5$	$\geqslant 3.5$	$\geqslant 4.5$	$\geqslant 5.5$	$\geqslant 6.5$	$\geqslant 7.5$	$\geqslant 8.5$
<0.5	<1.5	<2.5	<3.5	<4.5	<5.5	<6.5	<7.5	<8.5	$+\infty$

回归好像可以做分类？

3.7 为什么线性回归不适合分类任务？

线性回归分类（24.36%）

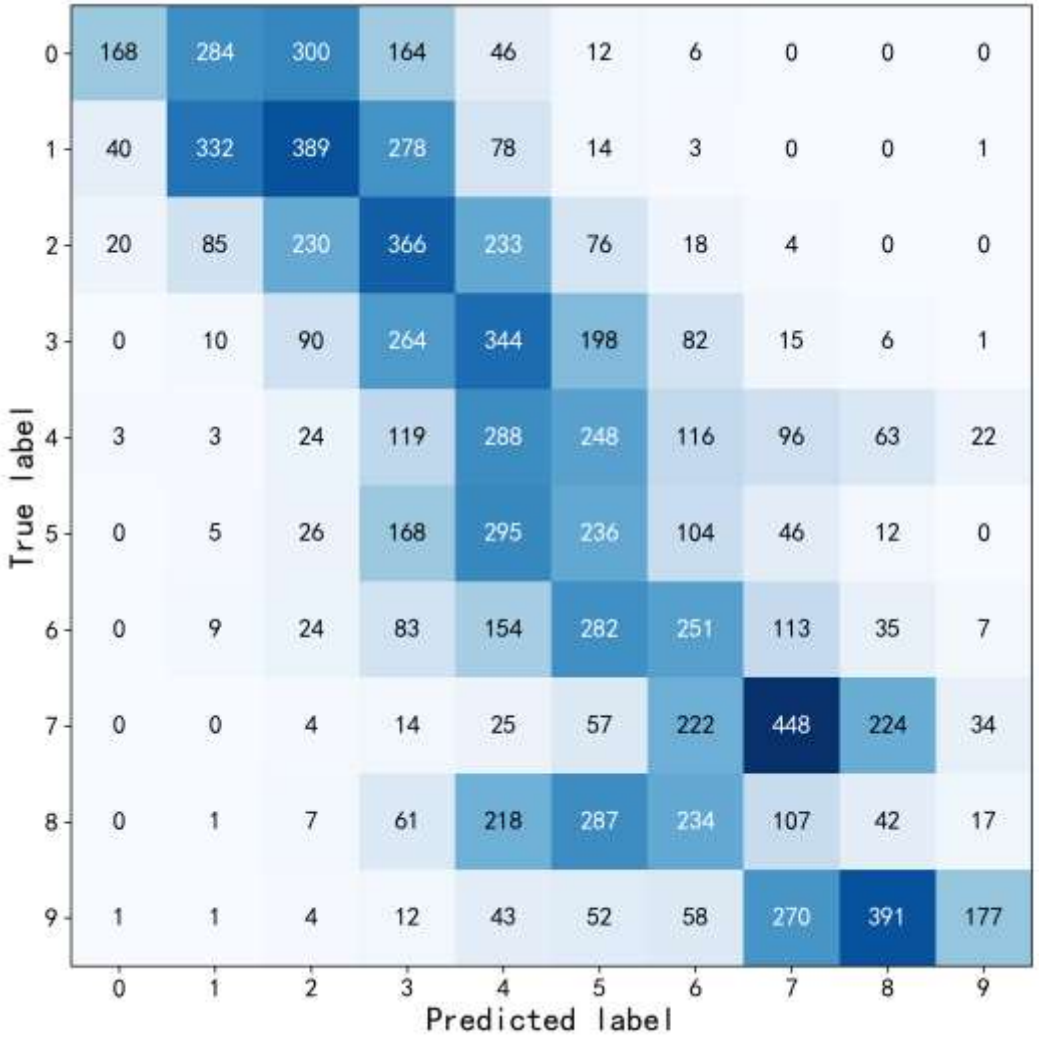

专门的分类方法（87.31%）

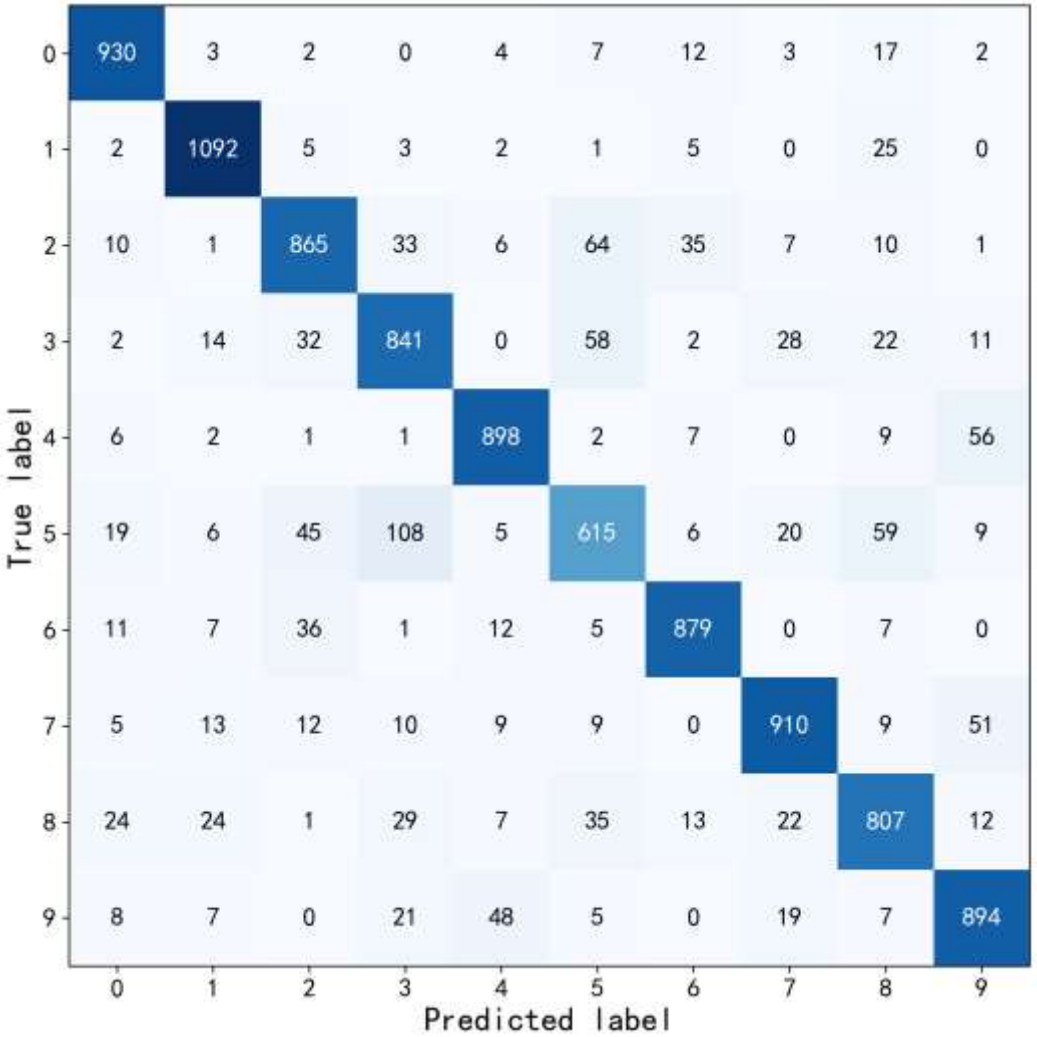

3.7 为什么线性回归不适合分类任务？

实验：比较**线性回归模型**和**分类模型**在不同样本数量条件下的分类结果

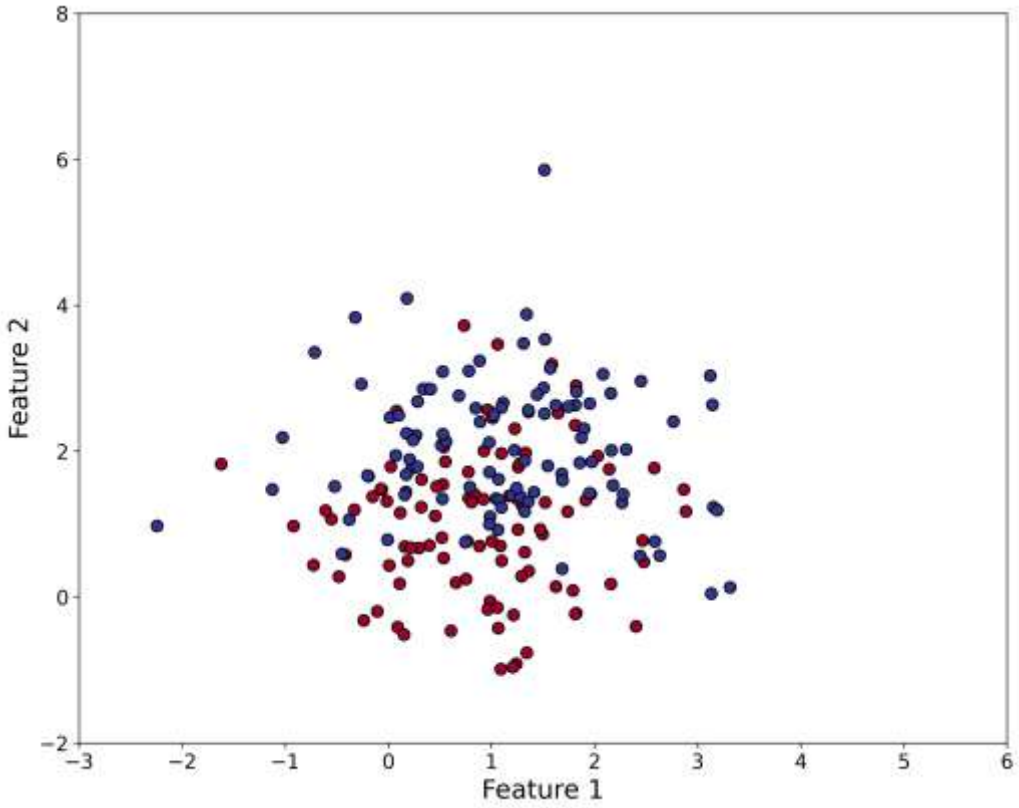

- 类型：1　数量：100
- 类型：0　数量：100

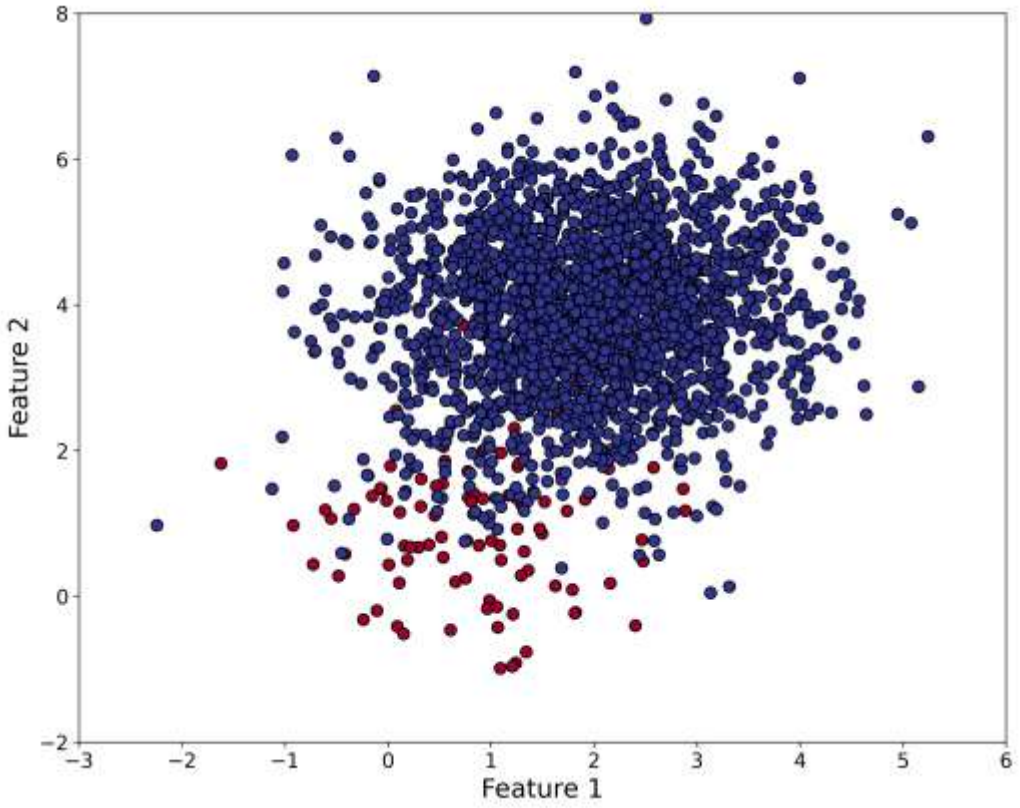

- 类型：1　数量：100+2000
- 类型：0　数量：100

3.7 为什么线性回归不适合分类任务？

线性回归

$$y = w_1 x_1 + w_2 x_2 + b$$

$$y \in \{0, 1\}$$

$$\hat{y} \in [-\infty, +\infty]$$

分类模型

$$y = f_c(w_1, w_2, b)$$

$$y \in \{0, 1\}$$

$$\hat{y} \in [0, 1]$$

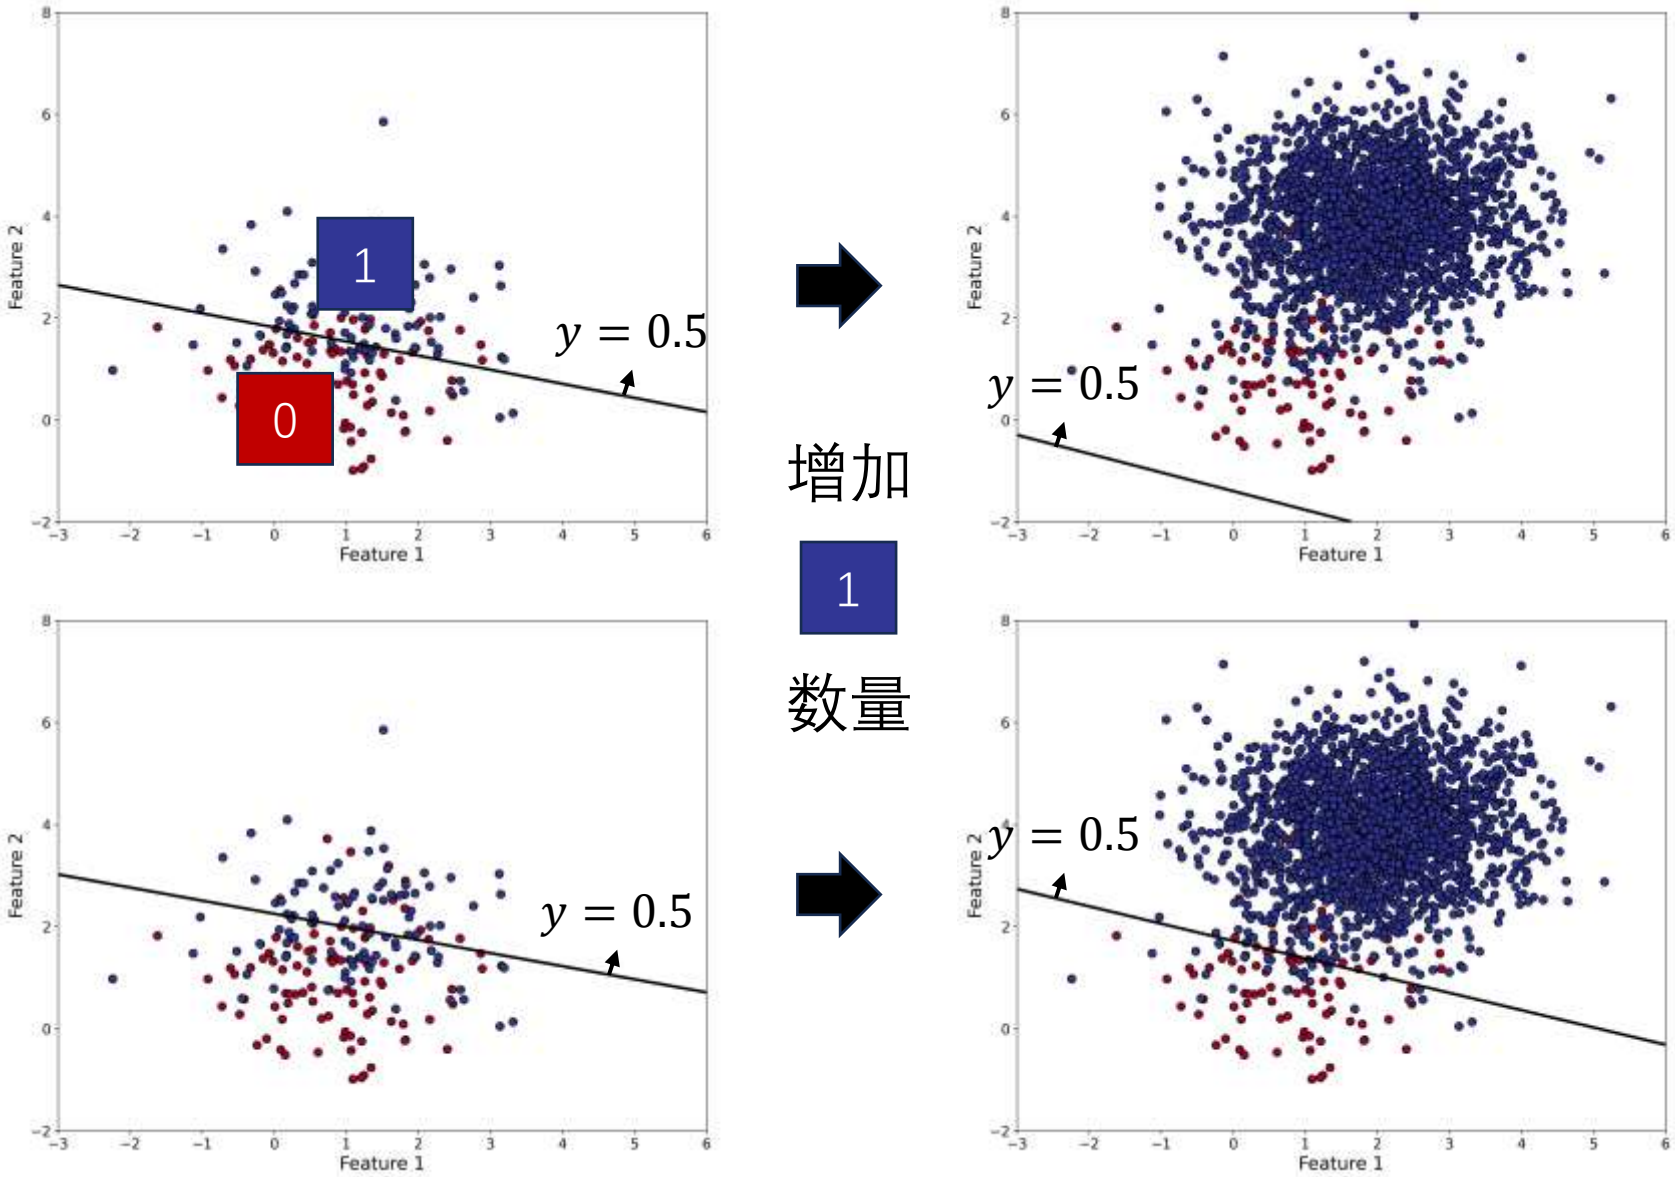

3.7 为什么线性回归不适合分类任务？

线性回归的目的——找到最佳的拟合函数

实际上是拟合标签的数值，并非区分样本类别

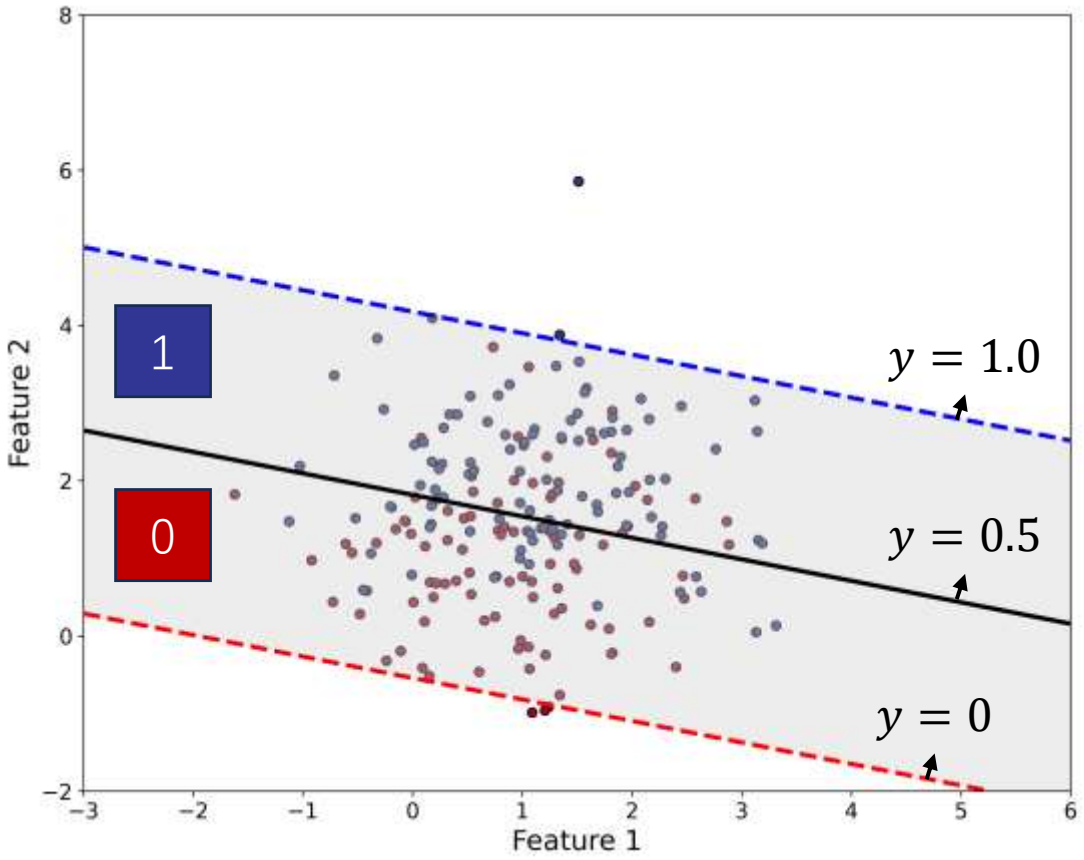

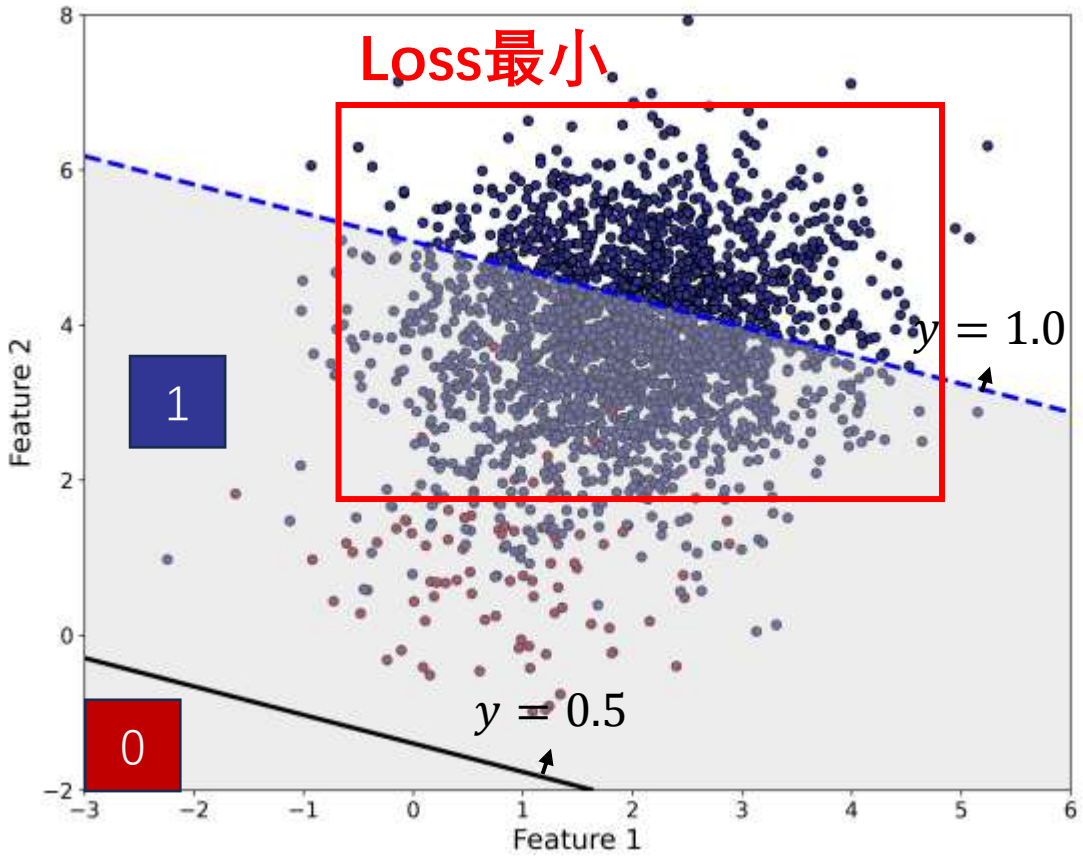

3.8 由线性回归到逻辑回归

分类器的目的——找出类别间的边界

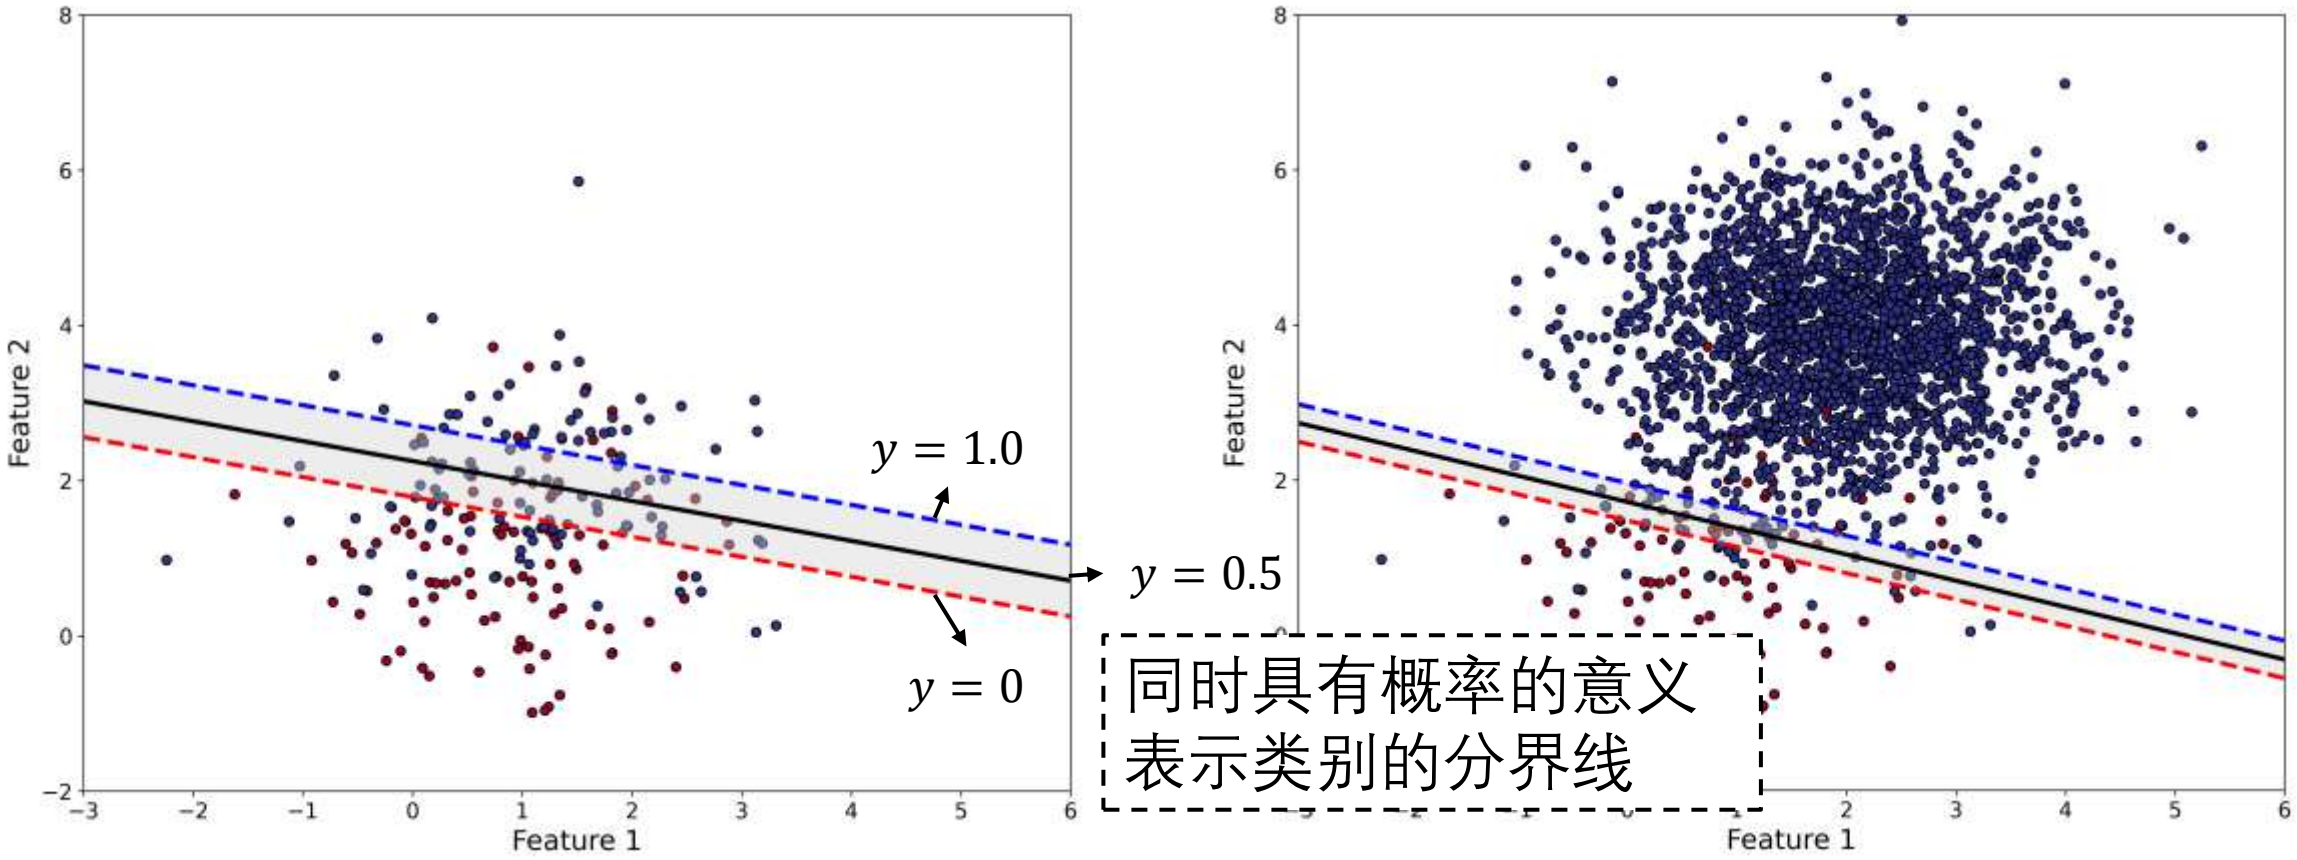

同时具有概率的意义
表示类别的分界线

3.8 由线性回归到逻辑回归

分类器的目的——找出类别间的边界

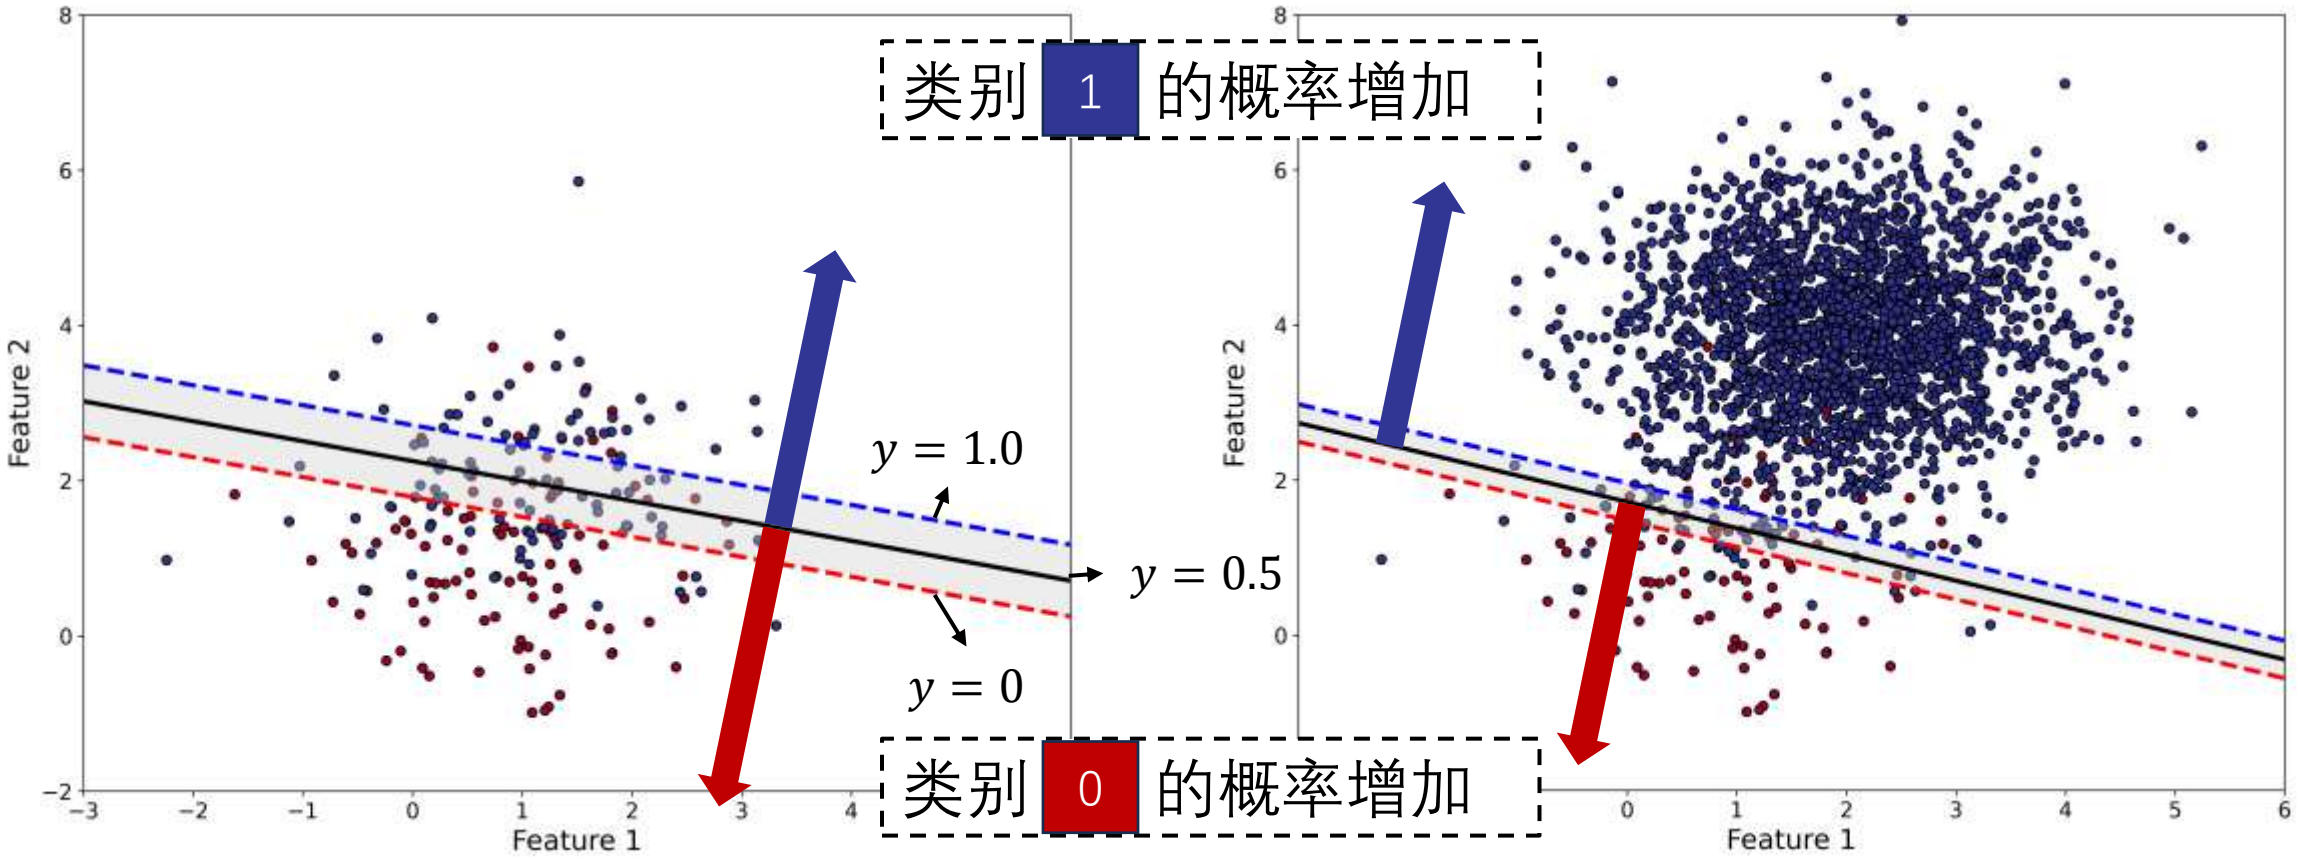

3.8 由线性回归到逻辑回归

分类器的目的——找出类别间的边界

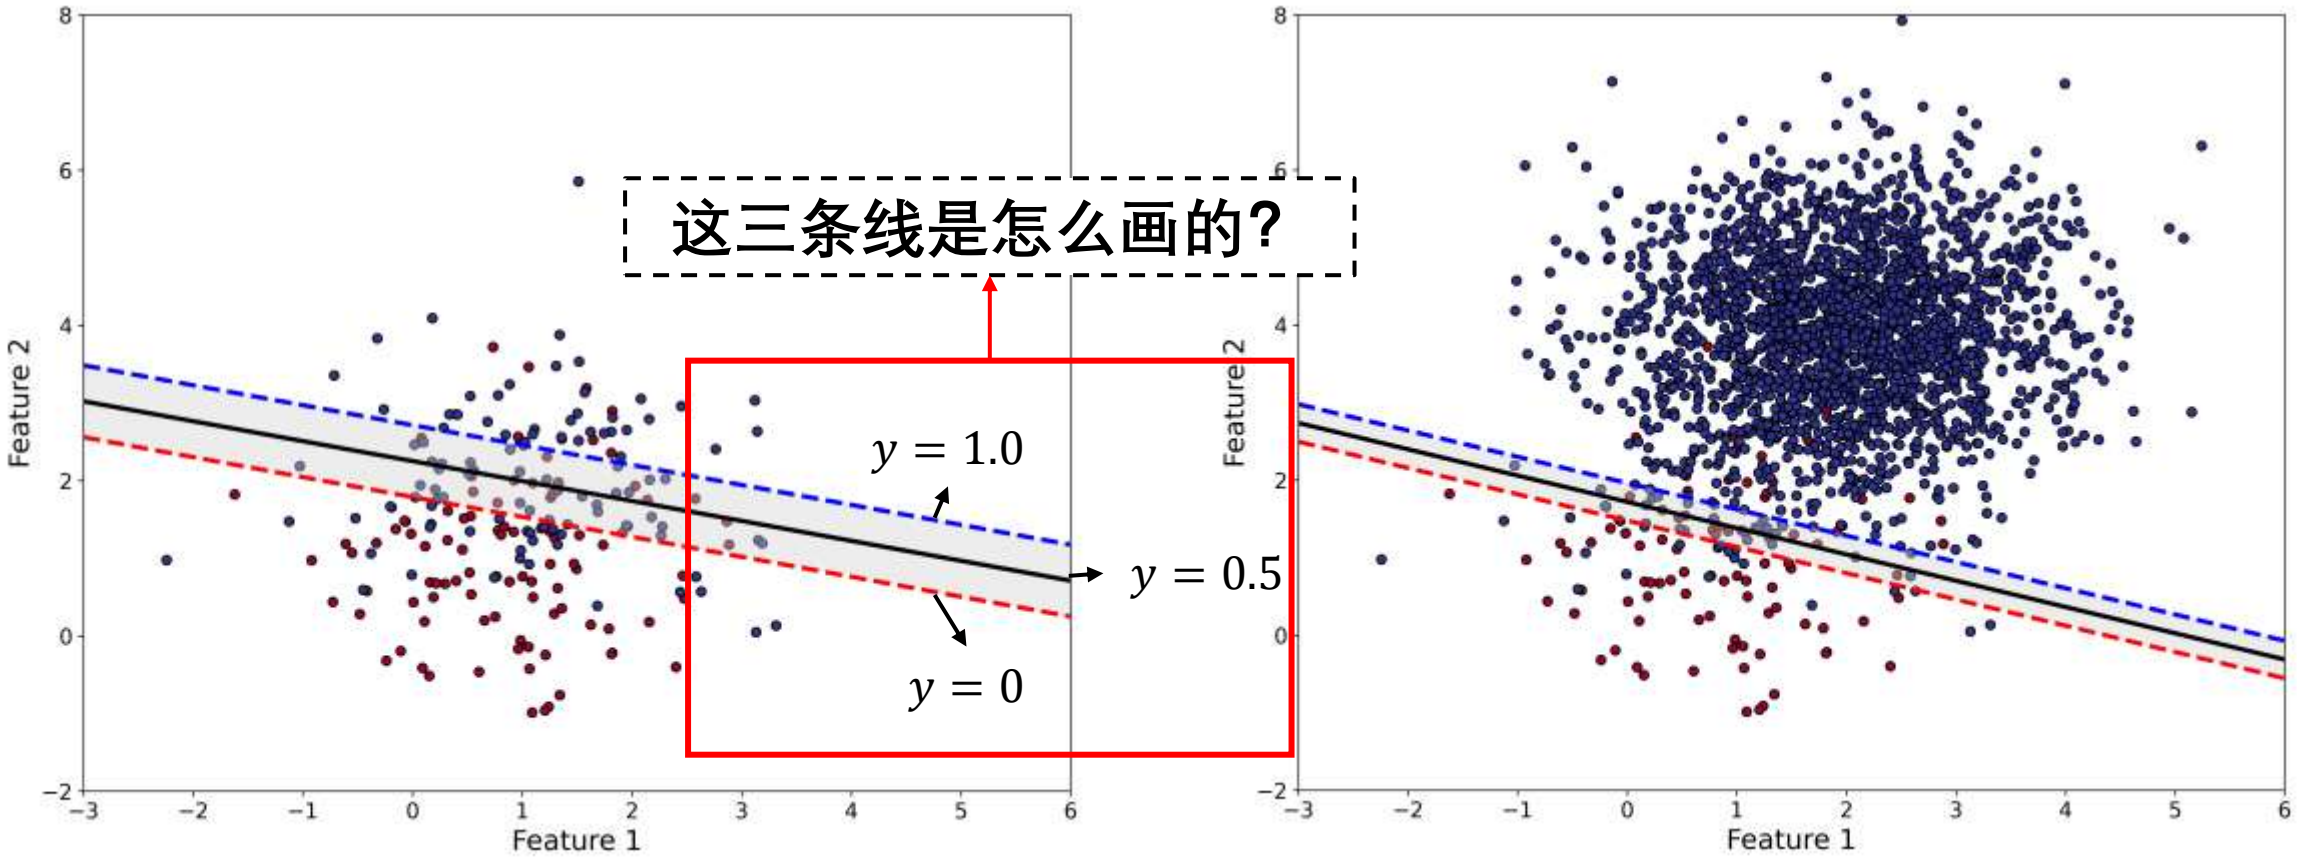

3.8 由线性回归到逻辑回归

分类器的目的——找出类别间的边界

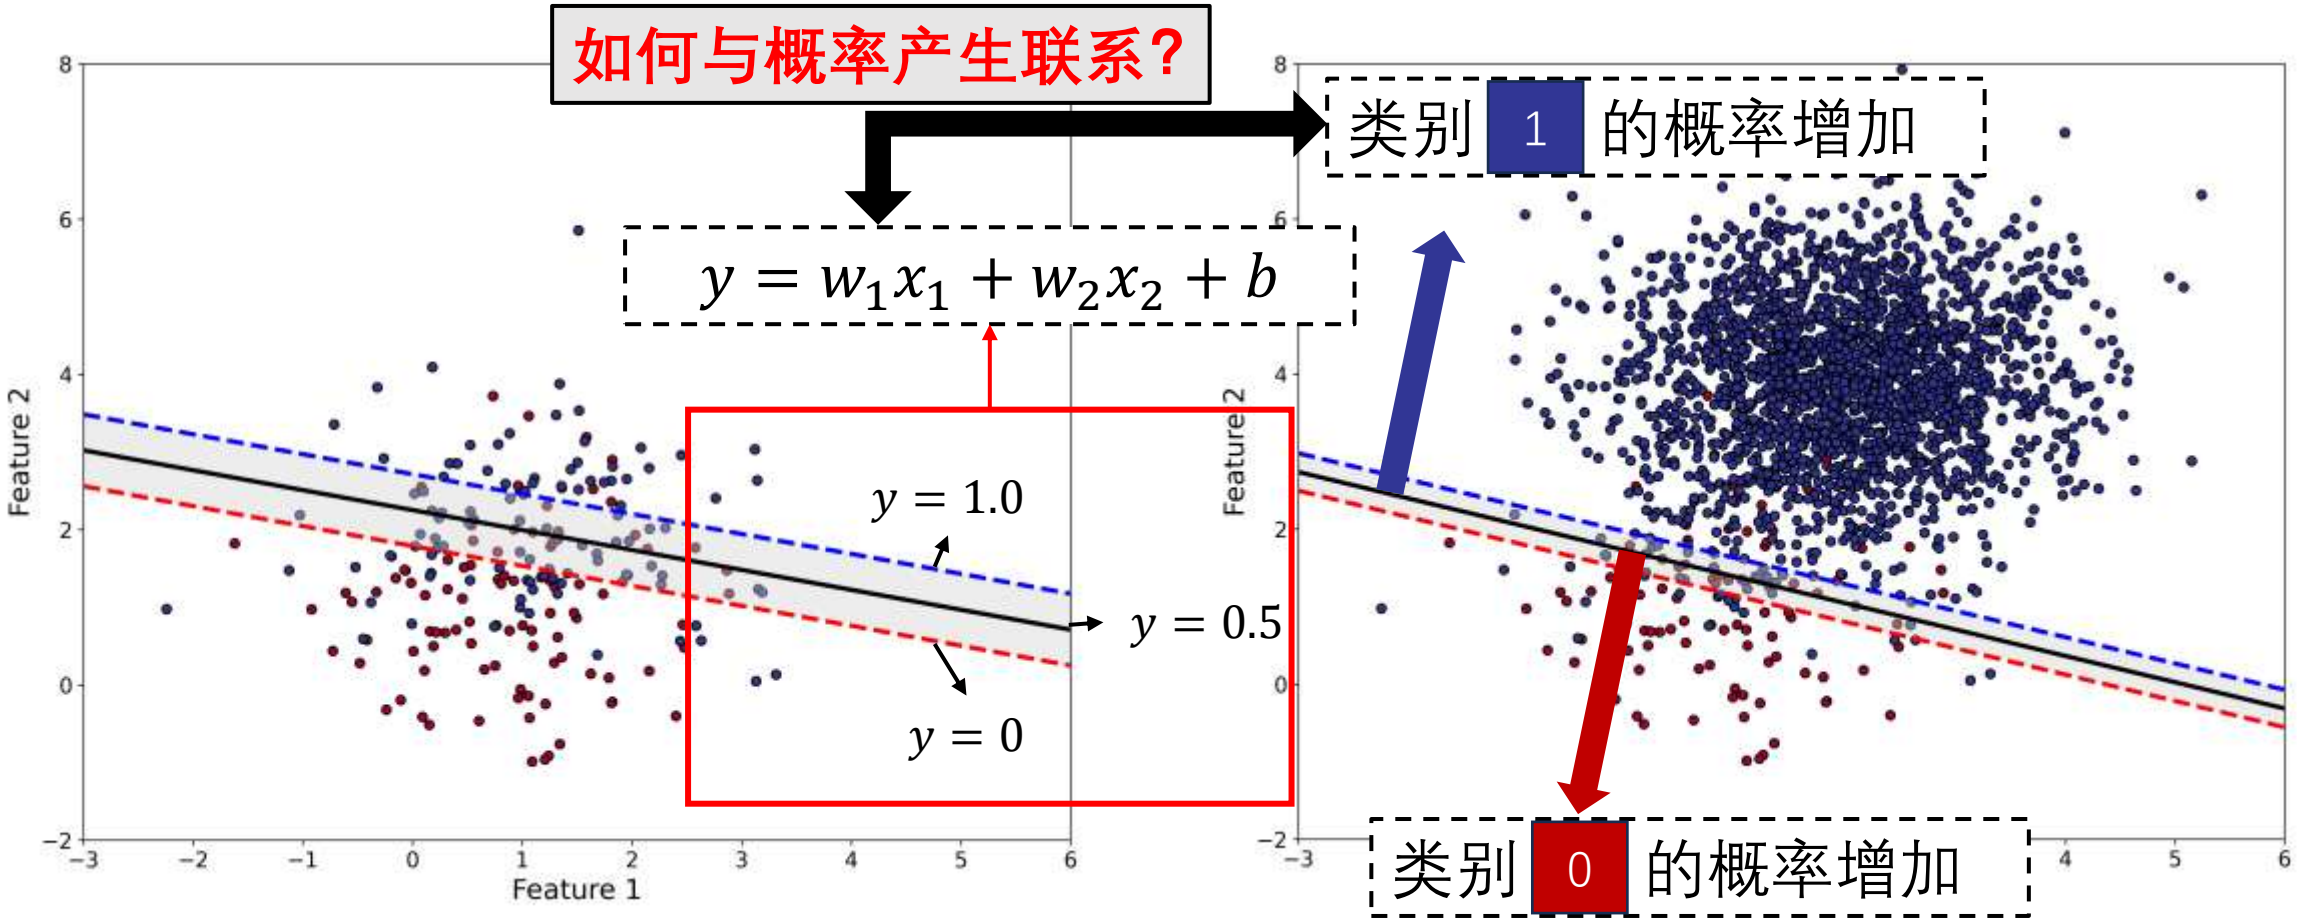

3.8 由线性回归到逻辑回归——Sigmoid函数

如何与概率产生联系？

$$y = w_1x_1 + w_2x_2 + b \quad \in (-\infty, +\infty)$$

$$y = \boxed{P(x_1, x_2, b)} \quad \in [0, 1] \ \rightarrow [0\%, 100\%]$$

Sigmoid函数

3.8 由线性回归到逻辑回归——Sigmoid函数

！！！ Sigmoid函数！！！

$$y = \frac{1}{1 + e^{-z}}$$

3.8 由线性回归到逻辑回归——Sigmoid函数

直观理解Sigmoid函数 $y = \dfrac{1}{1+e^{-z}}$

$z = w_1x_1 + w_2x_2 + b$

$z \in (-\infty, +\infty)$

$y \in [0, 0.5) \rightarrow 0$

$y \in [0.5, 1] \rightarrow 1$

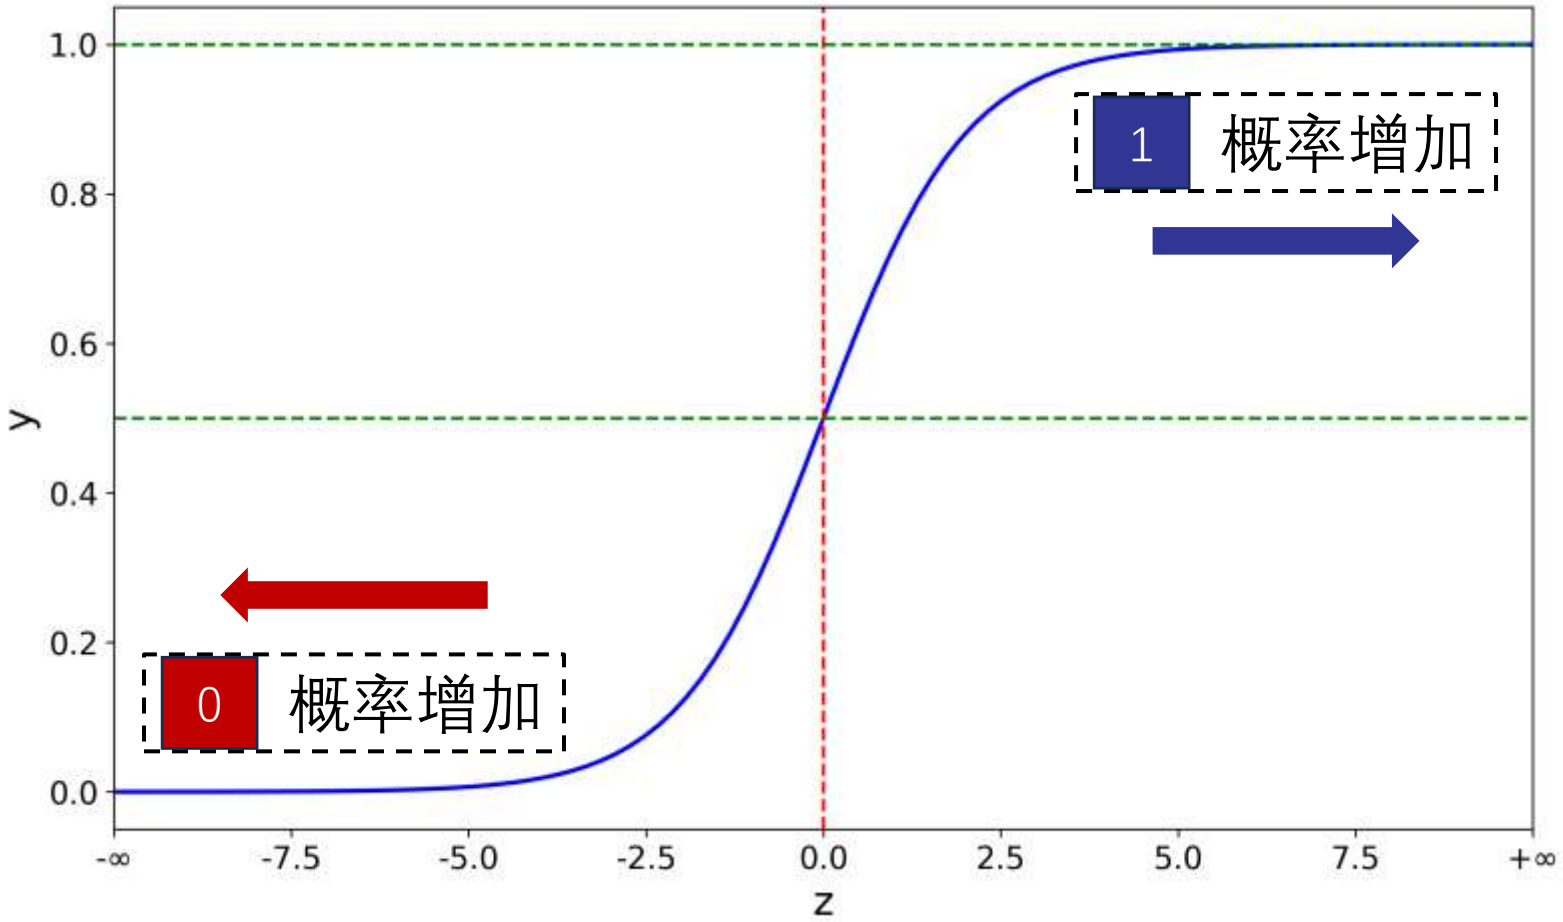

3.8 由线性回归到逻辑回归——Sigmoid函数

逻辑回归就是“给线性回归模型加一层Sigmoid映射函数”

$$y = \frac{1}{1 + e^{-z}}, \qquad z = \sum w_i x_i + b$$

分类模型已经设计好了

是时候祭出梯度下降法来训练模型了

3.9 基于逻辑回归的二分类问题——问题定义

构建二分类任务（识别数字“1”）的数据集：

输入	0	1	2	3	4	5	6	7	8	9
原任务标签	“0”	“1”	“2”	“3”	“4”	“5”	“6”	“7”	“8”	“9”
识别数字“1”的标签	“0”	“1”	“0”	“0”	“0”	“0”	“0”	“0”	“0”	“0”

3.9 基于逻辑回归的二分类问题——问题定义

定义逻辑回归分类模型:

输入 | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9

Sigmoid 函数

$$y = \frac{1}{1 + e^{-\sum w_i(\boxed{1}) + b}}$$

① 输入的形式是什么?

② 如何训练?

输出

关于目标类型的概率分布 $(0.05, 0.67)$

3.9 基于逻辑回归的二分类问题——数据预处理

① 输入的形式是什么？

线性模型无法以图片作为输入

需要对输入数据进行预处理

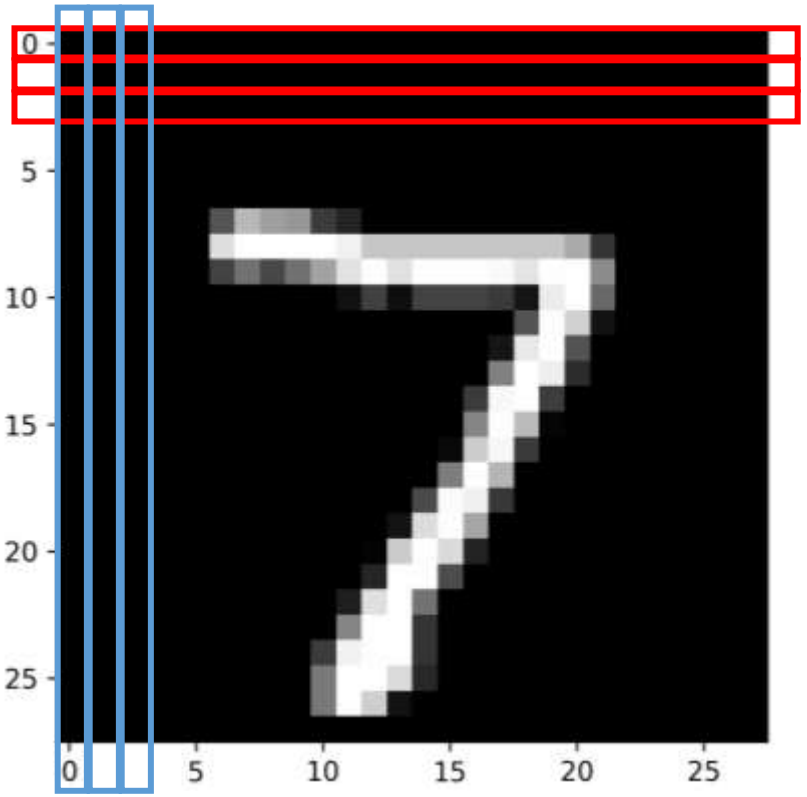

展平图片至特征向量

向量长度为28X28=784

3.9 基于逻辑回归的二分类问题——损失函数设计

② 如何训练逻辑回归模型?

损失函数

交叉熵
Cross Entropy Loss

$$Loss = -\frac{1}{N}\sum_{i=1}^{N}\boxed{y_i \log_e \hat{y}_i + (1-y_i)\log_e(1-\hat{y}_i)}$$

$y_i = 1$: $l_i = -\log_e \hat{y}_i$

$y_i = 0$: $l_i = -\log_e(1-\hat{y}_i)$

损失函数的值越小，则分类结果越准确

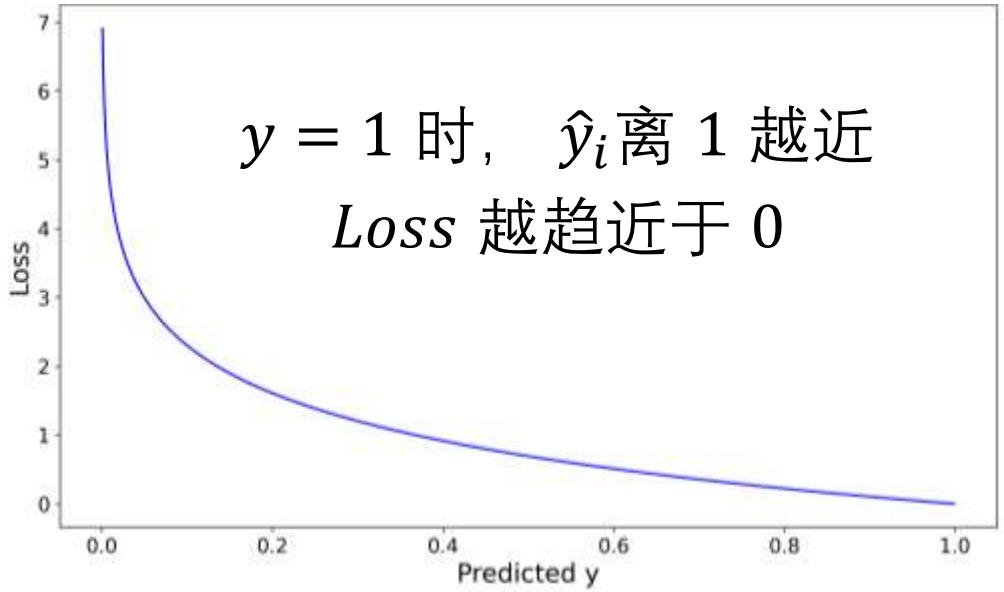

$y = 1$ 时， $\hat{y}_i$离 1 越近
$Loss$ 越趋近于 0

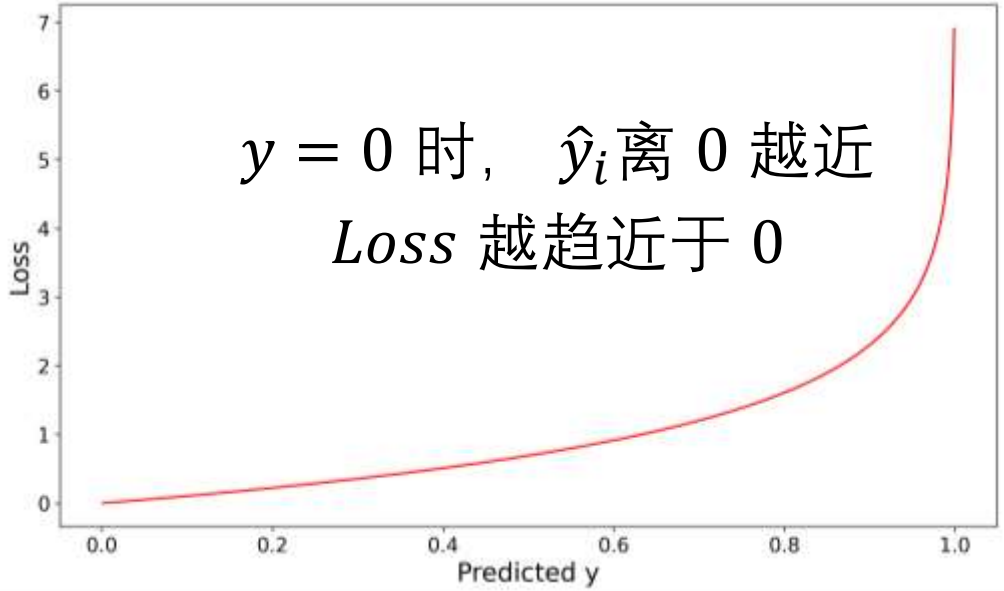

$y = 0$ 时， $\hat{y}_i$离 0 越近
$Loss$ 越趋近于 0

3.9 基于逻辑回归的二分类问题——梯度下降

② 如何训练逻辑回归模型?

损失函数 ➡ **梯度下降**

$$\frac{\partial Loss}{\partial w_i} = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)x_i$$

$$\frac{\partial Loss}{\partial b} = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)$$

逻辑回归和线性回归模型的梯度在形式上是一样的

几乎不用修改训练过程相关的代码!

Step 1: 计算w_i和b的梯度

Step 2: 更新参数 $w_{i+1} = w_i - \eta\frac{\partial L}{\partial w_i}$

Step 3: 不断重复 **Step 1** 和 **Step 2**

3.9 基于逻辑回归的二分类问题——One More Thing

为什么不使用均方误差算Loss?

$$Loss = \frac{1}{2N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2$$

$$\frac{\partial Loss}{\partial w} = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)(1-\hat{y}_i)\hat{y}_i x_i$$

当 $y_i = 1$ 时

如果 $\hat{y}_i = 1$， $\frac{\partial Loss}{\partial w} = 0$， 不学习 √

如果 $\hat{y}_i = 0$， $\frac{\partial Loss}{\partial w} = 0$， 不学习 ×

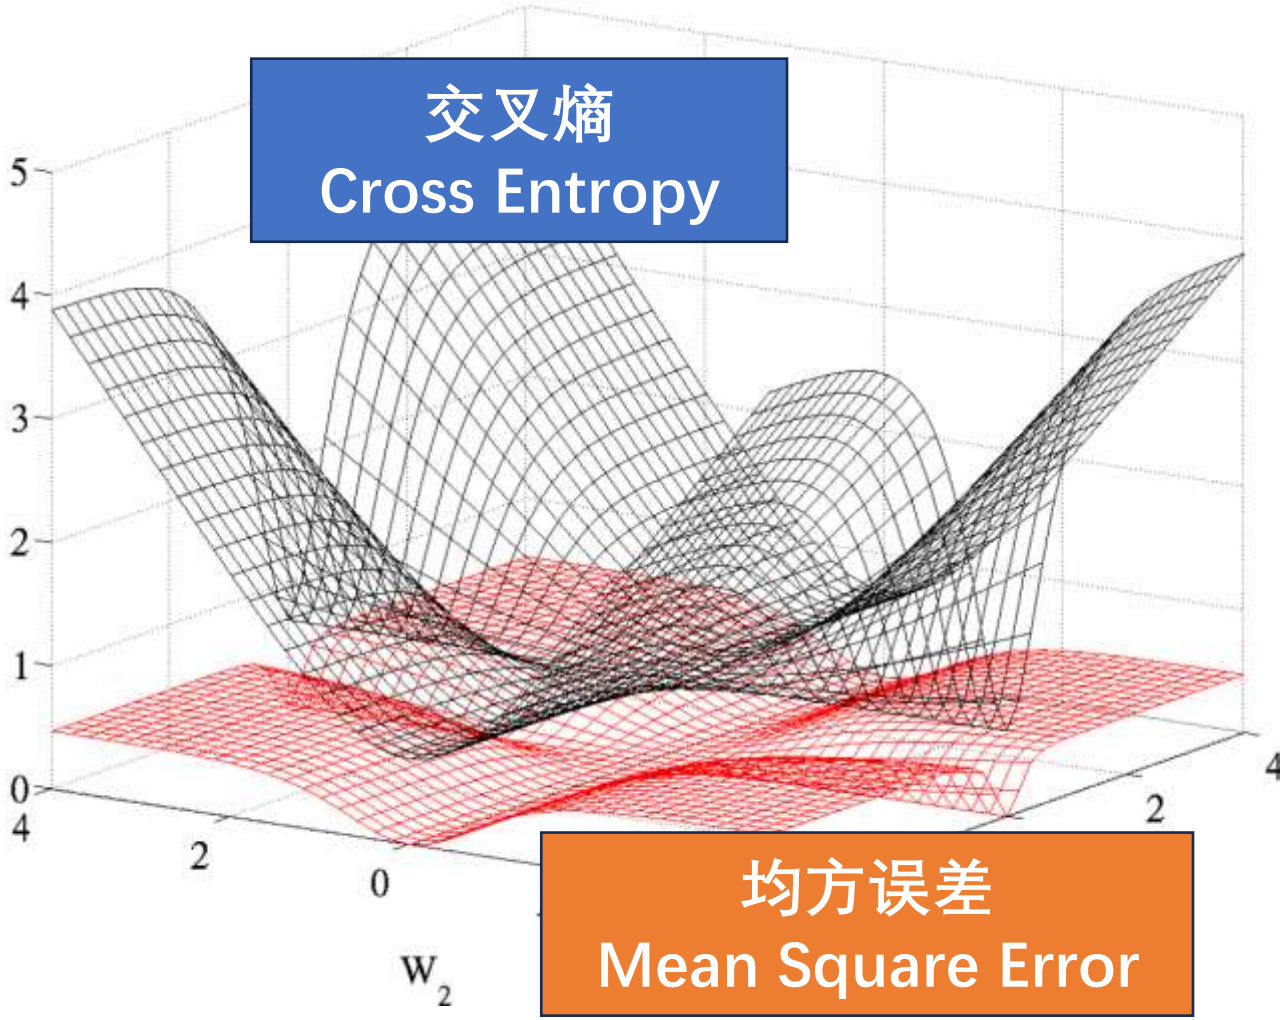

Glorot, Xavier, and Yoshua Bengio. "Understanding the difficulty of training deep feedforward neural networks." Proceedings of the thirteenth international conference on artificial intelligence and statistics. JMLR Workshop and Conference Proceedings, 2010.

3.10 基于Softmax回归的多分类问题

$$C_1: w_1, b_1 \quad z_1 = w_1 x + b_1 \quad y_1 = \boxed{p(z_1)}$$
$$C_2: w_2, b_2 \quad z_2 = w_2 x + b_2 \quad y_2 = \boxed{p(z_2)} \in (0, 1)$$
$$C_3: w_3, b_3 \quad z_3 = w_3 x + b_3 \quad y_3 = \boxed{p(z_3)}$$

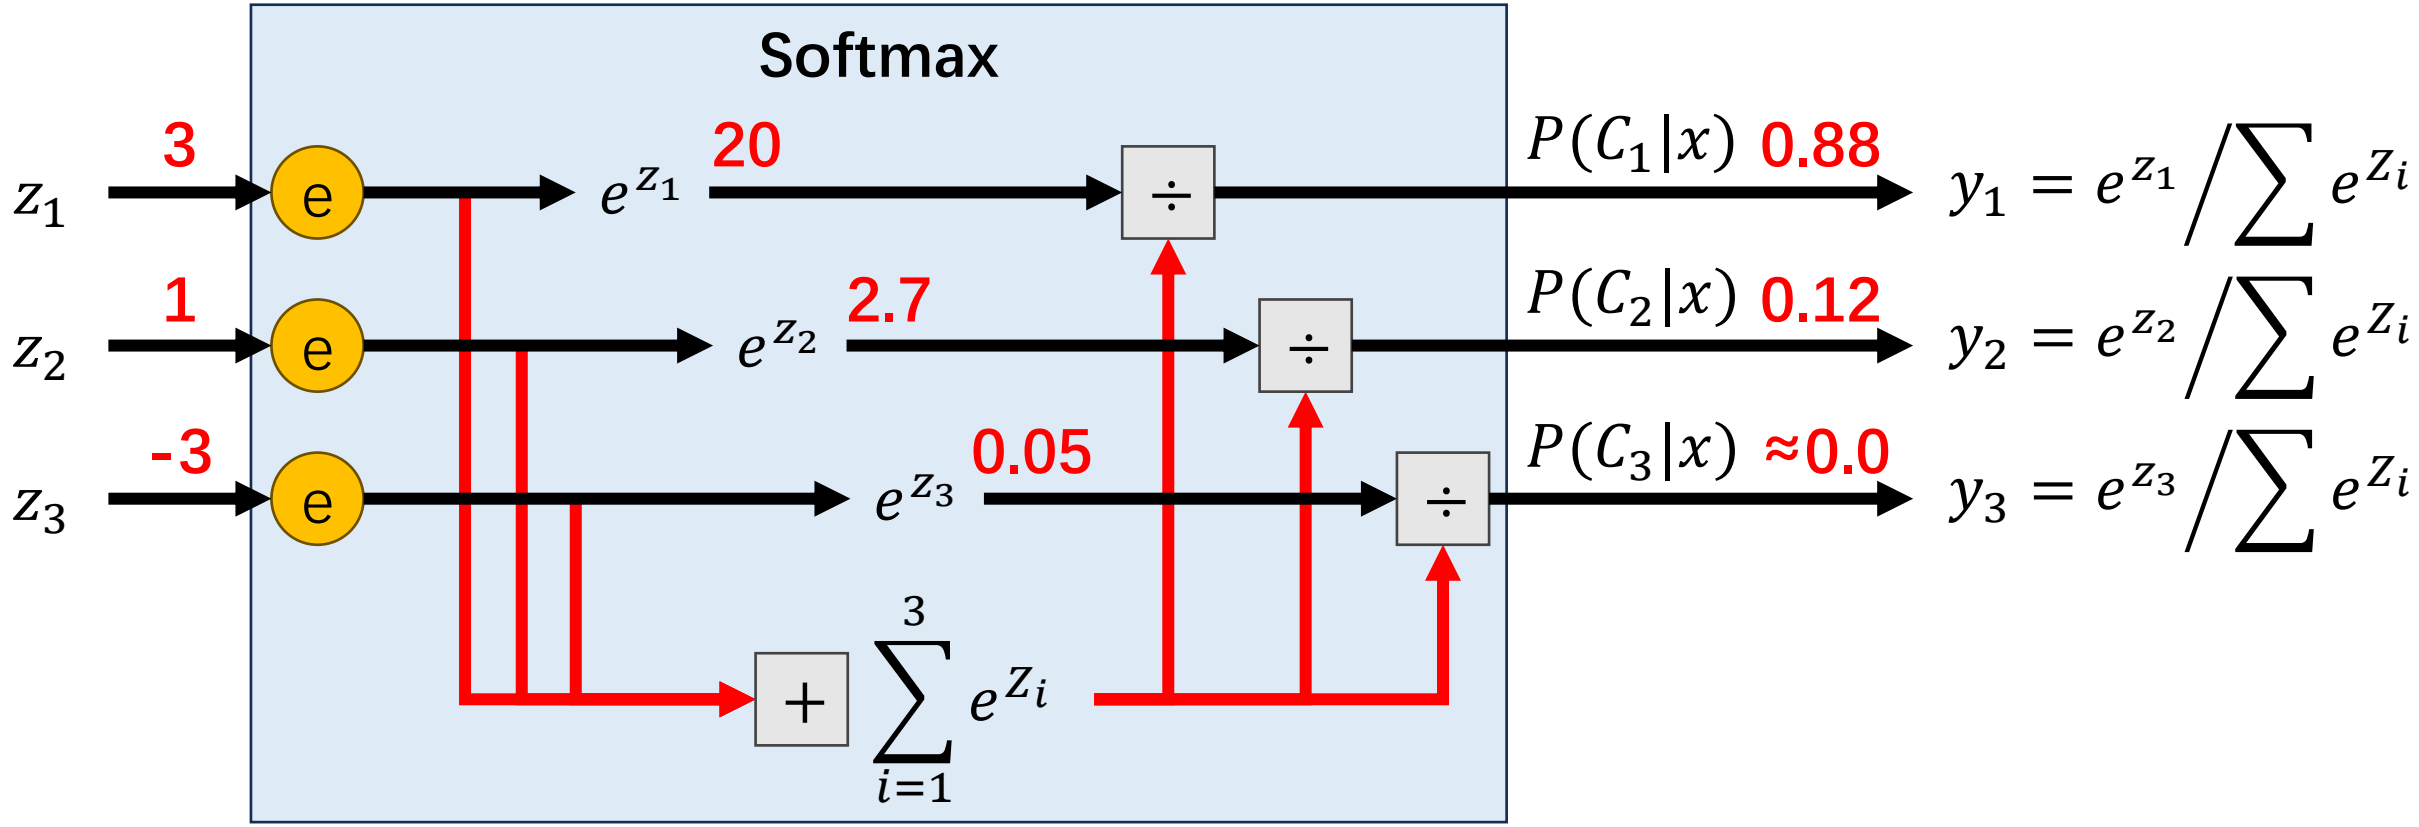

3.10 基于Softmax回归的多分类问题

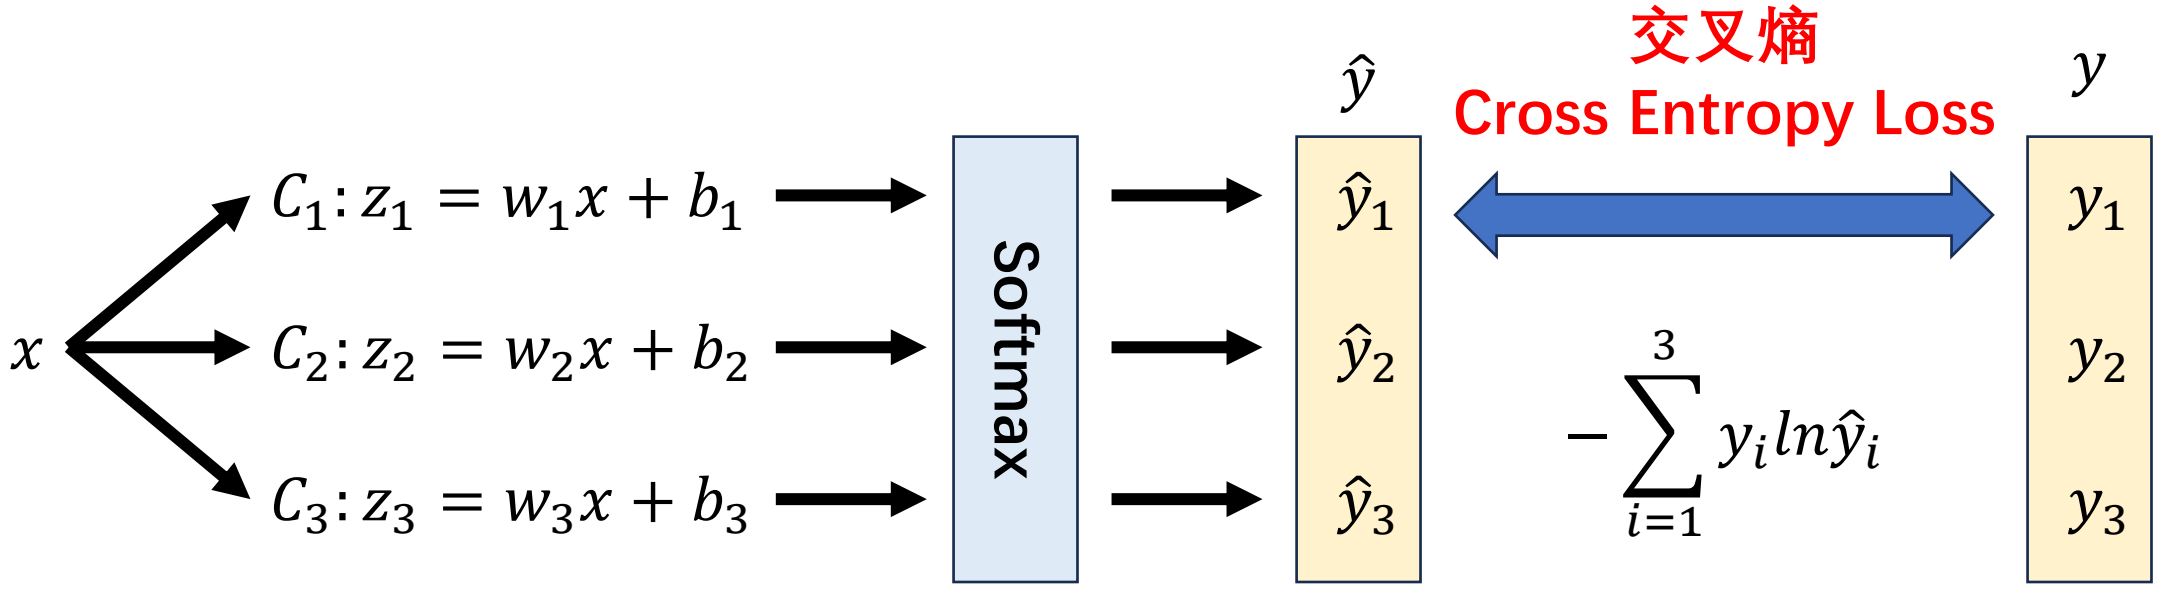

当 $x \in C_1$ 时

$$\hat{y} = \begin{bmatrix}0.88\\0.11\\0.01\end{bmatrix} \quad y = \begin{bmatrix}1\\0\\0\end{bmatrix}$$

$$loss = 0.043$$

当 $x \in C_2$ 时

$$\hat{y} = \begin{bmatrix}0.12\\0.88\\0.01\end{bmatrix} \quad y = \begin{bmatrix}0\\1\\0\end{bmatrix}$$

$$loss = 0.043$$

当 $x \in C_3$ 时

$$\hat{y} = \begin{bmatrix}0.22\\0.28\\0.50\end{bmatrix} \quad y = \begin{bmatrix}0\\0\\1\end{bmatrix}$$

$$loss = 0.231$$

3.10 基于Softmax回归的多分类问题

x

$C_1: z_1 = w_1 x + b_1$

$C_2: z_2 = w_2 x + b_2$

$C_3: z_3 = w_3 x + b_3$

Softmax

$\hat{y}$

$\hat{y}_1$

$\hat{y}_2$

$\hat{y}_3$

交叉熵

Cross Entropy Loss

y

y_1

y_2

y_3

$$-\sum_{i=1}^{3} y_i ln\hat{y}_i$$

求偏导

$$\frac{\partial\left(-\sum_{i=1}^{3} y_i ln\hat{y}_i\right)}{\partial w_i}$$

$\Delta w_1,\quad \Delta b_1$

$\Delta w_2,\quad \Delta b_2$

$\Delta w_3,\quad \Delta b_3$

更新参数

Softmax回归模型的训练过程

主流的机器/深度学习、LLM的训练都遵循一个通用框架

步骤1 收集一堆数据 → 步骤2 初始化一个模型 → 步骤3 梯度下降训练

《钟点工》2000年春节联欢晚会

Step 0: 定义Loss函数

Step 1: 计算w_i和b的梯度

Step 2: 更新参数 $w_{i+1} = w_i - \eta \frac{\partial L}{\partial w_i}$

Step 3: 不断重复 **Step 1** 和 **Step 2**