2.1 绕不开的房价预测

由回归问题开始了解机器学习

前情提要——ML和DL与AI的关系

$$AI \subset ML \subset DL$$

人工智能（Artificial Intelligence，AI）

让机器展现出甚至超越人类的智慧

机器学习（Machine Learning，ML）

当前实现人工智能的一种主流方法

深度学习（Deep Learning，DL）

机器学习中的一种“大力出奇迹”方法

前情提要——ML和DL是什么？

ML和DL皆以学习的方式

从数据中寻找一个解决问题的函数

$$f(x) = y$$

前情提要——$f(x)$能解决哪些问题?

感知世界

回归
分类
聚类

创造（虚拟）世界

文本生成
图像生成
视频生成
语音生成

改变（物理）世界

具身智能
人形机器人
无人驾驶

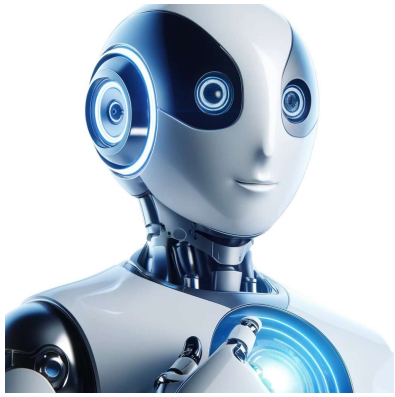

从房价预测开始的机器学习

回归问题是什么？

讨论：准确判断房屋价格应该怎么做呢？

收集信息，信息越丰富越好！

学区房	景观房	商业中心
医疗条件	居民经济条件	交通情况
房型结构	房屋面积	……

找到房屋信息与房价间的联系

f(

学区房	湖景房	商业中心	医疗条件	经济条件	交通情况	房型结构	房屋面积	……

) = 房屋价格

这就是回归问题

特点1：任务是预测或者推断

特点2：目标是找出输入和输出之间的函数关系

特点3：输出的是连续数值

T 博士
《灌篮高手》

f(大气压力 | 温度 | 湿度 | 风速 | 风向 | 降水 | 历史气候 | 云形 | ……) = 天气变化

f(GDP | 通货膨胀 | 财务状况 | 交易情况 | 股价走势 | 股权变动 | 舆论行情 | 行规变动 | ……) = 股价变化

这就是回归问题

T 博士
《灌篮高手》

特点1：任务是预测或者推断

特点2：目标是找出输入和输出之间的函数关系

特点3：输出的是连续数值

用机器学习的方法解决回归问题

案例研究

1978波士顿区域房价预测

波士顿房价预测问题——If…else…方法

步骤1：数据准备

1978年波士顿区域房屋价格表

x_1：犯罪率（%）	0.00632	0.02731	0.02729	0.03237	0.06905
x_2：大住宅用地占比（%）	18.00	0.00	0.00	0.00	0.00
x_3：非零售商业用地占比（%）	2.31	7.07	7.07	2.18	2.18
x_4：景观房（0/1）	0	0	0	0	0
x_5：氮氧化物浓度（ppm）	0.538	0.469	0.469	0.458	0.458
x_6：平均房间数（个）	6.575	6.421	7.185	6.998	7.147
x_7：老旧房屋占比（%）	65.2	78.9	61.1	45.8	54.2
x_8：离就业中心的加权距离	4.09	4.9671	4.9671	6.0622	6.0622
……	……	……	……	……	……
y：房价中位数（千美元）	**24.00**	**21.6**	**34.7**	**33.4**	**36.2**

Harrison, D. and Rubinfeld, D.L. "Hedonic prices and the demand for clean air", J. Environ. Economics & Management, vol.5, 81-102, 1978.

波士顿房价预测问题——If…else…方法

步骤2：分析数据，发现规律，构建规则（人工）

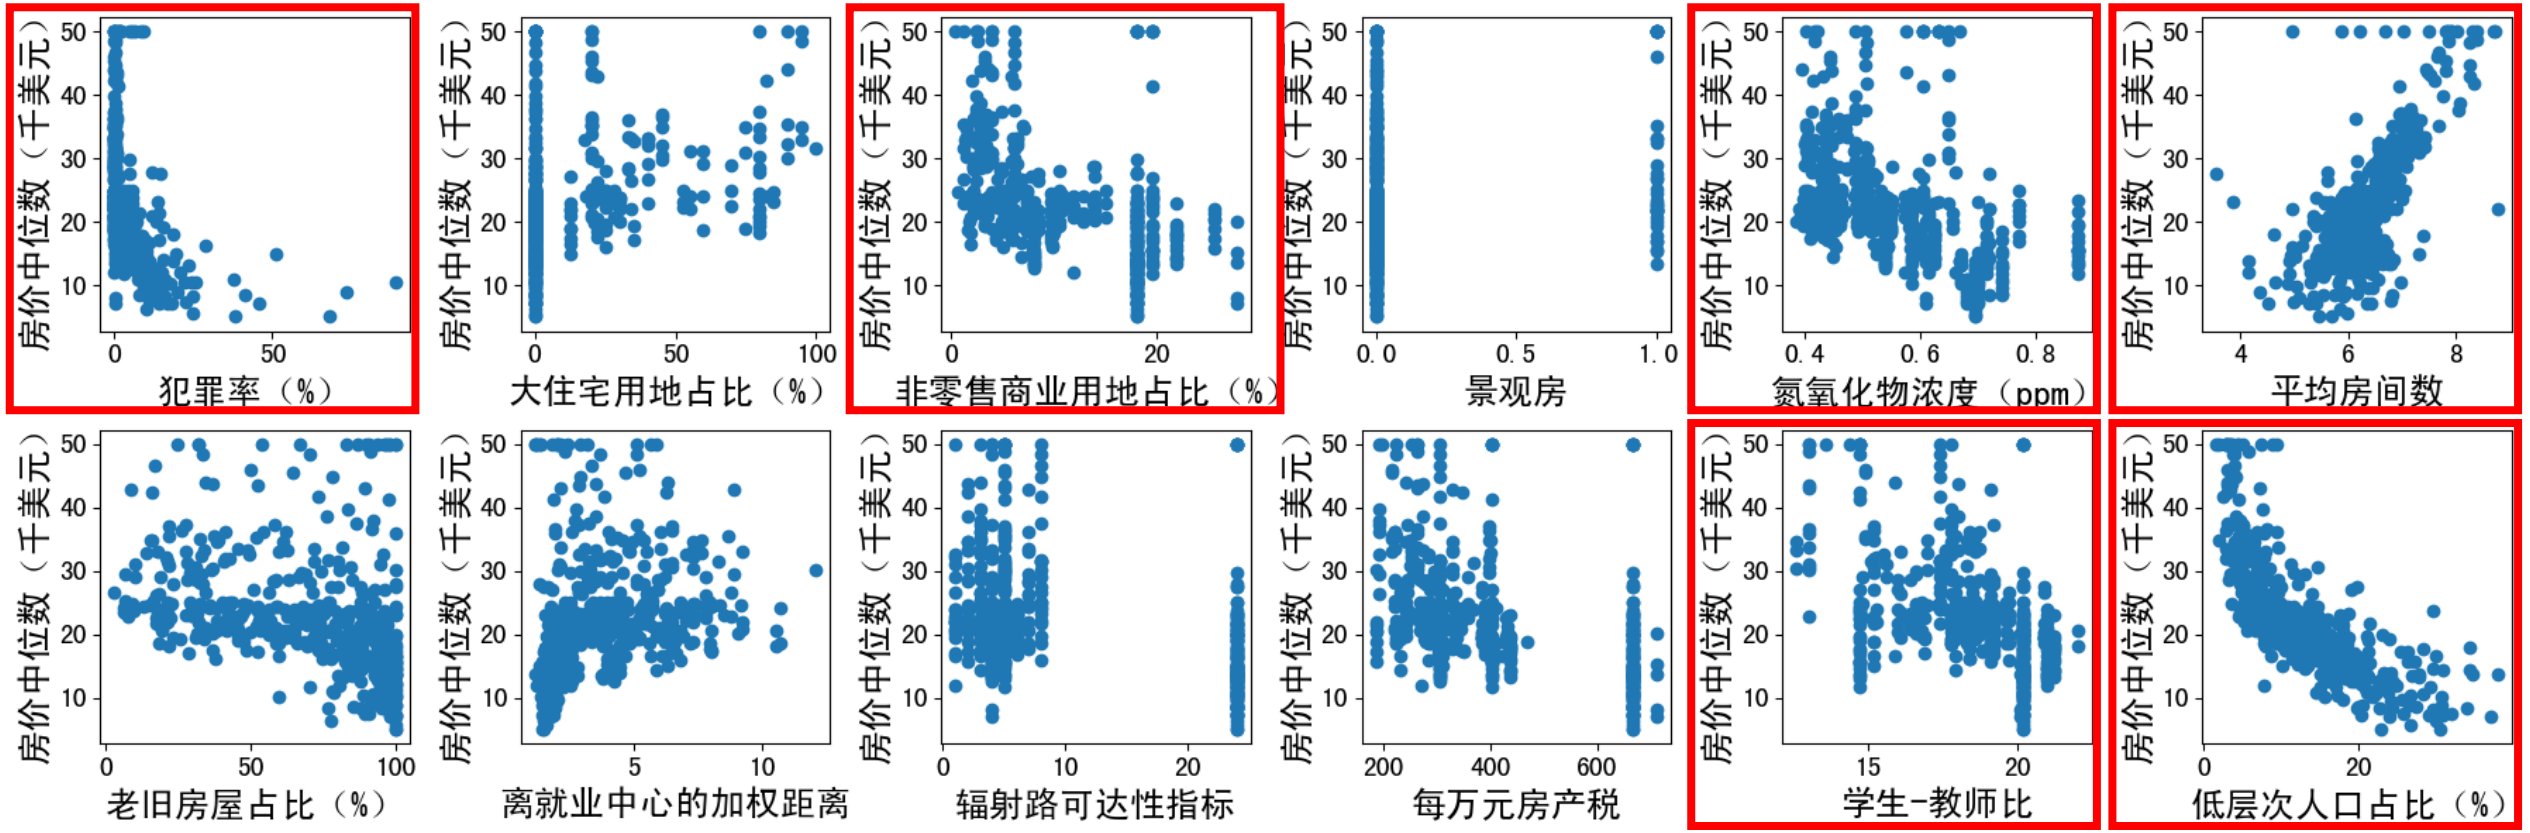

部分特征与房价明显相关，部分特征有一定影响

波士顿房价预测问题——If…else…方法

步骤2：分析数据，发现规律，构建规则（人工）

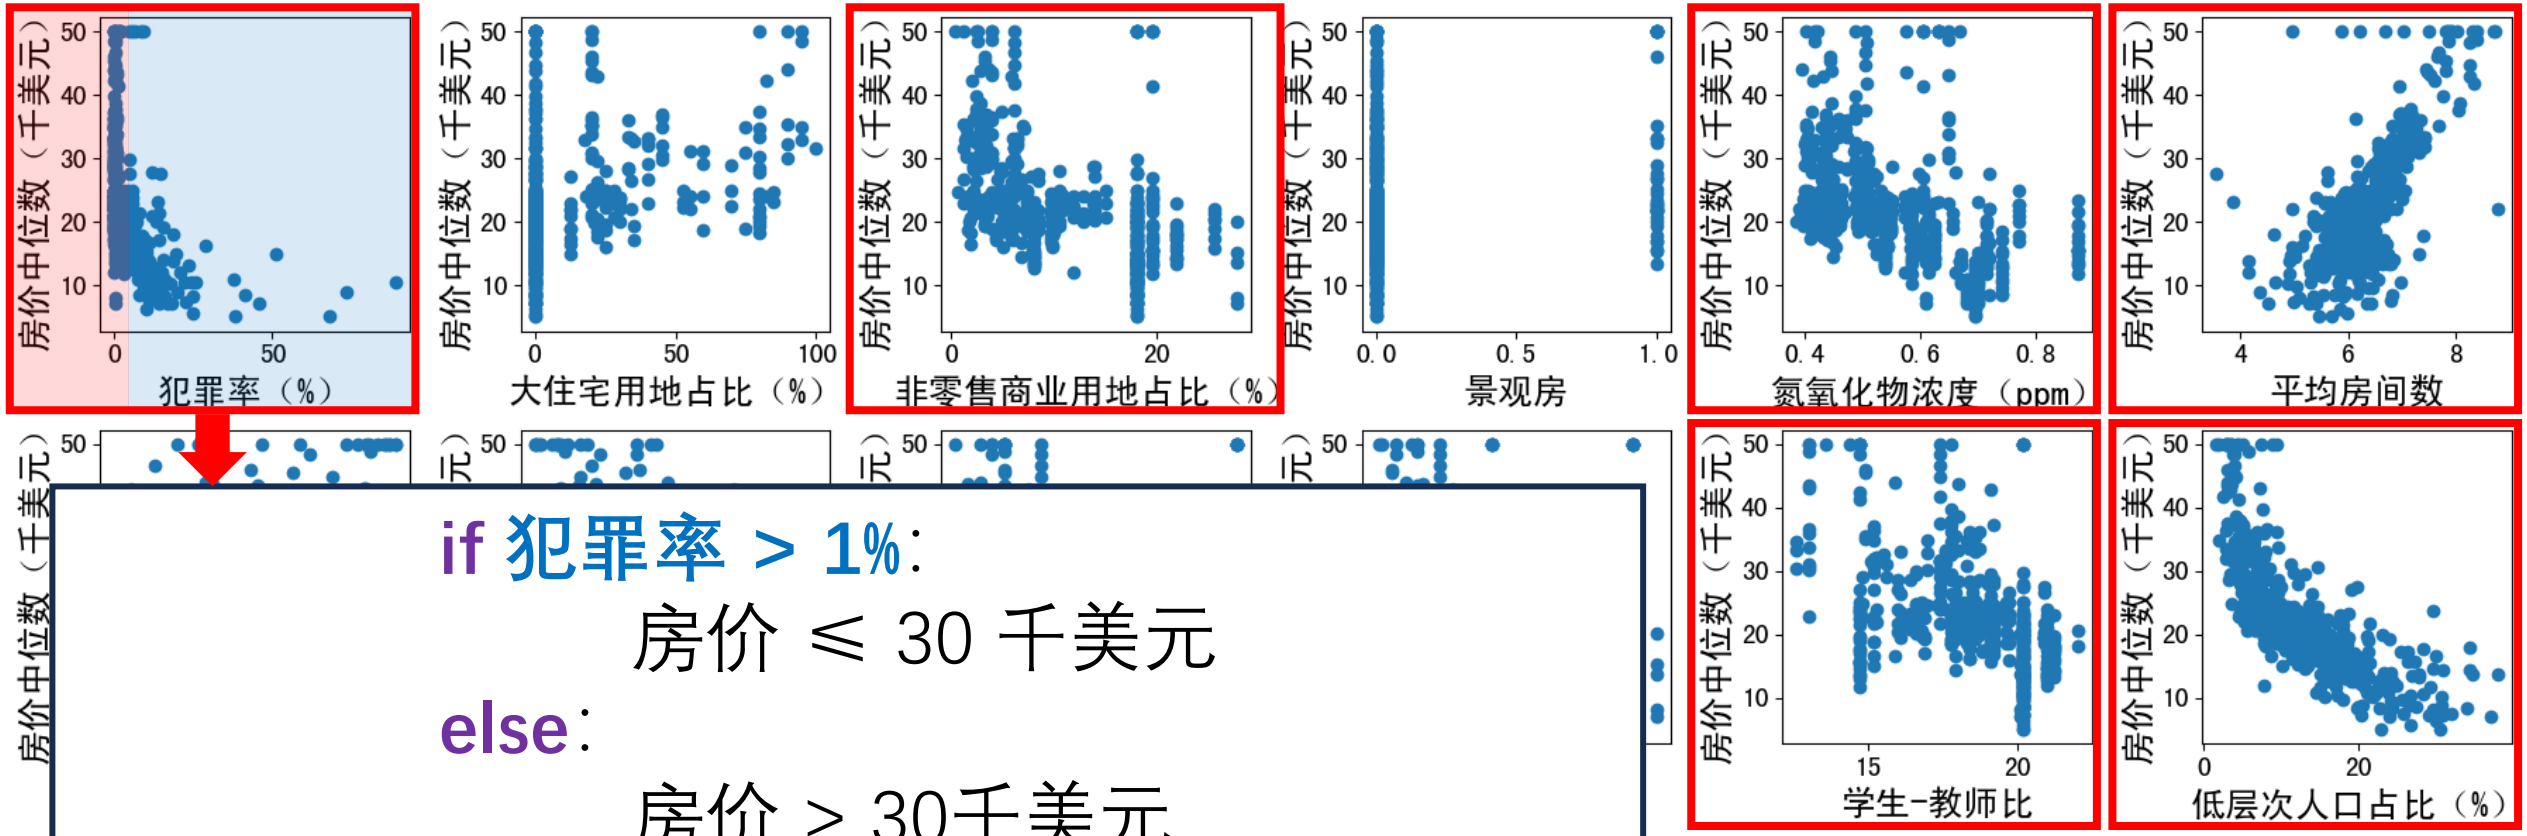

if 犯罪率 > 1%:

房价 ≤ 30 千美元

else:

房价 > 30千美元

波士顿房价预测问题——If…else…方法

步骤2：分析数据，发现规律，构建规则（人工）

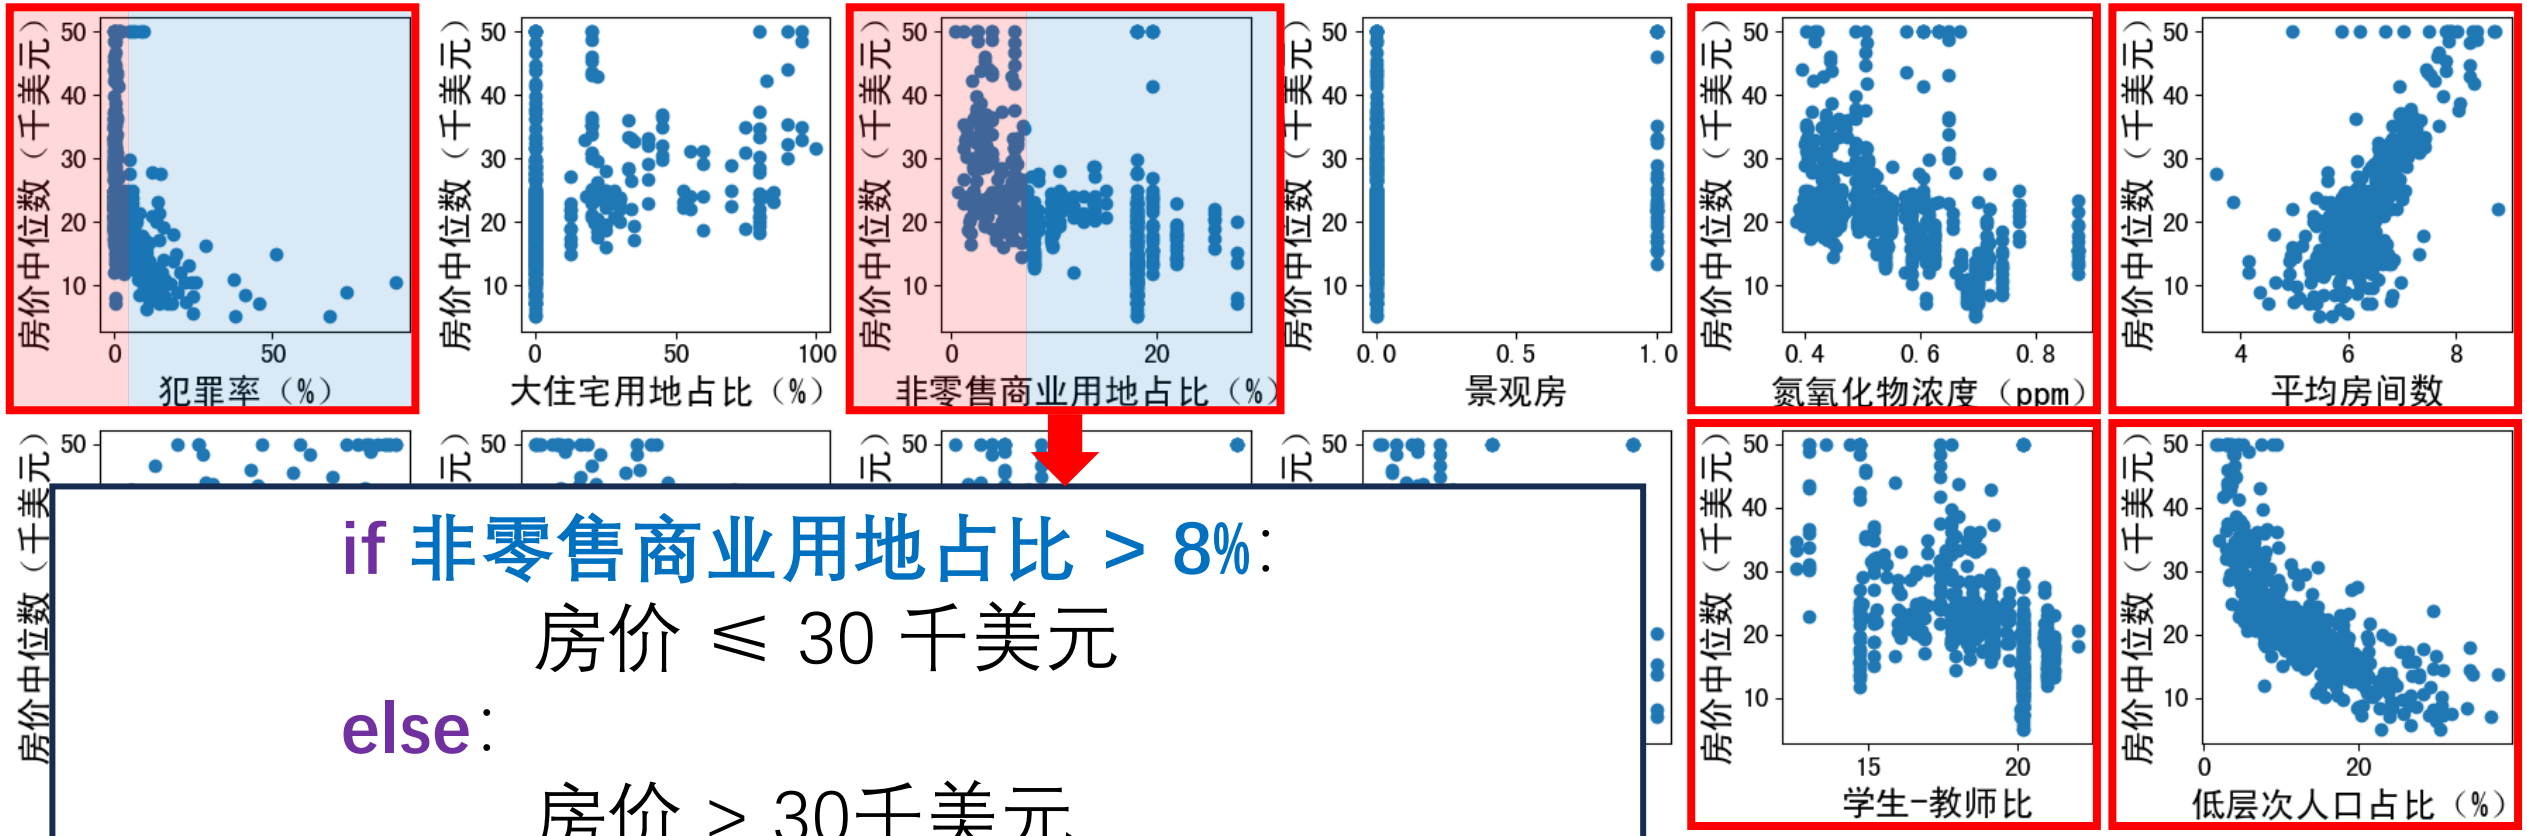

if 非零售商业用地占比 > 8%：

房价 ≤ 30 千美元

else：

房价 > 30千美元

波士顿房价预测问题——If…else…方法

步骤2：分析数据，发现规律，构建规则（人工）

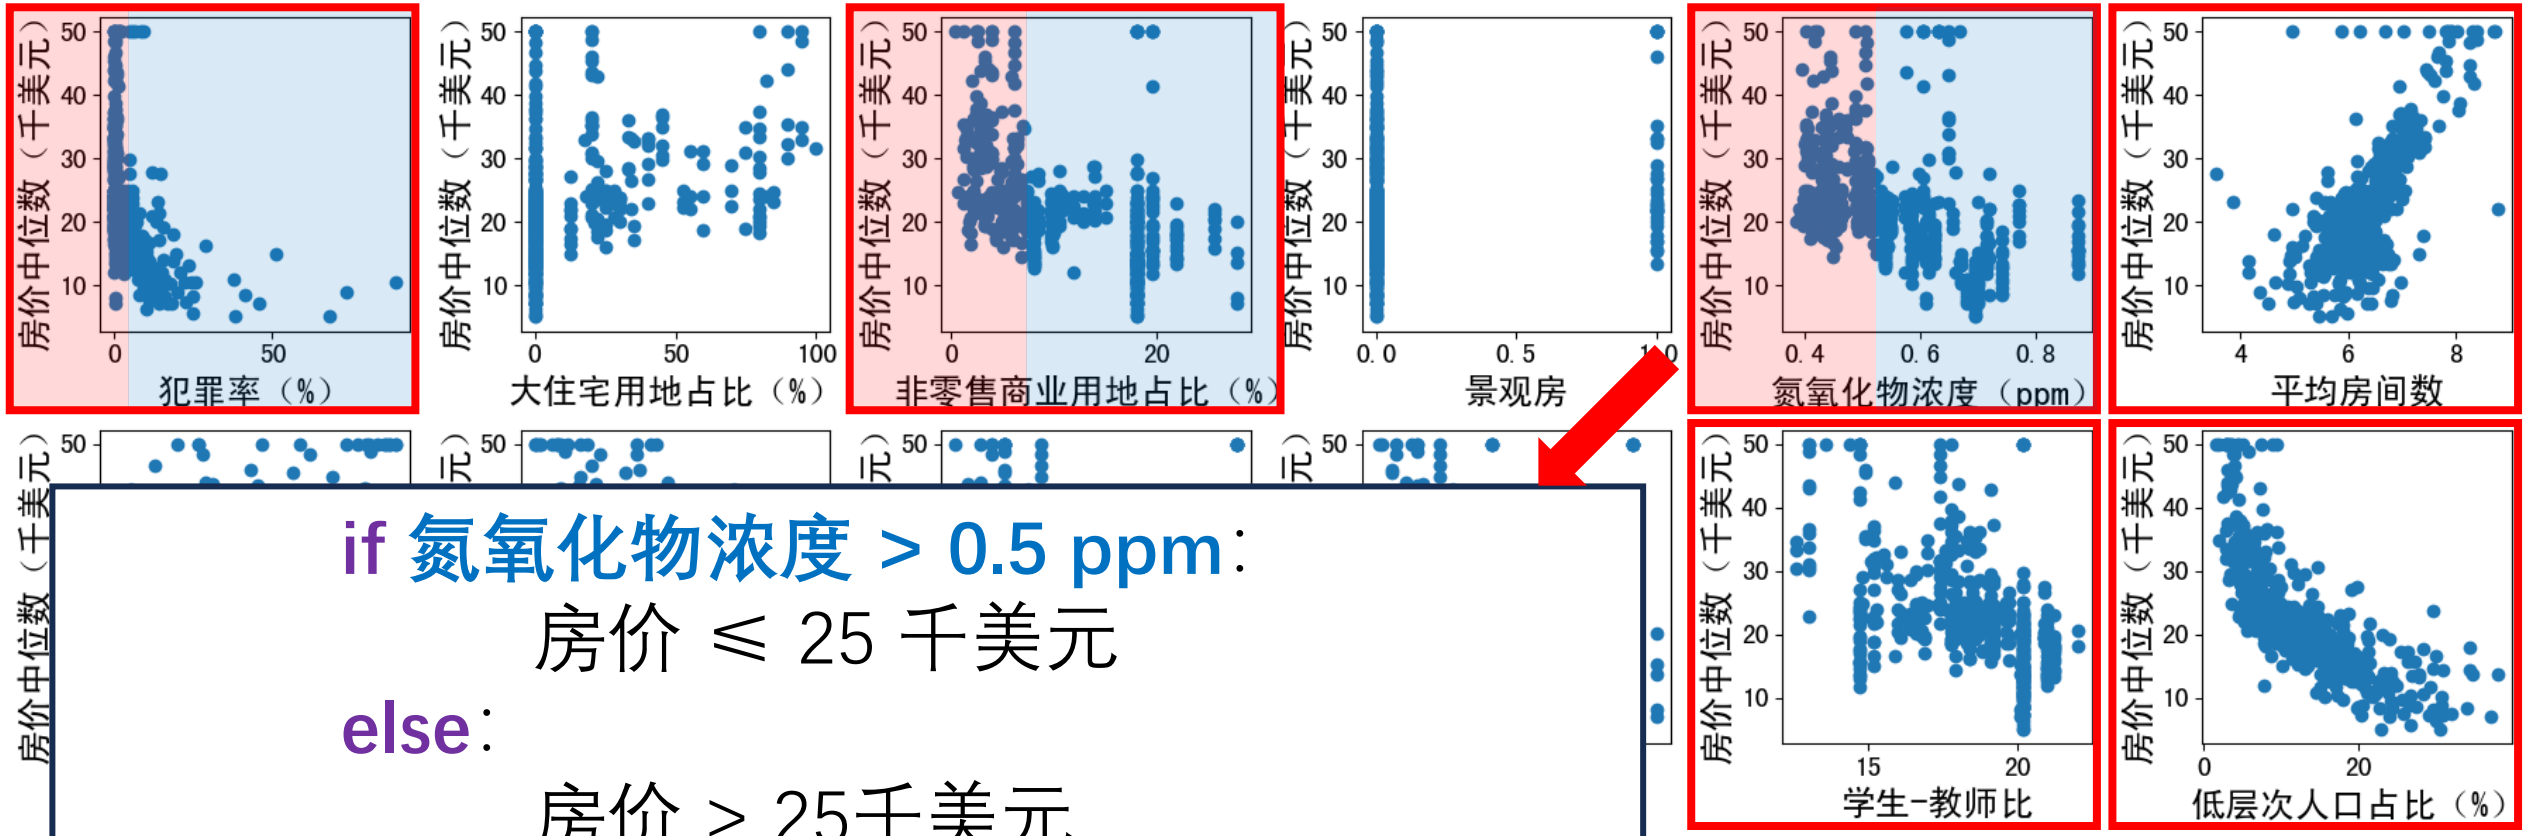

if 氮氧化物浓度 > 0.5 ppm：

房价 ≤ 25 千美元

else：

房价 > 25千美元

波士顿房价预测问题——If…else…方法

步骤2：分析数据，发现规律，构建规则（人工）

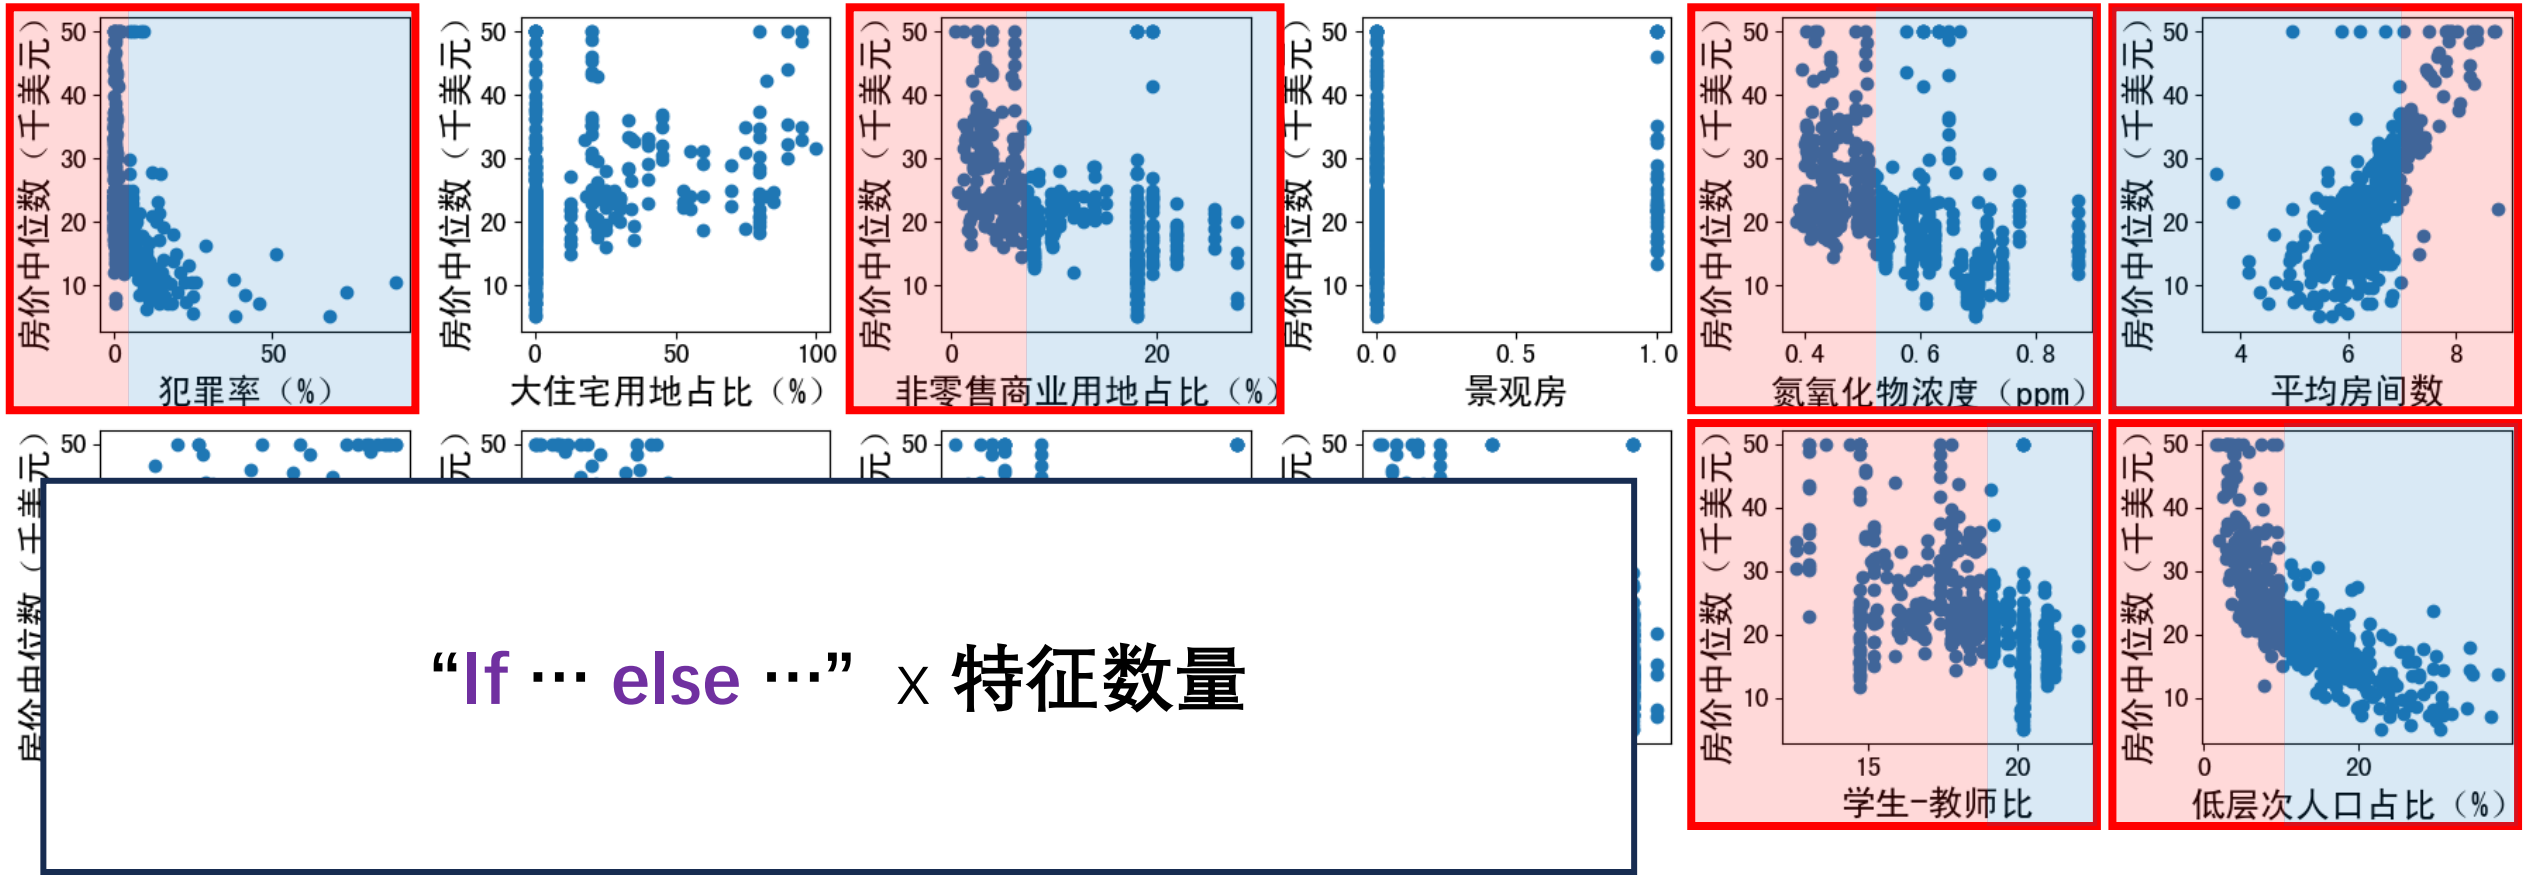

“If … else …” x 特征数量

波士顿房价预测问题——If…else…方法

步骤3：根据专家知识，编写推理引擎

if 犯罪率 < 0.05% & 非零售商业用地 < 2% & 氮氧化物浓度 < 0.4 ppm & …:
房价 > 50 千美元
else if 0.05% < 犯罪率 < 0.1% & 非零售商业用地 < 2% & 氮氧化物浓度 < 0.4 ppm & … :
50 千美元 ≥ 房价 > 45 千美元
else if 0.05% < 犯罪率 < 0.1% & 2% < 非零售商业用地 < 4% & 0.4 ppm < 氮氧化物浓度 < 0.5 ppm & … :
45 千美元 ≥ 房价 > 40 千美元
else if 0.1% < 犯罪率 < 0.2% & 4% < 非零售商业用地 < 8% & 0.4 ppm < 氮氧化物浓度 < 0.5 ppm & … :
40 千美元 ≥ 房价 > 35 千美元
else if 0.1% < 犯罪率 < 0.2% & 4% < 非零售商业用地 < 8% & 0.5 ppm < 氮氧化物浓度 < 0.6 ppm & … :
35 千美元 ≥ 房价 > 30 千美元
……

容易理解，但是极其复杂，难以用于其它的情况（难泛化）

波士顿房价预测问题——If…else…方法

步骤2：分析数据，发现规律，构建规则（人工）

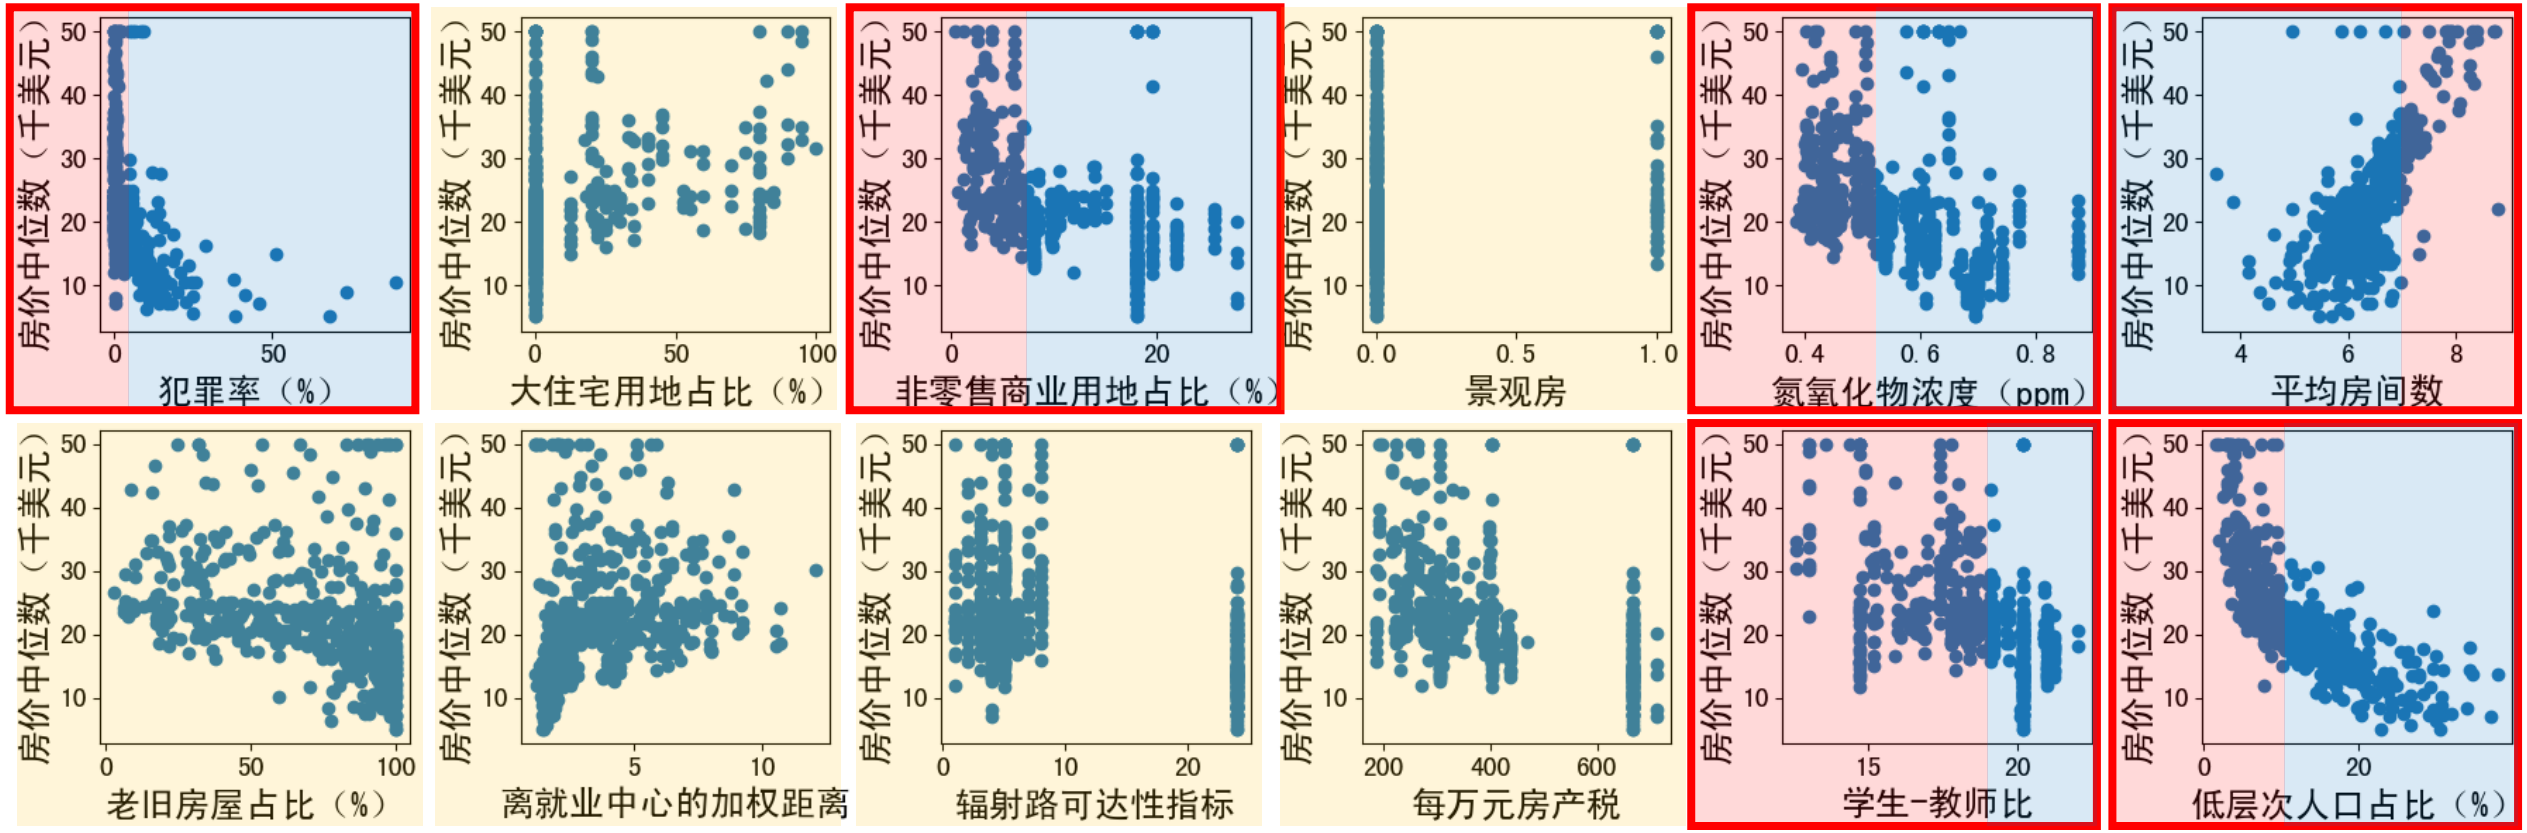

容易忽视其它特征的影响

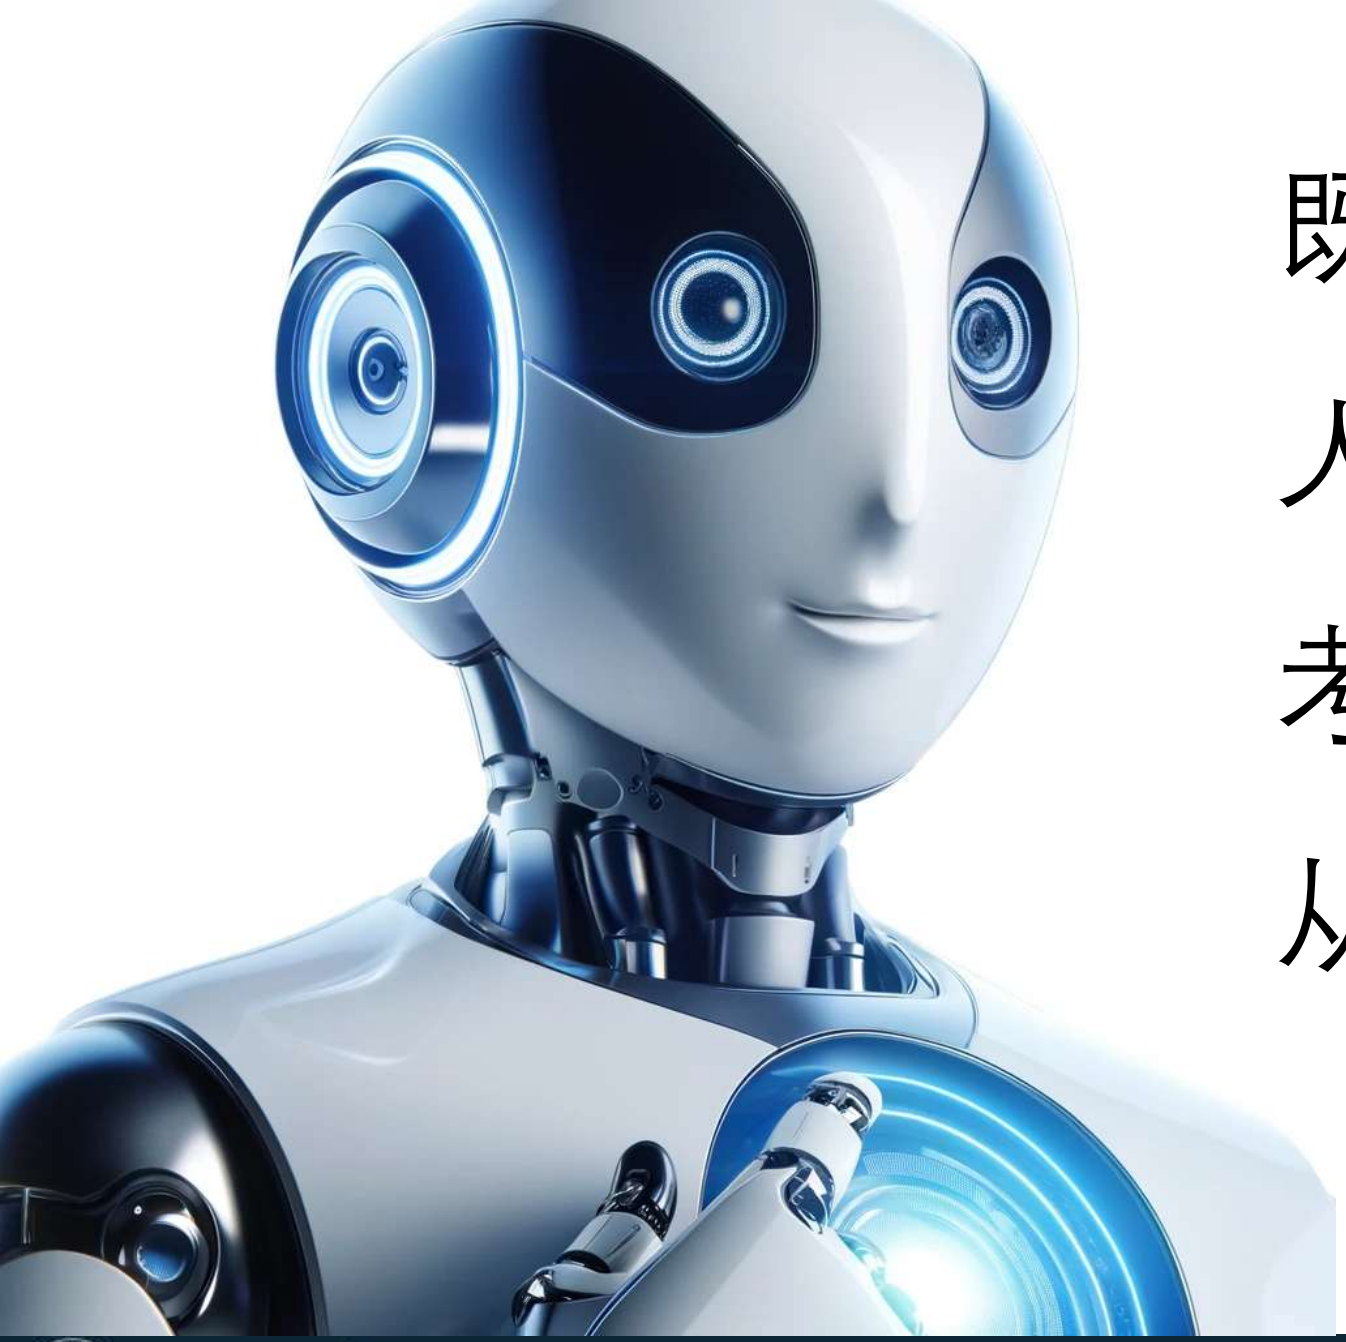

既然这么繁琐复杂，

人类，要不……

考虑一下让机器

从数据中学习规律

波士顿房价预测问题——机器学习方法

一大堆数据

- 输入：房价特征
- 输出：房价（标签）
- 定义问题形式
- 阐述正确的结果

x：平均房间数（个）	y：房价中位数（千美元）
6.575	24.00
6.421	21.60
7.185	34.70
…	…

波士顿房价预测问题——机器学习方法

一大堆数据

- 输入：房价特征
- 输出：房价（标签）
- 定义问题形式
- 阐述正确的结果

一堆模型
$f_1, f_2, \dots, f_n$

- $y = \Sigma\alpha x + \beta$，$x$是特征值
- f由参数α和β定义

$$f_1 \rightarrow y = 3.5x + 2$$

$$f_2 \rightarrow y = 1.5x + 3$$

- f有无数的可能

波士顿房价预测问题——机器学习方法

一大堆数据 → 选择最优模型 ← 一堆模型 $f_1, f_2, \dots, f_n$

- 输入：房价特征
- 输出：房价（标签）
- 定义问题形式
- 阐述正确的结果

平均房间数	6.575	6.421	7.185
房价（千美元）	**24**	**21.6**	**34.7**

✓

25.0	24.5	27.1

✗

12.9	13.6	13.8

- $y = \Sigma\alpha x + \beta$，$x$是特征值
- f由参数α和β定义

$f_1 \rightarrow y = 3.5x + 2$

$f_2 \rightarrow y = 1.5x + 3$

- f有无数的可能

波士顿房价预测问题——机器学习方法

一大堆数据

选择最优模型

一堆模型
$f_1, f_2, \dots, f_n$

- 输入：房价特征
- 输出：房价（标签）

- $y = \Sigma\alpha x + \beta$，$x$是特征值
- f由参数α和β定义

平均房间数
6.998
7.147

最优模型f_{best}

房价（千美元）
33.4
36.2

波士顿房价预测问题——机器学习方法

训练阶段（Training）

步骤1

一大堆数据

步骤3

选择最优模型

步骤2

一堆模型

$f_1, f_2, \dots, f_n$

- 输入：房价特征
- 输出：房价（标签）

- $y = \Sigma\alpha x + \beta$，$x$是特征值
- f由参数α和β定义

测试阶段（Testing）

平均房间数
6.998
7.147

步骤4

最优模型f_{best}

房价（千美元）
33.4
36.2

这也是所有机器学习方法的通用框架！

（专家系统）

IF-ELSE vs 机器学习

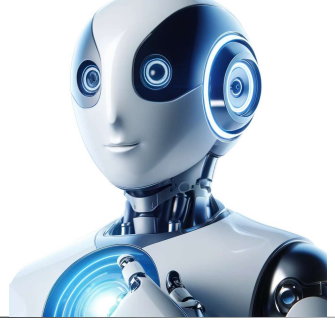

工作原理	由人类专家手工编写规则	由算法自动学习模式和关系
数据需求	依赖专家知识 数据需求低	依赖数据质量 数据需求高
优 势	可解释性强 高度定制化	专业知识需求低 泛化能力强
劣 势	知识获取难 规则维护难	对数据要求高 可解释性差

应该选哪一种方法呢？

（专家系统）

IF-ELSE vs 机器学习

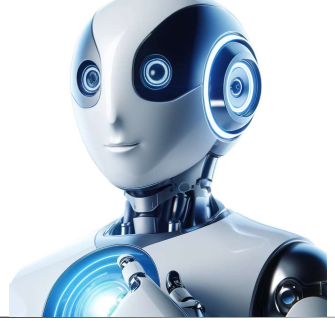

工作原理	由人类专家手工编写规则	由算法自动学习模式和关系
数据需求	依赖专家知识 数据需求低	依赖数据质量 数据需求高

没有“一刀切”的方案，具体问题具体分析

抓住问题的关键，选择最合适的方法

课程小结

前情提要 —— 回顾机器学习的概念和典型问题

↓

房价预测问题 —— **什么是回归问题?**

↓

波士顿房价案例 —— **如何用机器学习的思想解决回归问题?**

- 专家系统（以If…else…为例）
- 机器学习方法
- 比较两类方法的优劣

步骤1

一大堆数据

步骤3

选择最优模型

步骤2

一堆模型

$f_1, f_2, \ldots, f_n$

《钟点工》2000年春节联欢晚会

成功装箱还需对细节的把握……

思考：仅考虑单个特征，应如何设计预测模型？

如何选择最优模型？

实验2：基于线性回归的房价预测

简介：分析特征与房价的关系，预测房价

数据集：1978波士顿区域房价预测

实验内容应包括：

- 用**散点图**展示房屋特征和房价的关系
- 使用**线性模型**和至少一种**非线性模型**进行房价预测
- 单个特征条件下，使用**蛮力法**选择最优模型
- 所有特征条件下，使用**梯度下降**训练模型
- 分别使用**留出法**、**交叉验证法**和**Boostrapping**方法构建测试集
- 模拟**过拟合**和**欠拟合**的情况，并尝试解决（可选）