2.3 梯度下降 Gradient Descent

学习率 & 自适应梯度

更加复杂的情况下是否还能如此呢?

- 当房价相关特征的数量为10时
- 线性模型至少由10个参数决定
- 损失函数的计算次数N_{Loss}:

$$N_{Loss} = 100^{10} = 10^{20}\ （次）$$

- 计算一次Loss平均耗时 0.382（毫秒）
- 计算10^{20}次Loss耗时约 12亿年

蛮力法成本太高

需要启发式方法

梯度下降的基本思想

设想一下

不论从何处开始，都能

判断最优点的大致方向，

并快速向其靠近

$$w^*, b^* = arg \min_{w,b} L(w, b)$$

向最小的 $L(w, b)$ 前进

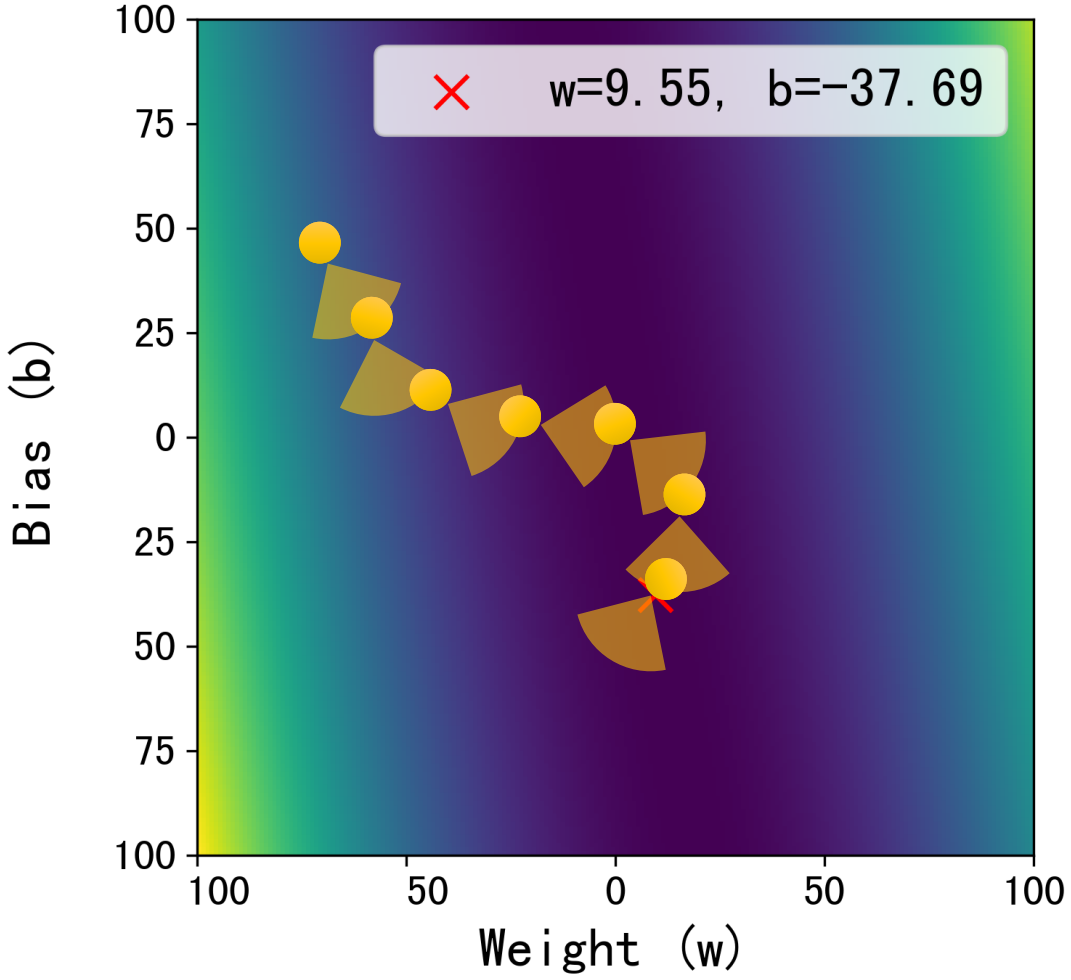

梯度下降的基本思想

沿 $b = -37.69$， 画一条关于 w 的损失函数曲线 $L(w)$

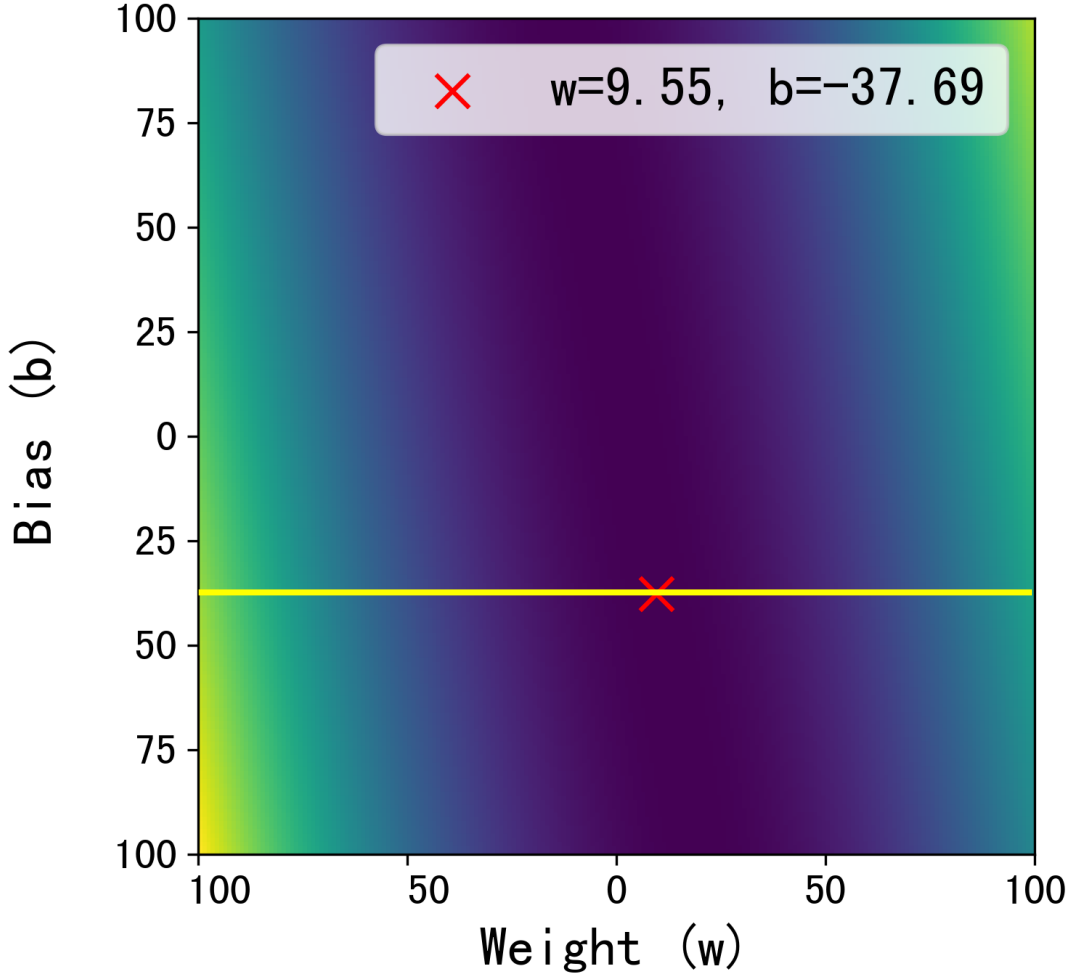

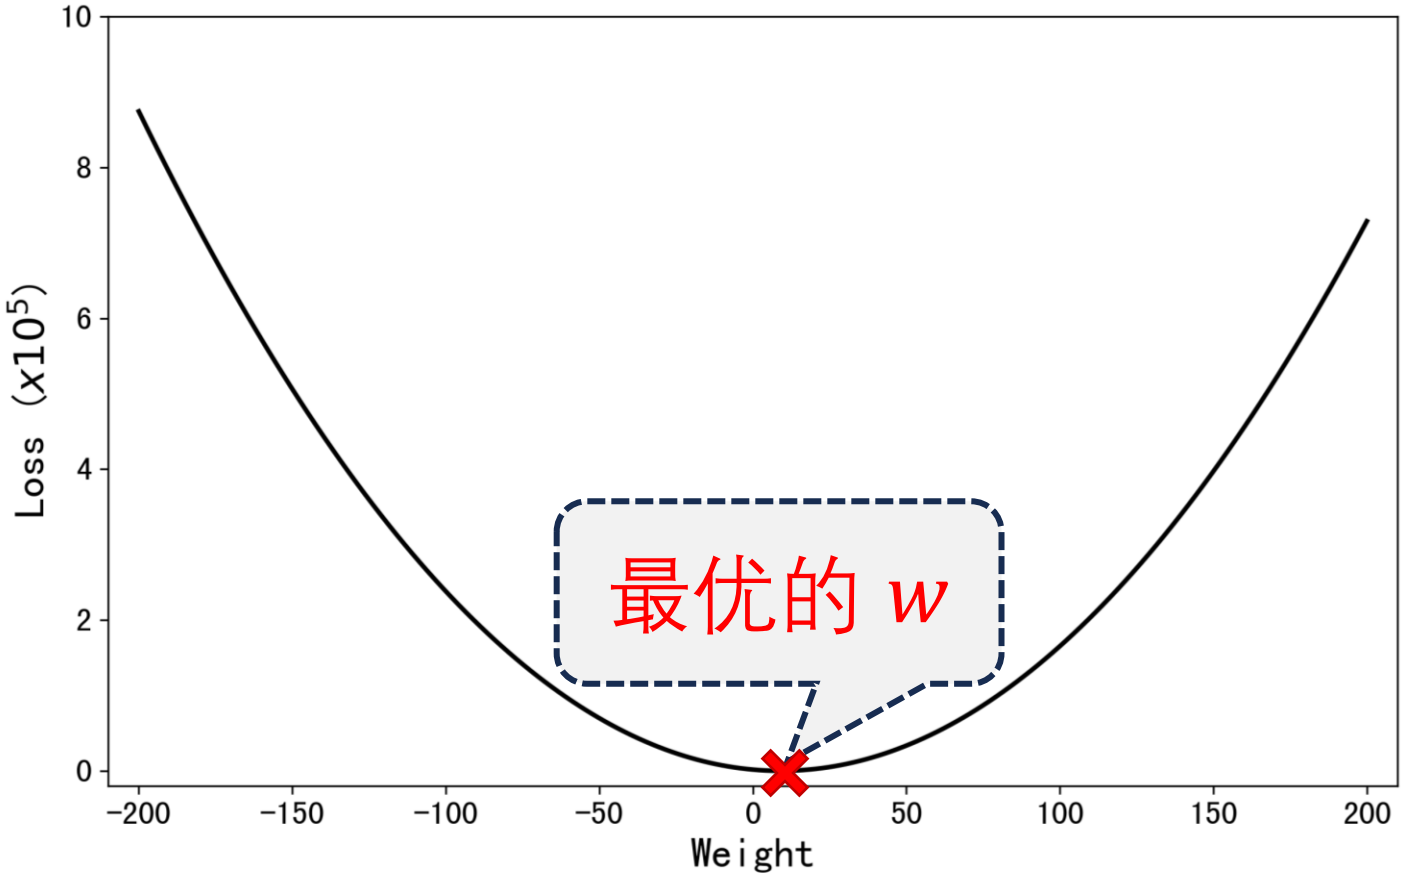

梯度下降的基本思想

在曲线上任意选择一个点 P_0

通过启发式的策略

都可快速收敛到最优的 w

模型训练

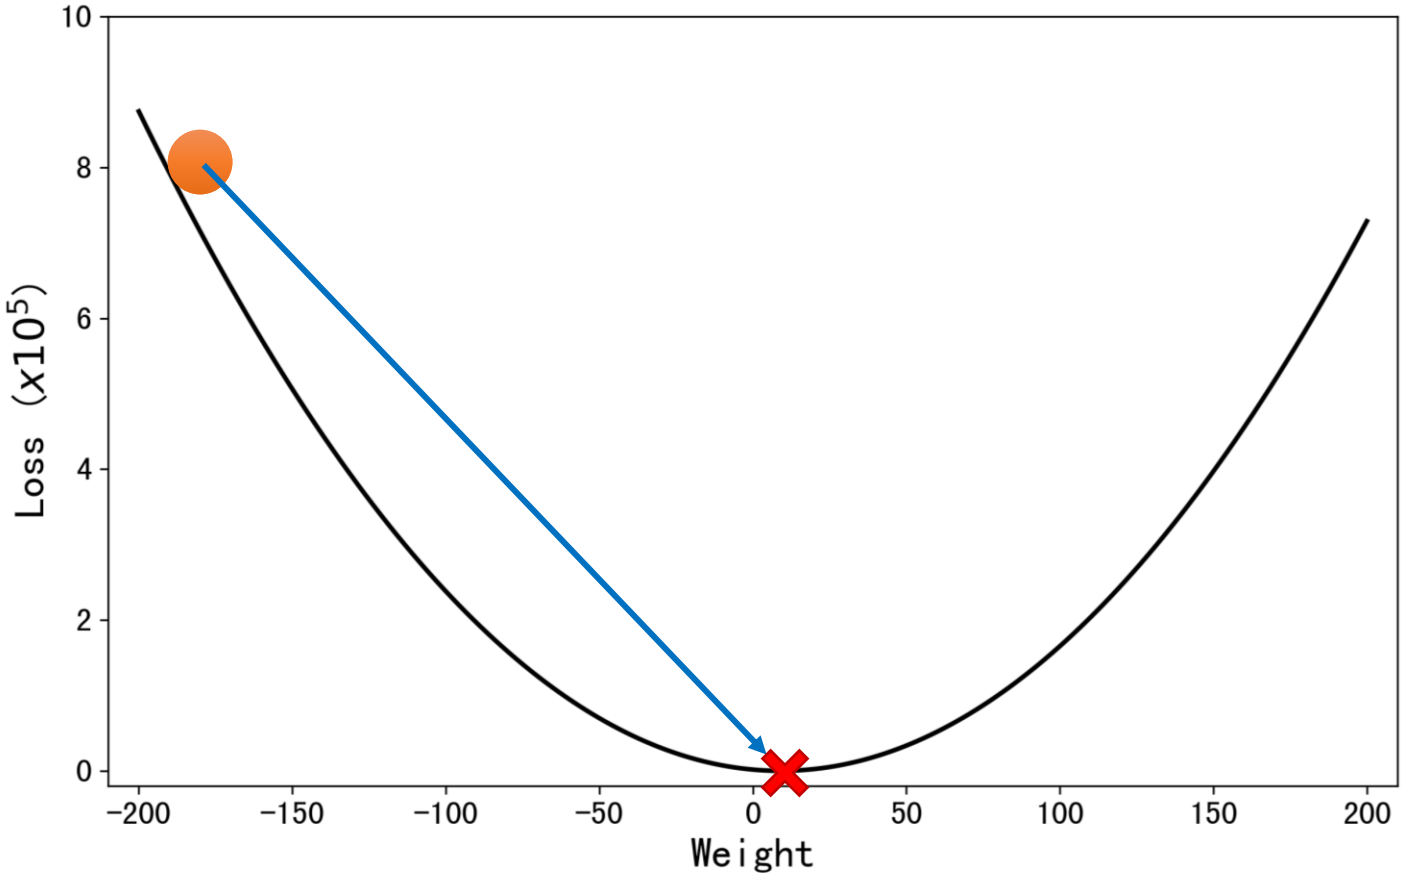

梯度下降的基本思想

解开封印

唤醒巅峰状态

《圣斗士星矢》

梯度下降的基本思想

想象一下在P_0点放上个小球

小球在重力作用下，沿曲线

$$y = f(x)$$

朝着最优点下滑

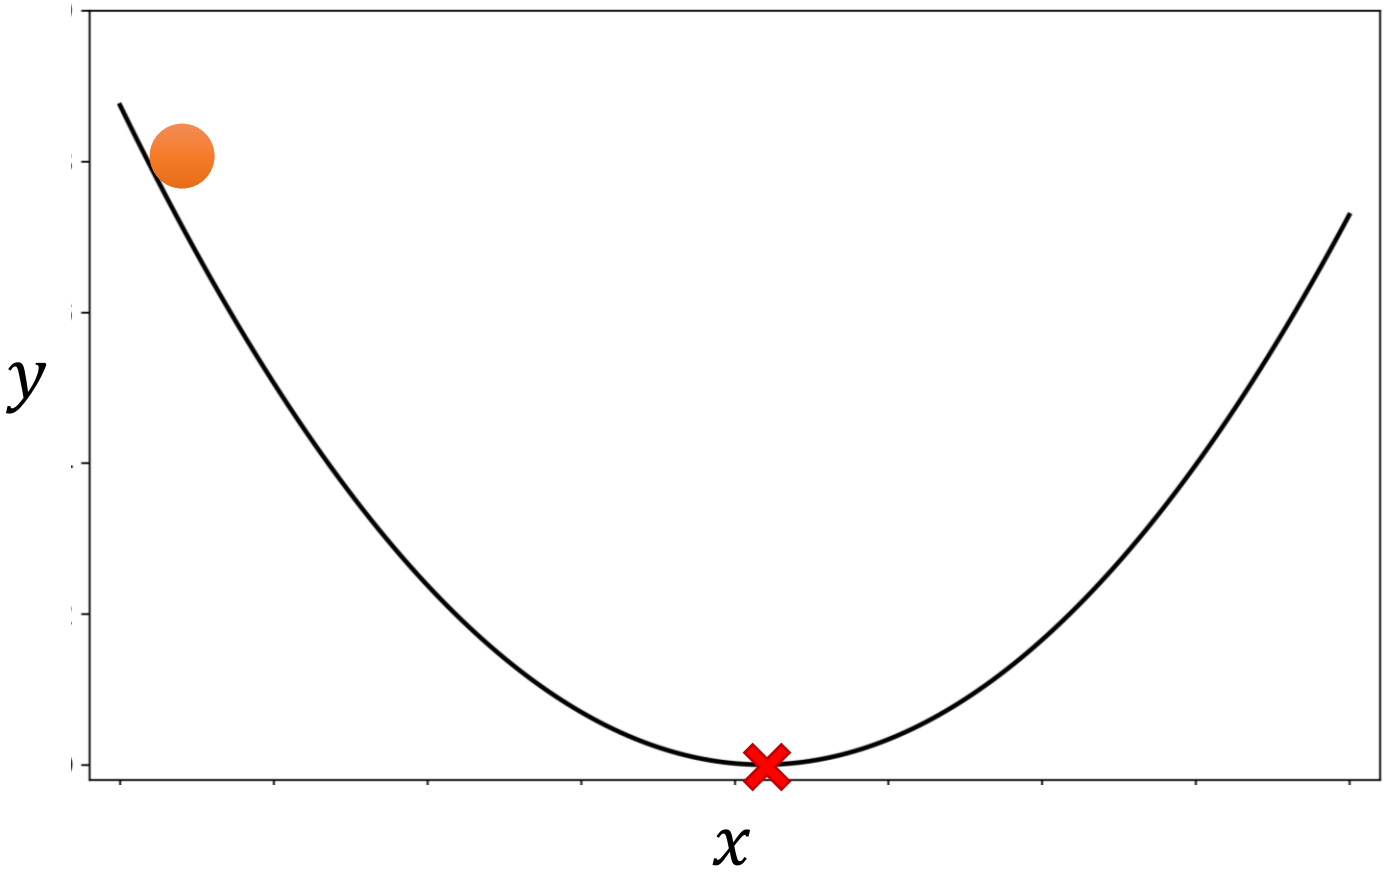

梯度下降的基本思想

想象一下在P_0点放上个小球

小球在重力作用下，沿曲线

$$y = f(x)$$

朝着最优点下滑

t_0时刻，小球沿合力方向运动，

即曲线在P_0处切线方向

沿切线方向运动即为最快到达目标的方向

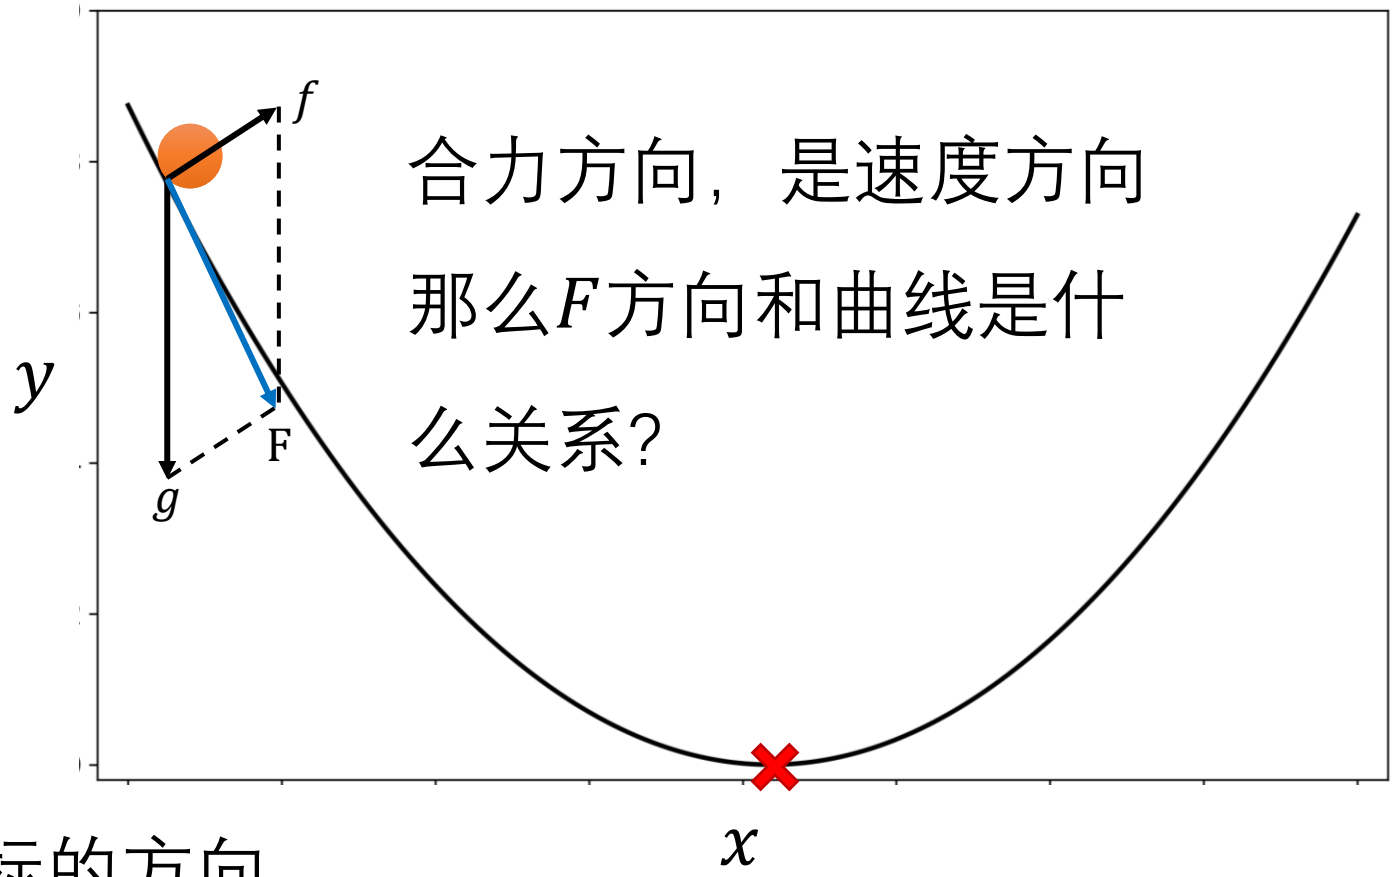

合力方向，是速度方向

那么F方向和曲线是什么关系?

梯度下降的基本思想

用数学符号归纳运动

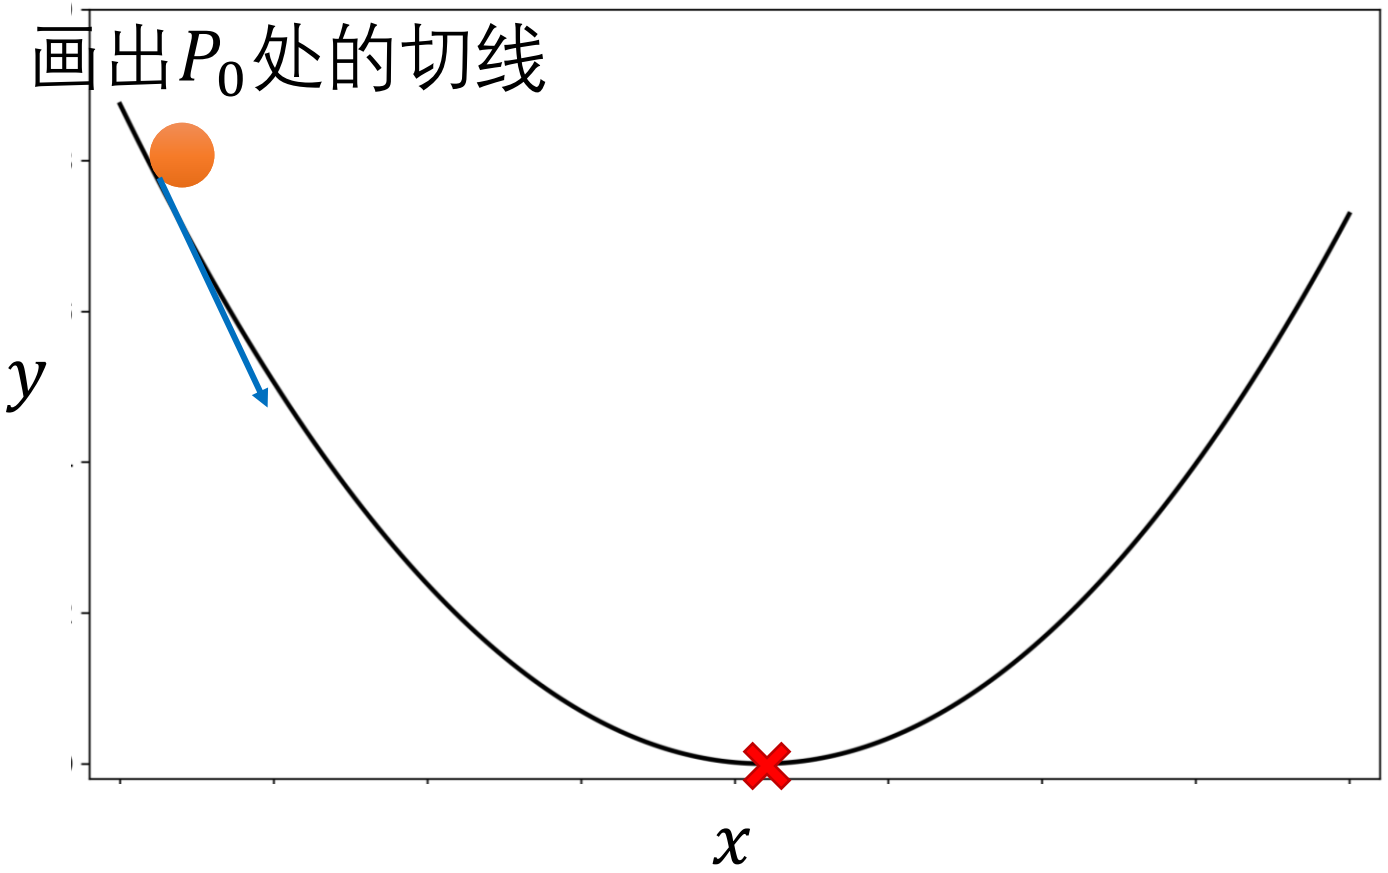

梯度下降的基本思想

用数学符号归纳运动

P_0 处切线为$y = a_{p_0}x + b_{p_0}$

$$a_{p_0} < 0$$

在下一时刻，小球移动到 P_1

$$x_1 - x_0 > 0$$

“当斜率为负时，球朝正向移动”

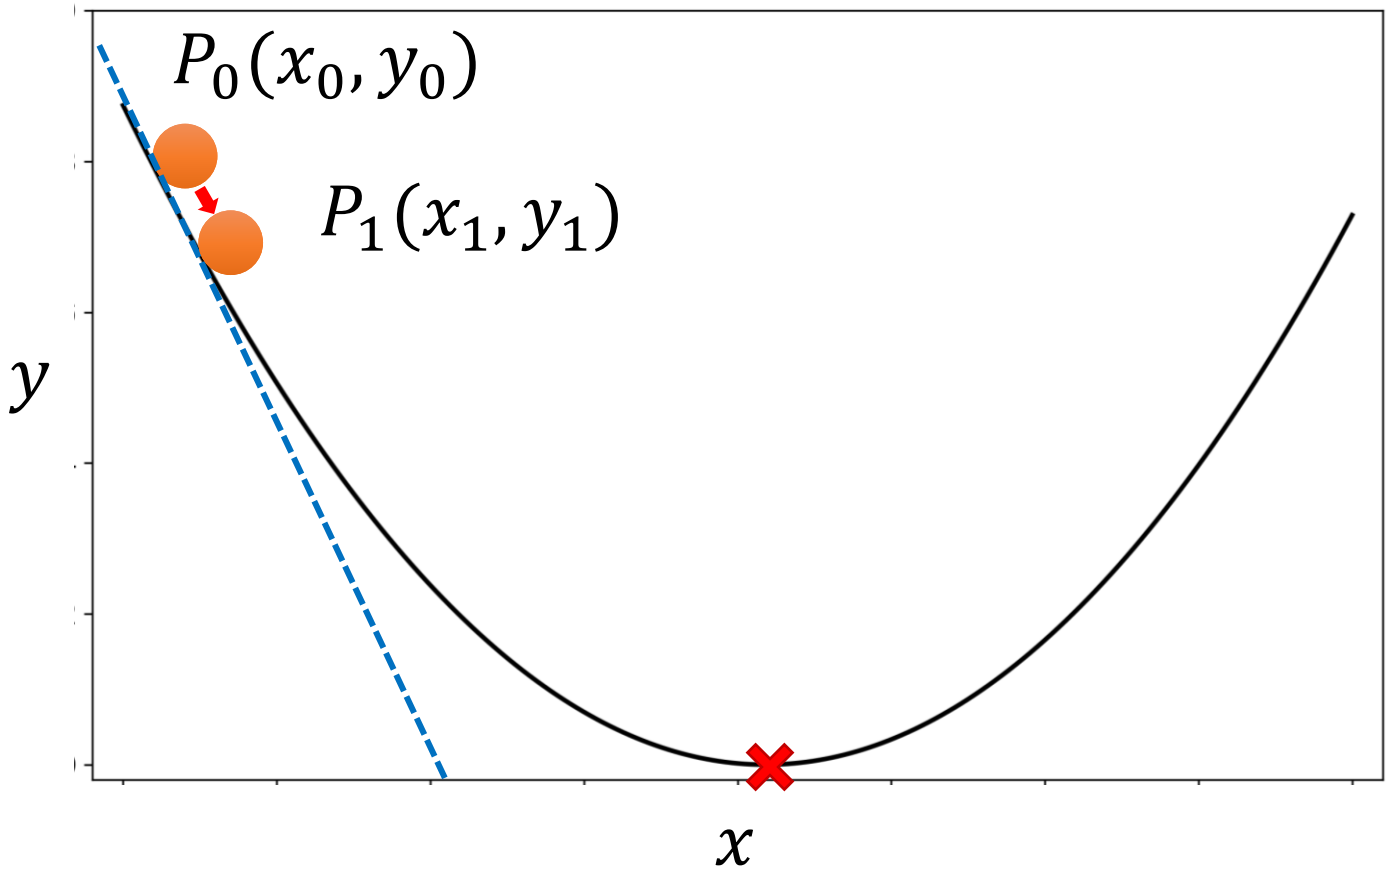

梯度下降的基本思想

用数学符号归纳运动

假设 P_0 处切线为$y = a'_{p_0}x + b'_{p_0}$

$$a'_{p_0} > 0$$

在下一时刻，小球移动到 P_1

$$x_1 - x_0 < 0$$

“当斜率为正时，球朝负向移动”

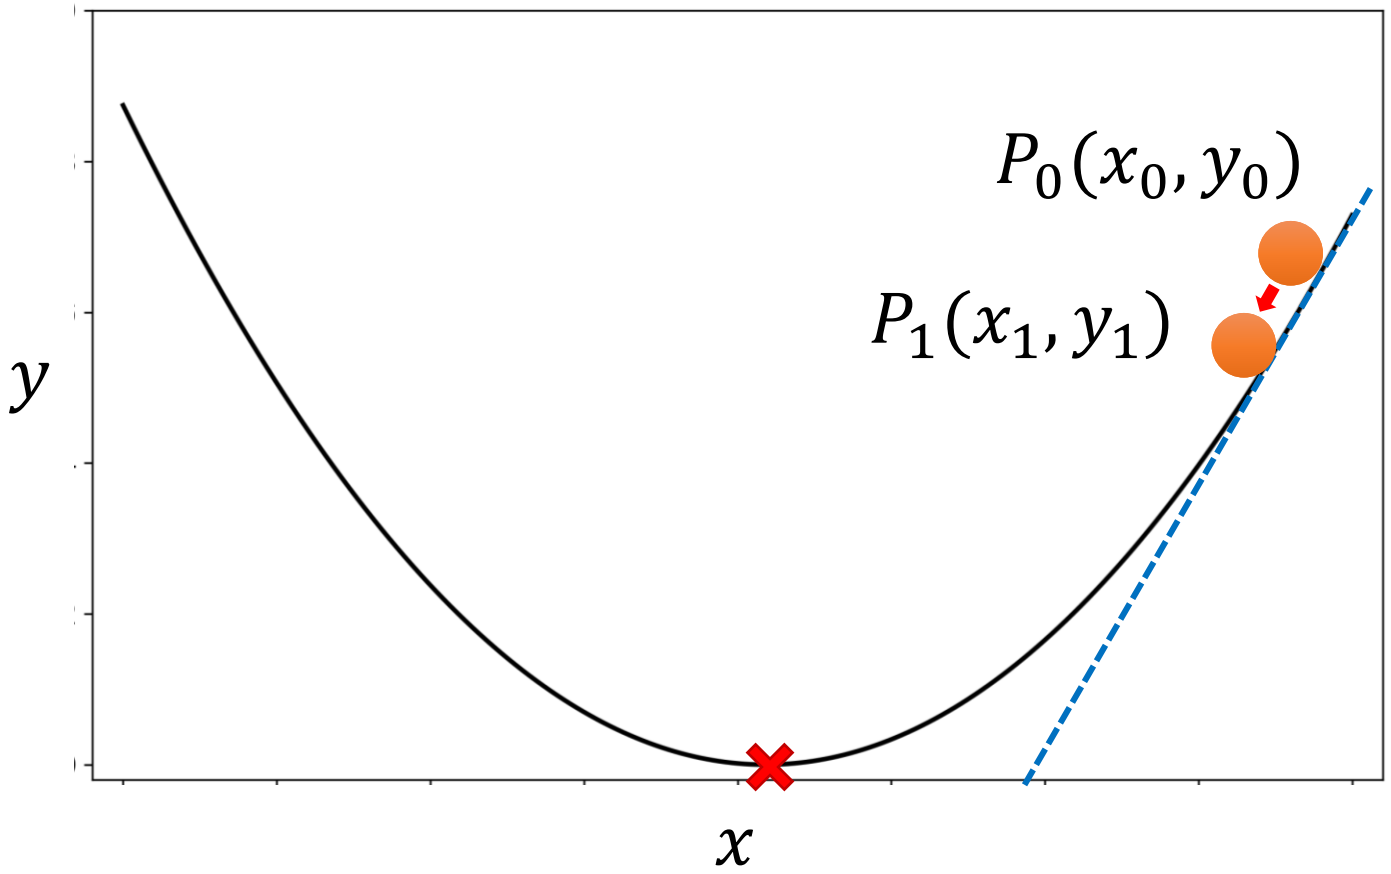

梯度下降的基本思想

用数学符号归纳运动

$P_0 \rightarrow P_1$:

$$-\eta \cdot a_{p_0} = -\eta \cdot \frac{dy}{dx}\Big|_{x=x_0}$$

$P_1 \rightarrow P_2$:

$$-\eta \cdot a_{p_1} = -\eta \cdot \frac{dy}{dx}\Big|_{x=x_1}$$

$\ldots \rightarrow P_n$:

$$-\eta \cdot a_{p_{n-1}} = -\eta \cdot \frac{dy}{dx}\Big|_{x=x_{n-1}}$$

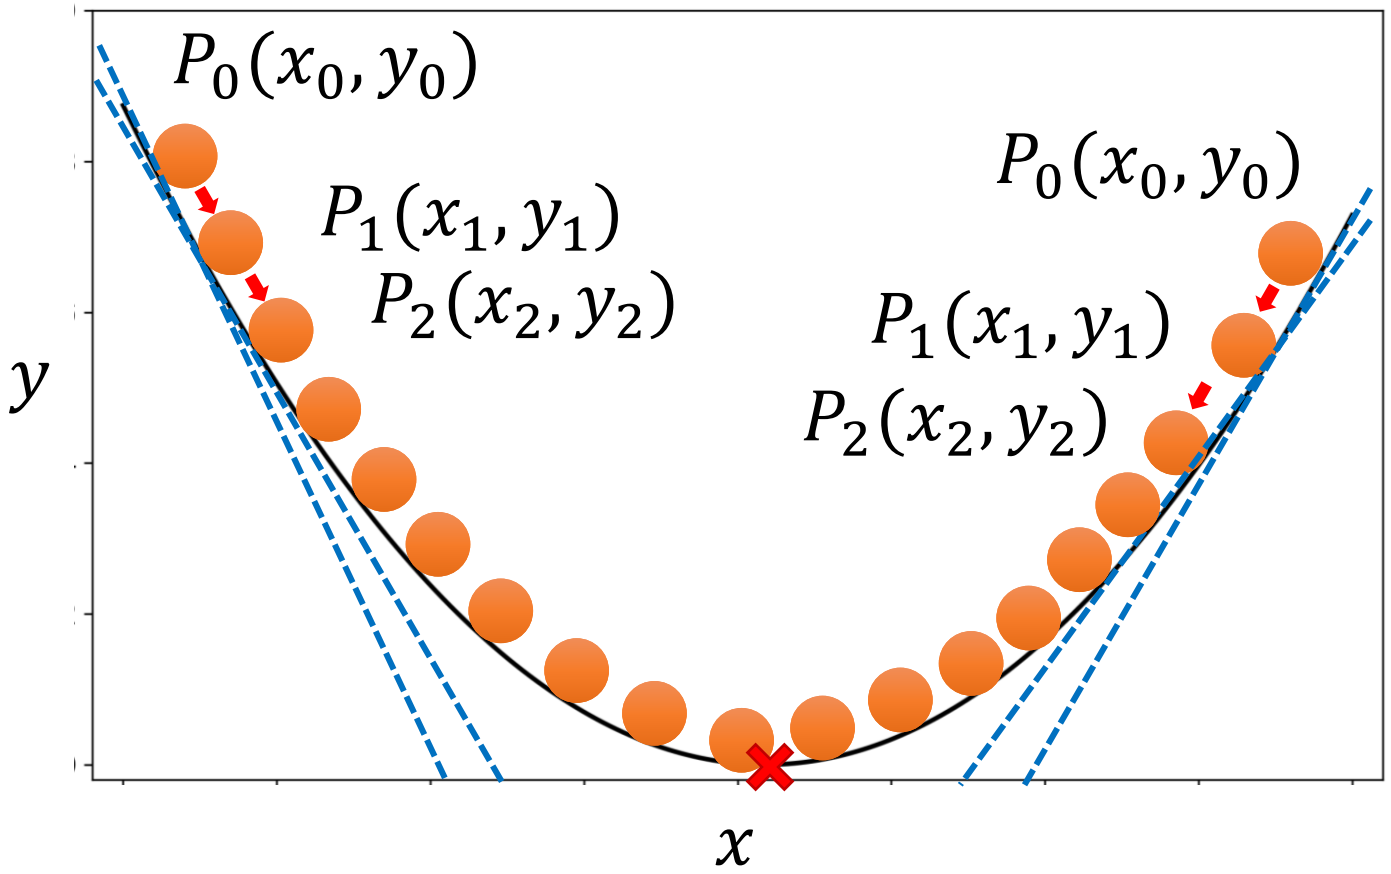

梯度下降的基本思想

回到找最优预测函数的问题 $w^* = arg\min_{w} L(w)$

Step 1: 计算一下 P_0 处的梯度 $\frac{d_L}{d_w}$

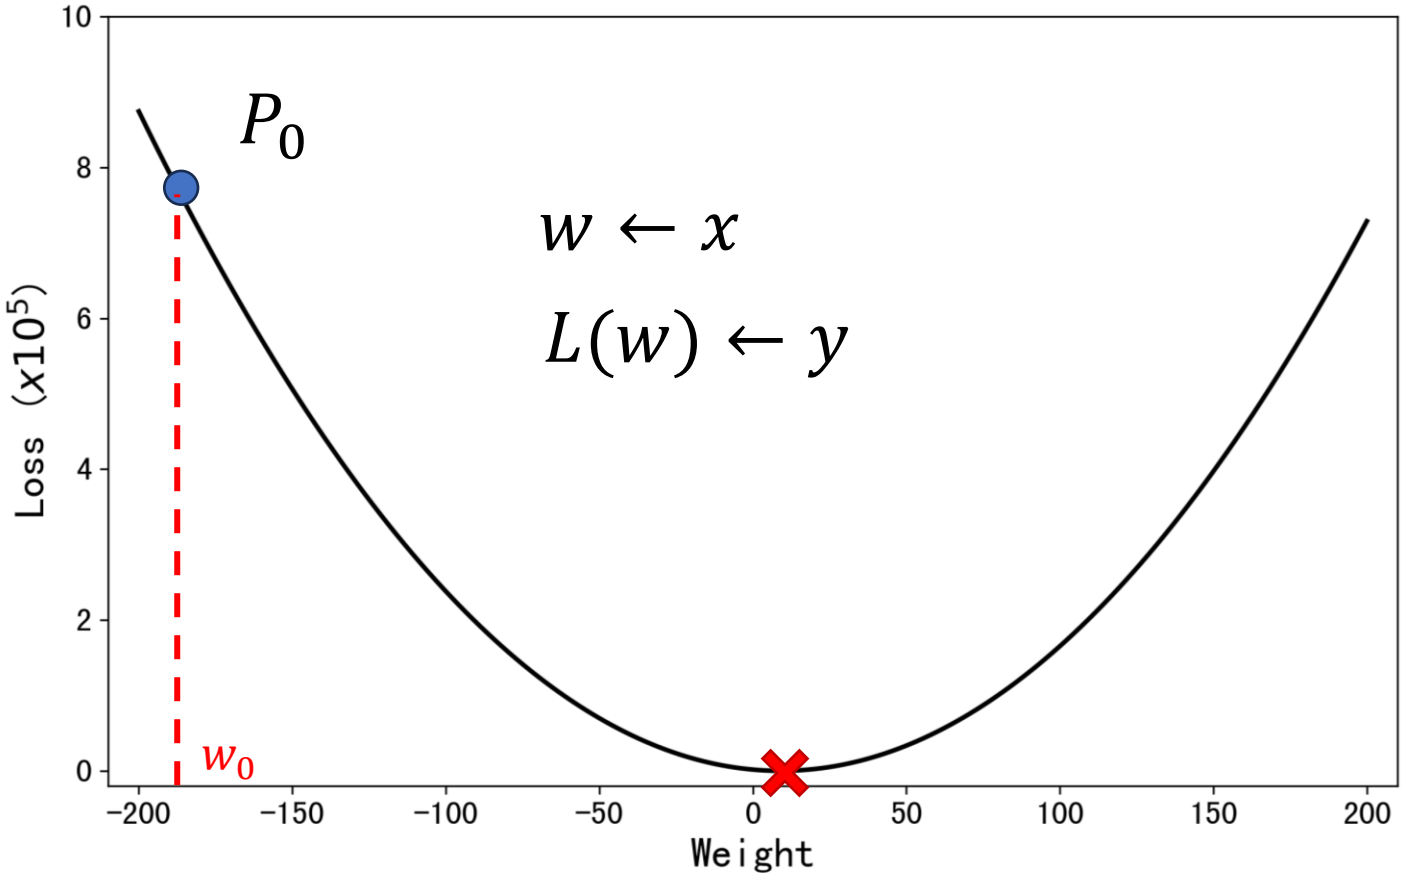

梯度下降的基本思想

回到找最优预测函数的问题 $w^* = arg\min_{w} L(w)$

Step 1: 计算一下 P_0 处的梯度 $\frac{d_L}{d_w}$

$$Loss = \frac{1}{2N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2$$

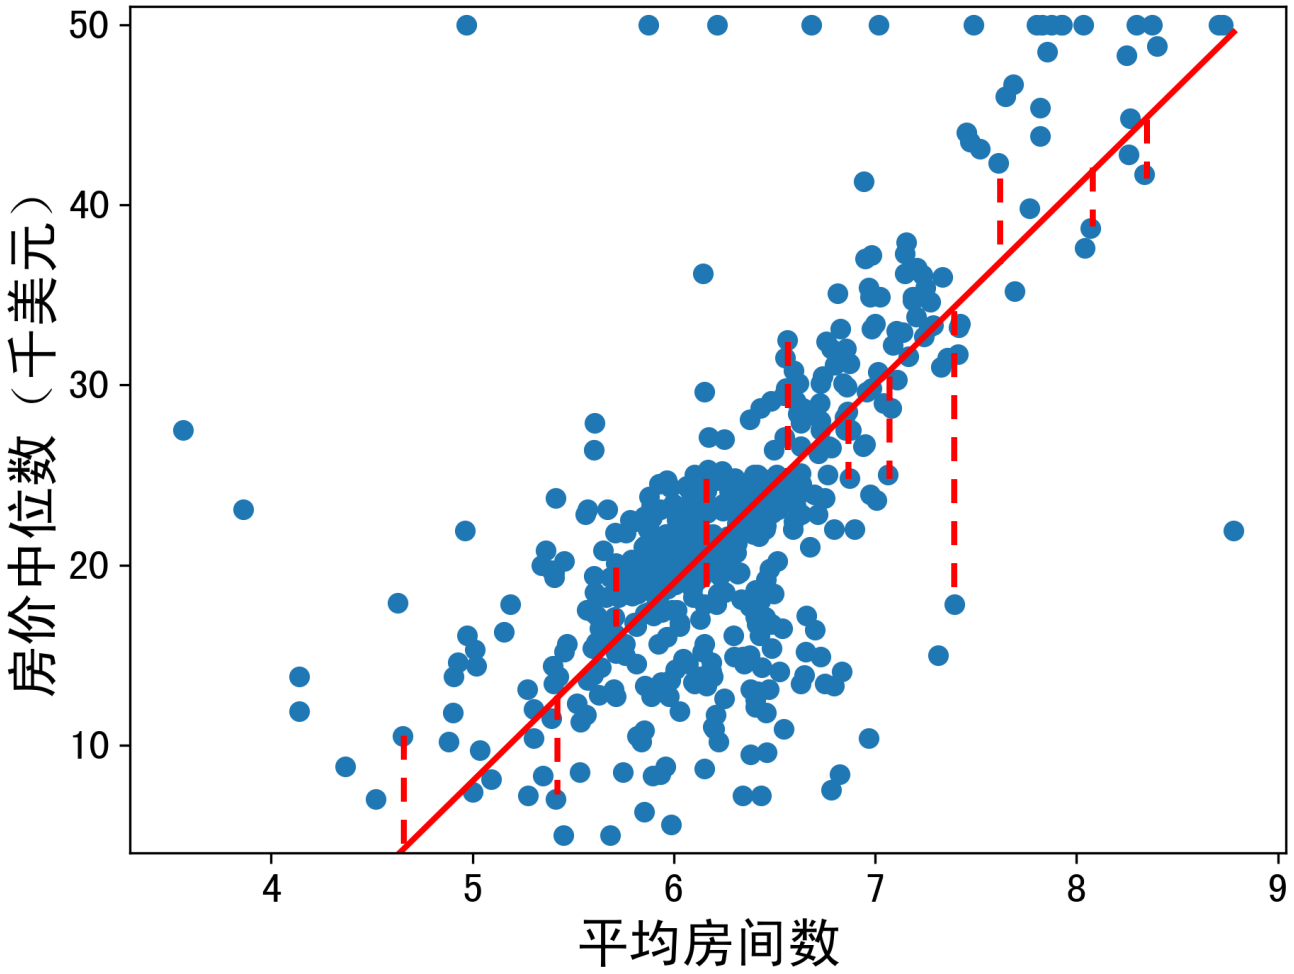

梯度下降的基本思想

回到找最优预测函数的问题 $w^* = arg\min_{w} L(w)$

Step 1: 计算一下 P_0 处的梯度 $\frac{d_L}{d_w}$

$$\frac{d_L}{dw} = \frac{d\left(\frac{1}{2N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2\right)}{dw}, \qquad \hat{y}_i = wx_i + b$$

$$= \frac{d\left(\frac{1}{2N}\sum_{i=1}^{N}\left((wx_i + b) - y_i\right)^2\right)}{d_w}$$

$$= \frac{1}{N}\sum_{i=1}^{N}(wx_i + b - y_i)x_i$$

梯度下降的基本思想

回到找最优预测函数的问题 $w^* = arg\min_{w} L(w)$

Step 2: 沿梯度反方向$-\frac{d_L}{d_w}$移动 η

$$w = w - \frac{d_L}{d_w} \cdot \eta$$

学习率

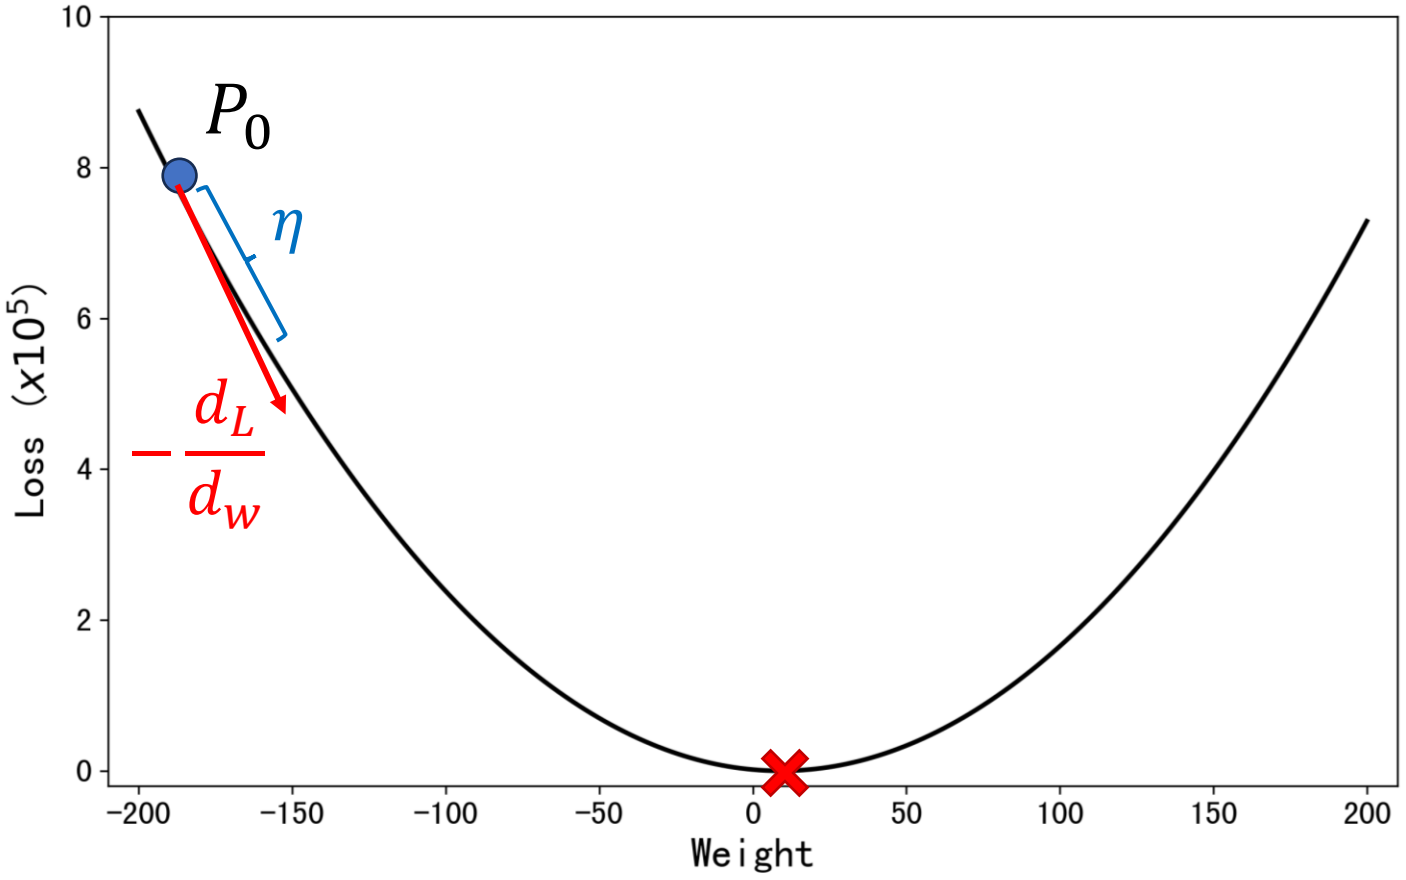

梯度下降的基本思想

回到找最优预测函数的问题 $w^* = arg\min_w L(w)$

Step 3: 不断重复Step 1和Step 2

计算当前w的梯度 $\frac{d_L}{d_w}$

梯度下降

$$w = w - \frac{d_L}{d_w} \cdot \eta$$

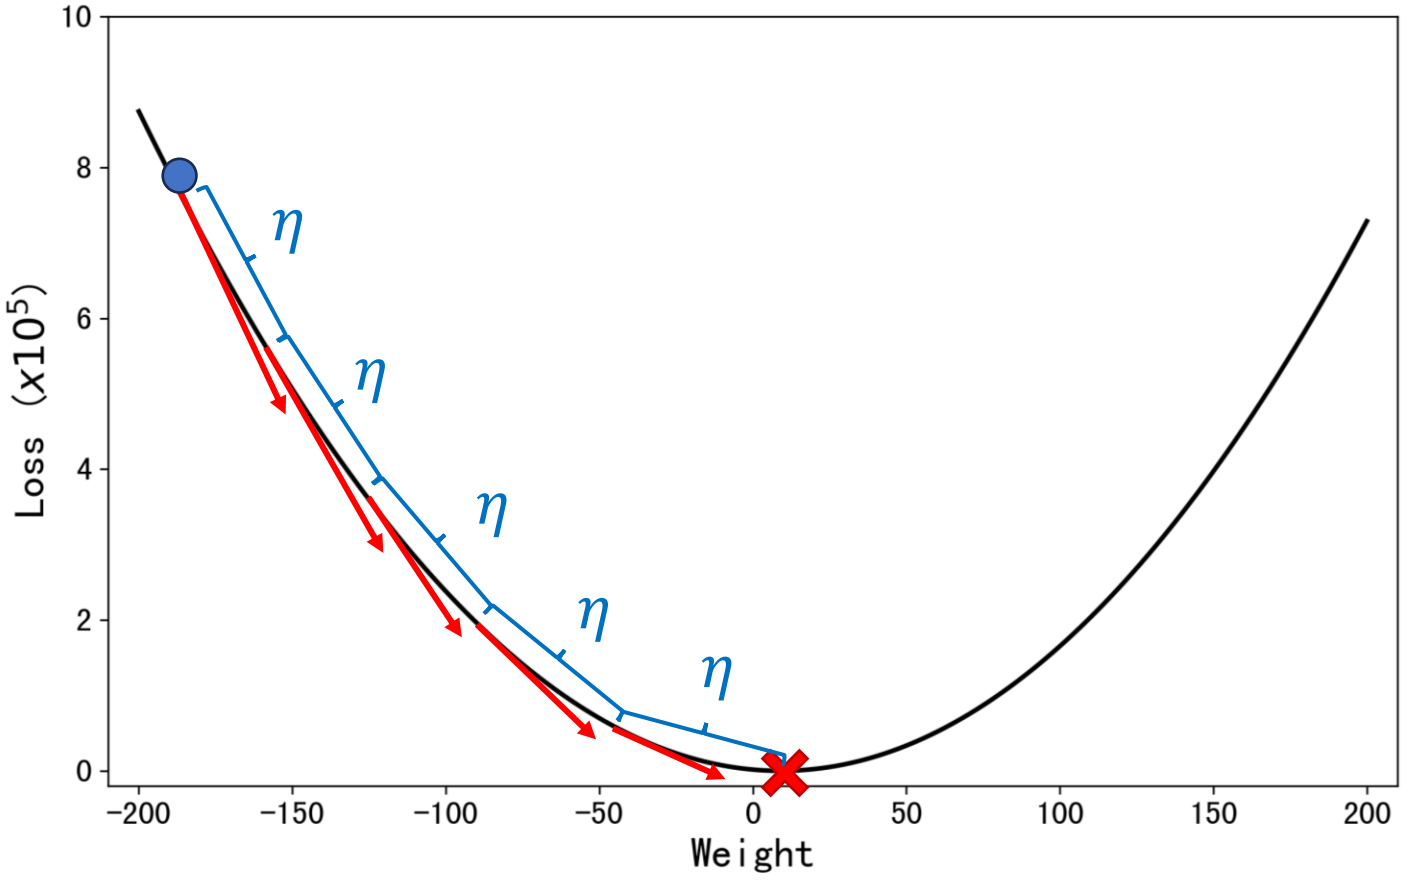

梯度下降的基本思想

对于更加复杂的函数怎么办？ $L(\boldsymbol{w}, b) = \sum_{i=1}^{N} w_i \cdot x_i + b$

Step 1: 计算各参数的偏导数 $\frac{\partial L}{\partial b}$， $\frac{\partial L}{\partial w_i}$

Step 2: 分别更新各参数 $b = b - \eta \frac{\partial L}{\partial b}$， $w_i = w_i - \eta \frac{\partial L}{\partial w_i}$

Step 3: 不断重复 Step 1 和 Step 2

梯度下降的基本思想

$$-\frac{d_L}{d_w}\cdot\eta$$

理解 1：梯度描述变化速度

$$\frac{d_L}{d_w}$$

梯度数值越大，w变化越快

数值越小，表示变化越平缓

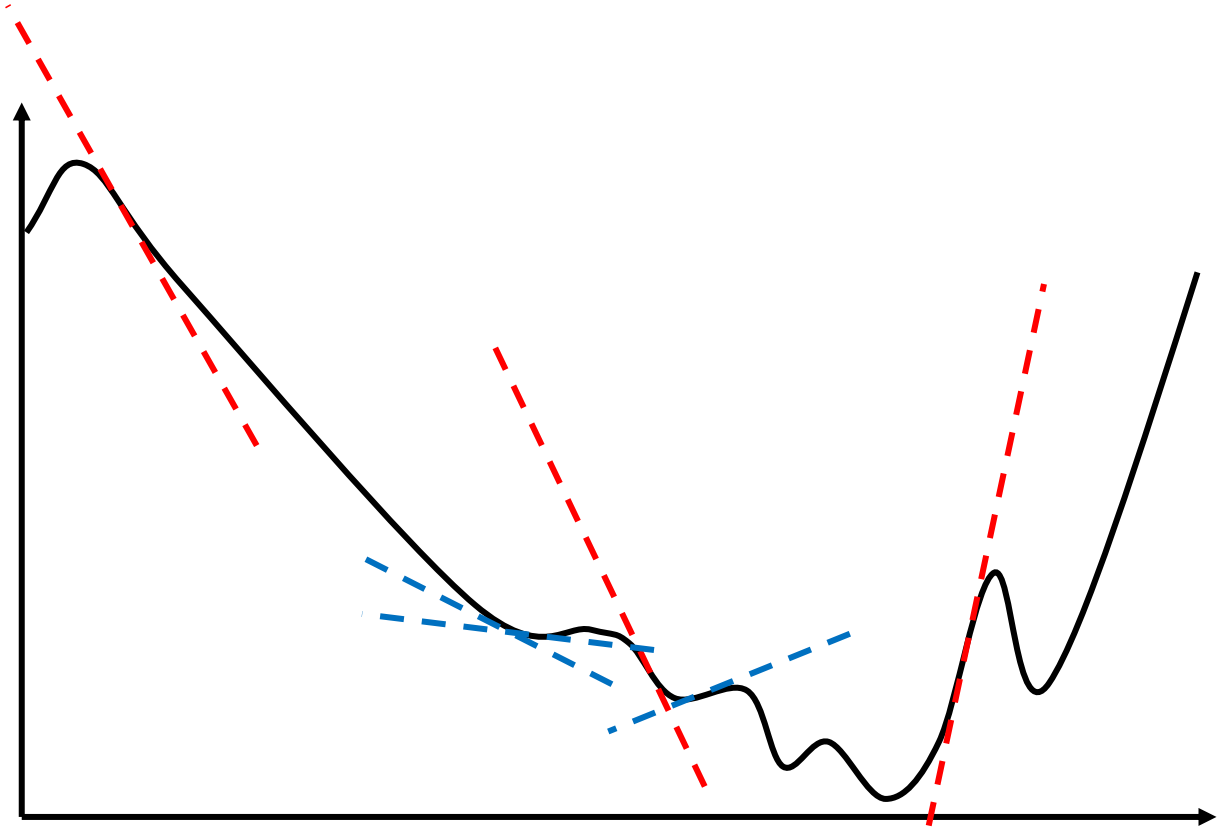

梯度下降的基本思想

$$-\frac{d_L}{d_w}\cdot\eta$$

理解 1：梯度描述变化速度

理解 2：学习率为“步幅”，需由人工谨慎设定

η

较大的学习率能提升模型训练效率。但是，过于“激进”的学习率会“爆炸”。过于“谨慎”的学习率，会使模型训练效率极为低下。

学习率的选择一定要慎重

学习率的选择

在训练模型时……

理想情况

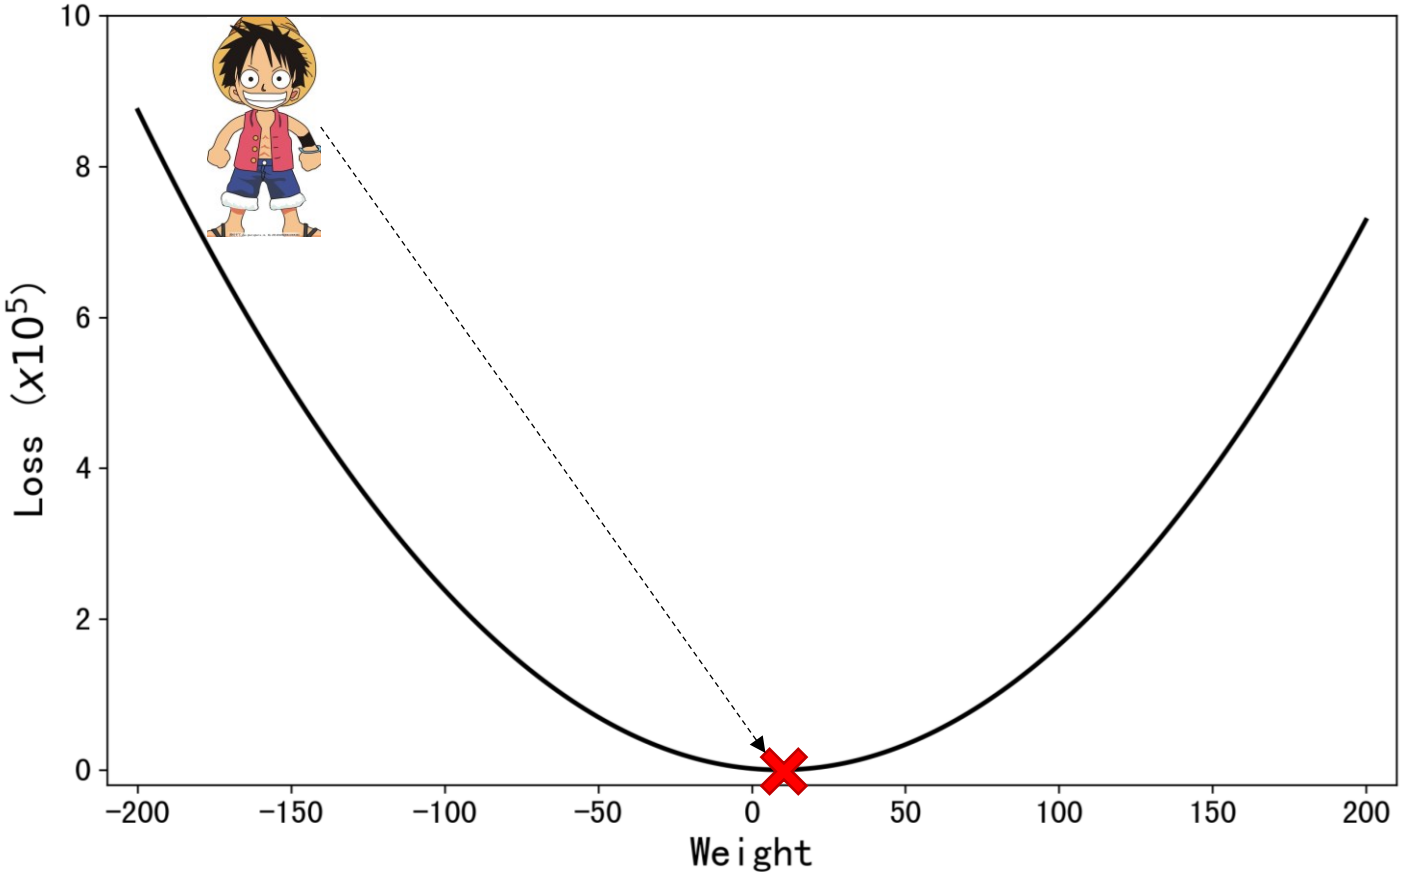

学习率的选择

在训练模型时……

实际情况

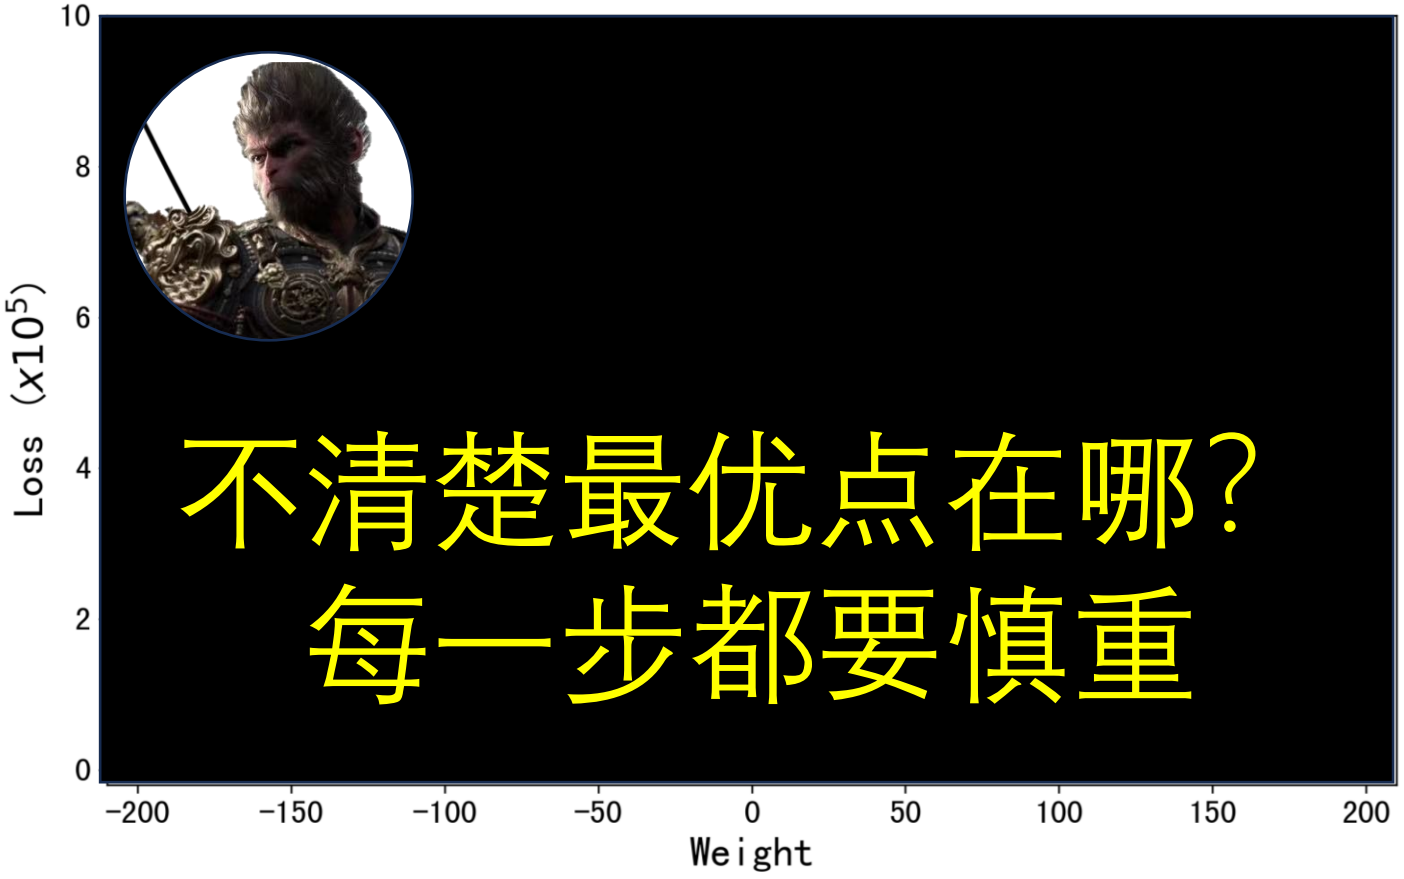

学习率的选择

当碰巧选择了合适的学习率，能在时间范围内收敛至最优点

$$\eta = 0.00001$$

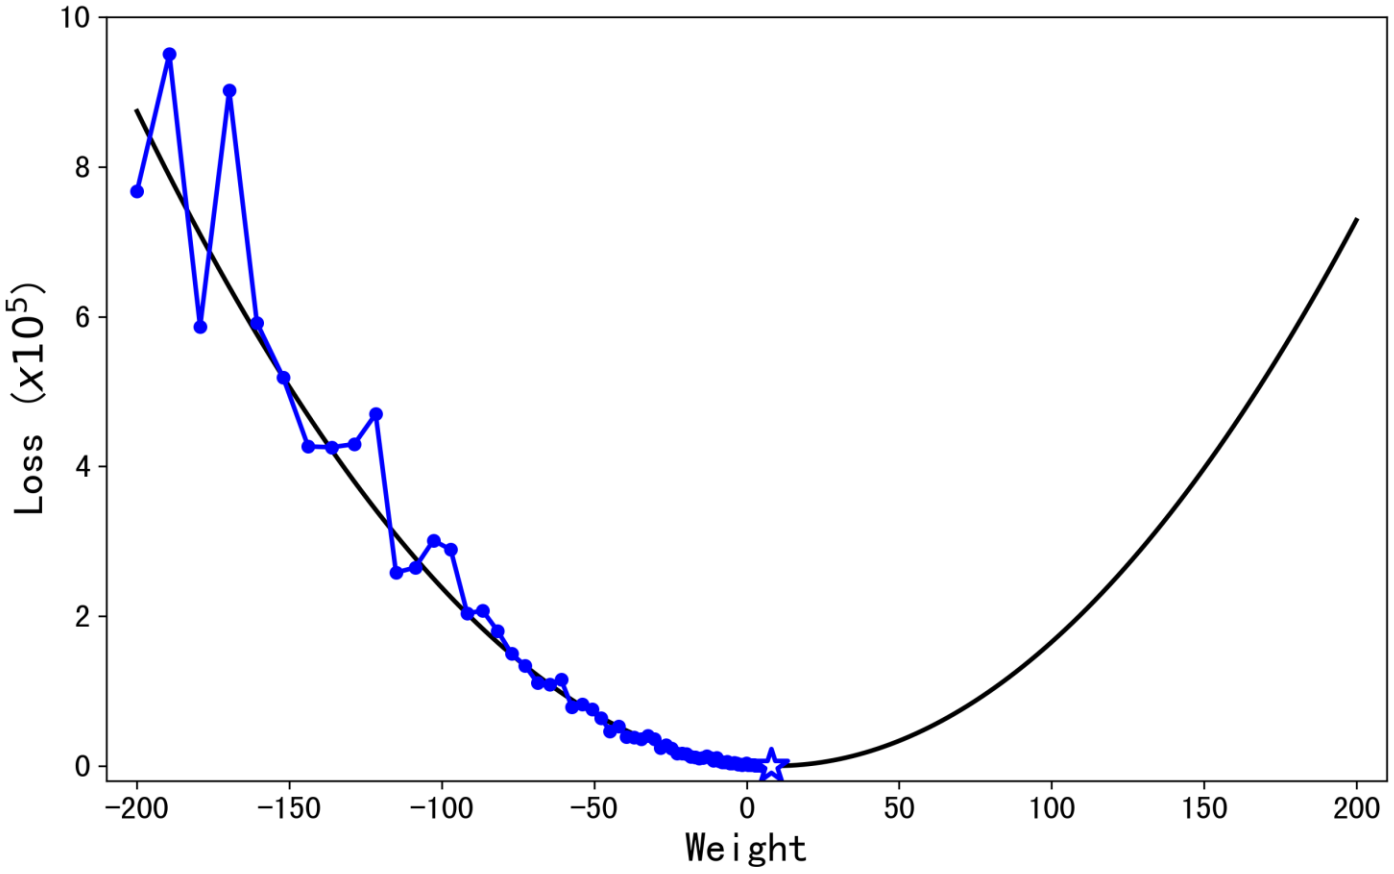

学习率的选择

更小一点的学习率，无法在规定的时间内收敛至最优点

$$\eta = 0.000001$$

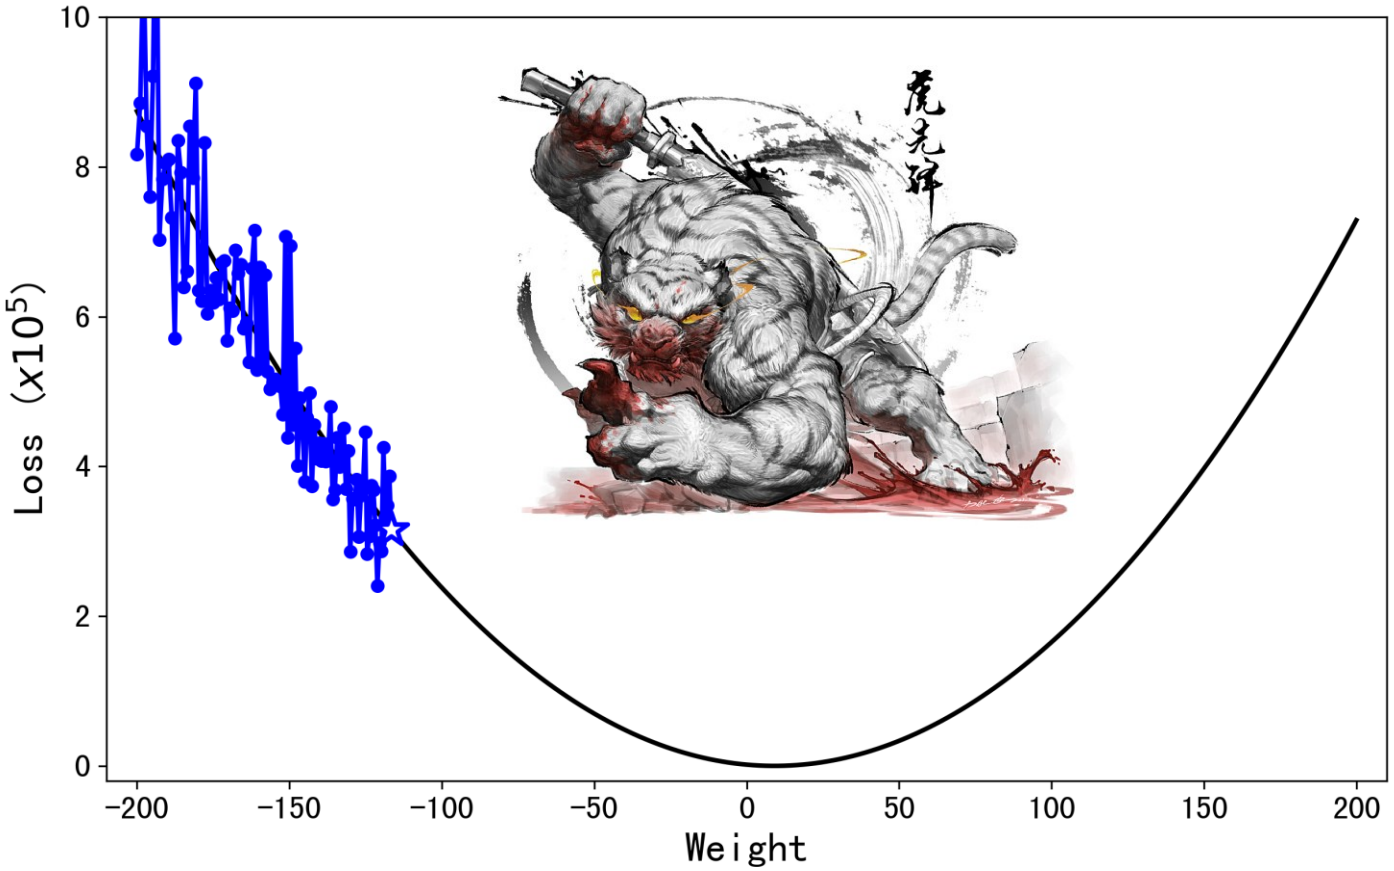

学习率的选择

再小一点的学习率，无法学到一点

$$\eta = 0.0000001$$

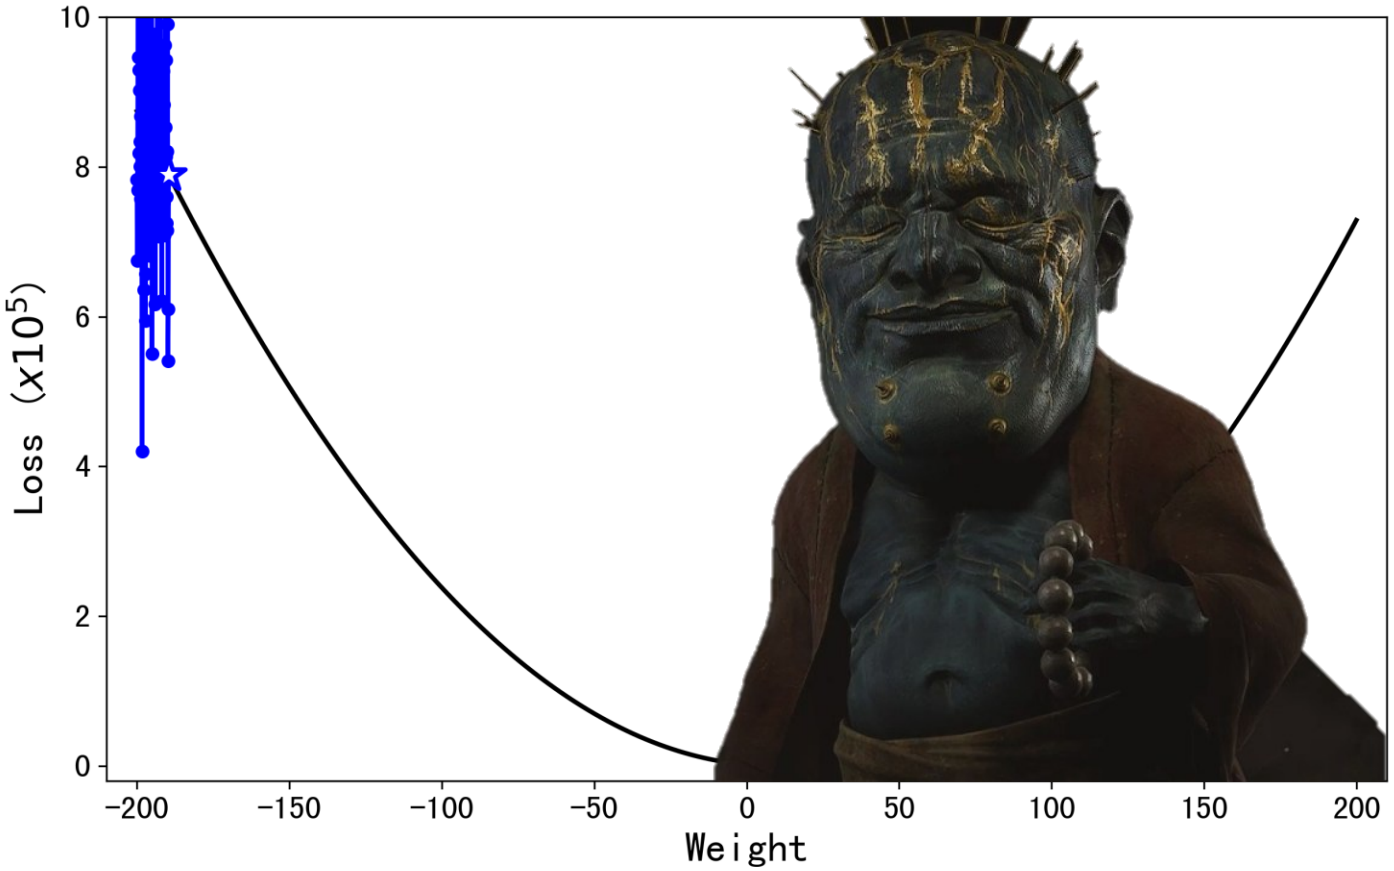

学习率的选择

调大一点学习率，能够更快速地逼近最优点

$$\eta = 0.0001$$

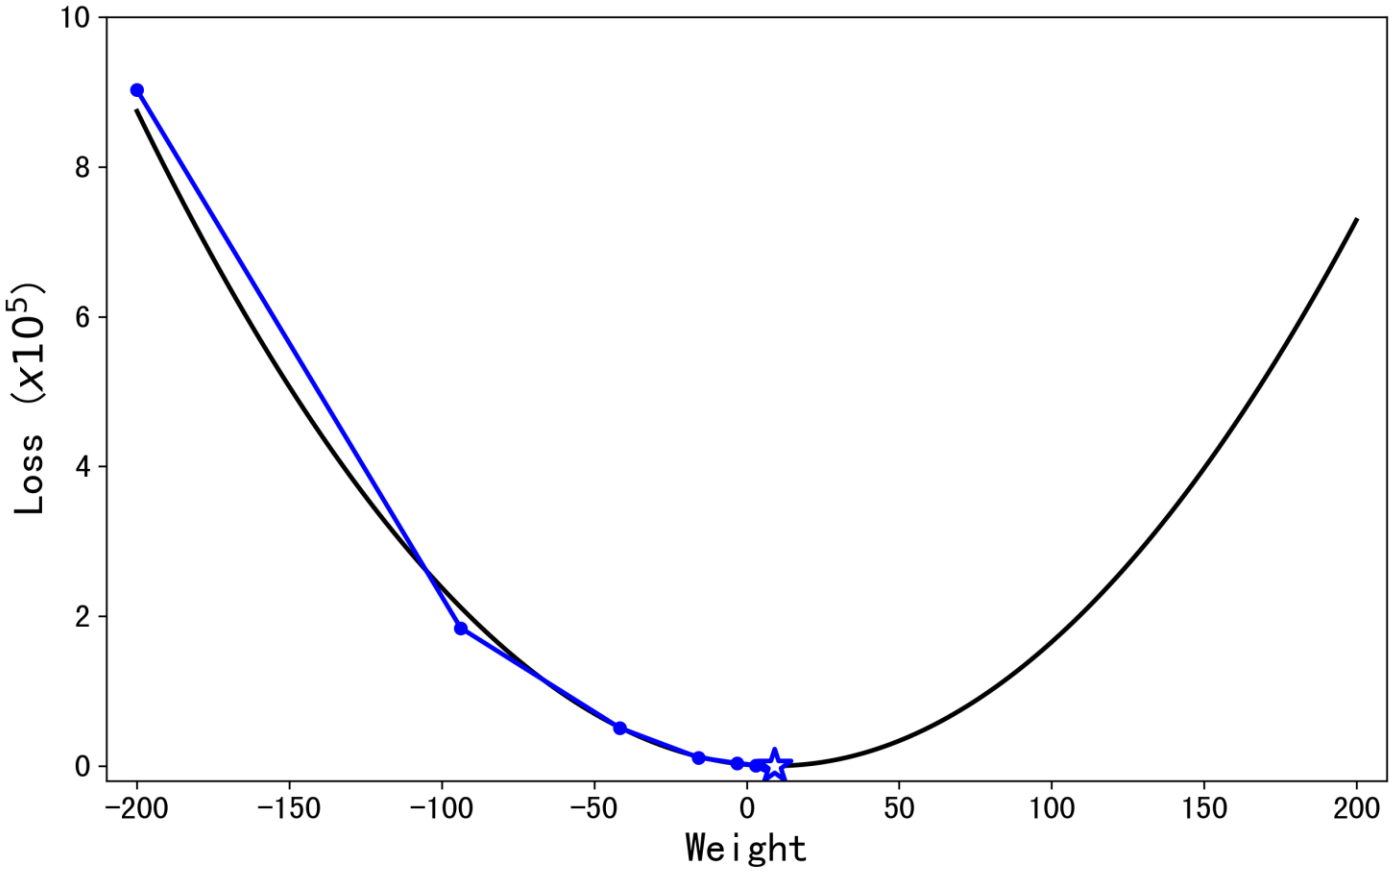

学习率的选择

如果学习率设更大一点，在最优点周围反复横跳

$$\eta = 0.0003$$

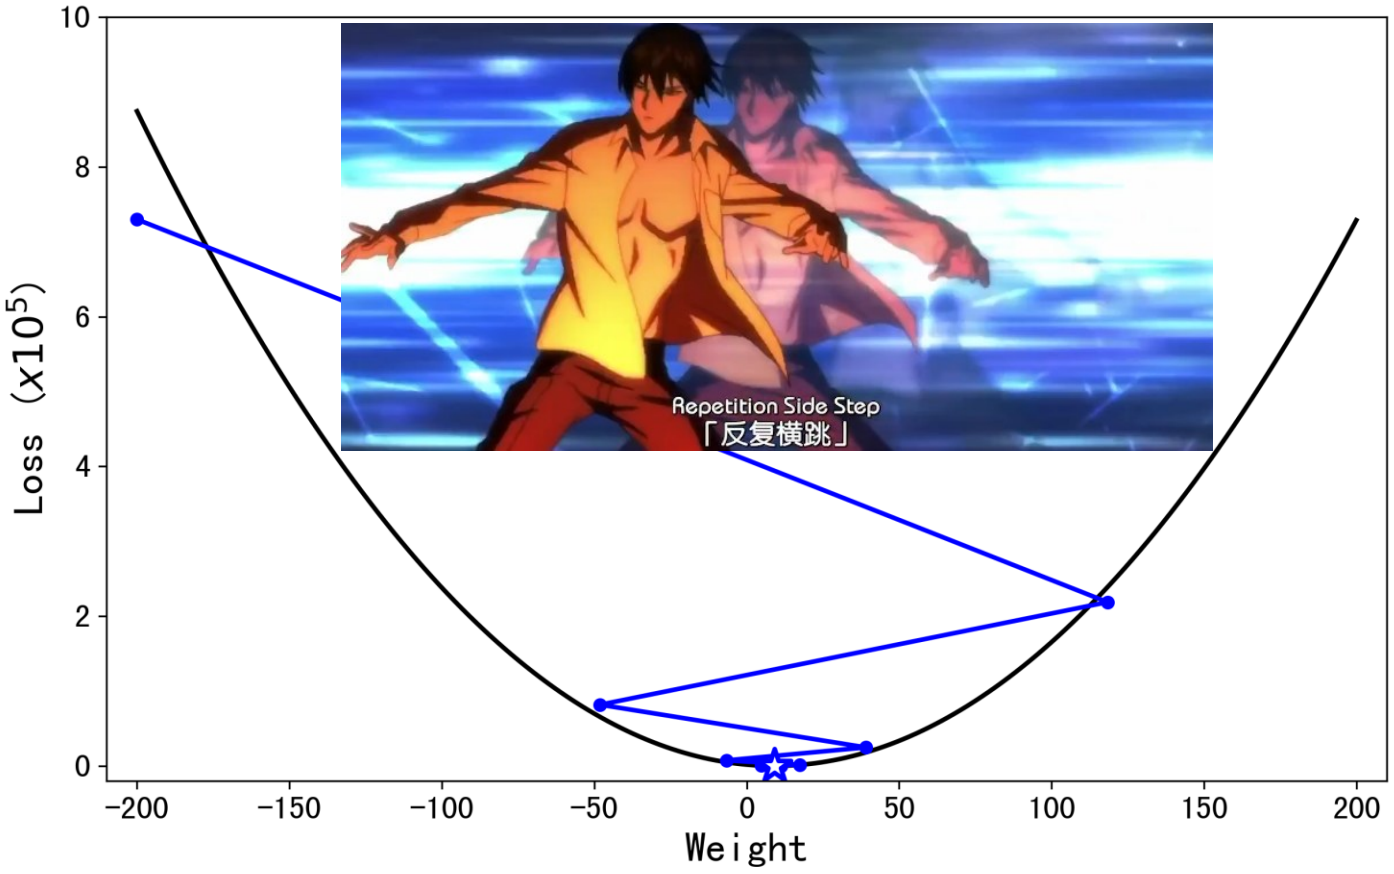

《在下版本有何贵干》

学习率的选择

如果学习率设再大一点，结果便不收敛了

$$\eta = 0.001$$

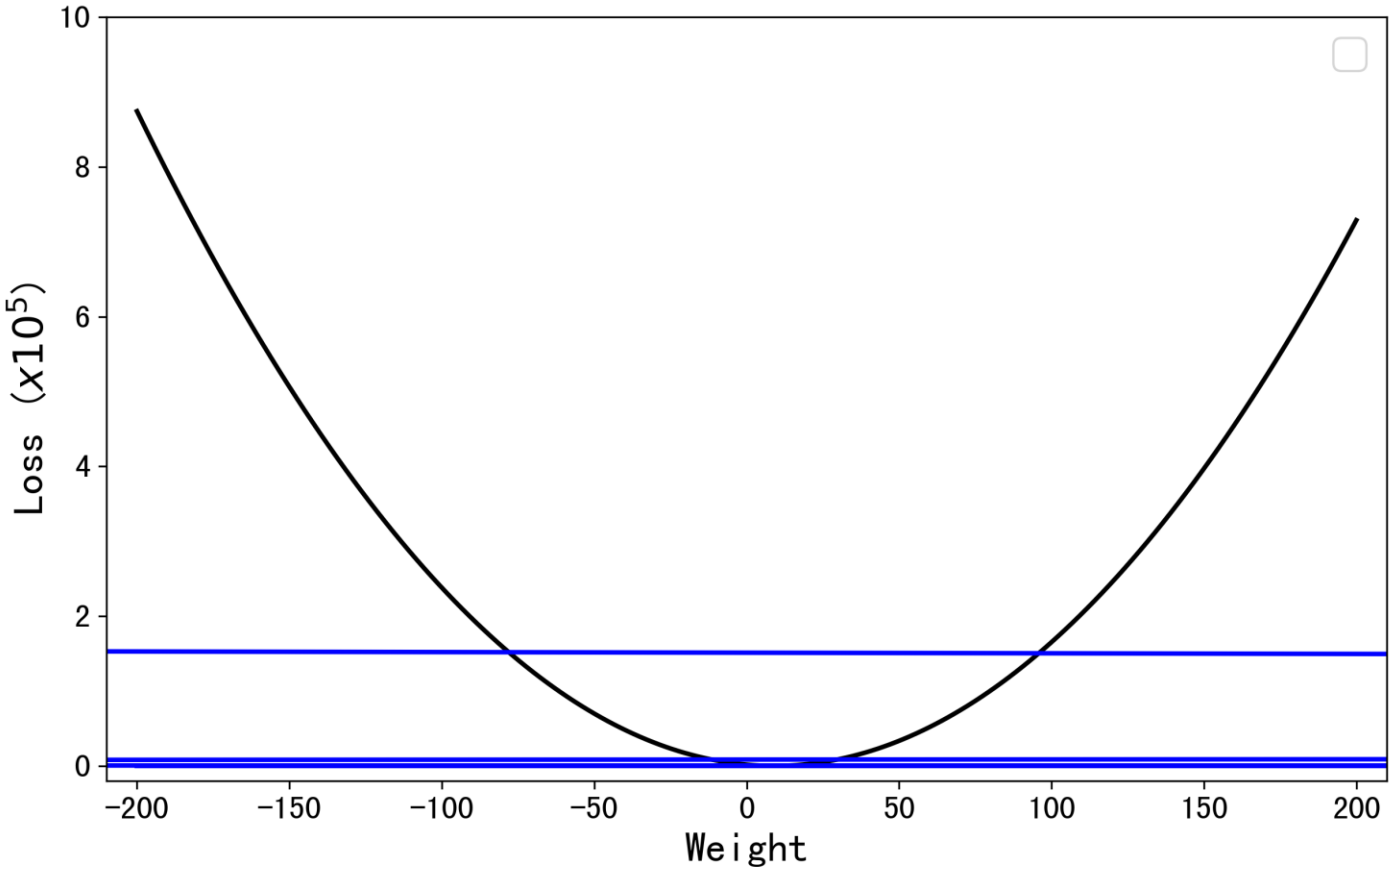

学习率最好是开始大，后来小

自适应学习率

让学习率随时间动态变小:

$$\eta = \frac{1}{T}\eta$$

学习率开始大，能够迅速靠近最优点

学习率随时间增加逐渐减小

在靠近最优点时，较小地学习率能够避免反复横跳，从而收敛

所有参数统一减小是好事吗？

自适应学习率

观察右图，学习w和b 时有何不同:

学习w较快，学习b较慢

如果w和b的学习率同步减小，则b可能难以收敛至最优

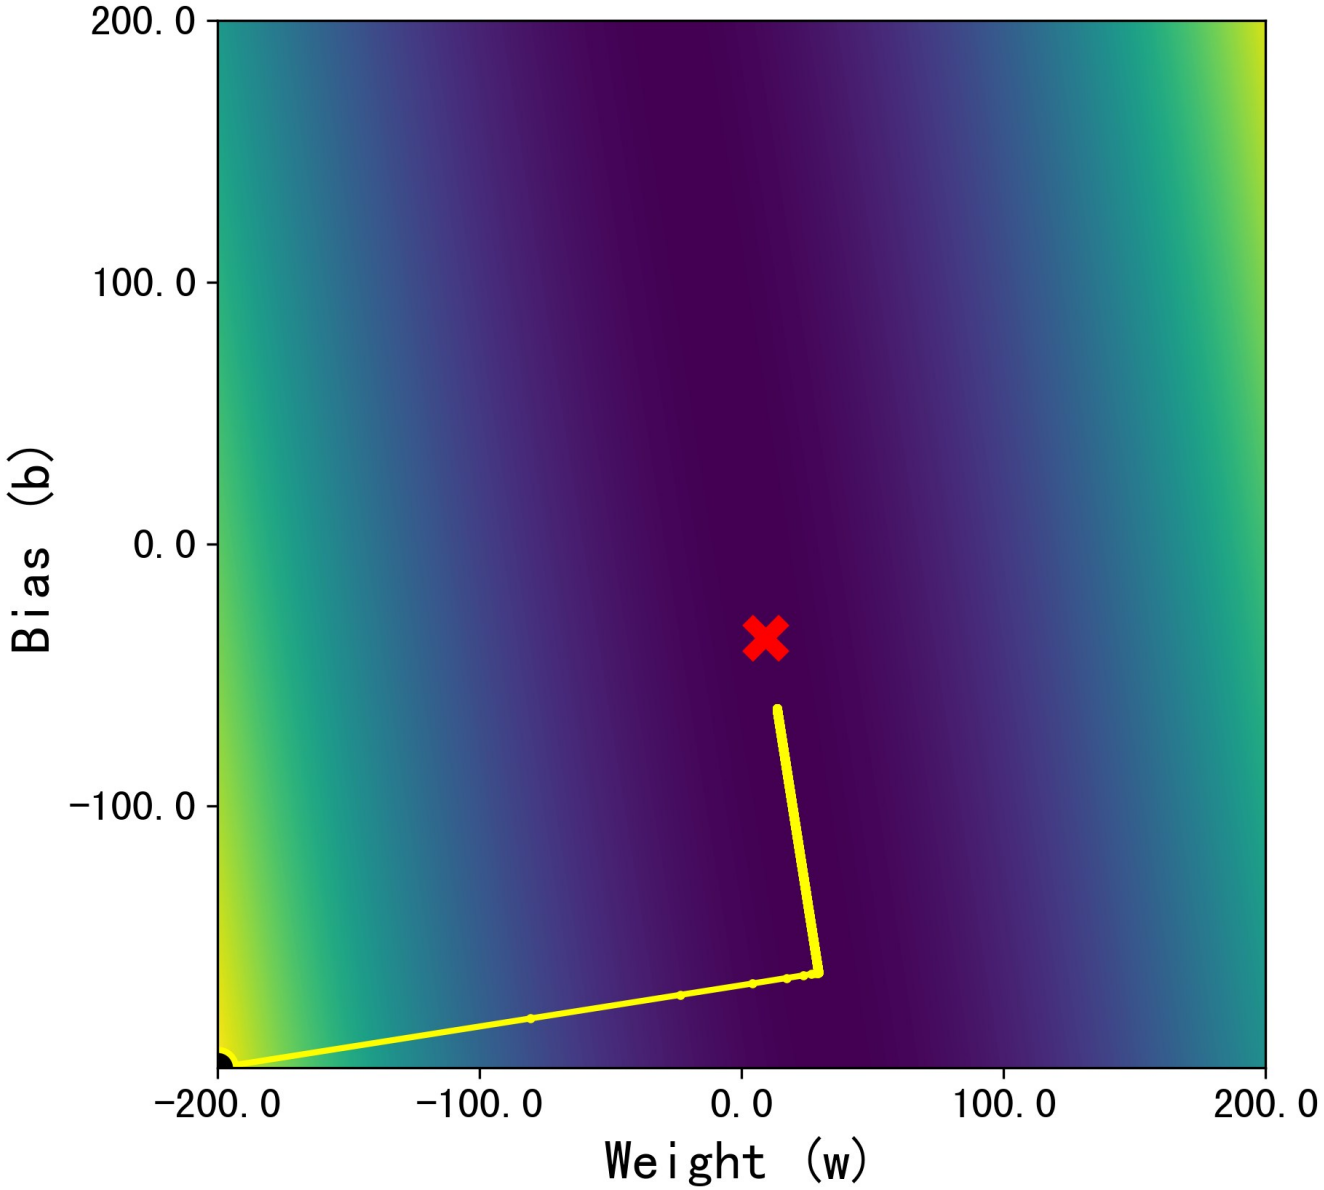

最好根据参数定制学习率衰减方式

自适应学习率——Adagrad

Adagrad 数学公式:

$$\eta_w = \frac{1}{\sqrt{\sum_{i=1}^{T}\left(dw_i - \overline{dw}\right)^2 + \epsilon}}\eta_w$$

极小值，保证分母不出现0

自适应学习率——Adagrad

Adagrad 数学公式:

$$\eta_w = \frac{1}{\sqrt{\sum_{i=1}^{T}\left(dw_i - \overline{dw}\right)^2}}\eta_w$$

自适应学习率——Adagrad

Adagrad 数学公式:

$$\eta_w = \frac{1}{\sqrt{\sum_{i=1}^{T}\left(dw_i - \overline{dw}\right)^2}}\eta_w$$

分子分母同时除以$\sqrt{T-1}$公式:

$$\frac{\frac{1}{\sqrt{T-1}}}{\boxed{\sqrt{\frac{\sum_{i=1}^{T}\left(dw_i - \overline{dw}\right)^2}{T-1}}}}\eta_w$$

前T次计算所得之dw的标准差

自适应学习率——Adagrad

标准差（Standard Deviation）表示数据集中的数值与数据集的平均值（均值）之间的偏差程度，是衡量一组数据离散程度的一个指标。标准差越大，数据的分布越广；标准差越小，数据的分布越集中。

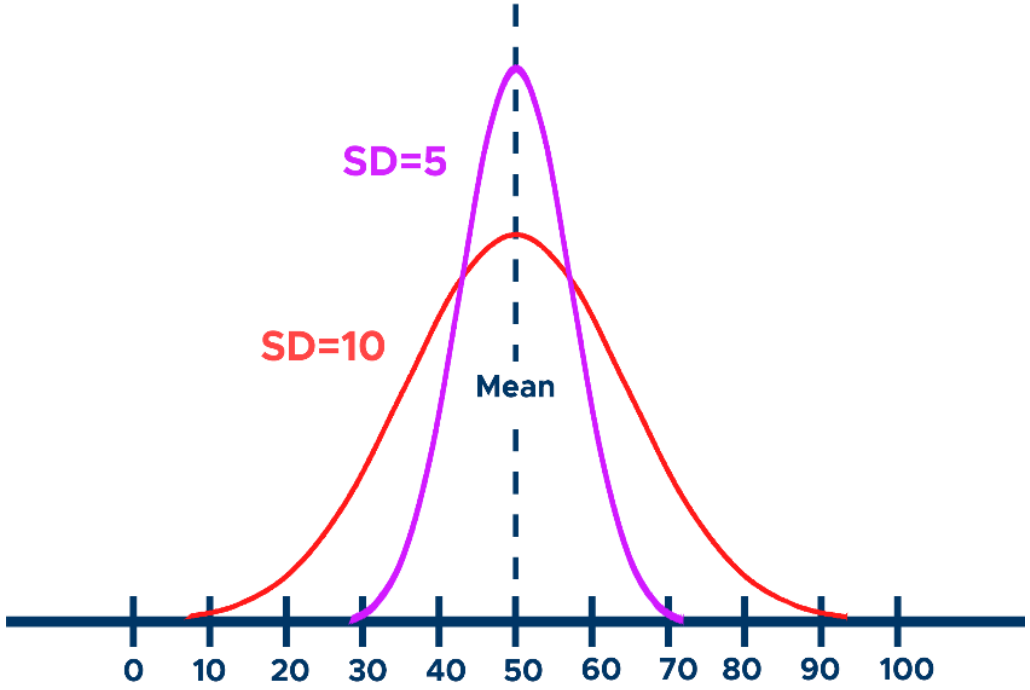

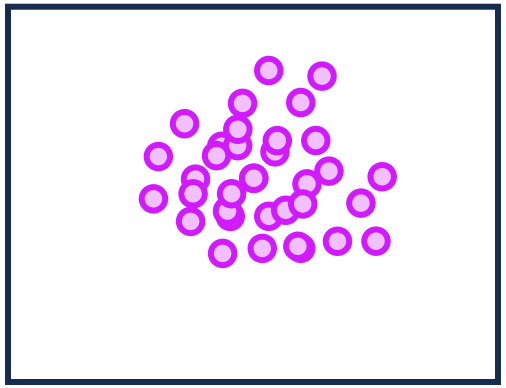

标准差较小，即
前T次的 dw 相似

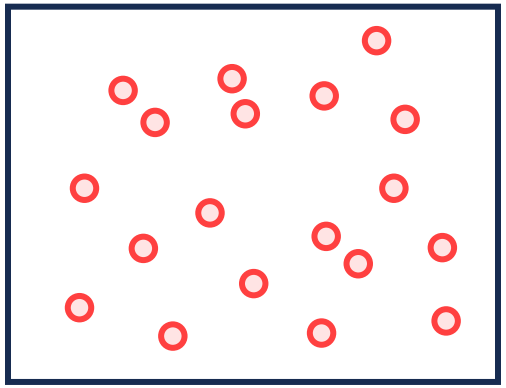

标准差较大，即
前T次的 dw 变化大

自适应学习率——Adagrad

$$\eta_w = \frac{\frac{1}{\sqrt{T-1}}}{\sqrt{\frac{\sum_{i=1}^{T}\left(dw_i - \overline{dw}\right)^2}{T-1}}}\eta_w$$

① σ小，$1/\sigma$大，η_w衰减慢

② σ大，$1/\sigma$小，η_w衰减快

学习率的更新与时间没有直接关系

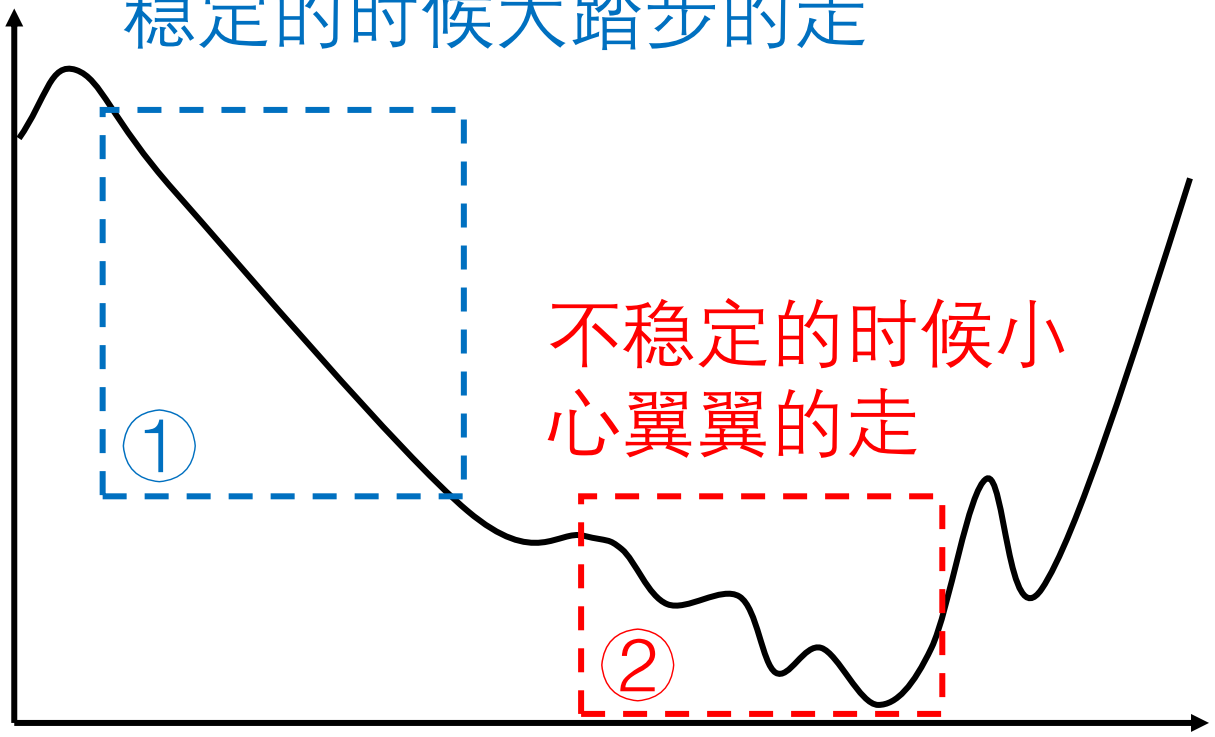

自适应学习率——Adagrad

在训练时应用Adagrad，各参数都能较为快速的收敛

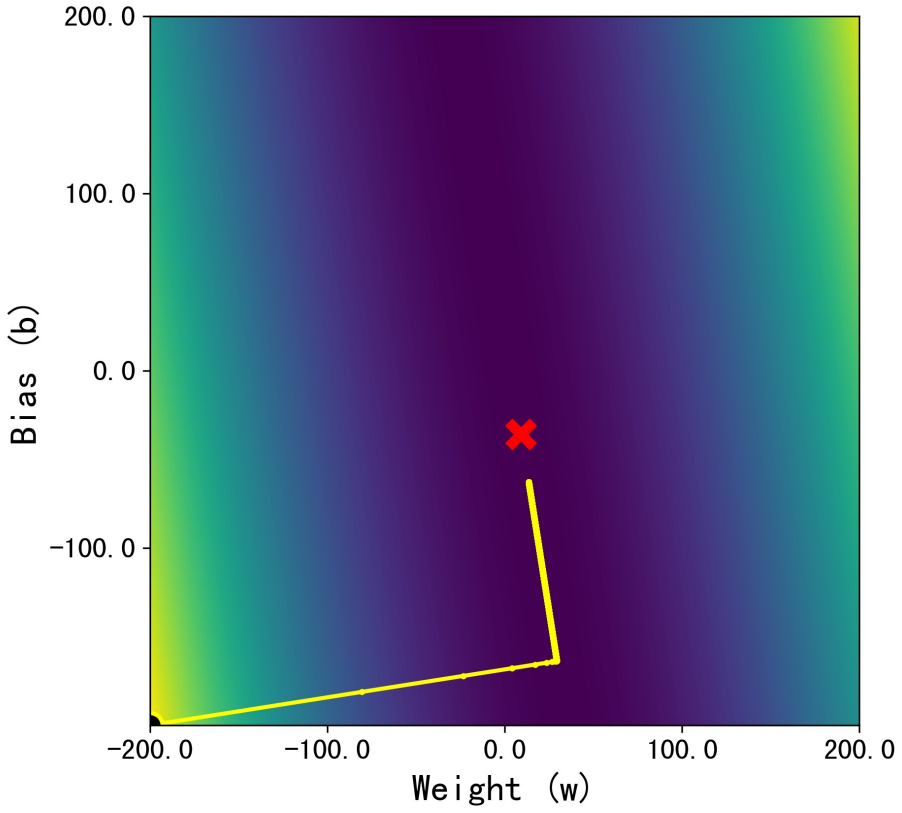

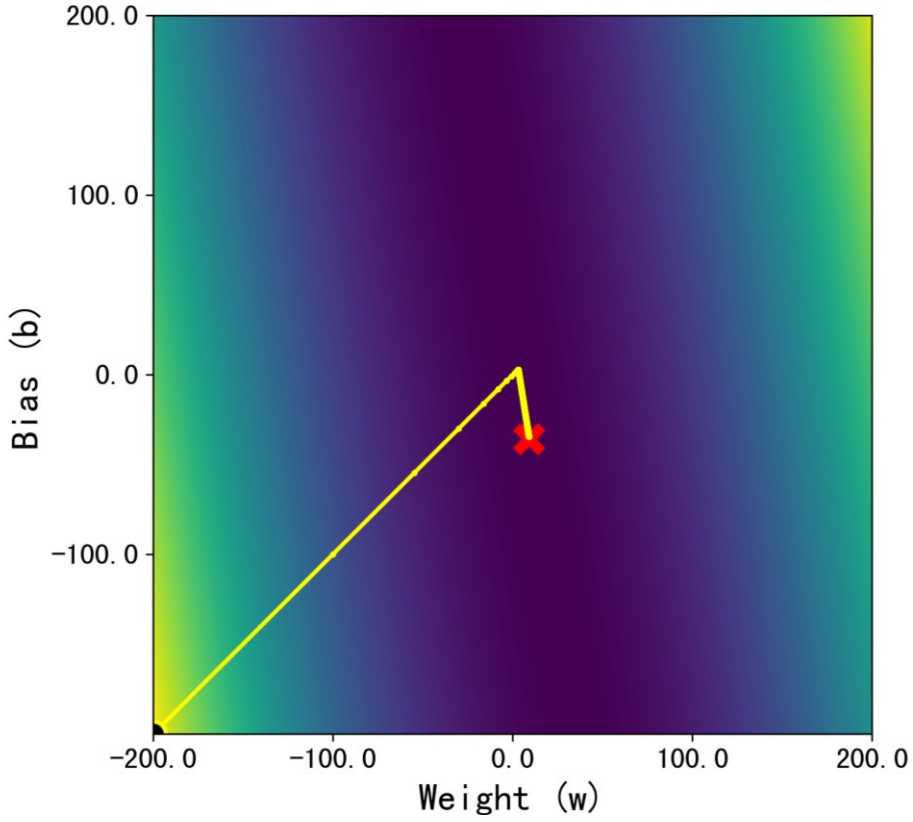

课后思考：这样训练完预测模型就能直接用了吗？