# 2.5 发生过拟合了怎么办?

数据增强&正则化&交叉验证&早停法

顺带提一下欠拟合问题

# 前情提要——使用Gradient Descent方法找到最优的预测模型

Step 1: 计算各参数的偏导数

$$\frac{\partial L}{\partial b}, \quad \frac{\partial L}{\partial w_i}$$

Step 2: 分别更新各参数

$$b = b - \eta \frac{\partial L}{\partial b}, \quad w_i = w_i - \eta \frac{\partial L}{\partial w_i}$$

Step 3: 重复 Step 1 和 Step 2

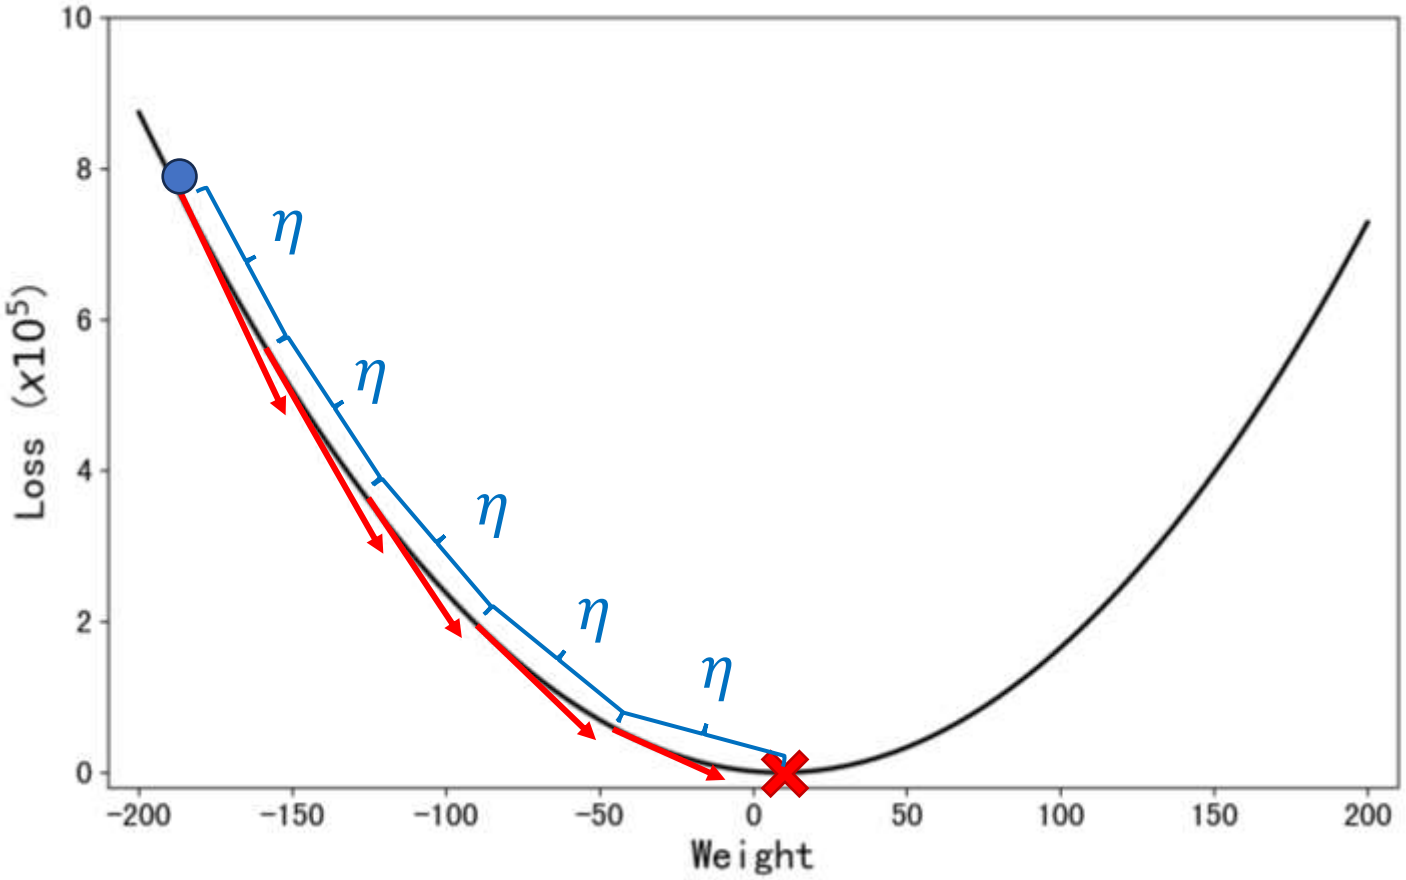

# 思考问题

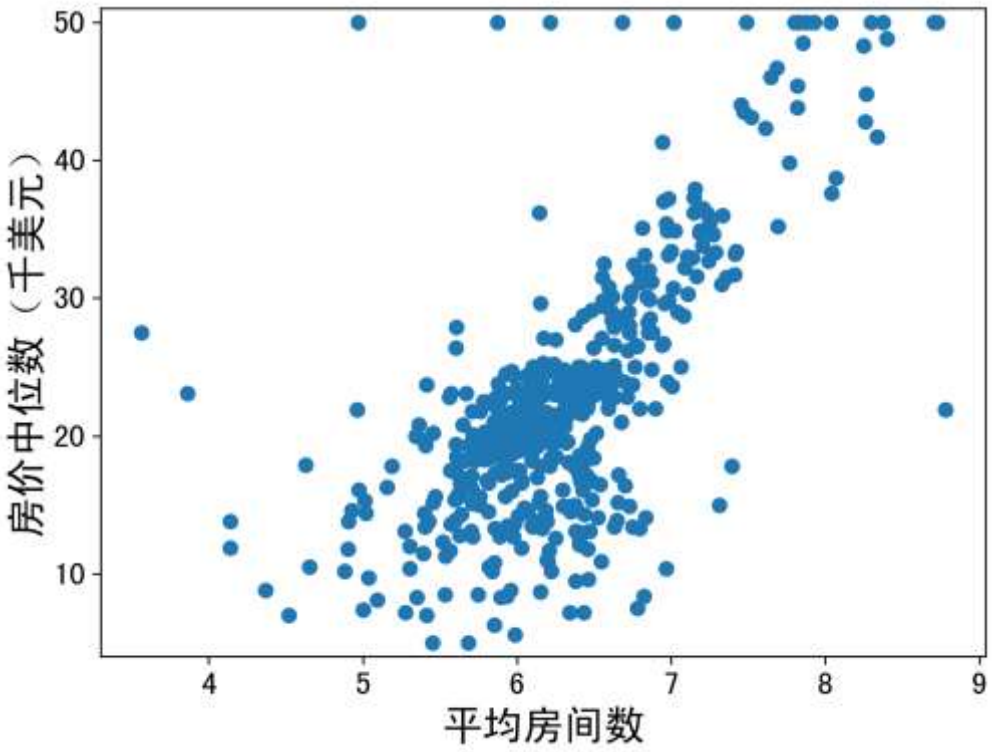


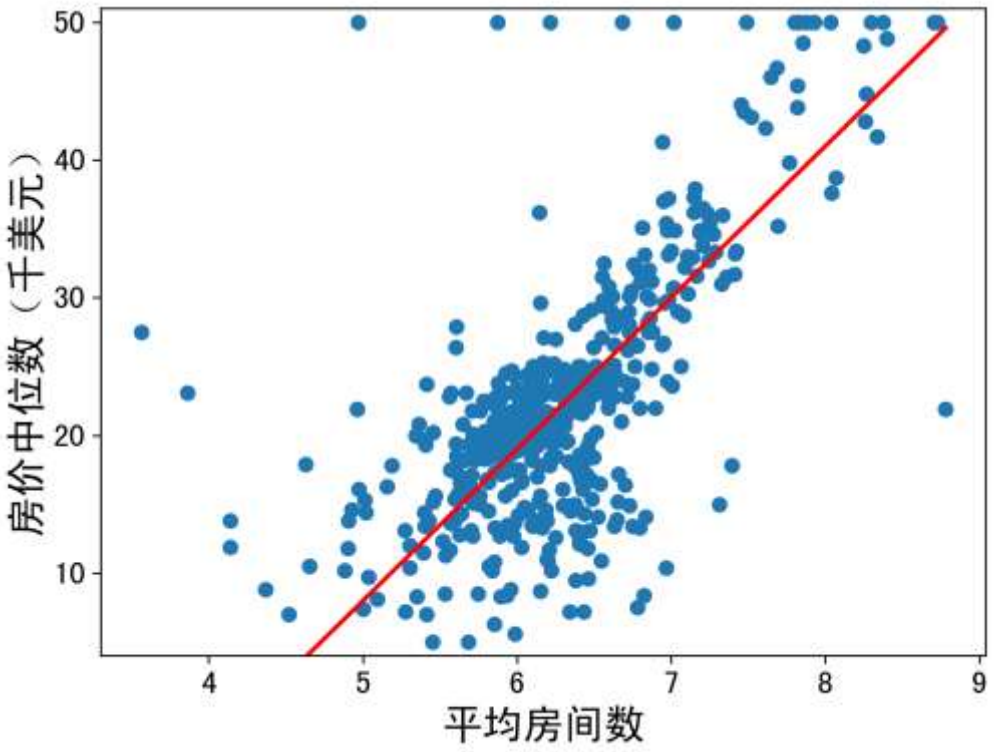


**这样训练完预测模型就能直接用了吗？**

# 一个发生了过拟合的人

极其熟悉训练环境与操作的细节

无法直接在新环境中顺利完成入库

**通过放置水桶还原训练场景中的关键参考物，不失为一种泛化方法。**

思考并讨论：有哪些方法可以让此人在训练过程中避免过拟合？

# 发生过拟合应该怎么办?

不同复杂度模型的训练和测试误差

| 复杂度 | 训练误差 | 测试误差 |
|---|---|---|
| 1 | 2.8898 | 4.9989 |
| 2 | 2.8688 | 2.1824 |
| 3 | 2.4948 | 9.7763 |
| 4 | 1.8300 | 27.6936 |
| 5 | 1.8525 | 26.4811 |
| 6 | 1.7230 | 142.1823 |
| 7 | 0.5671 | 3563.2944 |
| 8 | 0.5238 | 6518.7184 |
| 9 | 0.6230 | 26062.6516 |
| 10 | 0.8185 | 91591.8384 |

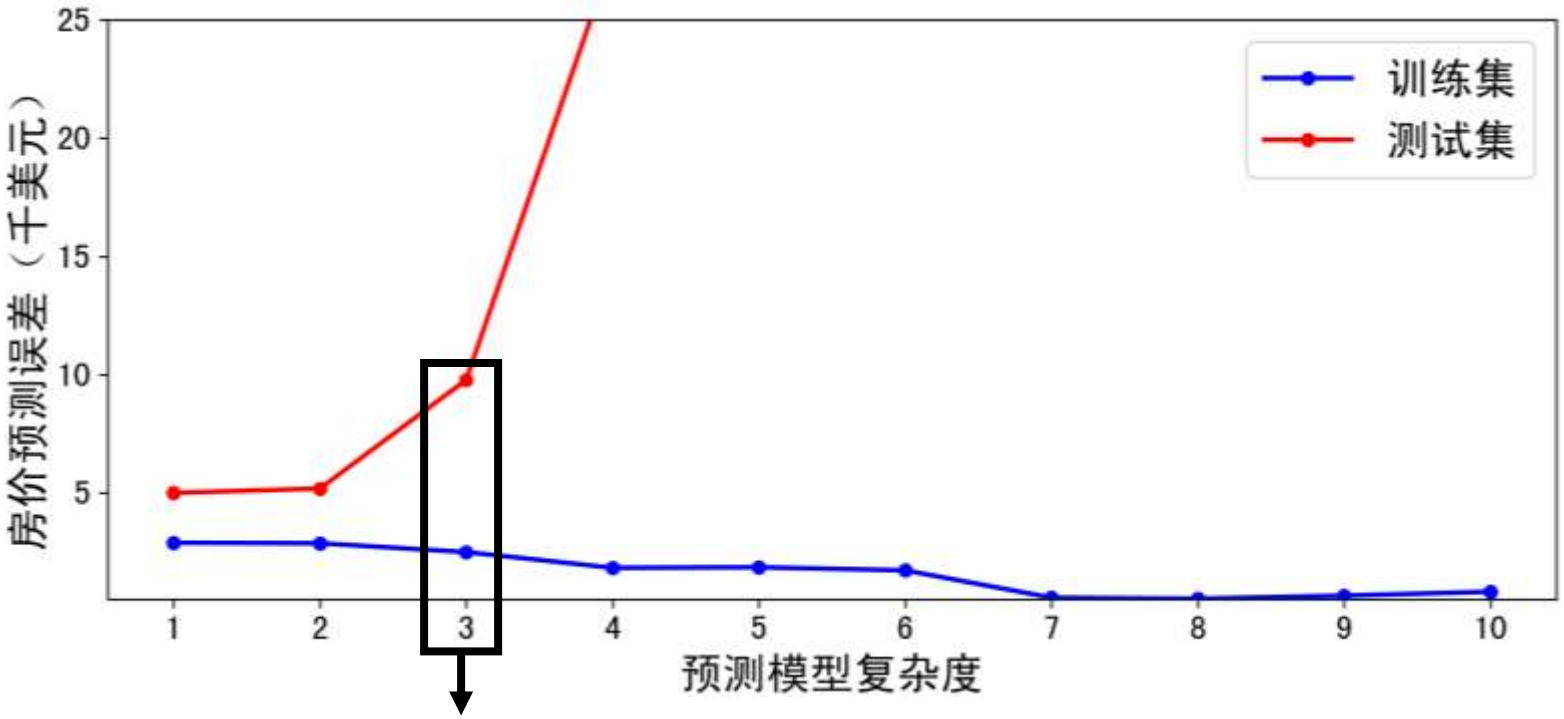


不出意外，这里应该是出意外了

训练集表现良好，测试集表现很差。

大概率发生了**过拟合**

# 发生过拟合应该怎么办？—— ① 降低模型复杂度

不同复杂度模型的训练和测试误差

| 复杂度 | 训练误差 | 测试误差 |
|---|---|---|
| 1 | 2.8898 | 4.9989 |
| 2 | 2.8688 | 2.1824 |
| 3 | 2.4948 | 9.7763 |
| 4 | 1.8300 | 27.6936 |
| 5 | 1.8525 | 26.4811 |
| 6 | 1.7230 | 142.1823 |
| 7 | 0.5671 | 3563.2944 |
| 8 | 0.5238 | 6518.7184 |
| 9 | 0.6230 | 26062.6516 |
| 10 | 0.8185 | 91591.8384 |

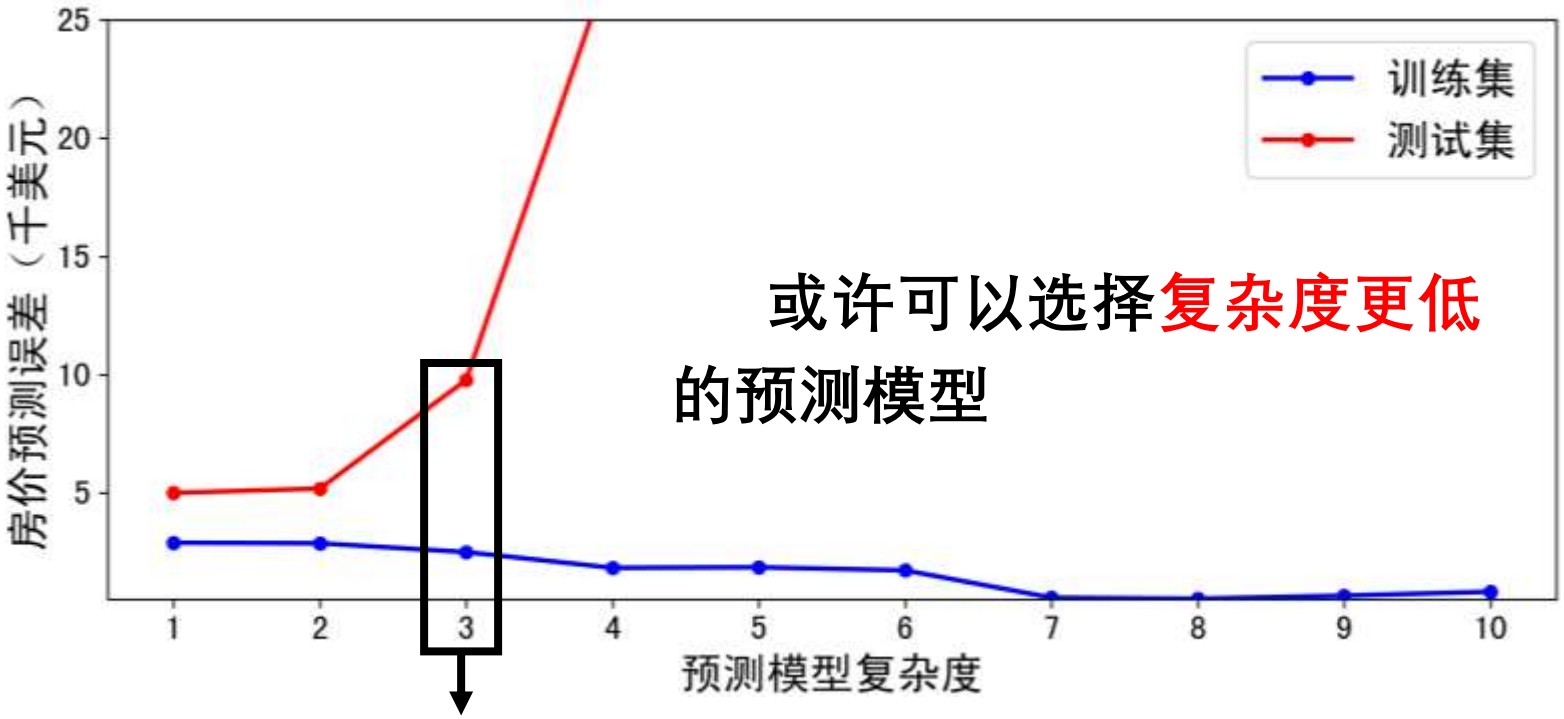


不出意外，这里应该是出意外了

训练集表现良好，测试集表现很差。

大概率发生了**过拟合**

# 发生过拟合应该怎么办？—— ② 数据增强：扩展数据体量

例： $y = b + w_1x + w_2x^2 + w_3x^3 + w_4x^4 + w_5x^5 + w_6x^6 + w_7x^7 + w_8x^8 + w_9x^9 + w_{10}x^{10}$

训练集

测试集

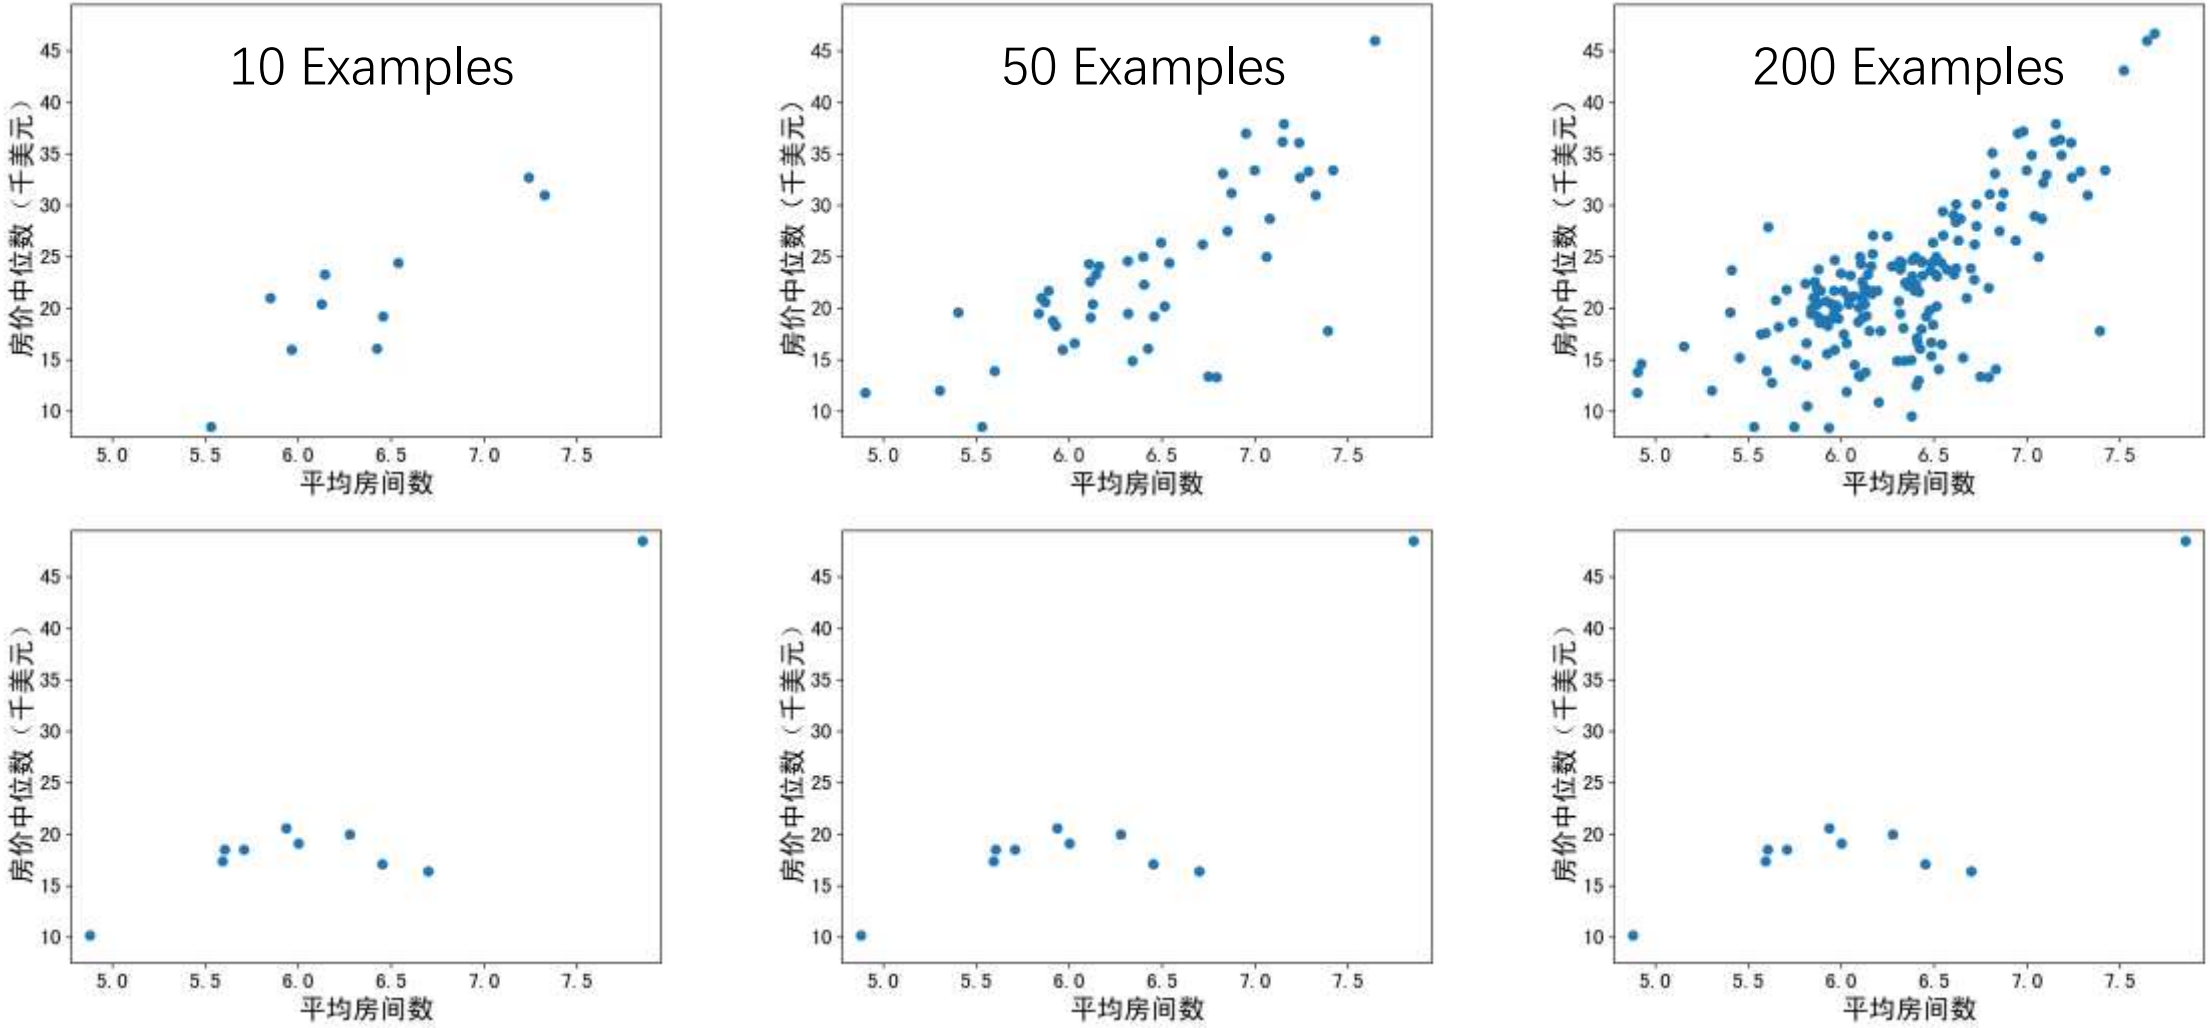

# 发生过拟合应该怎么办？—— ② 数据增强：扩展数据体量

例： $y = b + w_1x + w_2x^2 + w_3x^3 + w_4x^4 + w_5x^5 + w_6x^6 + w_7x^7 + w_8x^8 + w_9x^9 + w_{10}x^{10}$

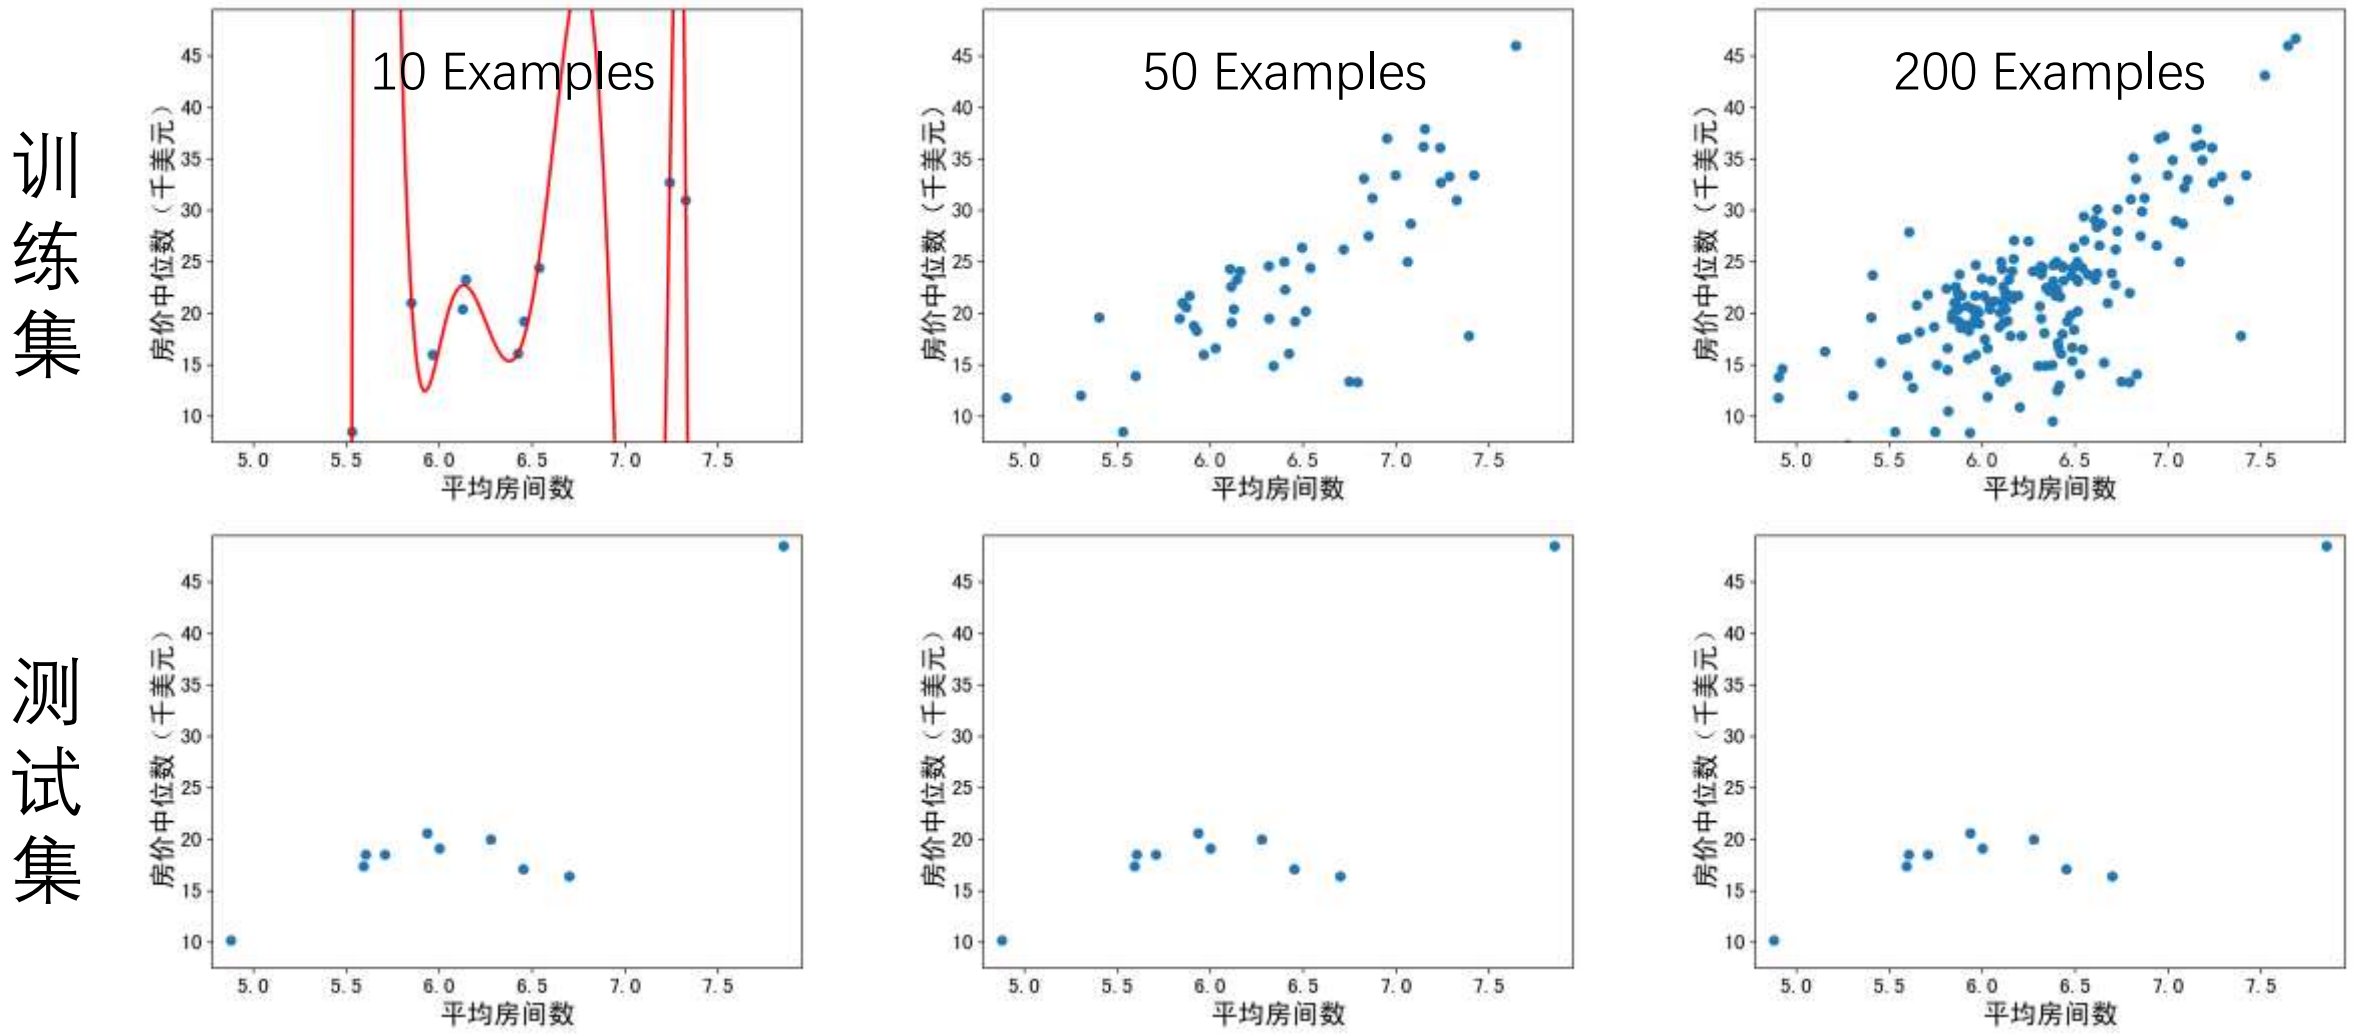

# 发生过拟合应该怎么办？—— ② 数据增强：扩展数据体量

例： $y = b + w_1x + w_2x^2 + w_3x^3 + w_4x^4 + w_5x^5 + w_6x^6 + w_7x^7 + w_8x^8 + w_9x^9 + w_{10}x^{10}$

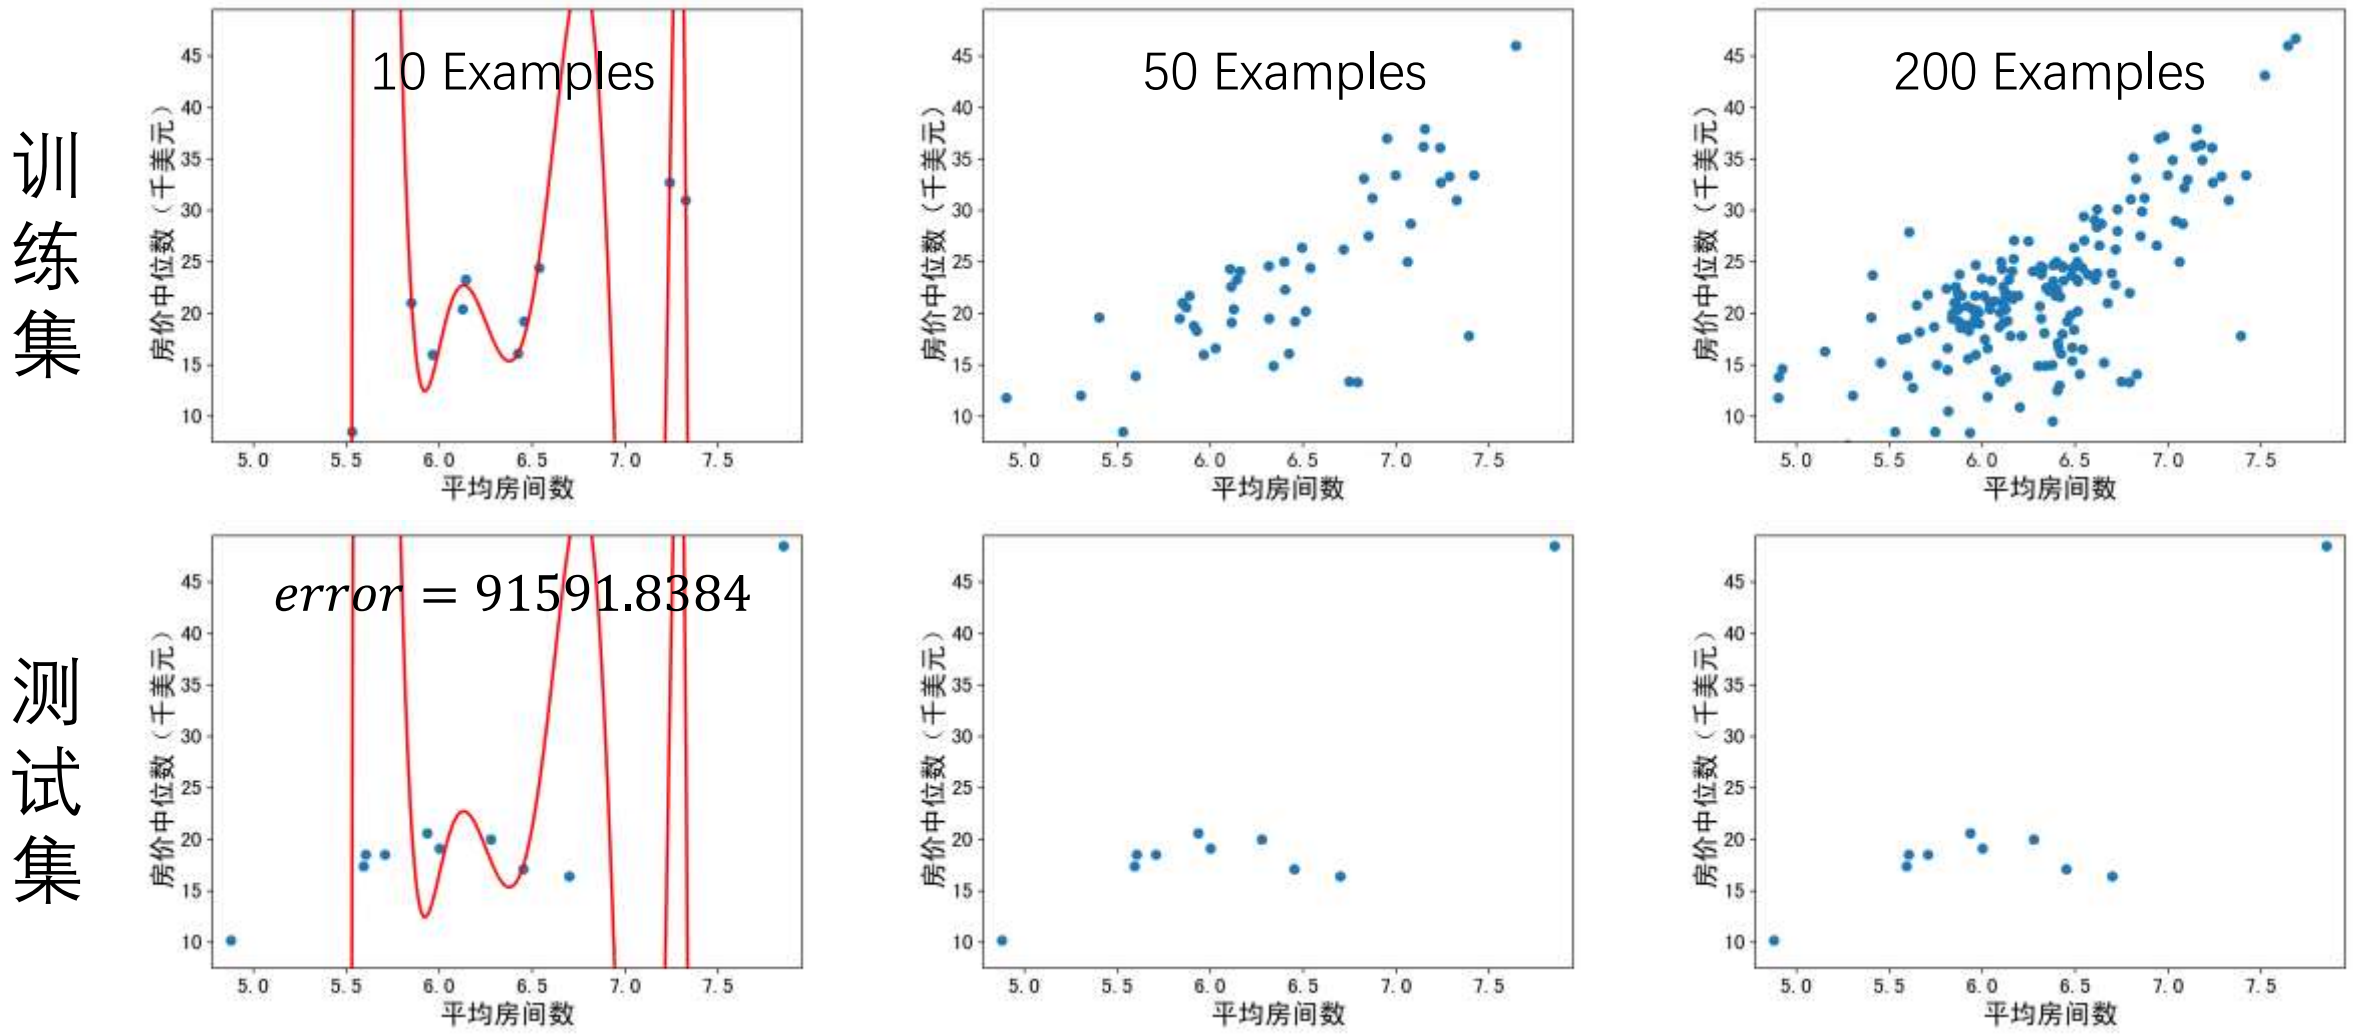

# 发生过拟合应该怎么办？—— ② 数据增强：扩展数据体量

例： $y = b + w_1x + w_2x^2 + w_3x^3 + w_4x^4 + w_5x^5 + w_6x^6 + w_7x^7 + w_8x^8 + w_9x^9 + w_{10}x^{10}$

训练集

测试集

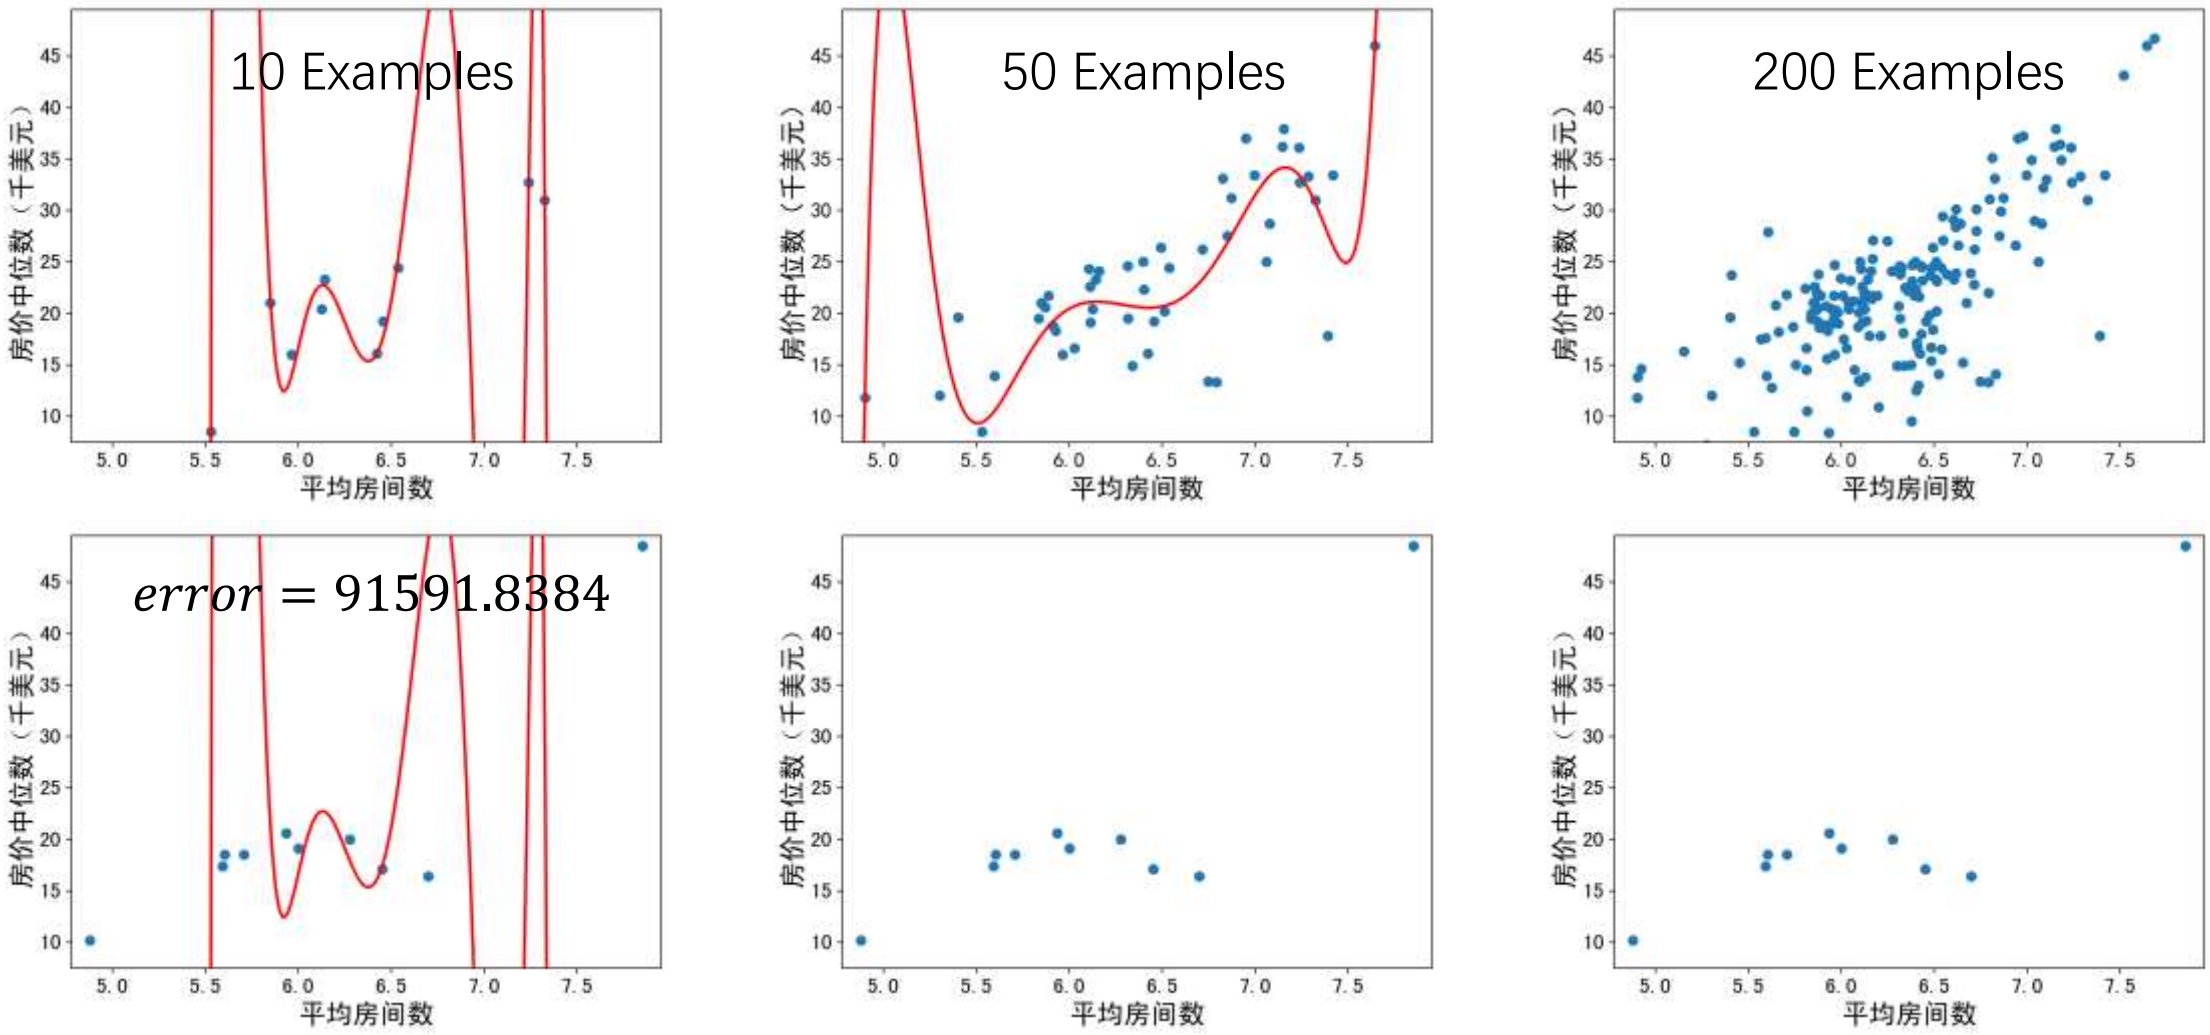

# 发生过拟合应该怎么办？—— ② 数据增强：扩展数据体量

例： $y = b + w_1x + w_2x^2 + w_3x^3 + w_4x^4 + w_5x^5 + w_6x^6 + w_7x^7 + w_8x^8 + w_9x^9 + w_{10}x^{10}$

训练集

测试集

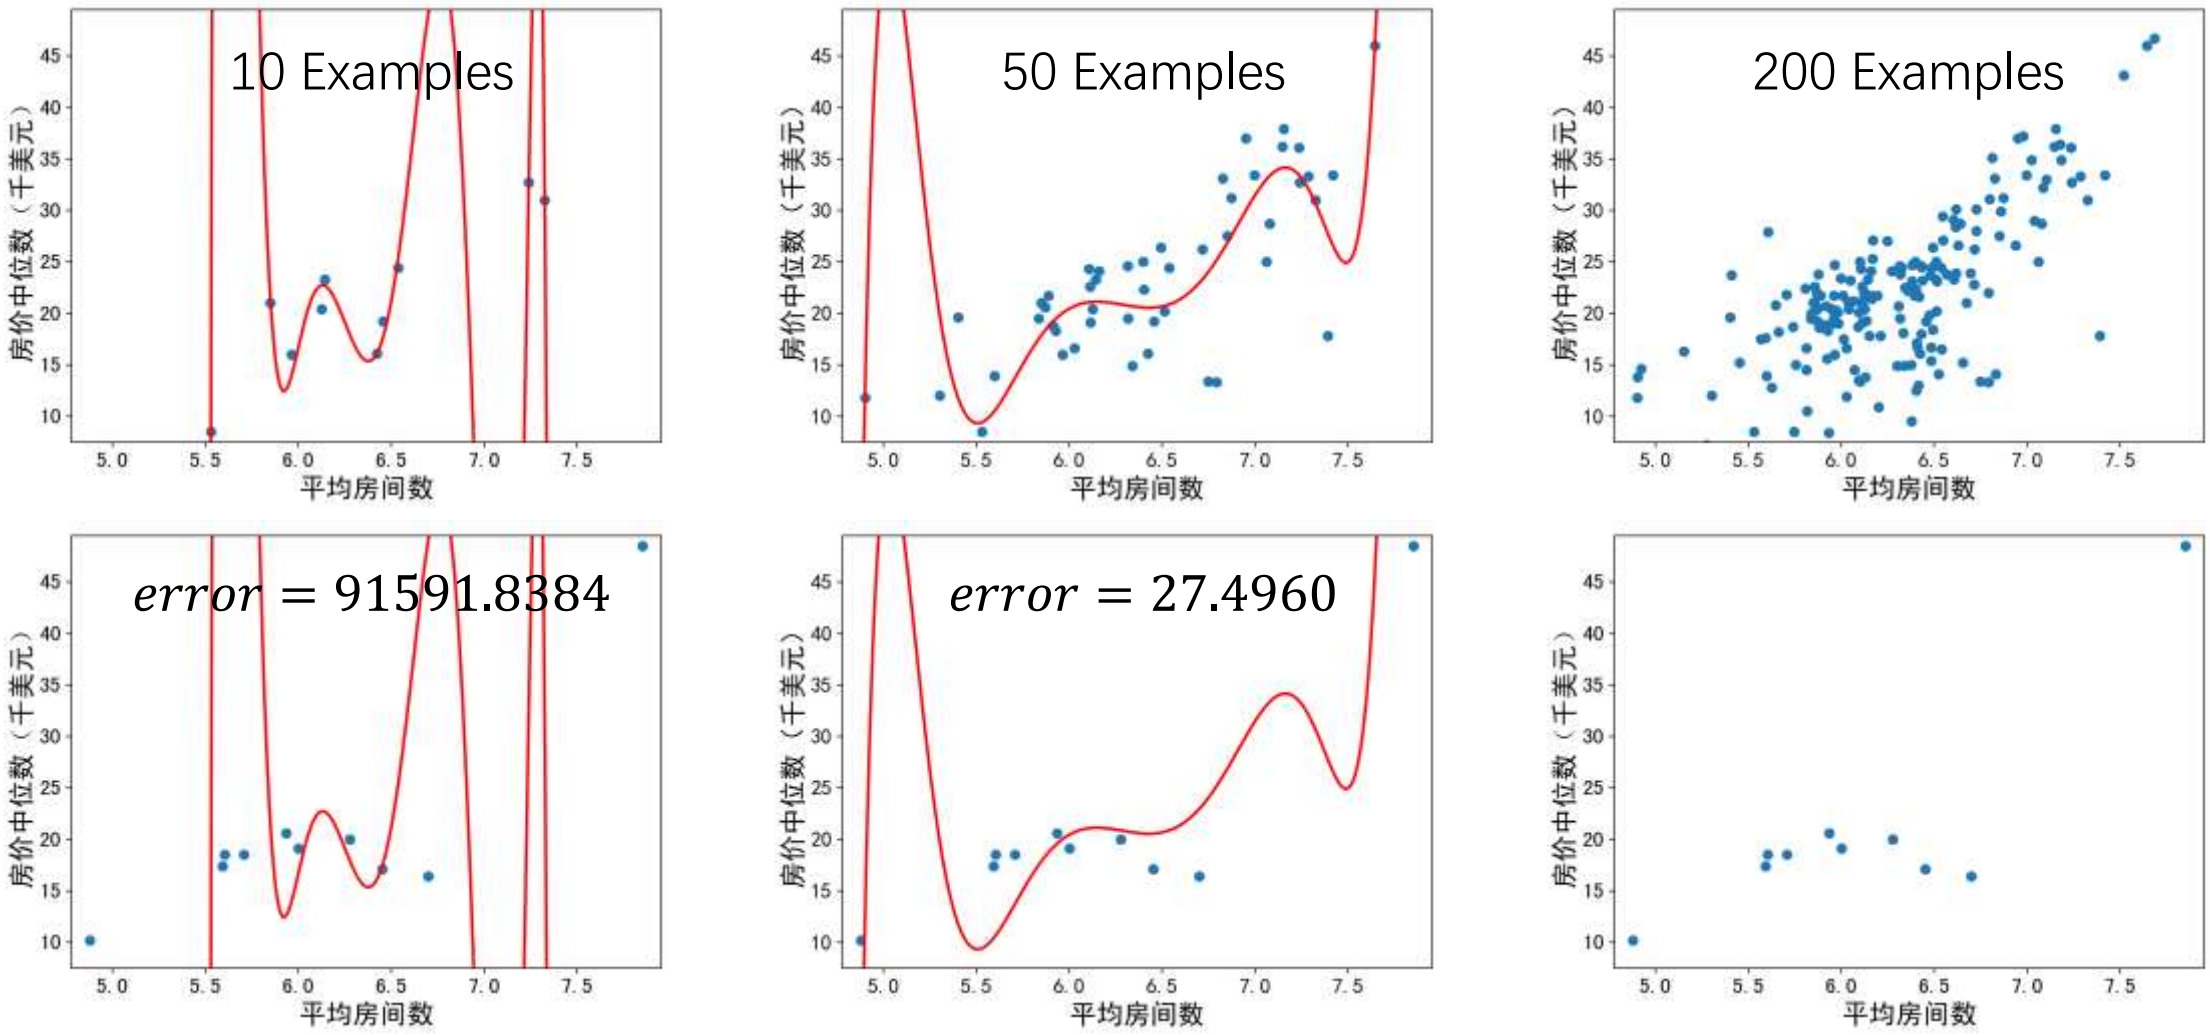

# 发生过拟合应该怎么办？—— ② 数据增强：扩展数据体量

例： $y = b + w_1x + w_2x^2 + w_3x^3 + w_4x^4 + w_5x^5 + w_6x^6 + w_7x^7 + w_8x^8 + w_9x^9 + w_{10}x^{10}$

训练集

测试集

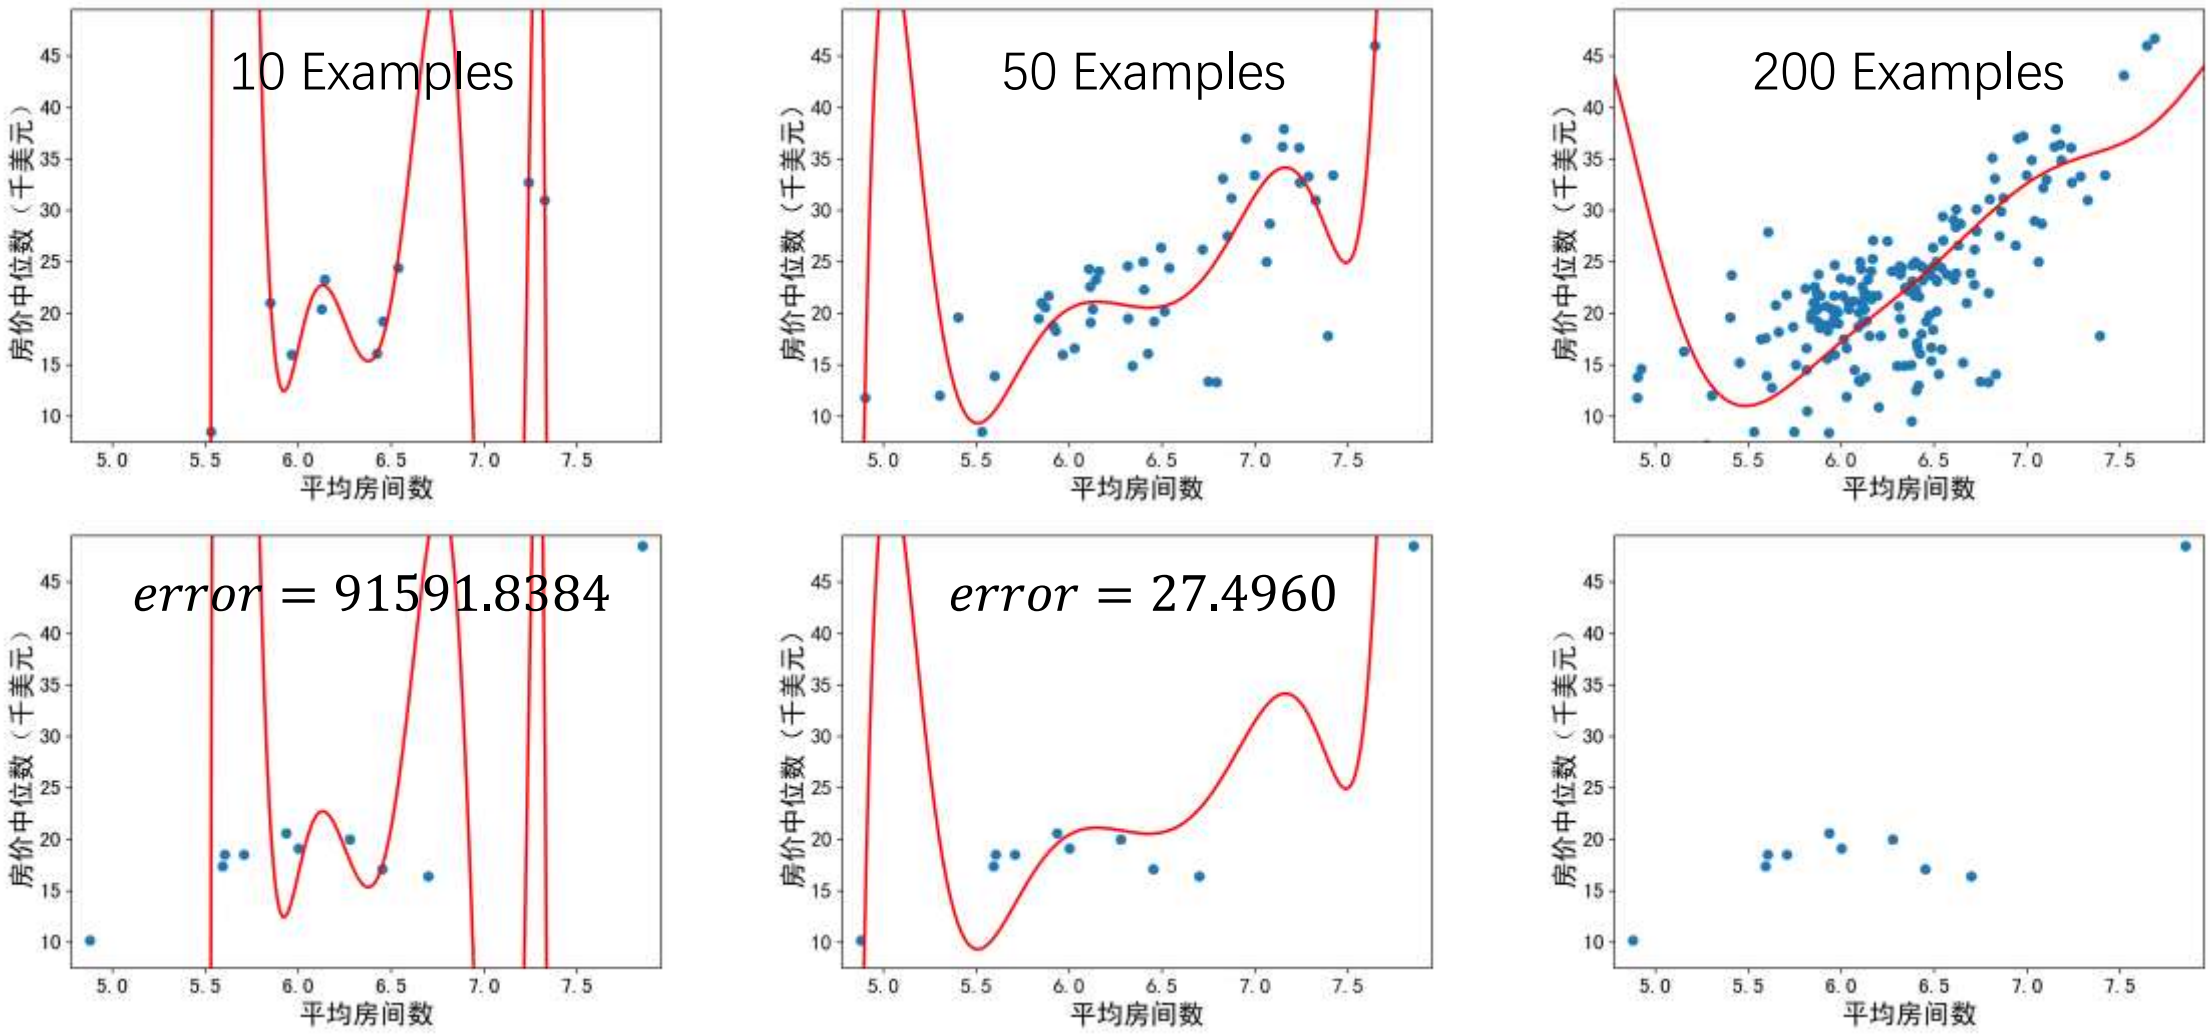

# 发生过拟合应该怎么办？—— ② 数据增强：扩展数据体量

例： $y = b + w_1x + w_2x^2 + w_3x^3 + w_4x^4 + w_5x^5 + w_6x^6 + w_7x^7 + w_8x^8 + w_9x^9 + w_{10}x^{10}$

训练集

测试集

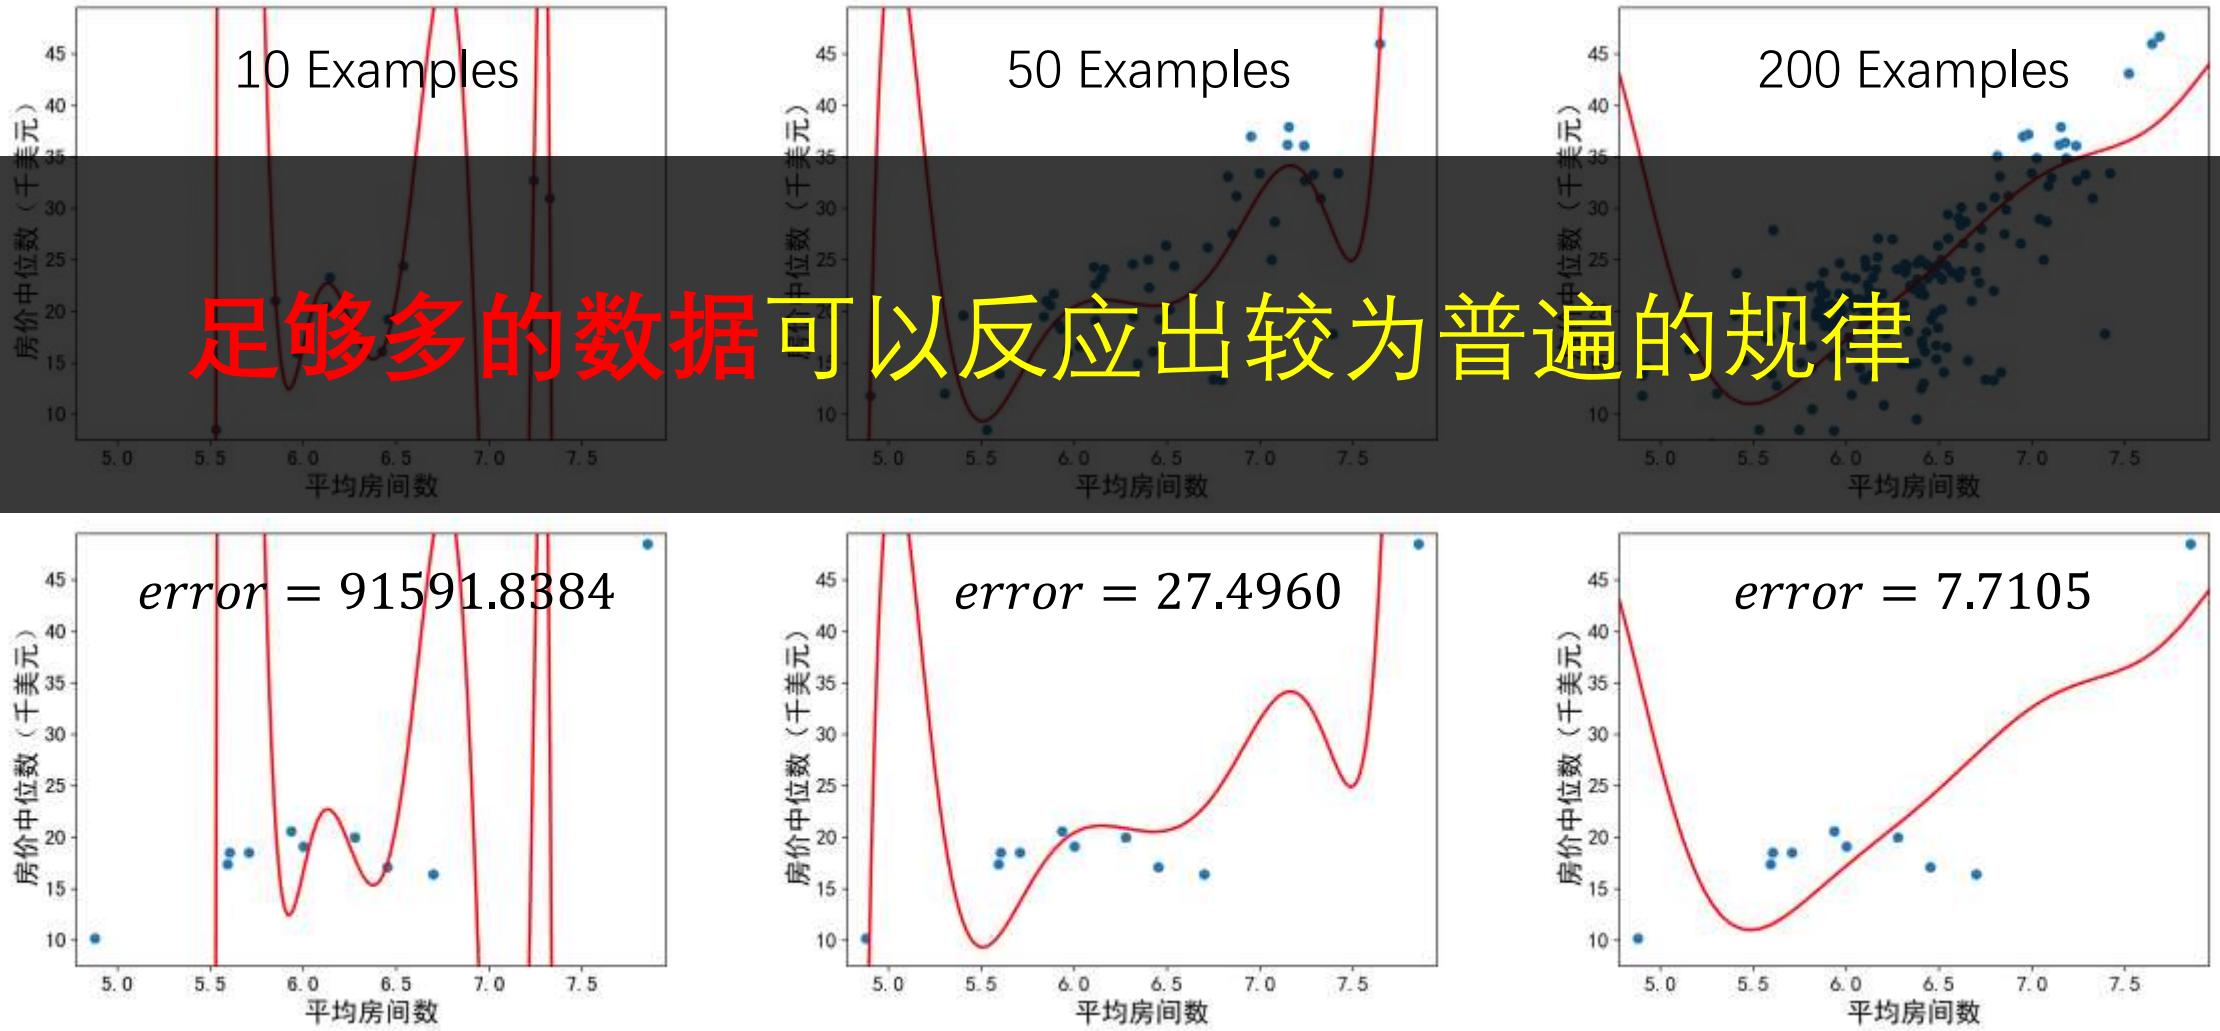


足够多的数据可以反应出较为普遍的规律

# 发生过拟合应该怎么办？—— ② 数据增强：生成虚拟数据

使用虚拟数据可以模拟多样性，避免模型过于关注细节

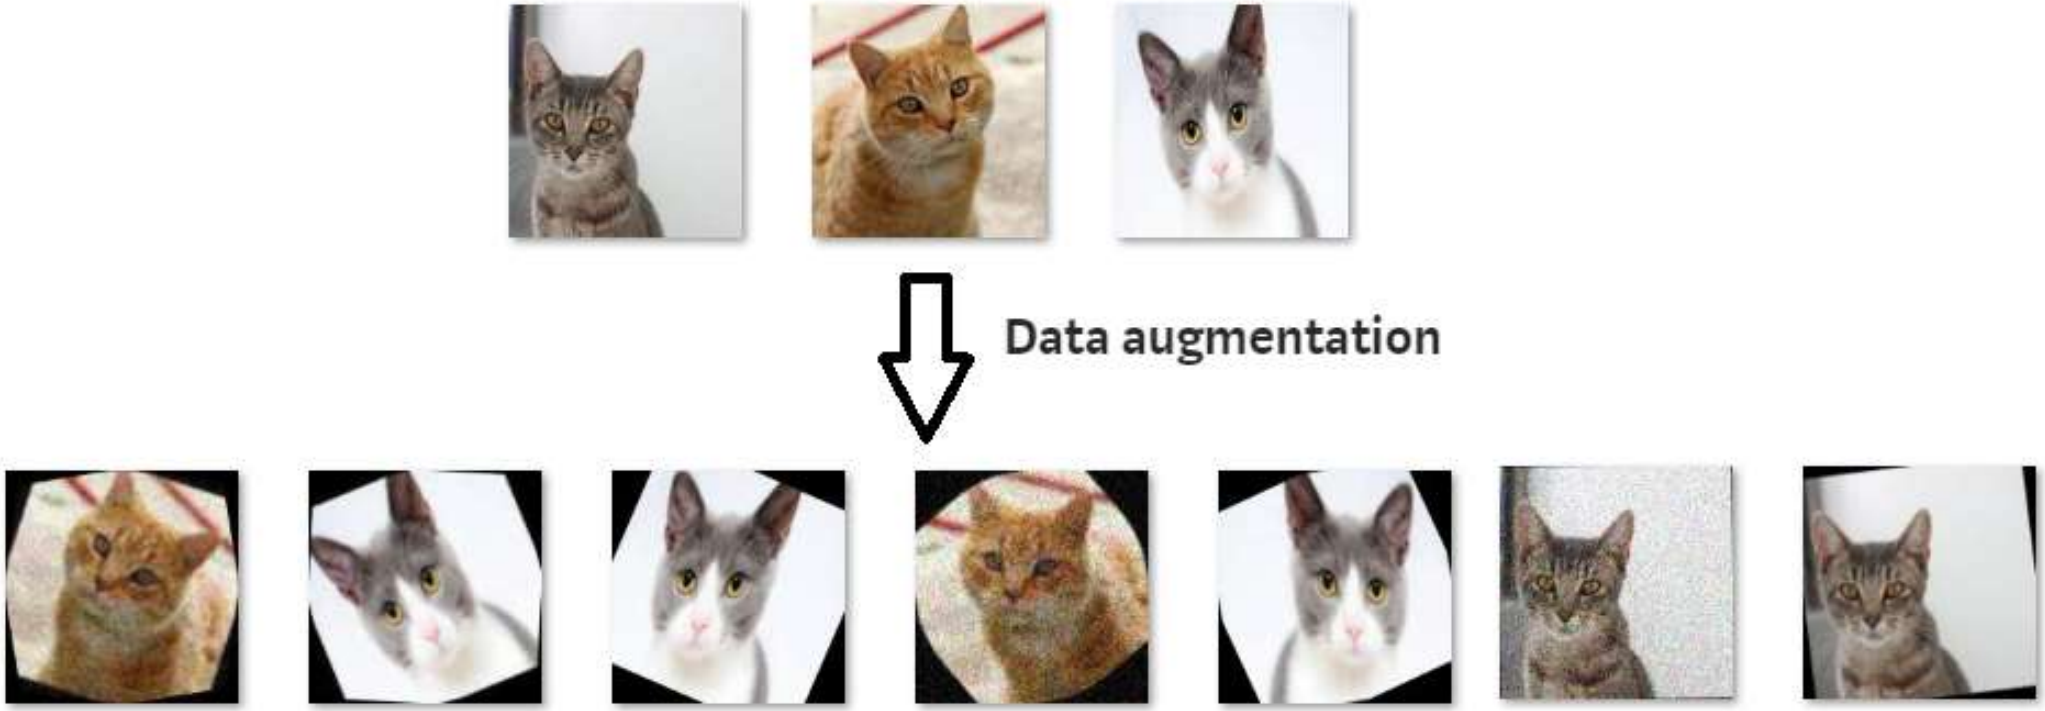

# 发生过拟合应该怎么办？—— ③ 数据增强：引入更丰富的特征

例： $y = b + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4 + w_5 x^5 + w_6 x^6 + w_7 x^7 + w_8 x^8 + w_9 x^9 + w_{10} x^{10}$

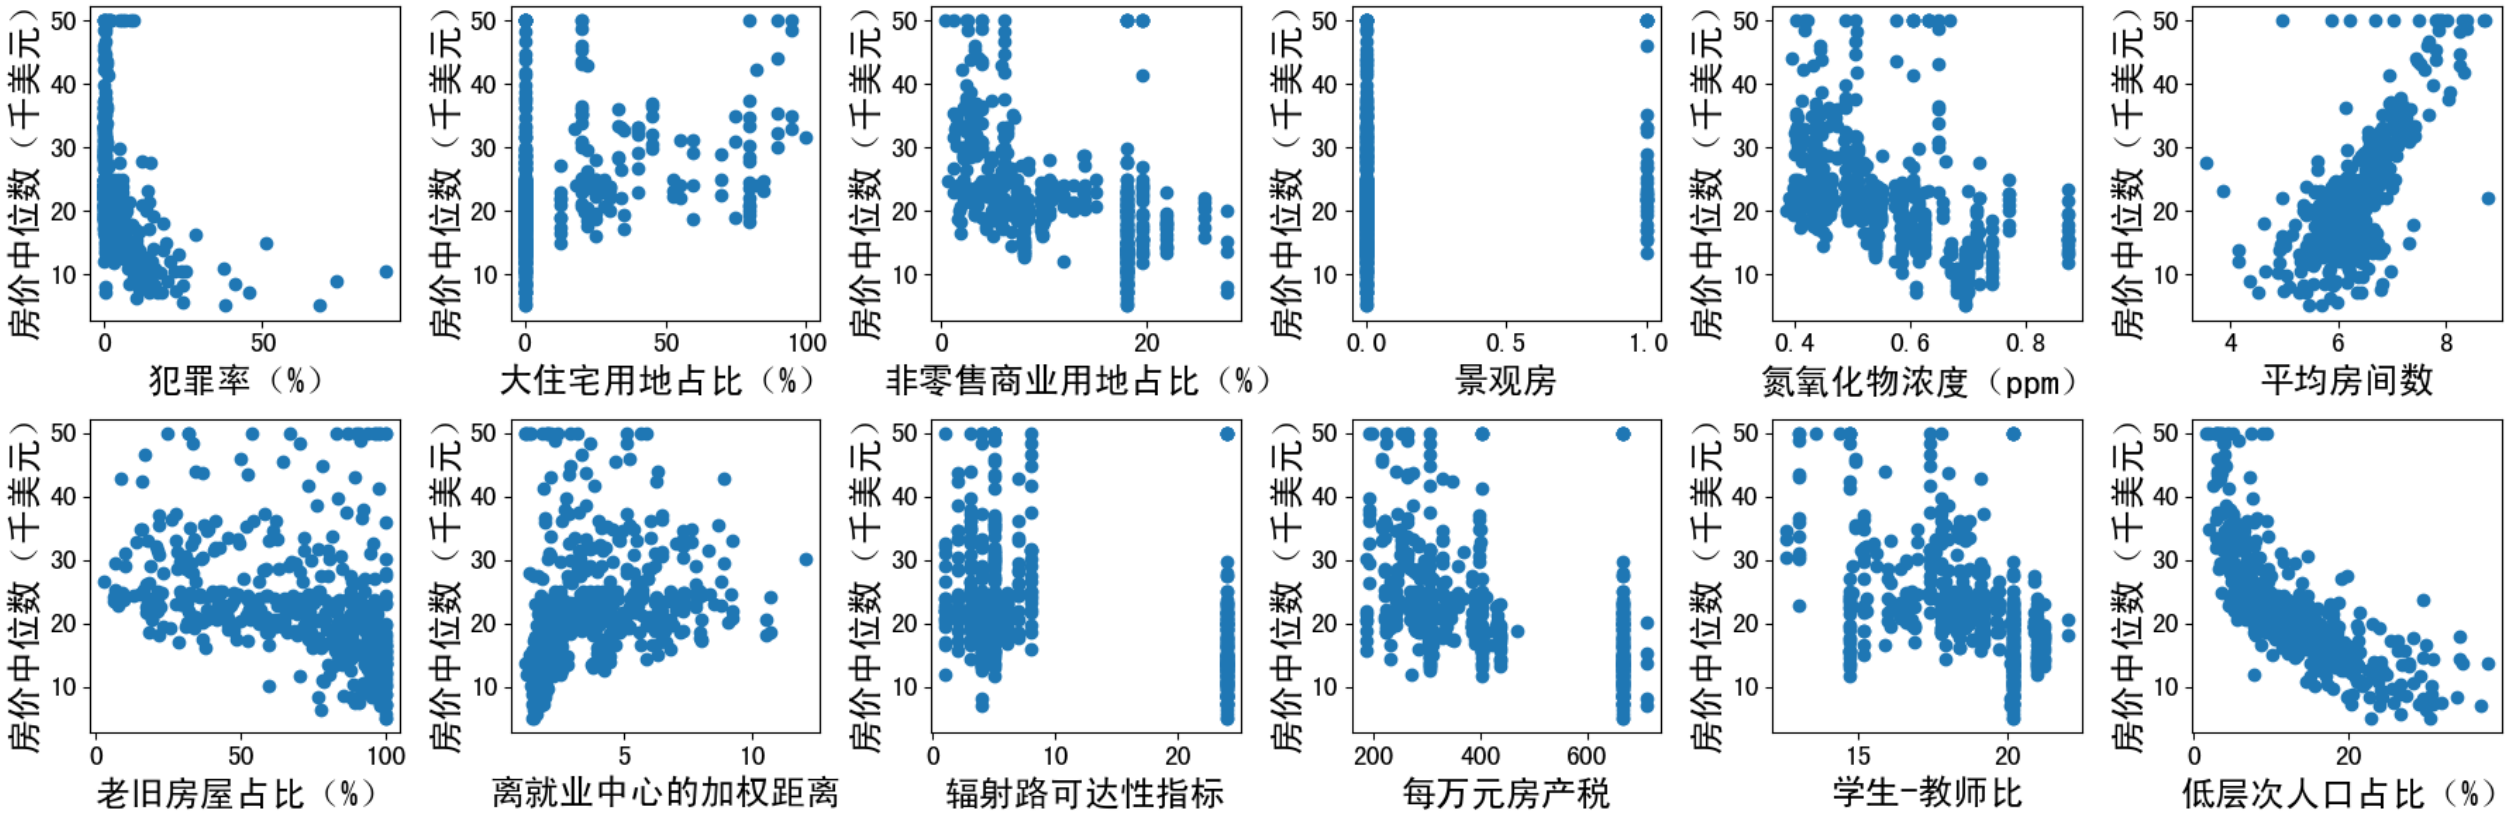

# 发生过拟合应该怎么办？—— ③ 数据增强：引入更丰富的特征

例：$y = b + w_1 x_{cr} + w_2 x_{zn} + w_3 x_{nr} + w_4 x_{ch} + w_5 x_{ppm} + w_6 x_{rn} + w_7 x_{ag} + w_8 x_{cd} + w_9 x_{ra}$
$+ w_{10} x_{rt} + w_{11} x_{st} + w_{12} x_{lr}$

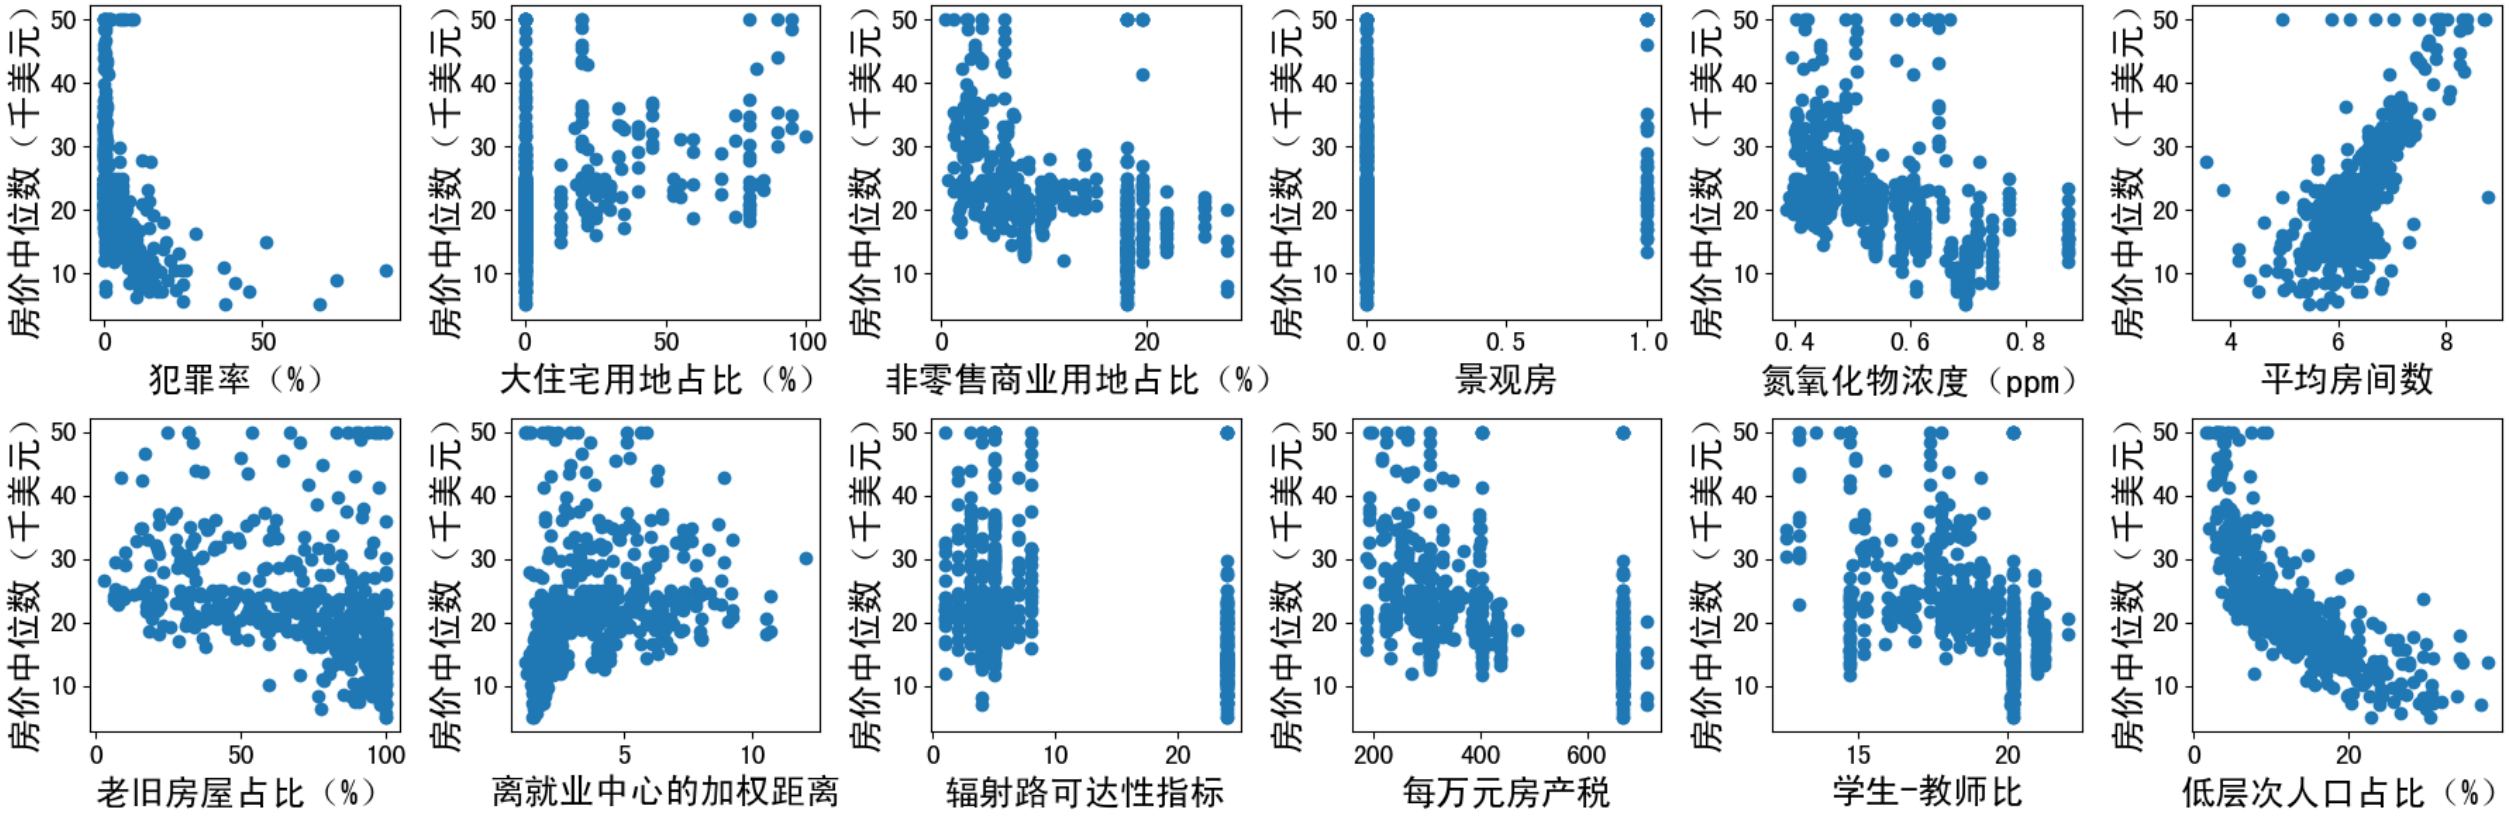

# 发生过拟合应该怎么办？—— ③ 数据增强：引入更丰富的特征

## 哪些特征更有用咧？

肉眼可辨的规律　　需要深耕多年的从业经验

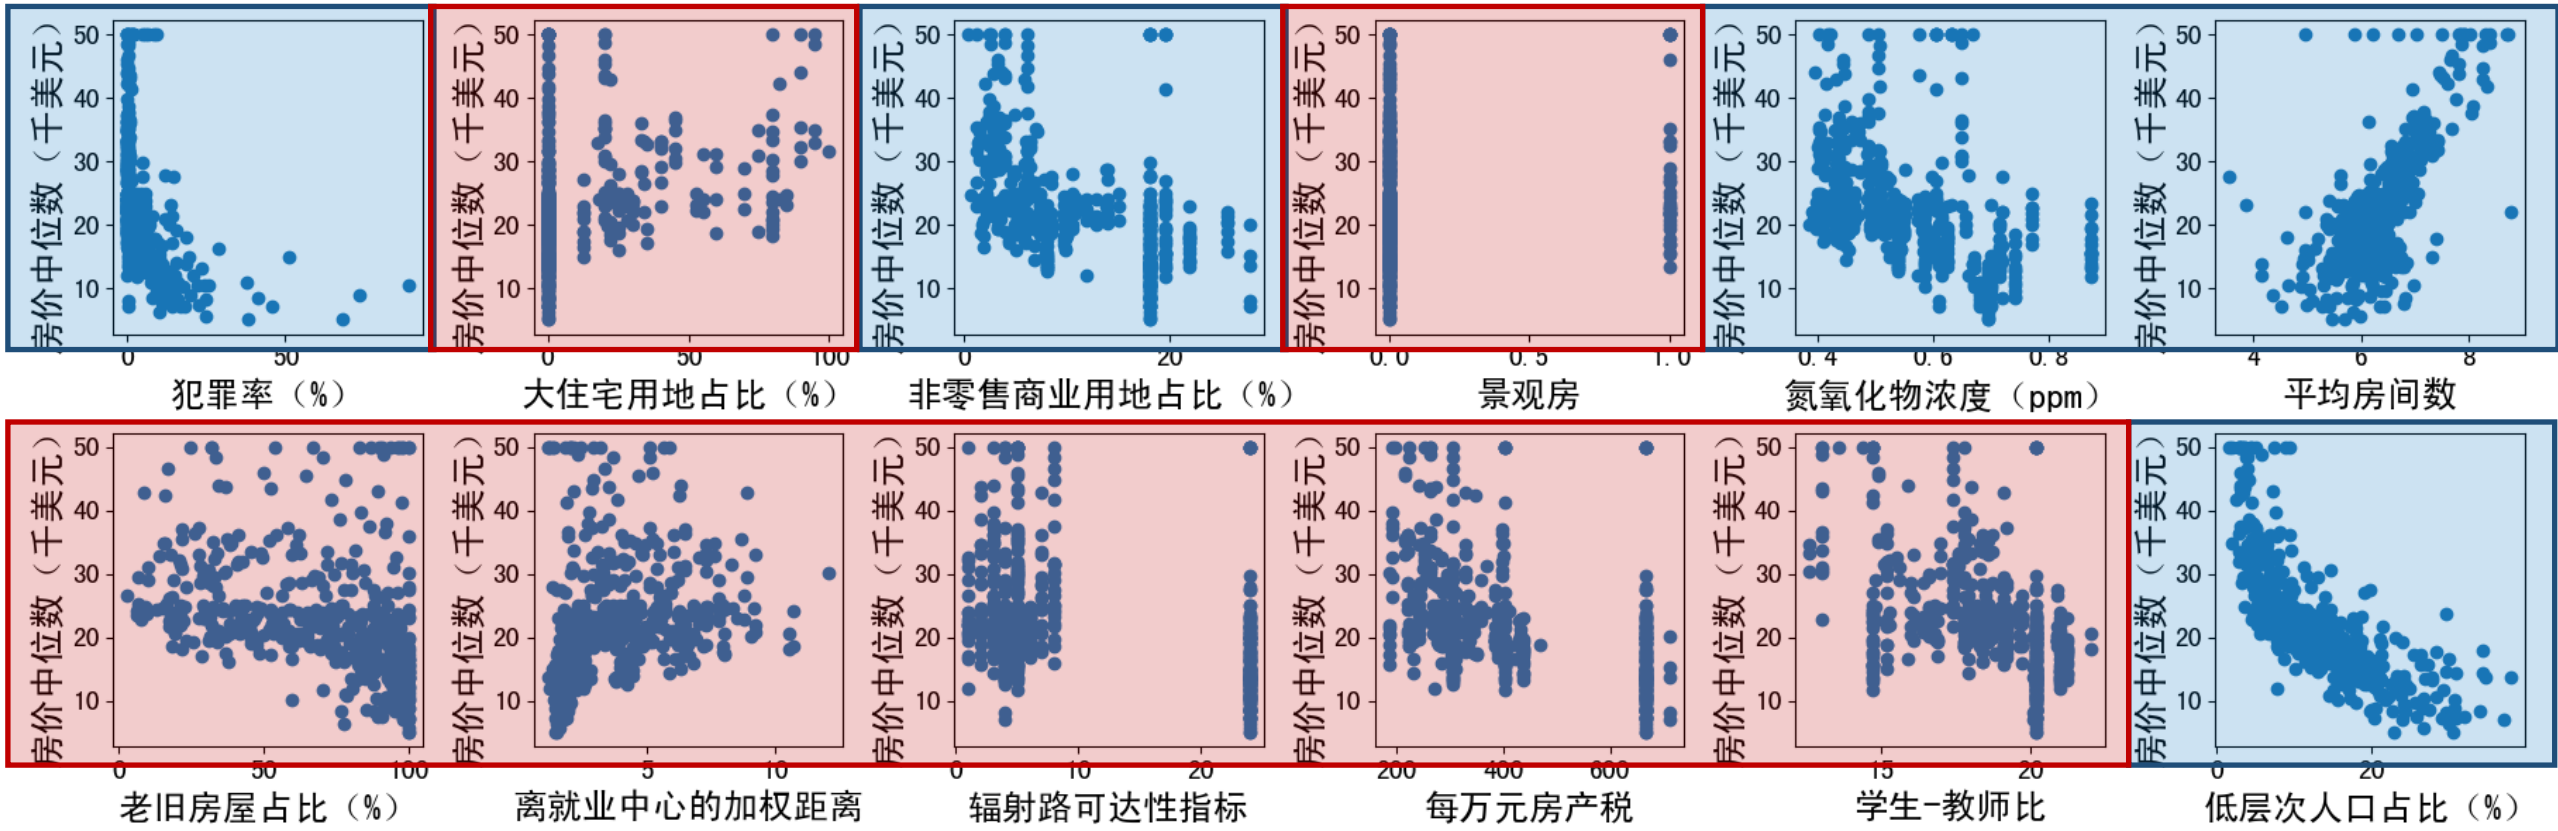

# 发生过拟合应该怎么办？—— ④ 正则化：L2范式

在Loss函数中引入一个奇怪的部分 $\eta \cdot \sum w^2$

$$\hat{y} = \sum_{i=1}^{M} w_i x_i + b$$

这样就能确定有意义的特征吗？

$$Loss = \frac{1}{2N} \sum_{k=1}^{N} (\widehat{y_k} - y_k)^2 + \boxed{\eta \cdot \sum_{i=1}^{M} w_i^2}$$

# 发生过拟合应该怎么办？—— ④ 正则化：L2范式

在Loss函数中引入一个奇怪的部分 $\eta \cdot \sum w^2$

$$\hat{y} = \sum_{i=1}^{M} w_i x_i + b$$

$$Loss = \frac{1}{2N} \sum_{k=1}^{N} (\widehat{y_k} - y_k)^2 + \eta \cdot \sum_{i=1}^{M} w_i^2$$

**需明确的关键一点：**

**不论Loss的形式如何，训练的时候只会机械寻找参数，使得Loss最低。**

# 发生过拟合应该怎么办？—— ④ 正则化：L2

在Loss函数中引入一个奇怪的部分 $\eta \cdot \sum w^2$

$$\hat{y} = \sum_{i=1}^{M} w_i x_i + b$$

$$Loss = \frac{1}{2N}\sum_{k=1}^{N}(\widehat{y_k} - y_k)^2 + \eta \cdot \sum_{i=1}^{M} w_i^2$$

预测的准确度

此部分的值降低有什么意义？

正则化是为了让参数变小，让函数变得更加

**平 滑（Smooth)**

**这两个部分的值在训练的时候都会降低**

# 发生过拟合应该怎么办？—— ④ 正则化：L2范式

在Loss函数中引入一个奇怪的部分 $\eta \cdot \sum w^2$

$$\hat{y} = \sum_{i=1}^{M} w_i x_i + b$$

为什么参数小就能使函数变得平滑？

$$Loss = \frac{1}{2N} \sum_{k=1}^{N} (\widehat{y_k} - y_k)^2 + \eta \cdot \sum_{i=1}^{M} w_i^2$$

**所谓平滑是指，预测函数的输出对于输入的变化不敏感，不容易受到噪声影响。**

# 发生过拟合应该怎么办？—— ④ 正则化：L2范式

在Loss函数中引入一个奇怪的部分 $\eta \cdot \sum w^2$

$$\hat{y} = \sum_{i=1}^{M} w_i x_i + b$$

$x_i$: $+\Delta$

$\hat{y}$: $+w_i(x_i + \Delta)$

$$Loss = \frac{1}{2N}\sum_{k=1}^{N}(\widehat{y_k} - y_k)^2 + \eta \cdot \sum_{i=1}^{M} w_i^2$$

- 如果$w_i$不够小，$\Delta$较大，$\hat{y}$变化大
- 如果$w_i$足够小，$\Delta$较大，$\hat{y}$变化小
- 如果特征$x_i$与$\hat{y}$无关，正则化可使模型学到较小的$w_i$（理想$w_i \to 0$）

⬇

**确定有意义的特征**

**所谓平滑是指，预测函数的输出对于输入的变化不敏感，不容易受到噪声影响。**

# 发生过拟合应该怎么办？—— ④ 正则化：L2范式

$\eta$ 的作用又是什么？

$$Loss = \frac{1}{2N}\sum_{k=1}^{N}(\widehat{y_k} - y_k)^2 + \eta \cdot \sum_{i=1}^{M} w_i^2$$

# 发生过拟合应该怎么办？—— ④ 正则化：L2范式

$\eta$ 的作用又是什么？ 是人工预定义的值，描述正则化倾向（重要性）

$$Loss = \boxed{\frac{1}{2N}\sum_{k=1}^{N}(\widehat{y_k} - y_k)^2} + \eta \cdot \boxed{\sum_{i=1}^{M} w_i^2}$$

预测的准确度　　平滑度

| $\eta$ | 训练误差 | 测试误差 |
|---|---|---|
| 0 | 3.2953 | 4.6701 |
| 1 | 3.3242 | 4.6683 |
| 10 | 3.3877 | 4.7461 |
| 100 | 4.8020 | 6.1936 |
| 1000 | 5.7546 | 6.9953 |
| 10000 | 6.1221 | 7.3265 |
| 100000 | 6.7197 | 7.9166 |

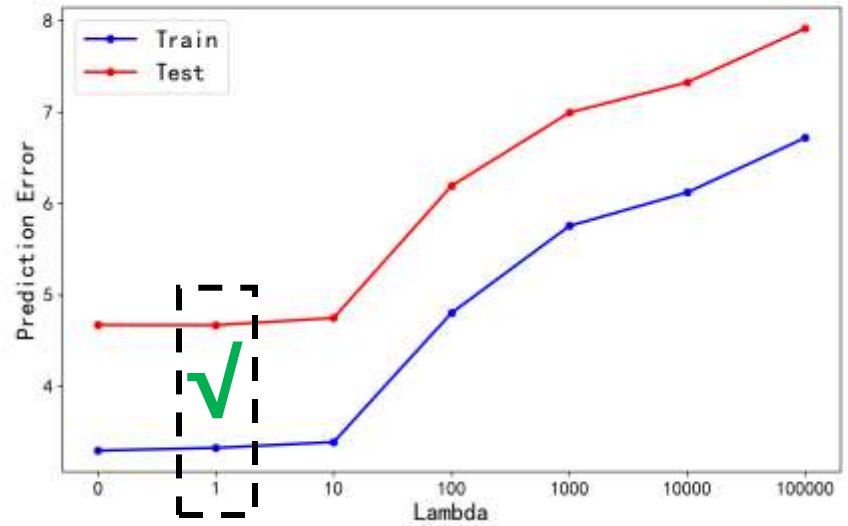


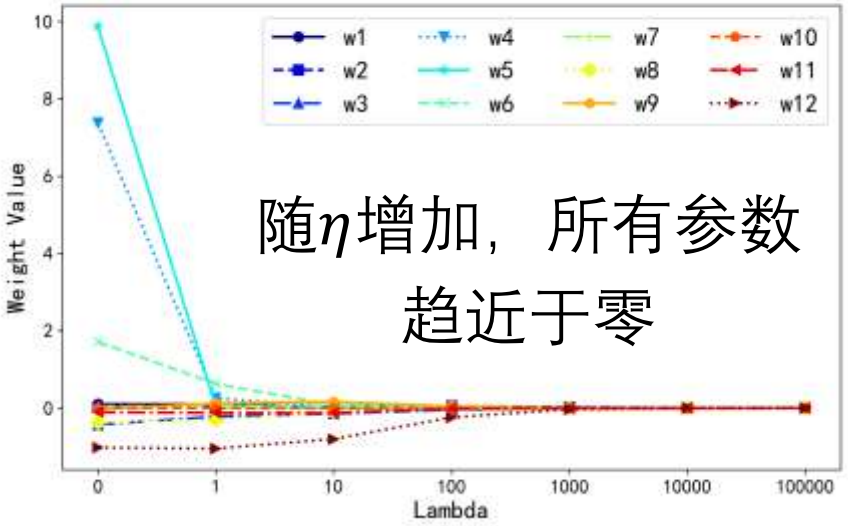


随$\eta$增加，所有参数趋近于零

# 发生过拟合应该怎么办？—— ④ 正则化：L1范式

在Loss函数中引入另一个奇怪的部分 $\eta \cdot \sum|w|$

$$Loss = \frac{1}{2N}\sum_{k=1}^{N}(\widehat{y_k} - y_k)^2 + \eta \cdot \sum_{i=1}^{M}|w_i|$$

- L1范式适用于样本较大、特征较多的场景
- 能使$w$为0，降低存储开销
- 在0处不可微分，一般使用正弦函数近似

$$\frac{d_{Loss}}{d_{w_i}} = \frac{1}{N}\sum_{k=1}^{N}(\widehat{y_k} - y_k)x_k + \eta \cdot \sin(w_i)$$

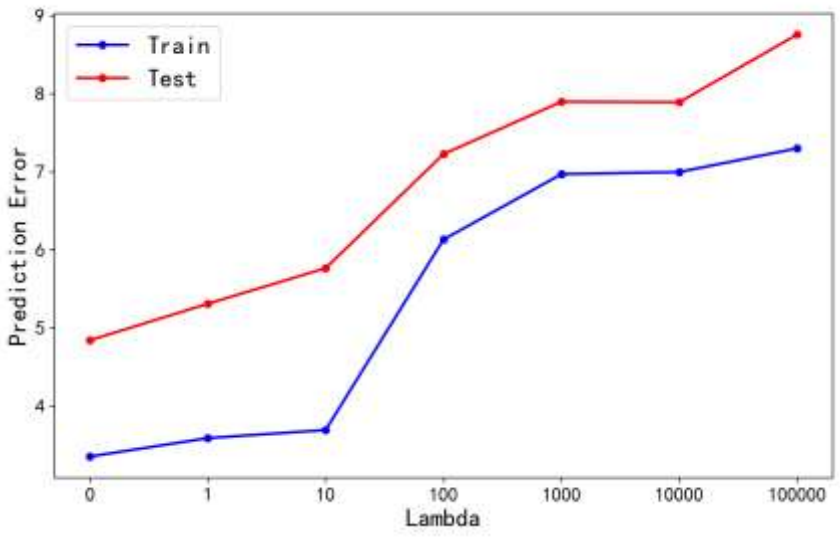


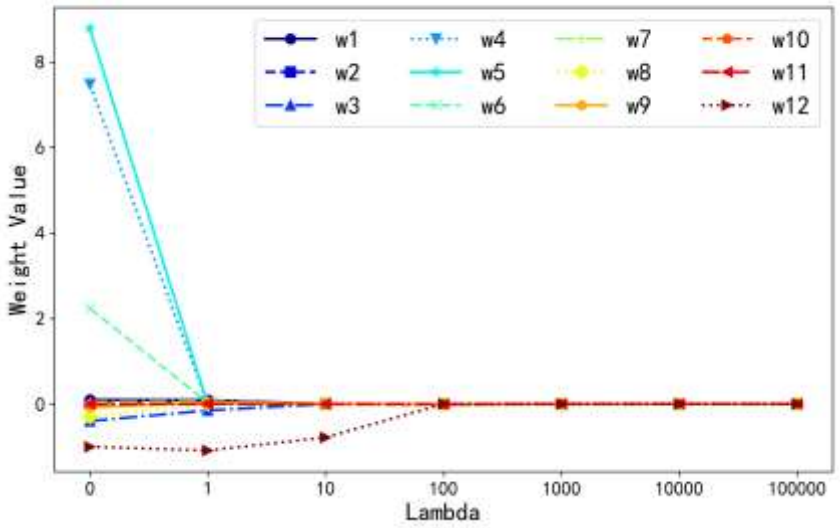

# 发生过拟合应该怎么办？—— ⑤ 交叉验证增强评估能力

**在训练时评估**
**模型泛化能力**

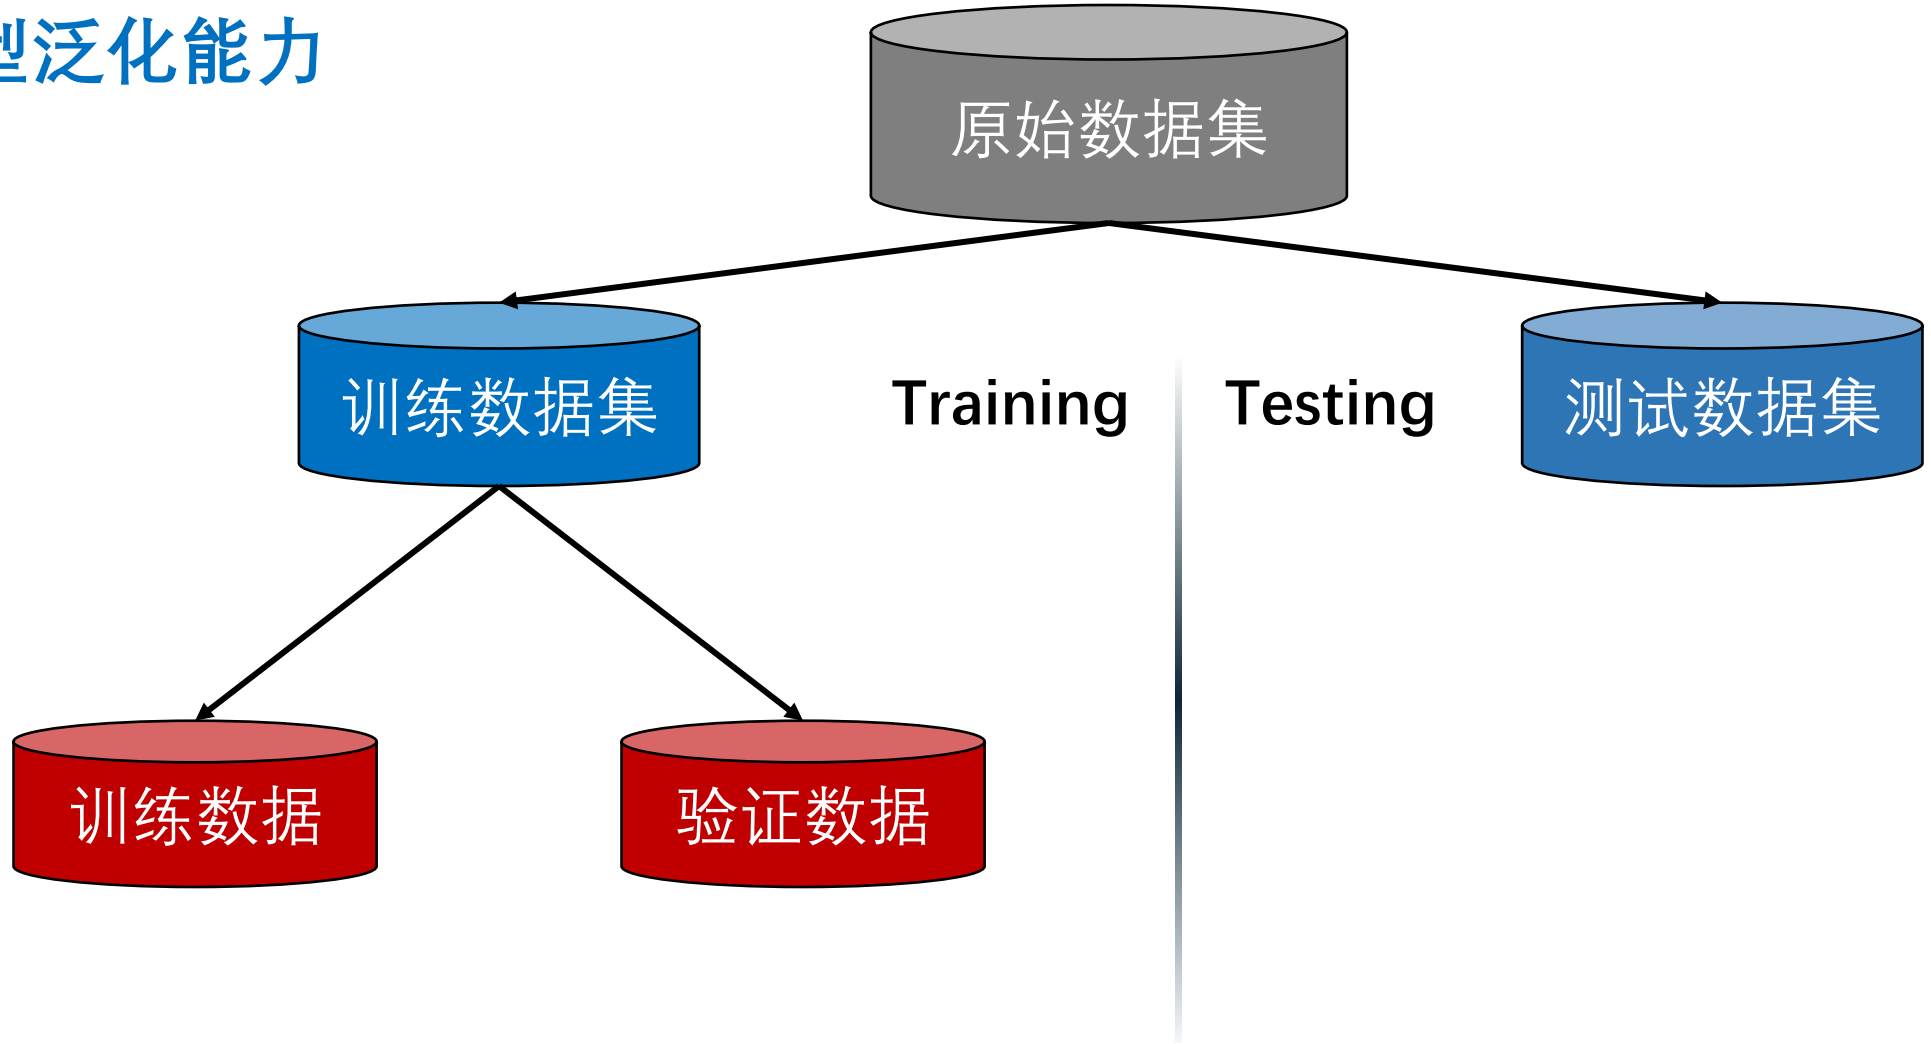

# 发生过拟合应该怎么办？—— ⑤ 交叉验证增强评估能力

**在训练时评估**
**模型泛化能力**

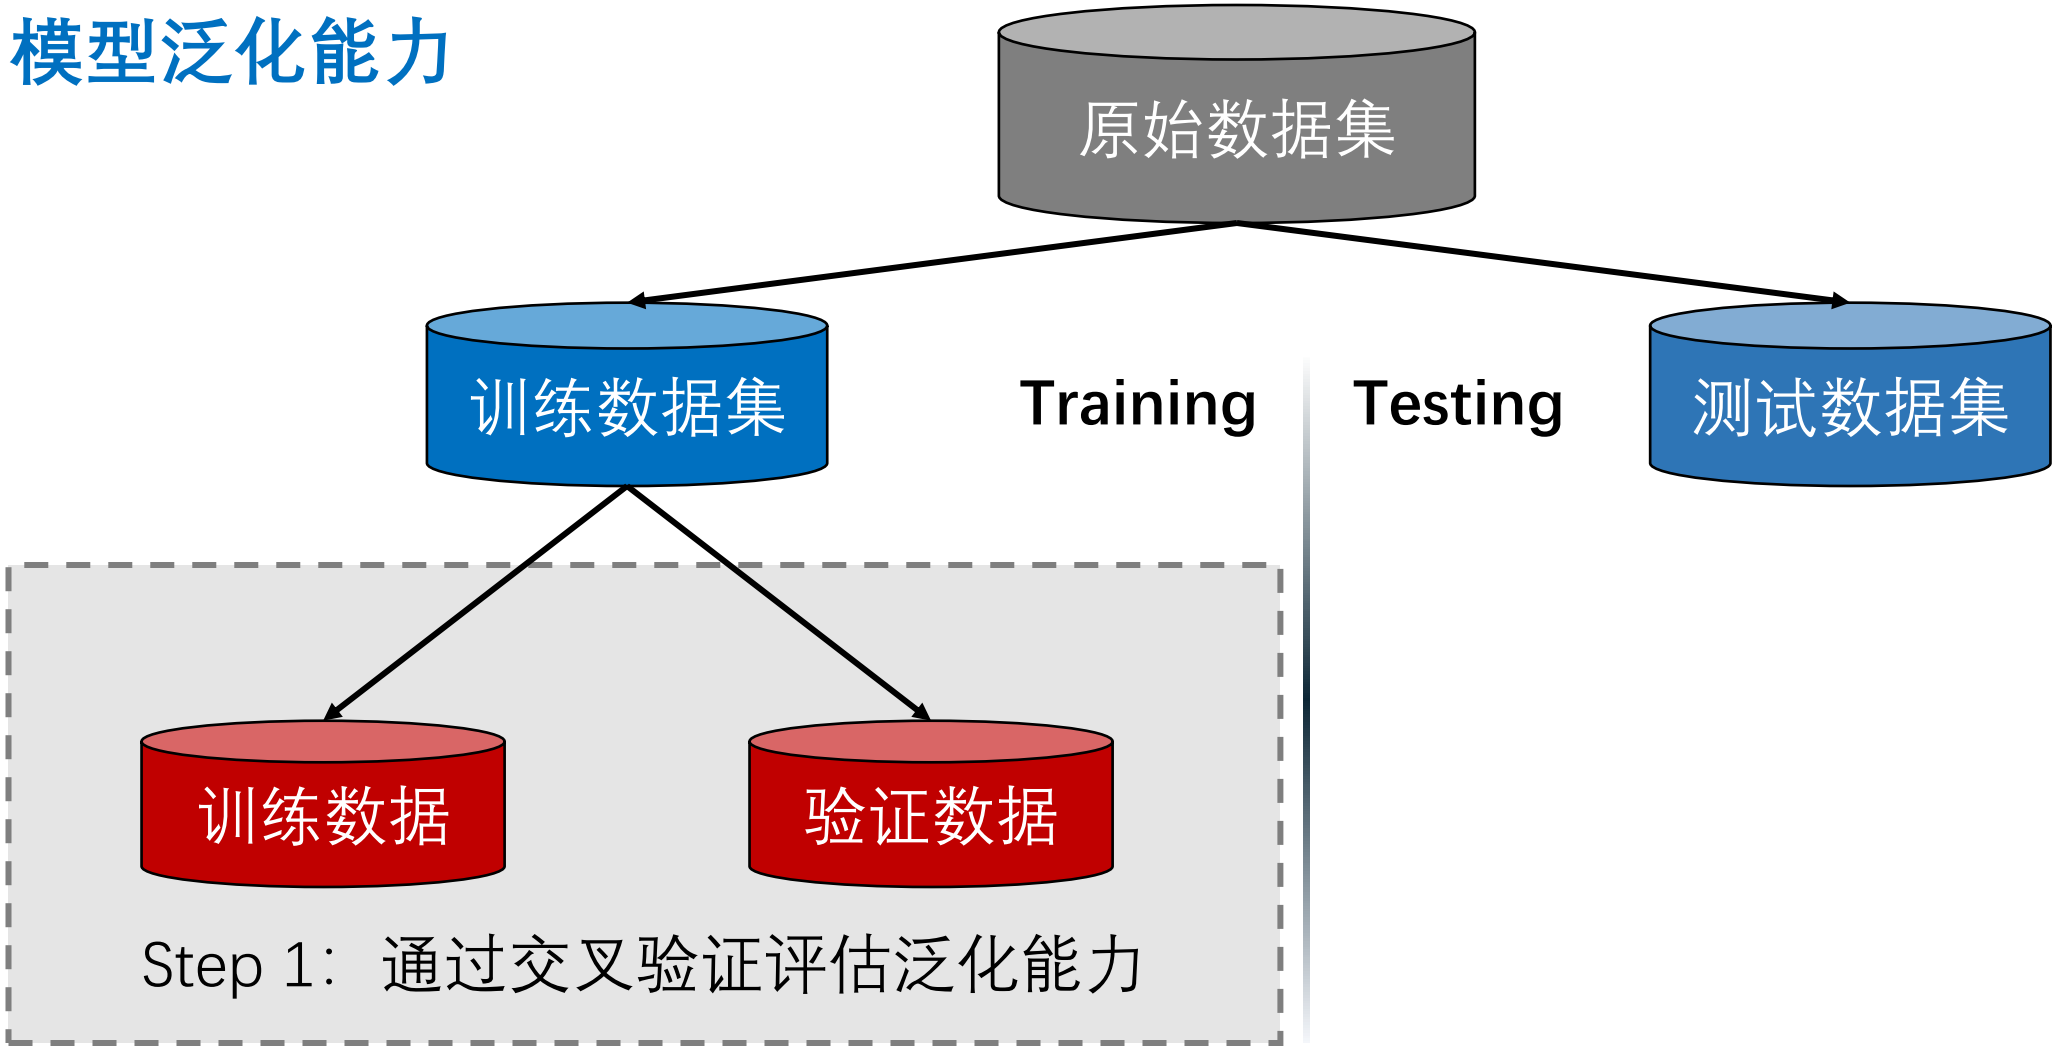

# 发生过拟合应该怎么办？—— ⑤ 交叉验证增强评估能力

**在训练时评估**
**模型泛化能力**

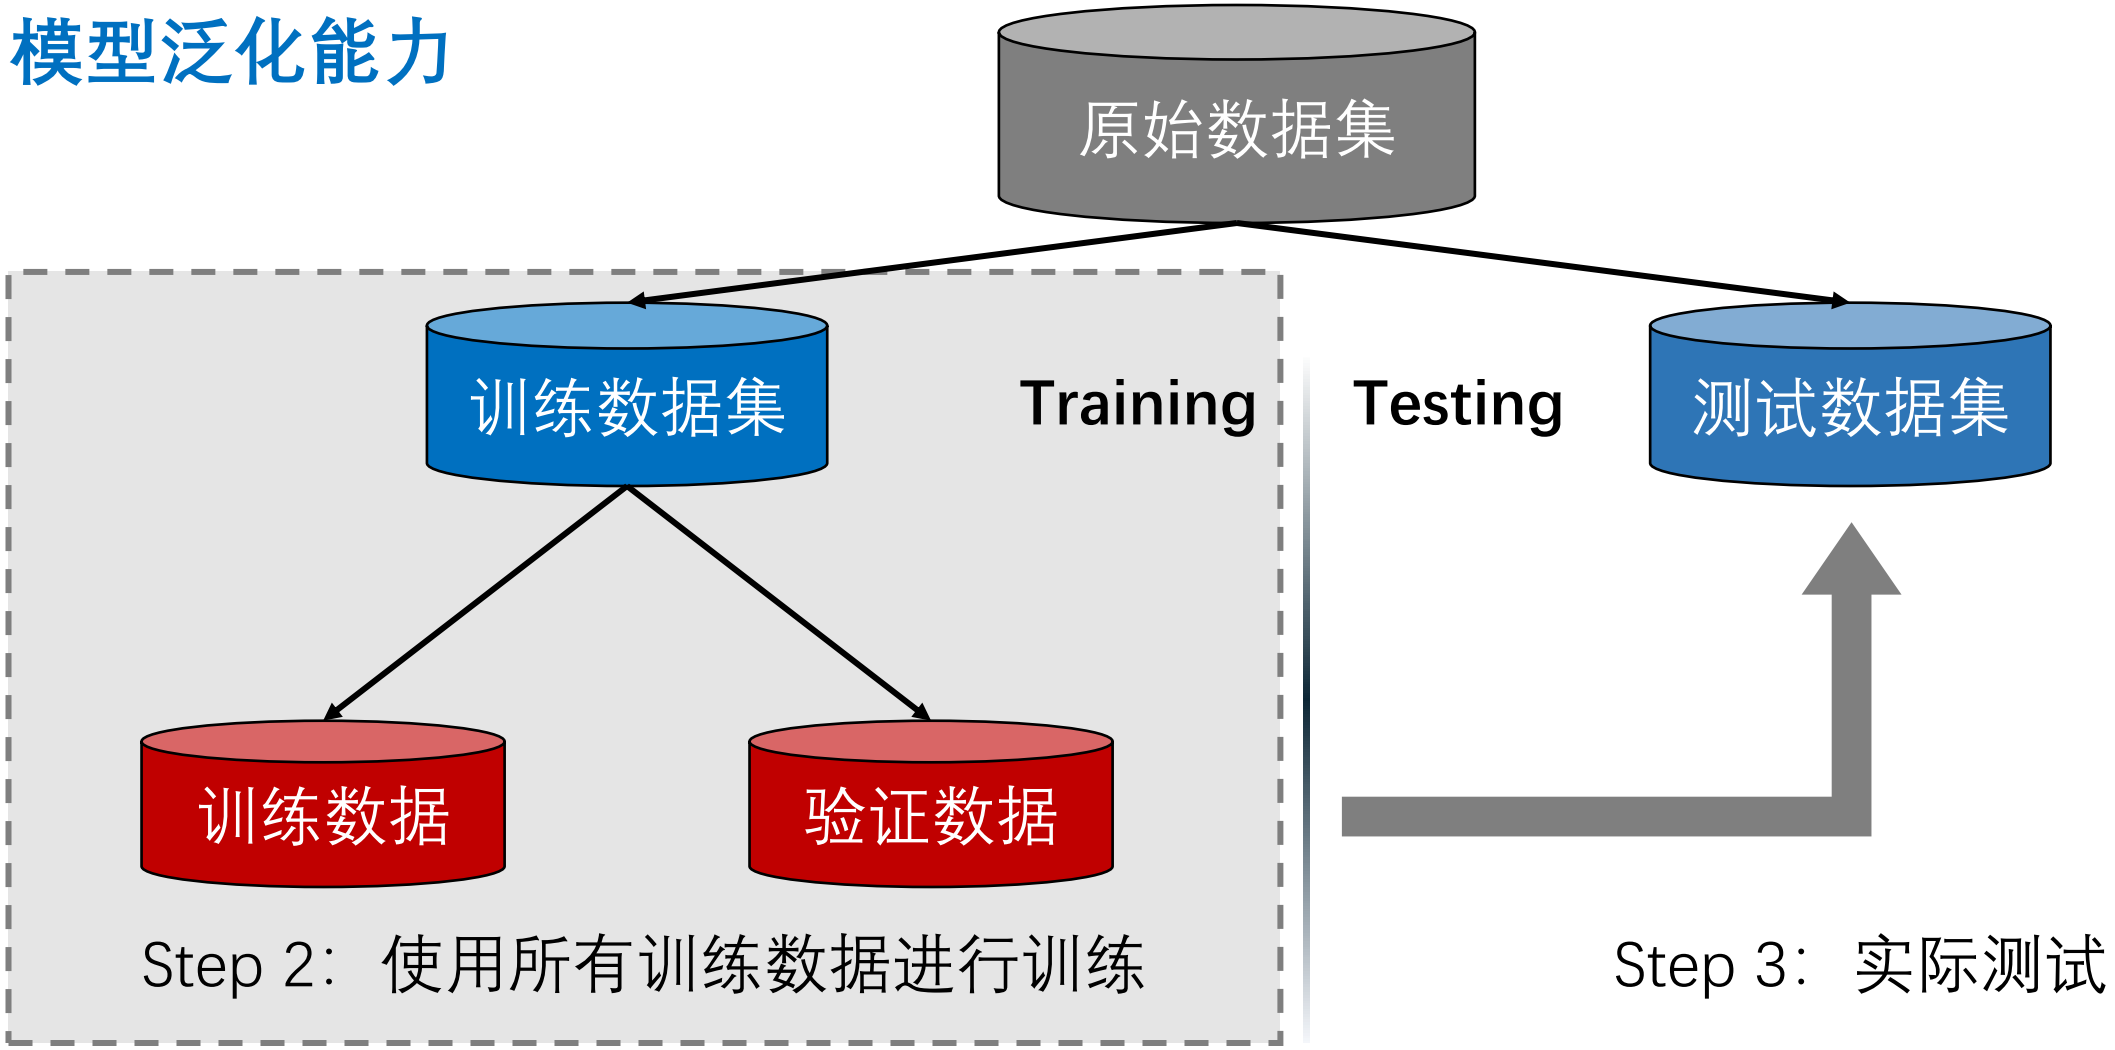

# 发生过拟合应该怎么办？—— ⑤ 交叉验证增强评估能力

## 常用的交叉验证方法有哪些咧？

- 留出法 Leave-P-Out

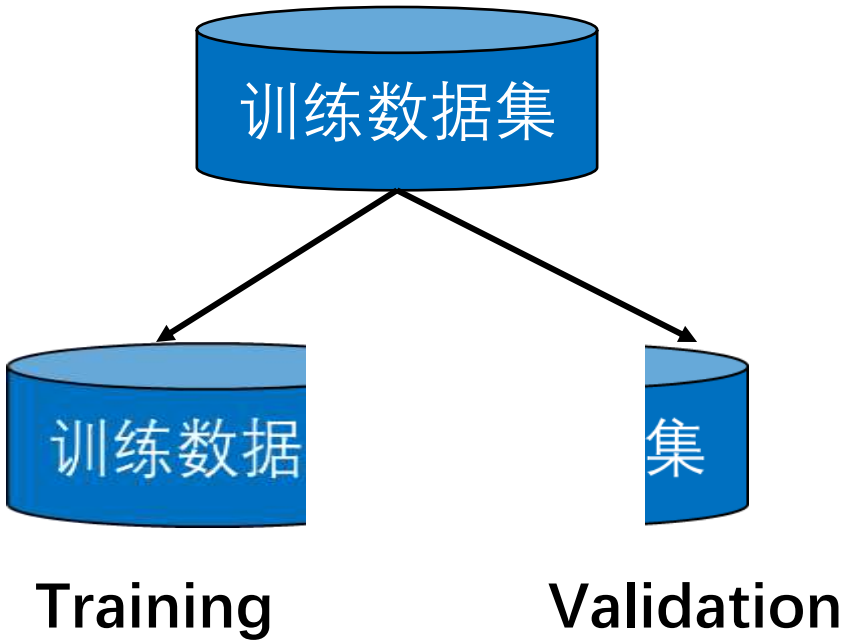

# 发生过拟合应该怎么办？—— ⑤ 交叉验证增强评估能力

## 常用的交叉验证方法有哪些咧？

- 留出法 Leave-P-Out
- K折法 K-fold: k = 3

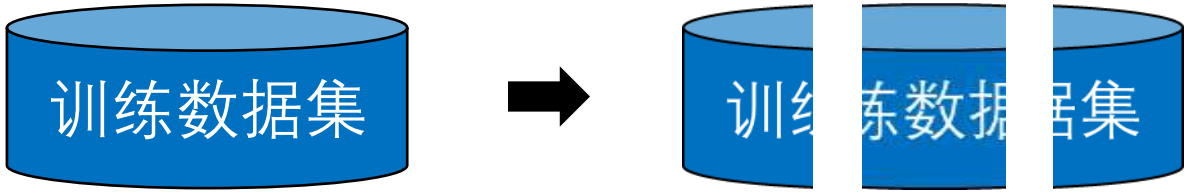


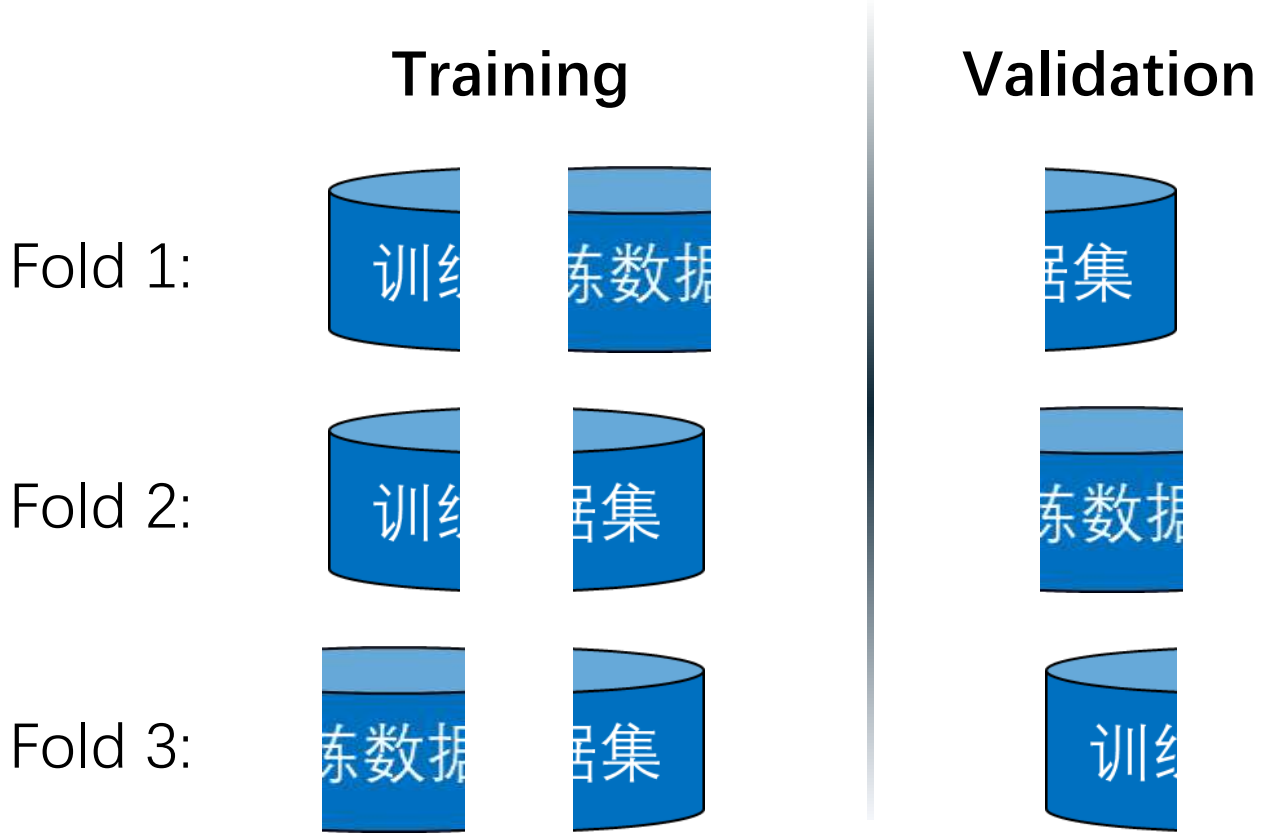

# 发生过拟合应该怎么办？—— ⑤ 交叉验证增强评估能力

## 常用的交叉验证方法有哪些咧？

- 留出法 Leave-P-Out
- K折法 K-fold: k = 3
- 自助法 Boostrapping

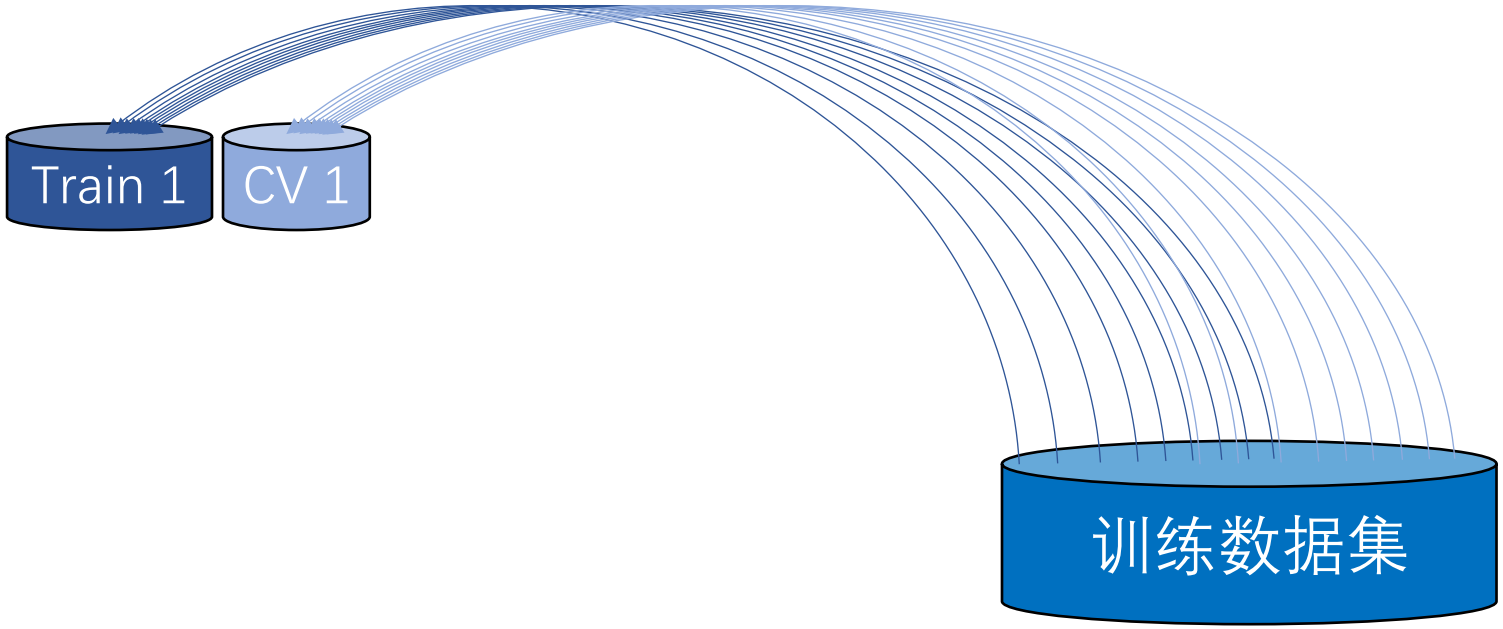

# 发生过拟合应该怎么办？—— ⑤ 交叉验证增强评估能力

## 常用的交叉验证方法有哪些咧？

- 留出法 Leave-P-Out
- K折法 K-fold: k = 3
- 自助法 Boostrapping

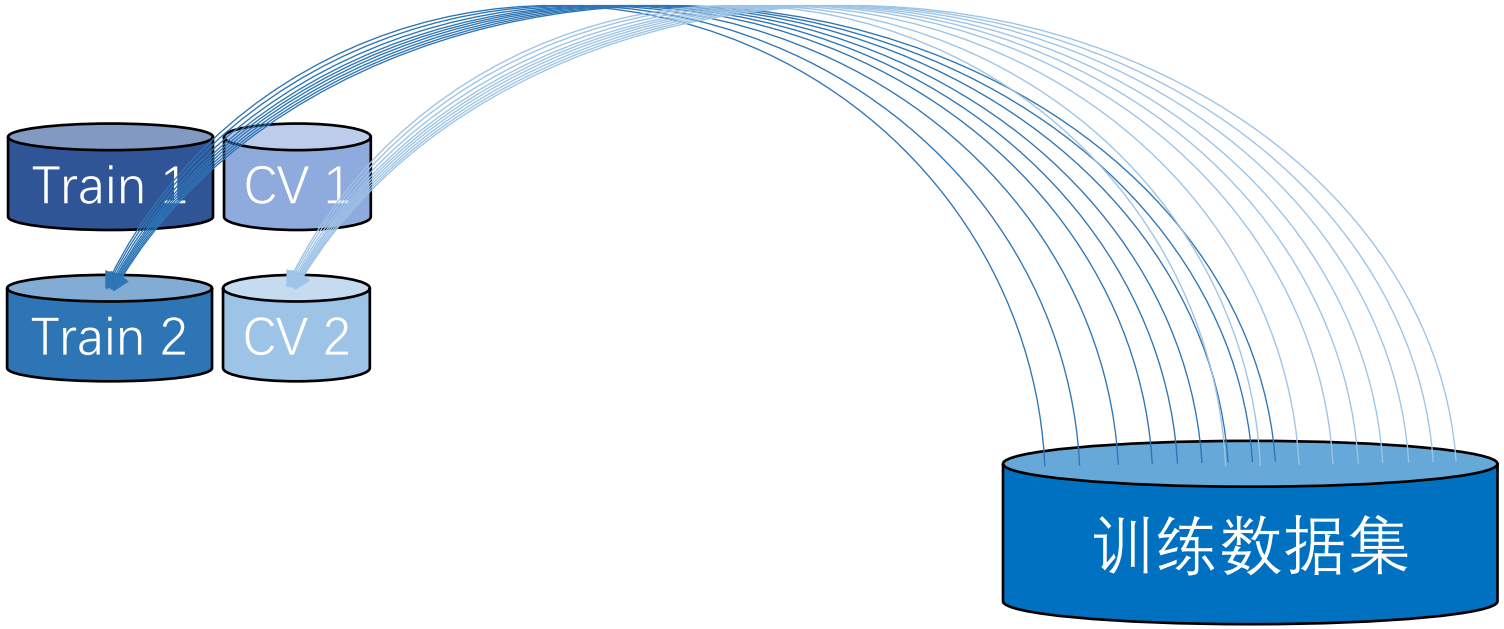

# 发生过拟合应该怎么办？—— ⑤ 交叉验证增强评估能力

## 常用的交叉验证方法有哪些咧？

- 留出法 Leave-P-Out
- K折法 K-fold: k = 3
- 自助法 Boostrapping

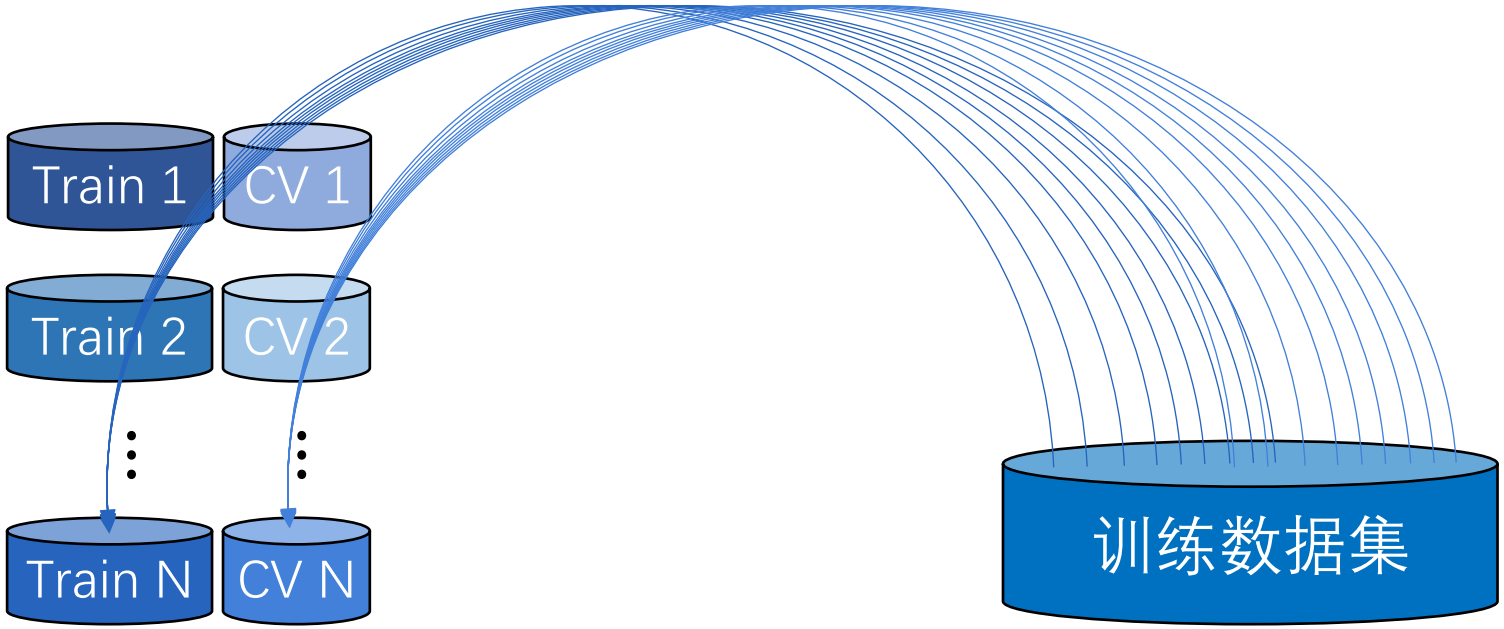

# 发生过拟合应该怎么办？—— ⑤ 交叉验证增强评估能力

利用**学习曲线**判断泛化能力

理想情况：训练和验证的损失（误差） 以相似的趋势减小并收敛。

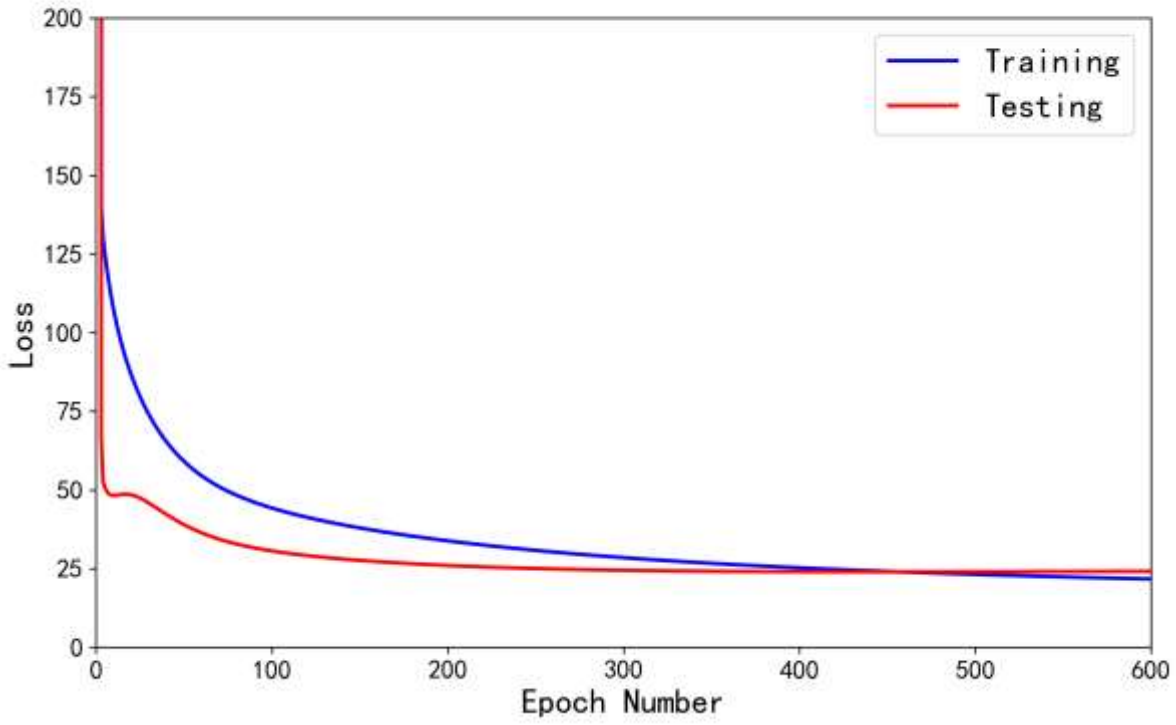


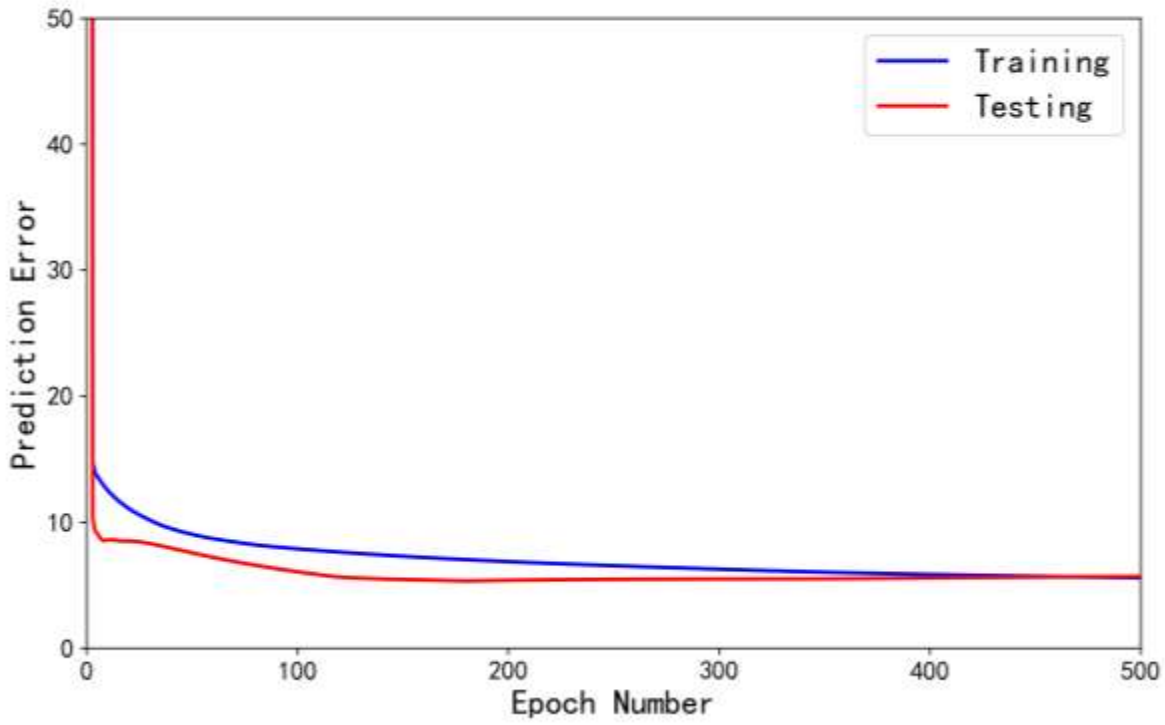

# 发生过拟合应该怎么办？—— ⑤ 交叉验证增强评估能力

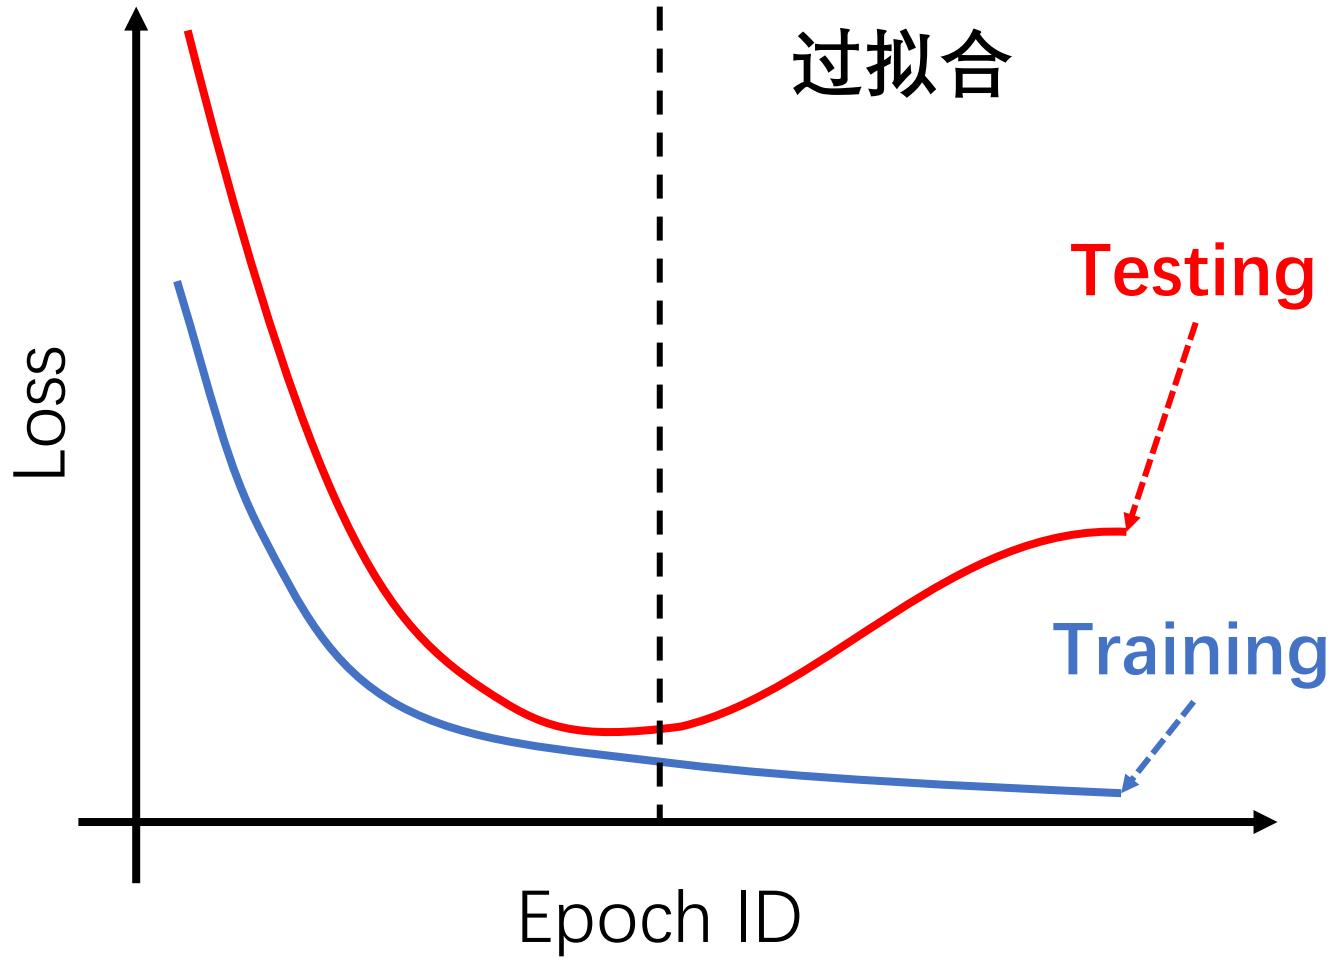


经过一段时间的训练

在训练集上表现很好

在验证集上越来越差

# 发生过拟合应该怎么办？—— ⑥ 在发生过拟合之前结束训练

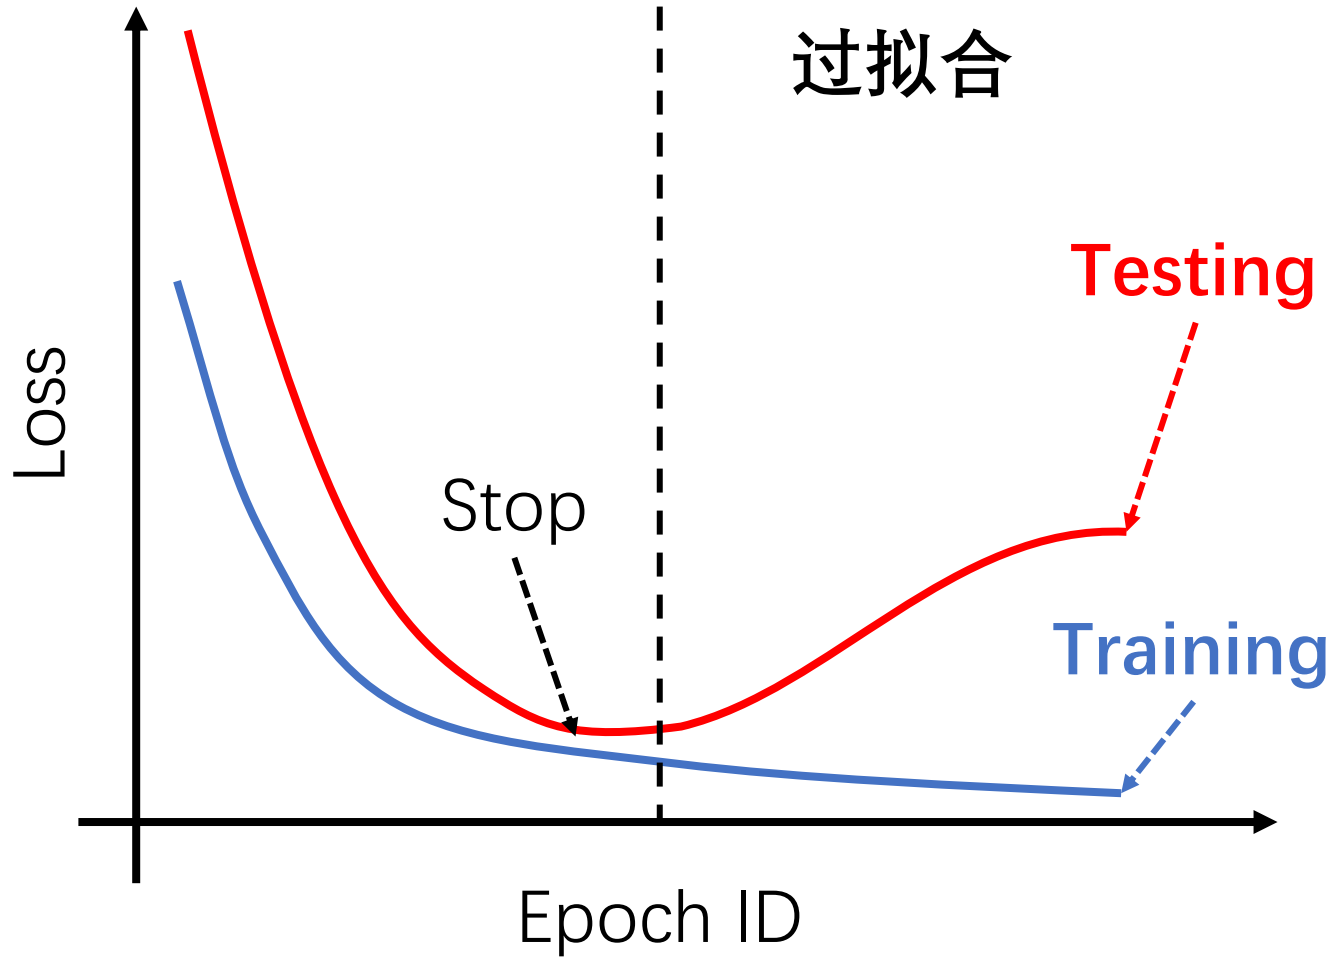


**早停法（Early Stopping)**

一段时间内，在测试集上的表现不再提升则停止训练。

# 支线任务——欠拟合及应对方法

如果一不小心停早了会怎么样?

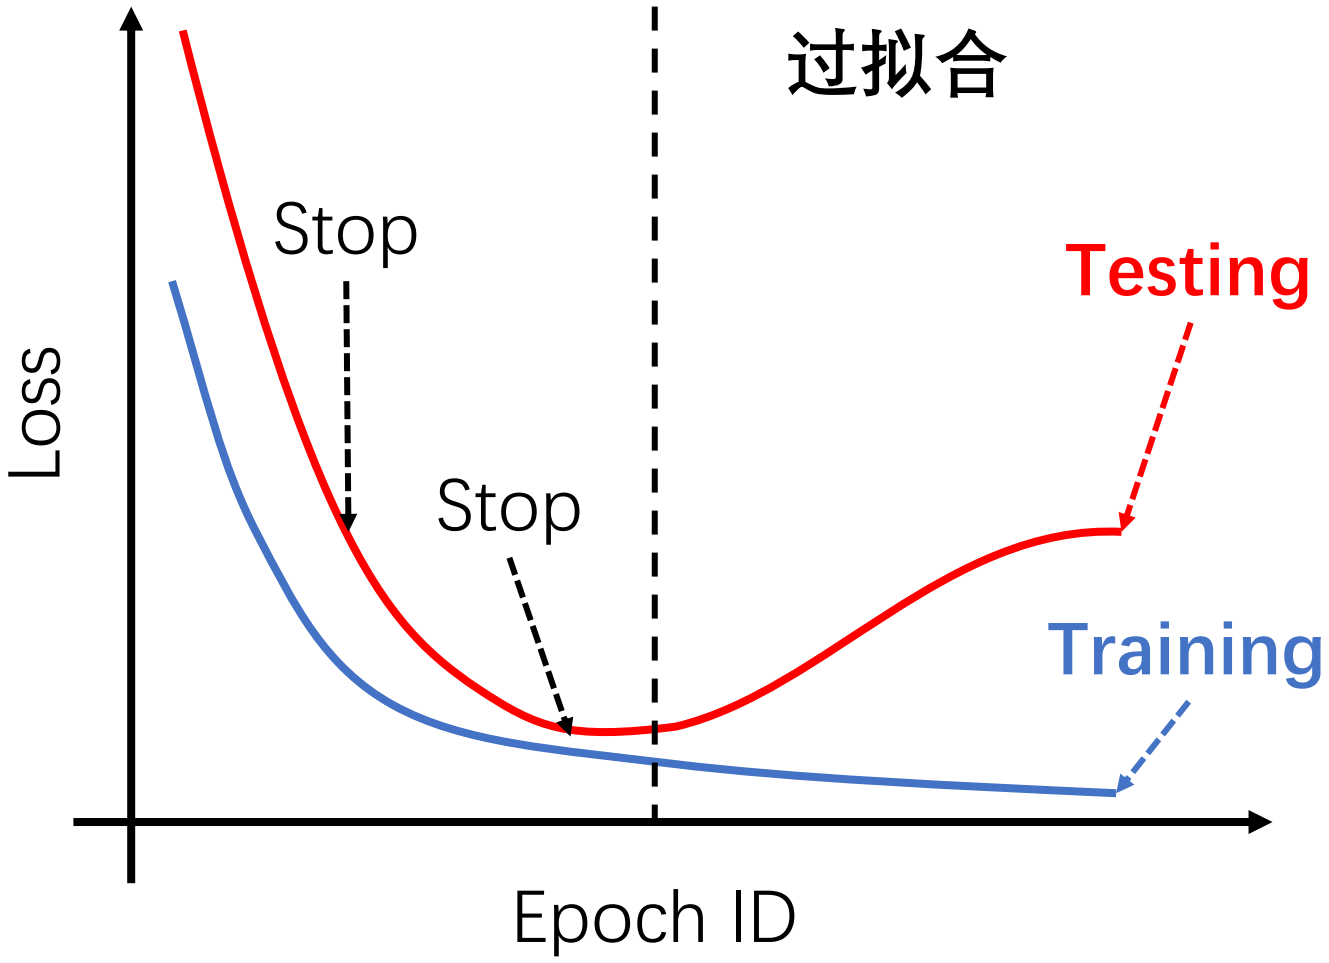

# 支线任务——欠拟合及应对方法

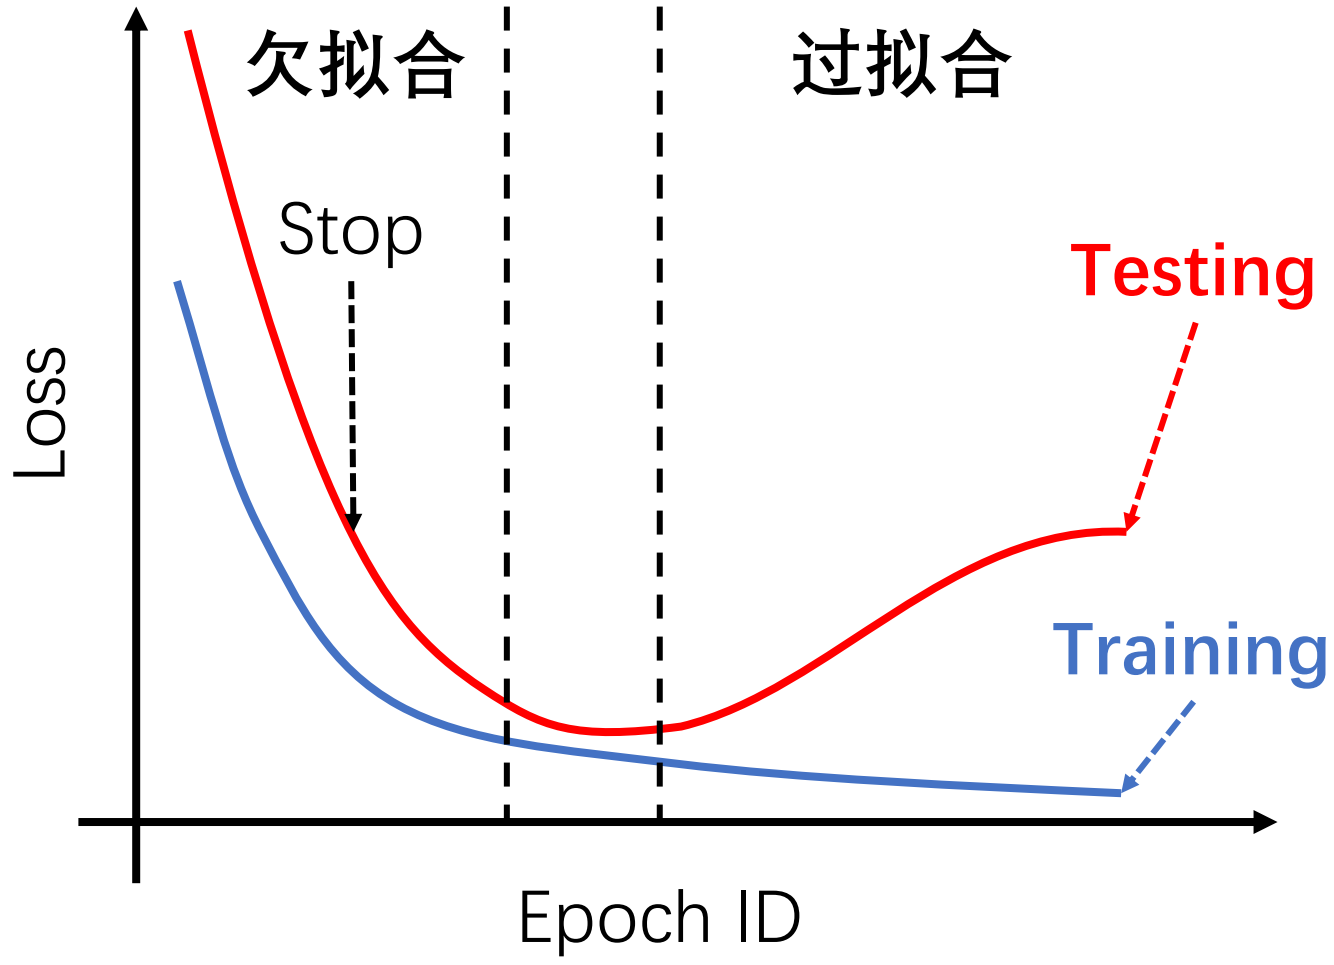


如果一不小心停早了会怎么样?

在训练集上表现差

在测试集上表现差

**欠拟合**

# 支线任务——欠拟合及应对方法

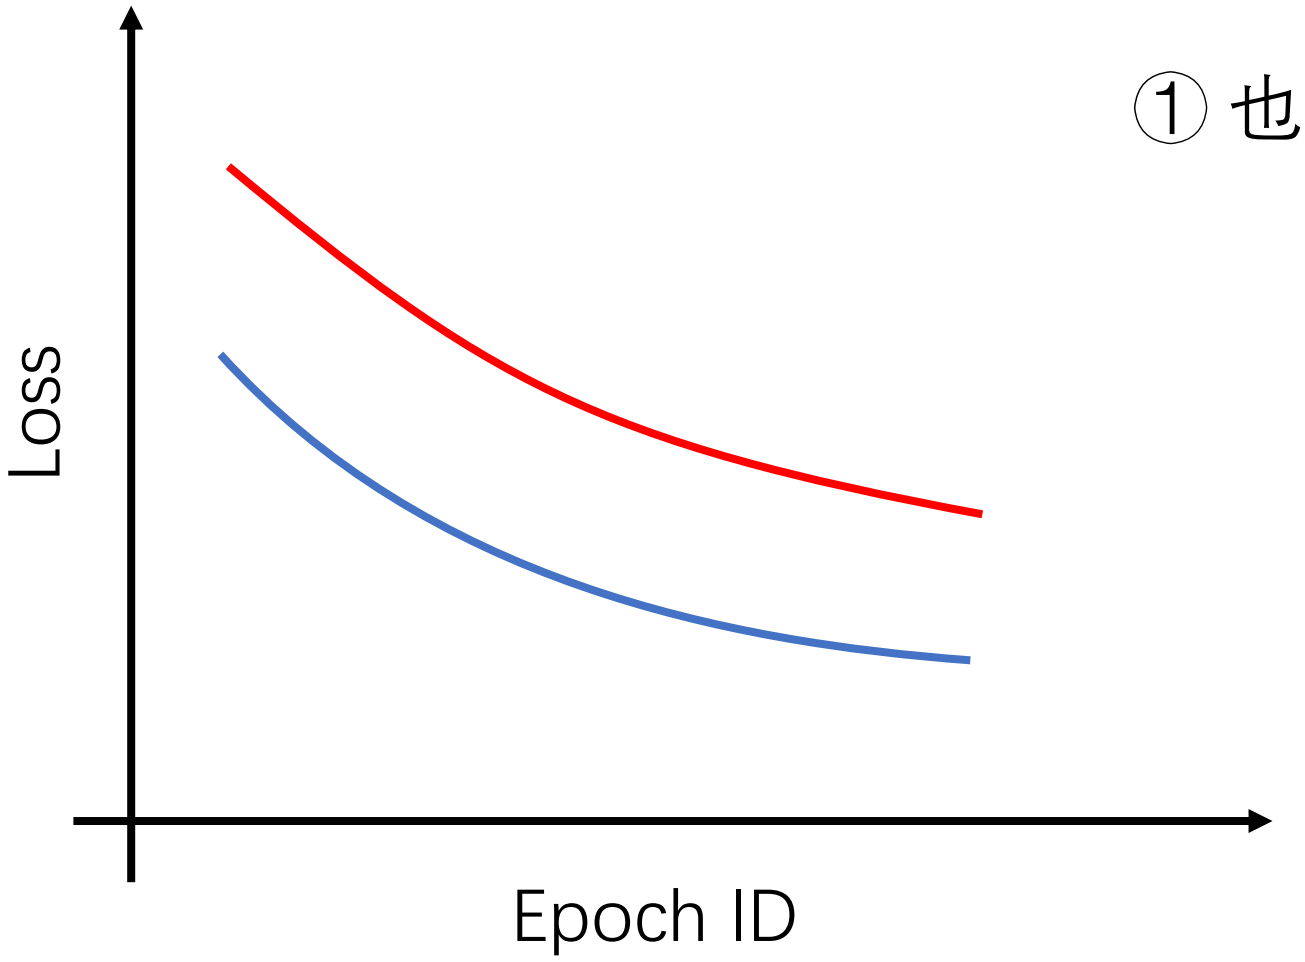


**发生欠拟合的原因**

① 也许是**训练不够充分**

# 支线任务——欠拟合及应对方法

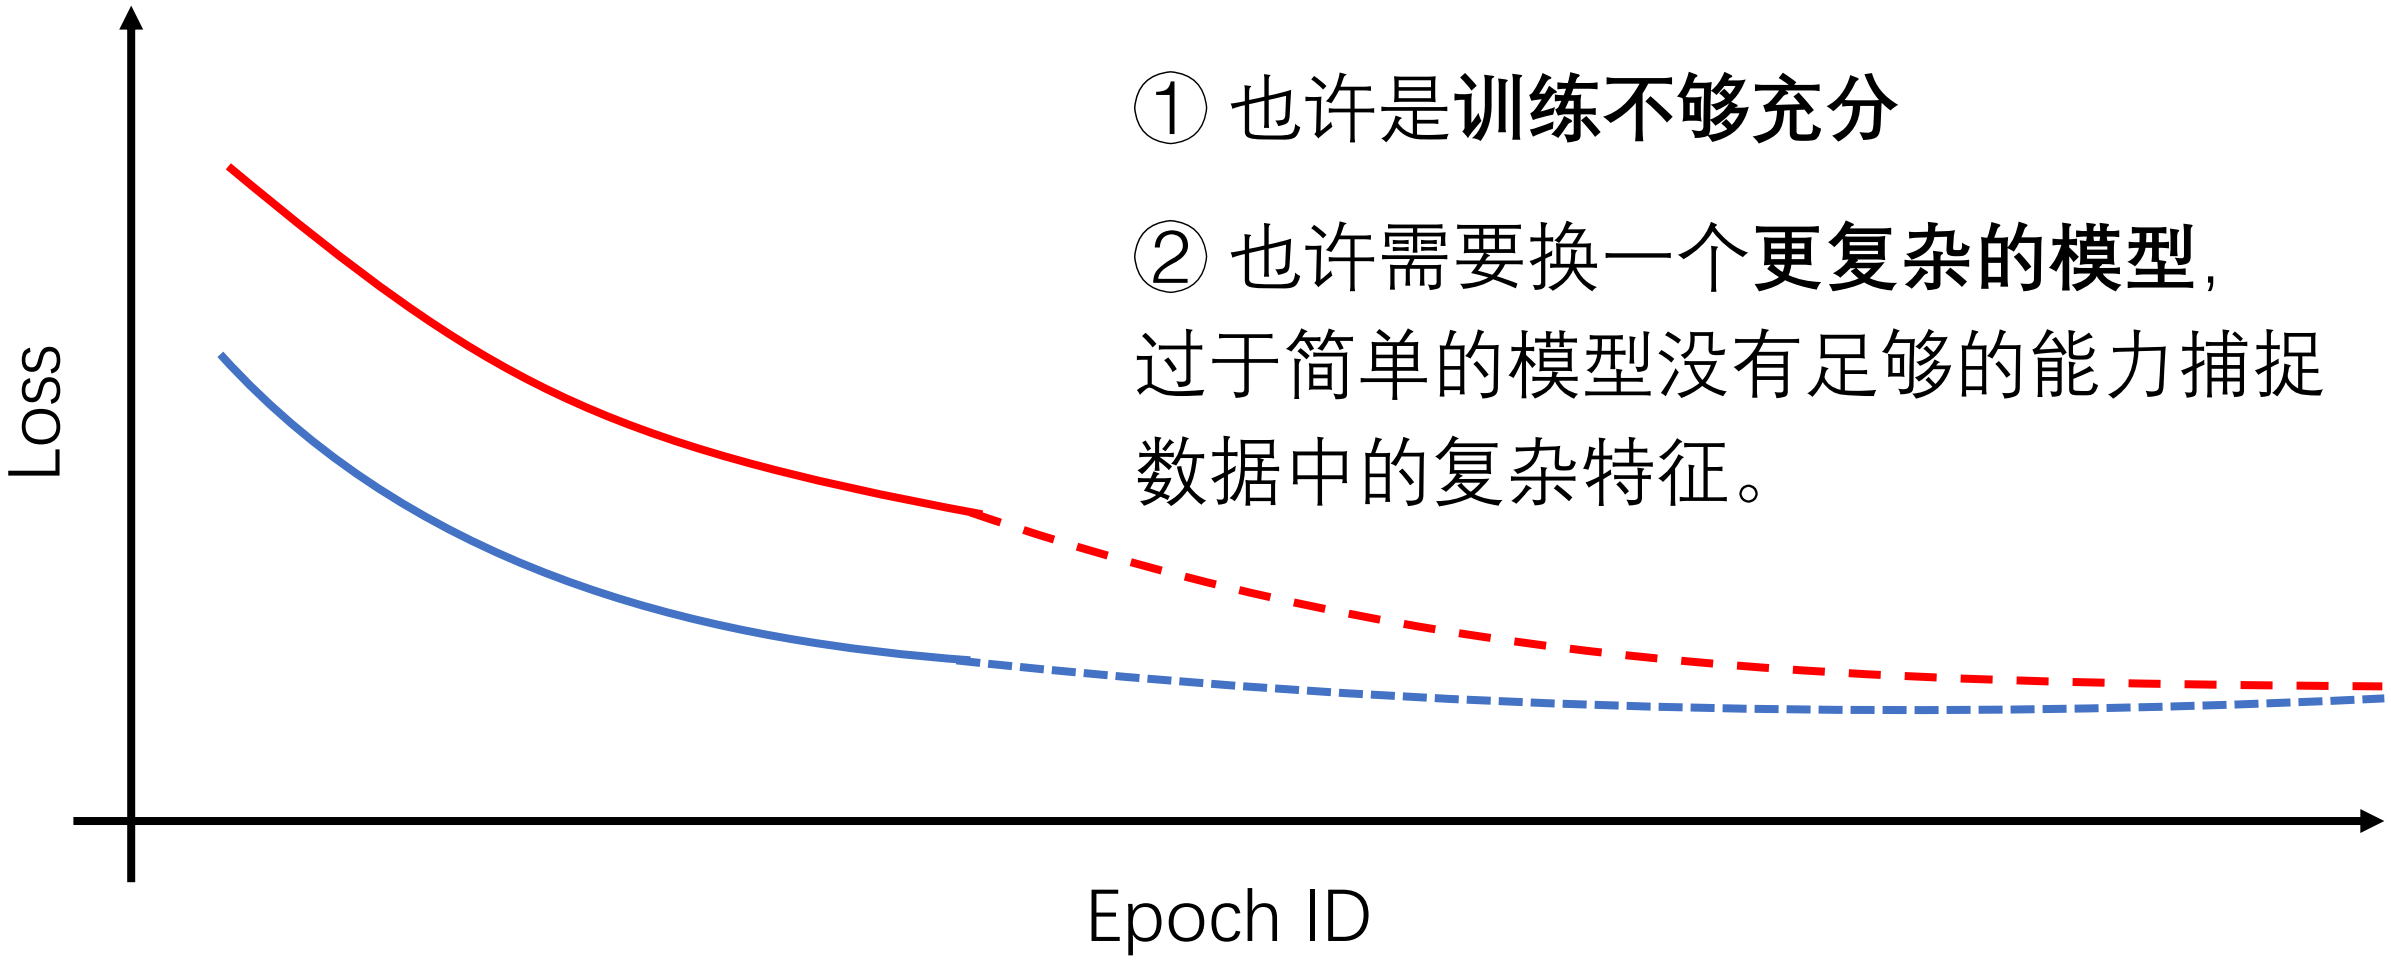


**发生欠拟合的原因**

① 也许是**训练不够充分**

② 也许需要换一个**更复杂的模型**，过于简单的模型没有足够的能力捕捉数据中的复杂特征。

# 总结：本章知识点

- **什么是回归问题?**
  - ✓ 任务预测或者推断
  - ✓ 输出是连续数值
- **机器学习的通用框架**
  - ✓ 训练-测试阶段
  - ✓ 训练阶段包括三个步骤
- **线性回归问题**
- **损失函数&目标函数**
- **梯度下降&学习率选择**
- **模型泛化**
- **过拟合及解决方法**
  - ✓ 更简单的模型
  - ✓ 数据增强
  - ✓ 正则化
  - ✓ 交叉验证
  - ✓ 早停法
- **欠拟合及解决方法**