3.3 常用的分类模型一

决策树 & 基尼指数 & 随即森林

最简单的决策树长什么样子?

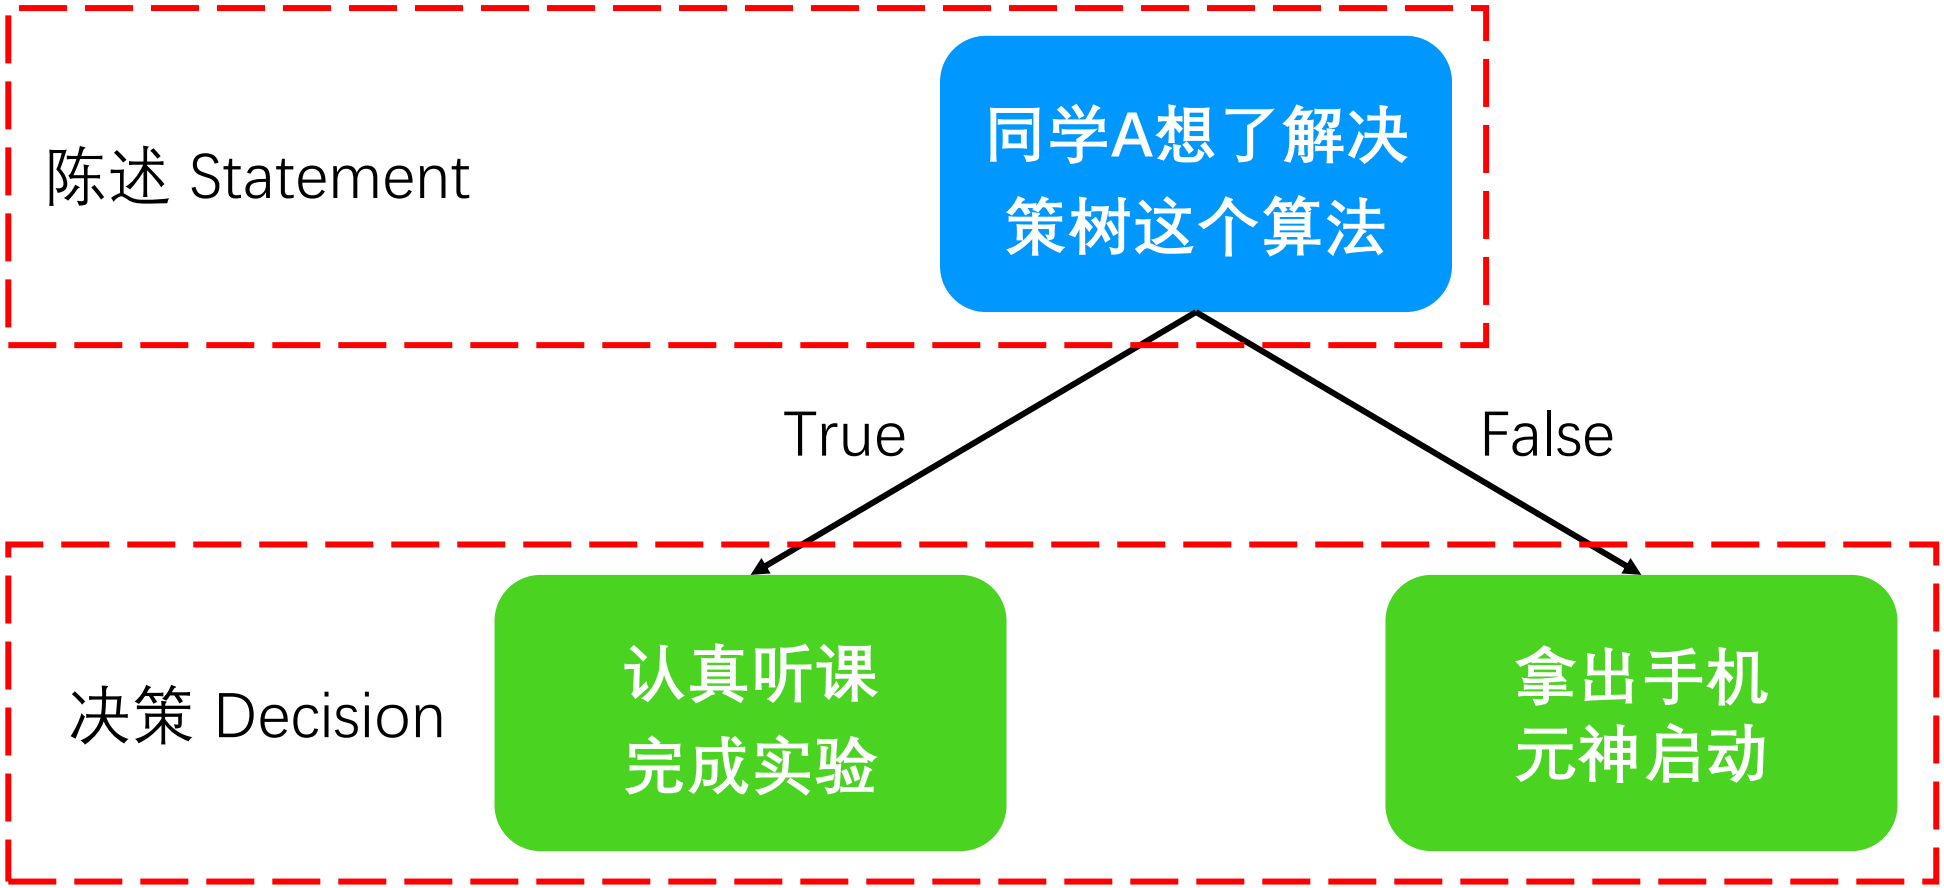

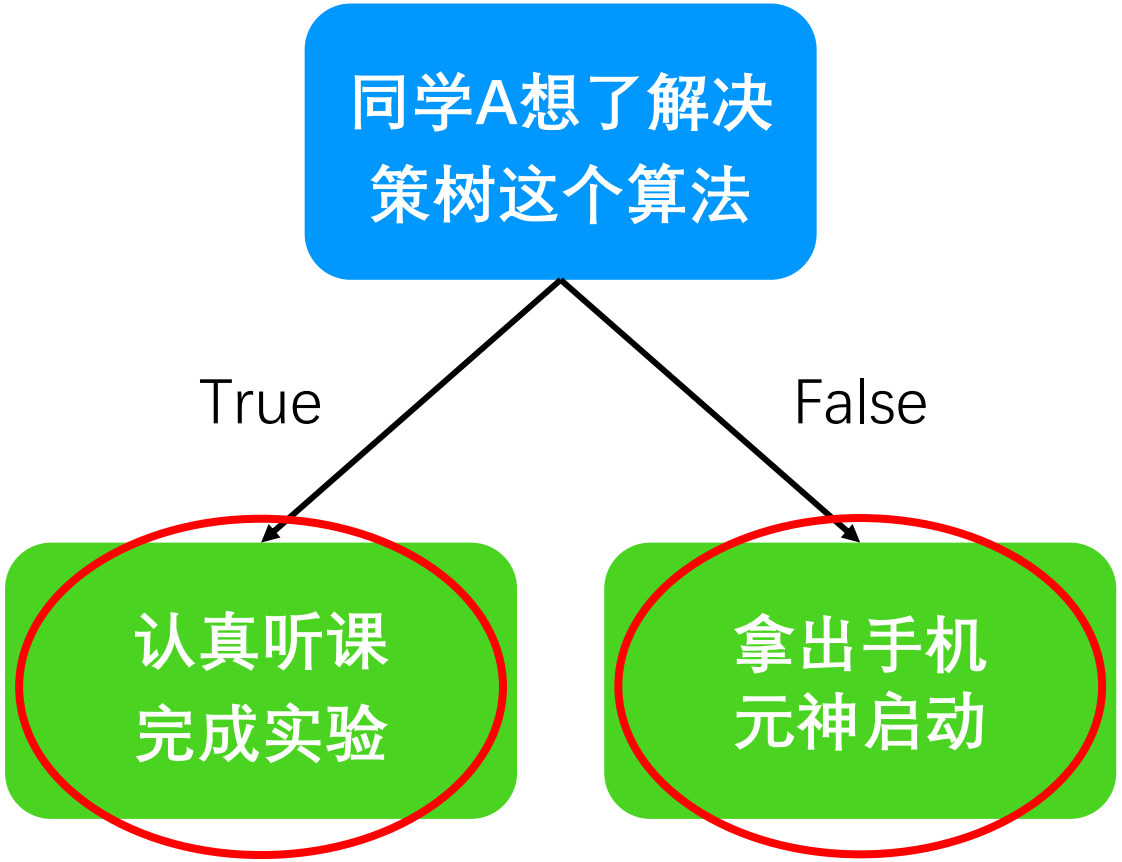

决策的结果为<u>类别</u>时

分类树

决策的结果为类别时

分类树

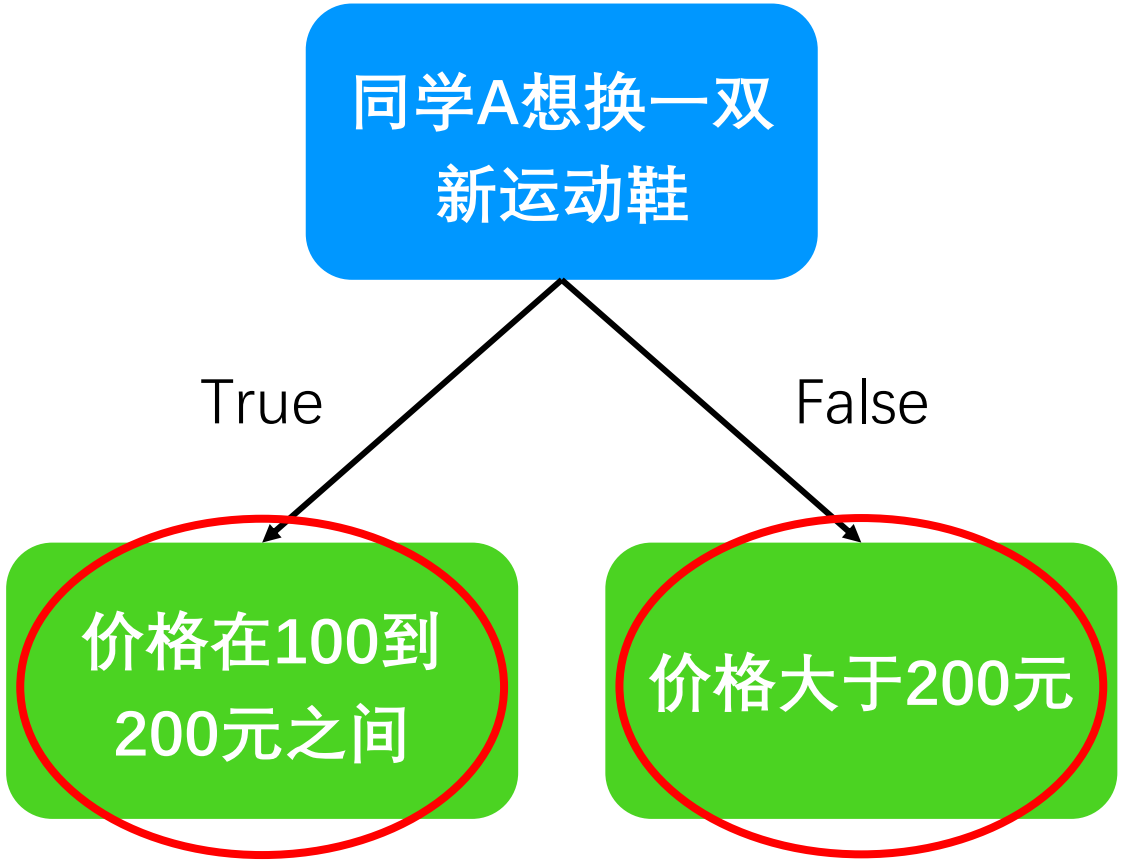

决策的结果为数值时

回归树

如何构建决策树呢？ 以老师在二次元世界游历的经历为例

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

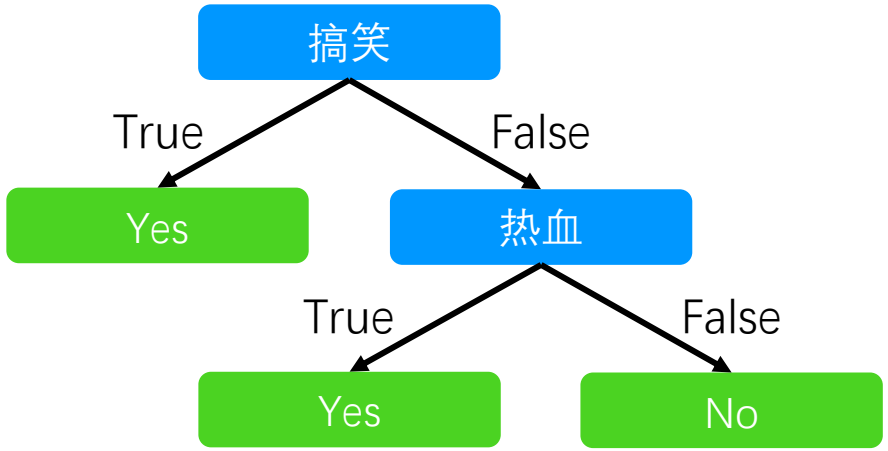

从对决策树结构一无所知开始

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

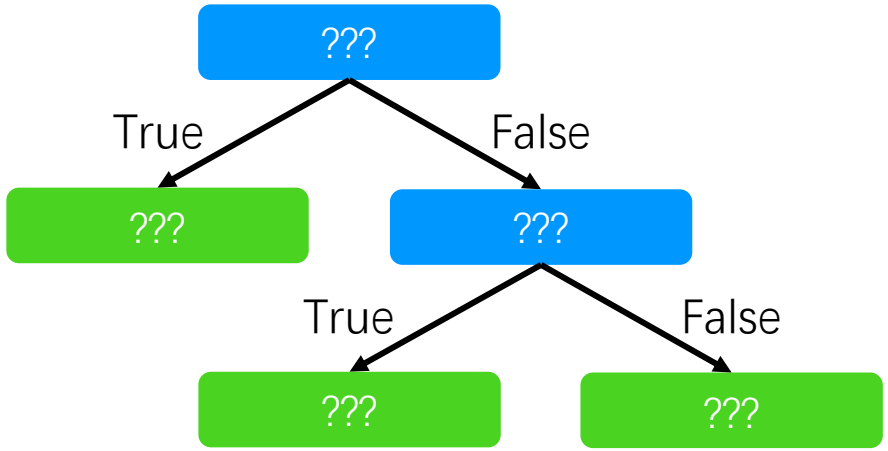

如果不知道应该以哪个特征的情况作为根节点的话，那么……

把每种可能都试一下吧

试一下让“搞笑”作为根节点

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

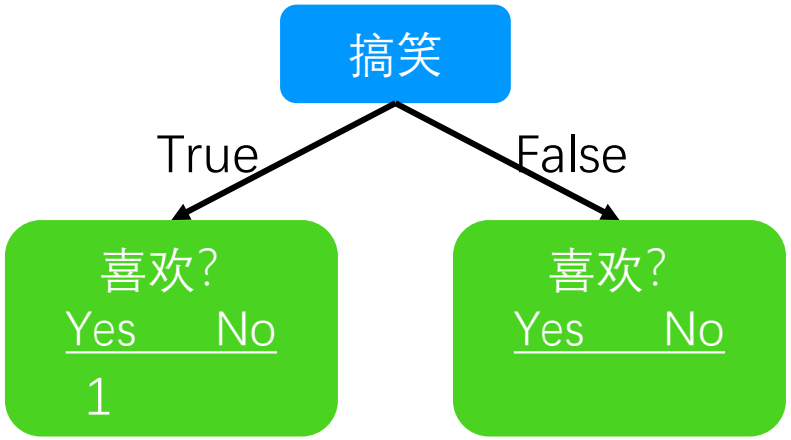

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

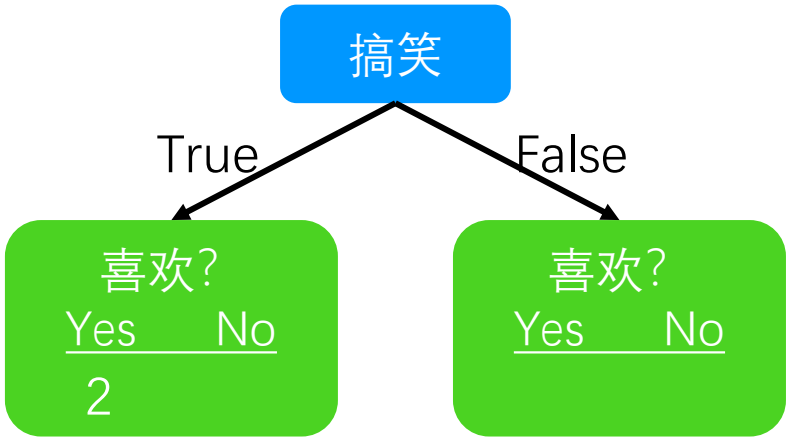

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

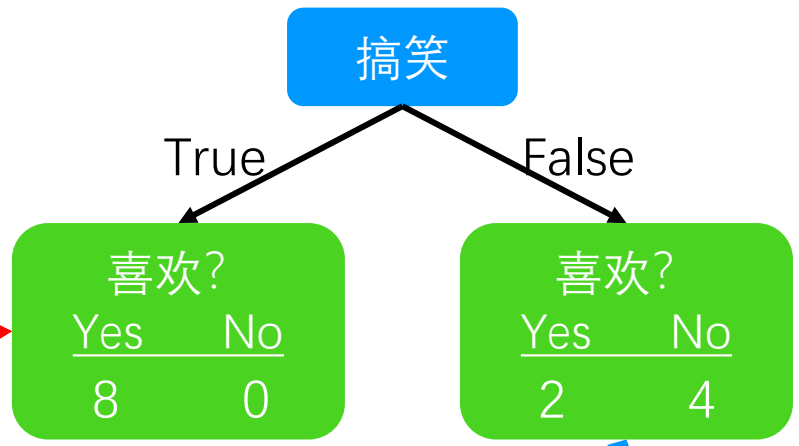

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

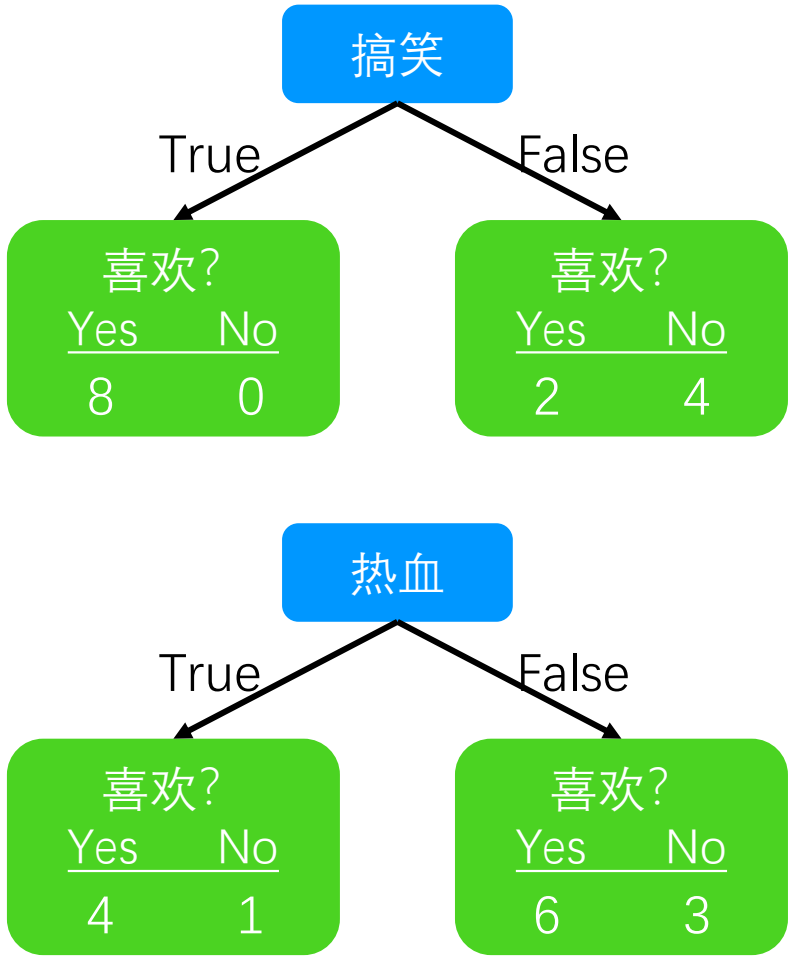

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

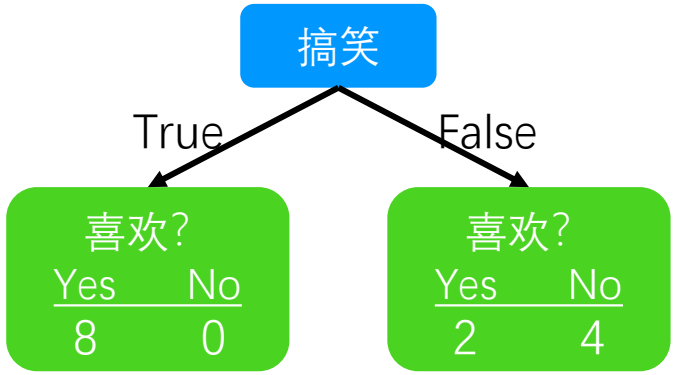

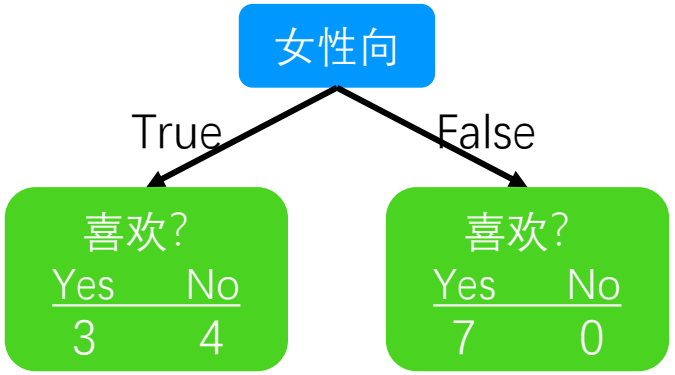

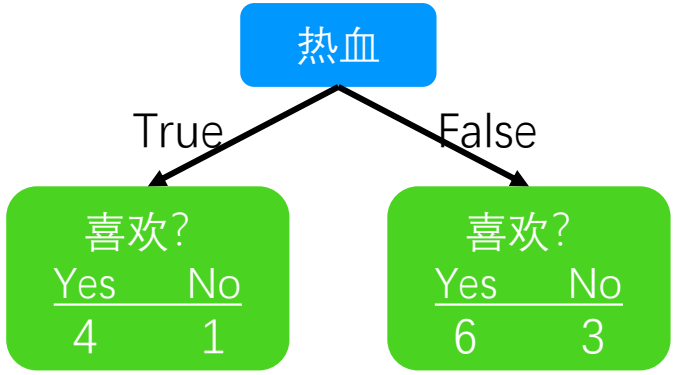

这些只包含**喜欢**影片的
叶子节点被称为

纯节点

Pure Node

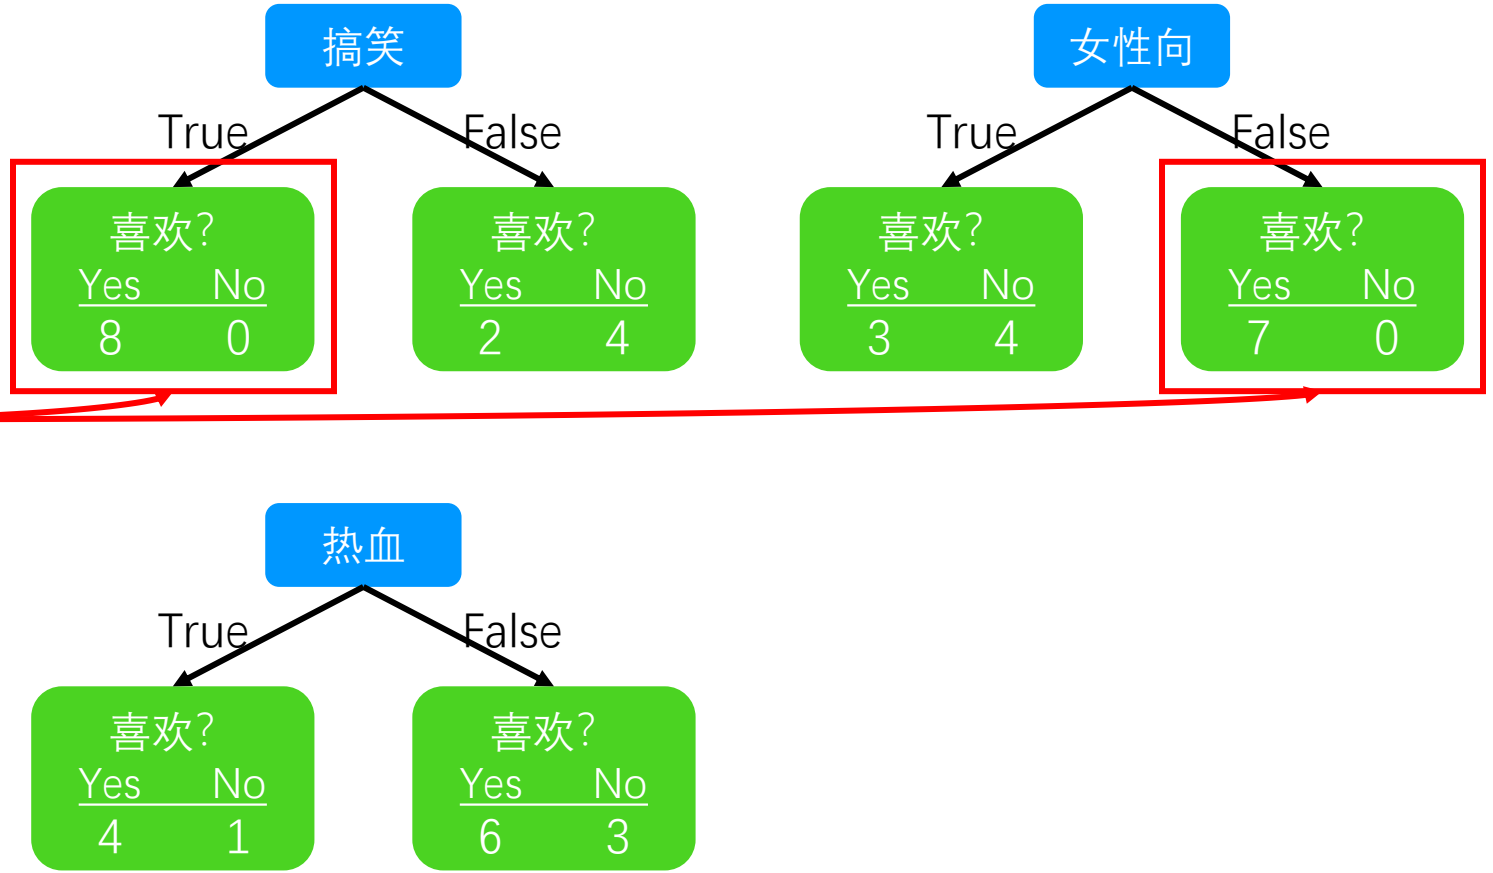

这些同时包含喜欢和不喜欢
影片的叶子节点被称为

不纯节点

Impure Node

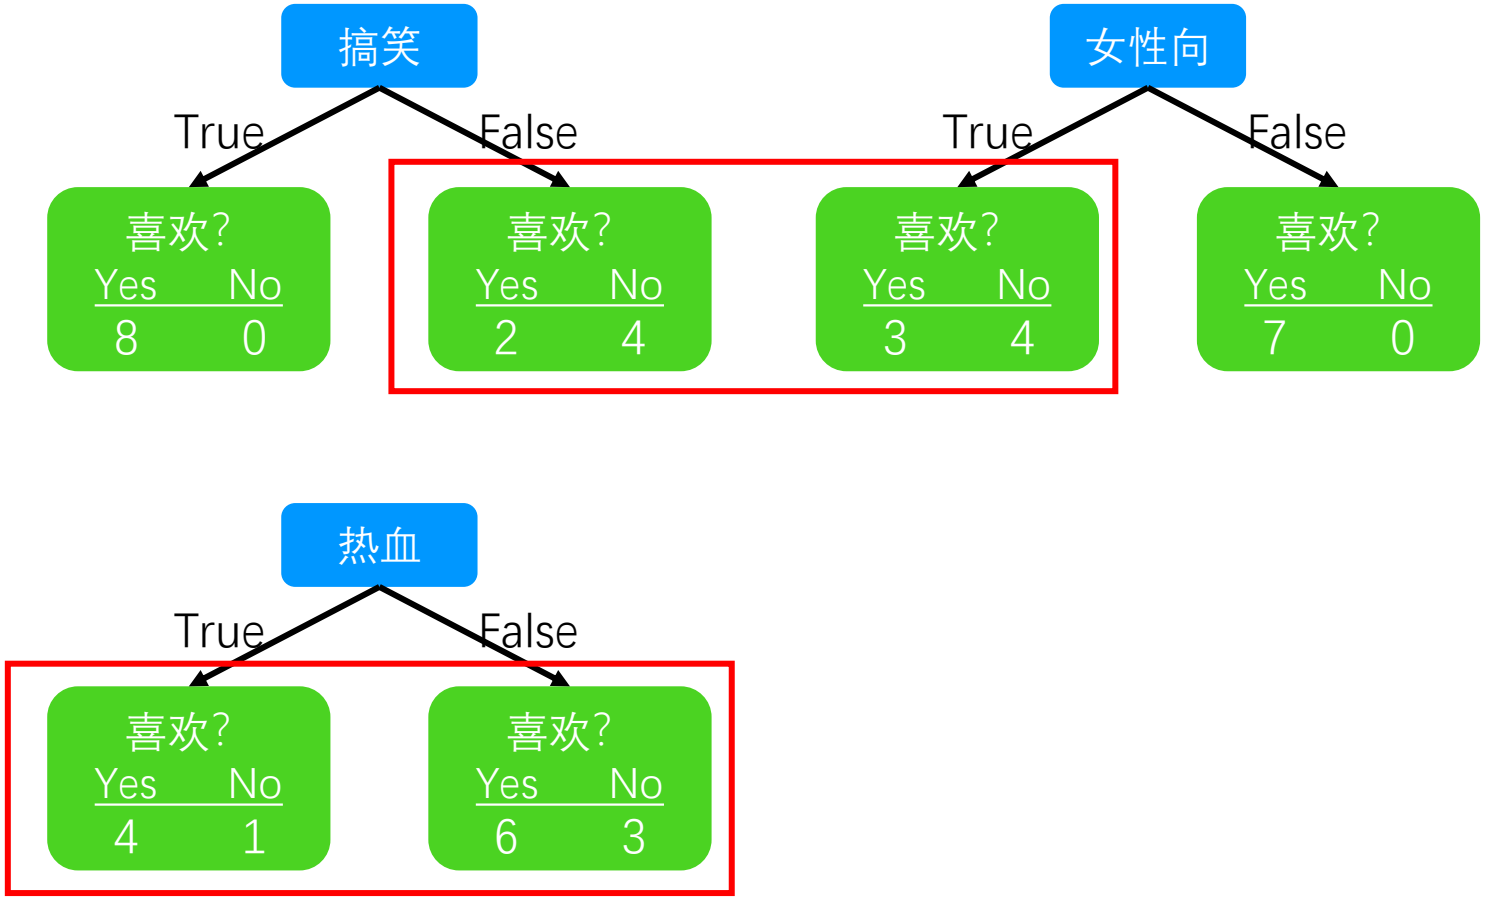

相比而言，以“搞笑”和“女性向”特征，更容易区分是否喜欢

如果能够量化纯度将更容易做出判断

基尼指数

Gini Index

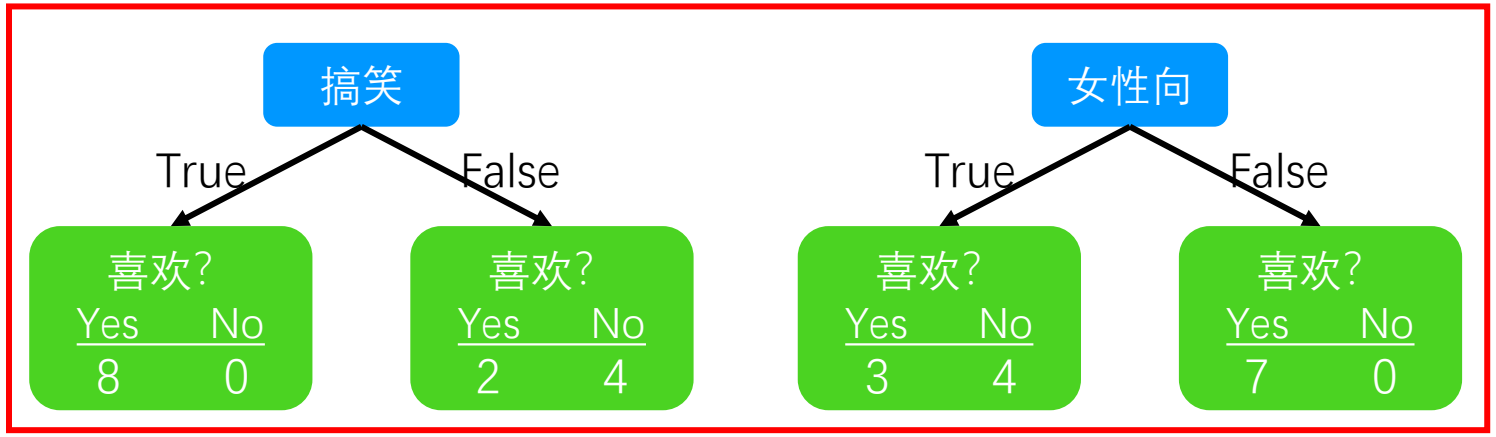

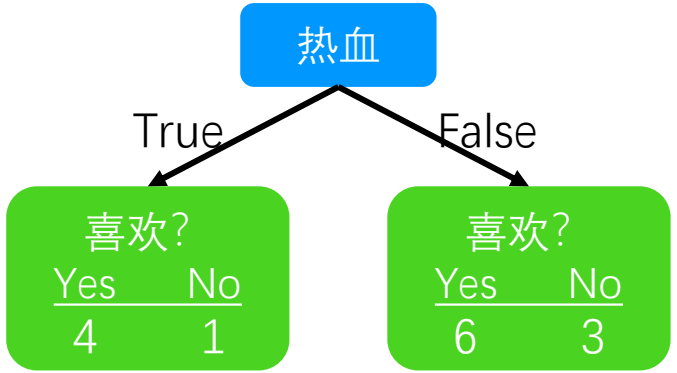

《机器学习》P79

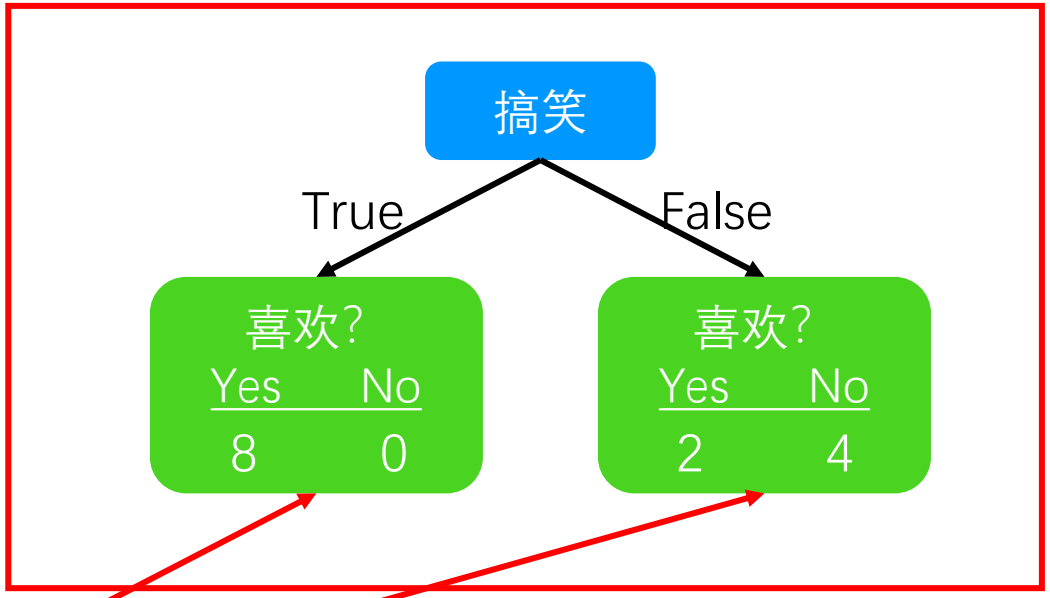

计算以“搞笑”为根节点的决策树的基尼指数

首先，需要分别计算各**叶子节点**的**基尼指数**

左边**叶子节点**的基尼指数，
形式如下……

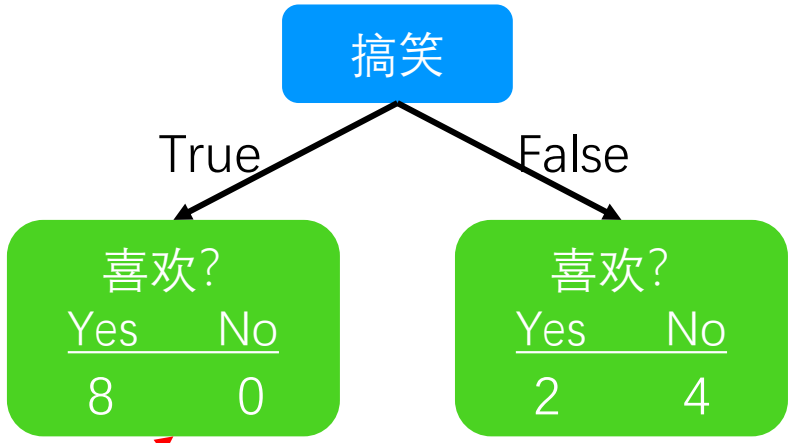

$$基尼指数 = 1 - (“Yes”所占比例)^2 - (“No”所占比例)^2$$

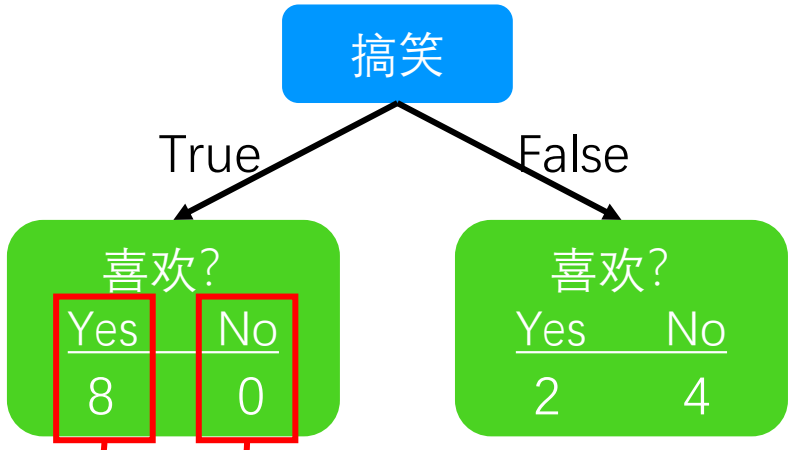

$$\text{基尼指数} = 1 - (\text{“}Yes\text{”所占比例})^2 - (\text{“}No\text{”所占比例})^2$$

$$= 1 - \left(\frac{8}{8+0}\right)^2 - \left(\frac{0}{8+0}\right)^2$$

$$= 0$$

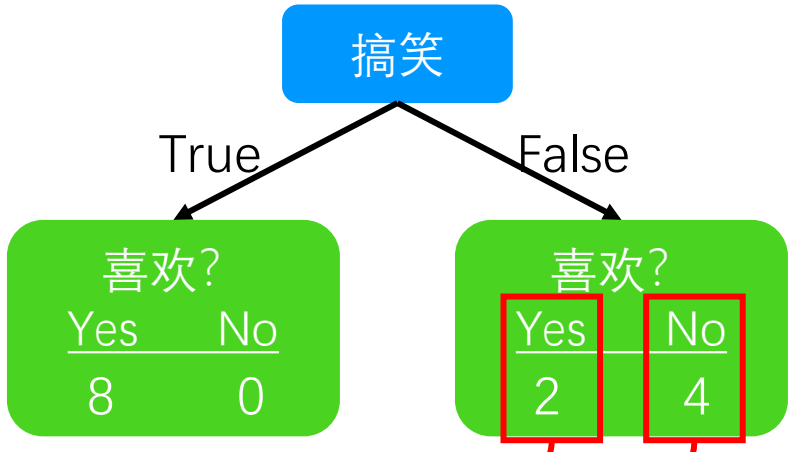

基尼指数 = 0

$$\text{基尼指数} = 1 - (\text{“}Yes\text{”所占比例})^2 - (\text{“}No\text{”所占比例})^2$$

$$= 1 - \left(\frac{2}{2+4}\right)^2 - \left(\frac{4}{2+4}\right)^2$$

$$= 0.444$$

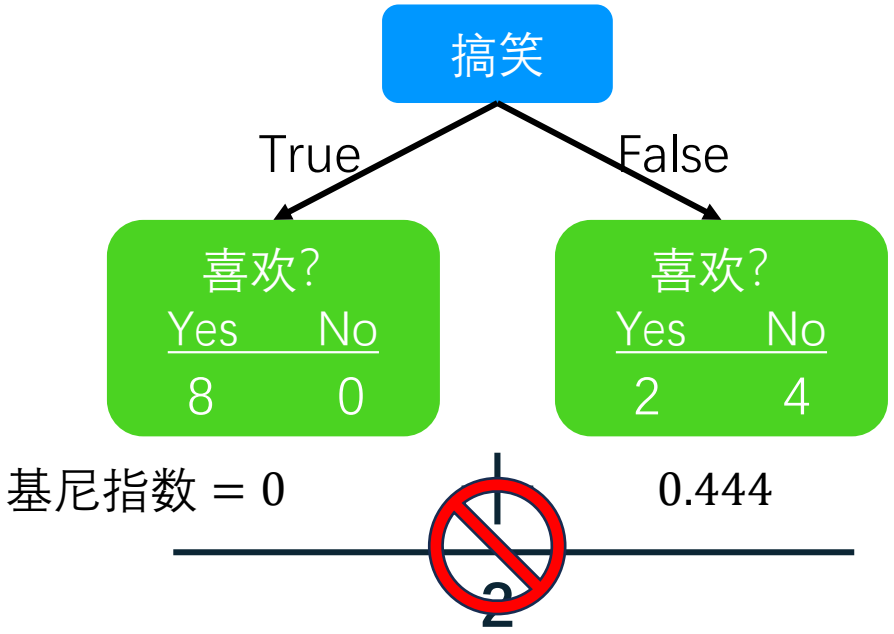

左边叶子节点
包含 **8** 部影片

右边叶子节点
包含 **6** 部影片

叶子节点所代表的影片数不同，
存在**不平衡**的问题

为解决不平衡的问题
需要对两个叶子节点的基尼指数进行
加权求和

“影片更多的节点越重要”

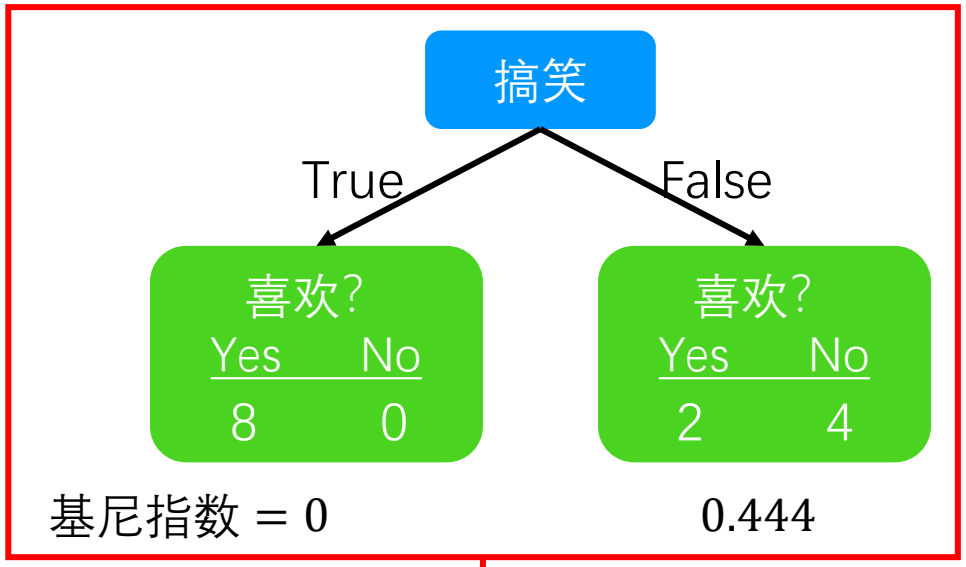

$$\text{整体基尼指数} = w_{left}G(\text{左叶子节点}) + w_{right}G(\text{右叶子节点})$$

$$= \left(\frac{8}{8+6}\right) \times 0 + \left(\frac{6}{8+6}\right) \times 0.444$$

$$= 0.19$$

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

基尼指数 = 0.190

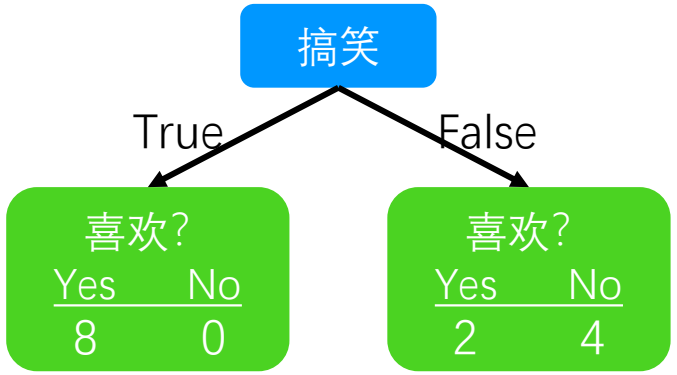

基尼指数 = 0.245

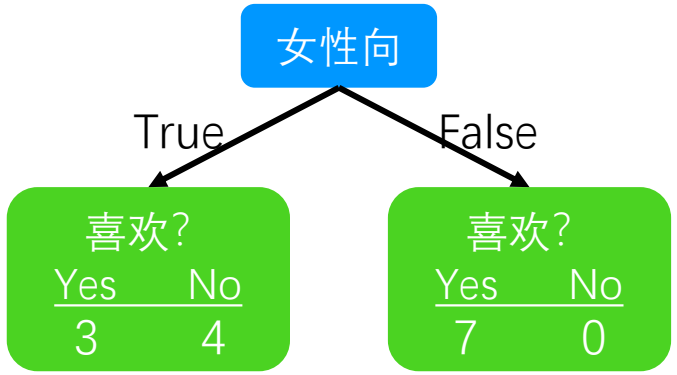

基尼指数 = 0.400

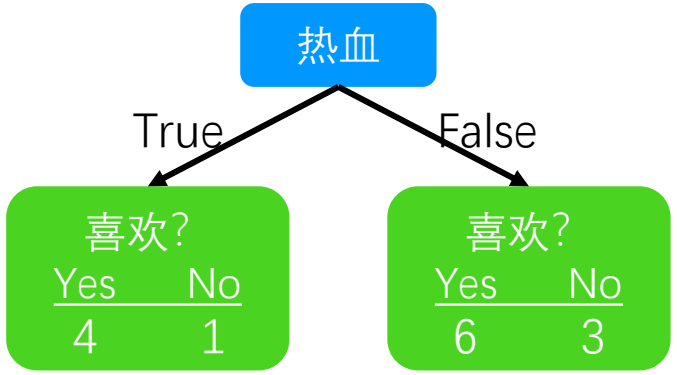

基尼指数 = ???

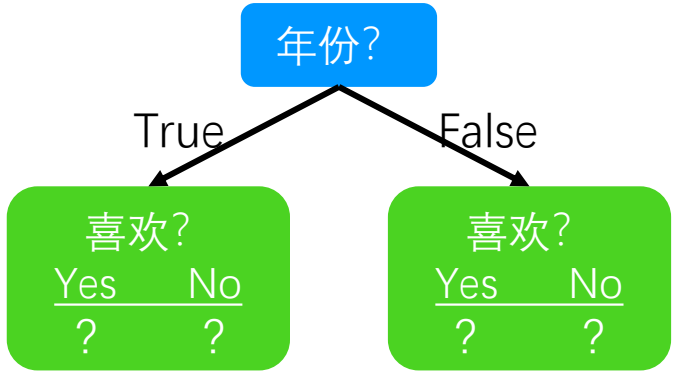

以作品的年份构建决策树

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

首先，按照年份进行**排序**

以作品的年份构建决策树

作品名	搞笑	热血	女性向	年份	喜欢
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
薄樱鬼	否	是	是	2010	Y
世界第一初恋	否	否	是	2011	N
十万个冷笑话	是	否	否	2012	Y
进击的巨人	否	是	否	2013	Y
狐妖小红娘	是	否	否	2015	Y
碧蓝之海	是	是	否	2018	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
魔道祖师	否	是	是	2018	N
仙王的日常生活	是	否	否	2020	Y
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y
格斗实况	是	是	否	2024	Y

2009

2010.5

2011.5

2012.5

2014

2016.5

2019

2022

然后，计算相邻年份的均值

以作品的年份构建决策树

作品名	搞笑	热血	女性向	年份	喜欢
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
薄樱鬼	否	是	是	2010	Y
世界第一初恋	否	否	是	2011	N
十万个冷笑话	是	否	否	2012	Y
进击的巨人	否	是	否	2013	Y
狐妖小红娘	是	否	否	2015	Y
碧蓝之海	是	是	否	2018	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
魔道祖师	否	是	是	2018	N
仙王的日常生活	是	否	否	2020	Y
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y
格斗实况	是	是	否	2024	Y

最后，对应的基尼指数指数最低的情况作为树根

2009	0.393
2010.5	0.389
2011.5	0.371
2012.5	0.394
2014	0.405
2016.5	0.408
2019	0.407
2022	0.395

以作品的年份构建决策树

作品名	搞笑	热血	女性向	年份	喜欢
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
薄樱鬼	否	是	是	2010	Y
世界第一初恋	否	否	是	2011	N
十万个冷笑话	是	否	否	2012	Y
进击的巨人	否	是	否	2013	Y
狐妖小红娘	是	否	否	2015	Y
碧蓝之海	是	是	否	2018	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
魔道祖师	否	是	是	2018	N
仙王的日常生活	是	否	否	2020	Y
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y
格斗实况	是	是	否	2024	Y

2011.5

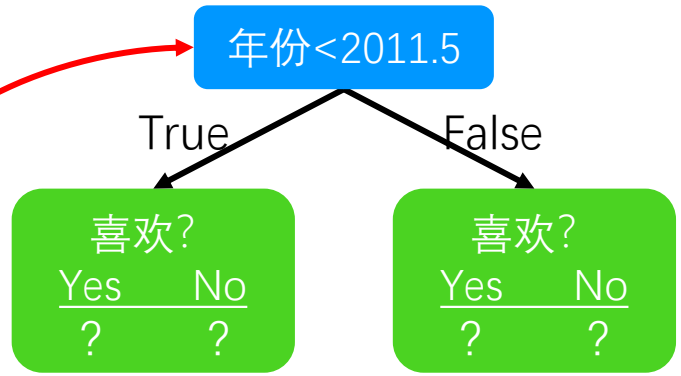

以作品的年份构建决策树

作品名	搞笑	热血	女性向	年份	喜欢
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
薄樱鬼	否	是	是	2010	Y
世界第一初恋	否	否	是	2011	N
十万个冷笑话	是	否	否	2012	Y
进击的巨人	否	是	否	2013	Y
狐妖小红娘	是	否	否	2015	Y
碧蓝之海	是	是	否	2018	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
魔道祖师	否	是	是	2018	N
仙王的日常生活	是	否	否	2020	Y
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y
格斗实况	是	是	否	2024	Y

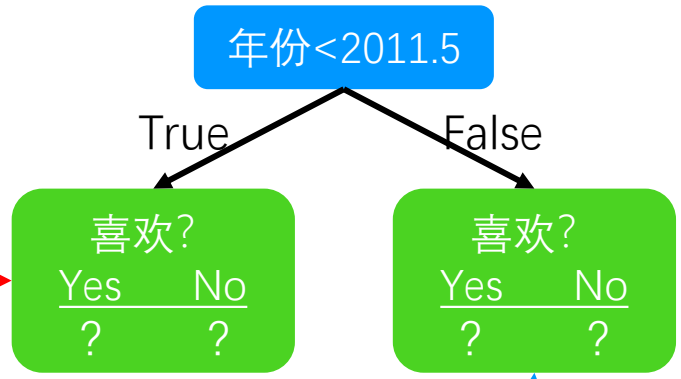

以作品的年份构建决策树

作品名	搞笑	热血	女性向	年份	喜欢
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
薄樱鬼	否	是	是	2010	Y
世界第一初恋	否	否	是	2011	N
十万个冷笑话	是	否	否	2012	Y
进击的巨人	否	是	否	2013	Y
狐妖小红娘	是	否	否	2015	Y
碧蓝之海	是	是	否	2018	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
魔道祖师	否	是	是	2018	N
仙王的日常生活	是	否	否	2020	Y
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y
格斗实况	是	是	否	2024	Y

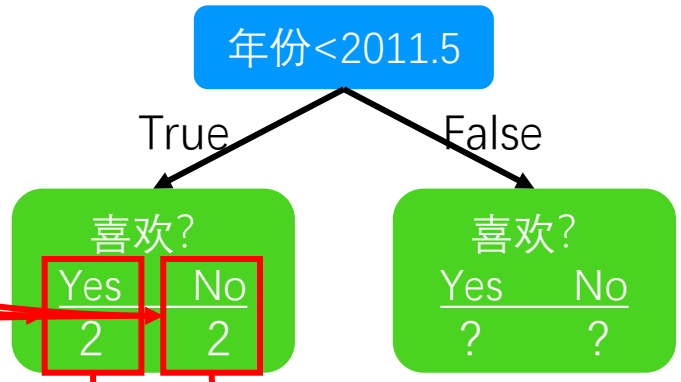

基尼指数 = 0.5

$$\text{基尼指数} = 1 - (\text{“}Yes\text{”所占比例})^2 - (\text{“}No\text{”所占比例})^2$$

$$= 1 - \left(\frac{2}{2+2}\right)^2 - \left(\frac{2}{2+2}\right)^2$$

$$= 0.5$$

以作品的年份构建决策树

作品名	搞笑	热血	女性向	年份	喜欢
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
薄樱鬼	否	是	是	2010	Y
世界第一初恋	否	否	是	2011	N
十万个冷笑话	是	否	否	2012	Y
进击的巨人	否	是	否	2013	Y
狐妖小红娘	是	否	否	2015	Y
碧蓝之海	是	是	否	2018	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
魔道祖师	否	是	是	2018	N
仙王的日常生活	是	否	否	2020	Y
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y
格斗实况	是	是	否	2024	Y

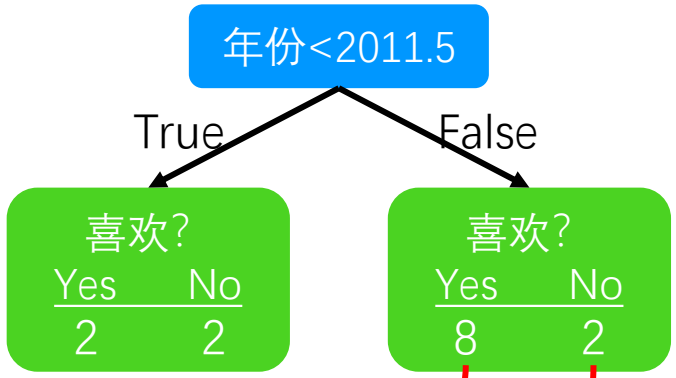

基尼指数 = 0.5　　0.32

$$\text{基尼指数} = 1 - (\text{“}Yes\text{”所占比例})^2 - (\text{“}No\text{”所占比例})^2$$

$$= 1 - \left(\frac{8}{8+2}\right)^2 - \left(\frac{2}{8+2}\right)^2$$

$$= 0.32$$

以作品的年份构建决策树

作品名	搞笑	热血	女性向	年份	喜欢
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
薄樱鬼	否	是	是	2010	Y
世界第一初恋	否	否	是	2011	N
十万个冷笑话	是	否	否	2012	Y
进击的巨人	否	是	否	2013	Y
狐妖小红娘	是	否	否	2015	Y
碧蓝之海	是	是	否	2018	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
魔道祖师	否	是	是	2018	N
仙王的日常生活	是	否	否	2020	Y
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y
格斗实况	是	是	否	2024	Y

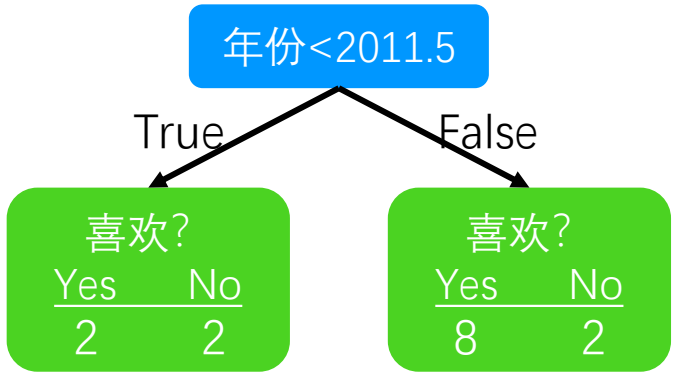

基尼指数 $= 0.5$ $\quad$ 0.32

$$\text{整体基尼指数} = w_{left}G(\text{左叶子节点}) + w_{right}G(\text{右叶子节点})$$

$$= \left(\frac{4}{4+10}\right) \times 0.5 + \left(\frac{10}{4+10}\right) \times 0.32$$

$$\underline{= 0.371}$$

将“搞笑”作为根节点

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

基尼指数 = 0.190

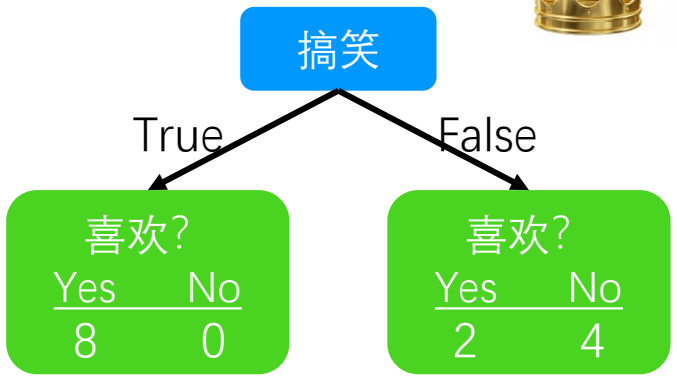

基尼指数 = 0.245

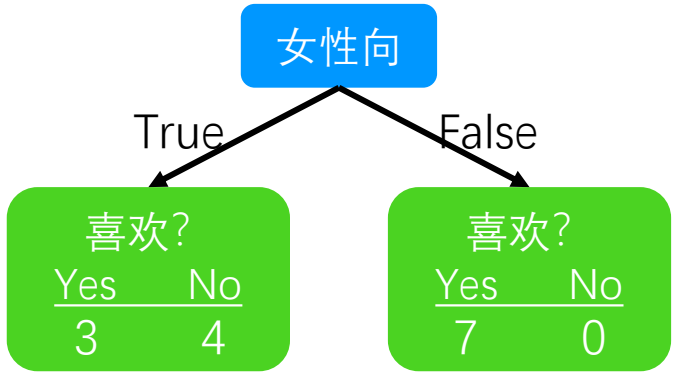

基尼指数 = 0.400

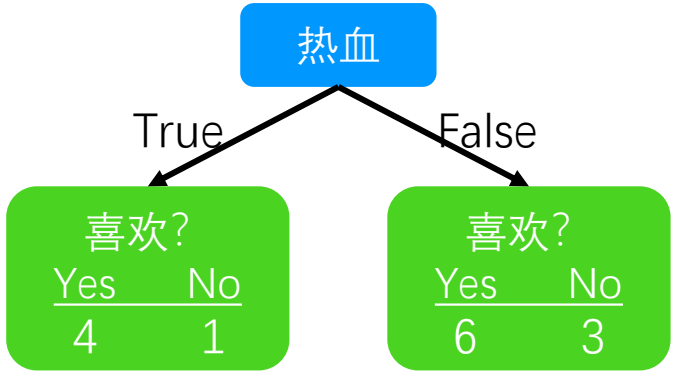

基尼指数 = 0.371

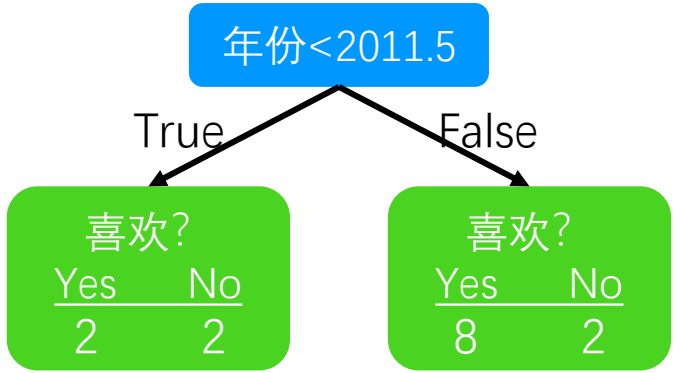

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

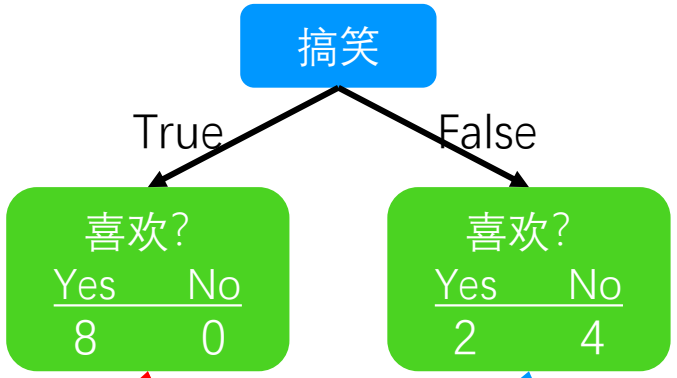

作品名	热血	女性向	年份	喜欢
格斗实况	是	否	2024	Y
碧蓝之海	是	否	2018	Y
十万个冷笑话	否	否	2012	Y
狐妖小红娘	否	否	2015	Y
仙王的日常生活	否	否	2020	Y
关于我转生变成史莱姆这档事	否	否	2018	Y
樱兰高校男公关部	否	是	2008	Y
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	否	是	2020	Y

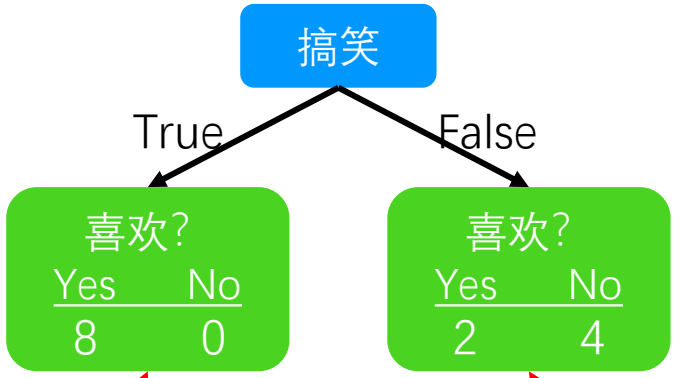

基尼指数 = 0
没有歧义

以相同的逻辑确定**子树根**

作品名	热血	女性向	年份	喜欢
进击的巨人	是	否	2013	Y
薄樱鬼	是	是	2010	Y
魔道祖师	是	是	2018	N
纯情罗曼史	否	是	2008	N
世界第一初恋	否	是	2011	N
恋与制作人	否	是	2020	N

作品名	热血	女性向	年份	喜欢
进击的巨人	是	否	2013	Y
薄樱鬼	是	是	2010	Y
魔道祖师	是	是	2018	N
纯情罗曼史	否	是	2008	N
世界第一初恋	否	是	2011	N
恋与制作人	否	是	2020	N

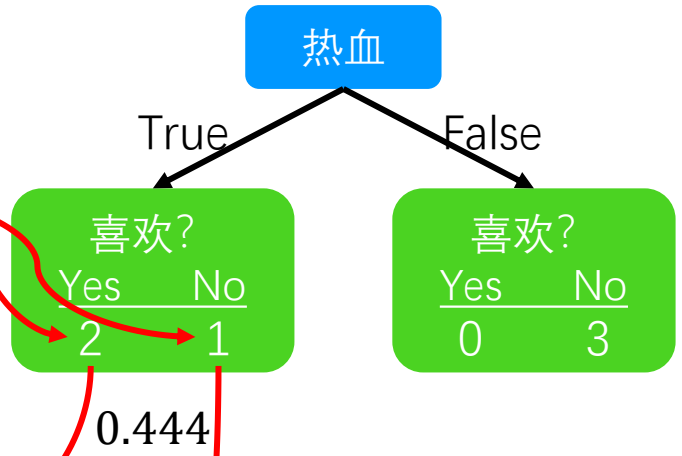

$$基尼指数 = 1 - (“Yes”所占比例)^2 - (“No”所占比例)^2$$

$$= 1 - \left(\frac{2}{2+1}\right)^2 - \left(\frac{1}{2+1}\right)^2$$

$$= 0.444$$

作品名	热血	女性向	年份	喜欢
进击的巨人	是	否	2013	Y
薄樱鬼	是	是	2010	Y
魔道祖师	是	是	2018	N
纯情罗曼史	否	是	2008	N
世界第一初恋	否	是	2011	N
恋与制作人	否	是	2020	N

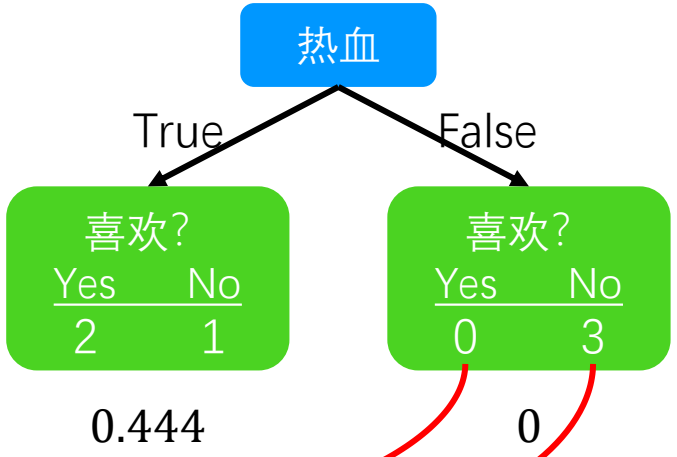

$$基尼指数 = 1 - (“Yes”所占比例)^2 - (“No”所占比例)^2$$

$$= 1 - \left(\frac{0}{0+3}\right)^2 - \left(\frac{3}{0+3}\right)^2$$

$$= 0$$

作品名	热血	女性向	年份	喜欢
进击的巨人	是	否	2013	Y
薄樱鬼	是	是	2010	Y
魔道祖师	是	是	2018	N
纯情罗曼史	否	是	2008	N
世界第一初恋	否	是	2011	N
恋与制作人	否	是	2020	N

基尼指数 $= 0.222$

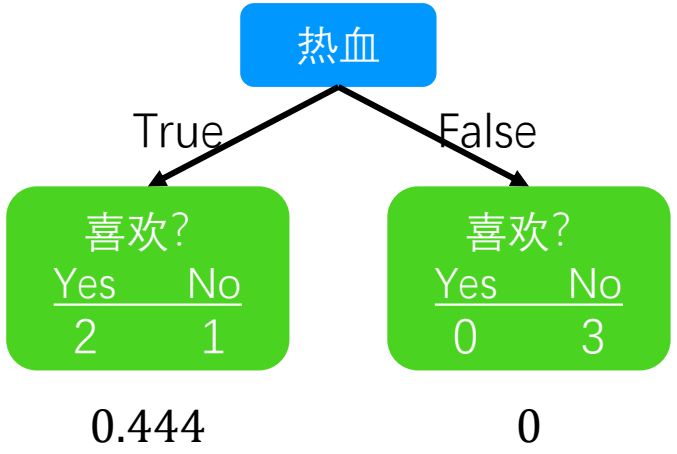

$$\text{整体基尼指数} = w_{left}G(\text{左叶子节点}) + w_{right}G(\text{右叶子节点})$$

$$= \left(\frac{3}{3+3}\right) \times 0.444 + \left(\frac{3}{3+3}\right) \times 0$$

$$= 0.222$$

以“热血”特征作为子树根

作品名	热血	女性向	年份	喜欢
进击的巨人	是	否	2013	Y
薄樱鬼	是	是	2010	Y
魔道祖师	是	是	2018	N
纯情罗曼史	否	是	2008	N
世界第一初恋	否	是	2011	N
恋与制作人	否	是	2020	N

作品名	热血	女性向	年份	喜欢
纯情罗曼史	否	是	2008	N
薄樱鬼	是	是	2010	Y
世界第一初恋	否	是	2011	N
进击的巨人	是	否	2013	Y
魔道祖师	是	是	2018	N
恋与制作人	否	是	2020	N

基尼指数 = 0.222

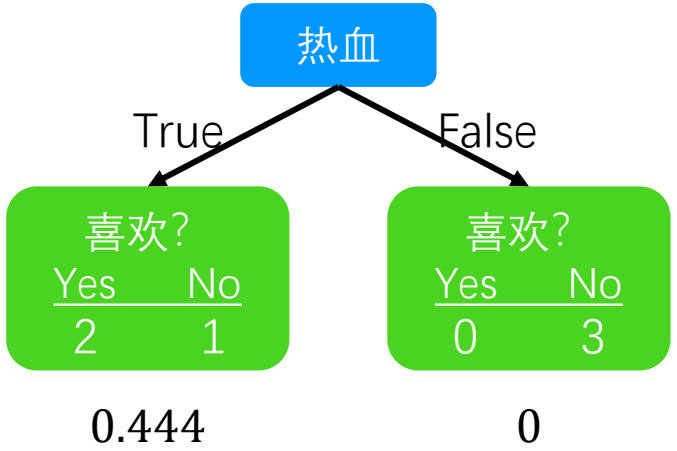

基尼指数 = 0.267

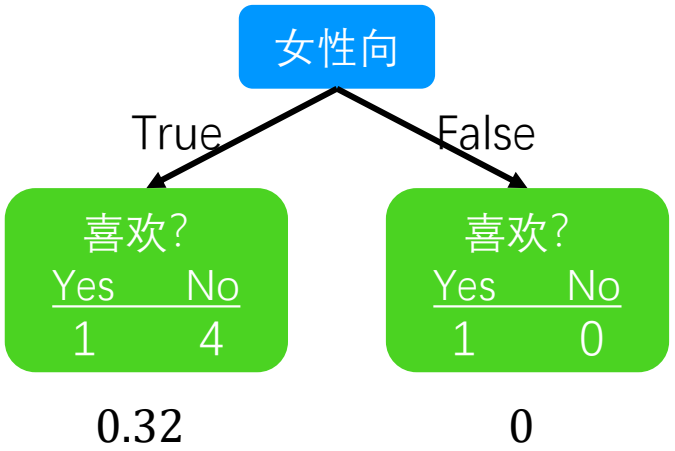

① 排序 ② 计算平均年份

③ 确定最低指数

2009	0.400
2010.5	0.417
2012	0.444
2015.5	0.333
2019	0.400

基尼指数 = 0.333

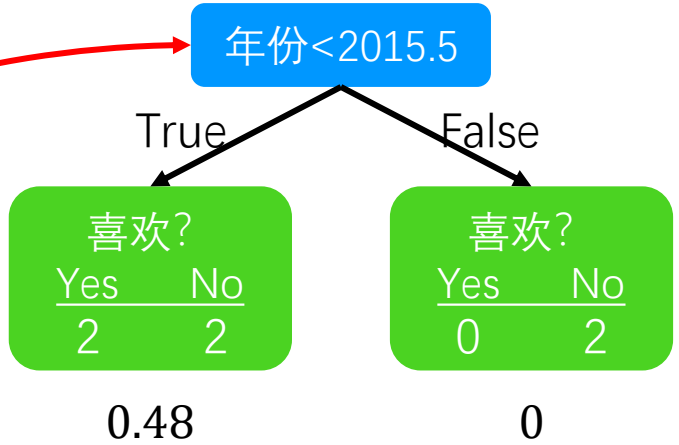

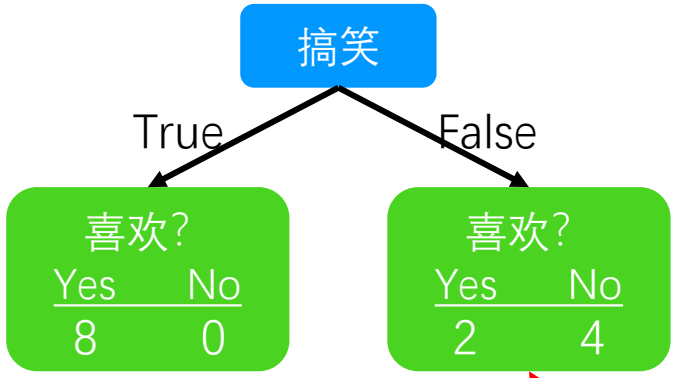

作品名	热血	女性向	年份	喜欢
进击的巨人	是	否	2013	Y
薄樱鬼	是	是	2010	Y
魔道祖师	是	是	2018	N
纯情罗曼史	否	是	2008	N
世界第一初恋	否	是	2011	N
恋与制作人	否	是	2020	N

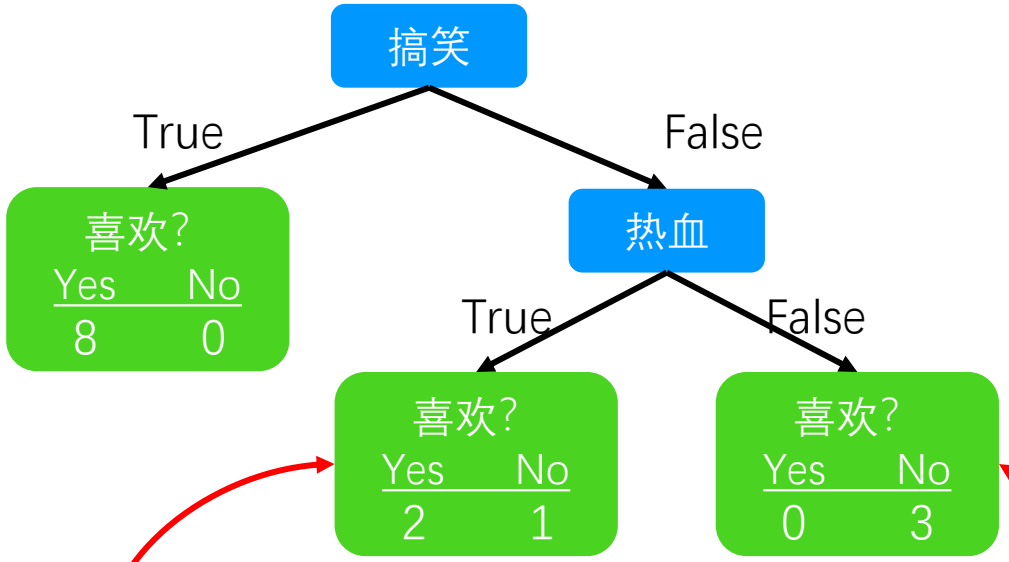

基尼指数 = 0
没有歧义

以相同的逻辑确定子子树根

作品名	女性向	年份	喜欢
薄樱鬼	是	2010	Y
进击的巨人	否	2013	Y
魔道祖师	是	2018	N

作品名	女性向	年份	喜欢
纯情罗曼史	是	2008	N
世界第一初恋	是	2011	N
恋与制作人	是	2020	N

作品名	女性向	年份	喜欢
薄樱鬼	是	2010	Y
进击的巨人	否	2013	Y
魔道祖师	是	2018	N

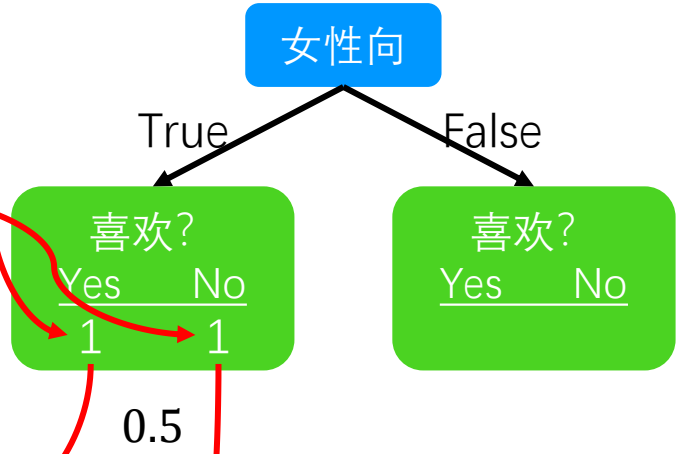

0.5

$$基尼指数 = 1 - (“Yes”所占比例)^2 - (“No”所占比例)^2$$

$$= 1 - \left(\frac{1}{1+1}\right)^2 - \left(\frac{1}{1+1}\right)^2$$

$$= 0.5$$

作品名	女性向	年份	喜欢
薄樱鬼	是	2010	Y
进击的巨人	否	2013	Y
魔道祖师	是	2018	N

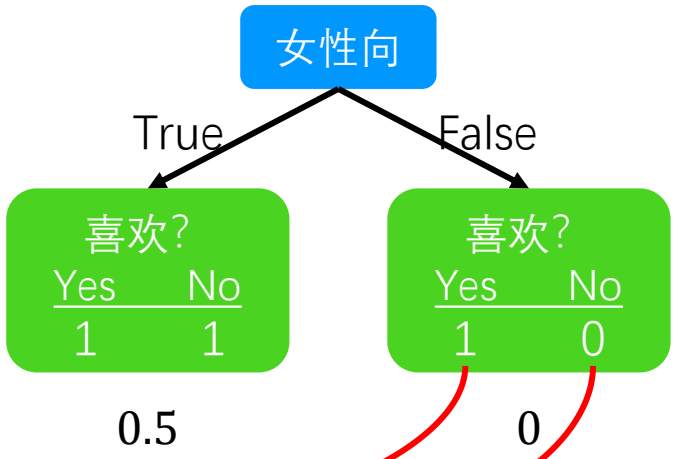

$$基尼指数 = 1 - (“Yes”所占比例)^2 - (“No”所占比例)^2$$

$$= 1 - \left(\frac{1}{1+0}\right)^2 - \left(\frac{0}{1+0}\right)^2$$

$$= 0$$

作品名	女性向	年份	喜欢
薄樱鬼	是	2010	Y
进击的巨人	否	2013	Y
魔道祖师	是	2018	N

基尼指数 = 0.333

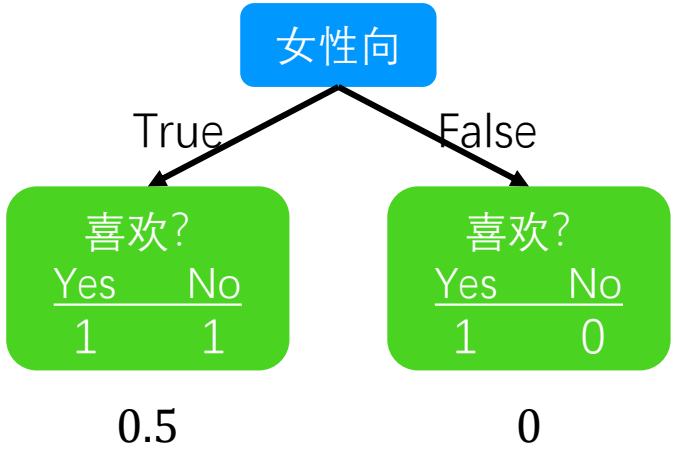

$$\text{整体基尼指数} = w_{left}G(\text{左叶子节点}) + w_{right}G(\text{右叶子节点})$$

$$= \left(\frac{2}{2+1}\right) \times 0.5 + \left(\frac{1}{2+1}\right) \times 0$$

$$= 0.333$$

作品名	女性向	年份	喜欢
薄樱鬼	是	2010	Y
进击的巨人	否	2013	Y
魔道祖师	是	2018	N

按年份排序

作品名	女性向	年份	喜欢
薄樱鬼	是	2010	Y
进击的巨人	否	2013	Y
魔道祖师	是	2018	N

2011.5 → 0.333

2015.5 → 0

基尼指数 = 0.333

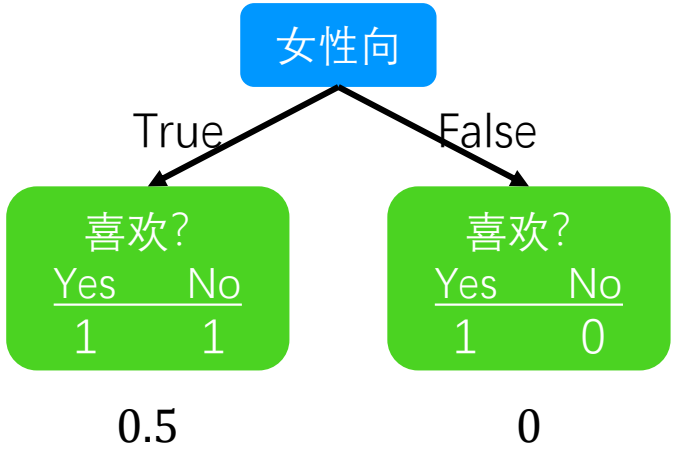

以“年份<2015.5”作为子树根

基尼指数 = 0

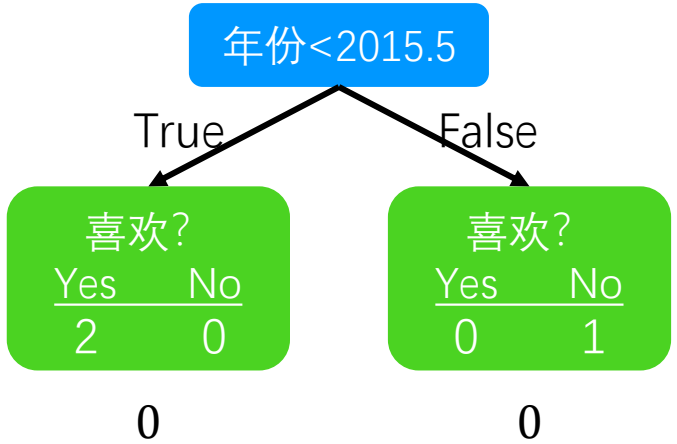

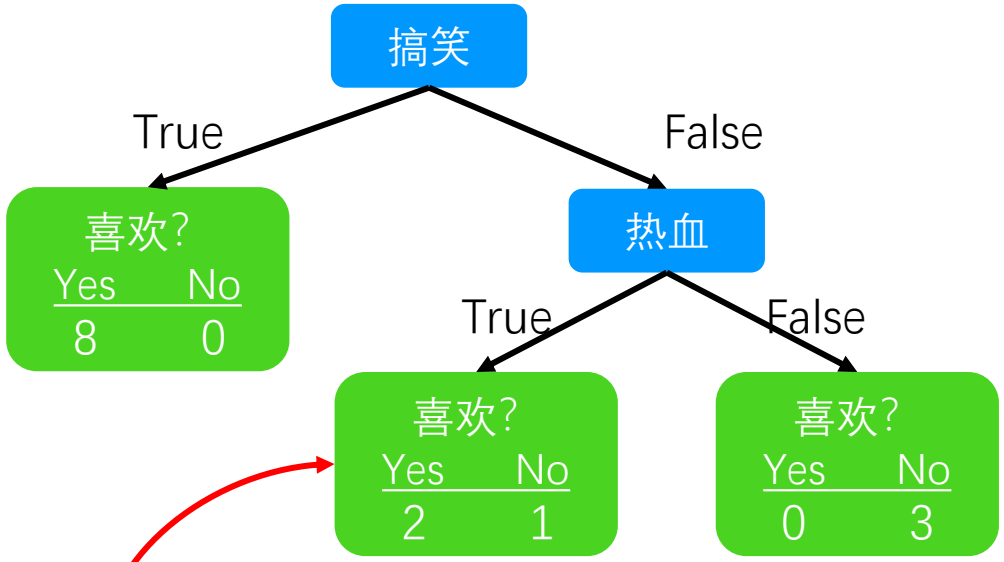

作品名	女性向	年份	喜欢
薄樱鬼	是	2010	Y
进击的巨人	否	2013	Y
魔道祖师	是	2018	N

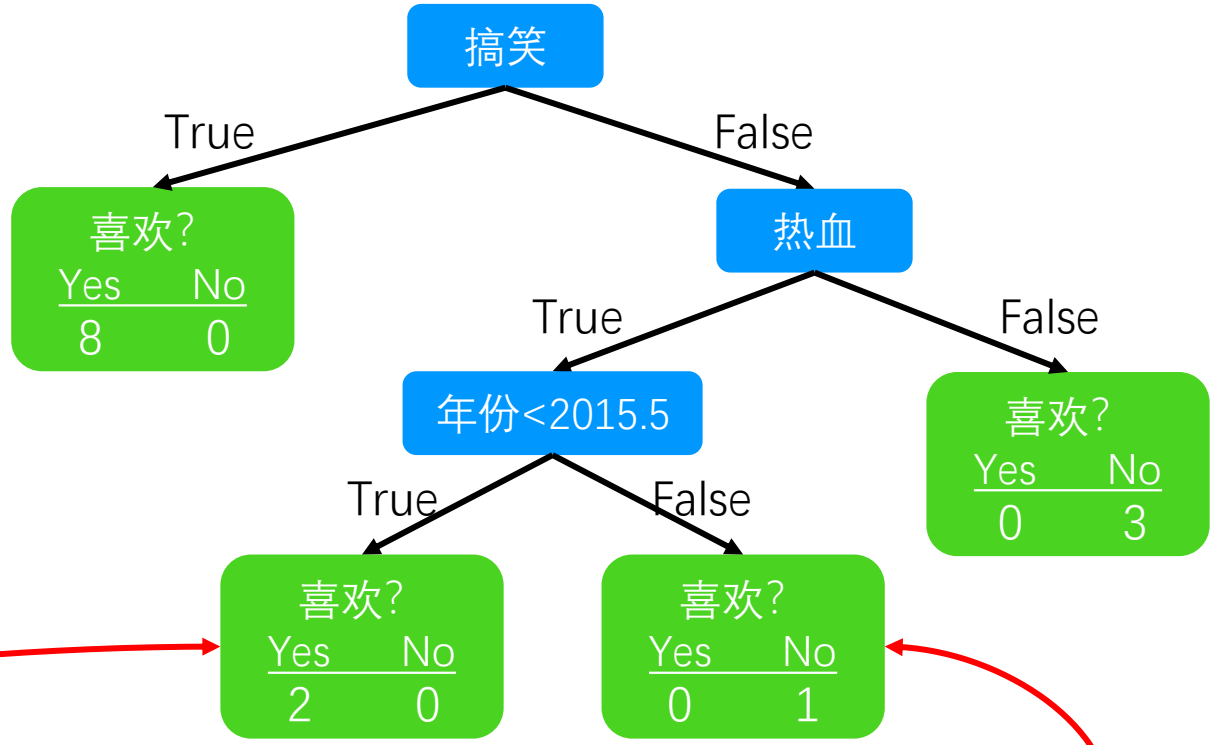

作品名	女性向	喜欢
薄樱鬼	是	Y
进击的巨人	否	Y

作品名	女性向	喜欢
魔道祖师	是	N

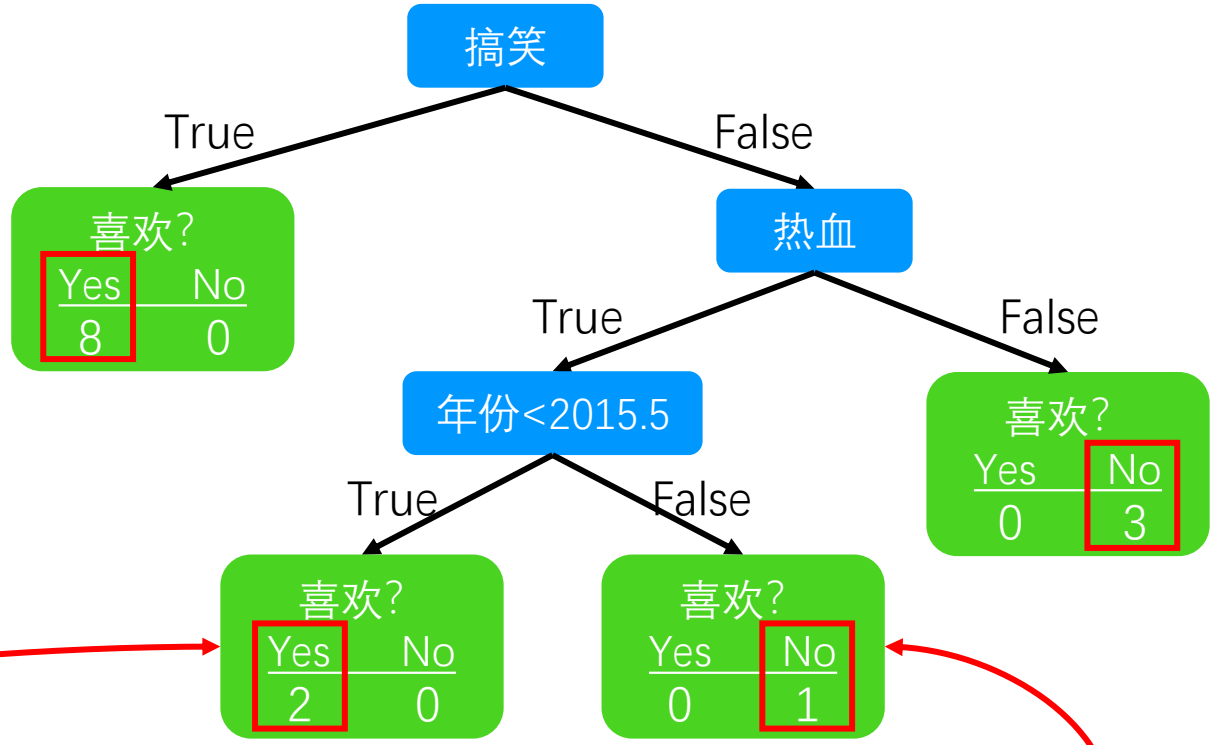

作品名	女性向	喜欢
薄樱鬼	是	Y
进击的巨人	否	Y

为每个叶子节点附上类别

作品名	女性向	喜欢
魔道祖师	是	N

使用此决策树推荐作品

作品名	搞笑	热血	女性向	年份	喜欢
关于我转生变成史莱姆这档事 第三季	是	否	否	2024	Y
我会招架一切 反误会的世界最强想成为冒险者	否	是	否	2024	N
Love Live! Super Star!! 第三季	否	否	是	2024	N

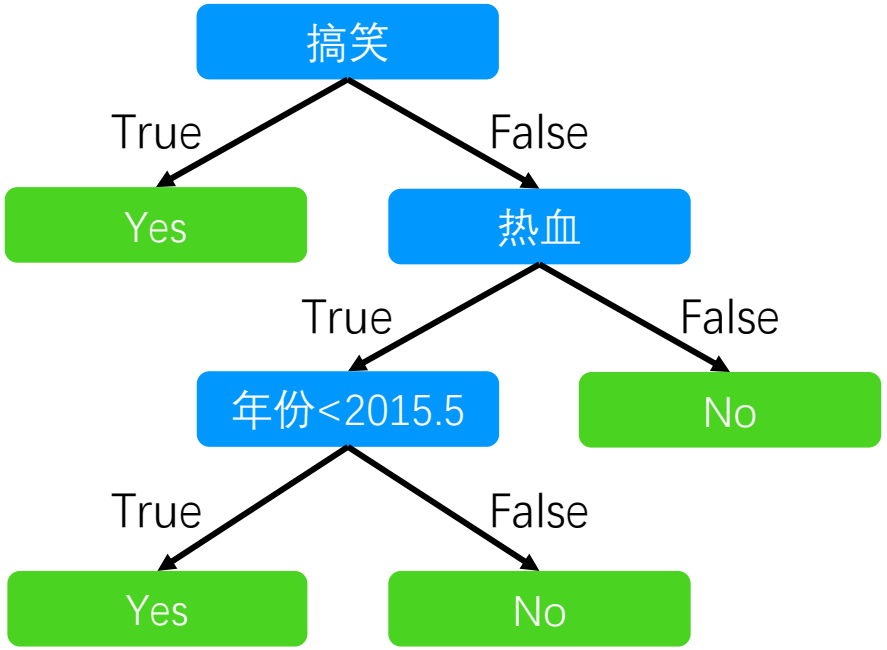

构建决策树的算法

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

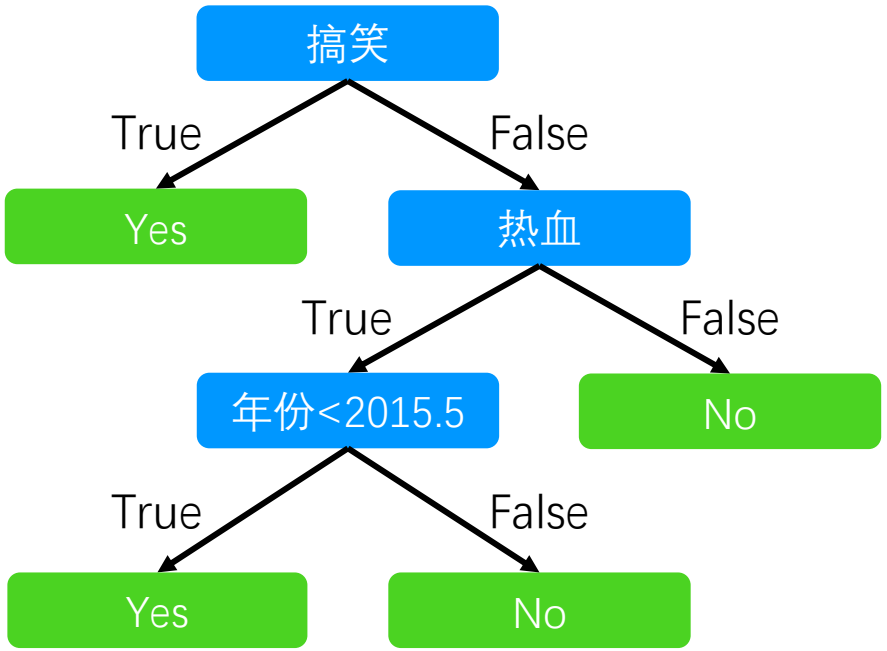

① 计算各个特征的基尼指数

② 基尼指数最低的特征作为根节点

③ 循环执行①和②至满足叶子节点条件则结束

决策树如何进行多分类问题?

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	1
碧蓝之海	是	是	否	2018	2
十万个冷笑话	是	否	否	2012	1
狐妖小红娘	是	否	否	2015	1
仙王的日常生活	是	否	否	2020	1
关于我转生变成史莱姆这档事	是	否	否	2018	2
进击的巨人	否	是	否	2013	2
樱兰高校男公关部	是	否	是	2008	1
薄樱鬼	否	是	是	2010	1
魔道祖师	否	是	是	2018	0
纯情罗曼史	否	否	是	2008	0
世界第一初恋	否	否	是	2011	0
恋与制作人	否	否	是	2020	0
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	1

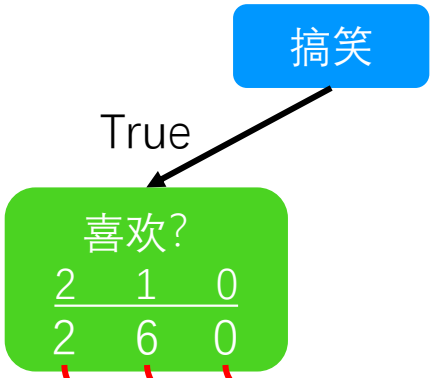

$$基尼指数 = 1 - (“2”占比)^2 - (“1”占比)^2 - (“0”占比)^2$$

$$= 1 - \left(\frac{2}{8}\right)^2 - \left(\frac{6}{8}\right)^2 - \left(\frac{0}{8}\right)^2$$

① 计算各个特征的基尼指数

决策树如何进行多分类问题?

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	1
碧蓝之海	是	是	否	2018	2
十万个冷笑话	是	否	否	2012	1
狐妖小红娘	是	否	否	2015	1
仙王的日常生活	是	否	否	2020	1
关于我转生变成史莱姆这档事	是	否	否	2018	2
进击的巨人	否	是	否	2013	2
樱兰高校男公关部	是	否	是	2008	1
薄樱鬼	否	是	是	2010	1
魔道祖师	否	是	是	2018	0
纯情罗曼史	否	否	是	2008	0
世界第一初恋	否	否	是	2011	0
恋与制作人	否	否	是	2020	0
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	1

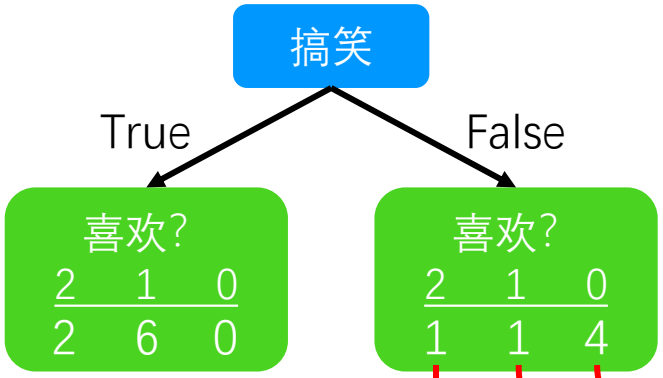

基尼指数=0.375　　0.5

$$\text{基尼指数} = 1 - (\text{“2”占比})^2 - (\text{“1”占比})^2 - (\text{“0”占比})^2$$

$$= 1 - \left(\frac{1}{6}\right)^2 - \left(\frac{1}{6}\right)^2 - \left(\frac{4}{6}\right)^2$$

$$= 0.5$$

① 计算各个特征的基尼指数

决策树如何进行多分类问题?

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	1
碧蓝之海	是	是	否	2018	2
十万个冷笑话	是	否	否	2012	1
狐妖小红娘	是	否	否	2015	1
仙王的日常生活	是	否	否	2020	1
关于我转生变成史莱姆这档事	是	否	否	2018	2
进击的巨人	否	是	否	2013	2
樱兰高校男公关部	是	否	是	2008	1
薄樱鬼	否	是	是	2010	1
魔道祖师	否	是	是	2018	0
纯情罗曼史	否	否	是	2008	0
世界第一初恋	否	否	是	2011	0
恋与制作人	否	否	是	2020	0
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	1

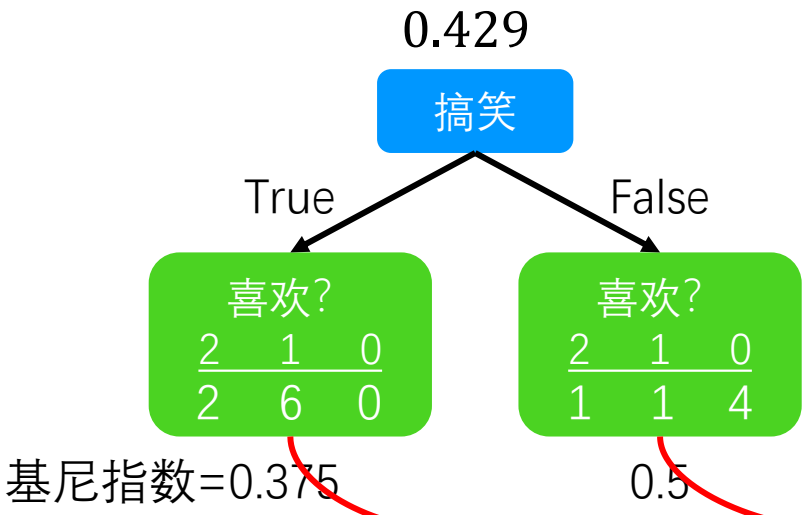

$$\text{整体基尼指数} = w_{left}G(\text{左叶子节点}) + w_{right}G(\text{右叶子节点})$$

$$= \left(\frac{8}{8+6}\right) \times 0.375 + \left(\frac{6}{8+6}\right) \times 0.5$$

$$= 0.429$$

① 计算各个特征的基尼指数

决策树如何进行多分类问题?

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	1
碧蓝之海	是	是	否	2018	2
十万个冷笑话	是	否	否	2012	1
狐妖小红娘	是	否	否	2015	1
仙王的日常生活	是	否	否	2020	1
关于我转生变成史莱姆这档事	是	否	否	2018	2
进击的巨人	否	是	否	2013	2
樱兰高校男公关部	是	否	是	2008	1
薄樱鬼	否	是	是	2010	1
魔道祖师	否	是	是	2018	0
纯情罗曼史	否	否	是	2008	0
世界第一初恋	否	否	是	2011	0
恋与制作人	否	否	是	2020	0
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	1

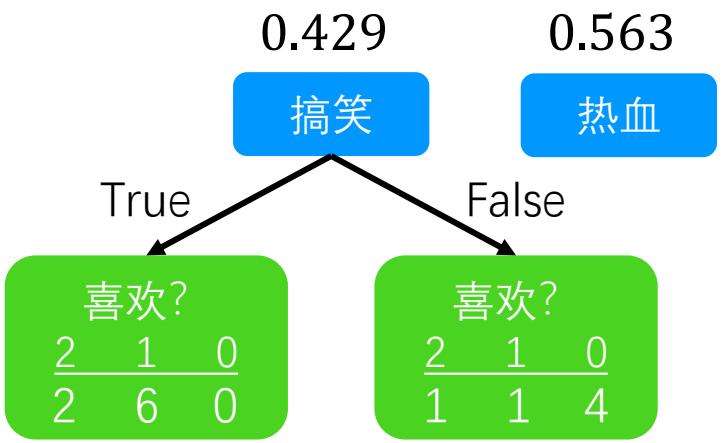

① 计算各个特征的基尼指数

决策树如何进行多分类问题?

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	1
碧蓝之海	是	是	否	2018	2
十万个冷笑话	是	否	否	2012	1
狐妖小红娘	是	否	否	2015	1
仙王的日常生活	是	否	否	2020	1
关于我转生变成史莱姆这档事	是	否	否	2018	2
进击的巨人	否	是	否	2013	2
樱兰高校男公关部	是	否	是	2008	1
薄樱鬼	否	是	是	2010	1
魔道祖师	否	是	是	2018	0
纯情罗曼史	否	否	是	2008	0
世界第一初恋	否	否	是	2011	0
恋与制作人	否	否	是	2020	0
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	1

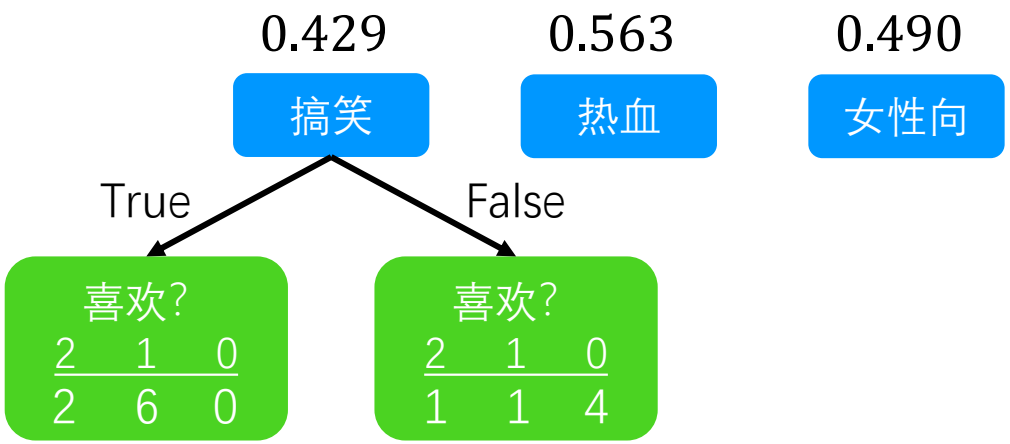

① 计算各个特征的基尼指数

决策树如何进行多分类问题?

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	1
碧蓝之海	是	是	否	2018	2
十万个冷笑话	是	否	否	2012	1
狐妖小红娘	是	否	否	2015	1
仙王的日常生活	是	否	否	2020	1
关于我转生变成史莱姆这档事	是	否	否	2018	2
进击的巨人	否	是	否	2013	2
樱兰高校男公关部	是	否	是	2008	1
薄樱鬼	否	是	是	2010	1
魔道祖师	否	是	是	2018	0
纯情罗曼史	否	否	是	2008	0
世界第一初恋	否	否	是	2011	0
恋与制作人	否	否	是	2020	0
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	1

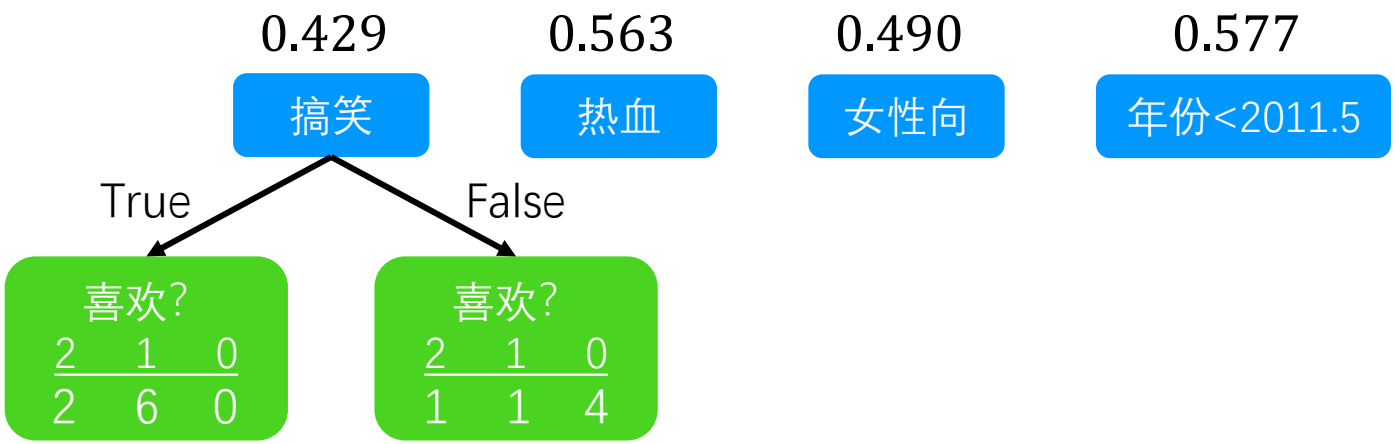

① 计算各个特征的基尼指数

决策树如何进行多分类问题?

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	1
碧蓝之海	是	是	否	2018	2
十万个冷笑话	是	否	否	2012	1
狐妖小红娘	是	否	否	2015	1
仙王的日常生活	是	否	否	2020	1
关于我转生变成史莱姆这档事	是	否	否	2018	2
进击的巨人	否	是	否	2013	2
樱兰高校男公关部	是	否	是	2008	1
薄樱鬼	否	是	是	2010	1
魔道祖师	否	是	是	2018	0
纯情罗曼史	否	否	是	2008	0
世界第一初恋	否	否	是	2011	0
恋与制作人	否	否	是	2020	0
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	1

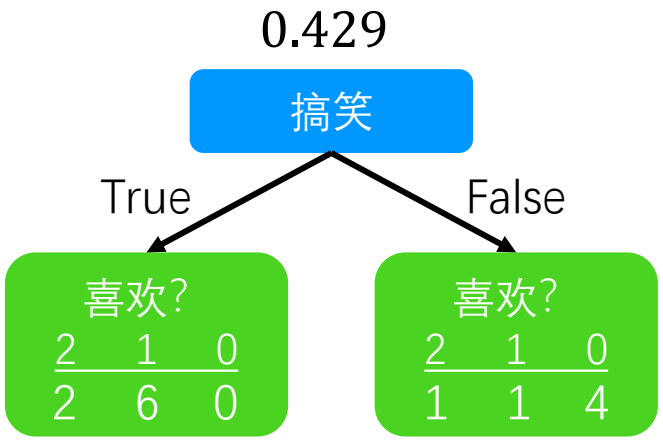

① 计算各个特征的基尼指数

② 基尼指数最低的特征作为根节点

③ 循环执行①和②至满足叶子节点条件则结束

决策树如何进行多分类问题?

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	1
碧蓝之海	是	是	否	2018	2
十万个冷笑话	是	否	否	2012	1
狐妖小红娘	是	否	否	2015	1
仙王的日常生活	是	否	否	2020	1
关于我转生变成史莱姆这档事	是	否	否	2018	2
进击的巨人	否	是	否	2013	2
樱兰高校男公关部	是	否	是	2008	1
薄樱鬼	否	是	是	2010	1
魔道祖师	否	是	是	2018	0
纯情罗曼史	否	否	是	2008	0
世界第一初恋	否	否	是	2011	0
恋与制作人	否	否	是	2020	0
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	1

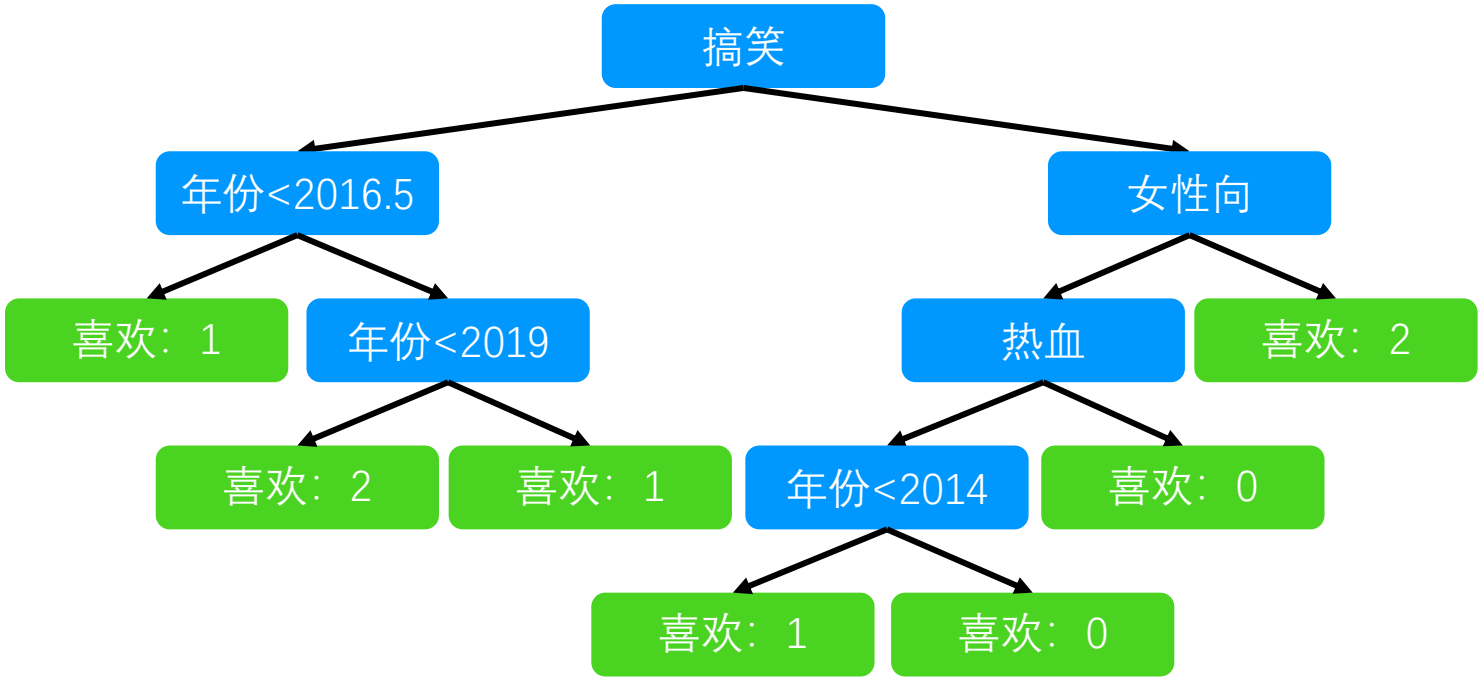

① 计算各个特征的基尼指数

② 基尼指数最低的特征作为根节点

③ 循环执行①和②至满足叶子节点条件则结束

决策树的优势

- 解释性强
- 无需对数据进行过多的预处理
- 可同时处理连续和离散数据
- 可自然处理缺失数据
- 可处理非线性关系数据
- 适用多类别任务
- 自然地衡量特征重要性

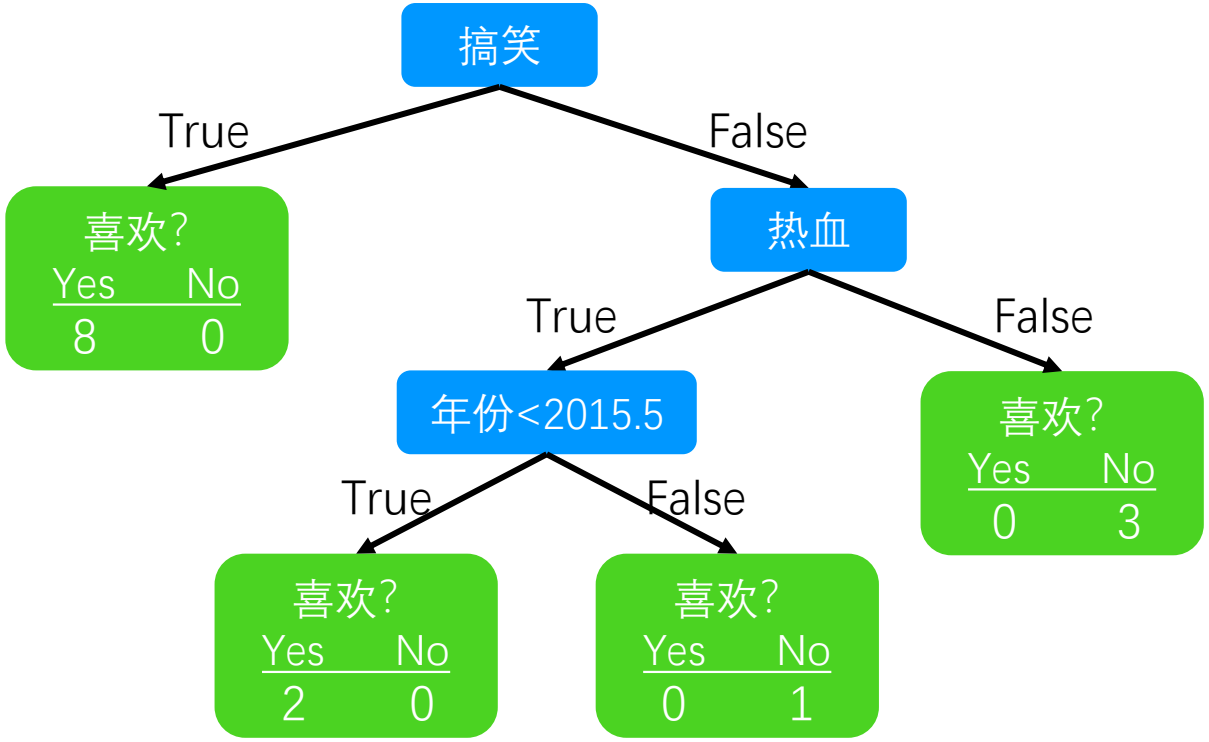

决策树的不足

- 容易发生过拟合

决策树的过拟合问题

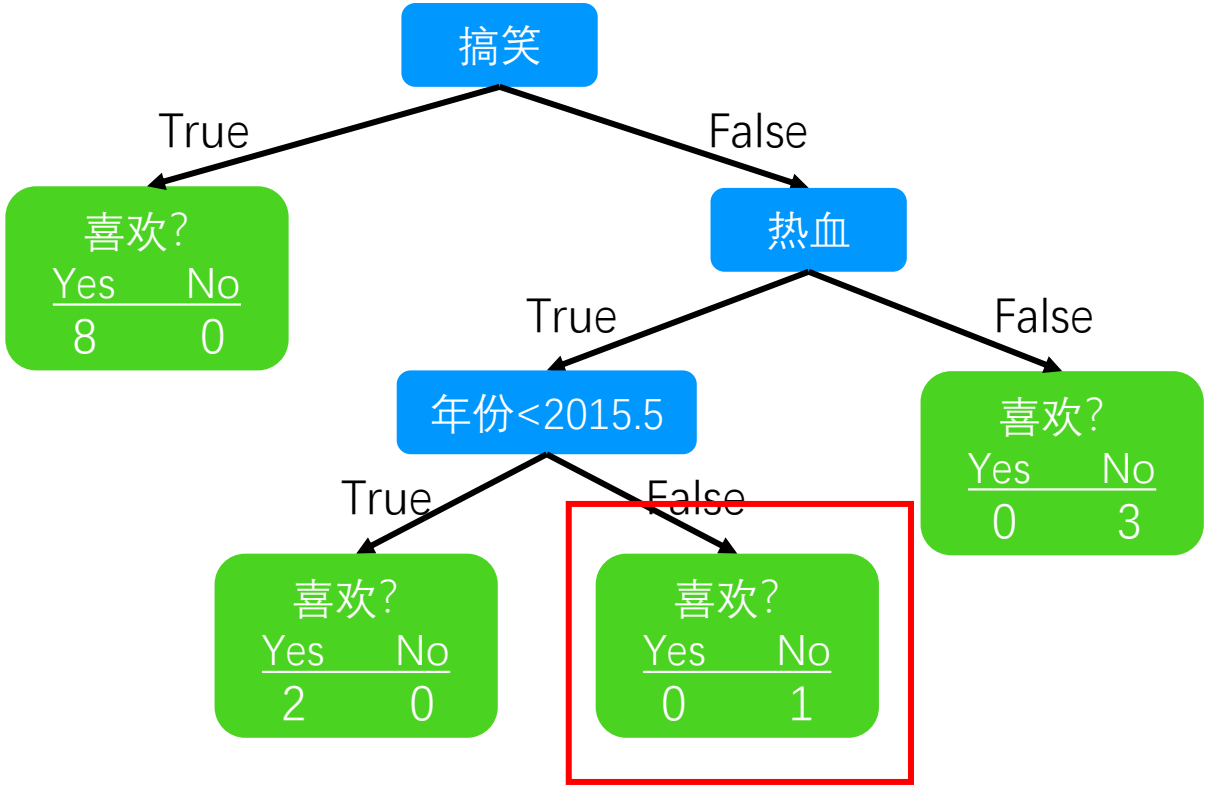

这种叶子节点中仅含 1 个样本

分类结果可信度不高

容易发生**过拟合**

决策树的过拟合问题

一种最简单的避免过拟合方法……

限制叶节点中的样本数量

样本数量不低于 K

例，当 K=3

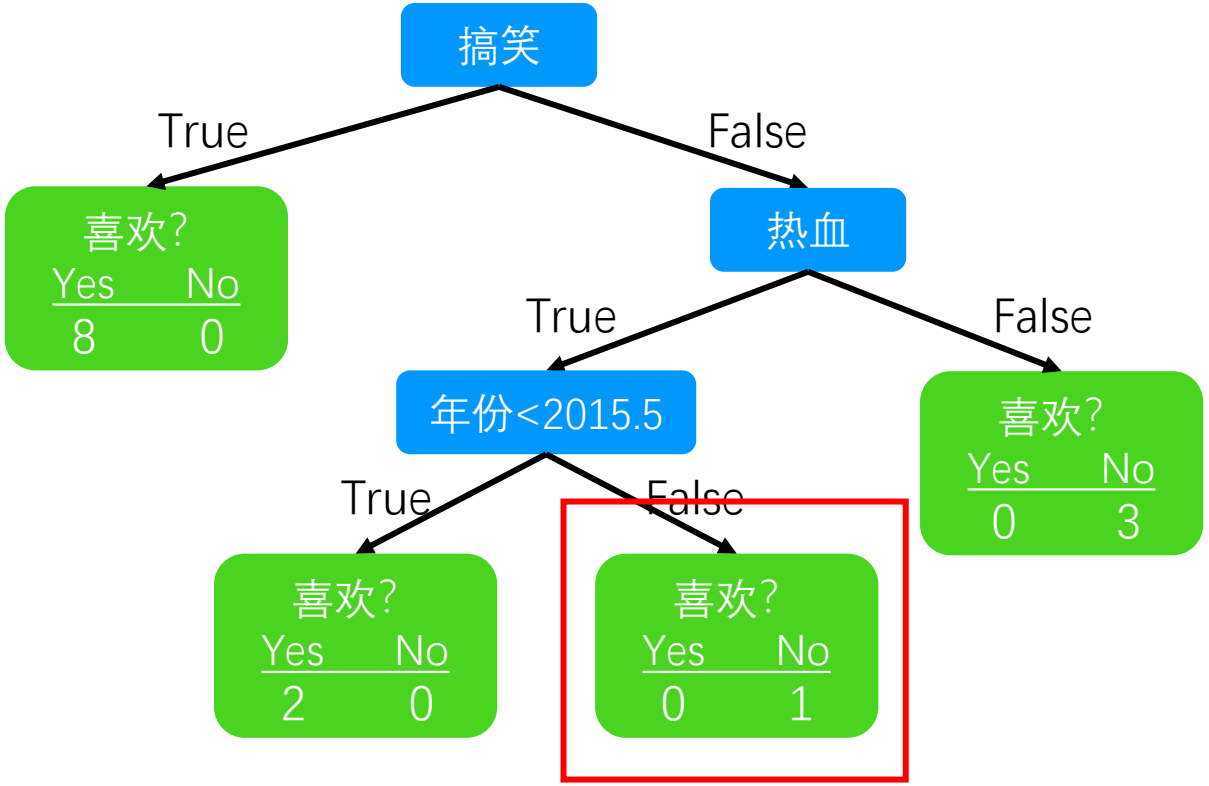

低于 K，应合并

“多数”作为类别

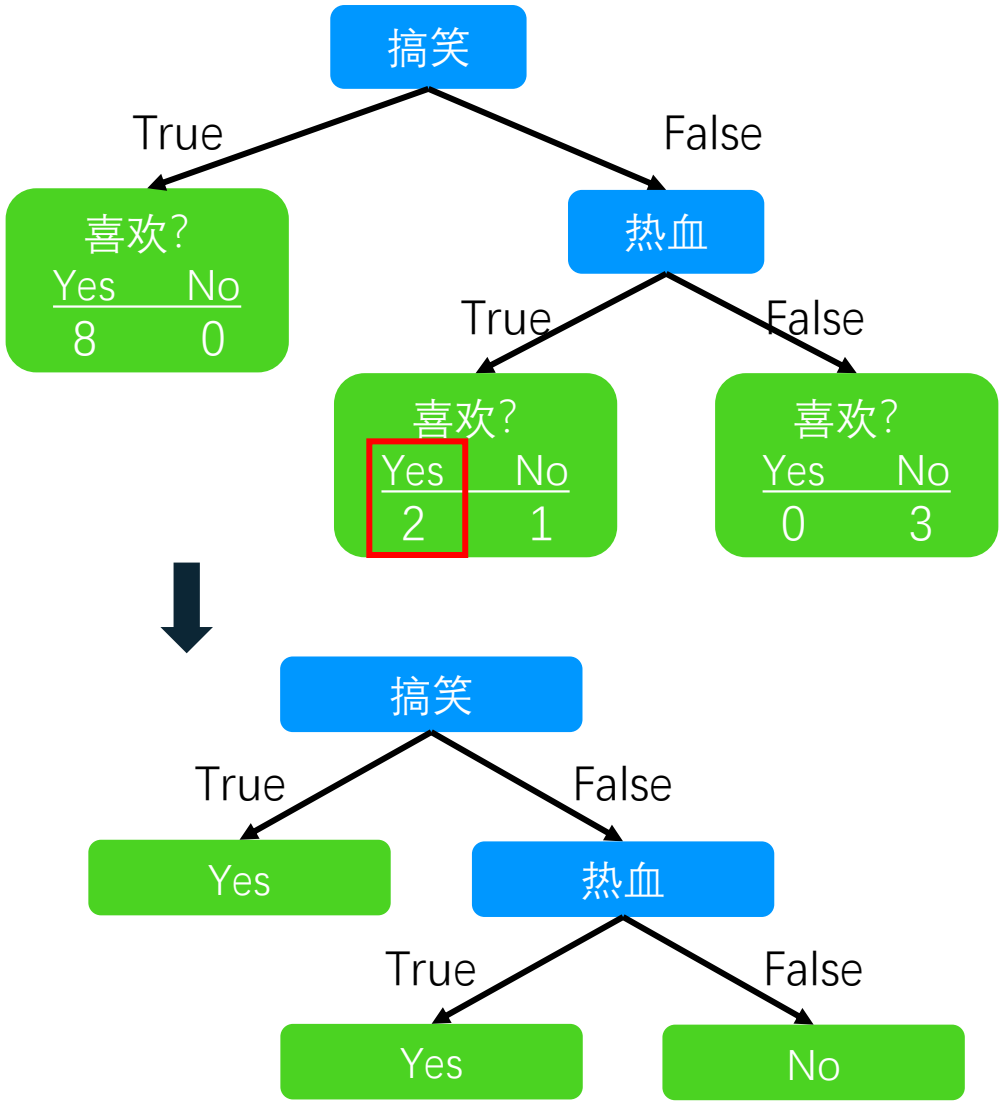
搞笑
True
False
喜欢?
Yes No
8 0
热血
True
False
喜欢?
Yes No
2 1
喜欢?
Yes No
0 3
搞笑
True
False
Yes
热血
True
False
Yes
No

限制前分类结果

作品名	搞笑	热血	女性向	年份	喜欢
关于我转生变成史莱姆这档事 第三季	是	否	否	2024	Y
我会招架一切反误会的世界最强想成为冒险者	否	是	否	2024	N
Love Live! Super Star!! 第三季	否	否	是	2024	N

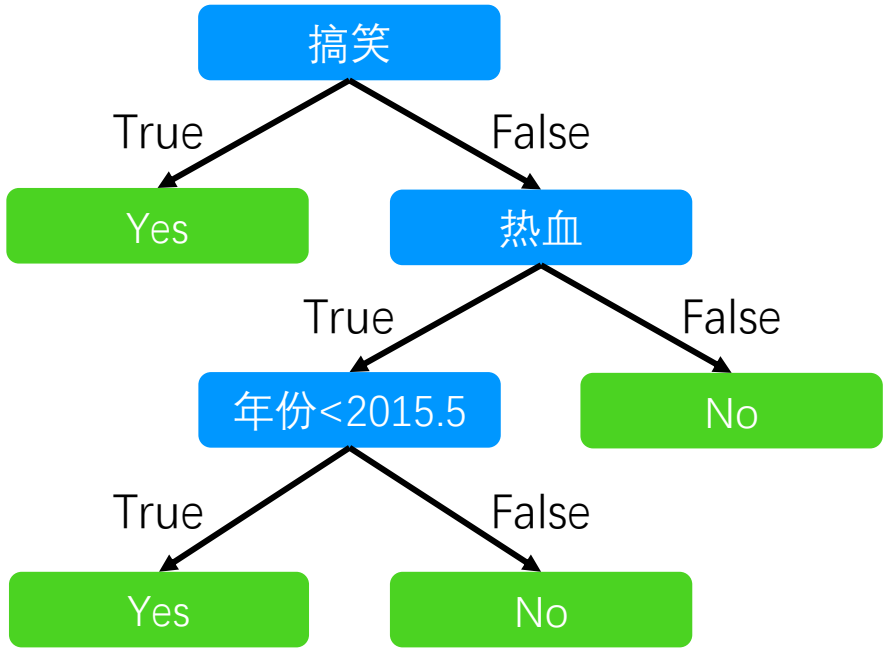

限制后分类结果

作品名	搞笑	热血	女性向	年份	喜欢
关于我转生变成史莱姆这档事 第三季	是	否	否	2024	Y
我会招架一切反误会的世界最强想成为冒险者	否	是	否	2024	Y
Love Live! Super Star!! 第三季	否	否	是	2024	N

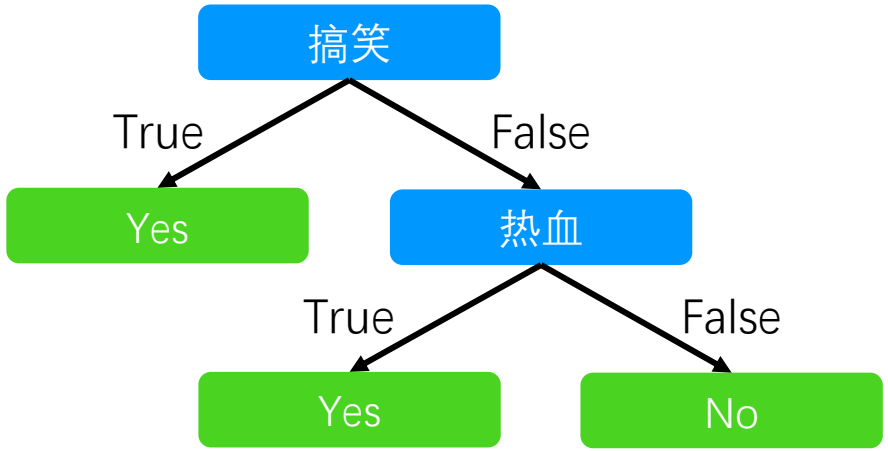

随机森林

更多的决策树意味着更强

如何构建随机森林呢？ —— Bagging

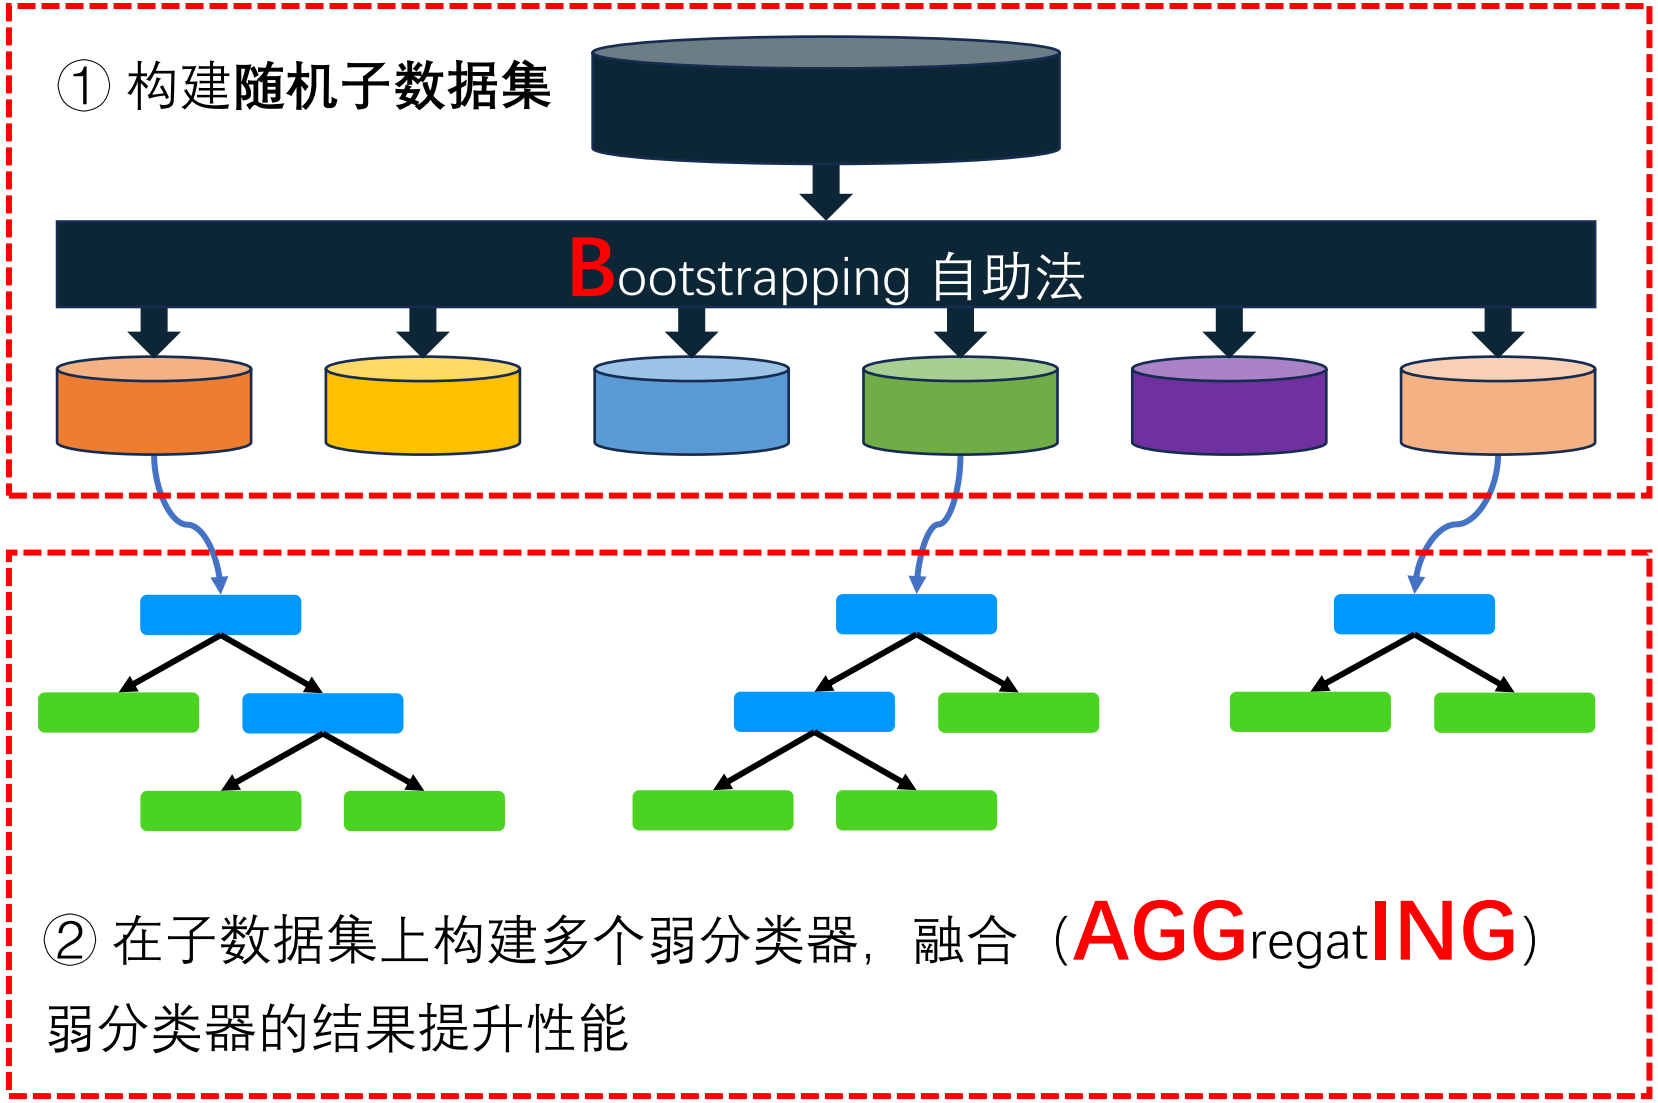

如何构建随机森林呢？ —— Bagging + 随机特征

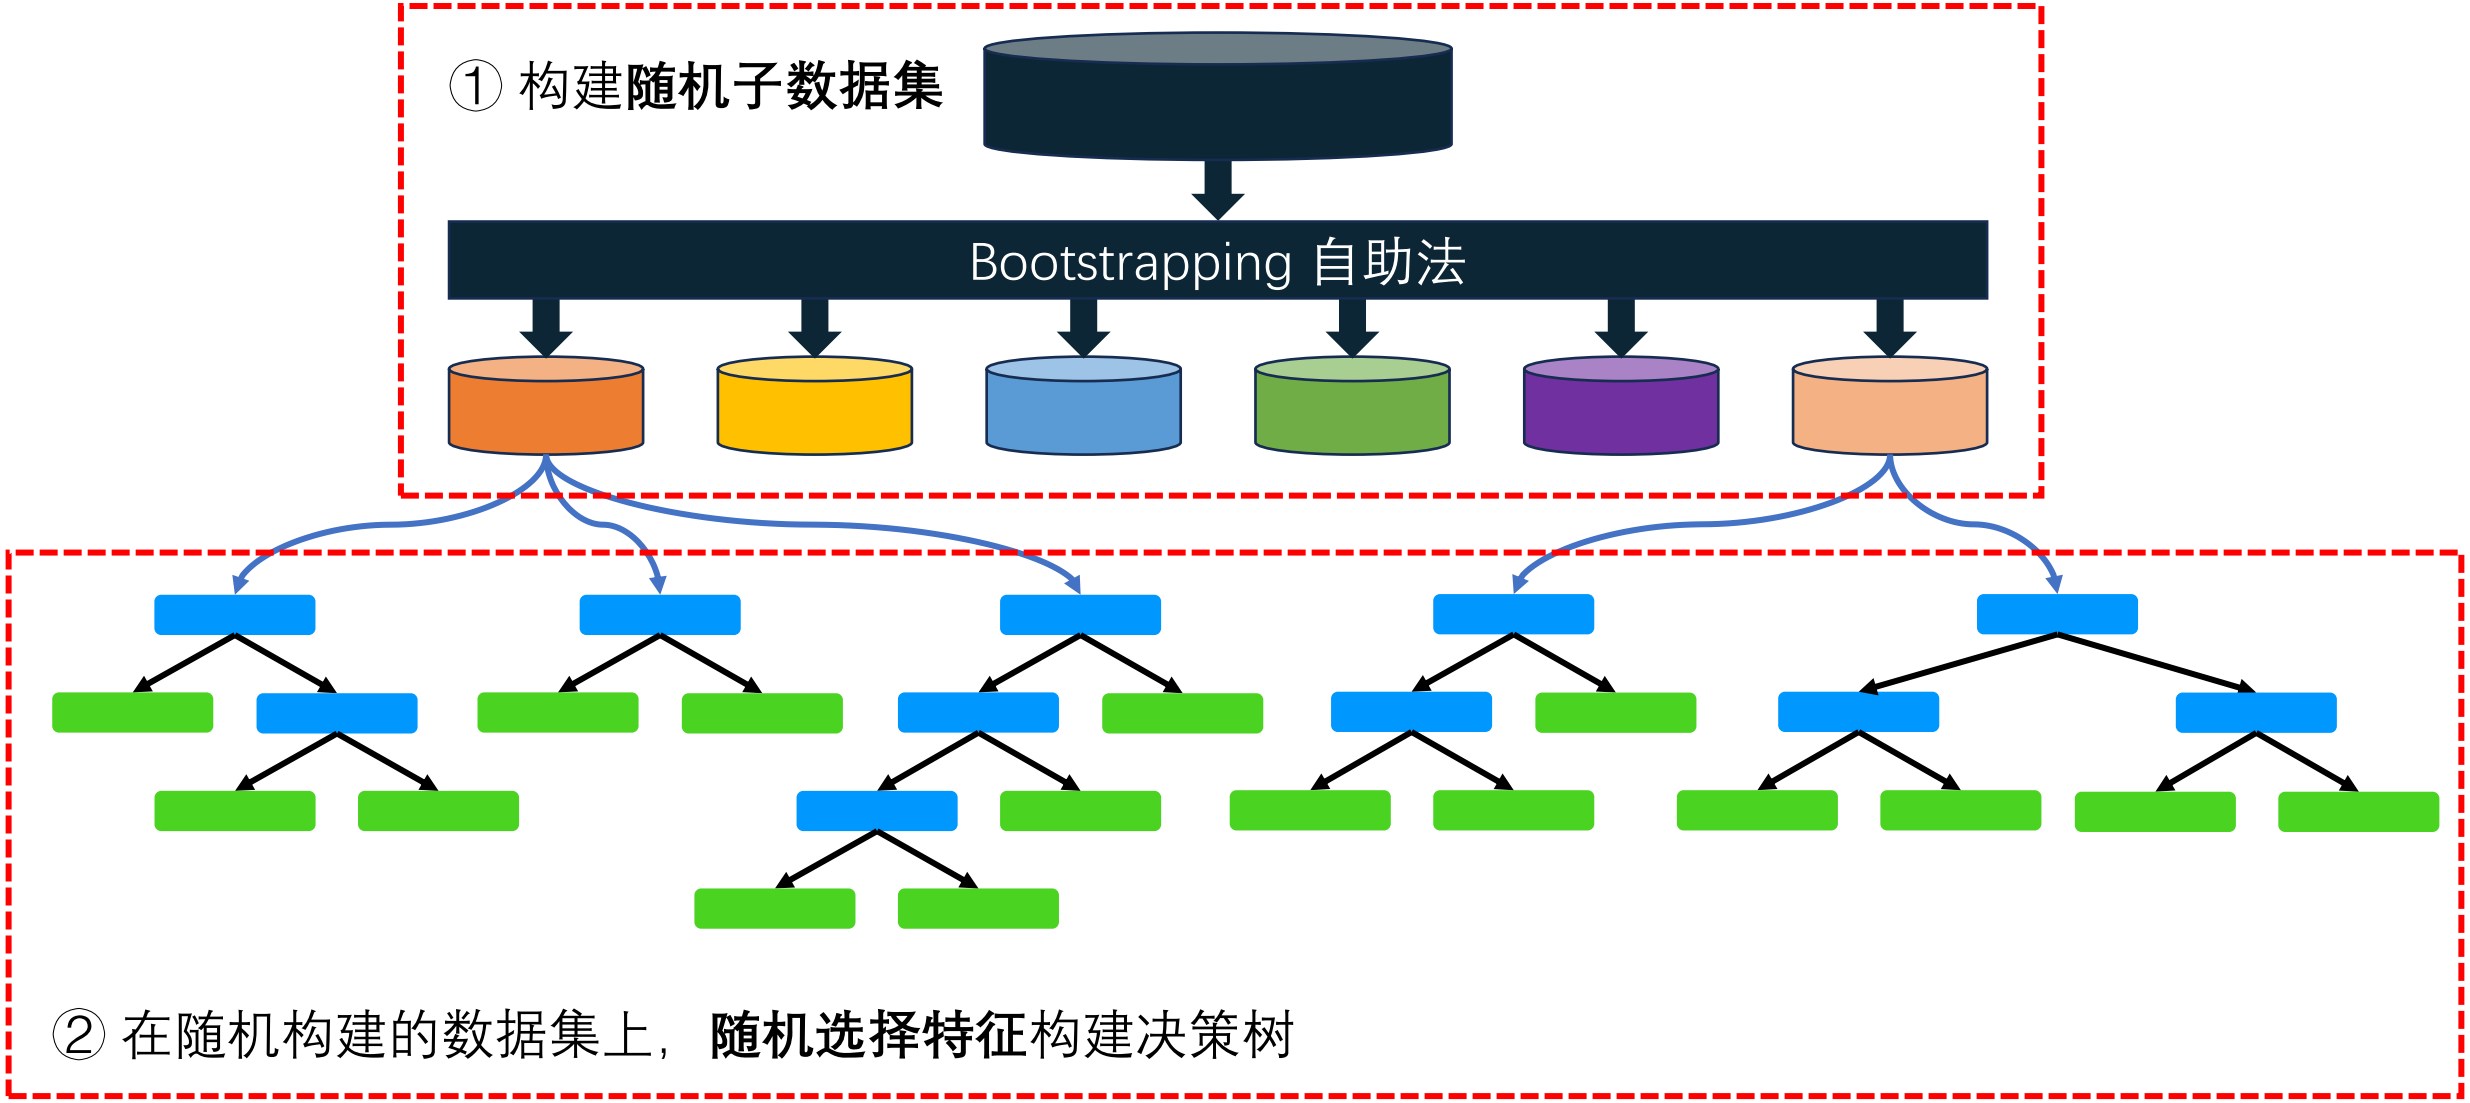

如何构建随机森林呢？ ① 构建随机子数据集

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
碧蓝之海	是	是	否	2018	Y

如何构建随机森林呢？ ① 构建随机子数据集

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
恋与制作人	否	否	是	2020	N
转生成为了只有乙女游戏破灭Flag的邪恶大小姐	是	否	是	2020	Y

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
碧蓝之海	是	是	否	2018	Y

作品名	搞笑	热血	女性向	年份	喜欢
仙王的日常生活	是	否	否	2020	Y
十万个冷笑话	是	否	否	2012	Y
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
魔道祖师	否	是	是	2018	N
魔道祖师	否	是	是	2018	N

如何构建随机森林呢？ ② 随机选择特征构建决策树

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
碧蓝之海	是	是	否	2018	Y

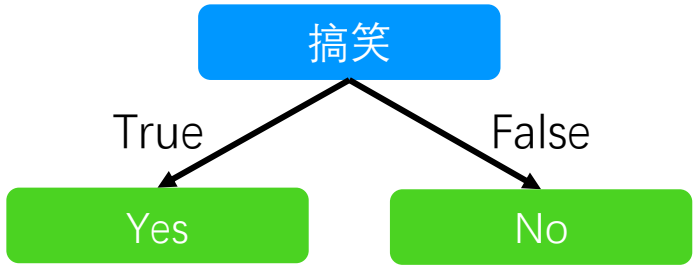

如何构建随机森林呢？ ② 随机选择特征构建决策树

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
碧蓝之海	是	是	否	2018	Y

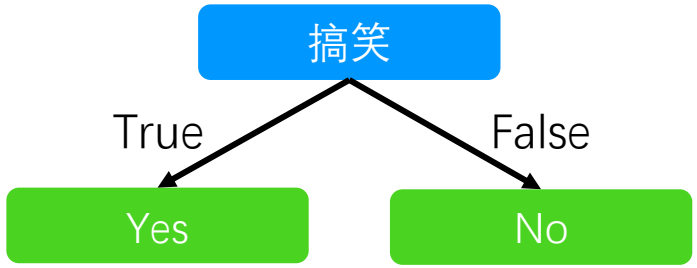

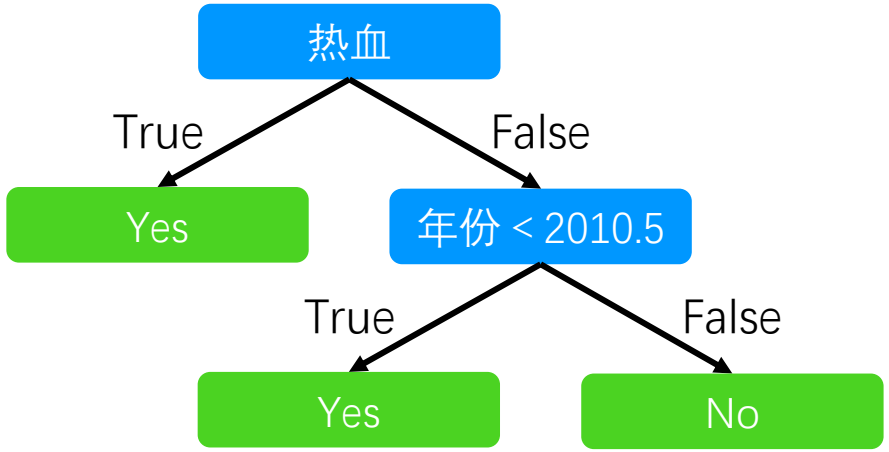

如何构建随机森林呢？ ② 随机选择特征构建决策树

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
樱兰高校男公关部	是	否	是	2008	Y
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N
碧蓝之海	是	是	否	2018	Y

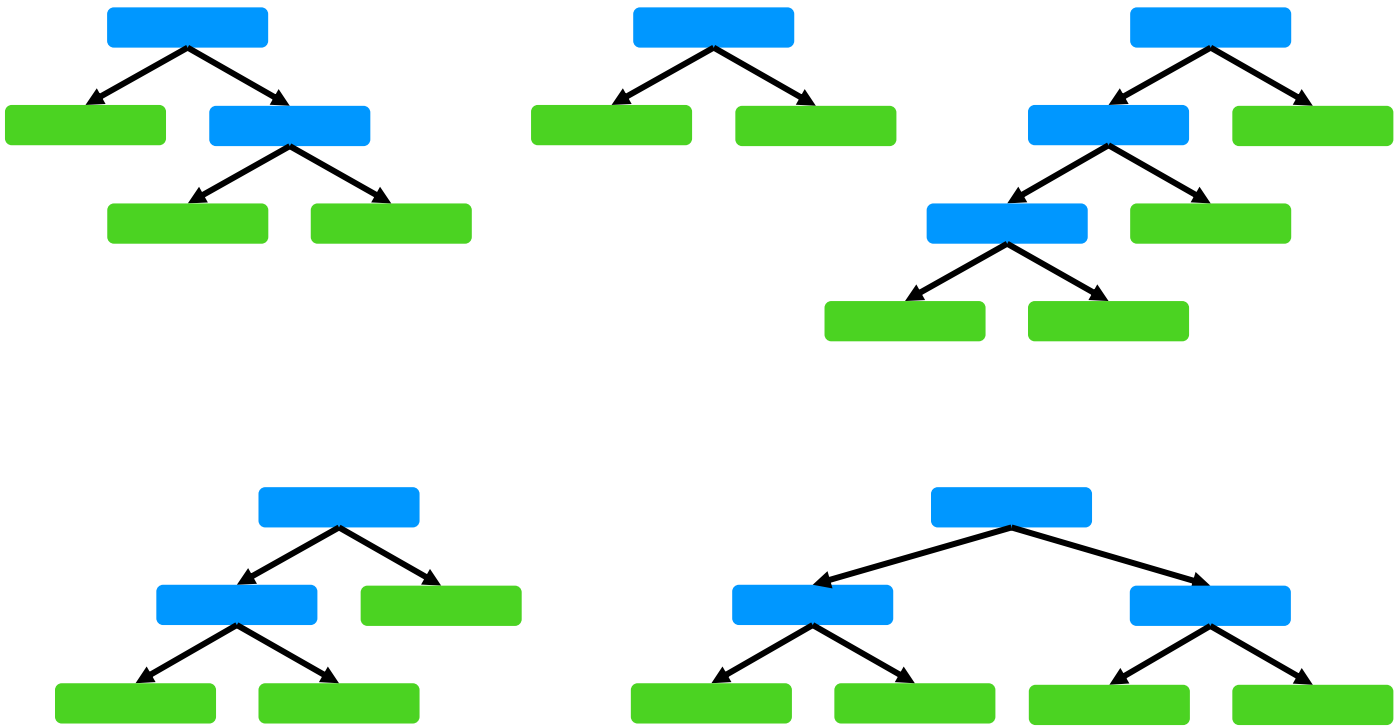

如何使用随机森林?

关于我转生变成史莱姆这档事 第三季	是	否	否	2024	Y

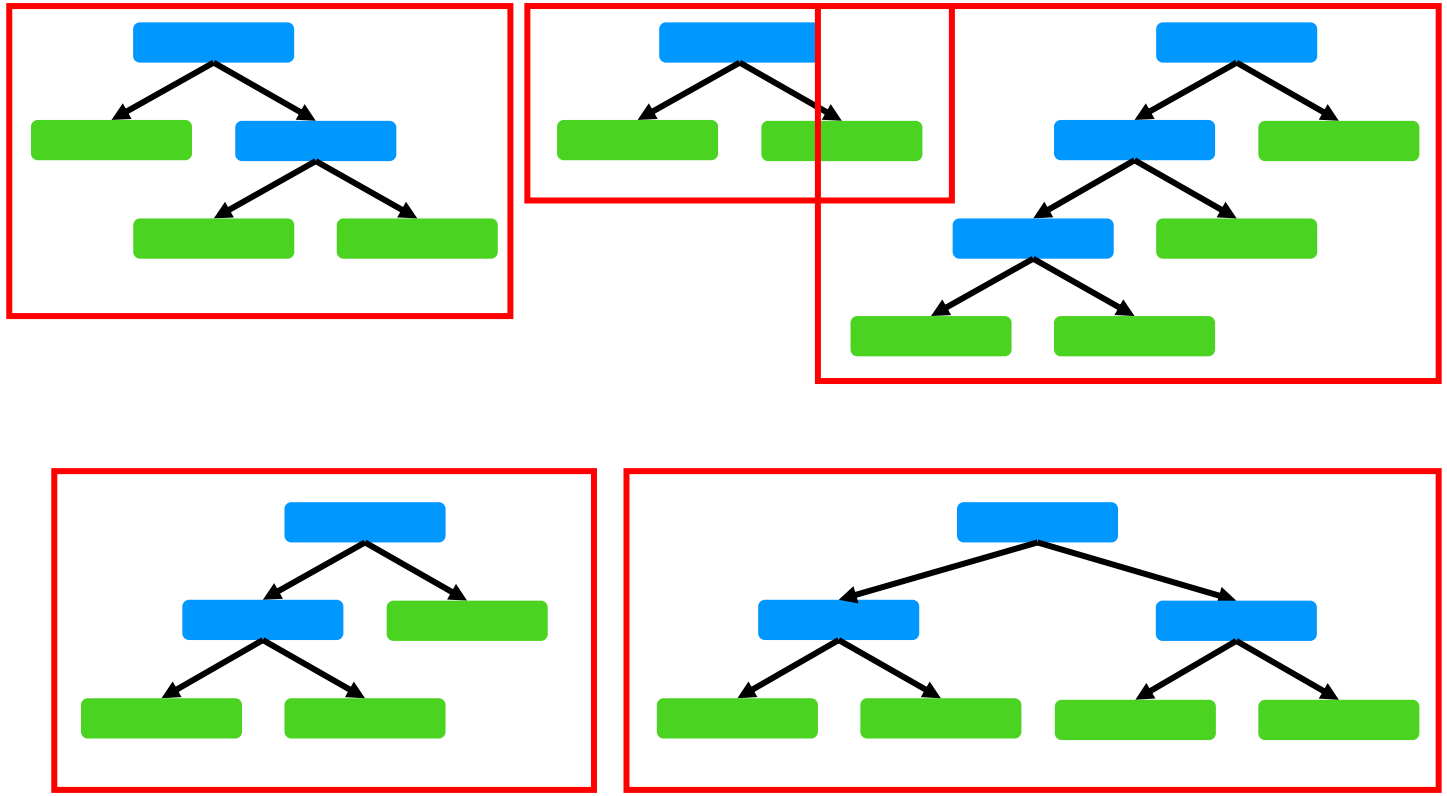

Yes：4

No：2

One More Thing

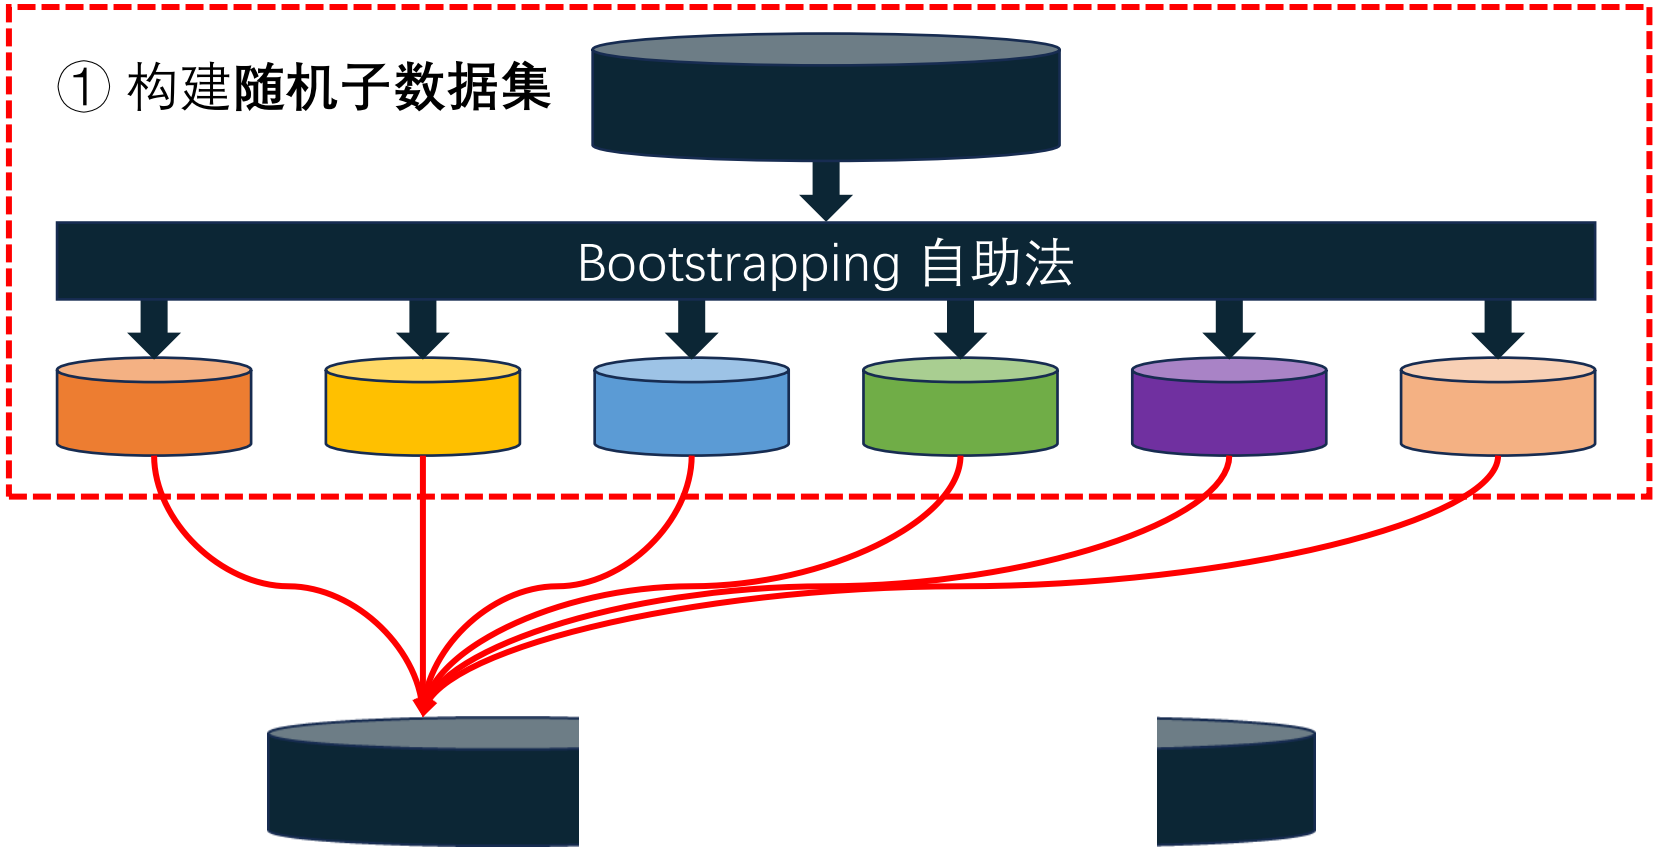

自助法仅用到约2/3的数据　　余下1/3的数据可用于交叉验证

随机森林的优势

- 通过构建多个不同的决策树并投票表决，可以降低过拟合的风险，使得模型更具泛化能力

- 通过随机选取样本和特征，极大的提高了模型的稳定性，减少了单一决策树所带来的随机性

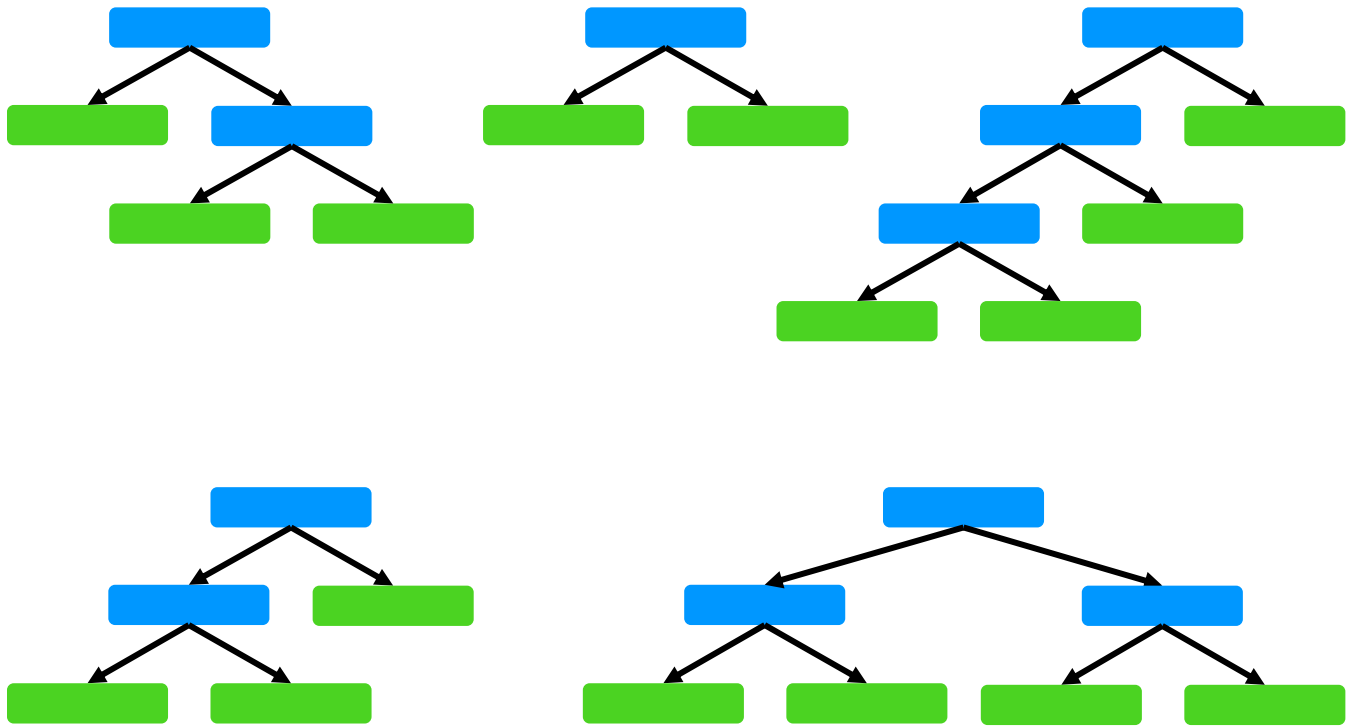

小结

决策树 Decision Tree

↓

通过基尼指数构建决策树

↓

随机森林 Random Forests