3.4 分类模型的度量

混淆矩阵 & 准确率 & 召回率

ROC曲线 & AUC

预测模型在实际应用中的关键能力

学习器在**新样本**上的误差称为“泛化误差”。显然，我们希望得到泛化误差小的学习器。（机器学习P23）

机器学习中的**泛化能力**（generalization ability）指的是模型在训练数据之外、在未见过的测试数据或真实世界数据上表现的能力。换句话说，泛化能力衡量模型从有限的训练数据中学到的知识是否能够有效地应用到新数据上。

在机器学习中，泛化能力（Generalization）指的是模型对未见过的数据进行预测的能力。一个具有良好泛化能力的模型能够从训练数据中学习到通用的规律，并且能够将这些规律应用到新的、未见过的数据上，从而做出准确的预测。

泛化能力是机器学习模型性能的关键指标之一，它与模型的过拟合（Overfitting）和欠拟合（Underfitting）密切相关：

如何评估预测模型的准确度?

不好描述 √ $$Loss = \frac{1}{2N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2$$

容易理解 √ $$prediction\ error = \frac{1}{N}\sum_{i=1}^{N}|\hat{y}_i - y_i|$$

举个栗子……

以下人物是否为男性？

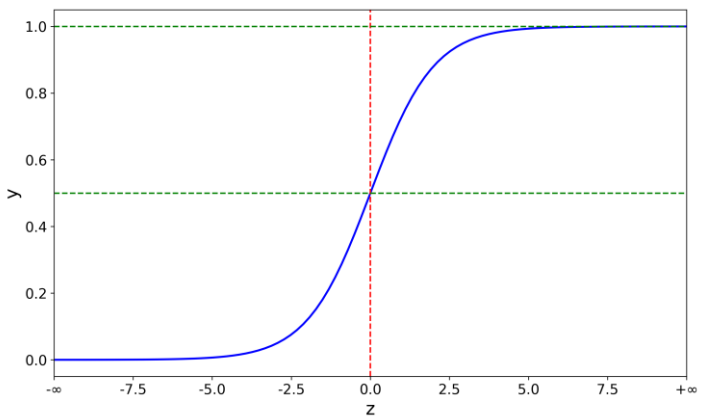

逻辑回归

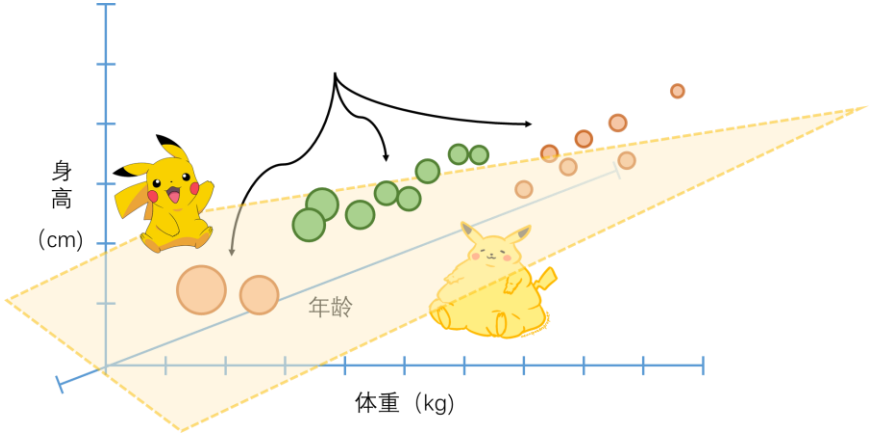

支持向量机

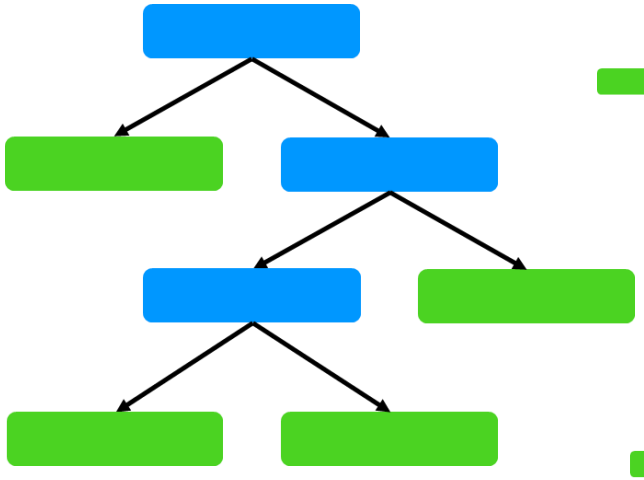

决策树

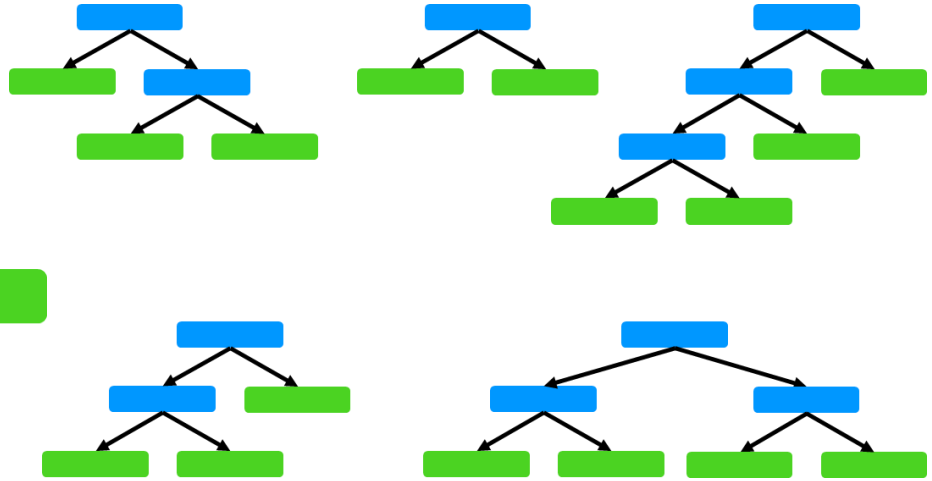

随机森林

分类方法远不止如此

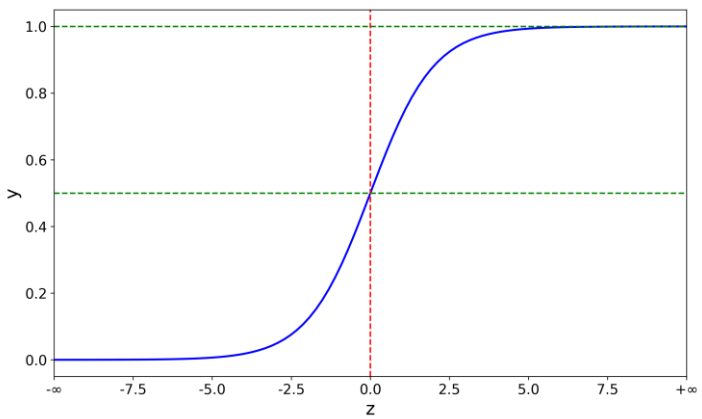

逻辑回归

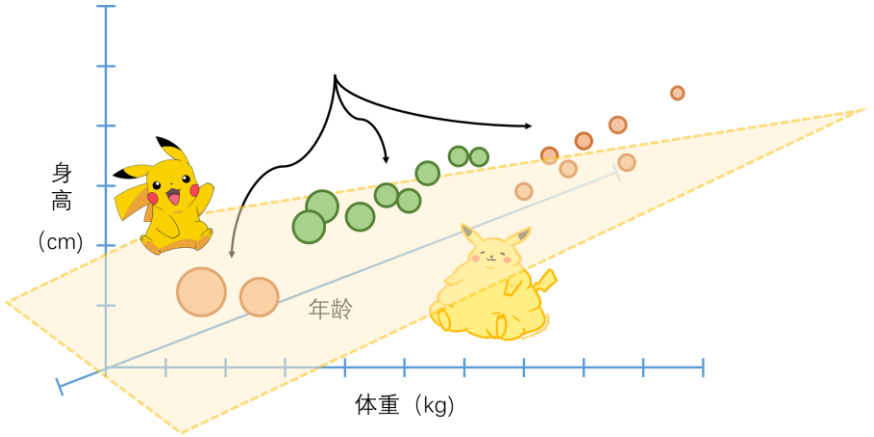

支持向量机

针对具体的问题，
我们应该如何判断，
哪种方法更加合适？

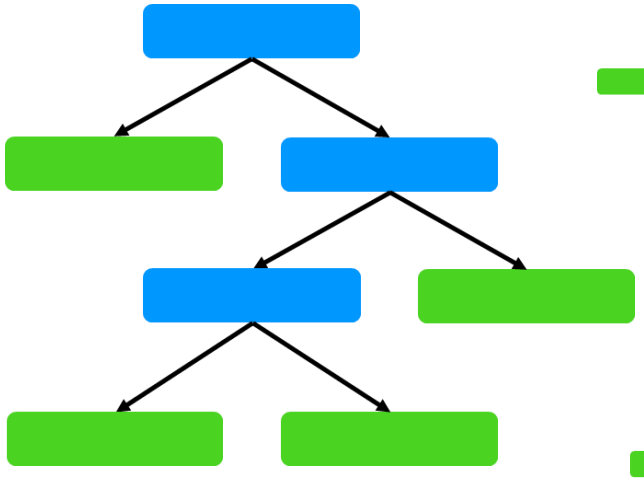

决策树

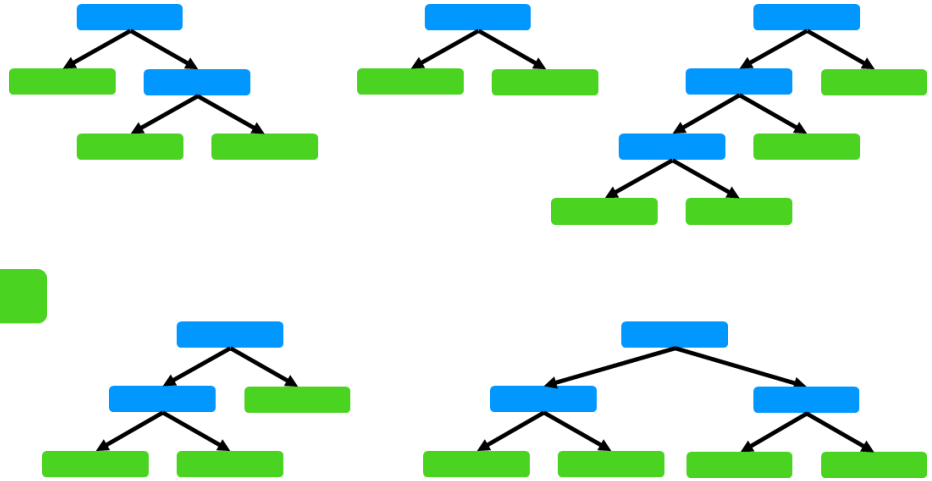

随机森林

如何判断?

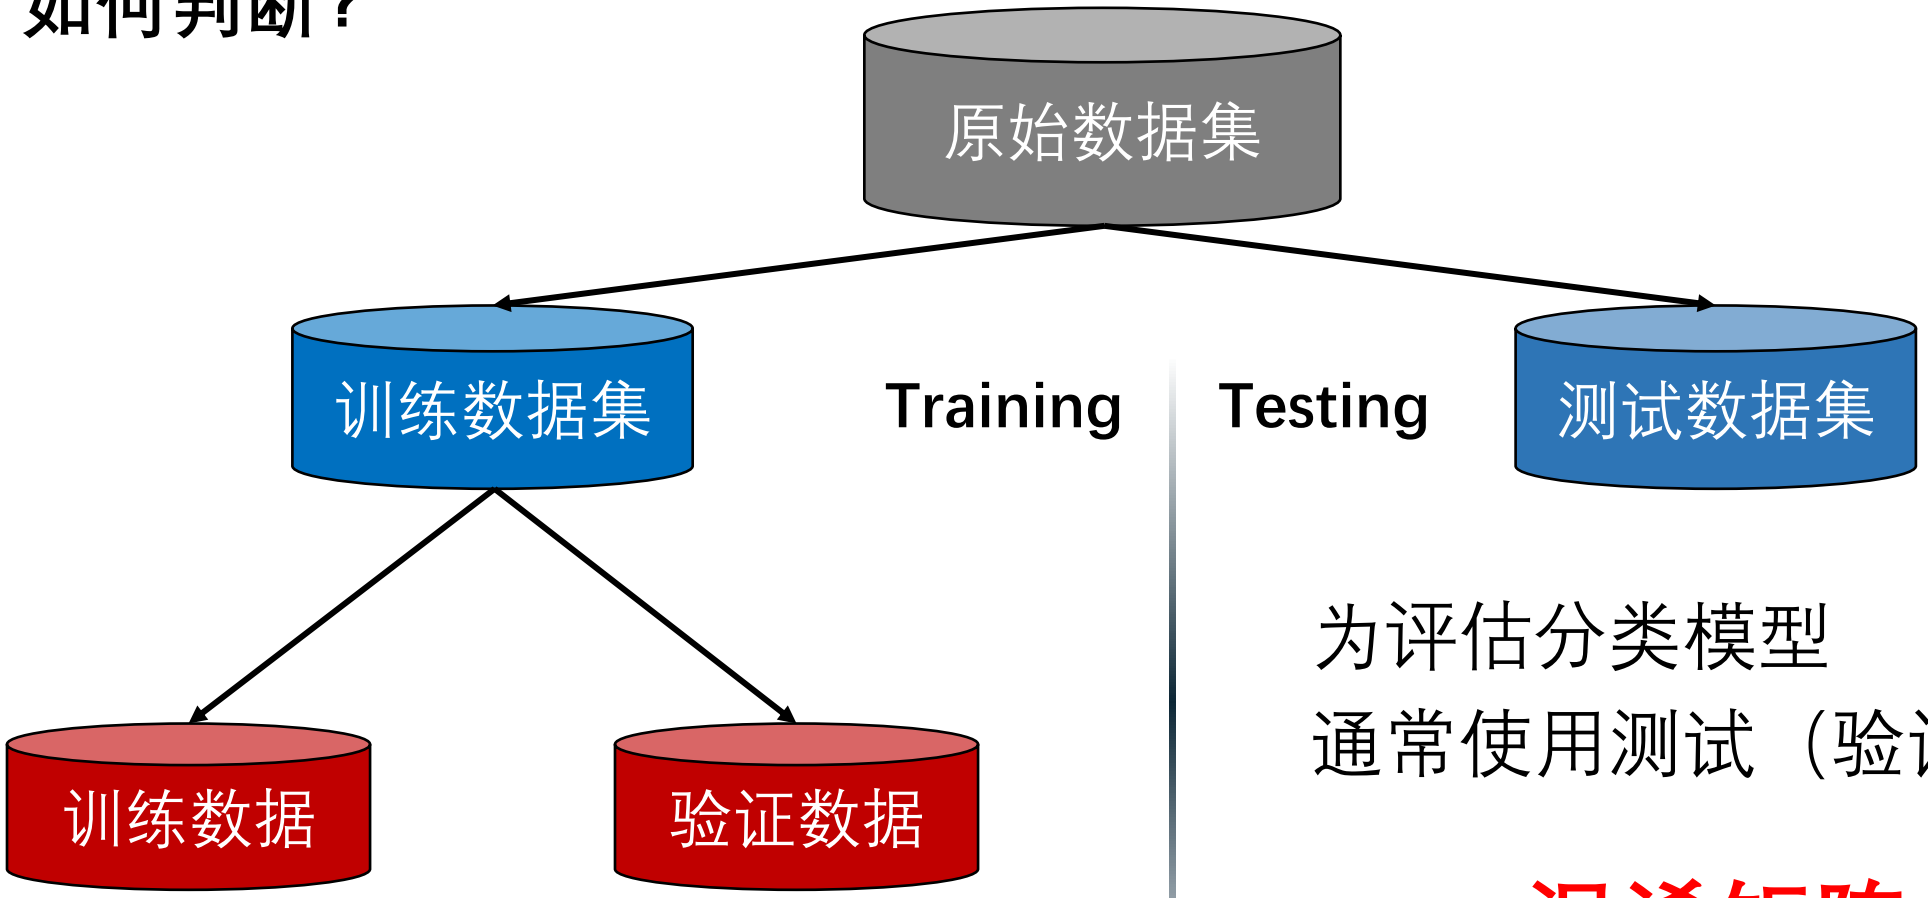

为评估分类模型

通常使用测试（验证）数据构建

混淆矩阵

Confusion Matrix

混淆矩阵是什么?

“行”为分类模型对于
样本的预测结果

实际类型
Actual Class

	是/阳/正例 Positive	否/阴/反例 Negative
预测类型 Predicted Class		
是/阳/正例 Positive	Positive	Positive
否/阴/反例 Negative	Negative	Negative

混淆矩阵是什么?

“列”为样本的实际类型

True / False 表示判断正确与否

实际类型
Actual Class

预测类型 Predicted Class	是/阳/正例 Positive	否/阴/反例 Negative
是/阳/正例 Positive	True Positive	False Positive
否/阴/反例 Negative	False Negative	True Negative

混淆矩阵是什么？

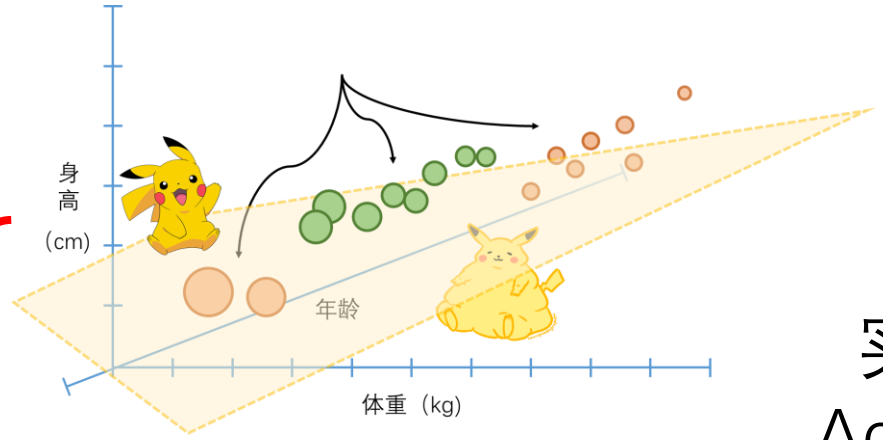

预测：是
实际：是

实际类型
Actual Class

预测类型 Predicted Class	是/阳/正例 Positive	否/阴/反例 Negative
是/阳/正例 Positive	True Positive	False Positive
否/阴/反例 Negative	False Negative	True Negative

混淆矩阵是什么?

预测： 否
实际： 是

		实际类型 Actual Class	
		是/阳/正例 Positive	**否/阴/反例** Negative
预测类型 Predicted Class	**是/阳/正例** Positive	**TP 1**	**False Positive**
	否/阴/反例 Negative	**False Negative**	**True Negative**

混淆矩阵是什么?

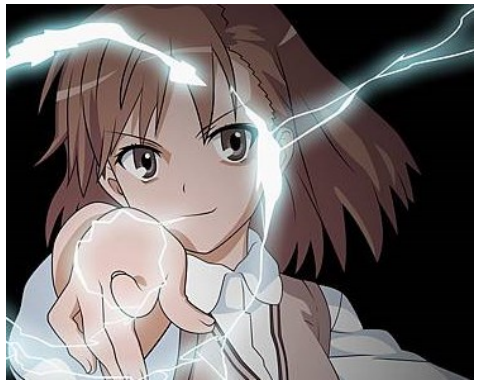

预测： 否
实际： 否

预测类型 Predicted Class	实际类型 Actual Class: 是/阳/正例 Positive	实际类型 Actual Class: 否/阴/反例 Negative
是/阳/正例 Positive	TP 1	False Positive
否/阴/反例 Negative	FN 1 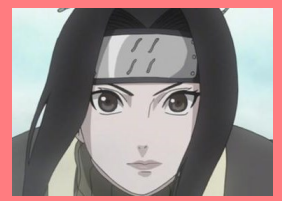	True Negative

混淆矩阵是什么?

预测： 是
实际： 否

		实际类型 Actual Class	
		是/阳/正例 Positive	**否/阴/反例** Negative
预测类型 Predicted Class	**是/阳/正例** Positive	TP 1	False Positive
	否/阴/反例 Negative	FN 1 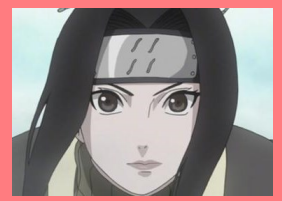	TN 1

混淆矩阵是什么?

预测： 否
实际： 是

		实际类型 Actual Class	
		是/阳/正例 Positive	**否/阴/反例** Negative
预测类型 Predicted Class	**是/阳/正例** Positive	TP 1	FP 1
	否/阴/反例 Negative	FN 1 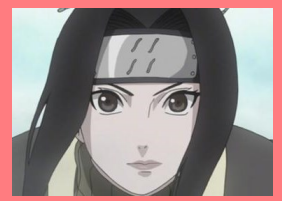	TN 1

混淆矩阵是什么?

实际类型
Actual Class

正确结果

预测类型 Predicted Class	是/阳/正例 Positive	否/阴/反例 Negative
是/阳/正例 Positive	TP 1	FP 1
否/阴/反例 Negative	FN 2	TN 1

混淆矩阵是什么?

实际类型
Actual Class

错误结果

预测类型 Predicted Class	是/阳/正例 Positive	否/阴/反例 Negative
是/阳/正例 Positive	TP 1	FP 1
否/阴/反例 Negative	FN 2	TN 1

根据结果判断……

逻辑回归最差

其他三种效果相当

如果一定得选的话，则需要更直接的量化方式

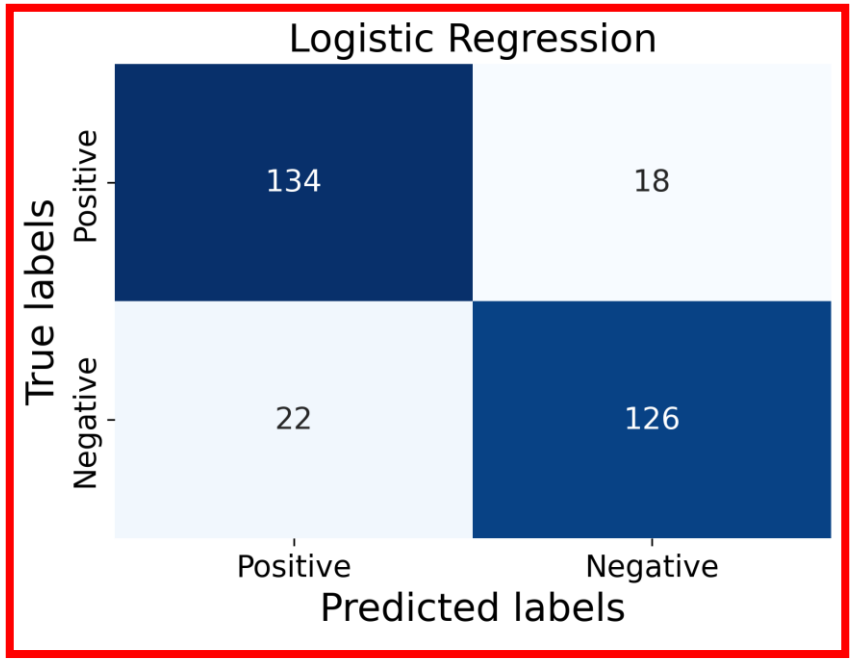

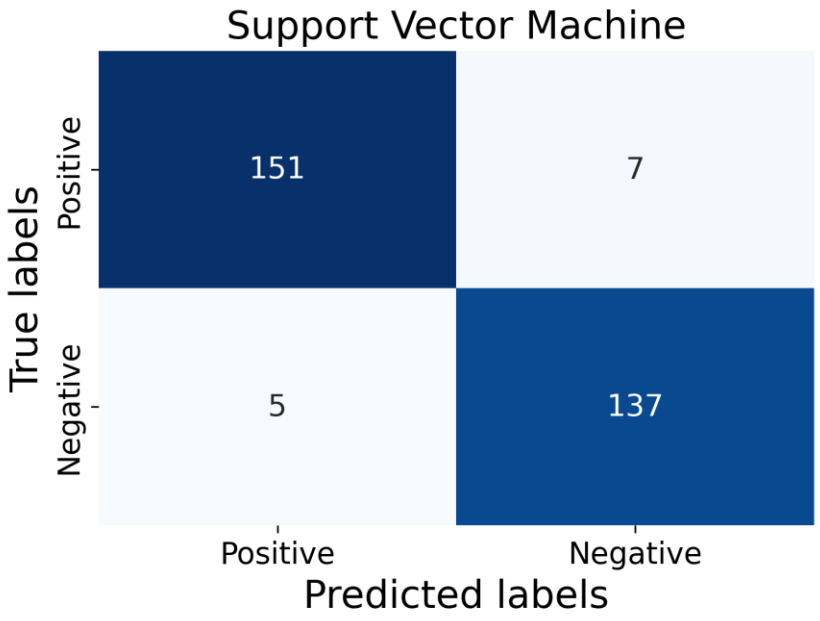

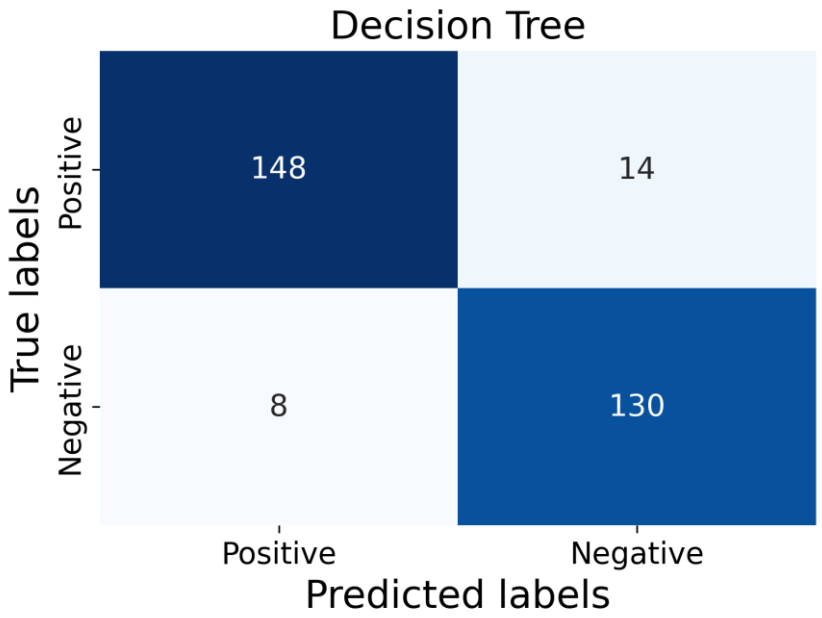

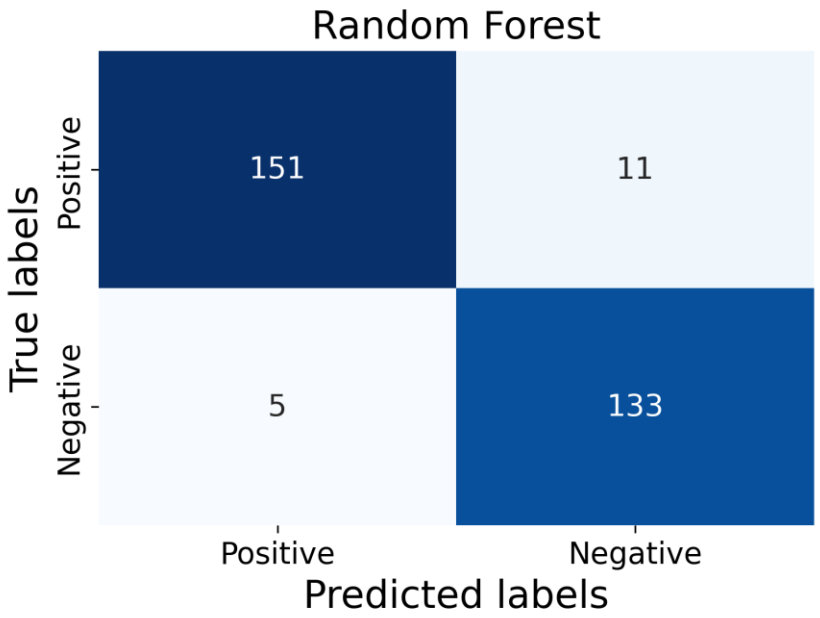

准确率 Accuracy ——衡量模型能够准确预测结果的能力

$$accuracy = \frac{TP + TN}{TP + FP + TN + FN}$$

准确预测的样本数量
占所有样本的比例

预测类型 Predicted Class \ 实际类型 Actual Class	是/阳/正例 Positive	否/阴/反例 Negative
是/阳/正例 Positive	True Positive	False Positive
否/阴/反例 Negative	False Negative	True Negative

准确率 Accuracy ——衡量模型能够准确预测结果的能力

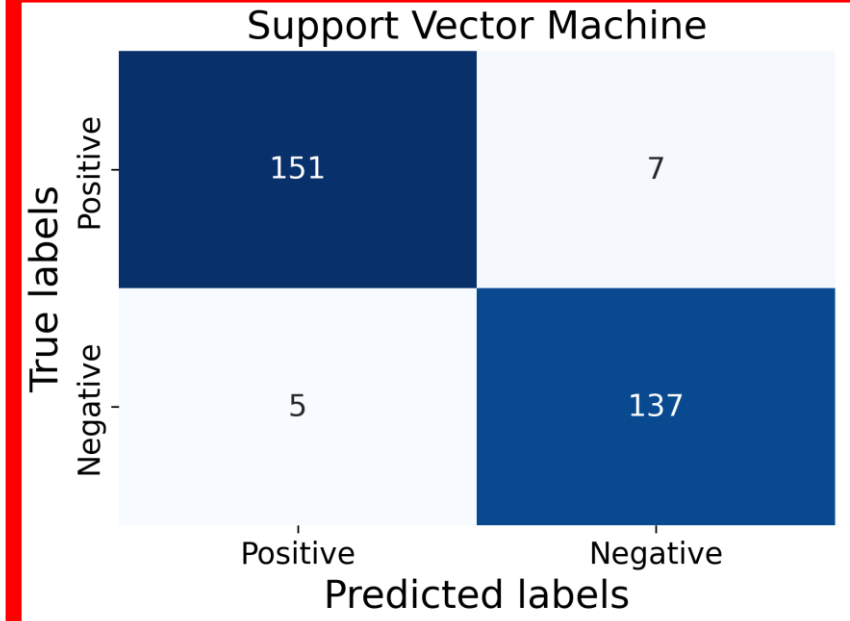

$accuracy = 0.96$

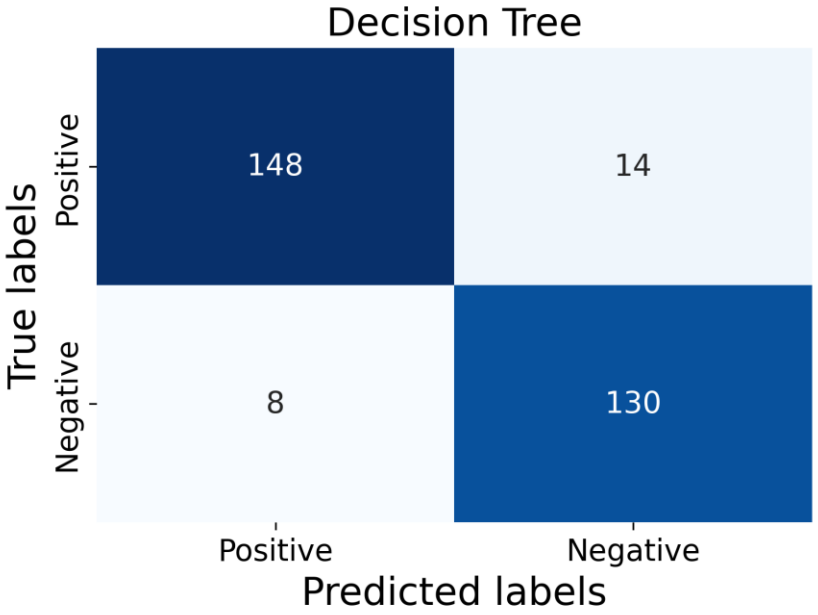

$accuracy = 0.92$

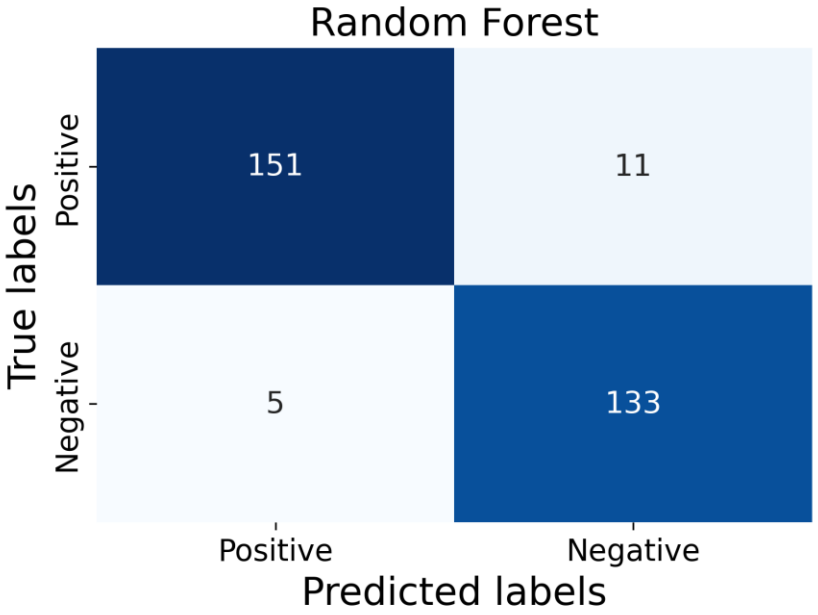

$accuracy = 0.95$

此例中，SVM的准确度最高，应选择SVM作为分类器

多分类问题的混淆矩阵与准确率

男　　女　　秀吉

$$accuracy = \frac{\boxed{\text{正确预测}}}{\boxed{\text{所有样本}}}$$

实际类型
Actual Class

预测类型
Predicted Class

	男	女	秀吉
男			
女			
秀吉			

如果问题是：判断性别是否为“秀吉”，会怎样？

男　　女

≫

秀吉

准确率很粗糙

不适用类别不平衡的问题

正常性别人物数量远远大于“秀吉”的数量

$$accuracy \in [\frac{100}{105}, \frac{105}{105}] \rightarrow accuracy \in [0.95,1]$$

<u>所有人物都不是秀吉</u>

实际类型
Actual Class

预测类型 Predicted Class	是/阳/正例 Positive	否/阴/反例 Negative
是/阳/正例 Positive	TP 5	FP 0
否/阴/反例 Negative	FN 0	TN 100

针对数据不平衡的情况 ——精确率（Precision）和召回率（Recall）

$$precision = \frac{TP}{TP + FP}$$

预测为正例之中，正确结果所占比例

反应出对正例预测结果的信心

		实际类型 Actual Class	
		是/阳/正例 Positive	**否/阴/反例** Negative
预测类型 Predicted Class	**是/阳/正例** Positive	True Positive	False Positive
	否/阴/反例 Negative	False Negative	True Negative

针对数据不平衡的情况 ——精确率（Precision）和召回率（Recall）

（判断正例的信心）

$$precision = \frac{TP}{TP + FP} \qquad recall = \frac{TP}{TP + FN}$$

所有正例样本中，被正确判断的比例

反映目标能否被全部检测出来的能力

		实际类型 Actual Class	
		是/阳/正例 Positive	否/阴/反例 Negative
预测类型 Predicted Class	**是/阳/正例** Positive	True Positive	False Positive
	否/阴/反例 Negative	False Negative	True Negative

针对数据不平衡的情况 ——精确率（Precision）和召回率（Recall）

（判断正例的信心）

$$precision = \frac{TP}{TP + FP}$$

（结果覆盖全部目标）

$$recall = \frac{TP}{TP + FN}$$

当$TP($ $) = 0$时，

正例判断的能力最差

$$precision = \frac{0}{0 + 3} = 0$$

$$recall = \frac{0}{0 + 5} = 0$$

	是/阳/正例 Positive	否/阴/反例 Negative
是/阳/正例 Positive	TP 0	FP 3
否/阴/反例 Negative	FN 5	TN 97

针对数据不平衡的情况 ——精确率（Precision）和召回率（Recall）

（判断正例的信心）

$$precision = \frac{TP}{TP + FP}$$

（结果覆盖全部目标）

$$recall = \frac{TP}{TP + FN}$$

当$TP($ $) = 3,$

这能说明比准确率（Accuracy）好用吗？

性别为“秀吉”的可信度为**50%**

60%的“秀吉”能被正确检测

$$precision = \frac{3}{3 + 3} = 0.5$$

$$recall = \frac{3}{3 + 2} = 0.6$$

	是/阳/正例 Positive	否/阴/反例 Negative
是/阳/正例 Positive	TP 3	FP 3
否/阴/反例 Negative	FN 2	TN 97

某银行信用卡中心——大数据反欺诈案例

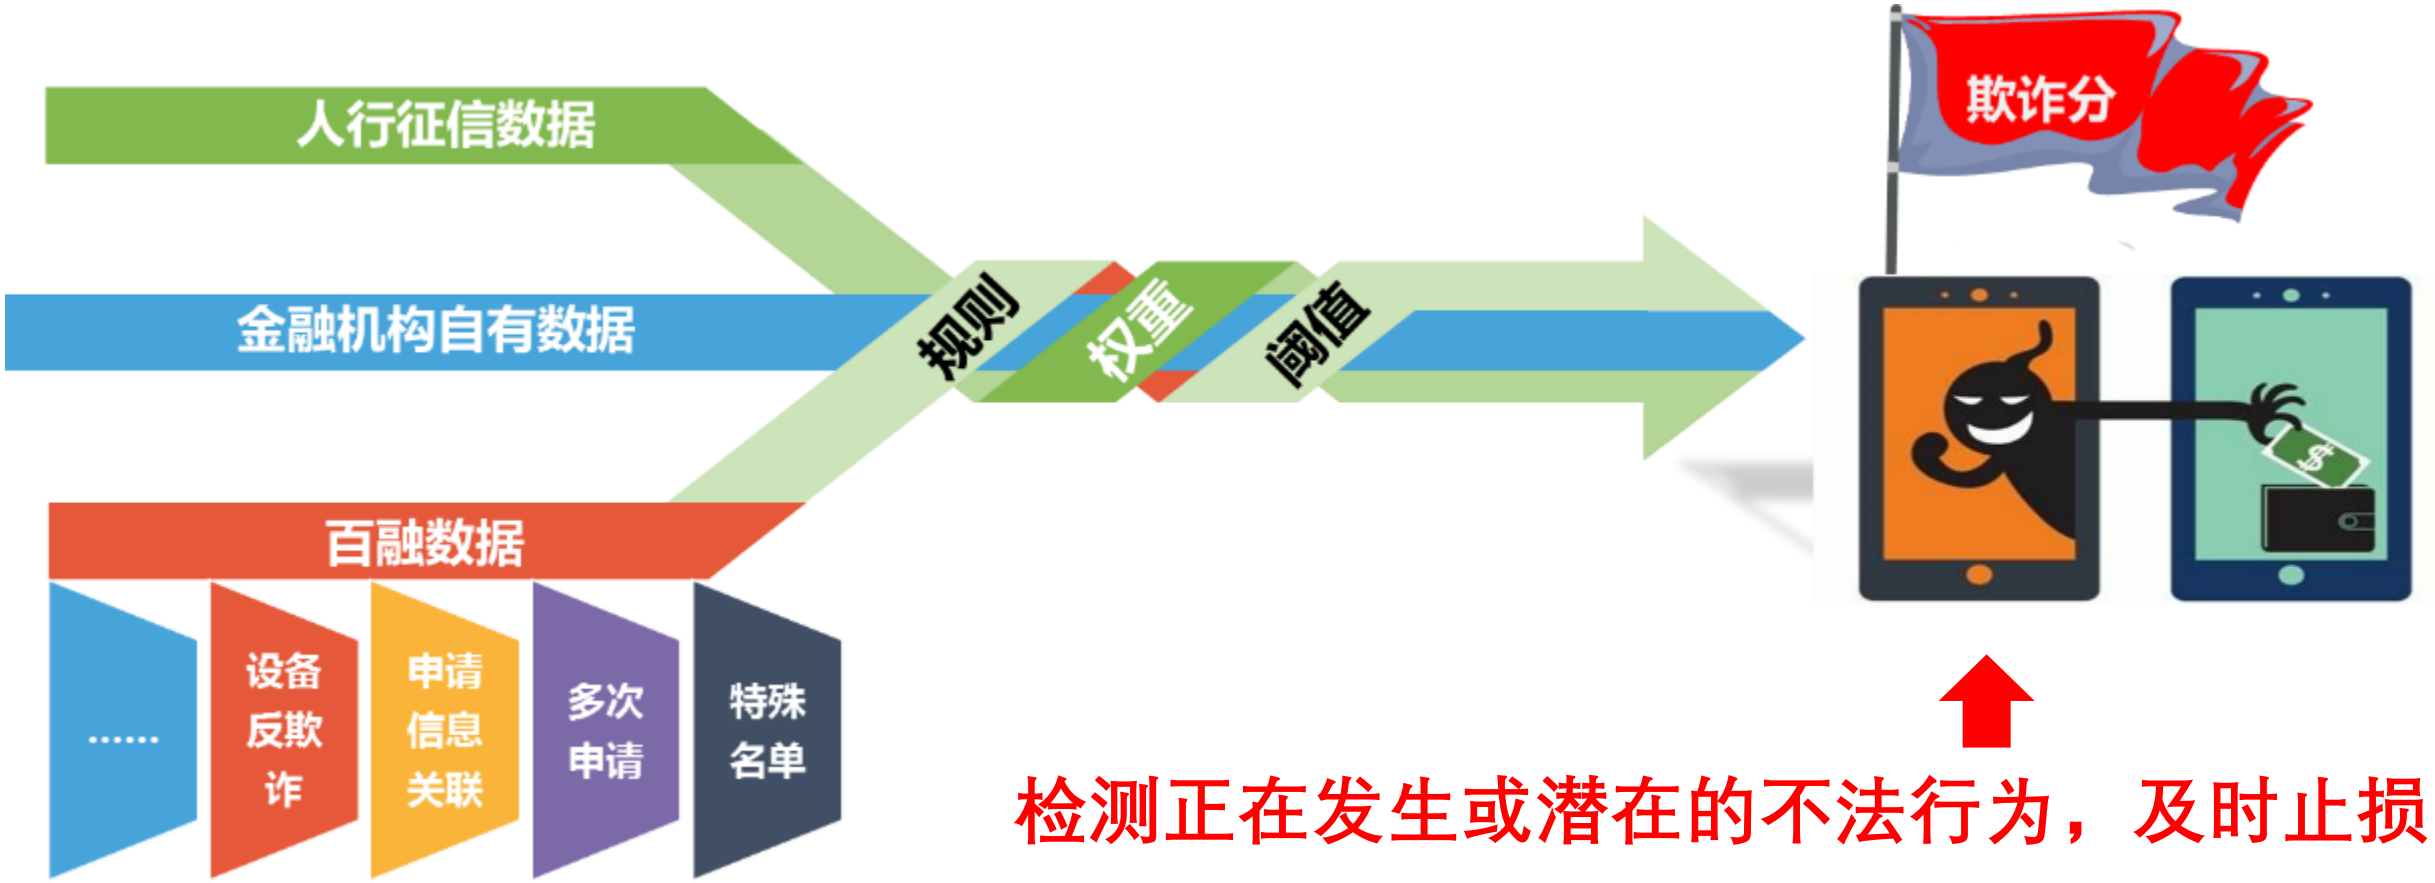

检测正在发生或潜在的不法行为，及时止损

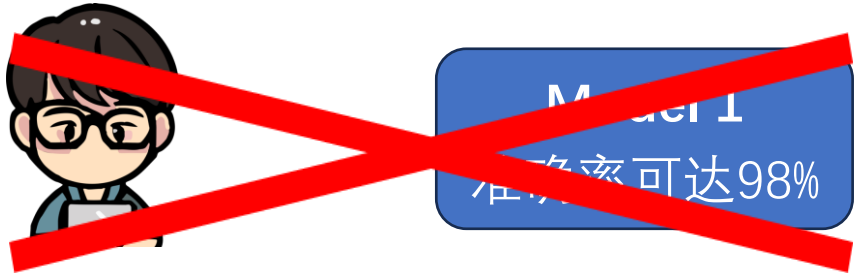

~~Model 1~~
~~准确率可达98%~~

Model 2
精确率：95%
召回率：60%

只要被我认定欺诈的，有95%的可能性是真的，同时召回率也不低

Model 3
精确率：90%
召回率：75%

我能找出75%的欺诈行为，且置信度为90%

算法工程师

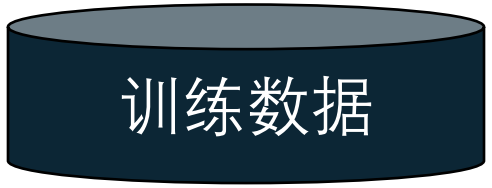

98%

2%

“**欺诈认定主要看召回率**。将无欺诈行为误认为欺诈行为只需要人工确认一下就好，没多大损失。但是，漏检造成的损失可能是几百甚至几千万。”

Model 2
精确率：95%
召回率：60%

只要被我认定欺诈的，有80%的可能性是真的，同时召回率也不低

Model 2 判定规则

概率≥0.5时，认定“存在欺诈风险”

概率＜0.5时，认定“不存在欺诈风险”

Model 2 改
精确率：85%
召回率：80%

如果下调阈值（Threshold），可能召回率就上升了

“你们这样变来变去，我怎么知道哪个模型好。这样，把所有可能的情况放到一张图里，我就能够做出判断了。”

P-R 曲线（Precision-Recall Curve）

Model 2 改
精确率：85%
召回率：80%

我能找出80%的欺诈行为，且置信度为85%

Model 3 改
精确率：80%
召回率：90%

我能找出90%的欺诈行为，且置信度为80%

“你们这样变来变去，我怎么知道哪个模型好。这样，把所有可能的情况放到一张图里，我就能够做出判断了。”

P-R 曲线（Precision-Recall Curve）

绘制P-R曲线：不同阈值的精确率和召回率

① 使用训练好的模型进行判断，输出**概率**

② 使用所有候选阈值判断类别，计算精确率和召回率

```
When threshold = 0.0 - Precision: 0.4800, Recall: 1.0000, F1 Score: 0.6486
When threshold = 0.1 - Precision: 0.5934, Recall: 0.9931, F1 Score: 0.7429
When threshold = 0.2 - Precision: 0.6900, Recall: 0.9583, F1 Score: 0.8023
When threshold = 0.3 - Precision: 0.7247, Recall: 0.8958, F1 Score: 0.8012
When threshold = 0.4 - Precision: 0.7654, Recall: 0.8611, F1 Score: 0.8105
When threshold = 0.5 - Precision: 0.8176, Recall: 0.8403, F1 Score: 0.8288
When threshold = 0.6 - Precision: 0.8382, Recall: 0.7917, F1 Score: 0.8143
When threshold = 0.7 - Precision: 0.9130, Recall: 0.7292, F1 Score: 0.8108
When threshold = 0.8 - Precision: 0.9375, Recall: 0.6250, F1 Score: 0.7500
When threshold = 0.9 - Precision: 1.0000, Recall: 0.3750, F1 Score: 0.5455
```

③ 以召回率为X轴，精确率为Y轴，画出曲线

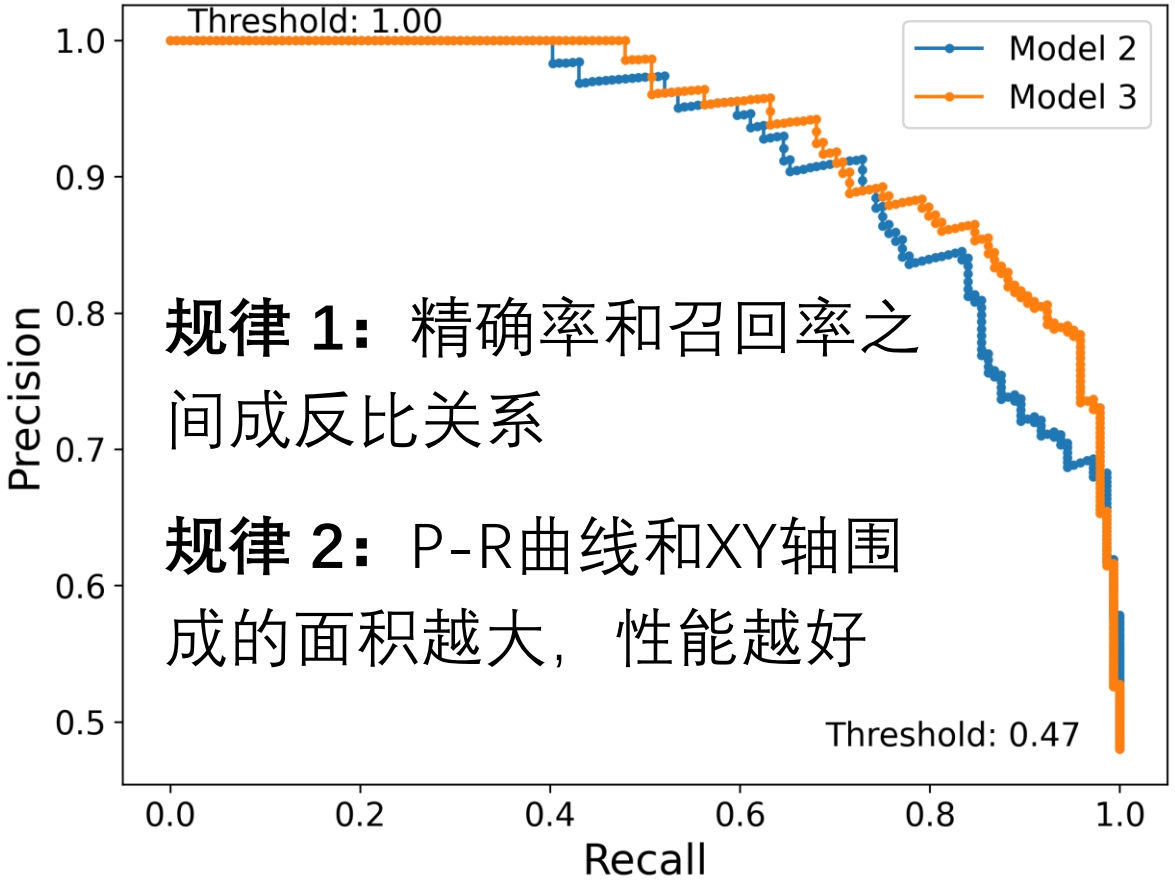

规律 1：精确率和召回率之间成反比关系

规律 2：P-R曲线和XY轴围成的面积越大，性能越好

F1分数（F1 Score）

$$f1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

如何确定合适的Threshold?

我们希望精确率和召回率都非常高

需要一个标准能够同时考虑两者

Model 3
拥有更好的表现

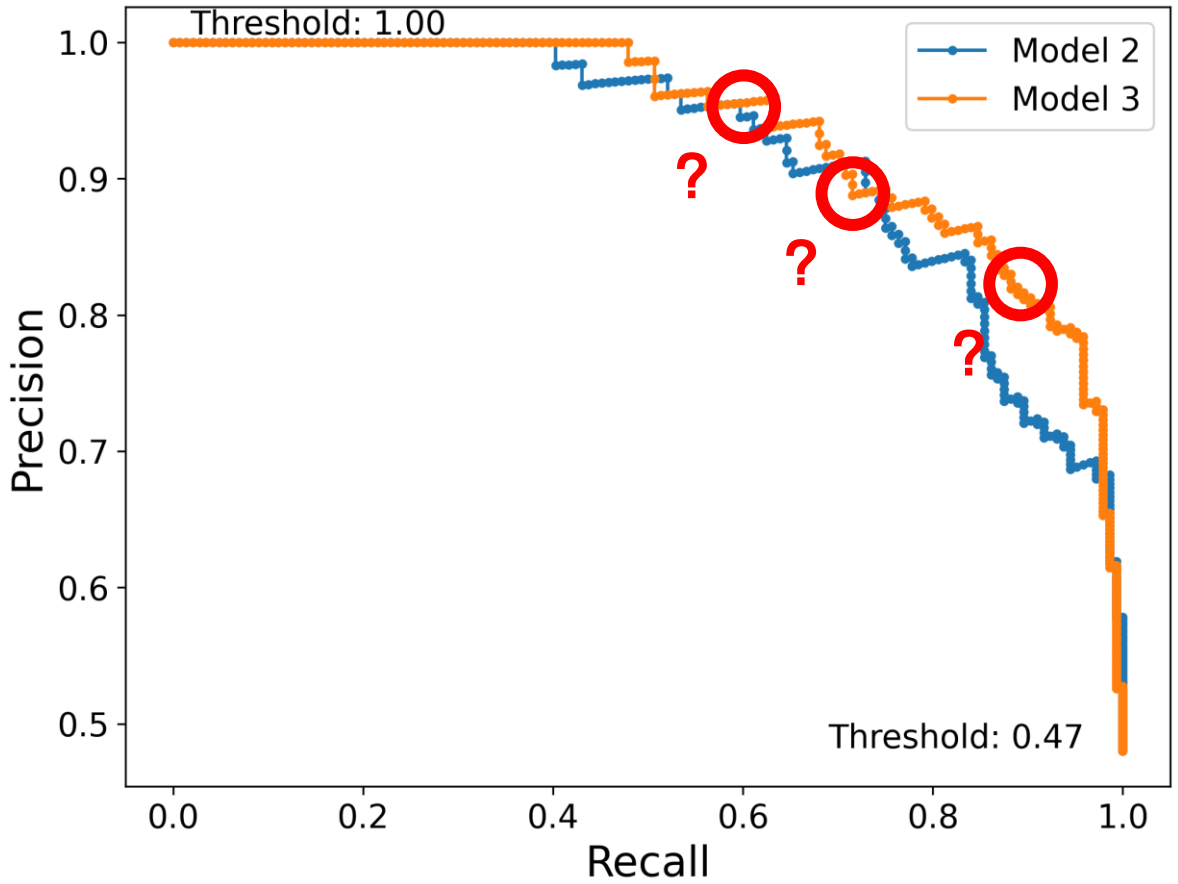

F1分数（F1 Score）

$$f1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

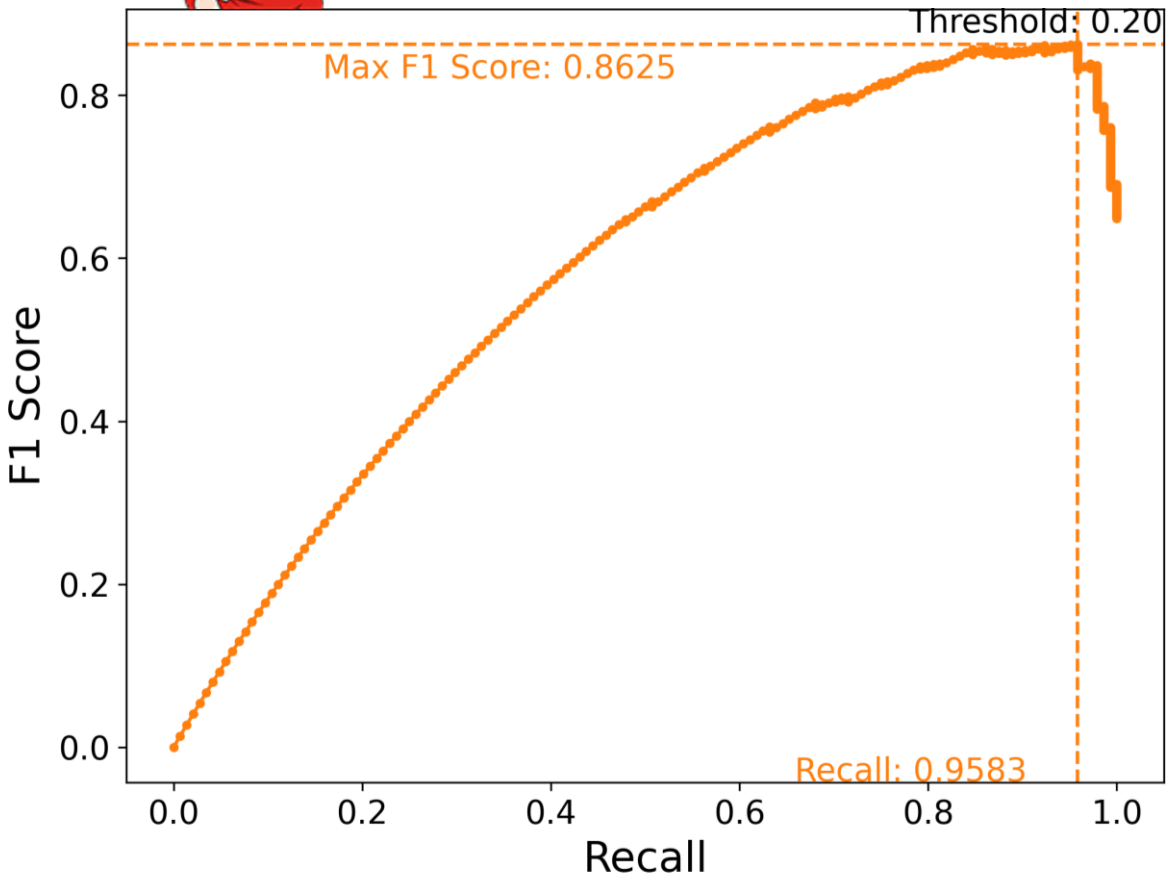

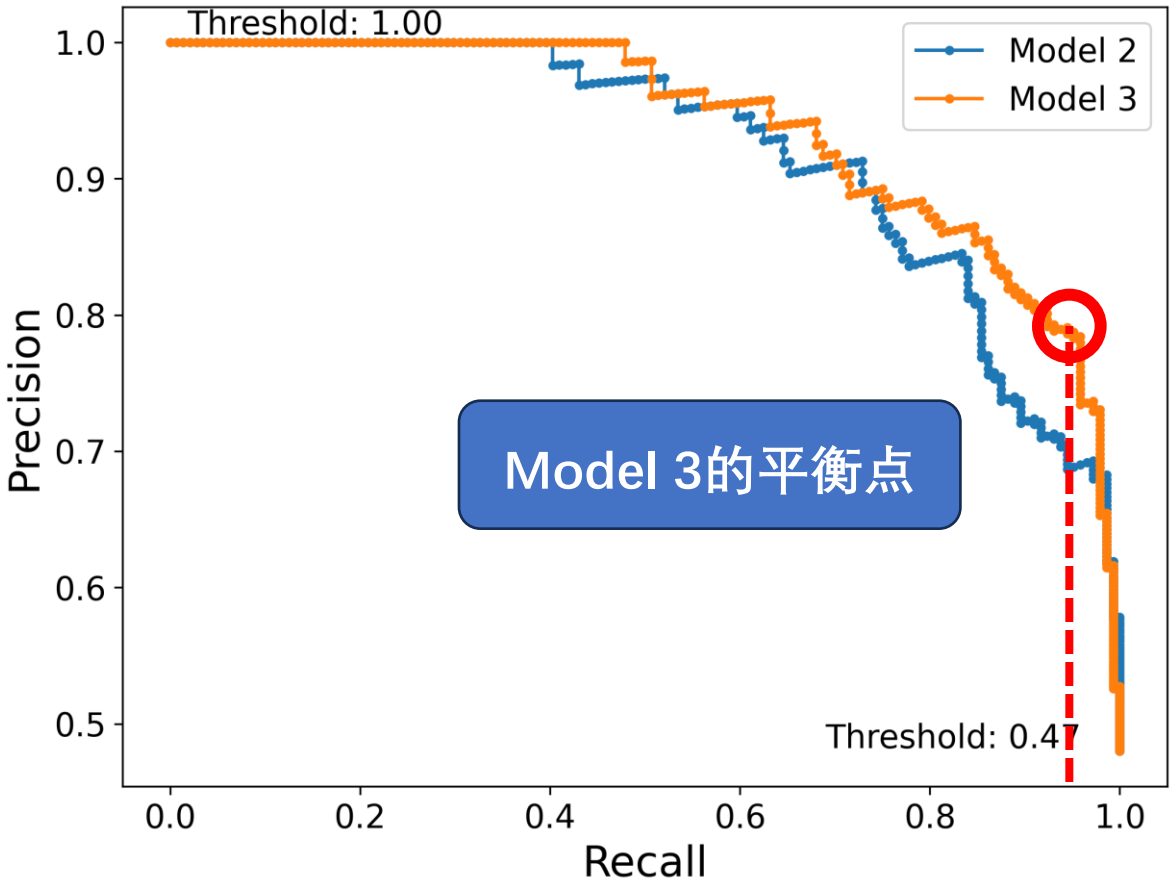

针对数据不平衡的情况

（判断正例的信心）

$$precision = \frac{TP}{TP + FP}$$

（结果覆盖全部目标）

$$recall = \frac{TP}{TP + FN}$$

$$f1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

虽然能够应对数据不平衡的情况，

但是**仅仅只关注对正例的判断结果**

<u>在部分场景中 **TN** 的判断也非常重要！</u>

	是/阳/正例 Positive	否/阳/反例 Negative
是/阳/正例 Positive	TP 0	FP 3
否/阳/反例 Negative	FN 5	TN 97 忽略

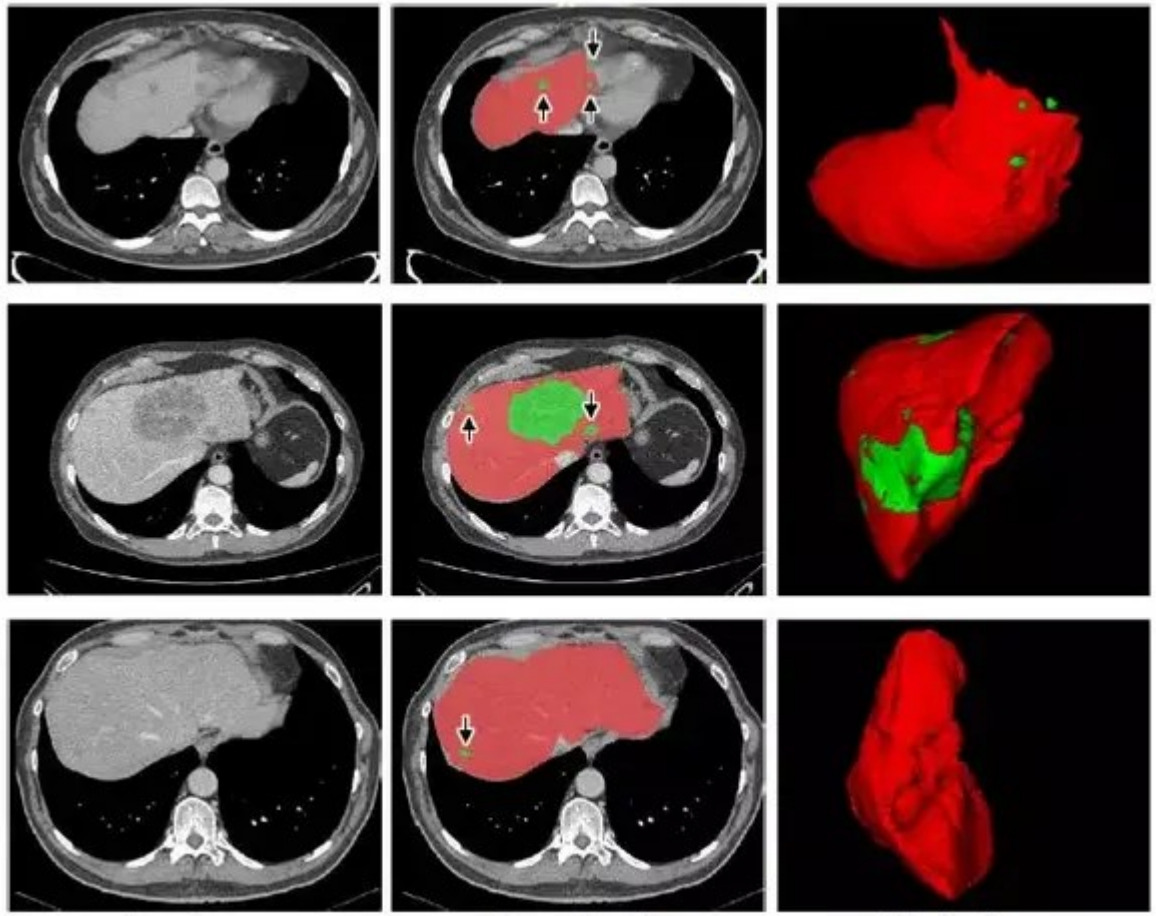

准确检测疾病（True Positive）及排除健康人员（True Negative）皆非常之重要

引入两个标准 —— 敏感性（Sensitivity）和特异性（Specificity）

$$sensitivity = \frac{TP}{TP + FN}$$

正确检测出疾病的概率

$$recall = \frac{TP}{TP + FN}$$

	存在疾病	健康
存在疾病	True Positive	False Positive
健康	False Negative	True Negative

引入两个标准 —— 敏感性（Sensitivity）和特异性（Specificity）

$$sensitivity = \frac{TP}{TP + FN}$$

正确检测出疾病的概率

$$specificity = \frac{TN}{TN + FP}$$

正确排除健康人员的概率

敏感性和特异性的优势

全面评估模型对正负两类样本的区分能力，特别是当误报和漏报的代价需要权衡时，优势明显。

	存在疾病	健康
存在疾病	True Positive	False Positive
健康	False Negative	True Negative

可以通过ROC曲线对敏感性和特异性做全面的展示，并用AUC进行量化

$$FPR = 1 - specificity$$

$$= 1 - \frac{TN}{TN + FP}$$

$$= \frac{FP}{TN + FP}$$

<u>健康人员被误检的概率</u>

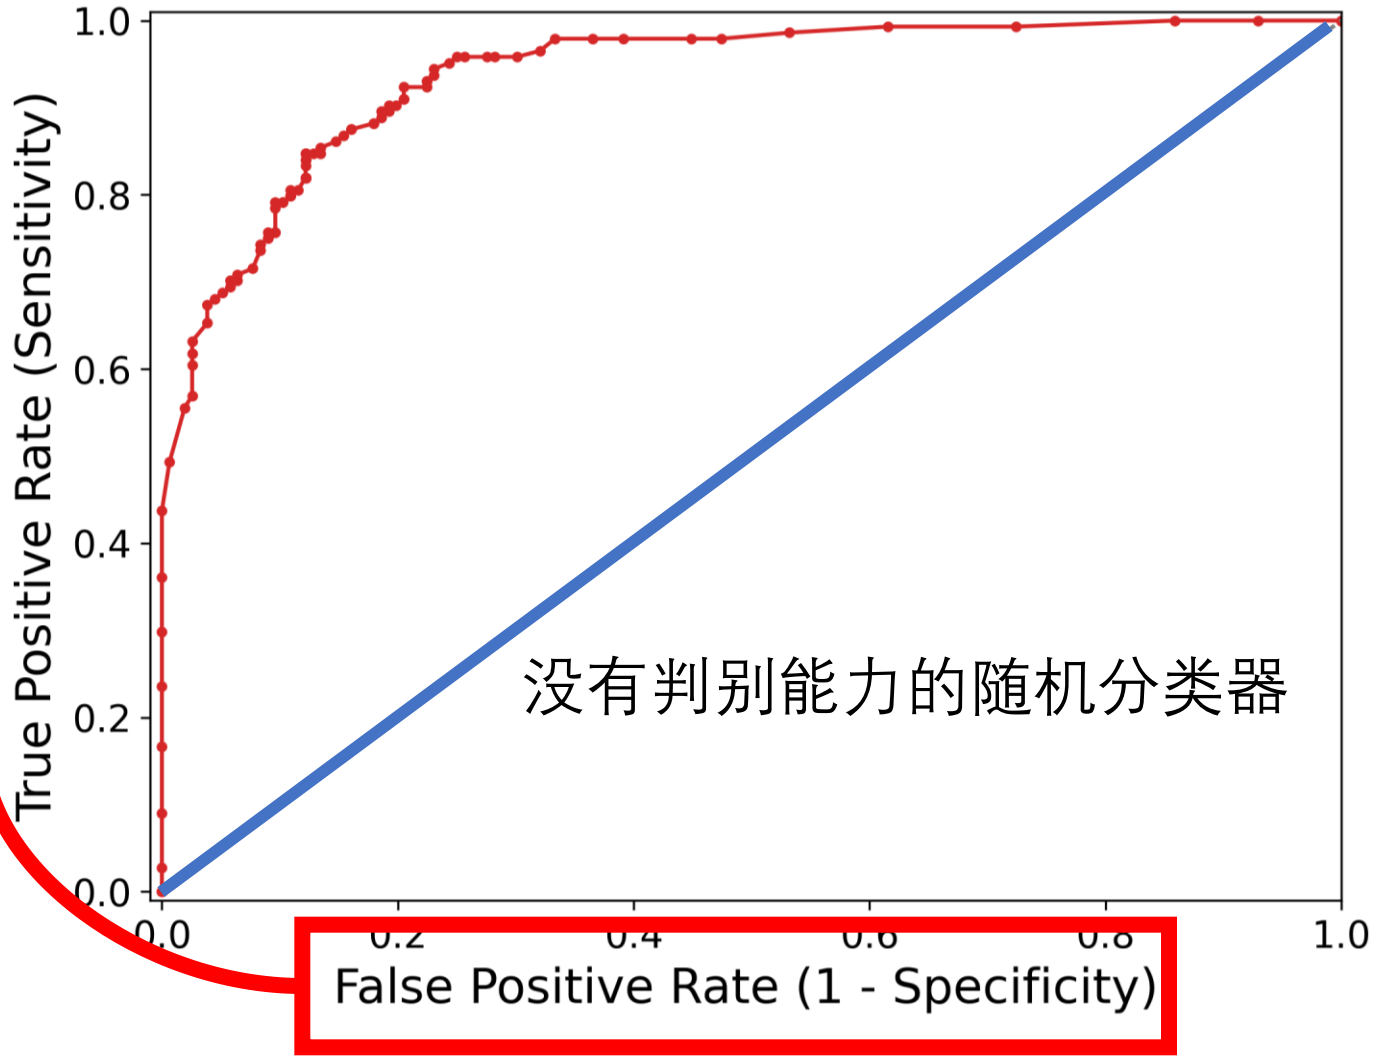

可以通过ROC曲线对敏感性和特异性做全面的展示，并用AUC进行量化

使用绘制P-R曲线的方法绘制ROC曲线

① 使用训练好的模型进行判断，输出**概率**

② 使用所有候选阈值判断类别，计算TPR（敏感性）和FPR（1-特异性）

③ 以FPR为X轴，TPR为Y轴，画出曲线

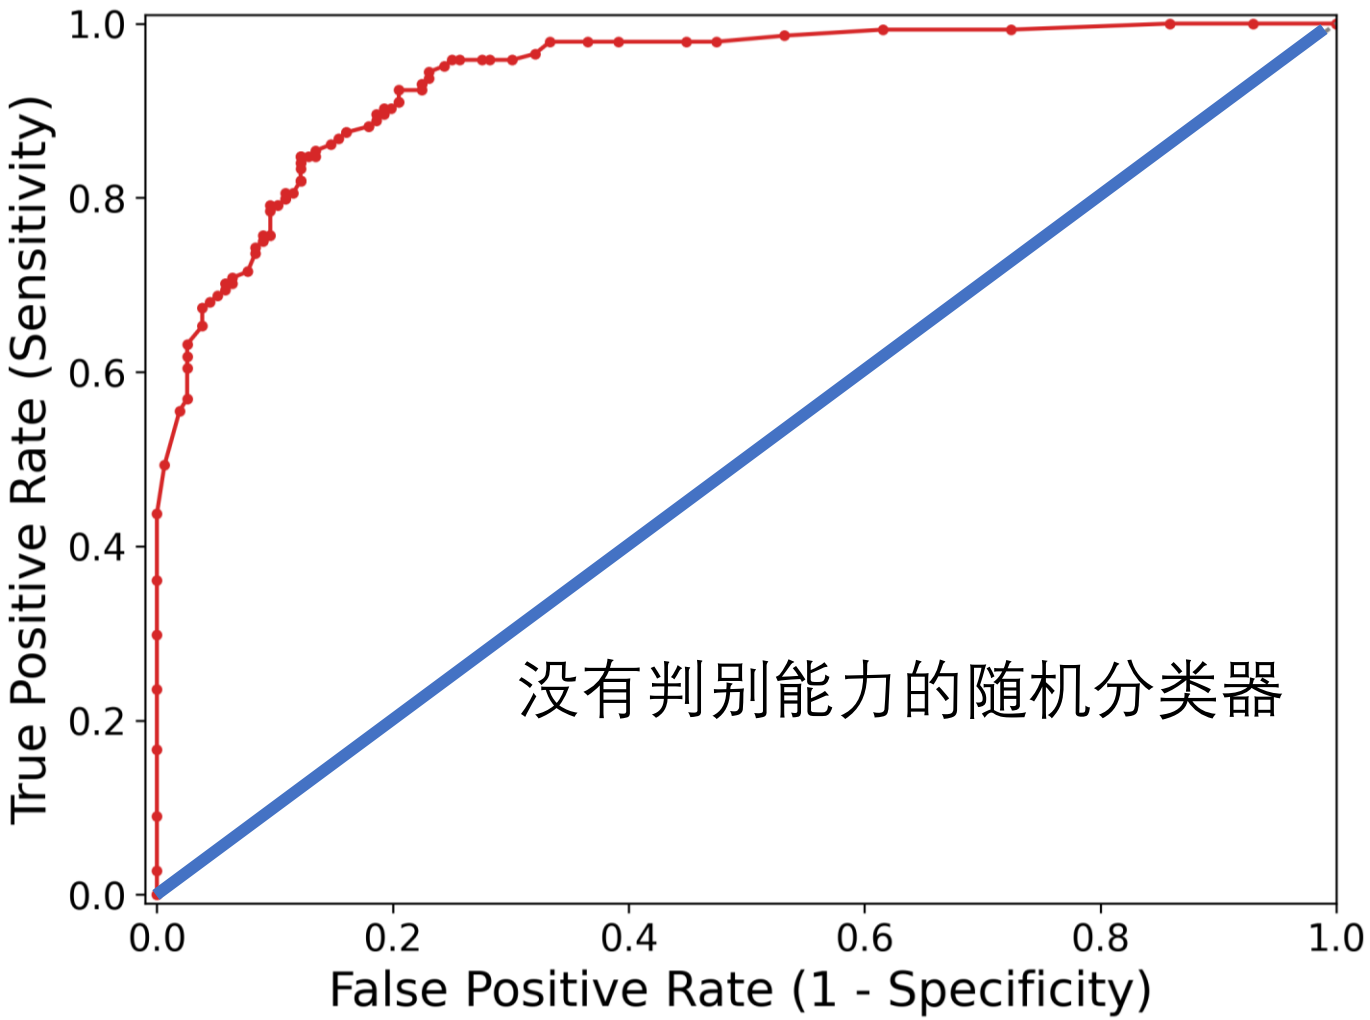

可以通过ROC曲线对敏感性和特异性做全面的展示，并用AUC进行量化

AUC——Aera Under Curve

通过计算曲线下的面积
判断分类器的整体表现

$$AUC \in (0,1)$$

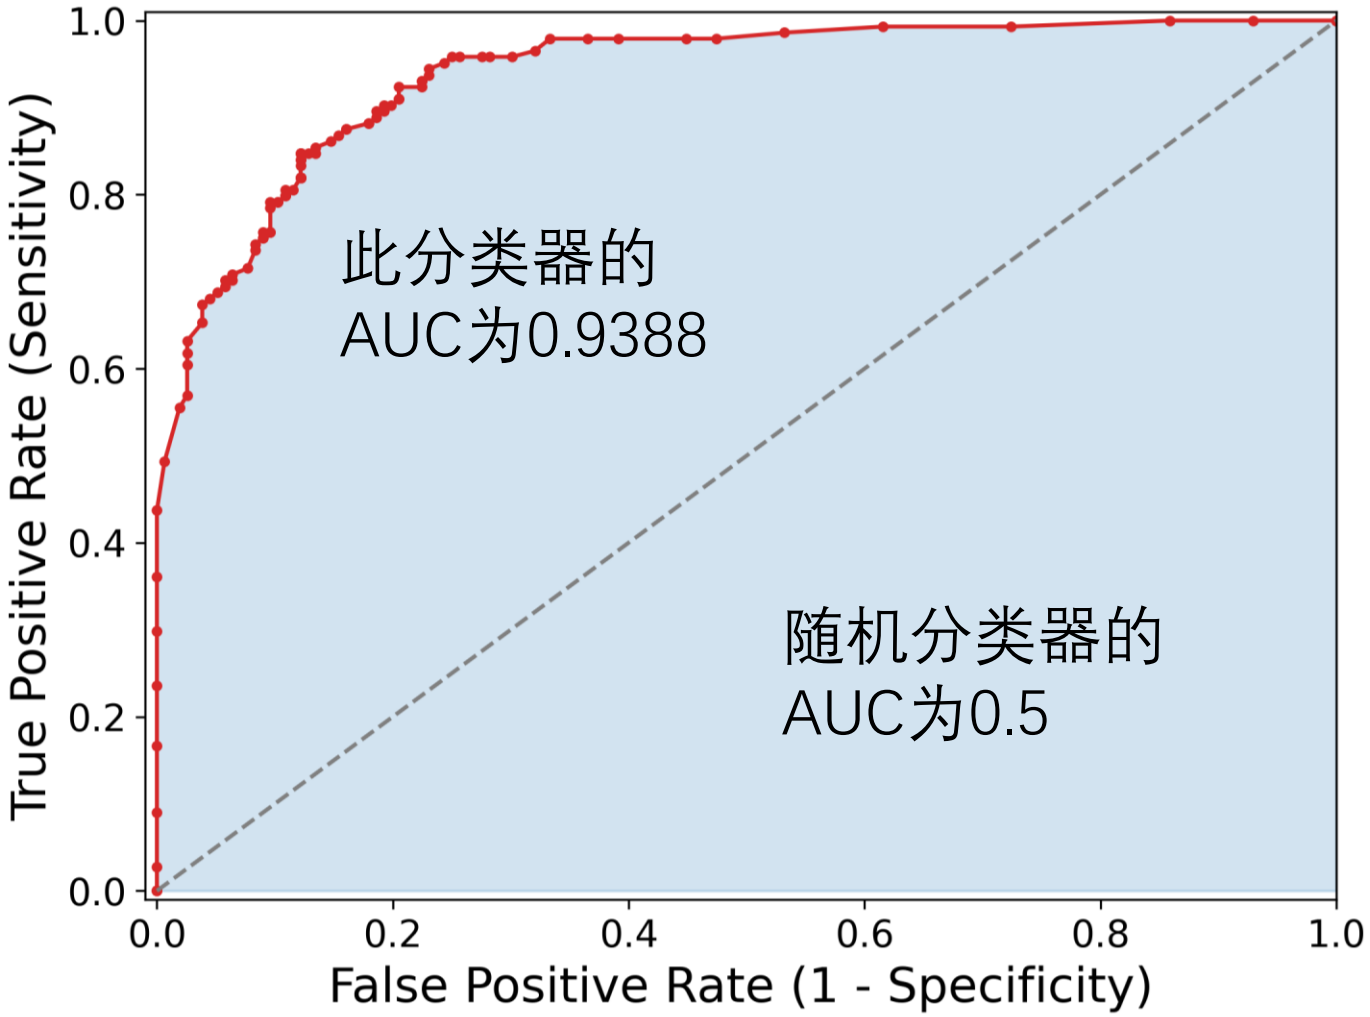

思考题（需在实验中体现）

本节课的评价方式主要针对**二分类**问题……

针对**多分类**问题，如何计算精确率、召回率、敏感性和特异性？

针对**多分类**问题，如何绘制P-R曲线、ROC曲线？

提示：可参考**One-vs-Rest**的思想。

小结

混淆矩阵

↓

精确度（Accuracy）： 适用类别样本数量均衡的场景

↓

精确率（Precision）、召回率（Recall）、F1得分（F1-Score）

适用数量不均衡的场景，但主要关注正例的情况

↓

敏感性（Sensitivity）、特异性（Specificity）、ROC和AUC

适用数量不均衡的场景，全面评估正负两类的情况