第四章 聚类 Clustering

了解无监督学习的典型问题之一，即聚类问题，初步具备构建经典聚类模型解决实际问题的能力，并了解分类模型的评估方法。

实验4：基于k-Means的背景分割与图像压缩

简介：

- 使用k-Means聚类算法分割图像的前景与背景
- 使用k-Means聚类算法压缩图像

实验主要内容：

- 使用OpenCV库载入图像
- 生成灰度图像，使用k-Means进行二值分割生成蒙版
- 使用k-Means压缩图像，观察不同k值的压缩结果
- 使用肘部法确定k值，思考k-means存在的问题

实验5：基于密度聚类和协同过滤算法的电影推荐

简介：

- 使用密度聚类算法发掘相似簇
- 使用协同过滤算法预测电影喜好程度

实验主要内容：

- 使用Pandas库载入电影评分数据
- 使用密度聚类算法进行聚类，发掘相似用户
- 使用协同过滤算法补全电影评分并进行推荐决策

4.1 k-Means 聚类算法

无监督学习 & 聚类 & k-Means

背景分割 & 图像压缩

案例回顾

输入数据 x	输出结果 y
6.575	24.0
6.421	21.6
7.185	34.7
6.998	33.4
7.147	36.2
……	……

回归模型

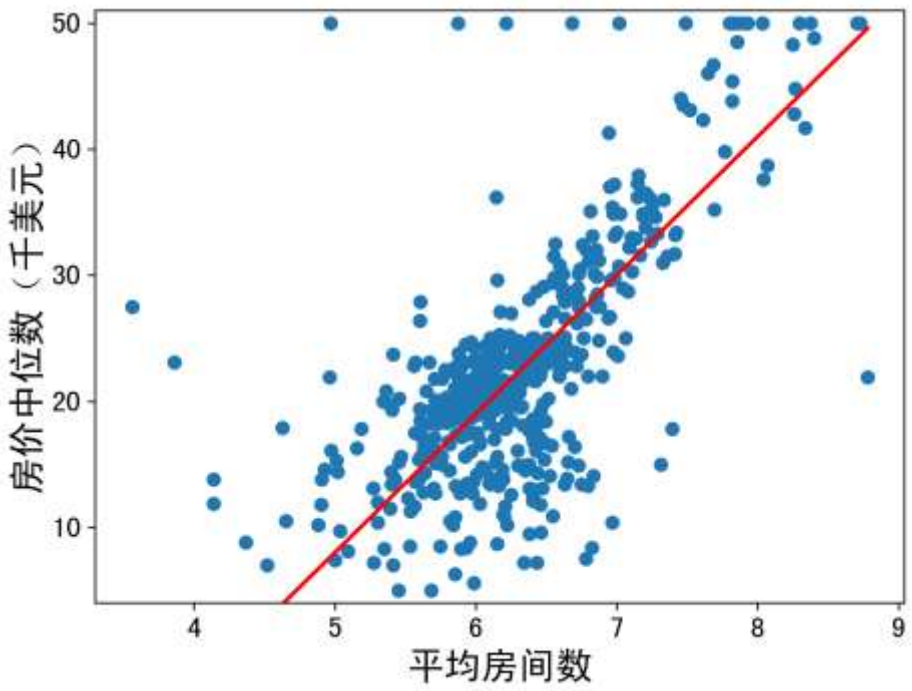

在房价的**监督**下训练回归模型

案例回顾

作品名	搞笑	热血	女性向	年份	喜欢
格斗实况	是	是	否	2024	Y
碧蓝之海	是	是	否	2018	Y
十万个冷笑话	是	否	否	2012	Y
狐妖小红娘	是	否	否	2015	Y
仙王的日常生活	是	否	否	2020	Y
关于我转生变成史莱姆这档事	是	否	否	2018	Y
进击的巨人	否	是	否	2013	Y
樱兰高校男公关部	是	否	是	2008	Y
薄樱鬼	否	是	是	2010	Y
魔道祖师	否	是	是	2018	N
纯情罗曼史	否	否	是	2008	N
世界第一初恋	否	否	是	2011	N

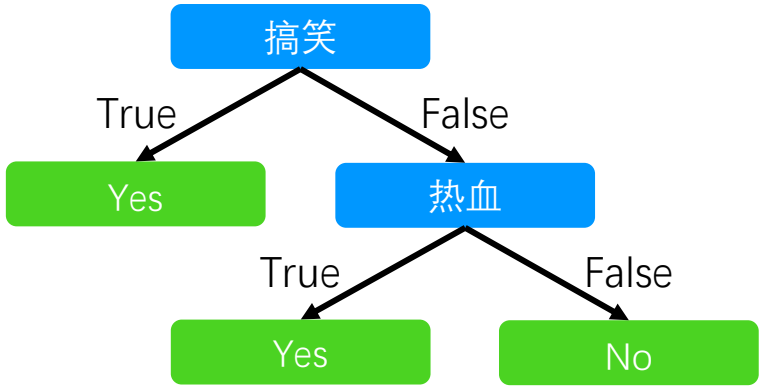

作品名	喜欢
关于我转生变成史莱姆这档事 第三季	Y
我会招架一切反误会的世界最强想成为冒险者	Y
Love Live! Super Star!! 第三季	N

在喜欢的**监督**下训练分类模型

案例规律

输入数据 x	y
6.575	24.0
6.421	21.6
7.185	34.7
6.998	33.4

作品名	搞笑	热血	女性向	喜欢
格斗实况	是	是	否	Y
碧蓝之海	是	是	否	Y
十万个冷笑话	是	否	否	Y
狐妖小红娘	是	否	否	Y
仙王的日常生活	是	否	否	Y

标签
Label

回归模型

描述特征和标签之间的映射关系

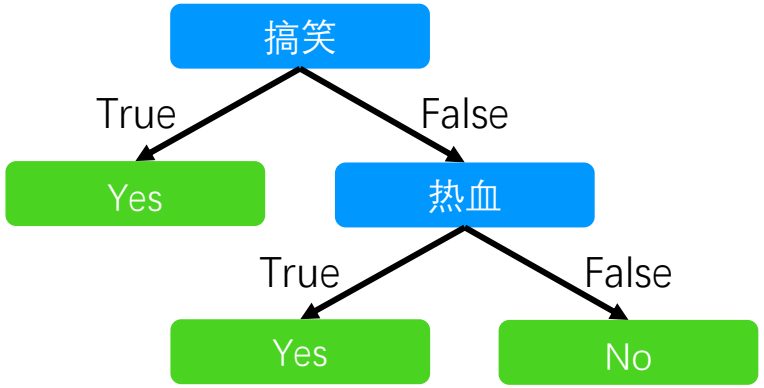

从已知数据中学习的方法叫监督学习

机器学习的另一种分类

监督学习	半监督学习	**无监督学习**	弱监督学习
训练样本全标注	训练样本少量标注	训练样本无标注	标注有噪声质量低

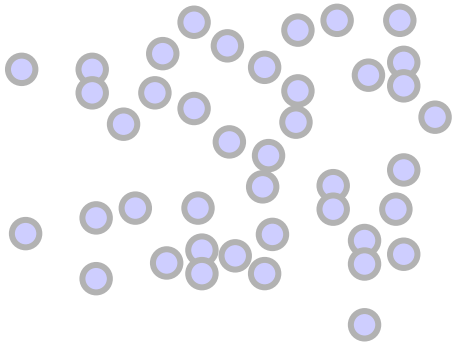

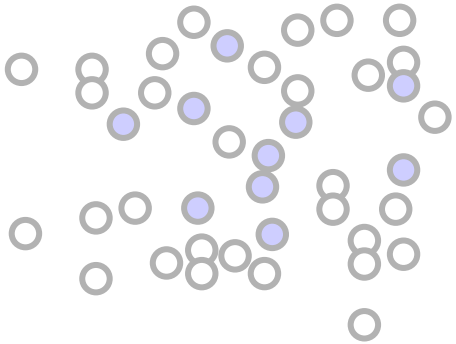

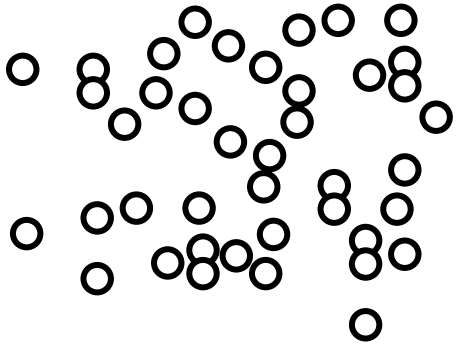

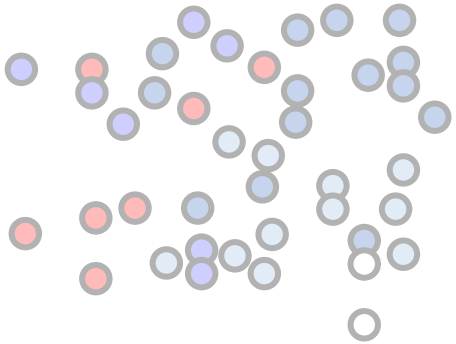

回归

分类

聚类

Clustering

用户行为

$$f(x)$$

挖掘相似特征

用户推荐

聚类能做什么？

用户画像分析

- 观看时长
- 观看频率
- 视频类型
- 视频内容
- 地理位置
- 性别年龄

- 群体倾向
- 消费习惯

个性推荐

异常检测

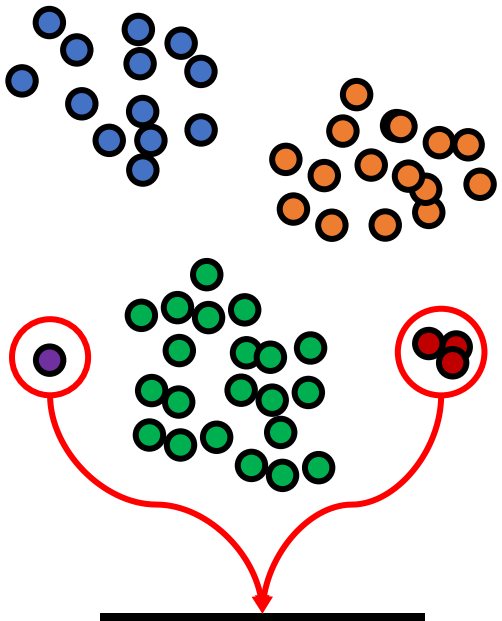

异常判断

图像分割

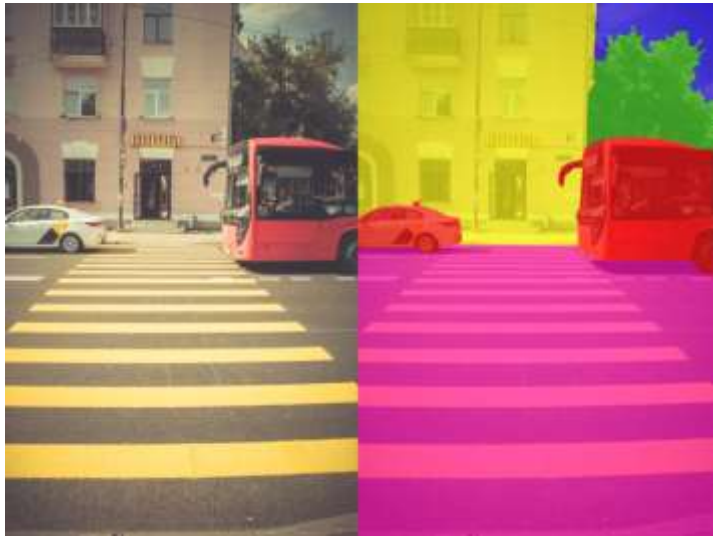

目标识别

* 在实际应用中，聚类一般作为一个中间环节，其结果很少作为最终判断

聚类算法

无监督学习

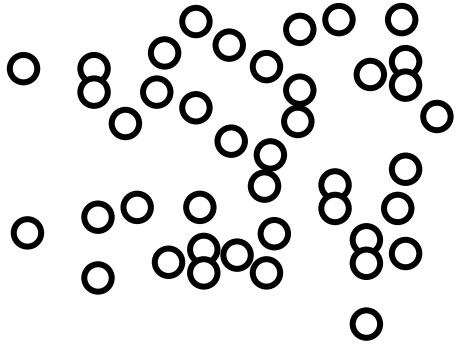

只需数据特征x
无需数据标签y

发掘数据中的模式

- 工作邮件
- 推广邮件
- 钓鱼邮件

- 购买模式
- 用户倾向
- 消费水平

形成共同群体

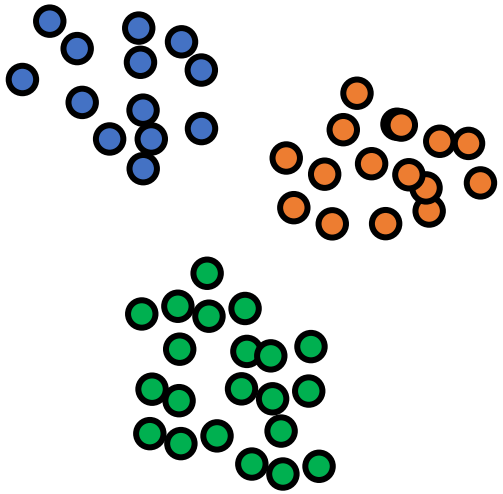

聚类算法——没有标签，如何形成聚类?

能够支持聚类的信息：样本间的**相似度**

相似的样本聚为一簇
（**Cluster**）

不相似的样本属于不同聚簇

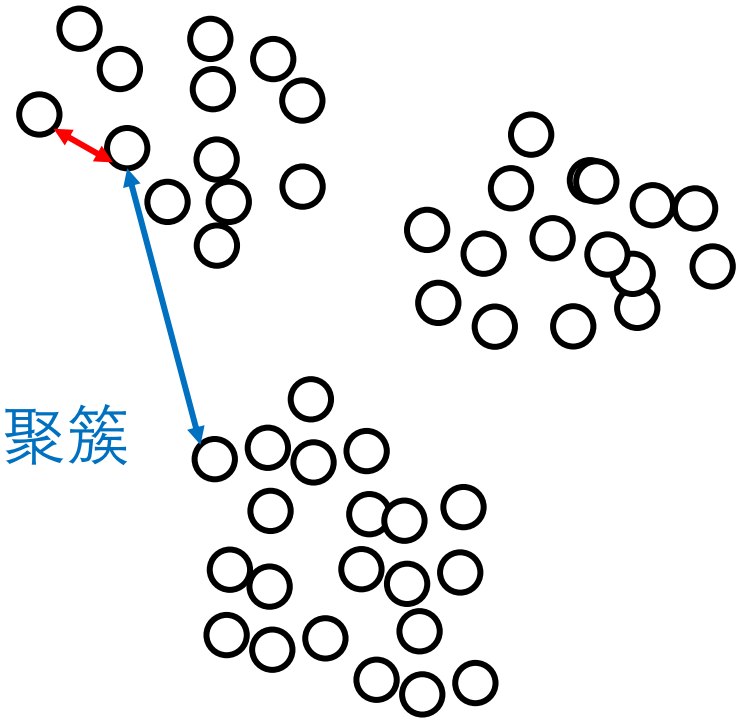

聚类算法——相似度的重要性

相似度的选择对于聚类至关重要

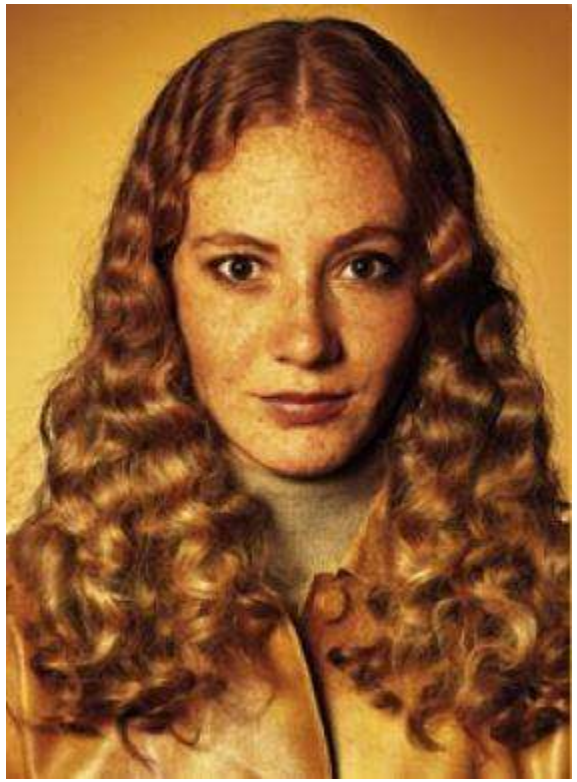

$x_1 \quad \sim? \quad x_2$

图片内容： $x_1 \neq x_2$

图片结构： $x_1 \sim x_2$

颜色分布： $x_1 \sim x_2$

聚类算法——相似度的重要性

不同的场景，不同的评定内容

图片检索	图片内容相似度
图片分割	图片像素（颜色）相似度
网页聚类	文本内容相似度
社交网络聚类	关注人群、喜好、发表内容
电商用户聚类	足迹、购买历史、位置

聚类算法——相似度的重要性

衡量相似度一般使用“**距离——描述向量之间的远近**”

欧式距离

$$d(\boldsymbol{x},\boldsymbol{y}) = \|\boldsymbol{x}-\boldsymbol{y}\| = \sqrt{\sum_{d=1}^{D}(x_d - y_d)^2}$$

曼哈顿距离

$$d(\boldsymbol{x},\boldsymbol{y}) = \sum_{d=1}^{D}|\boldsymbol{x}-\boldsymbol{y}|$$

核函数映射距离

$$d(\boldsymbol{x},\boldsymbol{y}) = \|\emptyset(\boldsymbol{x}) - \emptyset(\boldsymbol{y})\|$$

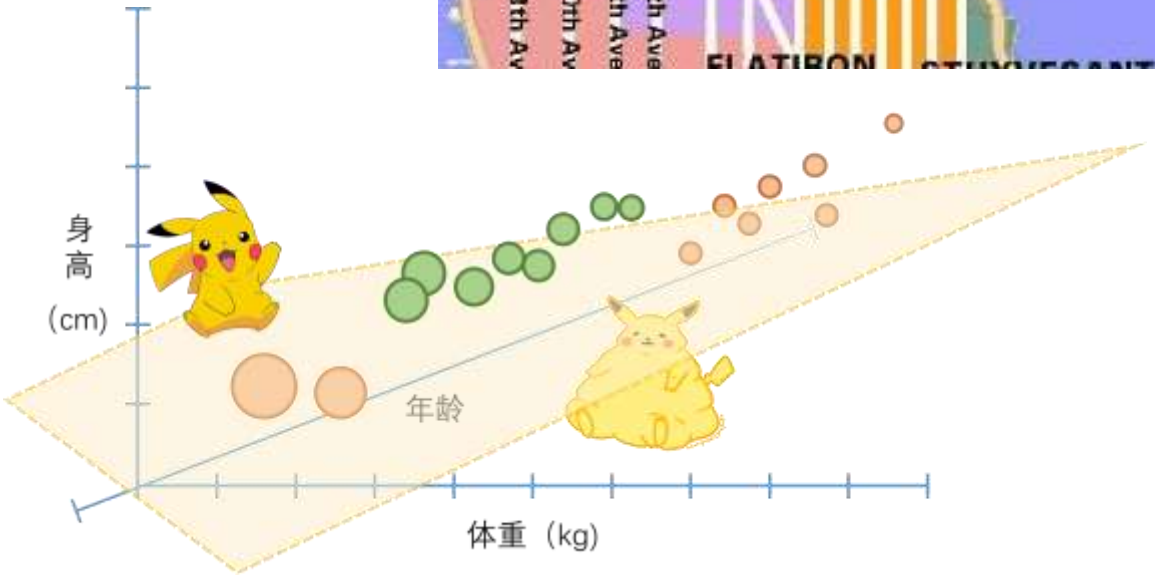

聚类算法——相似度的重要性

衡量相似度一般使用“**距离——描述向量之间的远近**”

余弦距离？

$$d(\boldsymbol{x},\boldsymbol{y}) = \frac{\boldsymbol{x}\cdot\boldsymbol{y}}{|\boldsymbol{x}||\boldsymbol{y}|}$$

衡量向量方向的区别

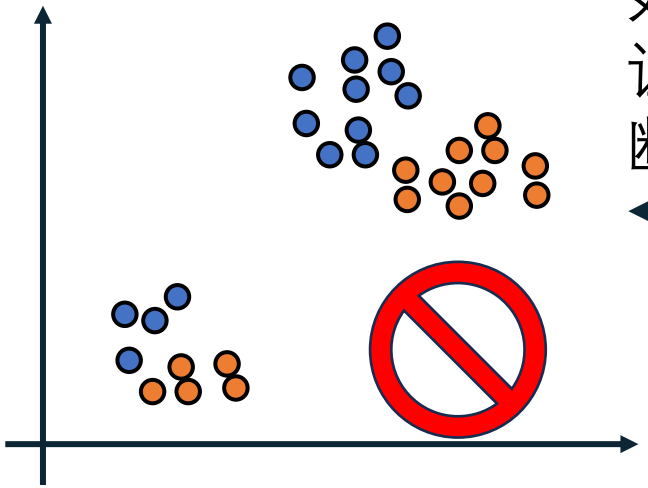

如何量化聚类结果，让计算机可以自行判断优劣？

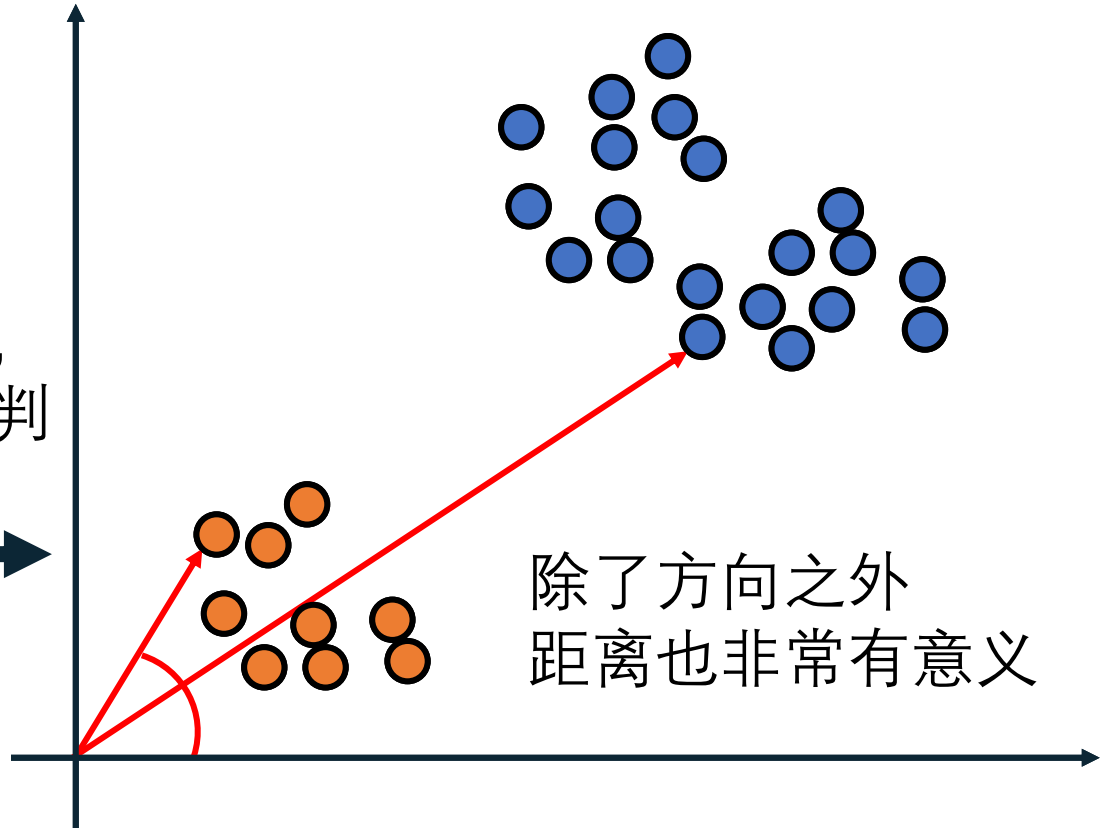

除了方向之外
距离也非常有意义

聚类算法——没有标签，如何评价结果好坏?

能够评价聚类结果好坏的信息：样本间的**相似度**

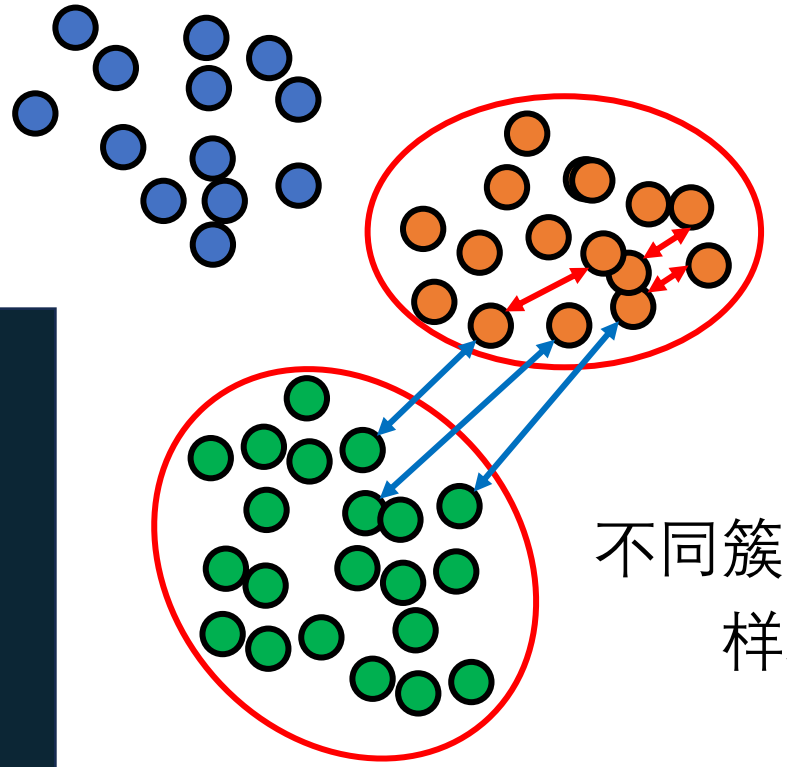

同一个簇（Cluster）中的样本距离近

不同簇（Cluster）的样本距离园

理想聚类

类内样本相似度高

类间样本相似度低

最常用的聚类算法——K-Means

K-Means

簇的数量

计算平均值

最常用的聚类算法——K-Means

K-Means算法步骤

① 初始化k和中心点位置

循环以下步骤至中心点位置稳定:

② 计算所有点到k个中心点的位置

③ 将各个点与最近中心点归为一类

④ 逐一计算各簇的均值并作为新中心点

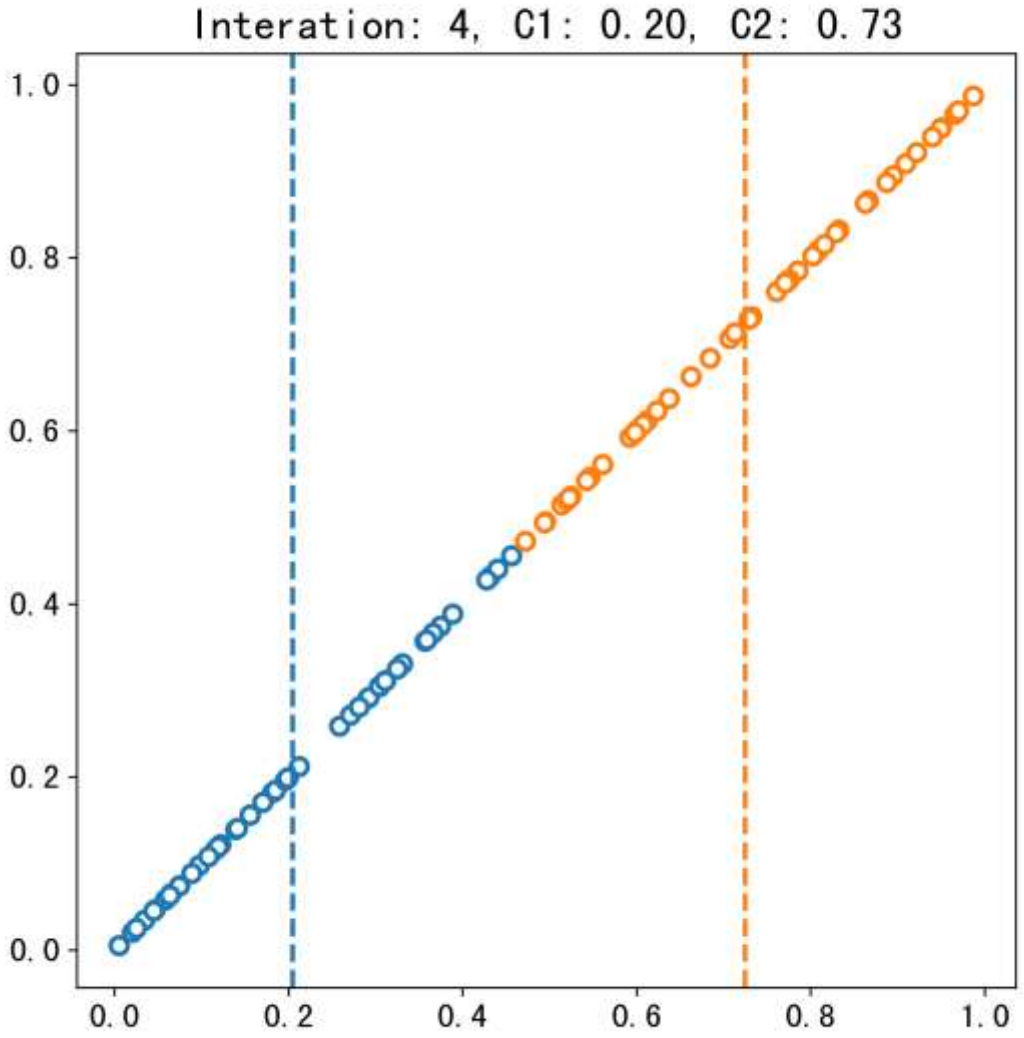

最常用的聚类算法——K-Means

K-Means算法步骤

① 初始化k和中心点位置

循环以下步骤至中心点位置稳定:

② 计算**所有点**到k个中心点的位置

③ 将**各个点**与最近中心点归为一类

④ 逐一**计算各簇的均值**并作为新中心点

皆为常量不影响聚类结果

最常用的聚类算法——K-Means

K-Means算法步骤

① 初始化k和中心点位置　　**能够影响聚类效果的变量**

循环以下步骤至中心点位置稳定:

② 计算所有点到k个中心点的位置

③ 将各个点与最近中心点归为一类

④ 逐一计算各簇的均值并作为新中心点

皆为常量不影响聚类结果

K-Means聚类之K值的选择

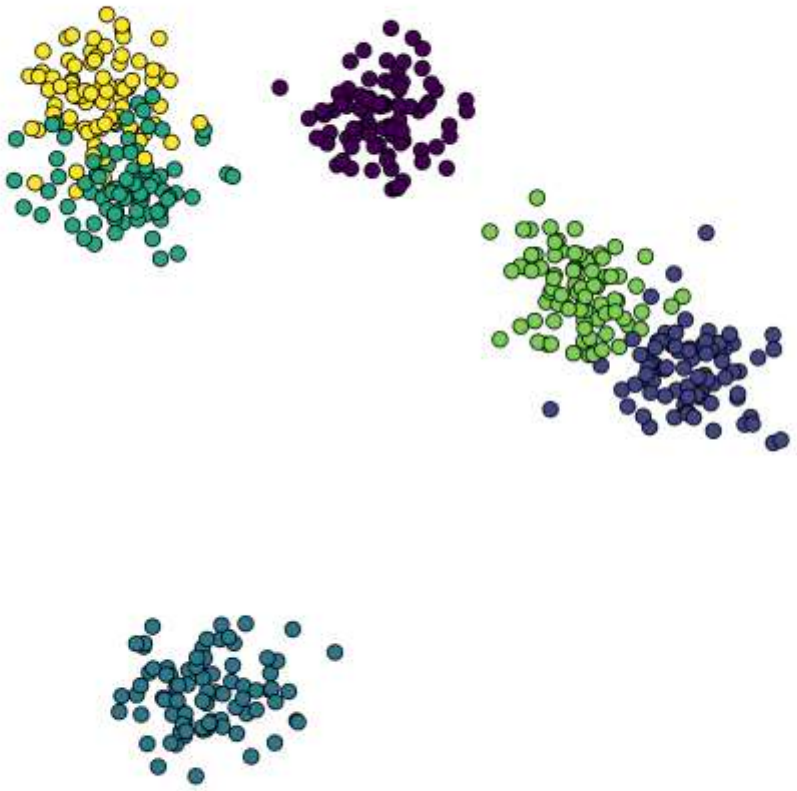

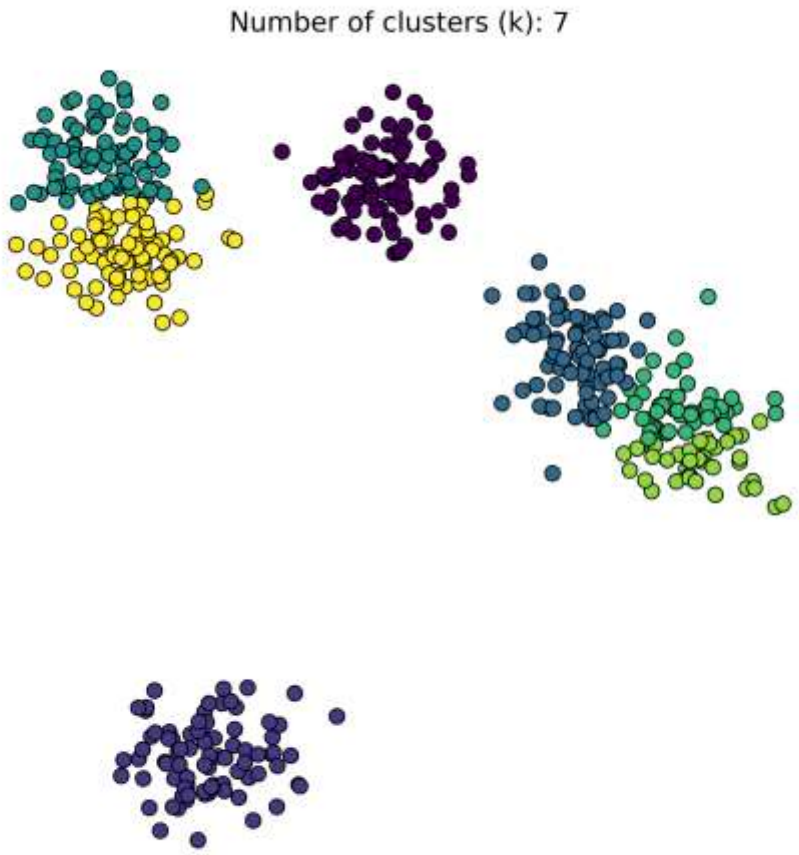

【真实情况】6个聚类，500个样本

应该如何确定K呢?

K-Means聚类之K值的选择

误差平方和 Sum of Squared Errors (SSE)

描述聚类样本中的紧密程度

$$sse = \boxed{\sum_{k=1}^{K}}\boxed{\sum_{n=1}^{N_k}}(x_n - \mu_k)^2$$

样本和中心点的距离

簇中所有样本

中心点数量（簇的数量）

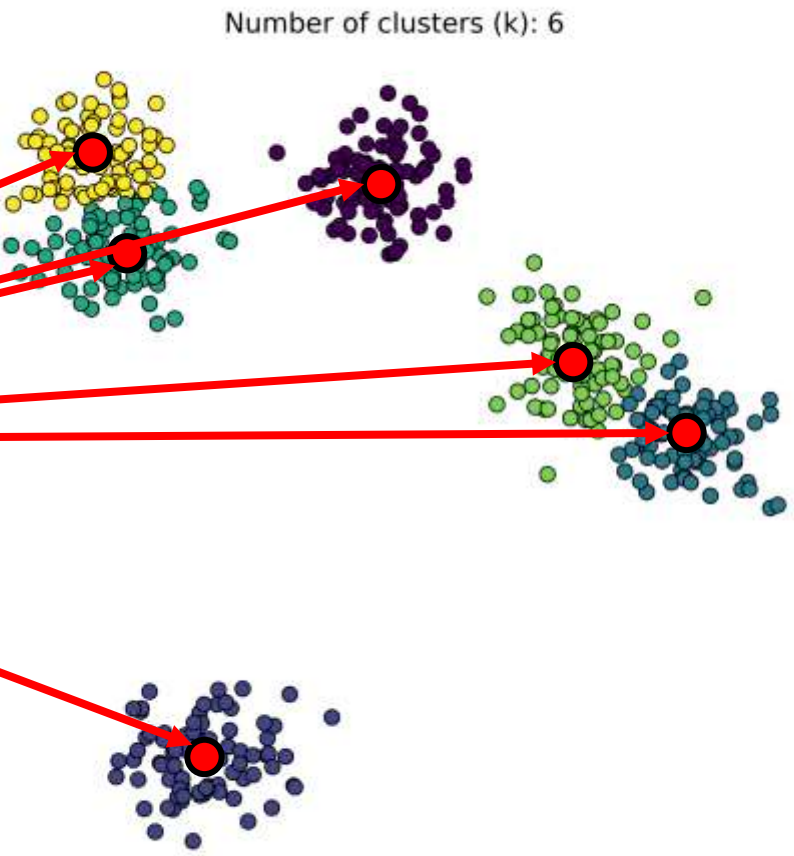

K-Means聚类之K值的选择

误差平方和 Sum of Squared Errors (SSE)

描述聚类样本中的紧密程度

$$sse = \frac{\sum_{k=1}^{K}\sum_{n=1}^{N_k}(x_n - \mu_k)^2}{N} \quad ?$$

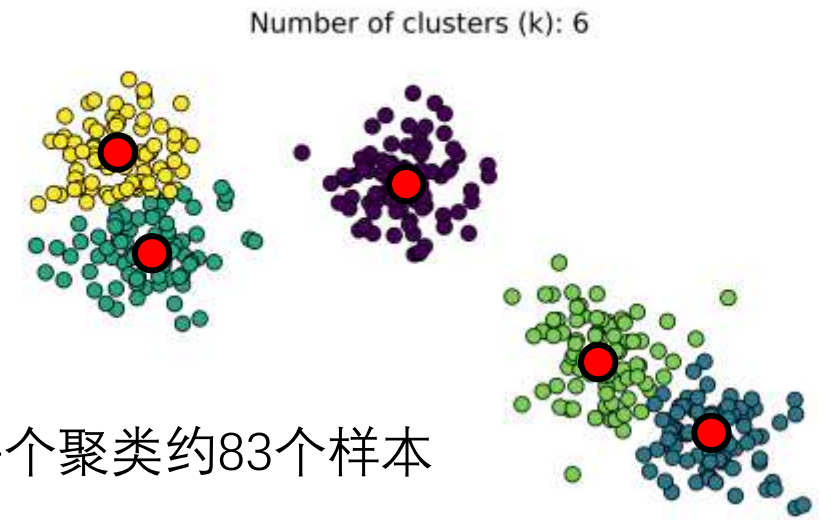

$K = 6$，每个聚类约83个样本

$N = 6 \times 83 \approx 500$

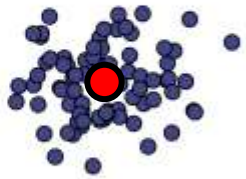

K-Means聚类之K值的选择

误差平方和 Sum of Squared Errors (SSE)

描述聚类样本中的紧密程度

$$sse = \frac{\sum_{k=1}^{K}\sum_{n=1}^{N_k}(x_n - \mu_k)^2}{\boldsymbol{N}} \quad ?$$

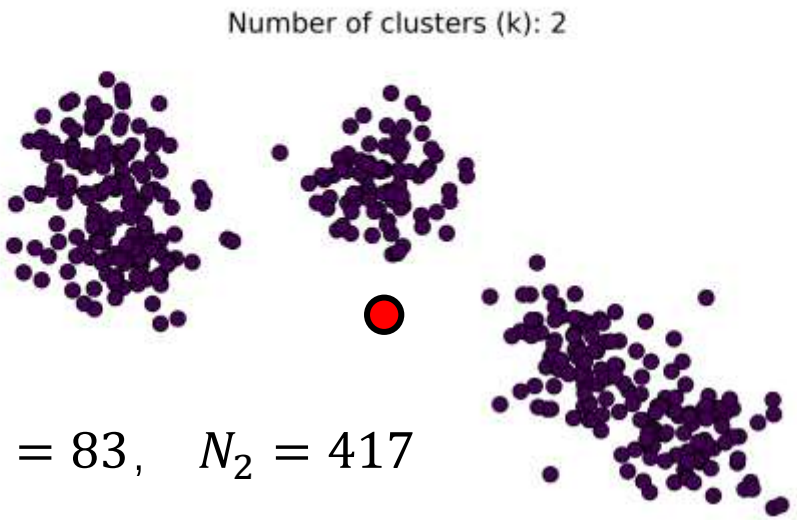

$K = 2, \quad N_1 = 83, \quad N_2 = 417$

$\boldsymbol{N} = N_1 + N_2 = 500$

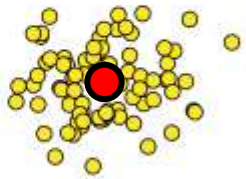

- $\boldsymbol{N}$为所有样本的数量，不随K变化
- $sse_2 > sse_6$： $K = 2$的聚类结果没有K =6紧凑

K-Means聚类之K值的选择

使用K和SSE画出肘部曲线（Elbow Curve）

尝试不同的K值（2，…，19）

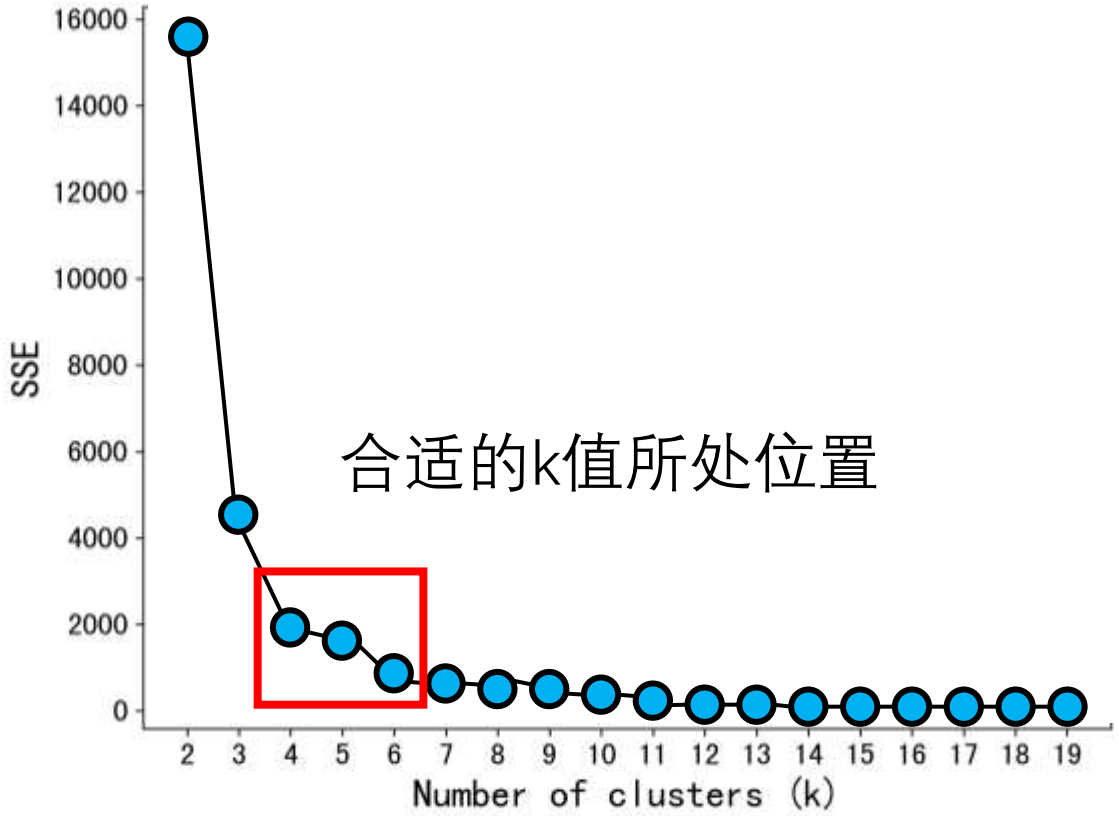

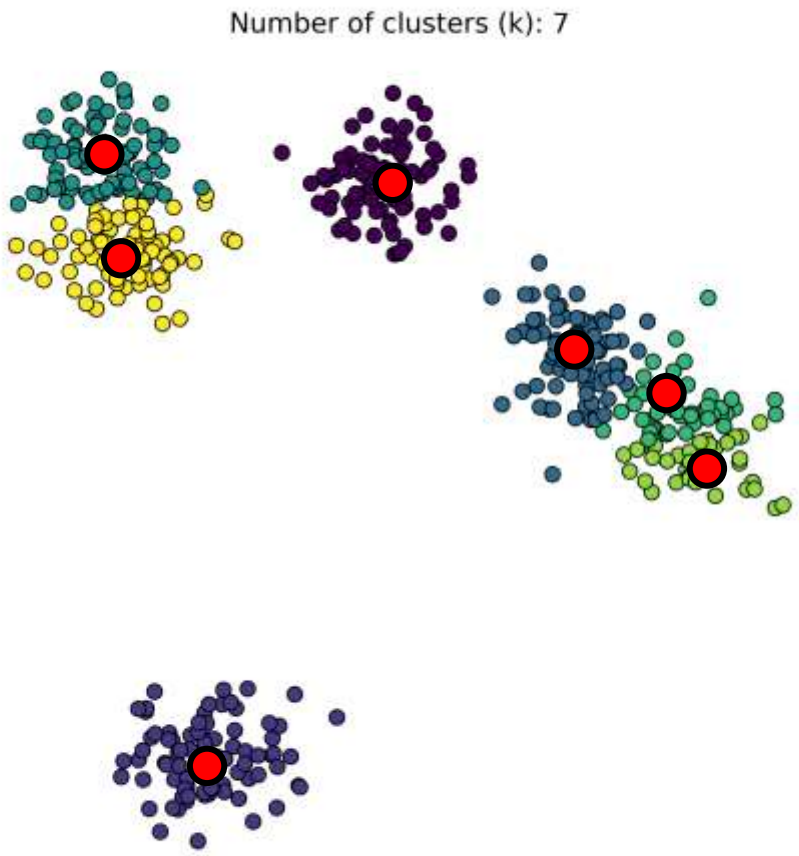

K-Means聚类之中心点的选择

中心点的初始位置也会影响聚类效果

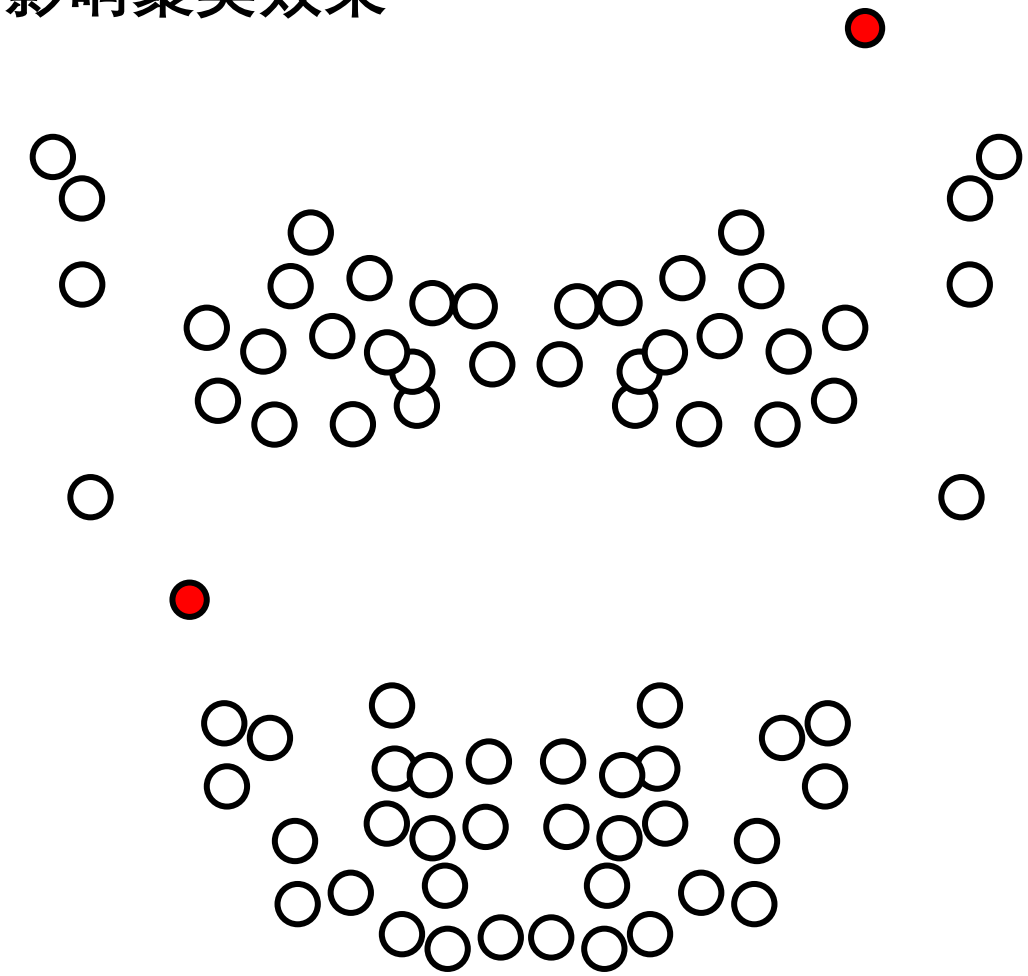

K-Means聚类之中心点的选择

中心点的初始位置也会影响聚类效果

一种特殊的情况

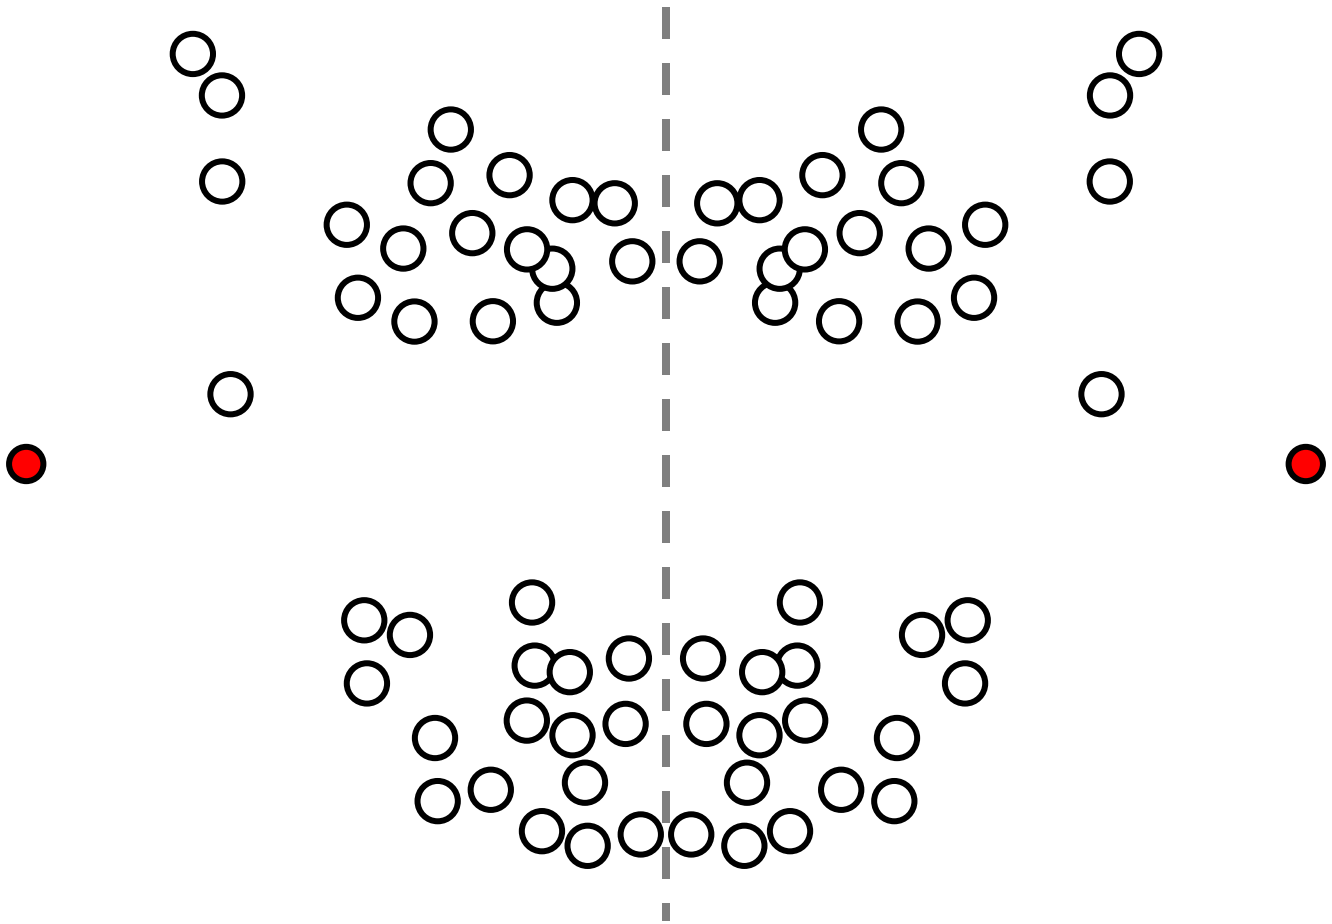

K-Means聚类之中心点的选择

中心点的初始位置也会影响聚类效果

一种特殊的情况

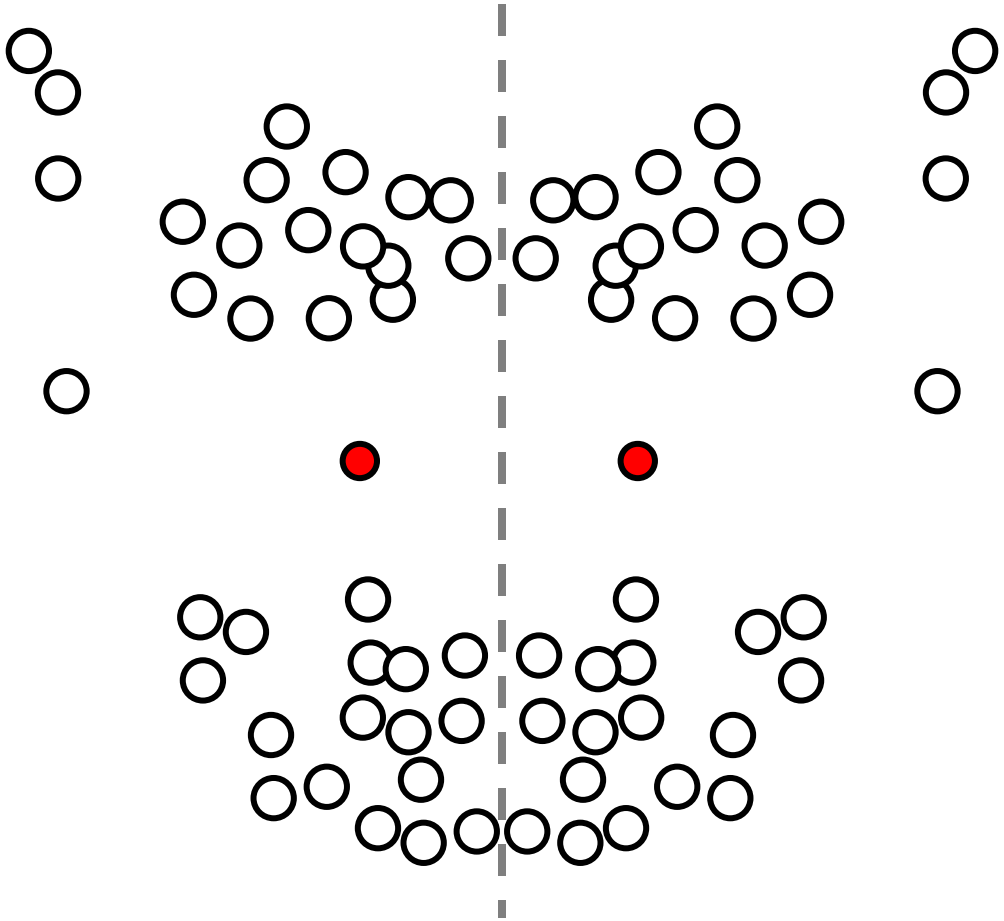

K-Means聚类之中心点的选择

中心点的初始位置也会影响聚类效果

一种特殊的情况

多次随机选择最优

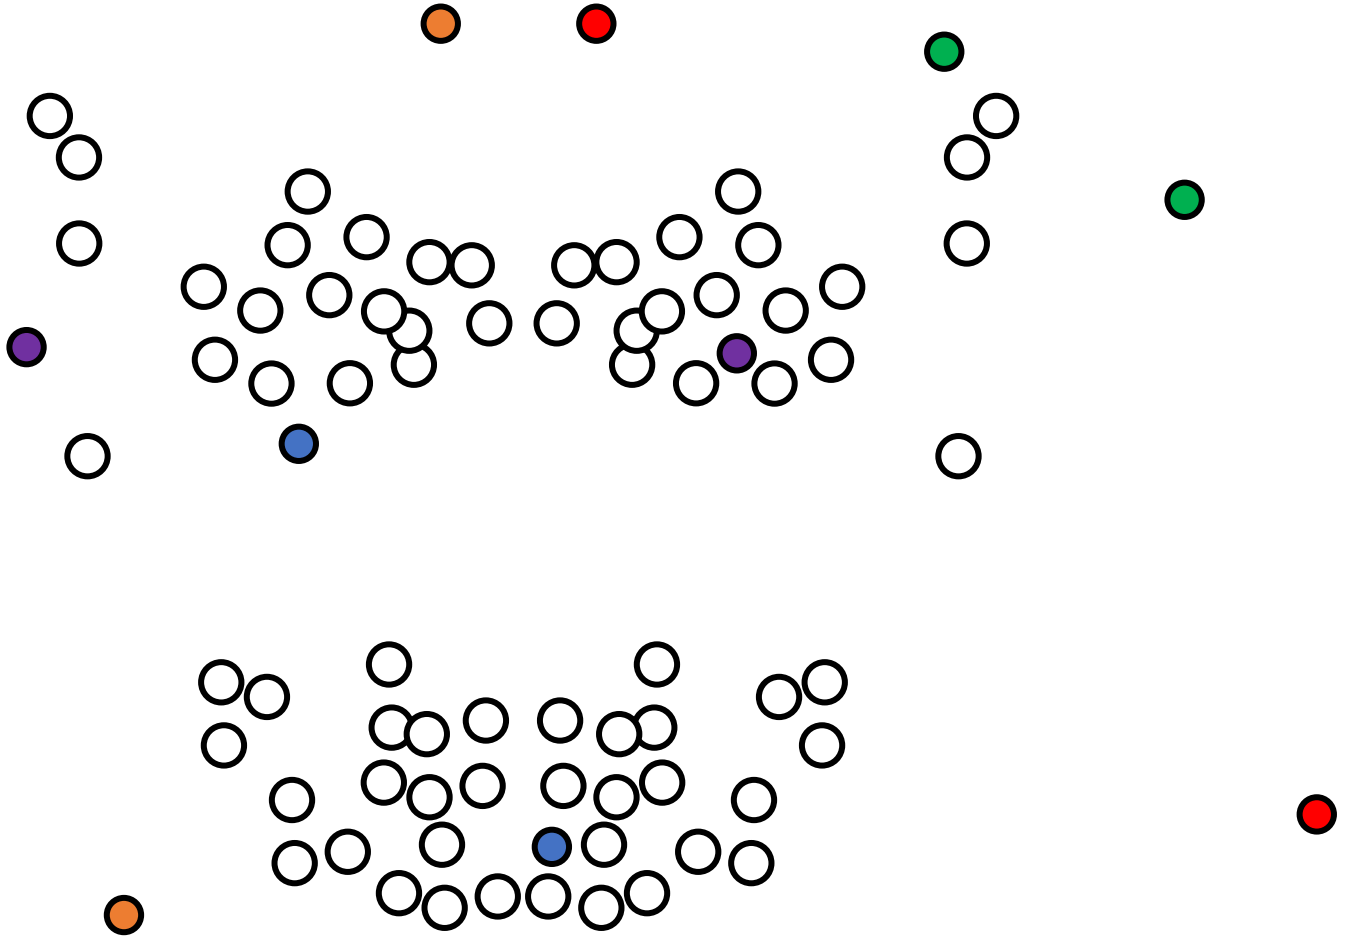

K-Means聚类之中心点的选择

以均值作为中心点对噪声尤其敏感

当存在噪声时……

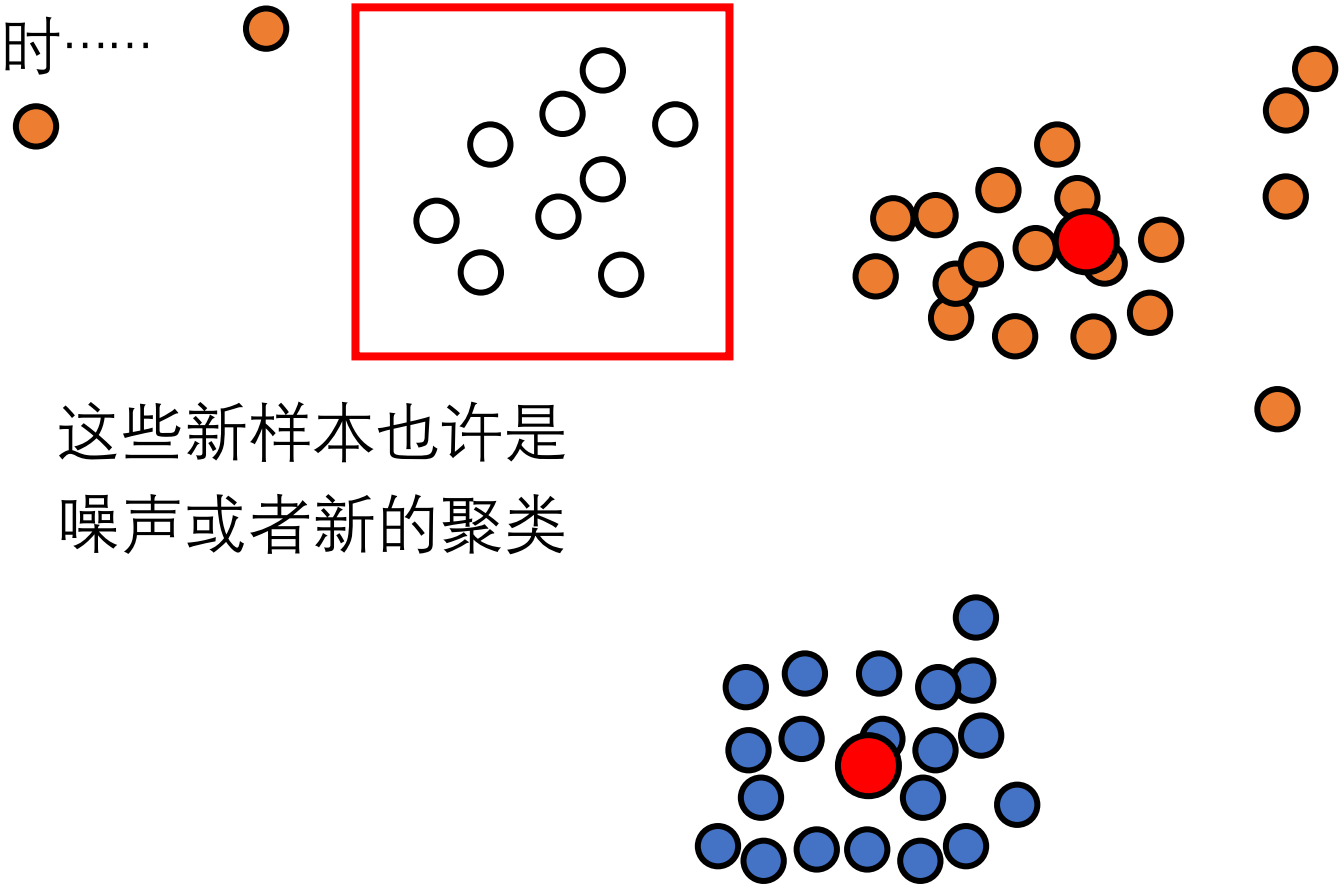

这些新样本也许是
噪声或者新的聚类

K-Means聚类之中心点的选择

以靠近均值的实际样本作为中心点

当存在噪声时……

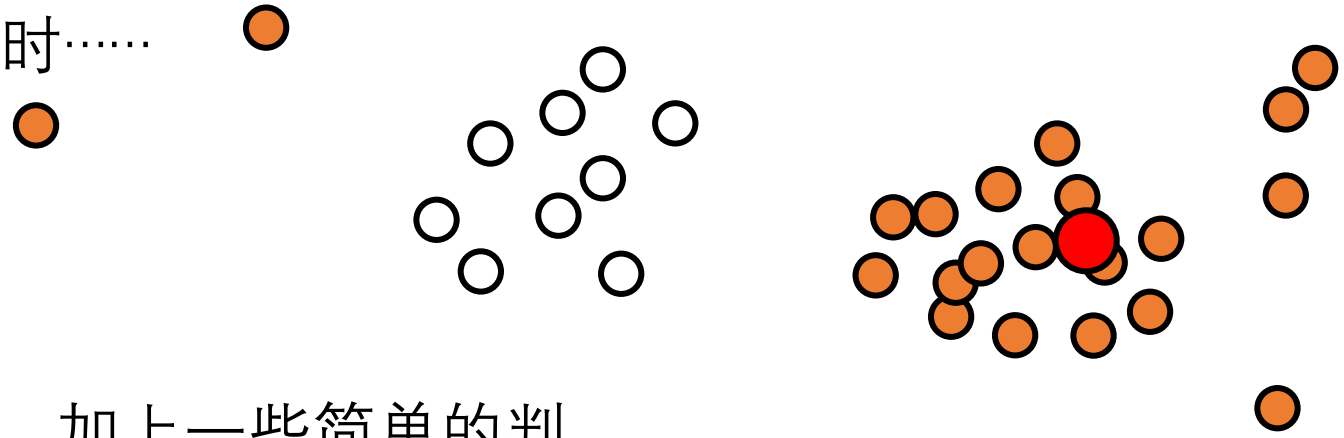

加上一些简单的判断就能检测出噪声或者新的聚类

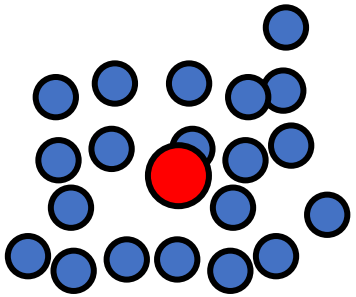

K-Means聚类应用——图像的二值分割

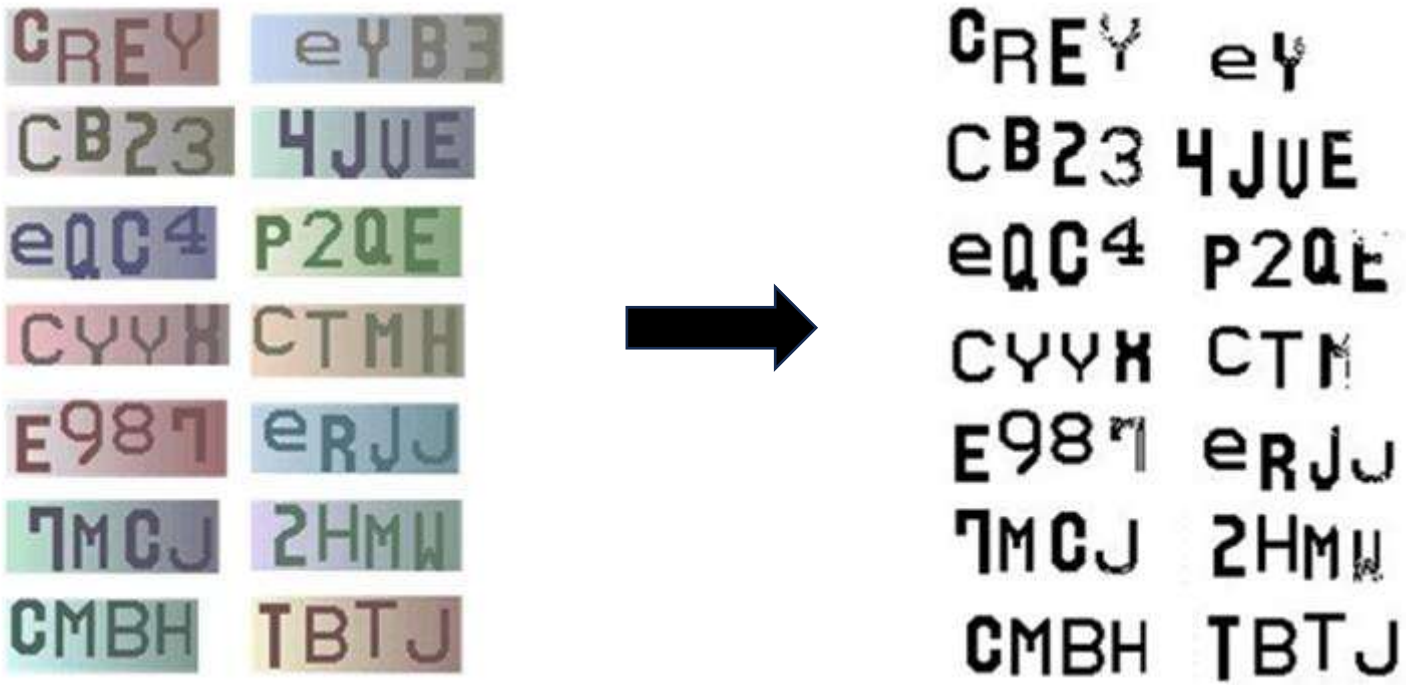

通过聚类区分图片的前景与背景
提取关键的信息用于后续的处理

K-Means聚类应用——图像的二值分割

以车牌识别为例

① 将图片转为灰度图像：像素值在[0, 255]区间内

② 使用k-Means聚为两类

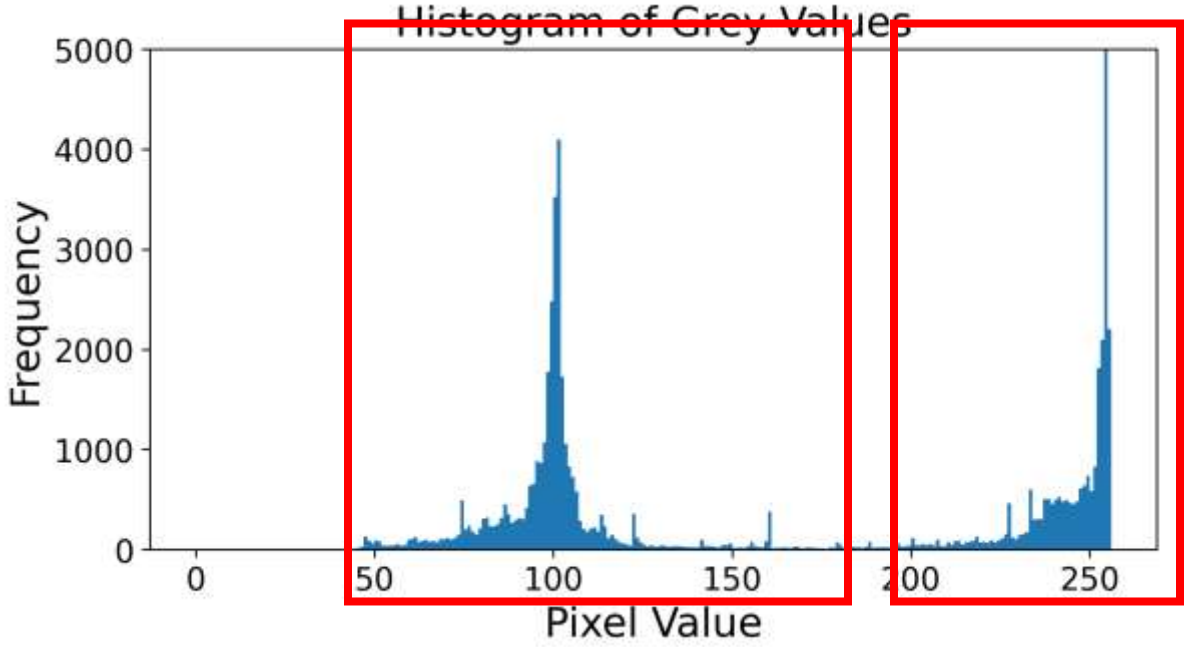

前景　　背景

K-Means聚类应用——图像的二值分割

以车牌识别为例

① 将图片转为灰度图像：像素值在[0, 255]区间内

② 使用k-Means聚为两类

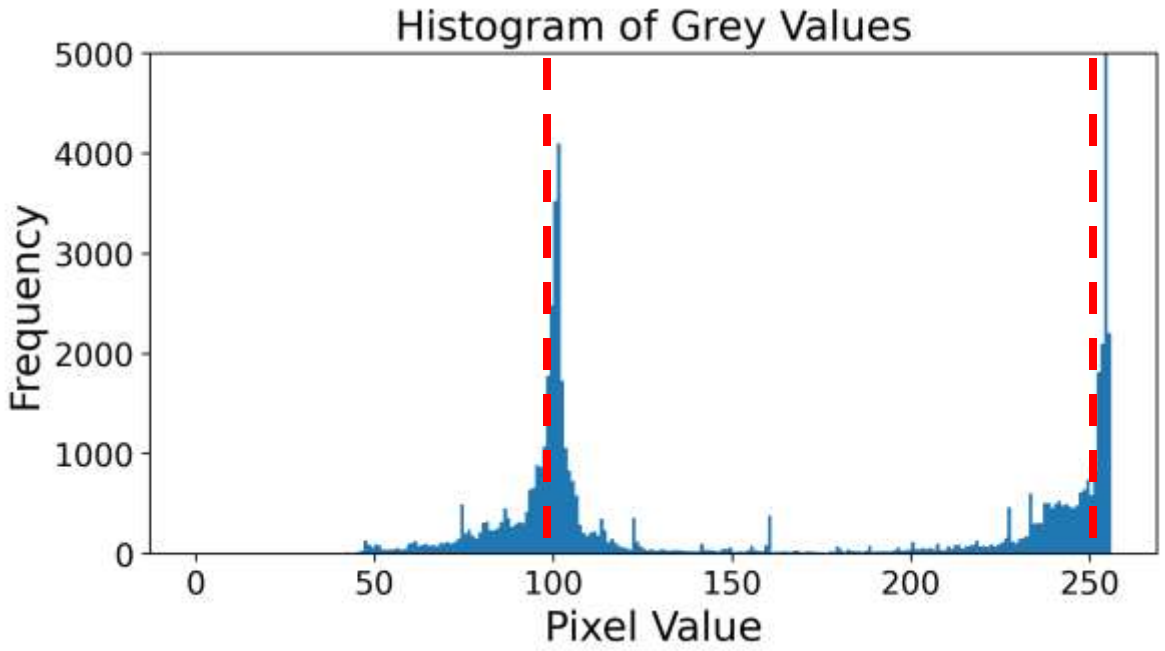

Final Centers: [252.55062255 98.44364715], Iteration:

K-Means聚类应用——图像压缩

K = 2

K = 4

2160X1080的RGB图像

假设每个像素需要3个Byte存储

Buffer = 2160 X 1080 X 3 = 6998400 bytes

= 6998400 / 1024^2 = 6.67 MB

通过“颜色+位置”的方式编码来压缩图像

通过减少颜色进行有损下所

K-Means聚类应用——图像压缩

K-Means聚类应用——图像压缩

K越小，即颜色越少，图像存储所需空间越小

K越大，颜色越多，图像质量越好

bmwk_comp_2.png	类型: PNG 文件 分辨率: 2160 x 1080	大小: 103 KB
bmwk_comp_4.png	类型: PNG 文件 分辨率: 2160 x 1080	大小: 261 KB
bmwk_comp_8.png	类型: PNG 文件 分辨率: 2160 x 1080	大小: 513 KB
bmwk_comp_16.png	类型: PNG 文件 分辨率: 2160 x 1080	大小: 831 KB
bmwk_comp_32.png	类型: PNG 文件 分辨率: 2160 x 1080	大小: 1.19 MB
bmwk_comp_64.png	类型: PNG 文件 分辨率: 2160 x 1080	大小: 1.69 MB

小结

聚类的概念及应用

↓

K-Means算法及K值和中心点的影响

↓

K-Means的应用

↓

二值分割

图像压缩