4.3 协同过滤与电影推荐

面向用户的协同过滤 & 面向物品的协同过滤

问题 1：喜欢动作电影的人会喜欢动画电影吗？

问题 2：他/她愿意去看这部电影吗？

问题 1：喜欢动作电影的人会喜欢动画电影吗？

? ? ? ? ? ? ? ? ? ? ? ? ? ?

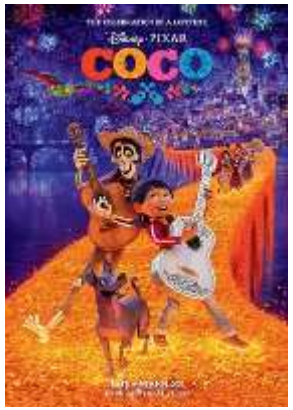

问题 1：喜欢动作电影的人会喜欢动画电影吗？

假设：客观的评分与主观的喜爱程度成正比

用户	动作电影喜爱程度	动画电影喜爱程度
1	3.6	2.6
2	4.8	1.3
3	0.5	1.2
…	…	…

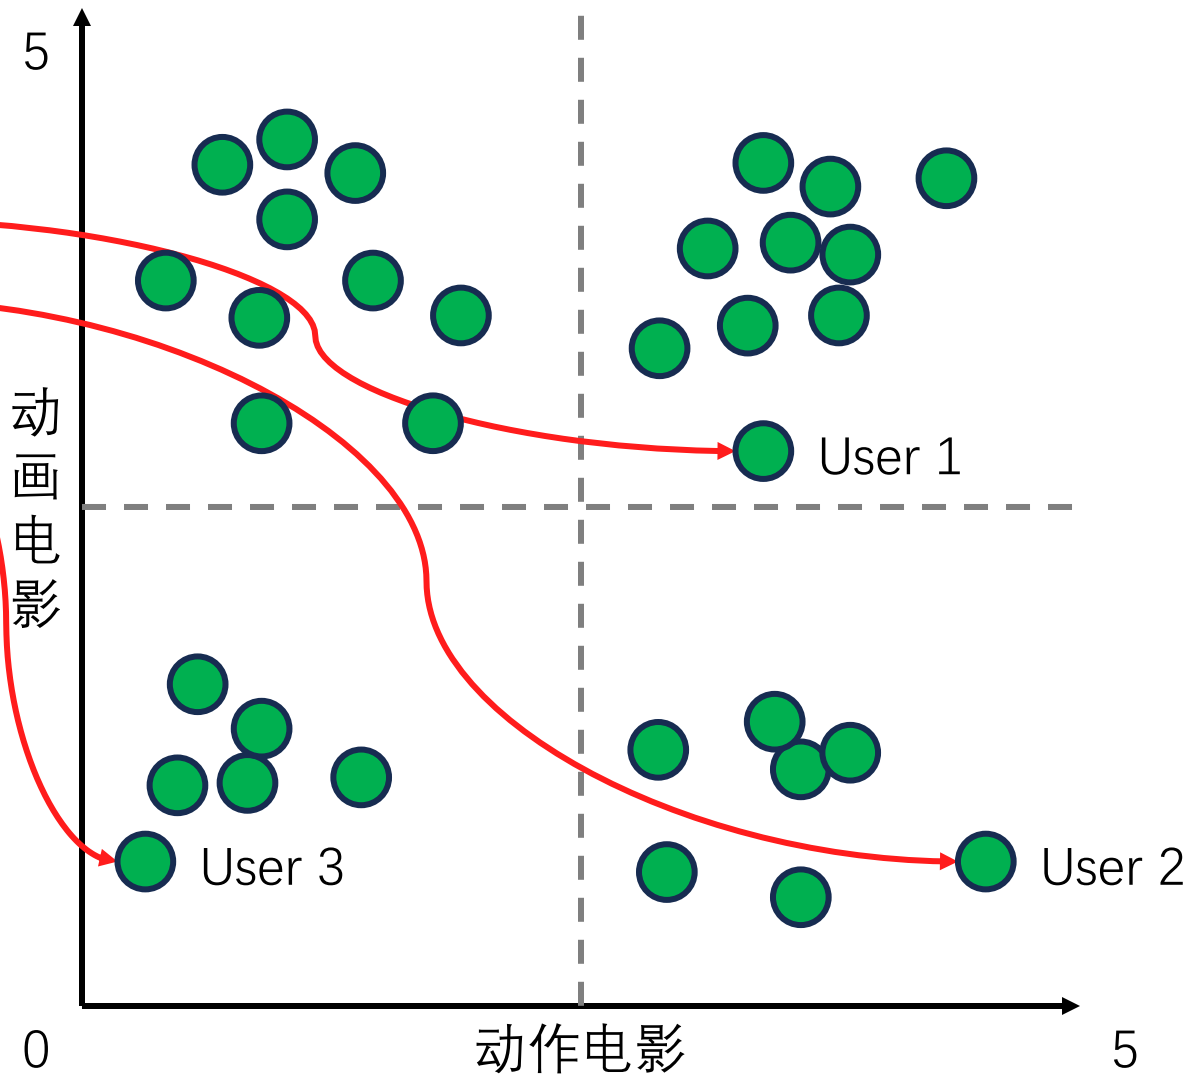

问题 1：喜欢动作电影的人会喜欢动画电影吗？

假设：客观的评分与主观的喜爱程度成正比

用户	动作电影喜爱程度	动画电影喜爱程度
1	3.6	2.6
2	4.8	1.3
3	0.5	1.2
…	…	…

- 喜爱动作电影，喜爱动画电影
- 不喜动作电影，喜爱动画电影
- 不喜动作电影，不喜动画电影
- 喜爱动作电影，不喜动画电影

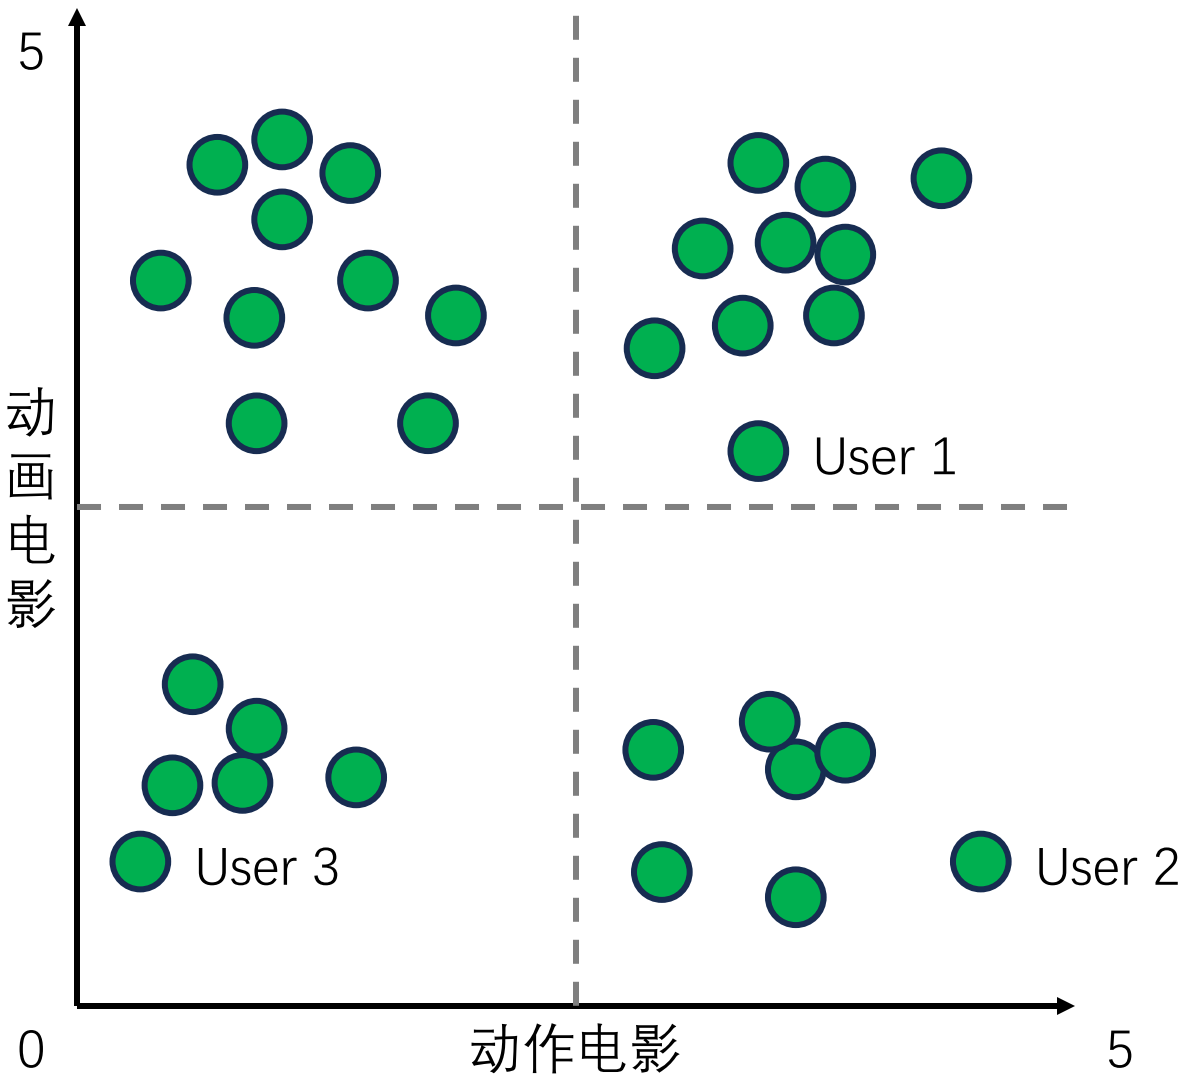

问题 1：喜欢动作电影的人会喜欢动画电影吗？

假设：客观的评分与主观的喜爱程度成正比

用户	动作电影喜爱程度	动画电影喜爱程度
1	3.6	2.6
2	4.8	1.3
3	0.5	1.2
…	…	…

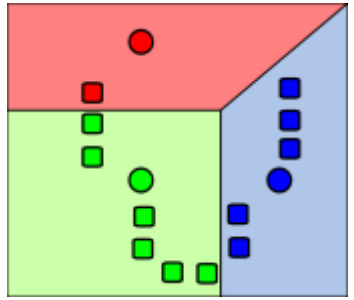

K-Means

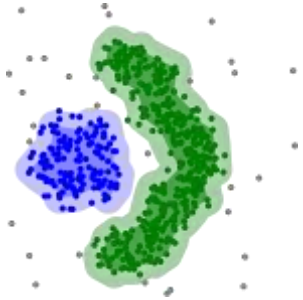

DBSCAN

问题 1：喜欢动作电影的人会喜欢动画电影吗？

ml-latest-small

5-star rating and free-text tagging

100836 ratings

3683 tags

9742 movies

610 users

March 29, 1996 and September 24, 2018

Users had rated at least 20 movies

Links.csv, **movies.csv**, **ratings.csv**, and tags.csv

https://movielens.org/

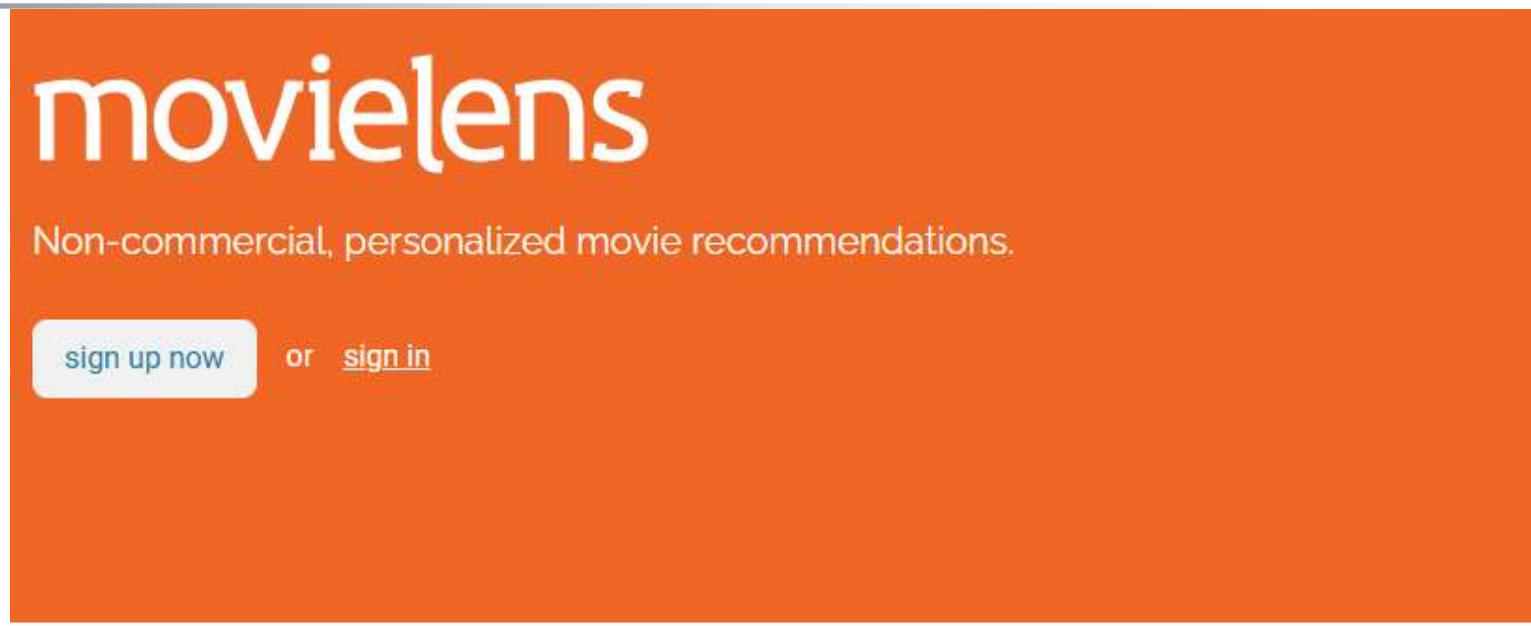

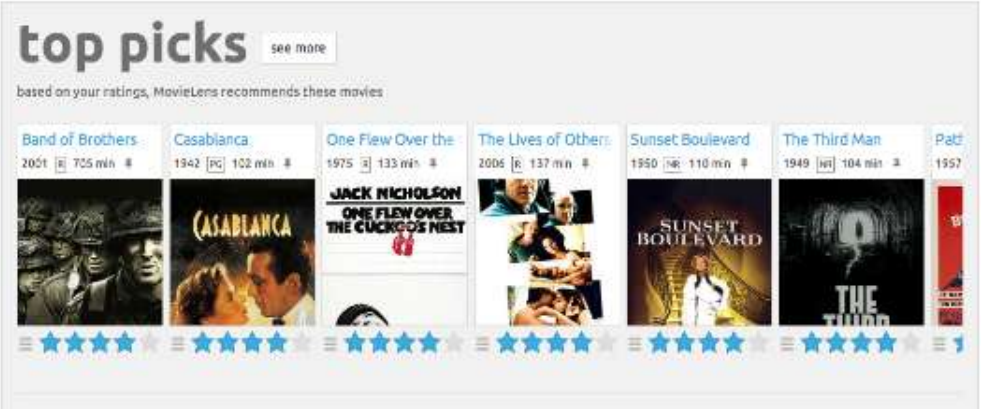

问题 1：喜欢动作电影的人会喜欢动画电影吗？

movies.csv

	movieId	title	genres
0	1	Toy Story (1995)	Adventure|Animation|Children|Comedy|Fantasy
1	2	Jumanji (1995)	Adventure|Children|Fantasy
2	3	Grumpier Old Men (1995)	Comedy|Romance
3	4	Waiting to Exhale (1995)	Comedy|Drama|Romance
4	5	Father of the Bride Part II (1995)	Comedy

Genres: (no genres listed) | 动作（Action）
| 冒险（Adventure）| 动画（Animation）
| 儿童（Children）| 喜剧（Comedy）
| 犯罪（Crime）| 纪录片（Documentary）
| 剧情（Drama）| 奇幻（Fantasy）
| 黑色电影（Film-Noir）| 恐怖（Horror）
| IMAX | 音乐（Musical）| 推理（Mystery）
| 爱情（Romance）| 科幻（Sci-Fi）
| 惊悚（Thriller）| 战争（War）
| 西部（Western）

ratings.csv

	userId	movieId	rating	timestamp
0	1	1	4.0	964982703
1	1	3	4.0	964981247
2	1	6	4.0	964982224
3	1	47	5.0	964983815
4	1	50	5.0	964982931

喜欢动作电影的人会喜欢动画电影吗？

movies.csv

	movieId	title	genres
0	1	Toy Story (1995)	Adventure|Animation|Children|Comedy|Fantasy
~~1~~	~~2~~	~~Jumanji (1995)~~	~~Adventure|Children|Fantasy~~
~~2~~	~~3~~	~~Grumpier Old Men (1995)~~	~~Comedy|Romance~~
~~3~~	~~4~~	~~Waiting to Exhale (1995)~~	~~Comedy|Drama|Romance~~
~~4~~	~~5~~	~~Father of the Bride Part II (1995)~~	~~Comedy~~

清洗数据 1：筛掉所有非动作和动画电影

清洗数据 2：筛掉非动作和动画电影的评分

数据预处理：逐个计算用户对电影类型的平均分

ratings.csv

	userId	movieId	rating	timestamp
0	1	1	4.0	964982703
~~1~~	~~1~~	~~3~~	~~4.0~~	~~964981247~~
2	1	6	4.0	964982224
3	1	47	5.0	964983815
~~4~~	~~1~~	~~50~~	~~5.0~~	~~964982931~~

user_genres_rates

	Action	Animation
0	4.322222	4.689655
1	3.954545	0.000000
2	3.571429	0.500000
3	3.320000	4.000000
4	3.111111	4.333333

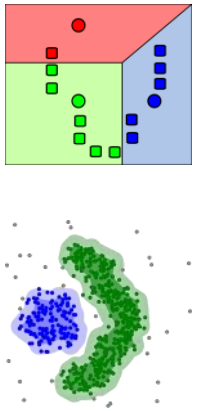

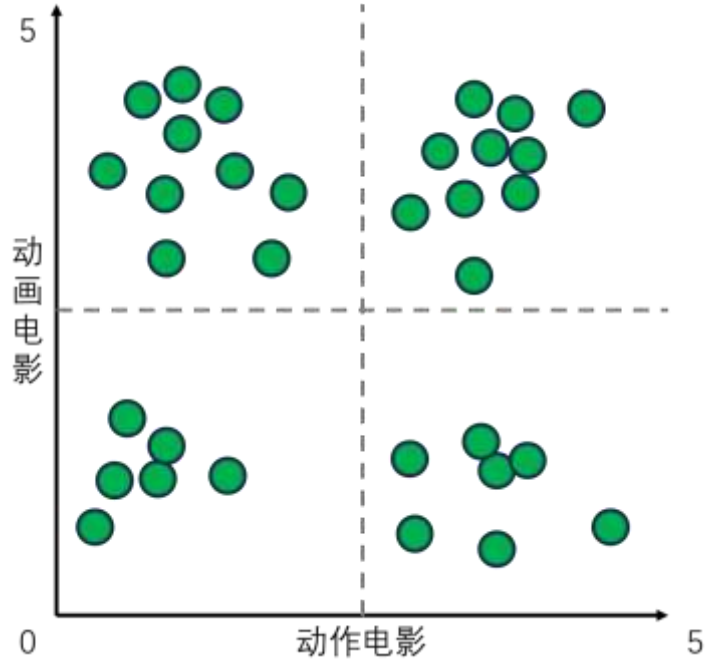

喜欢动作电影的人会喜欢动画电影吗？

绘制用户对于动作和动画电影评分的散点图并使用k-Means聚类

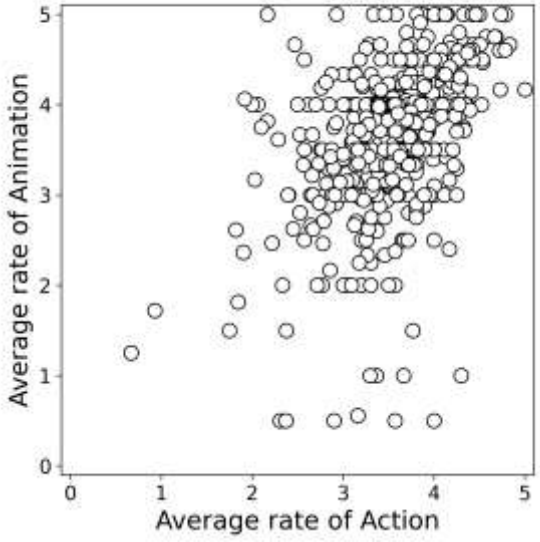

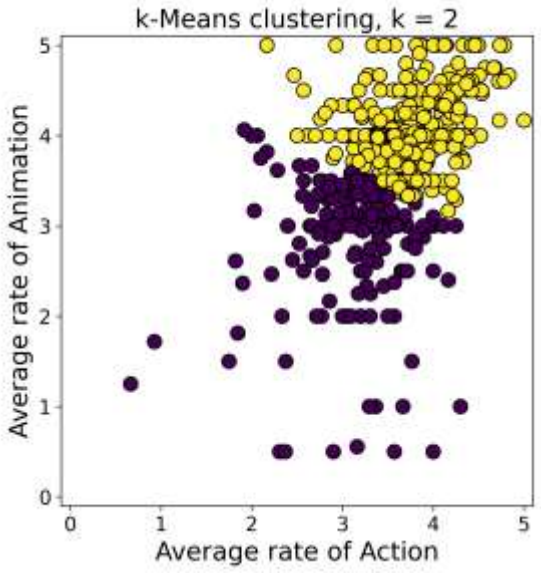

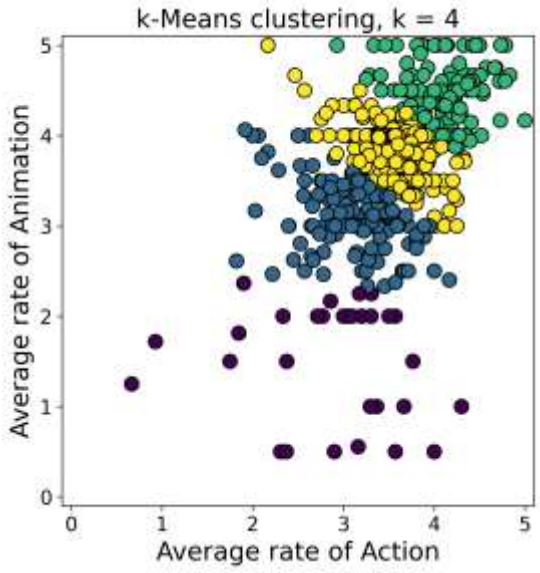

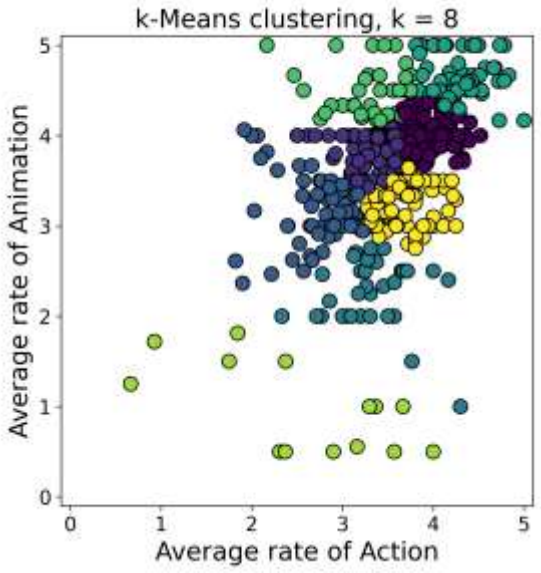

观察1：大部分的人既喜欢动作电影又喜欢动画电影

观察2：喜欢动画电影的极可能喜欢动作电影

观察3：一般喜欢动画电影的一般喜欢动作电影

观察4：不喜欢动画电影的可能喜欢动作电影

观察5：对于用户画像分析而言，聚类力度细不一定是好事

喜欢动作电影的人会喜欢动画电影吗？

使用DBSCAN聚类

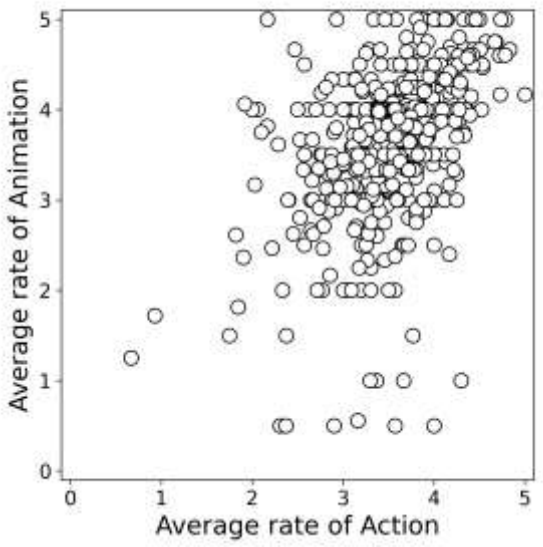

观察1：大部分的人既喜欢动作电影又喜欢动画电影

使用k-Distance确定合适的ϵ（$minPts = 3$）

ID	1	2	3	4	5	…	N
1	0	1.5	3.8	2.5	4.8	…	2.1
2	1.5	0	3.4	4.1			
3	3.8	3.4	0	3.4			
4	2.5	4.1	3.4	0			
5	4.8	1.1	4.2	3.9			
…	…	…	…	…			
N	2.1	0.5	4.9	4.2			

逐行排序

ID	~~1~~	~~2~~	~~3~~	~~4~~	~~5~~	~~…~~	~~N~~
1	0	1.5	2.1	2.5	3.8	4.8	…
			1.1	1.5	3.4	4.1	…
			3.4	3.8	4.2	4.9	…
			3.4	3.9	4.1	4.2	…
			2.7	3.9	4.2	4.8	…
			…	…	…	…	…
			2.1	2.7	4.2	4.9	…

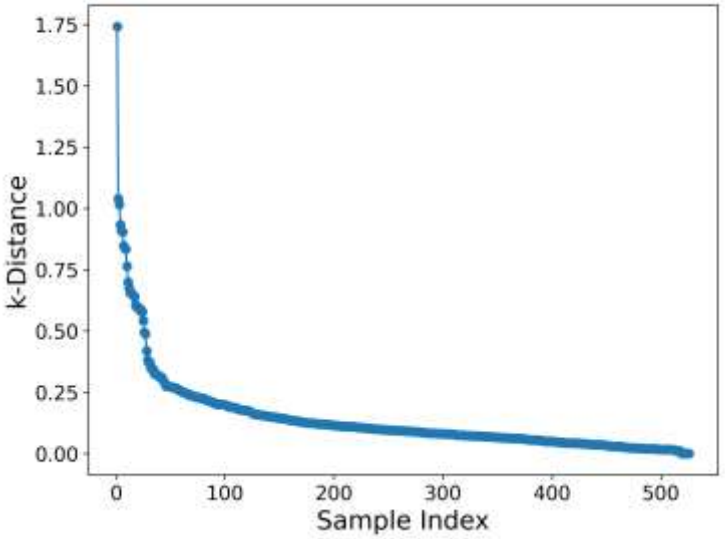

观察2：当ϵ处于0.25附近时，大部分样本密度相连，可形成聚类

喜欢动作电影的人会喜欢动画电影吗？

使用DBSCAN聚类

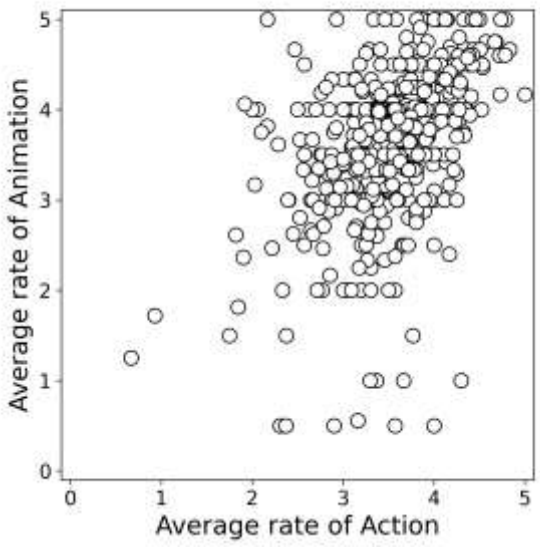

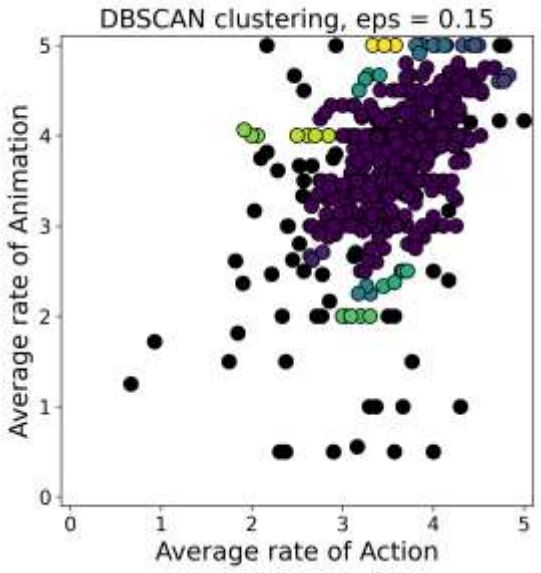

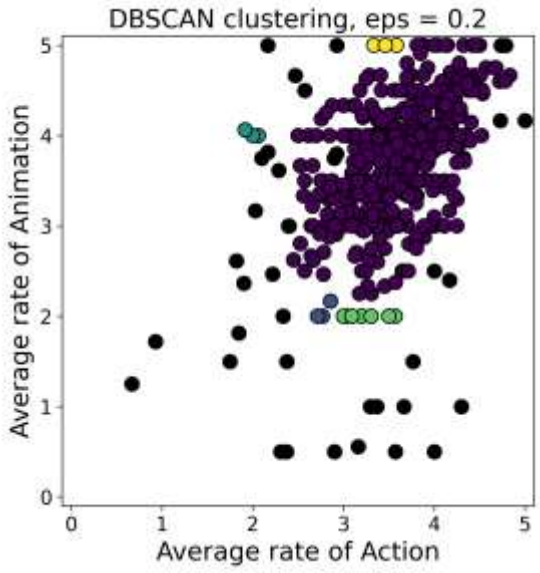

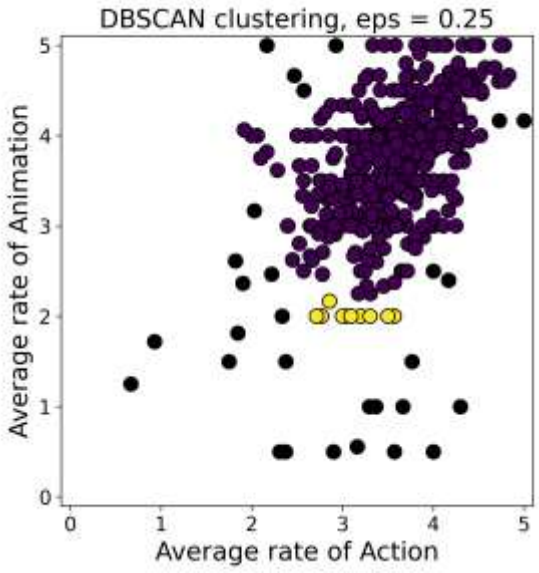

观察1：大部分的人既喜欢动作电影又喜欢动画电影

观察2：当ϵ过小时，聚类结果存在大量难以反映普遍规律的小聚簇

观察3：合适的ϵ形成的聚类能够反映普遍的规律，并且滤除噪声

问题 1：喜欢动作电影的人会喜欢动画电影吗？ 很可能会喜欢

问题 2：他/她愿意看这部电影吗？

他/她愿意看这部电影吗？

对具有相似喜好的用户做进一步分析

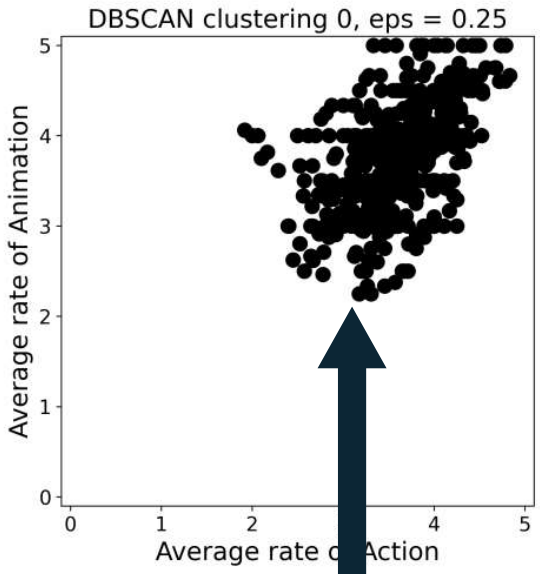

针对个人，如何估计对具体目标的喜爱程度？

协同过滤
Collaborative Filtering

找到相似的用户集合

↓

参考相似用户行为推荐商品

直接广播推荐，覆盖面广但效率不一定高

他/她愿意看这部电影吗？

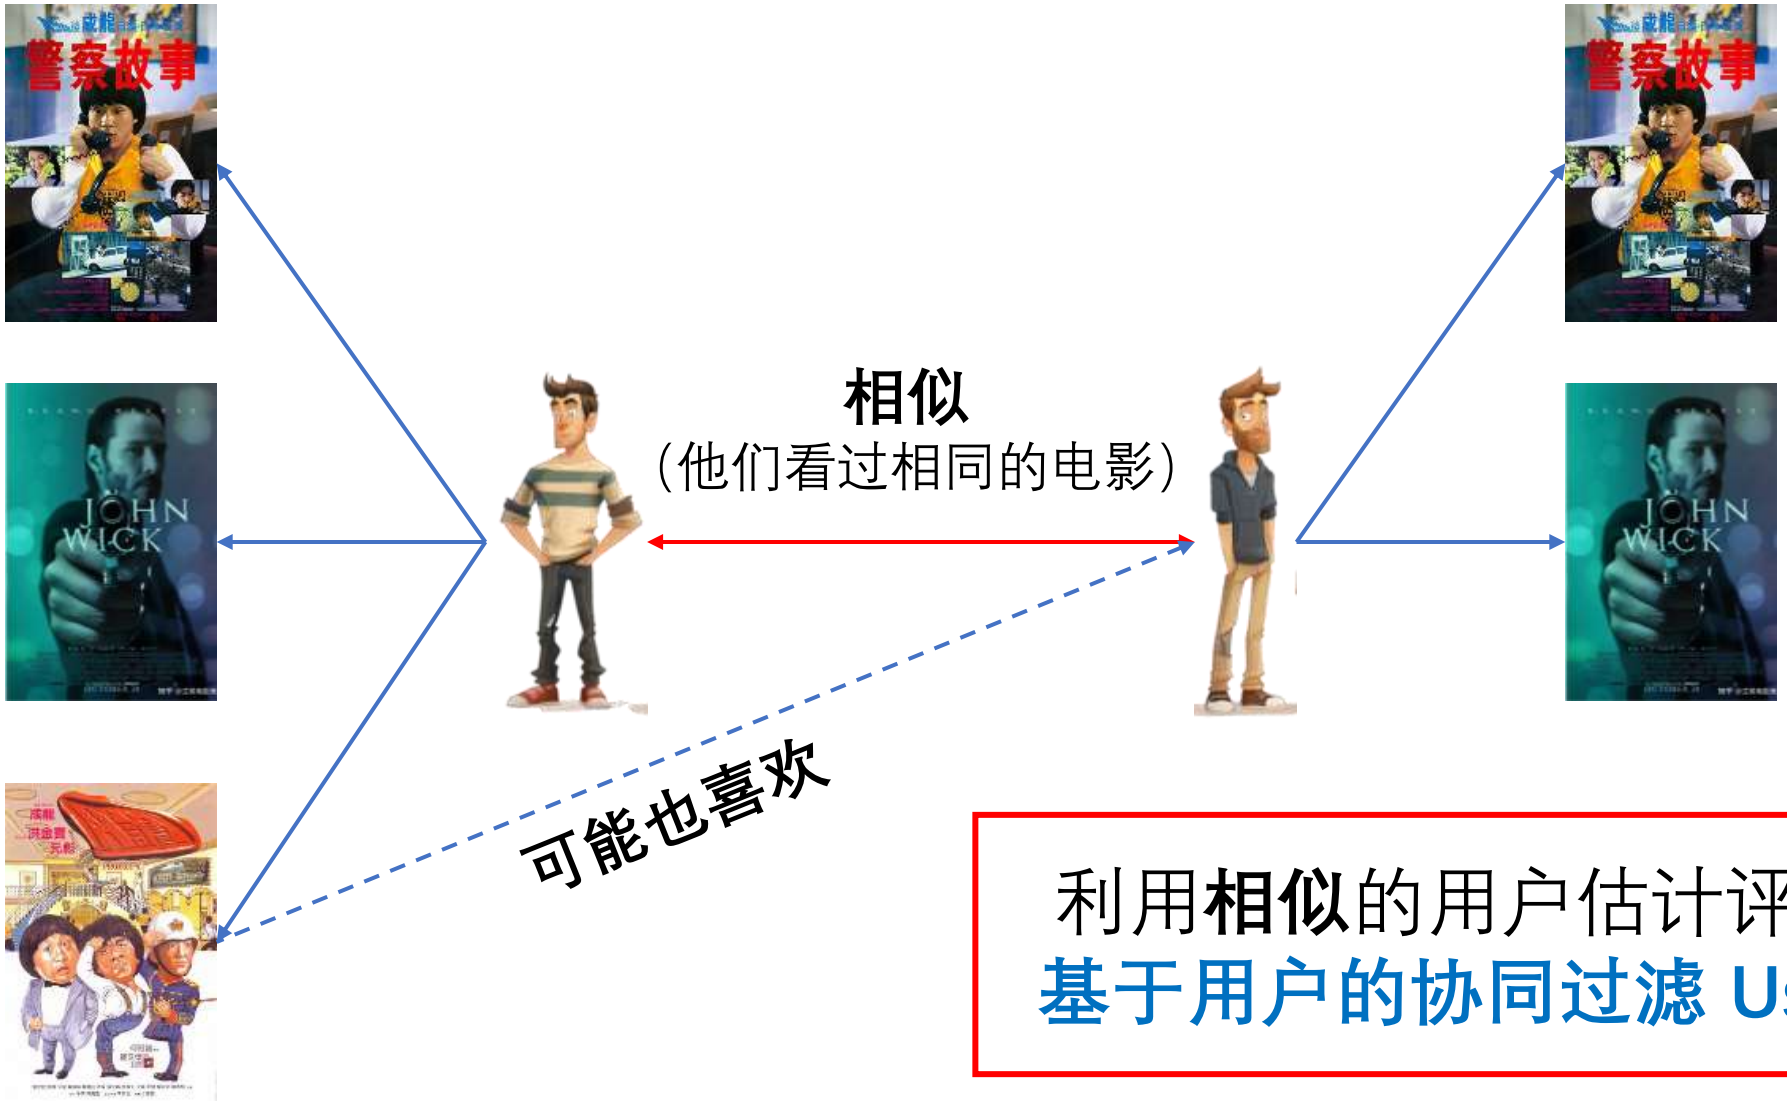

利用**相似**的用户估计评分是
基于用户的协同过滤 UserCF

他/她愿意看这部电影吗？

利用**相似**的物品估计评分是
基于物品的协同过滤 ItemCF

他/她愿意看这部电影吗?

核心问题：相似度的计算

	M1	M2	M3	M4	M5	M6	M7
大壮	4	3	?		5		4
丧彪	3			3	4		
小美	1		3	2			

① Jaccard相似系数: $\frac{|\mathbf{A} \cap \mathbf{B}|}{|\mathbf{A} \cup \mathbf{B}|} \in [0, 1]$

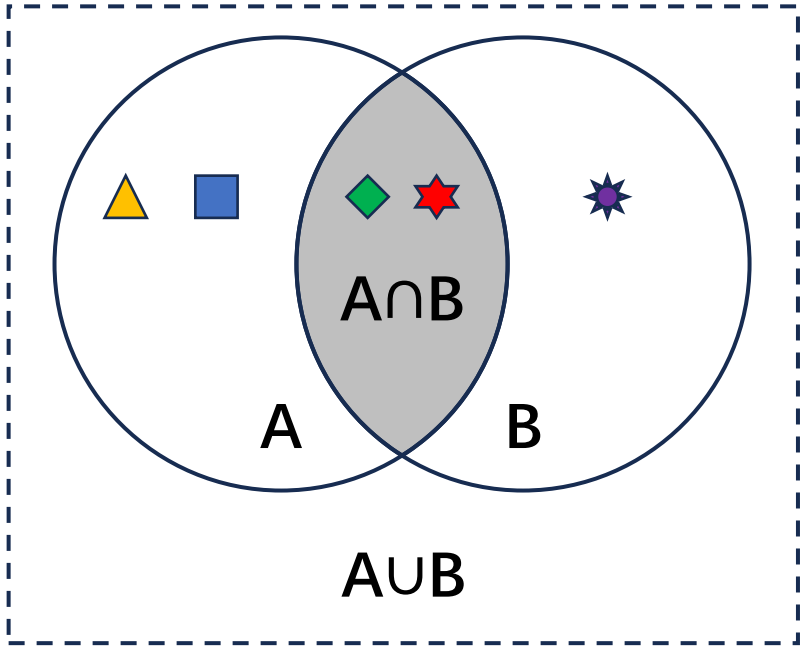

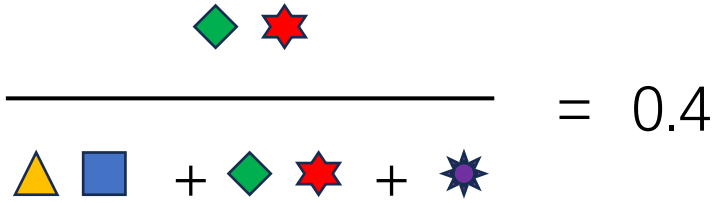

他/她愿意看这部电影吗?

核心问题：相似度的计算

	M1	M2	M3	M4	M5	M6	M7
大壮	4	3	?		5		4
丧彪	3			3	4		
小美	1		3	2			

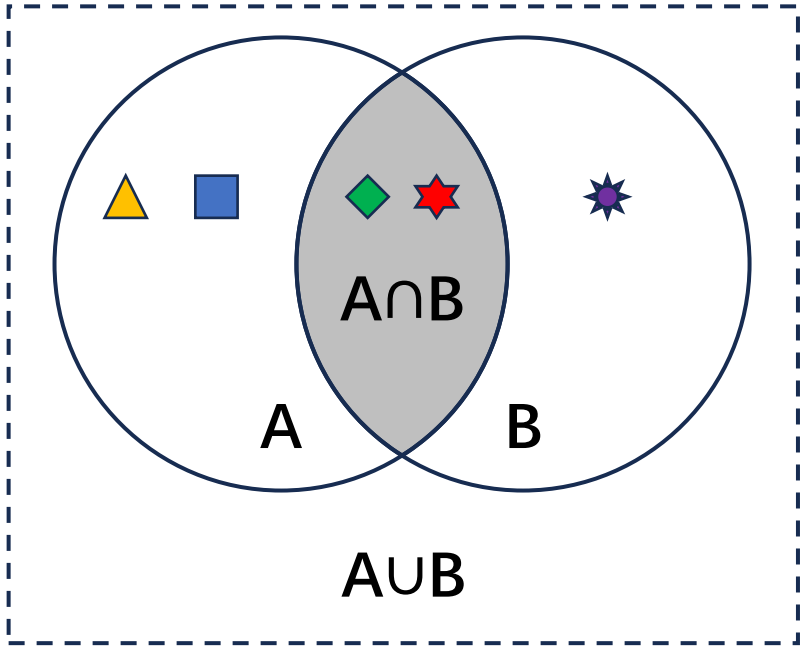

① Jaccard相似系数: $\frac{|\mathbf{A} \cap \mathbf{B}|}{|\mathbf{A} \cup \mathbf{B}|} \in [0, 1]$

② 余弦相似度:

$$\cos(\mathbf{A}, \mathbf{B}) = \frac{|\mathbf{A} \cap \mathbf{B}|}{\sqrt{|\mathbf{A}| \times |\mathbf{B}|}} \in [0, 1]$$

$$\cos(\mathbf{A}, \mathbf{B}) = \frac{2}{\sqrt{4 \times 3}} = 0.58$$

他/她愿意看这部电影吗？

核心问题：相似度的计算

	M1	M2	M3	M4	M5	M6	M7
大壮	4	3	**0?**	0	5	0	4
丧彪	3	0	0	3	4	0	0
小美	1	0	3	2	0	0	0

① Jaccard相似系数：$\dfrac{|\mathbf{A} \cap \mathbf{B}|}{|\mathbf{A} \cup \mathbf{B}|} \in [0,1]$

② 余弦相似度：

$$\cos(\mathbf{A},\mathbf{B}) = \frac{|\mathbf{A} \cap \mathbf{B}|}{\sqrt{|\mathbf{A}| \times |\mathbf{B}|}} \in [0,1]$$

目标是集合

将评分纳入相似度（* 补全缺失数值）

③ 欧氏距离

$$\sqrt{\sum_{i=1}^{D} (a_i - b_i)^2}$$

④ 曼哈顿距离

$$\sum_{i=1}^{D} |a_i - b_i|$$

⑤ 余弦距离

$$\cos(\boldsymbol{\alpha},\boldsymbol{\beta}) = \frac{\boldsymbol{\alpha} \cdot \boldsymbol{\beta}}{\|\boldsymbol{\alpha}\|\|\boldsymbol{\beta}\|}$$

基于用户的协同过滤

	M1	M2	M3	M4	M5	M6	M7
大壮	4	3	?		5		4
丧彪	3			3	4		
小美	1		3	2			
张三		1	3		2	4	2
李四	5	2	2	4		3	

	大壮	丧彪	小美	张三	李四
大壮	1	0.4	0.33	0.5	0.29

① 计算相似度： Jaccard相似系数 $\frac{|\mathbf{A} \cap \mathbf{B}|}{|\mathbf{A} \cup \mathbf{B}|}$

$$sim(\text{大壮}, \text{丧彪}) = \frac{2}{2+2+1} = 0.4$$

$$sim(\text{大壮}, \text{小美}) = \frac{2}{3+1+2} = 0.33$$

$$sim(\text{大壮}, \text{张三}) = \frac{3}{1+3+2} = 0.5$$

$$sim(\text{大壮}, \text{李四}) = \frac{2}{2+2+3} = 0.29$$

基于用户的协同过滤

	M1	M2	M3	M4	M5	M6	M7
大壮	4	3	3		5		4
丧彪	3			3	4		
小美	1		3	2			
张三		1	3		2	4	2
李四	5	2	2	4		3	

	大壮	丧彪	小美	张三	李四
大壮	1	0.4	0.33	0.5	0.29

未打分不考虑

以最相似的Top k个用户作为参考

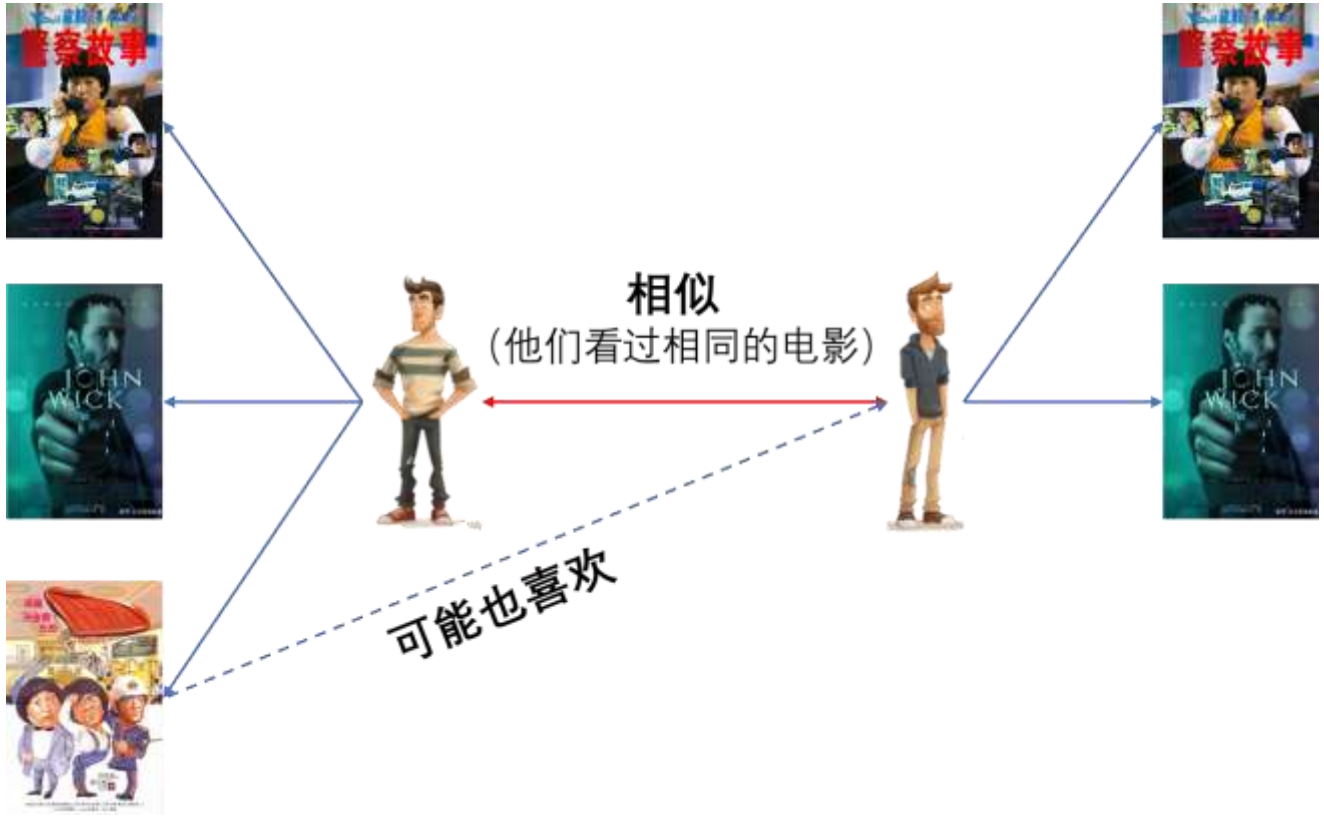

$$R_{M3} = \frac{\sum_{i=1}^{U} s_i R_{M3}}{\sum_{i=1}^{U} s_i} = \frac{0.33 \times 3 + 0.5 \times 3}{0.33 + 0.5} = 3$$

基于用户的协同过滤

	M1	M2	M3	M4	M5	M6	M7
大壮	4	3	3		5		4
丧彪	3			3	4		
小美	1		3	2			
张三		1	3		2	4	2
李四	5	2	2	4		3	

⬇ 用户相似度表

	大壮	丧彪	小美	张三	李四
大壮	1	0.4	0.33	0.5	0.29
丧彪	0.4	1	0.4	0.17	0.33
小美	0.33	0.4	1	0.14	0.6
张三	0.5	0.17	0.14	1	0.43
李四	0.29	0.33	0.6	0.43	1

① 计算（更新）用户相似度矩阵

② 对目标用户的用户相似度进行排序

	大壮	张三	丧彪	小美	李四
大壮	1	0.5	0.4	0.33	0.29

③ 取前k个对M3评过分的用户作为参考

④ 计算评分的加权平均值作为结果

$$R_{M3} = \frac{\sum_{i=1}^{U} s_i R_{M3}}{\sum_{i=1}^{U} s_i}$$

⑤ 电影推荐：判断预测评分是否超过阈值

基于物品的协同过滤

	M1	M2	M3	M4	M5	M6	M7
大壮	4	3	?		5		4
丧彪	3			3	4		
小美	1		3	2			
张三		1	3		2	4	2
李四	5	2	2	4		3	

物品相似度

	M1	M2	M3	M4	M5	M6	M7
M1	1	0.4	0.4	0.75	0.4	0.2	0.2
M2	0.4	1	0.5	0.2	0.5	0.67	0.67
M3	0.4	0.5	1	0.5	0.2	0.67	0.25
M4	0.75	0.2	0.5	1	0.2	0.25	0
M5	0.4	0.5	0.2	0.2	1	0.25	0.67
M6	0.2	0.67	0.67	0.25	0.25	1	0.33
M7	0.2	0.67	0.25	0	0.67	0.33	1

ItemCF与UserCF具有相同的逻辑

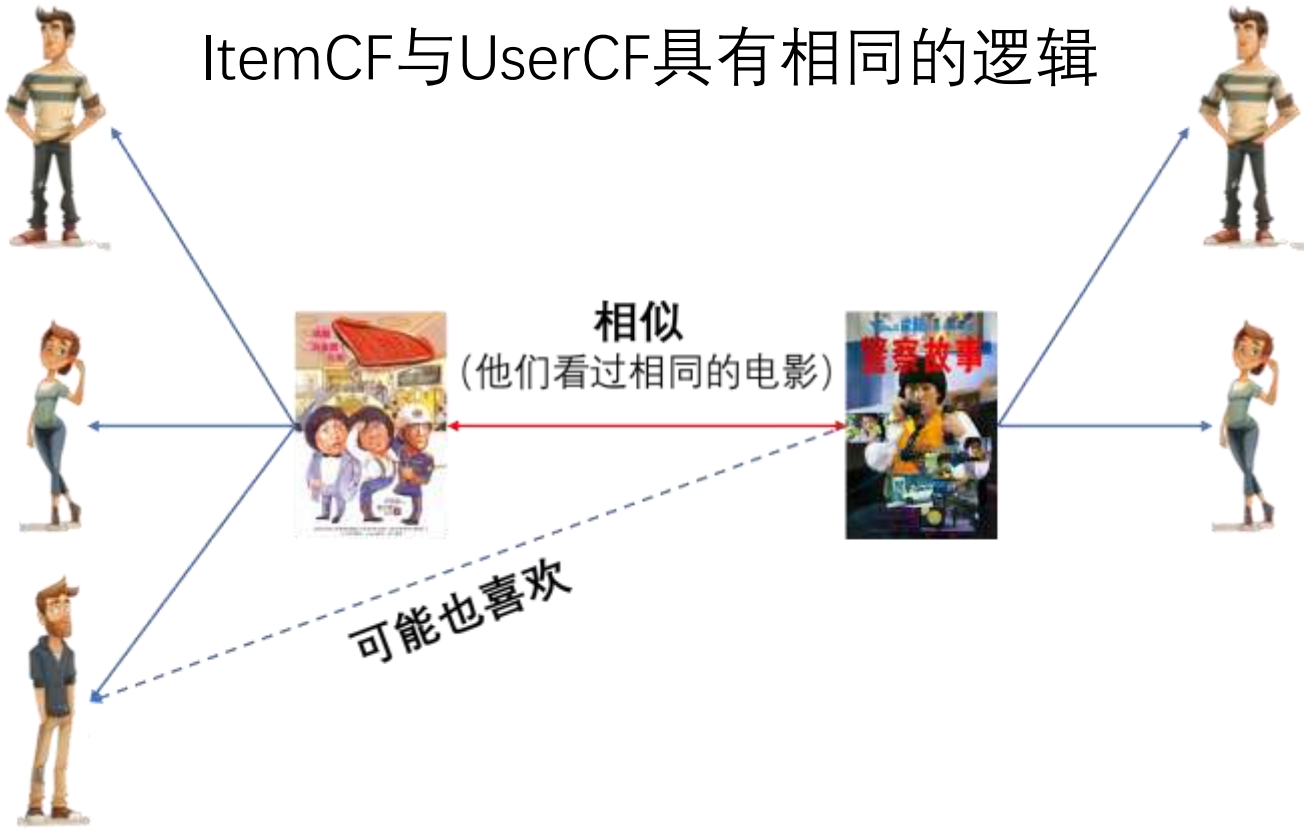

$$sim(M1, M2) = \frac{2}{2+2+1} = 0.4$$

基于物品的协同过滤

	M1	M2	M3	M4	M5	M6	M7
大壮	4	3	?		5		4
丧彪	3			3	4		
小美	1		3	2			
张三		1	3		2	4	2
李四	5	2	2	4		3	

	M1	M2	M3	M4	M5	M6	M7
M1	1	0.4	0.4	0.75	0.4	0.2	0.2
M2	0.4	1	0.5	0.2	0.5	0.67	0.67
M3	0.4	0.5	1	0.5	0.2	0.67	0.25
M4	0.75	0.2	0.5	1	0.2	0.25	0
M5	0.4	0.5	0.2	0.2	1	0.25	0.67
M6	0.2	0.67	0.67	0.25	0.25	1	0.33
M7	0.2	0.67	0.25	0	0.67	0.33	1

物品相似度

① 计算（更新）物品相似度矩阵

② 对目标物品M3的物品相似度进行排序

	M3	M6	M2	M4	M1	M7	M5
M3	1	0.67	0.5	0.5	0.4	0.25	0.2

③ 取大壮看过的前k个与M3相似物品作参考

④ 计算评分的加权平均值作为结果

$$R_{M3} = \frac{\sum_{i=1}^{M} s_i R_i}{\sum_{i=1}^{M} s_i} = \frac{0.5 \times 3 + 0.4 \times 4}{0.5 + 0.4} = 3.4$$

⑤ 电影推荐：判断预测评分是否超过阈值

UserCF vs ItemCF

	UserCF	ItemCF
适用场景	• 用户数量 « 物品数量 • 适用物品时效性强、更新快 • 新闻、短视频	• 物品数量 « 用户数量 • 长尾物品丰富，适用用户个性化需求强烈的领域 • 购物商城
对用户行为的敏感性	【较低】在用户相似表更新前，推荐结果不随用户新行为发生变化	【较高】只要用户对物品产生行为，就能推荐类似的物品
对物品更新的敏感性	【较高】新物品上线后，一旦与用户发生交互，就能将其推荐给其他相似用户	【较低】在物品相似表更新前，没办法将其推荐给用户
合理性	用户交互行为稀疏时，相似用户的判断结果可信度低，推荐结果合理性较低	根据用户个人的历史行为判断，合理性较高

推荐技术不止如此

协同过滤的缺点

- 无法解决数据稀疏性的问题

	M1	M2	M3	M4	M5	M6	M7
大壮	1						
丧彪		3					
小美				4			
张三					2		
李四							5

用户相似度

	大壮	丧彪	小美	张三	李四
大壮	0	0	0	0	0
丧彪	0	0	0	0	0
小美	0	0	0	0	0
张三	0	0	0	0	0
李四	0	0	0	0	0

物品相似度

	M1	M2	M3	M4	M5	M6	M7
M1	0	0	0	0	0	0	0
M2	0	0	0	0	0	0	0
M3	0	0	0	0	0	0	0
M4	0	0	0	0	0	0	0
M5	0	0	0	0	0	0	0
M6	0	0	0	0	0	0	0
M7	0	0	0	0	0	0	0

推荐技术不止如此

协同过滤的缺点

- 无法解决数据稀疏性的问题
- 泛化能力弱

	M1	M2	M3	M4	M5	M6	M7
丧彪		3					1
小美			1	4			1
张三	2				2		1
李四		4				1	1

物品相似度

	M1	M2	M3	M4	M5	M6	M7
M1	1	0	0	0	1	0	0.25
M2	0	1	0	0	0	0.5	0.5
M3	0	0	1	1	0	0	0.25
M4	0	0	1	1	0	0	0.25
M5	1	0	0	0	1	0	0.25
M6	0	0.5	0	0	0	1	0.25
M7	0.25	0.5	0.25	0.25	0.25	0.25	1

大壮	M1	M2	M3	M4	M5	M6
荐1	M5	M6	M4	M3	M1	M2
荐2	M7	M7	M7	M7	M7	M7
荐3	M2	M1	M1	M1	M2	M1

推荐技术不止如此

协同过滤的缺点

- 无法解决数据稀疏性的问题
- 泛化能力弱
- 无法利用更多的信息

回到MovieLens

采用UserCF的方式估计对动作电影评分和动画电影的评分

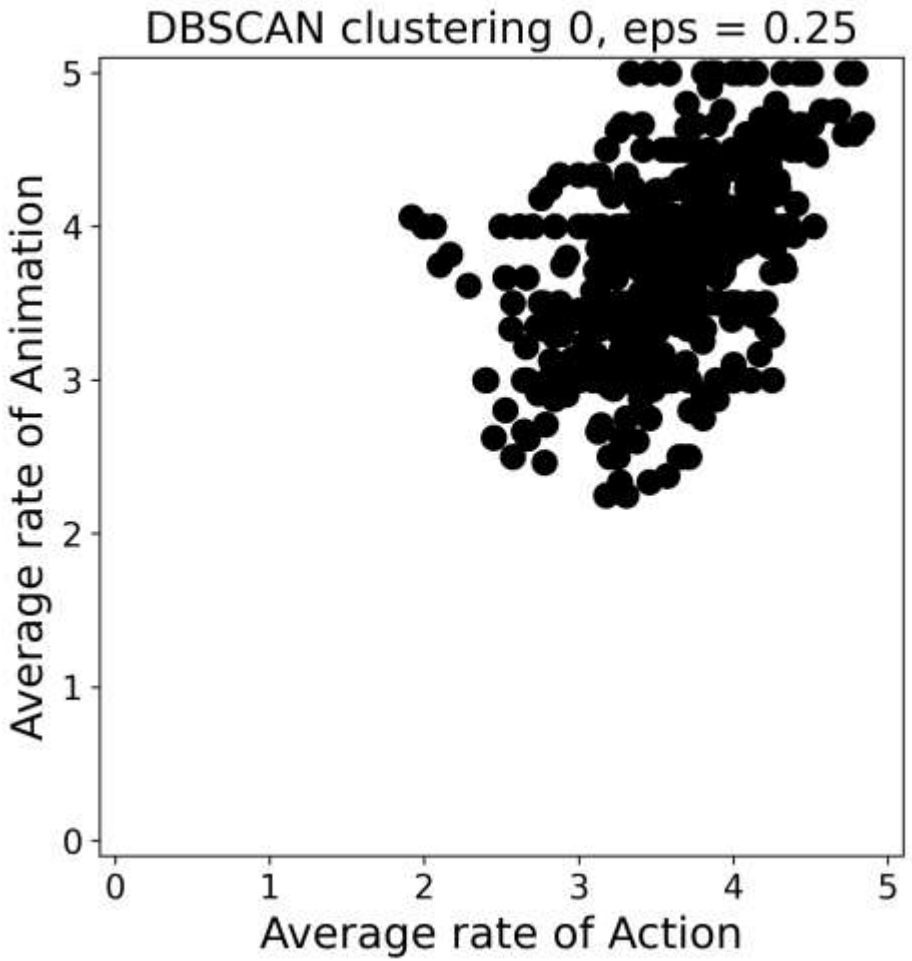

用户数量：468

电影数量：51

相似度计算方法：Jaccard

回到MovieLens

采用热力图直观的展示评分情况

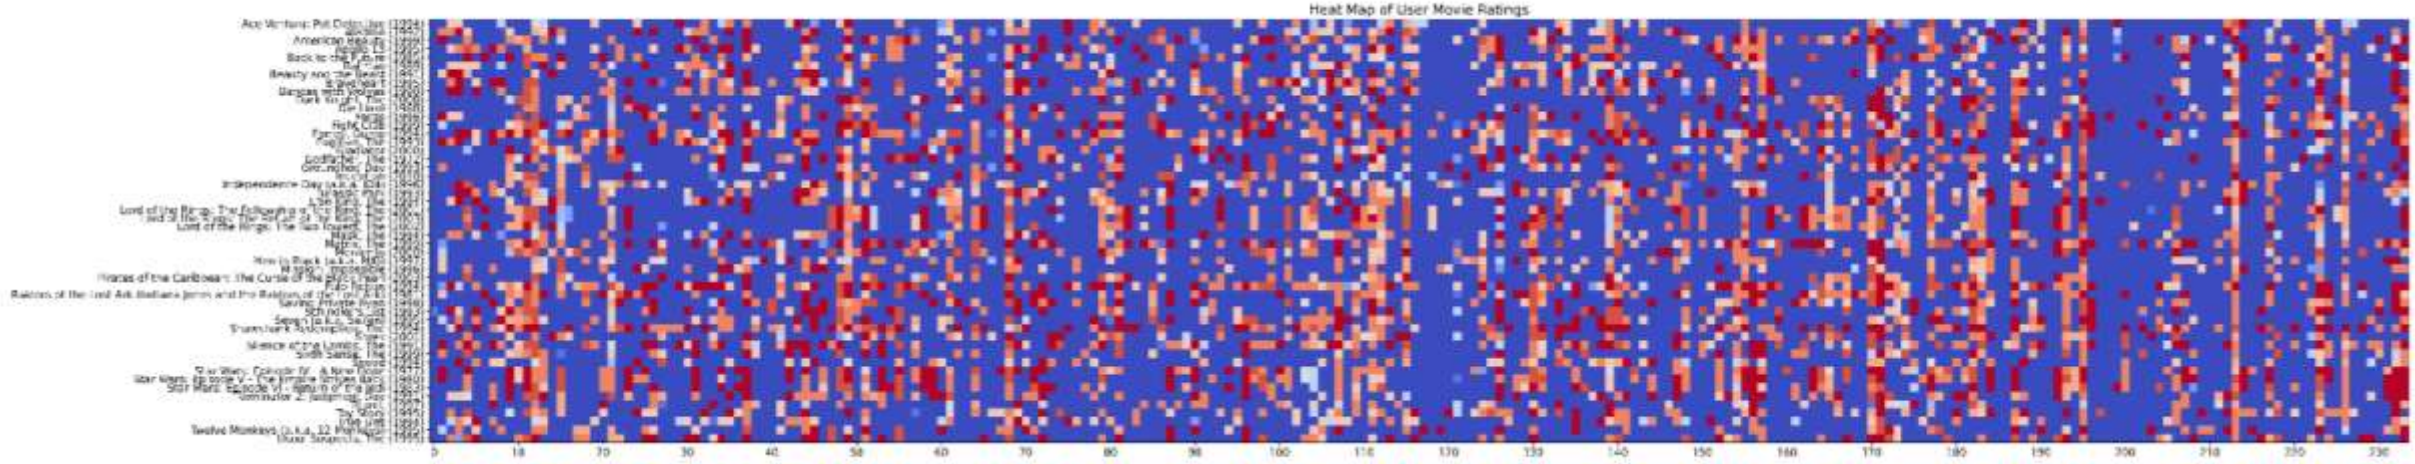

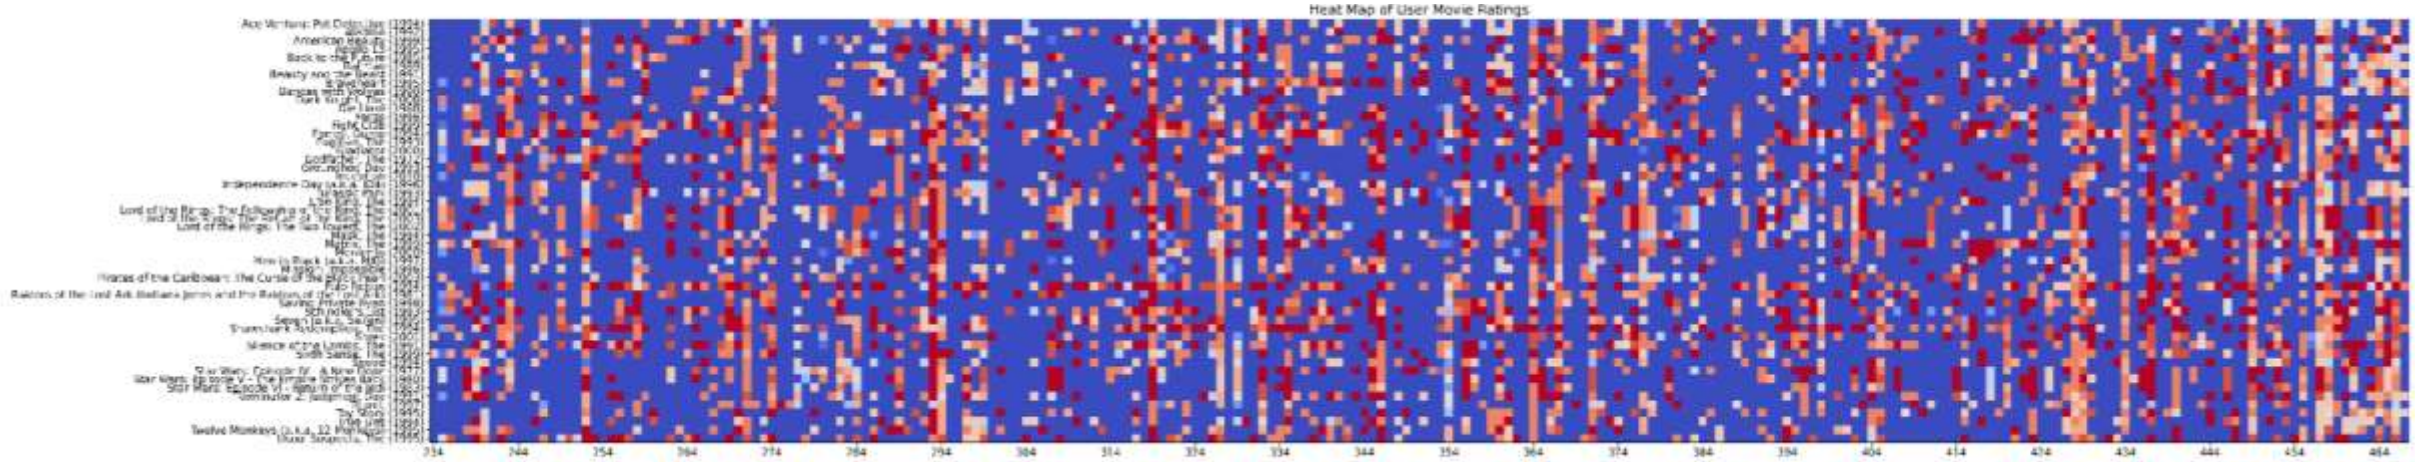

回到MovieLens

按照评分数量排序　　靠前的用户观影较多判断结果较合理

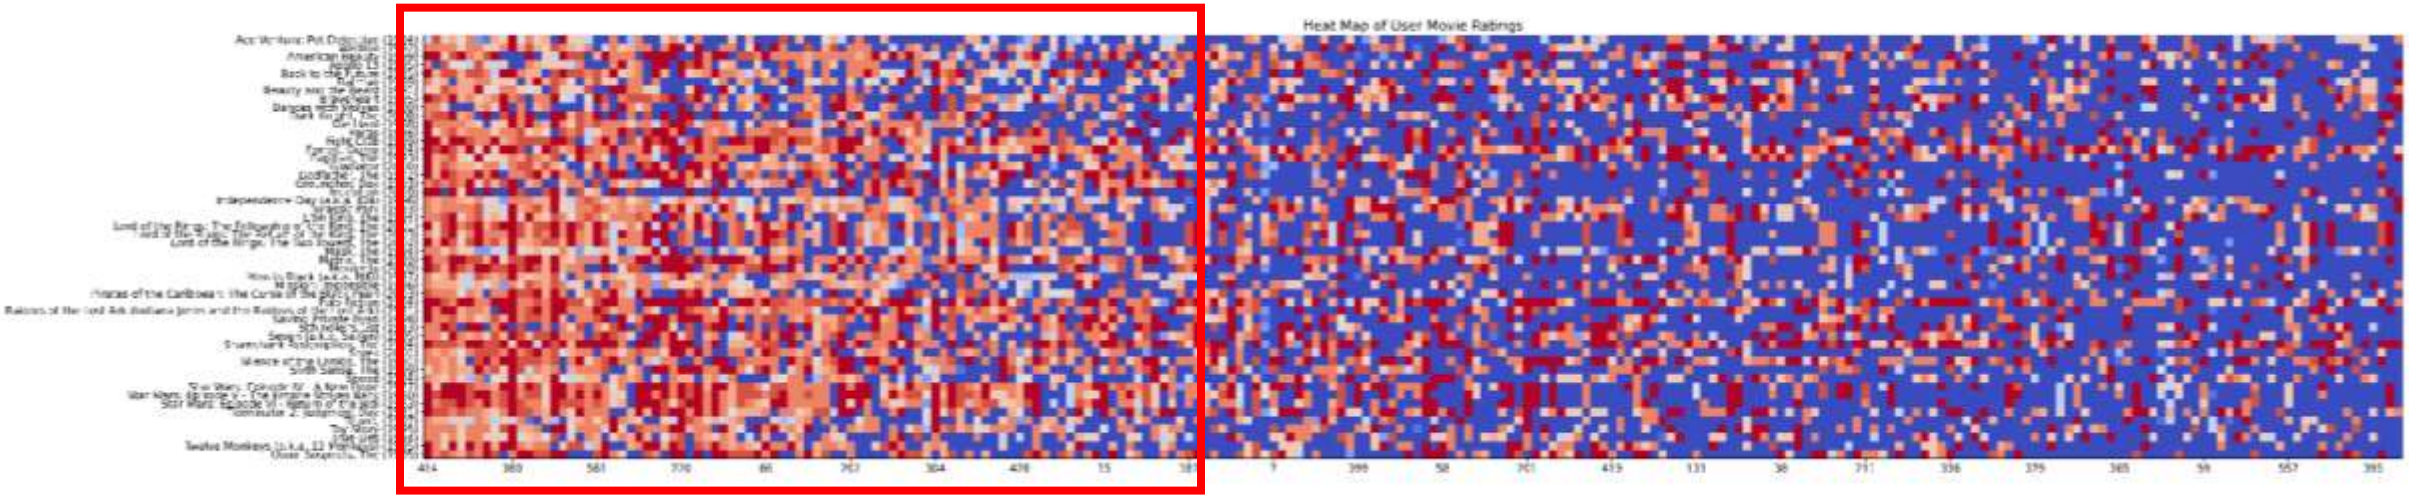

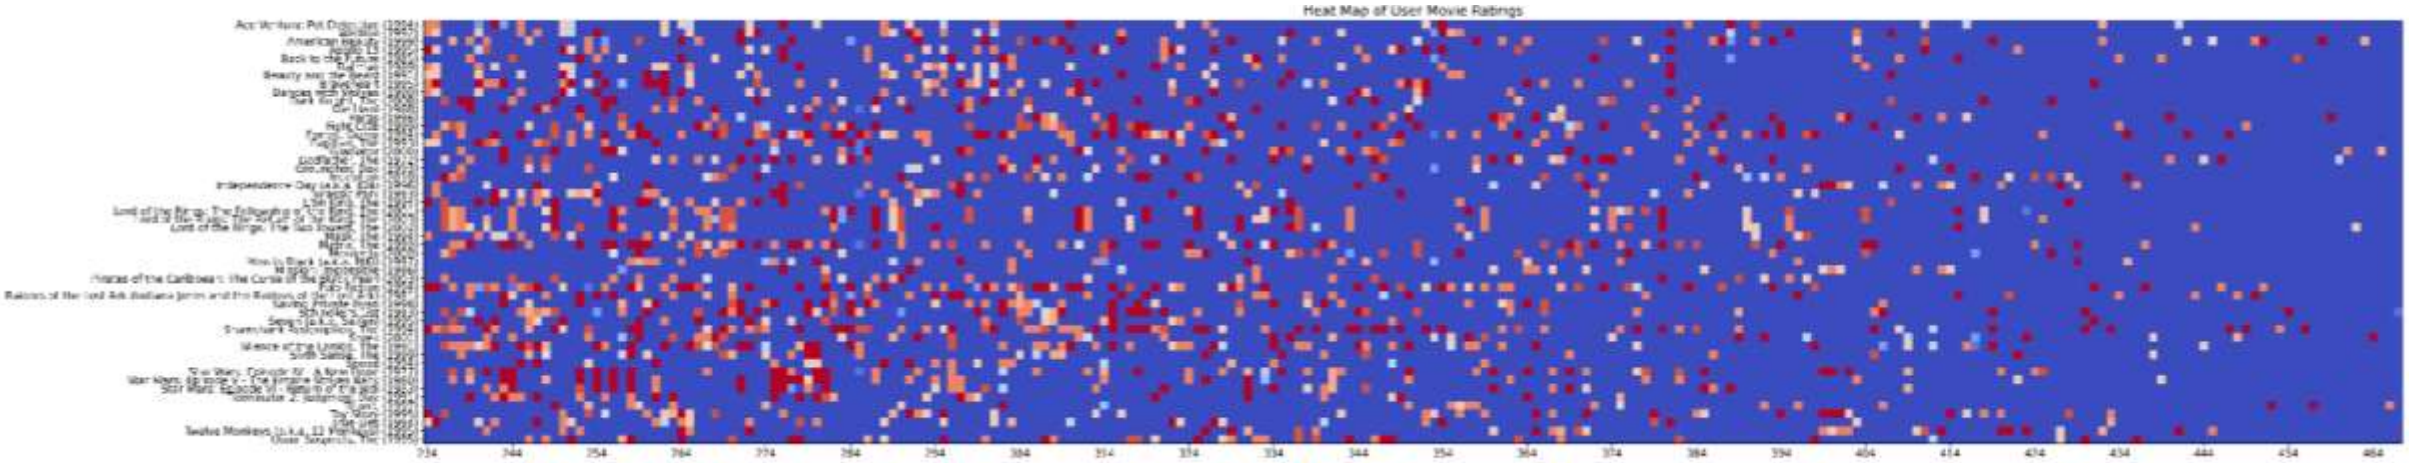

回到MovieLens

取前100个用户进行分析

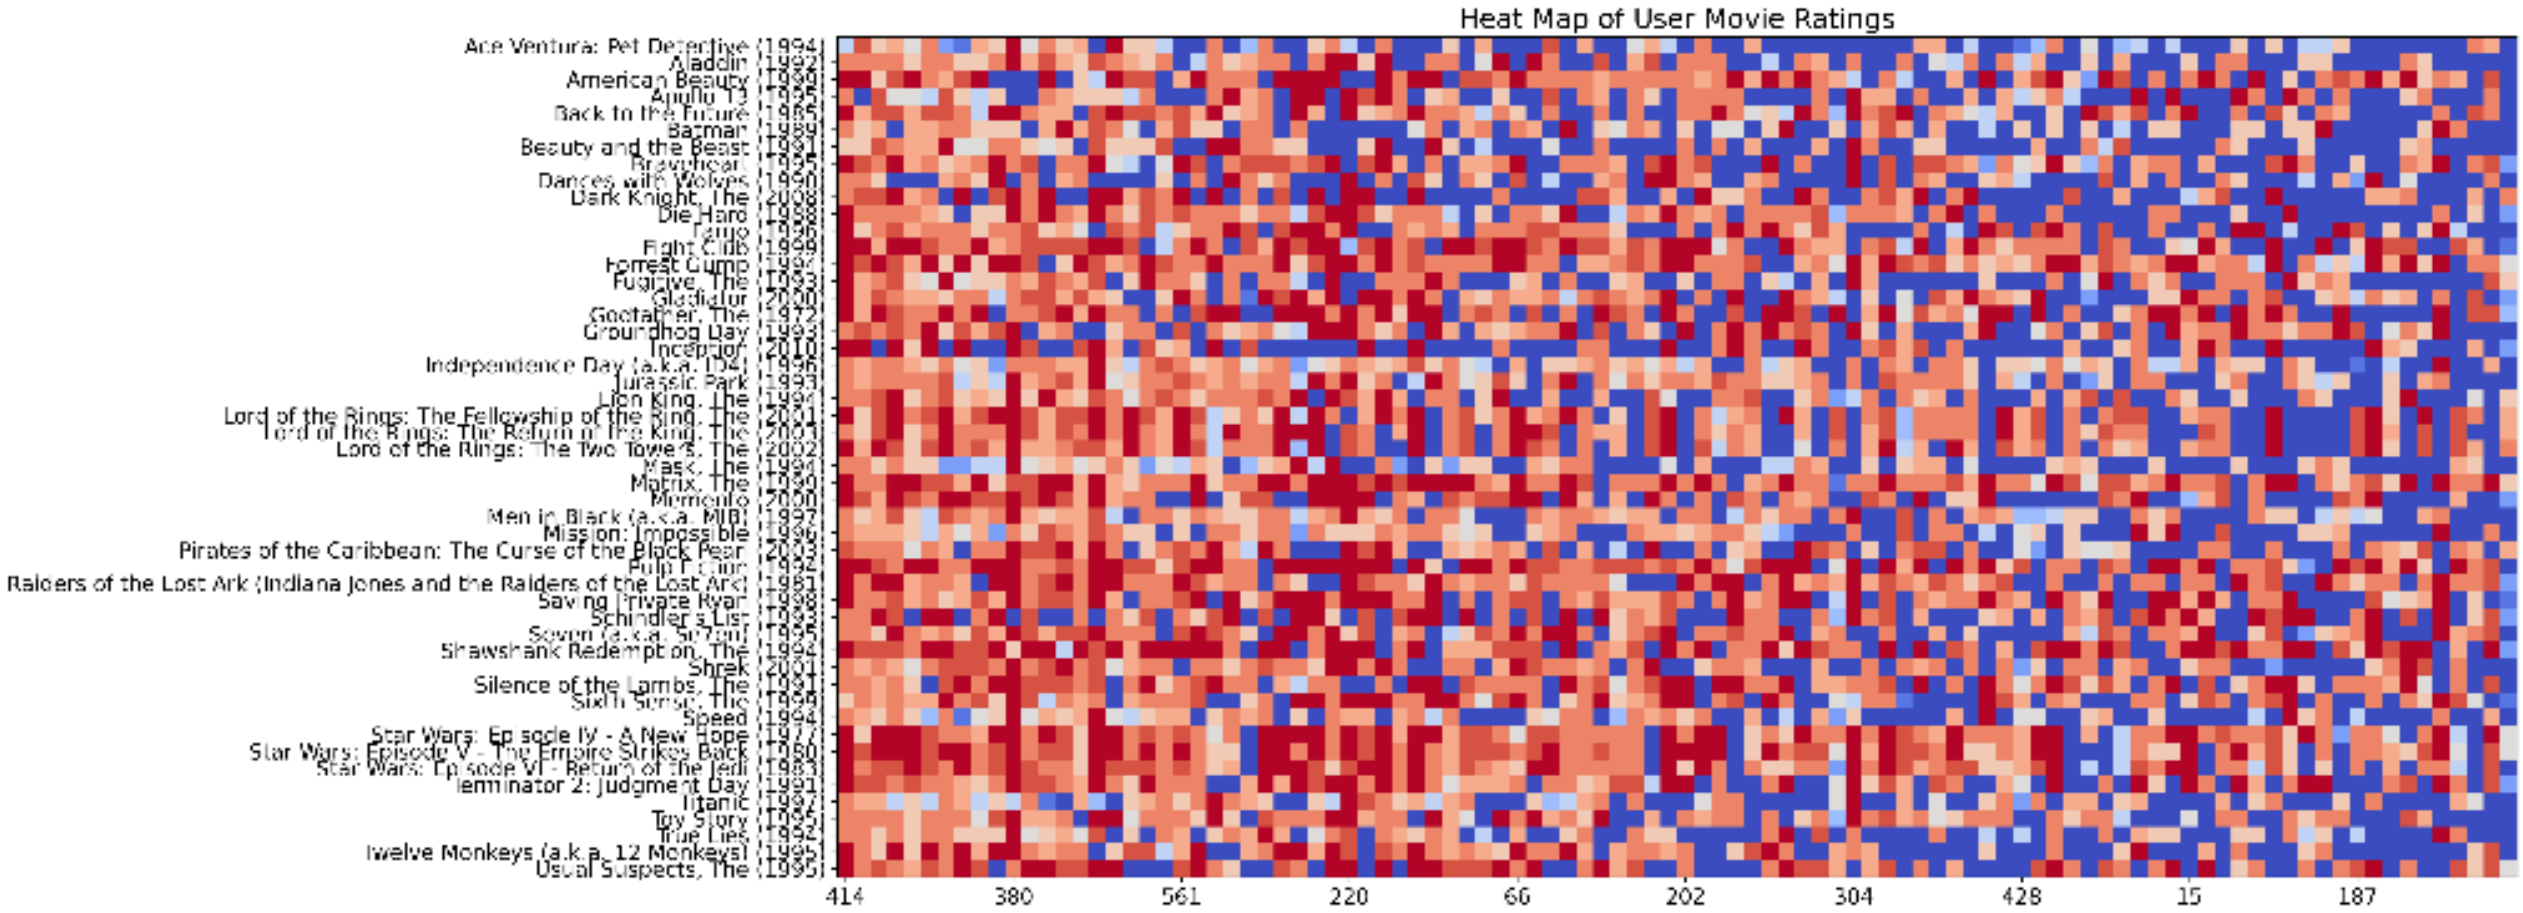

回到MovieLens

对未评分的电影进行估计，决定是否推荐

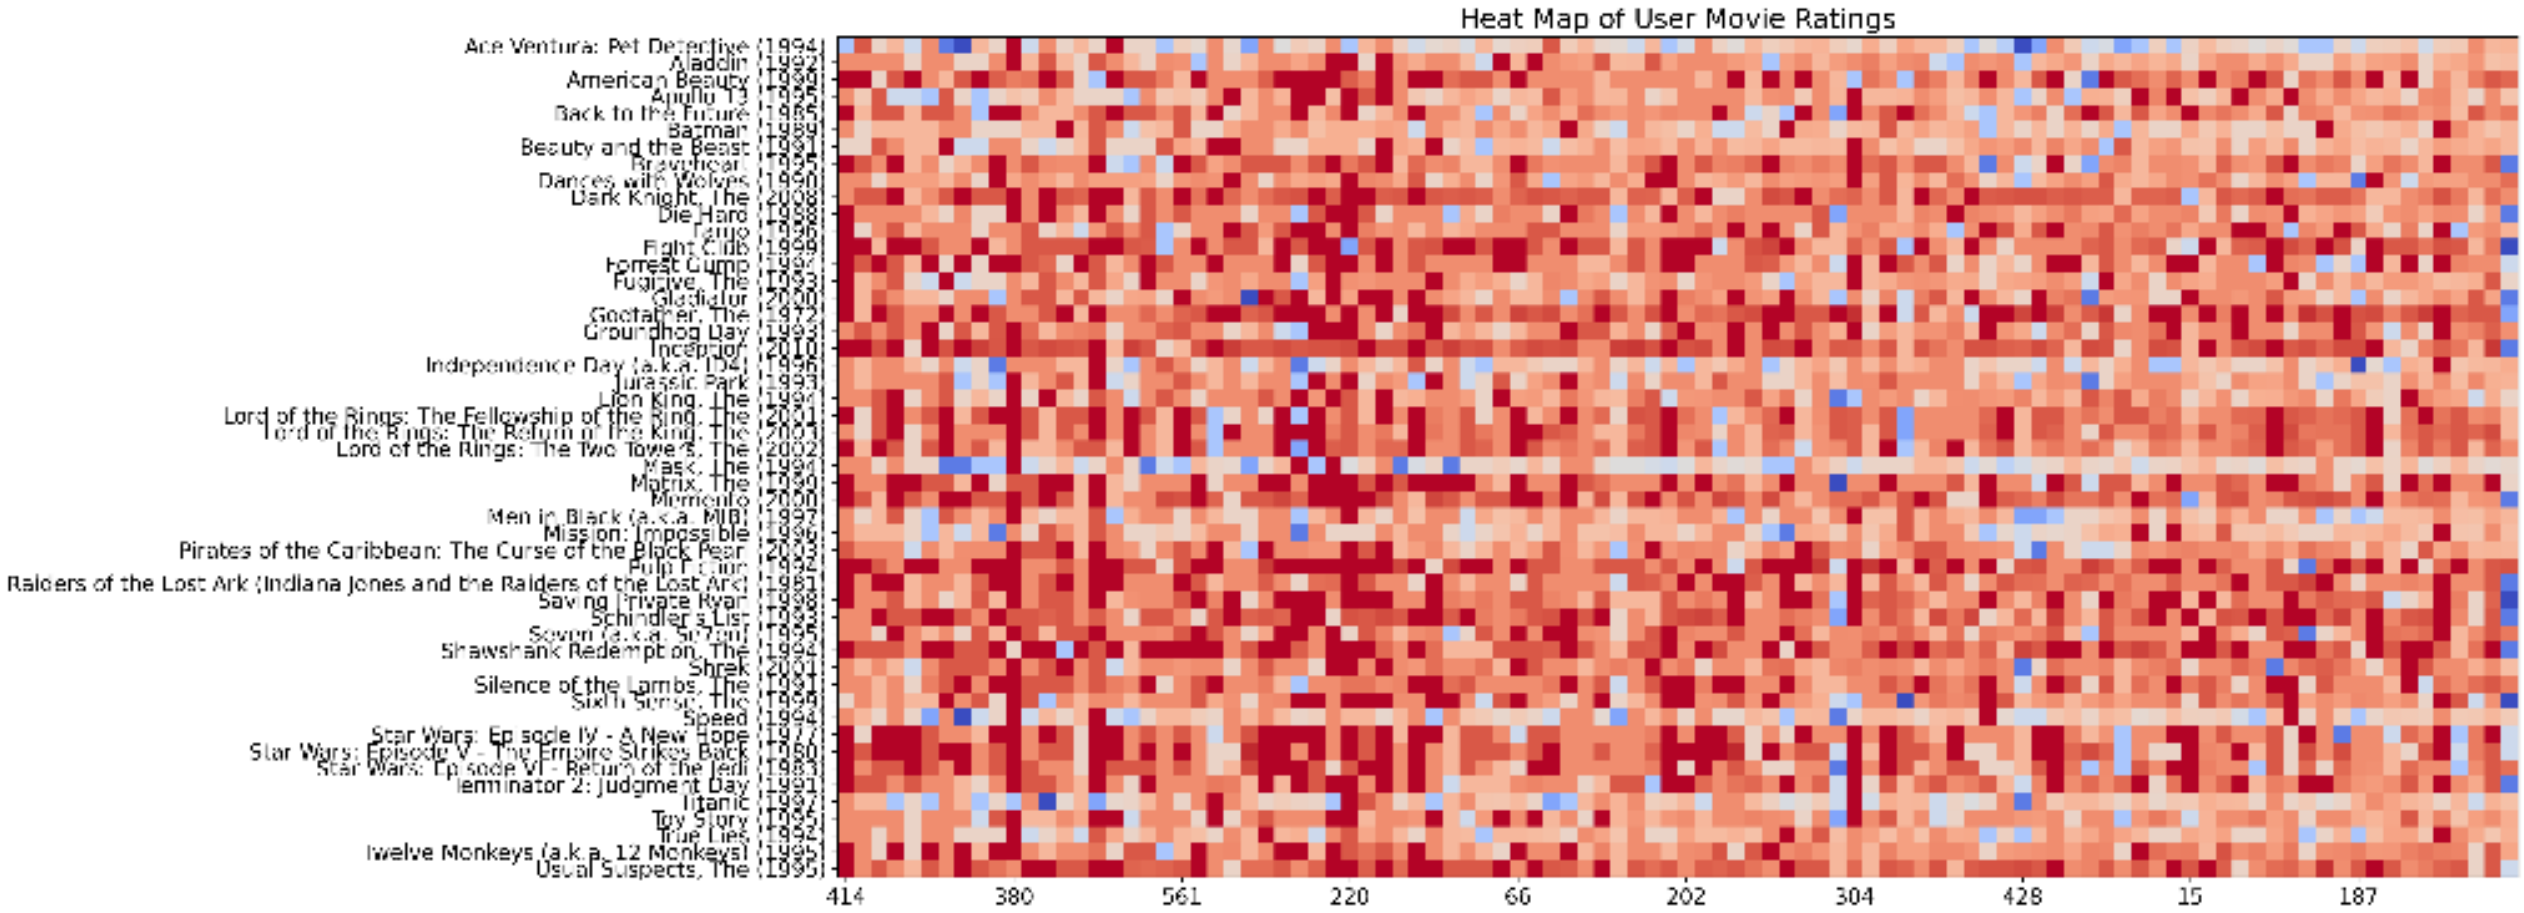

小结

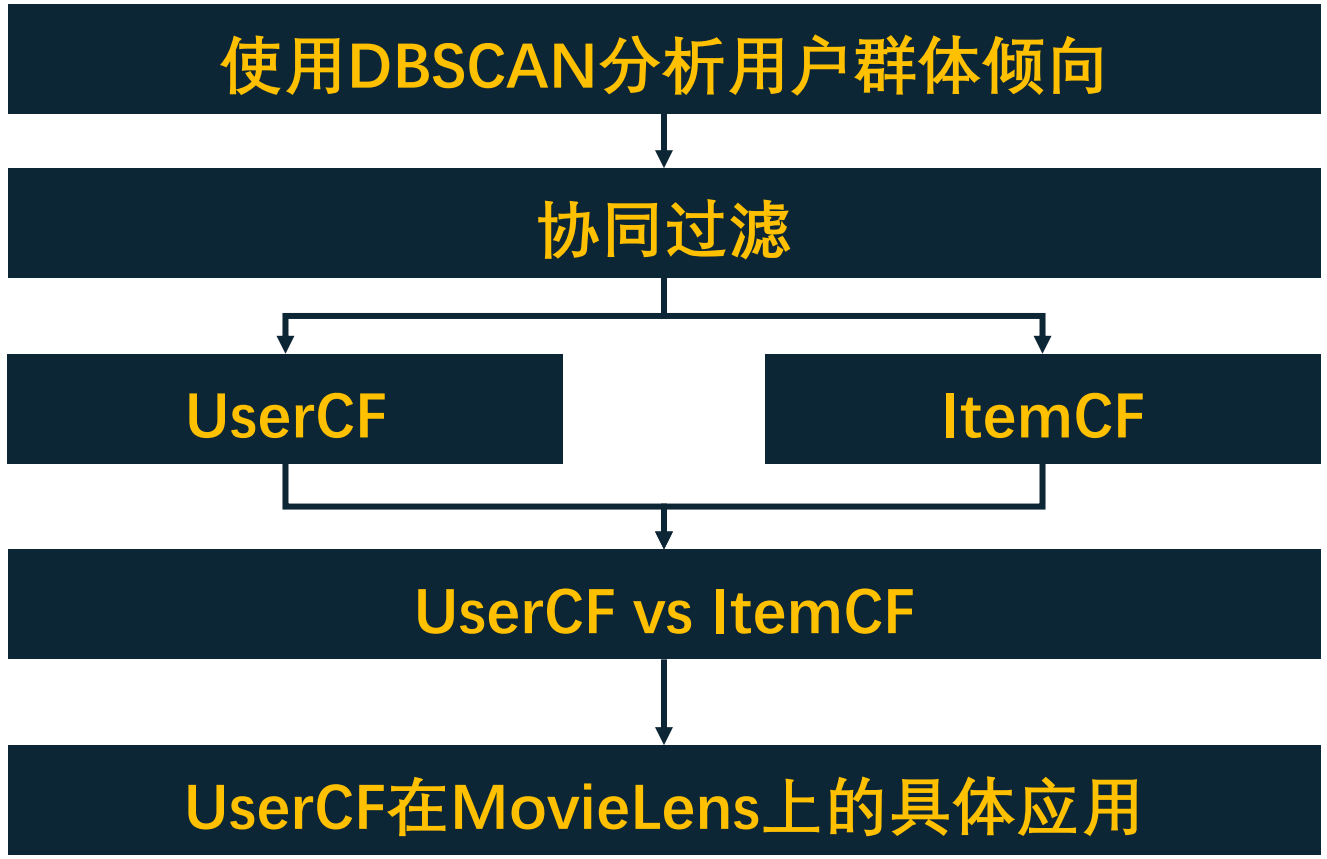
使用DBSCAN分析用户群体倾向
协同过滤
UserCF
ItemCF
UserCF vs ItemCF
UserCF在MovieLens上的具体应用